UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

APRENDIZADO SIMBÓLICO

PARTE 1

Prof. Cesar Augusto Tacla

http://www.pessoal.utfpr.edu.br/tacla

UTFPR/Campus Curitiba

- **Fundamentos**
  - Aprendizado, generalização, indução e viés (*bias*), medidas de desempenho

- **Indutivo** *(Inductive Learning)*
  Não utilizam K a priori do domínio para guiar a generalização, muitos dados de treinamento, supervisionado
  - Aprendizado de conceitos: *version space search* e **ID3**
  - Influência do viés indutivo no aprendizado

- **Baseado em explicação** *(Explanation-based Learning)*
  Utilizam K (conhecimento) a priori do domínio para guiar generalização, poucos dados de treinamento (ex. aprendizado por analogia), supervisionado

- **Não-supervisionado**
  Estudo da indução com dados de treinamento não categorizados. Algoritmos de agrupamento (*clustering*) CLUSTER/2 e COBWEB

- **Por Reforço** *(Reinforcement Learning)*
  O agente está situado num ambiente onde atua e recebe *feedback*. O agente deve interpretar o *feedback* e criar uma estratégia de ação.

Luger, G. F. Artificial Intelligence: Structures and Strategies for Complex Problem Solving, 5ª. Edição, Addison Wesley. → CAPÍTULO 10

Russel, S. e Norvig, P. Artificial Inteligence: a Modern Approach, 3ª. Edição, em inglês → capítulo 18

WEKA
http://www.cs.waikato.ac.nz/ml/weka/

1

FUNDAMENTOS

“Any change in a system that allows it to perform better the second time on repetition of the same task or on another task drawn from the same population”.

(Simon, 1983)

Questões em aprendizado

Generalização: um *learner* examina somente uma fração de todos os exemplos possíveis; a partir desta experiência limitada o *learner* deve ser capaz de generalizar seu conhecimento (*aplicá-lo*) para instâncias não previamente examinadas do domínio.

Indução: na maior parte dos problemas, os dados disponíveis não são suficientes para generalizar de forma ótima. Então os *learners* devem selecionar os aspectos/atributos daquela experiência limitada que se mostram mais efetivos em generalizações futuras.

Viés de indução se refere a quais aspectos (ou critérios/atributos) são selecionados para serem utilizados em generalizações de exemplos não vistos.

Continua …

Questões em aprendizado

Mudanças no *learner*:
aprendizado envolve mudanças no "código" do learner. O problema é como representá-las!!!

Aprendizado simbólico: aprendizado é a aquisição de conhecimento declarativo sobre um domínio. O *learner* constrói ou modifica **expressões numa linguagem simbólica** (ex. lógica) e guarda este conhecimento para uso futuro. A mudança ocorre na **base de conhecimentos** do *learner*.

Genético e evolucionário o aprendizado não se dá por linguagem simbólica, mas por por uma **função de *fitness*** que melhora com o tempo.

Redes neurais o aprendizado não se dá por linguagem simbólica, mas **por mudanças na estrutura da rede** (pesos e parâmetros).

SUPERVISIONADO: o programa é treinado com um conjunto de exemplos $(x_1, y_1), \ldots, (x_N, y_N)$ onde x é uma entrada (x pode ser um vetor de características) e **y é uma saída** (Russel e Norvig, p. 695, 3ed.) – *i.e. a categoria do exemplo é previamente conhecida.*

Exemplo: **x** pode ser um conjunto de sintomas de um paciente e **y**, a doença.

http://www.cs.waikato.ac.nz/ml/weka/

EXEMPLO: exemplos $(x_1, y_1), \ldots, (x_N, y_N)$ x é uma entrada, **y é uma saída**

Table 3.1. A loan application data set

ID	Age	Has_job	Own_house	Credit_rating	Class
1	young	false	false	fair	No
2	young	false	false	good	No
3	young	true	false	good	Yes
4	young	true	true	fair	Yes
5	young	false	false	fair	No
6	middle	false	false	fair	No
7	middle	false	false	good	No
8	middle	true	true	good	Yes
9	middle	false	true	excellent	Yes
10	middle	false	true	excellent	Yes
11	old	false	true	excellent	Yes
12	old	false	true	good	Yes
13	old	true	false	good	Yes
14	old	true	false	excellent	Yes
15	old	false	false	fair	No

Vetor de atributos x_n $\xrightarrow{f(x_n)}$ y_n

B. Liu, *Web Data Mining: Exploring Hyperlinks, Contents, and Usage Data*, Data-Centric Systems and Applications, DOI 10.1007/978-3-642-19460-3_3,
© Springer-Verlag Berlin Heidelberg 2011

Descoberta de função

Cada $\mathbf{y_j}$ é gerado por uma função desconhecida ***y=f(x)***.

Algoritmos de aprendizado supervisionado tentam descobrir uma função ***h*** que se aproxima da função real ***f***.

Por que supervisionado?

É supervisionado porque os valores y_j são dados por um supervisor/especialista → são conhecidos *a priori*.

APRENDIZADO COMO BUSCA NUM ESPAÇO DE ESTADOS:
A função ***h*** (slide anterior) é uma hipótese sobre a função *y=f(x)* (desconhecida).

Aprendizado é **uma busca por UMA hipótese** num espaço de hipóteses possíveis que tenha bom desempenho (ex. boa capacidade de generalização) em exemplos diferentes daqueles utilizados no treinamento.

FUNÇÃO h
A função h pode ser **estocástica** quando não depende exclusivamente de x (das entradas). Neste caso, o que deve ser aprendido é uma distribuição de probabilidade condicional P(y/x)
→ *aprendizado probabilístico – qual a probabilidade de ser ter a saída y dada a entrada x?*

CONJUNTO DE DADOS (DATASET) DE TREINAMENTO
Conjunto utilizado para calibrar a hipótese (encontrar uma boa hipótese). De outra forma, para aprender um modelo de classificação (ou de outro tipo).

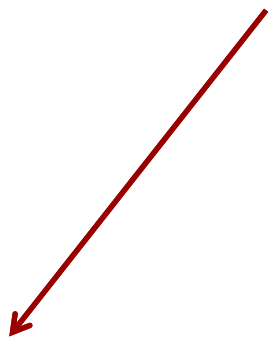
CONJUNTO DE DADOS (DATASET) DE TESTE
É um conjunto de exemplos utilizado para medir a acuracidade da hipótese aprendida por meio de treinamento.

Tipos de aprendizado em relação à saída y

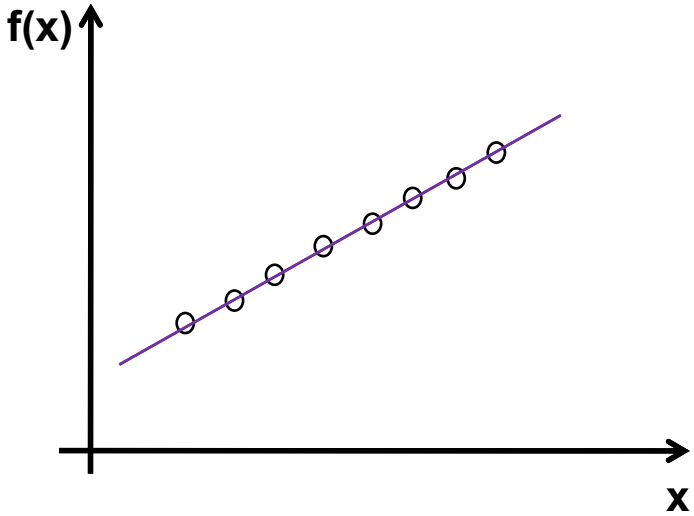


De classificação: quando y é um conjunto finito de valores (ex. ensolarado, nublado ou chuvoso)

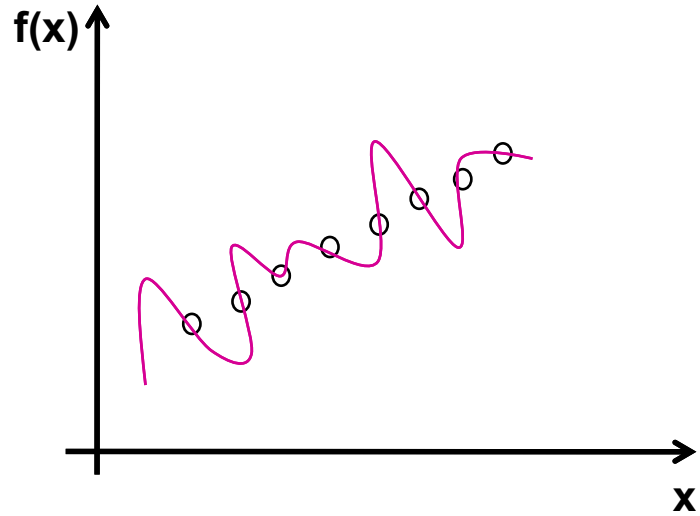
De regressão quando y é um número (ex. valor de uma ação na bolsa amanhã)



binária ou Booleana quando só há dois valores ou categorias possíveis. Também chamado de ***concept learning***.



A função *h* é uma função polinomial 0.4x + 3 **consistente** com os dados de treinamento



A função *h* é uma função polinomial de grau mais alto que a vizinha, e também é **consistente** com os dados de treinamento

Como escolher uma hipótese h do espaço de hipóteses H se todas são consistentes?

A mais simples, segundo o princípio da navalha de Ockham (*Ockham's razor*). *A escolha da hipótese mais simples ajuda a encontrar a verdadeira hipótese.*

Em geral, deve haver um **equilíbrio entre hipóteses complexas** que se adaptam bem aos dados de treinamento* e **hipóteses simples** que podem ter maior capacidade de generalização.

(Russel e Norvig, p. 696)

**Overfitting*: é um problema relacionado à adaptação EXCESSIVA aos dados de treinamento, dificultando generalização para outros dados de teste.

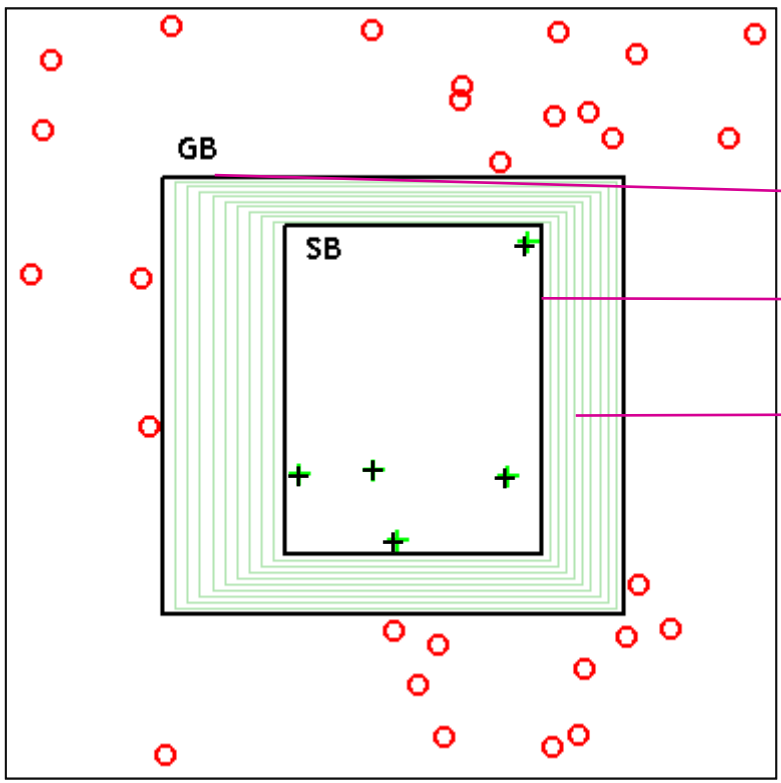
2 APRENDIZADO INDUTIVO

2 APRENDIZADO INDUTIVO

2.1 VERSION SPACE SEARCH

Algoritmo proposto por Mitchell em 1975

Um **espaço de versões** *(version space)* em *concept learning* ou em aprendizado indutivo é o **subconjunto de todas as hipóteses** que são consistentes com os exemplos de treinamento (Mitchell 1997).



GB: hipótese positiva mais geral
General boundary

SB: hipótese positiva mais específica
Specific boundary

Hipóteses no espaço de versões

\+ Exemplo positivo
o Exemplo negativo

[fonte http://en.wikipedia.org/wiki/File:Version_space.png]

Um **espaço de hipóteses potencial** é definido pela linguagem e pelas operações possíveis.

Exemplo:
Linguagem: lógica de primeira ordem
Operações: vários tipos de generalização (vide abaixo)

Substituição de constantes por variáveis:
cor(bola, vermelha) *pode ser generalizada para* cor(**x**, vermelha)

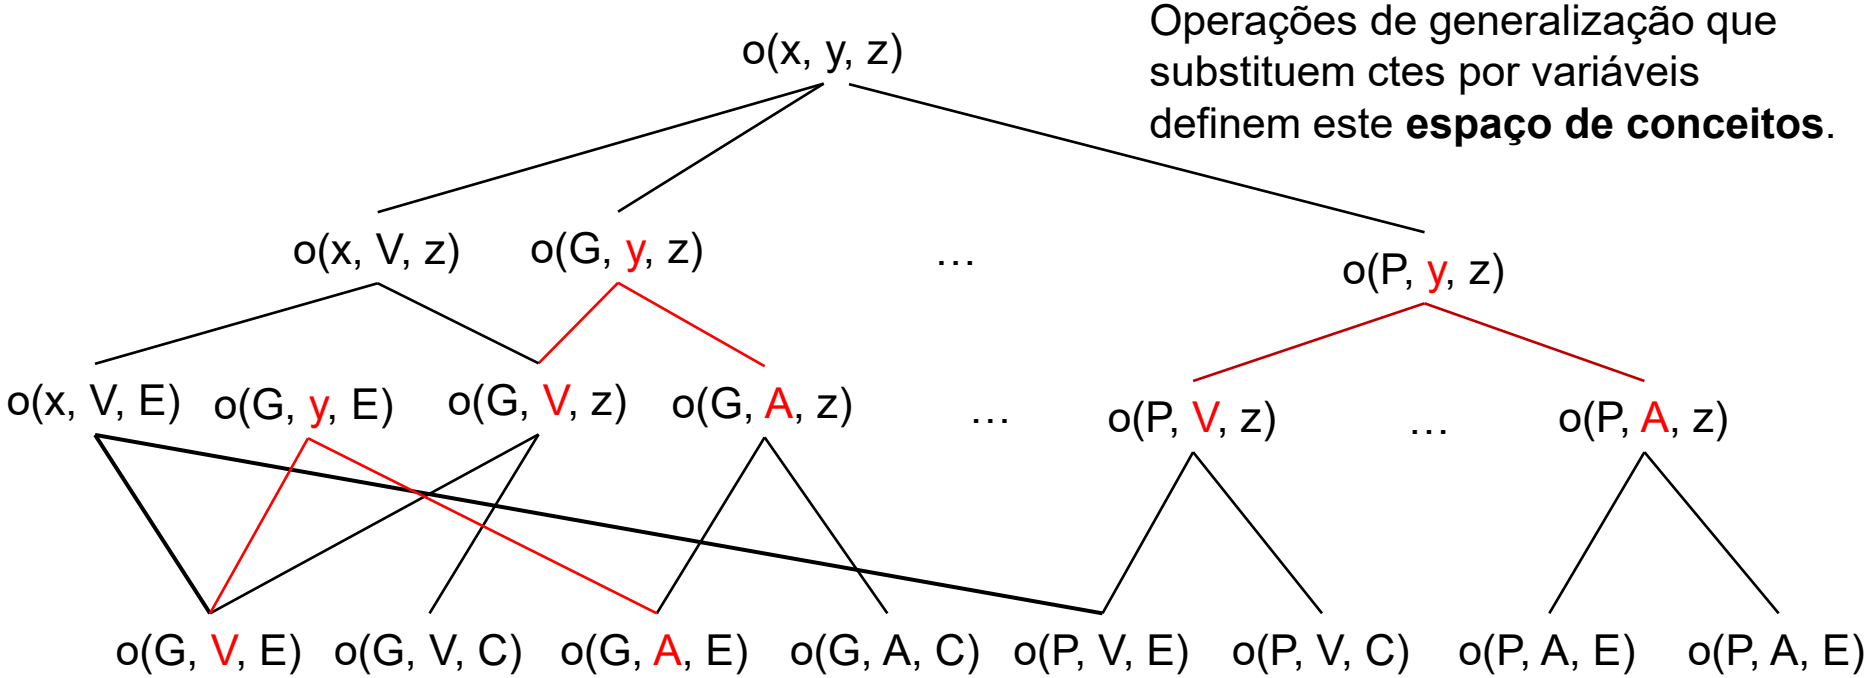
Descarte de condições de sentenças conjuntivas
forma(x, redonda) $\wedge$ tamanho(x, pequena) $\wedge$ cor(x, vermelha)
pode ser generalizada para
forma(x, redonda) $\wedge$ tamanho(x, pequena) ~~$\wedge$ cor(x, vermelha)~~

Adição de uma disjunção
forma(x, redonda) $\wedge$ tamanho(x, pequena) $\wedge$ cor(x, vermelha)
pode ser generalizada para
forma(x, redonda) $\wedge$ tamanho(x, pequena) $\wedge$ (cor(x, vermelha) $\vee$ **cor(x, azul)**)

Substituição por uma classe mais geral
cor(x, vermelha)
pode ser generalizada para
cor(x, **cor_primária**) *sabendo-se que cor_primária subsume vermelha*

Cobertura: se um conceito p é mais geral que um conceito q, então p subsume q. Por exemplo, cor(x, y) ⊇ cor(esfera, z) ⊇ cor(esfera, vermelha).
Supor o seguinte domínio de objetos descritos por:

Tam = {**G**rande, **P**equeno}
Cor={**V**ermelha, **A**zul}
Forma={**E**sférica, **C**úbica} *abaixo o espaço de hipóteses*

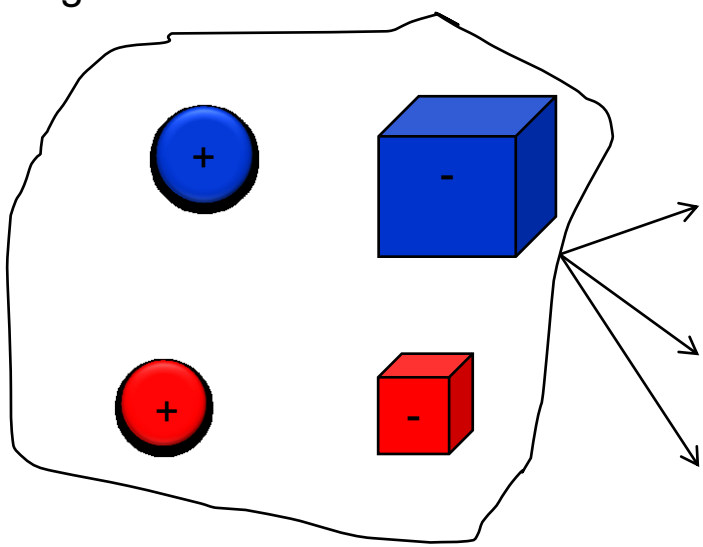


Operações de generalização que substituem ctes por variáveis definem este **espaço de conceitos**.

Aprendizado por indução é uma busca neste espaço de conceitos por um conceito que seja consistente com os exemplos de treinamento.

Por exemplo, dado um conjunto de exemplos de treinamento, como o algoritmo VSS pode aprender o conceito de ESFERA dado que o mundo é descrito em termos de tamanho, formas e cores?

A partir de exemplos positivos e negativos de ESFERA



Busca do mais específico para o mais geral
Hipótese positiva mais específica

Busca do mais geral para o mais específico
Hipótese positiva mais geral

Nos dois sentidos

Intuitivamente, qual o conceito de ESFERA em termos de um predicado objeto(<tam>, <cor>, <forma>)*?*

VERSION SPACE SEARCH: BUSCA DO MAIS ESPECÍFICO PARA O GERAL

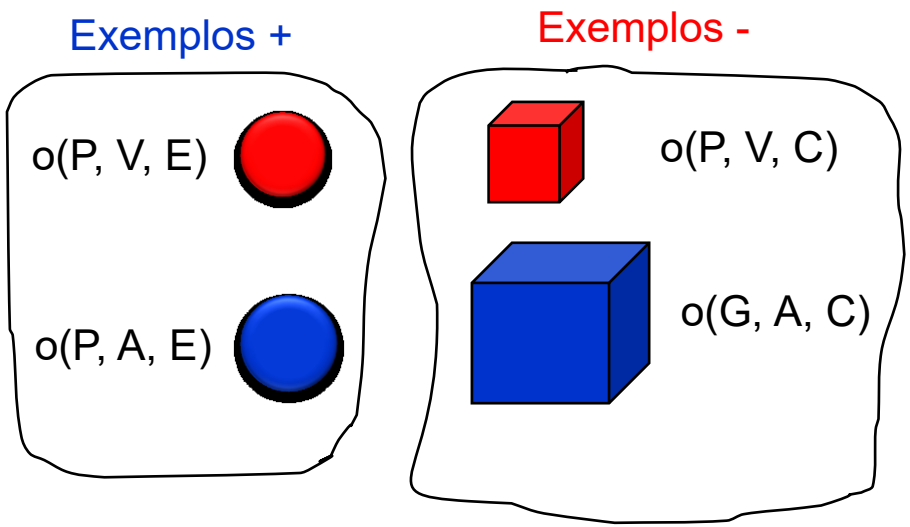
Busca pelo conjunto de hipóteses S que sejam o mais específicas possíveis para cobrir todos os exemplos positivos e nenhum exemplo negativo. A busca se faz do conceito mais específico para o mais geral ➔ **hipótese positiva mais específica**

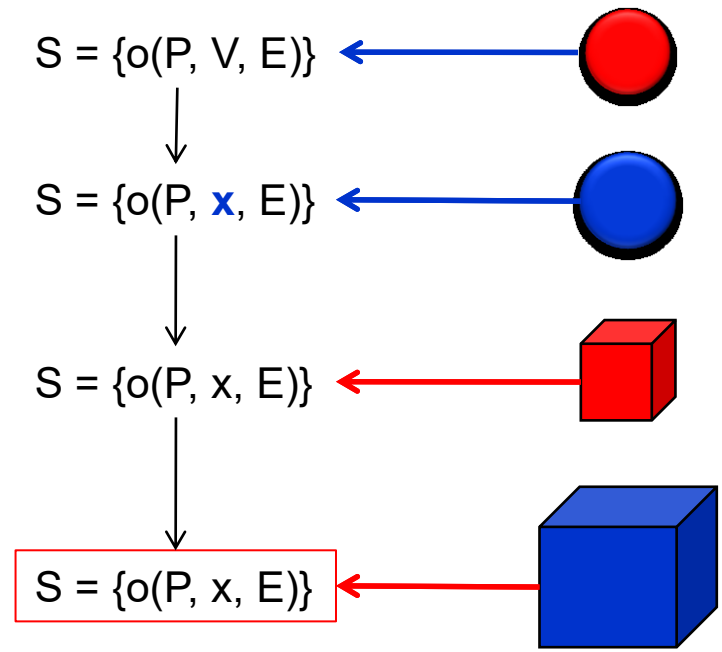
INÍCIO
Inicializar o conjunto S de hipóteses com todas generalizações mais específicas consistentes com o 1º. exemplo positivo
N é o conjunto de todos os exemplos negativos até o momento = { };

Enquanto houver exemplos faça
  Se exemplo positivo *p* faça:
    3.1 Para cada s de S, se s não cobre p, substitua s pela sua generalização mais específica que cubra p
    3.2 Eliminar de S todas as hipóteses que sejam mais gerais que qualquer outra hipótese de S
    3.3 Eliminar de S todas as hipóteses que cobrem um exemplo negativo de N;
  Se exemplo negativo *n* faça:
    4.1 Eliminar de S todas as hipóteses que cobrem n
    4.2 Adicionar *n* a N para verificar futuras hipóteses de sobre-generalização

FIM.

Exemplo: dado o conjunto de treinamento abaixo derive o conceito de ESFERA pelo VSS do mais específico para o mais geral.





O conceito aprendido de ESFERA é:
objeto pequeno, de qualquer cor e formato esférico

VERSION SPACE SEARCH: BUSCA DO MAIS GERAL PARA O ESPECÍFICO

Busca pelo conjunto de hipóteses G que sejam o mais GERAIS possíveis para cobrir todos os exemplos positivos e nenhum exemplo negativo. A busca se faz do conceito mais geral para o mais específico ➔ **hipótese positiva mais GERAL**

INÍCIO

1. Inicializar G com o conceito mais geral do espaço
2. P contém todos os exemplos positivos vistos até o momento;

3. Para cada exemplo negativo **n** faça:
   - 3.1 Para cada g de G, se g cobre n, substitua g pelas suas especializações mais gerais que não cubram **n**
   - 3.2 Eliminar de G todas as hipóteses que sejam mais específicas que qualquer outra hipótese de G
   - 3.3 Eliminar de G todas as hipóteses que não cobrem algum dos exemplos positivos em P

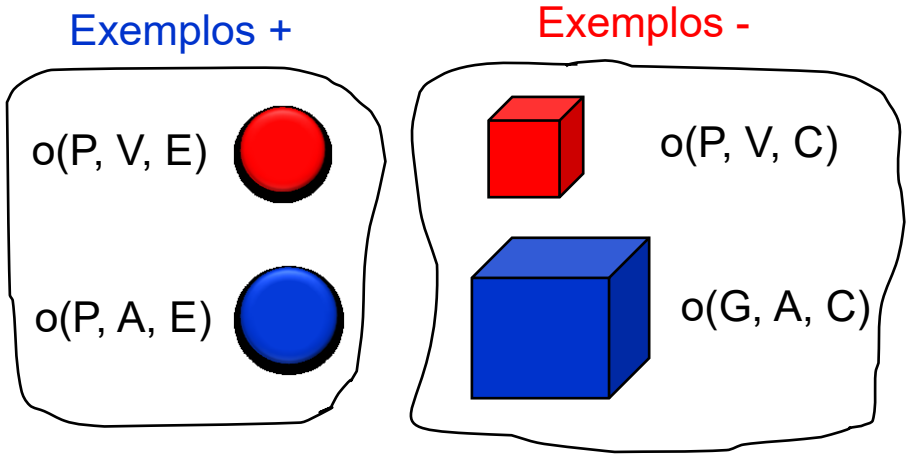
4. Para cada exemplo positivo p faça:
   - 4.1 Eliminar de G todas as hipóteses que não cobrem *p*
   - 4.2 Adicionar *p* a P

FIM.

VERSION SPACE SEARCH: BUSCA DO MAIS GERAL PARA O ESPECÍFICO

Exemplo: dado o conjunto de treinamento abaixo derive o conceito de esfera pelo VSS do mais específico para o mais geral.

o(<tam>, <cor>, <forma>)

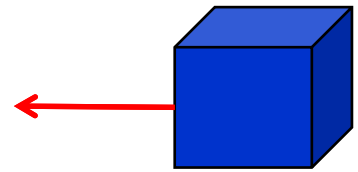


1 G = {o(x, y, z)}

2 G={o(G, y, z),
o(x, A, z),
o(x, y, E)}



3 G={o(G, V, z), ~~o(G, y, E),~~
o(P, A, z), ~~o(x, A, E)~~
o(x, y, E)}



4 G={~~o(G, V, z)~~, ~~o(G, y, E)~~,
~~o(P, A, z)~~,
o(x, y, E)}



5 S = {o(x, y, E)}



O conceito aprendido de esfera é:
objeto de qualquer tamanho, de qualquer cor e formato esférico

VERSION SPACE SEARCH: BI-DIRECIONAL ou ELIMINAÇÃO DE CANDIDATOS

O algoritmo tem dois cjtos de conceitos candidatos: G (mais gerais) e S (mais específicos). O algoritmo especializa G e generaliza S até convergirem a um conceito almejado ➔ **BI-DIRECIONAL**

INÍCIO

1. Inicializar G com o conceito mais geral do espaço
2. Inicializar S com o primeiro exemplo positivo;
3. Para cada exemplo positivo p faça:
   - 3.1 Eliminar de G todos os membros que não cobrem p
   - 3.2 Para cada s de S, se *s* não cobre p, substitua s com suas generalizações mais específicas que cubram p
   - 3.3 Eliminar de S todas hipóteses mais gerais que qualquer outra hipótese de S
   - 3.4 Eliminar de S todas hipóteses mais gerais que qualquer outra hipótese de G
4. Para cada exemplo negativo n faça:
   - 4.1 Eliminar de S todos os membros que cobrem *n*
   - 4.2 Para cada g de G, se g cobre n, substituir g por suas especializações mais gerais que não cobrem n
   - 4.3 Eliminar de G todas hipóteses mais específicas que qualquer outra hipótese de G
   - 4.4 Eliminar de G todas hipóteses mais específicas que qualquer outra hipótese de S

5. Se G=S e ambos são unitários o algoritmo encontrou um conceito consistente com os dados de treinamento
6. Se G=S={} então não há conceito que cubra todas os exemplos positivos e não cubra os negativos.
7. Caso contrário, o espaço de versões representa uma disjunção de hipóteses

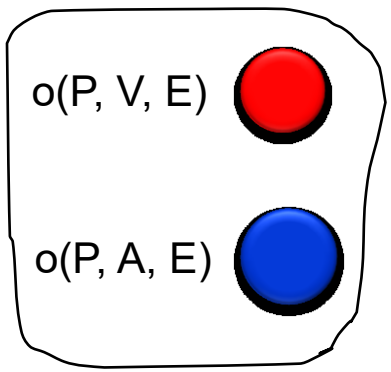
FIM.

VERSION SPACE SEARCH: BI-DIRECIONAL ou ELIMINAÇÃO DE CANDIDATOS

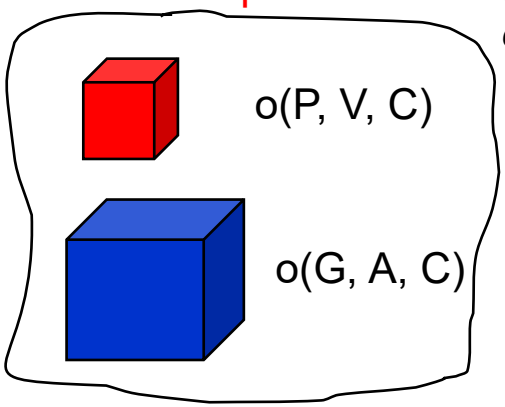
Exemplo: dado o conjunto de treinamento abaixo derive o conceito de bola pelo VSS bi-direcional

o(<tam>, <cor>, <forma>)

Exemplos +

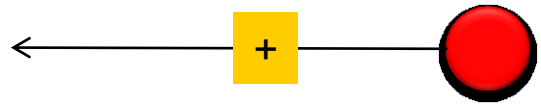


Exemplos -

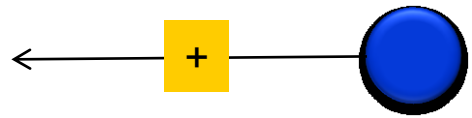


Foi necessário introduzir mais um exemplo positivo para o algoritmo convergir

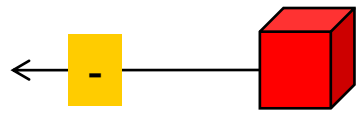
G={o(x, y, z)}
S={o(P,V,E)}



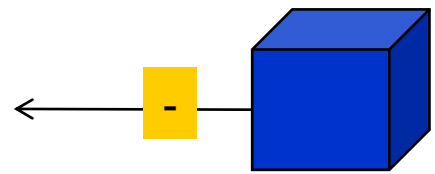
G={o(x, y, z)}
S={o(P,**y**,E)}



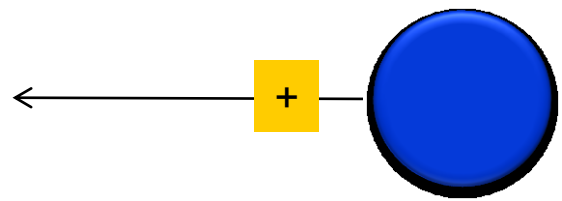
G={o(G, y, z), o(x, A, z), o(x, y, E)}
S={o(P,**y**,E)}



G={o(G, V, z), ~~o(G, y, E)~~
o(P, A, z), ~~o(x, A, E)~~,
o(x, y, E)}
S={o(P,**y**,E)}



G={~~o(G, V, z)~~,
~~o(P, A, z)~~,
o(x, y, E)}
S={o(x,y,E)}



O conceito aprendido de bola é: *objeto de qualquer tamanho, de qualquer cor e formato esférico*

O VSS é incremental: os exemplos podem ser apresentados ao algoritmo um por vez formando uma generalização utilizável (embora possivelmente incompleta) depois do aprendizado efetuado com cada exemplo.

Problema: o espaço de hipóteses pode ser muito grande. O número de elementos nos conjuntos S e G pode crescer exponencialmente.

Algoritmo original: (Buchanan & Mitchell, 1978) utilizaram-no no sistema Meta-Dendral para aprendizado de regras para prever como moléculas são quebradas num espectômetro de massa.

(Mitchel et al., 1983) também aplicaram-no no sistem LEX para resolver problemas de integração simbólica.

[fonte (Russel e Norvig, pg. 776)]

2 APRENDIZADO INDUTIVO

2.1 ID3 DECISION TREE INDUCTION

- **Proposto por Quinlan em 1986**
  Quinlan, J. R. (1986). Induction of decision trees, *Machine Learning 1(1): 81–106.*

- **Assim como o algoritmo de eliminação de candidatos, induz conceitos a partir de exemplos**

- **A representação dos conceitos aprendidos é sob a forma de árvore de decisão**

Documentação WEKA

http://weka.sourceforge.net/doc/weka/classifiers/trees/Id3.html

Arquivo .arff (formato WEKA) com exemplos para treinamento de uma árvore de decisão

```
@relation risco-de-credito

@attribute historico {semInfo, ruim, bom}
@attribute dividas {baixas, altas}
@attribute ganhos-extras {nenhum, adequado }
@attribute ganhos {0a15k, 15a35k, MQ35k}
@attribute risco {baixo, medio, alto}

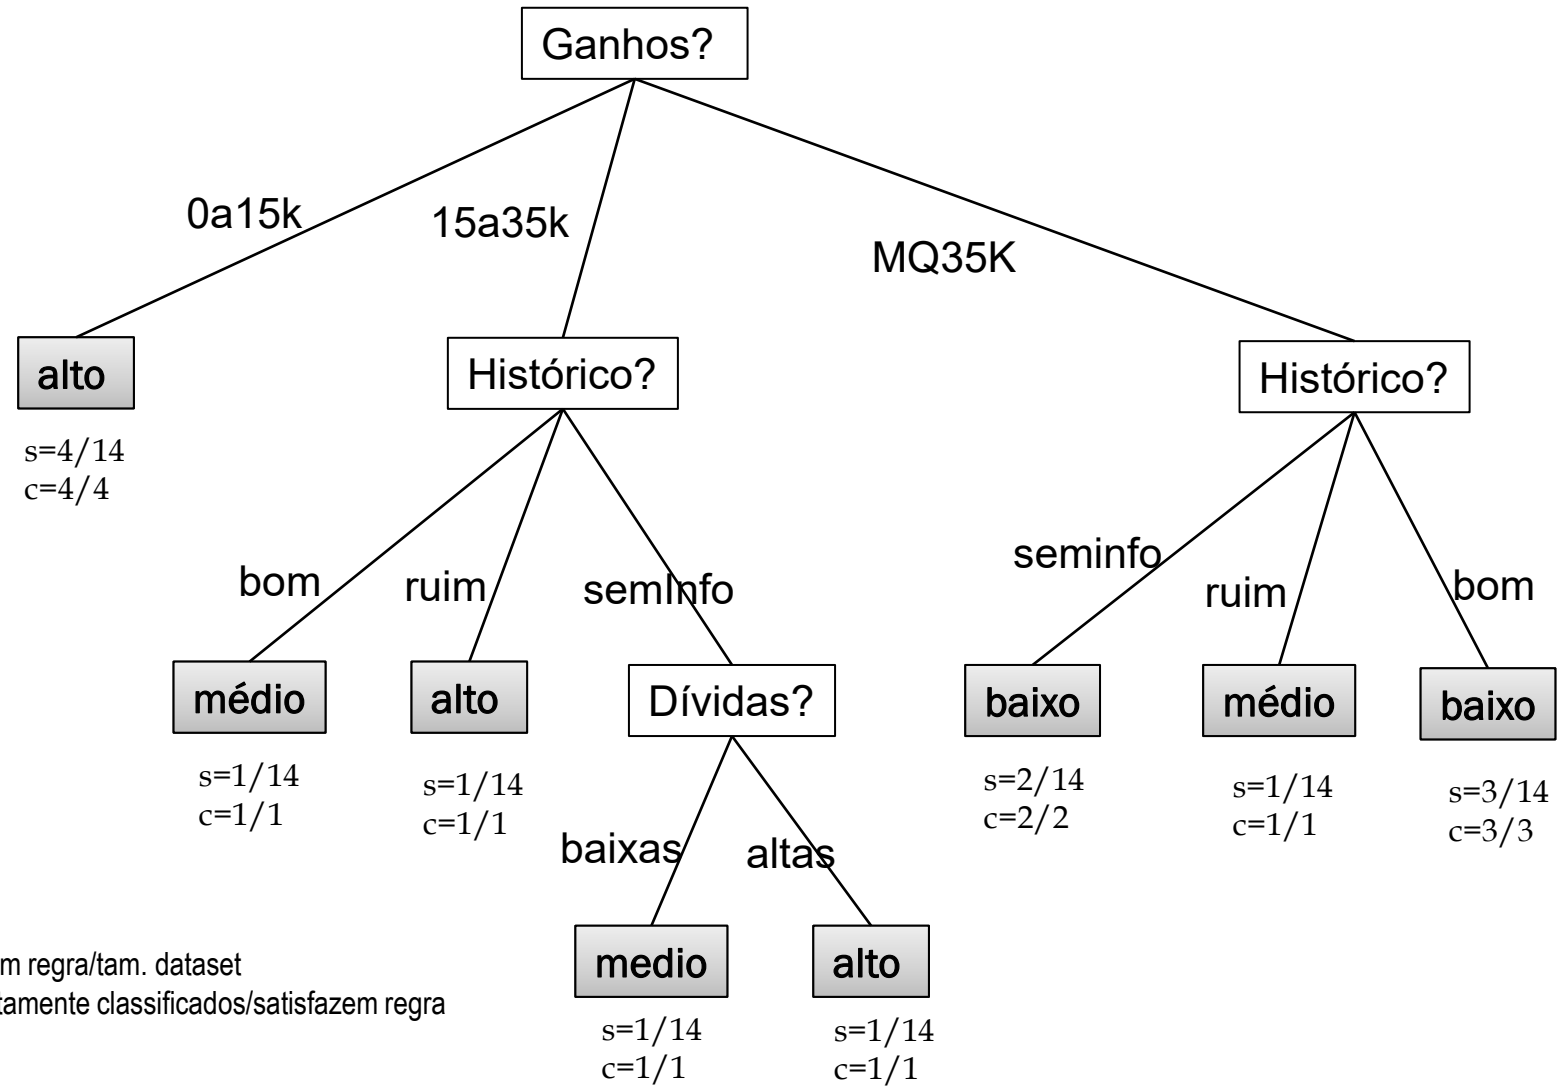
@data
ruim,      altas,  nenhum,   0a15k, alto
semInfo, altas,  nenhum,  15a35k, alto
semInfo, baixas, nenhum,  15a35k, medio
semInfo, baixas, nenhum,   0a15k, alto
semInfo, baixas, nenhum,   MQ35k, baixo
semInfo, baixas, adequado, MQ35k, baixo
ruim,      baixas, nenhum,   0a15k, alto
ruim,      baixas, adequado, MQ35k, medio
bom,       baixas, nenhum,   MQ35k, baixo
bom,      altas,  adequado,   MQ35k, baixo
bom,      altas,  nenhum,      0a15k, alto
bom,      altas,  nenhum,  15a35k, medio
bom,      altas,  nenhum,   MQ35k, baixo
ruim,      altas,  nenhum,  15a35k, alto
```

ID3

Indução da árvore de decisão pelo algoritmo ID3

```
ganhos = 0a15k: alto
ganhos = 15a35k
|  historico = semInfo
|  |  dividas = baixas: medio
|  |  dividas = altas: alto
|  historico = ruim: alto
|  historico = bom: medio
ganhos = MQ35k
|  historico = semInfo: baixo
|  historico = ruim: medio
|  historico = bom: baixo
```

Uma árvore possível para os exemplos de treinamento; a saída são as folhas=risco de crédito



s=support=satisfazem regra/tam. dataset
c=confidence=corretamente classificados/satisfazem regra

Cada ramo da árvore (da raiz a uma das folhas) representa uma regra onde os nós de decisão são premissas e a folha, o consequente.

```
ganhos = 0a15k → risco = alto

ganhos = 15a35K ∧ historico = semInfo ∧ dividas=baixas → risco=médio
ganhos = 15a35K ∧ historico = semInfo ∧ dividas=altas → risco=alto
ganhos = 15a35K ∧ historico = ruim → risco = alto
ganhos = 15a35K ∧ historico = bom → risco = médio

ganhos = MQ35K ∧ historico = semInfo → risco = baixo
ganhos = MQ35K ∧ historico = ruim → risco = médio
ganhos = MQ35K ∧ historico = bom → risco = baixo
```

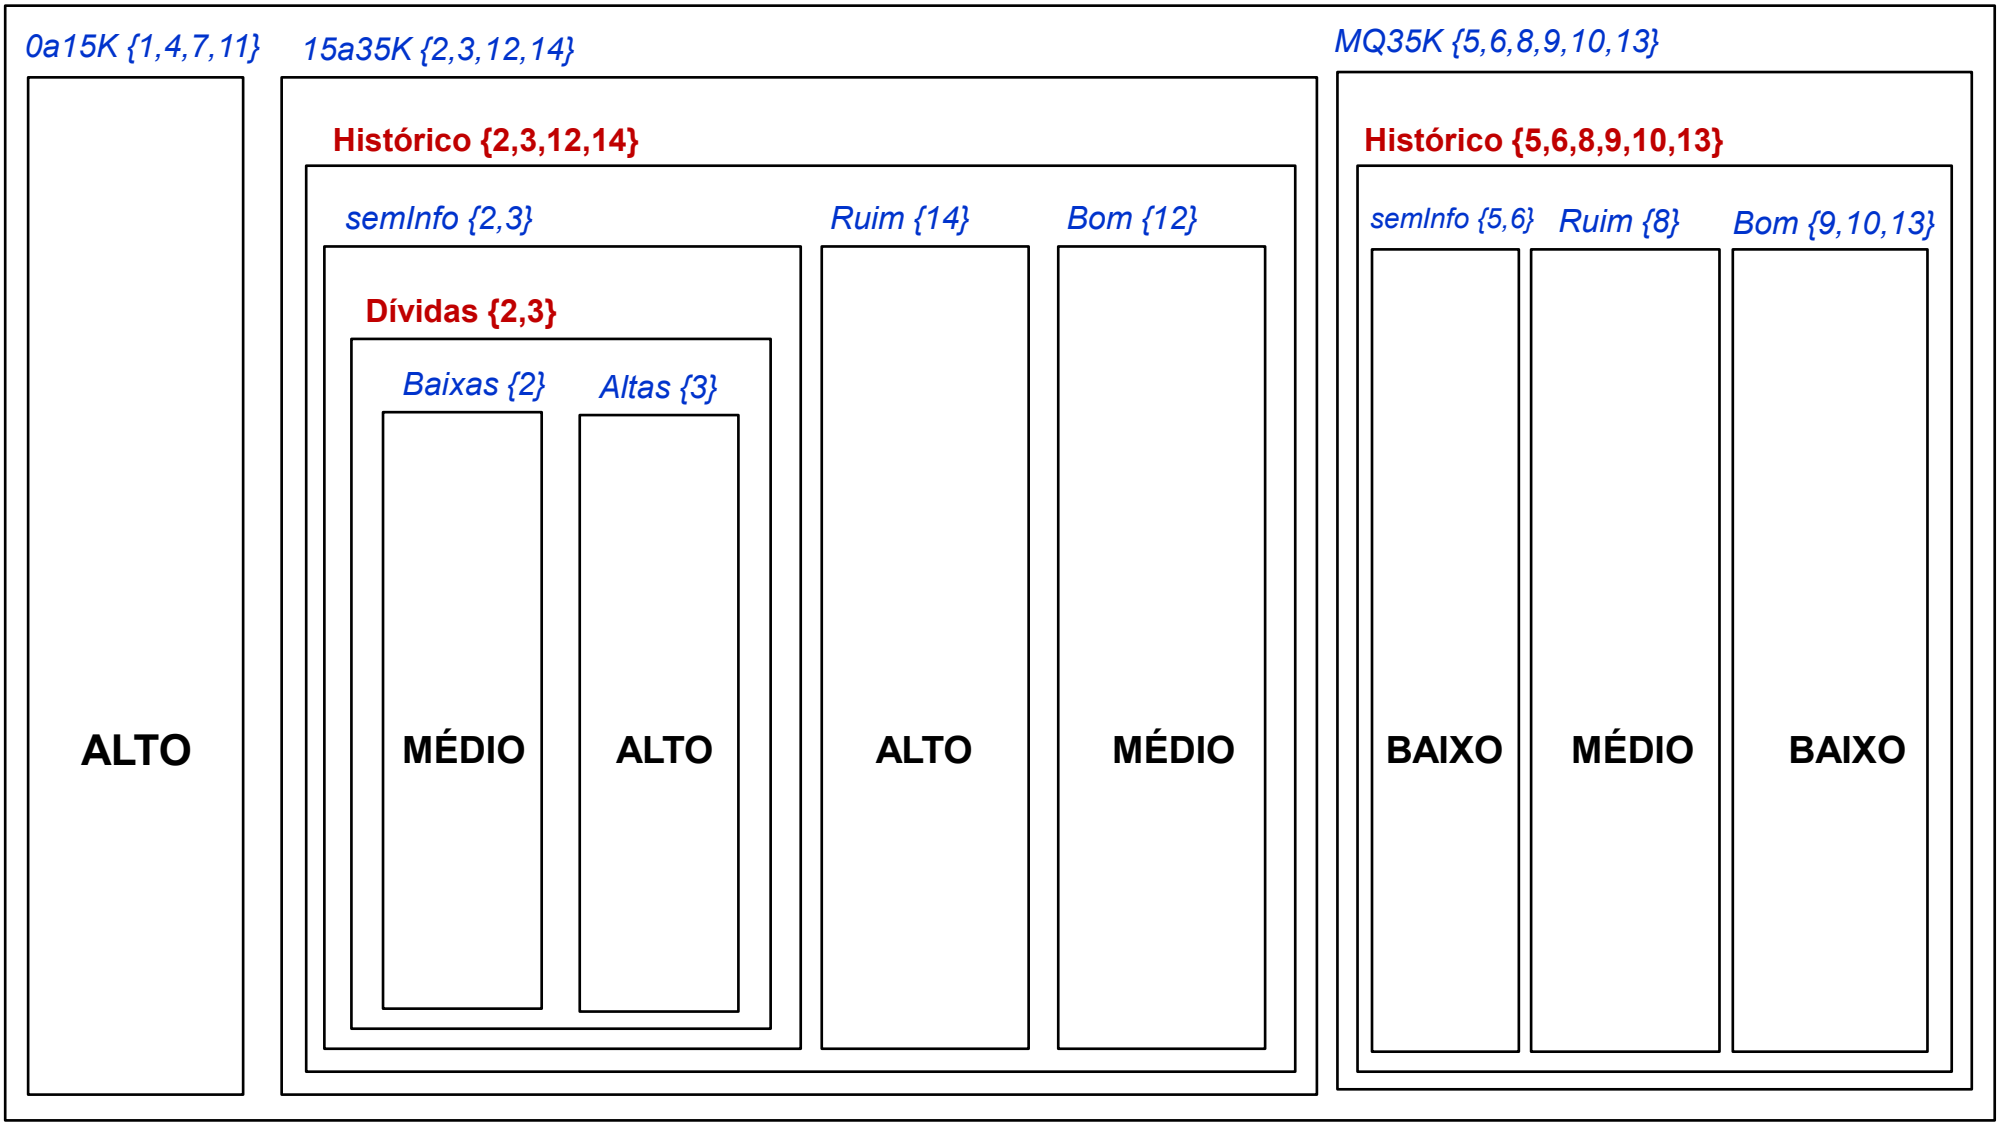
Cada regra tem uma medida de suporte e confiança:
s=support=satisfazem regra/tam. dataset
c=confidence=corretamente classificados/satisfazem regra

ID3(exemplos, ppdes) *;; ppdes é utilizado como sinônimo de atributos*
Se todas as entradas em **exemplos** pertencem a mesma classe
então retornar um nodo folha etiquetado com esta classe
senão
se **ppdes** igual a vazio
então retornar um nodo folha etiquetado com a disjunção de todas as classes de **exemplos**
senão
escolher uma propriedade P e torná-la raíz da árvore corrente
apagar P de **ppdes**
para cada valor V de P
criar um ramo da árvore etiquetado com V
partição$_V$:= elementos de **exemplos** com valores = V para a ppde P
chamar ID3(partição$_V$, ppdes), inserir resultado no ramo V
fimpara
Fimse
fimse

Uma questão importante é como escolher uma propriedade P?

ID3: ALGORITMO EXEMPLO EXECUÇÃO

Ganhos {1,2,3,...,14}



ID3: ESCOLHA DE PROPRIEDADE/ATRIBUTO

Weka Explorer

Preprocess | Classify | Cluster | Associate | Select attributes | Visualize

Open file... | Open URL... | Open DB... | Generate... | Undo | Edit... | Save...

Filter

Choose **None** Apply

Current relation

Relation: risco-de-credito

Instances: 14 Attributes: 5

Attributes

All | None | Invert | Pattern

No.	Name
1	historico
2	dividas
3	ganhos-extras
4	ganhos
5	risco

Remove

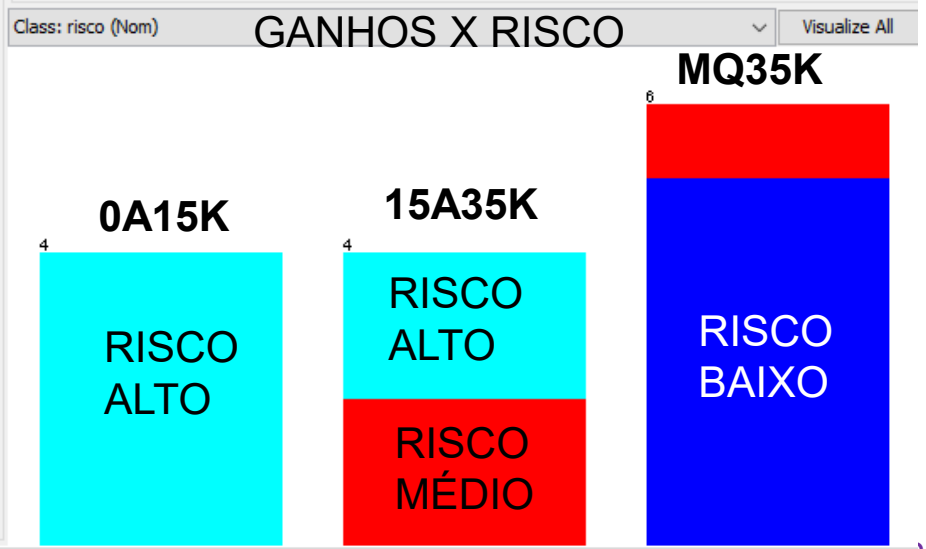
Selected attribute

Name: ganhos Type: Nominal

Missing: 0 (0%) Distinct: 3 Unique: 0 (0%)

No.	Label	Count
1	0a15k	4
2	15a35k	4
3	MQ35k	6

Class: risco (Nom) Visualize All



Uma árvore pode ser gerada sem levar em conta todas os atributos de treinamento:
Observar no exemplo anterior que o atributo ganhos-extras não aparece na árvore induzida.

O **tamanho da árvore pode variar** de acordo com a ordem em que os atributos são testados.

Na perspectiva de learning como busca, o conjunto de todas as árvores de decisão define o espaço de hipóteses. A operação neste espaço é a de adição de teste condicional.

ID3 implementa uma busca gulosa no espaço das árvores possíveis: adiciona um subárvore à árvore corrente e continua sua busca sem fazer backtracking

1. Execute o **WEKA > EXPLORER**
2. Na tab **PRE-PROCESSER**, abra o arquivo de treinamento: **RiscoCredito.arff** (em Tarefas > AprendizadoSimbolico)
3. Na tab **CLASSIFY**
    i. Escolha o classificador ID3
    ii. Em Test Options, marque [Use training set]
    iii. Dê início à execução
    iv. Observe a árvore gerada

4. Verifique/responda:

i. Todas as propriedades/atributos foram utilizados na árvore?
ii. Seria possível uma outra árvore de decisão com os mesmos atributos?
    i. observe na aba preprocess as contagens dos atributos → slide seguinte
iii. Que cada ramo da árvore representa um teste condicional formado pela conjunção dos testes deste ramo e que a árvore como um todo é a disjunção dos vários ramos.
iv. Tente explicar as seguintes medidas de avaliação:
    i. correctly/incorrectly classified instances
    ii. Detailed Accuracy by Class
        i. TP Rate/FP Rate
        ii. Precision/Recall
        iii. Confusion Matrix

USO DE ENTROPIA PARA ESCOLHA DA PROPRIEDADE/ATRIBUTO NO ID3

ENTROPIA MEDE O GRAU DE DESORDEM OU INCERTEZA EM UM CONJUNTO DE DADOS (DATASET)

ID3 escolhe a propriedade de menor incerteza/desordem – i.e. menor valor para a medida de entropia – como raiz da subárvore corrente.

$$E[D] = \sum_{i=1}^{|C|} -p(c_i).\log_2.(p(c_i))$$

Entropia de um dataset D **é uma medida de incerteza** associada à aleatoridade de uma variável. Unidade de medida: **BIT**

Em ID3, a variável aleatória considerada é a **classe** (a saída).

D = dataset
C = conjunto de classes de saída
$c_i = c_i \in C$ (*uma das classes de saída*)
$p(c_i)$ = probabilidade de c_i em D (se ci ocorre 40 vezes em D de tam. 100 = 400/100)

- **EXEMPLO**
  - D = dataset contendo amostragens de lançamentos de uma moeda
  - C = {cara, coroa}
  - Vamos supor diferentes conjuntos D

1) D: **50**% dos exemplos são cara e **50%** coroa

E(D) = -0.5 $\log_2$0.5 -0.5 $\log_2$0.5 = **1 BIT**

2) D: **80%** dos exemplos são cara e **20%** coroa

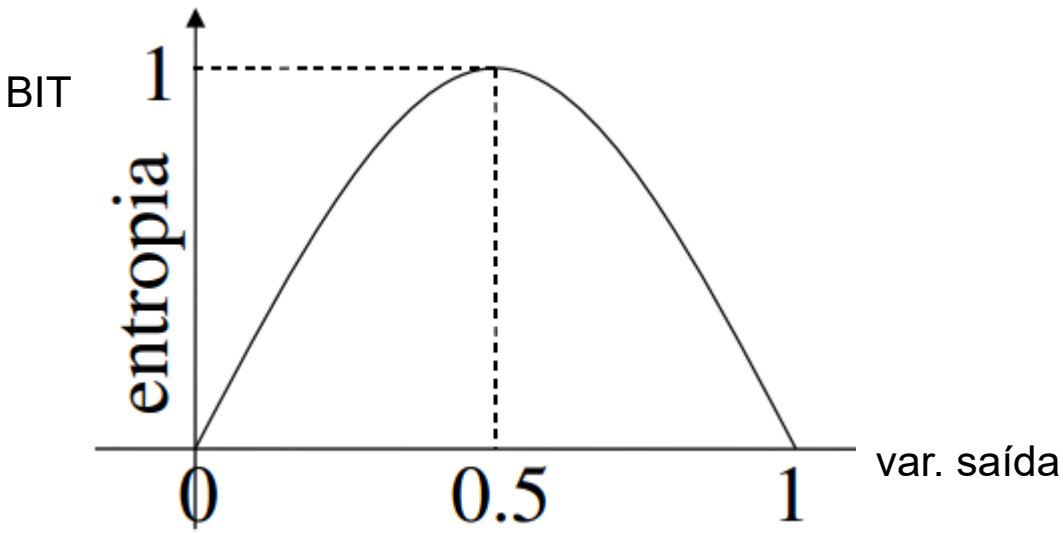
E(D) = -0.8 $\log_2$0.8 -0.2 $\log_2$0.2 = **0.722 BIT**

3) D: **100%** dos exemplos são cara e **0%** coroa

E(D) = -1 $\log_2$1 -0. $\log_2$0 = **0 BIT**



Quanto menor o valor da entropia, menor a DESORDEM (incerteza)!



EXEMPLO (continuação)

Para uma variável de saída binária que represente a classe dos exemplos de treinamento. Há exemplos positivos (ex. *cara*) e negativos (ex. coroa)

No eixo X, a distribuição de exemplos positivos (vamos supor, cara).

Se tivermos 0 exemplos com cara ou se todos exemplos tem cara como saída, a entropia é 0.

Se temos 0.5 (cara e coroa são equiprováveis no conjunto de treinamento) então temos entropia máxima

Retomando o exemplo de ***Risco de Crédito***
p(alto) = **6**/14
p(medio) = **3**/14
p(baixo) = **5**/14

alto medio baixo

$$E[RdC] = -\frac{6}{14} * log2\left(\frac{6}{14}\right) - \frac{3}{14} * log2\left(\frac{3}{14}\right) - \frac{5}{14} * log2\left(\frac{5}{14}\right)$$

$$E[RdC] = -\frac{6}{14} * (-1{,}222) - \frac{3}{14} * (-2{,}222) - \frac{5}{14} * (-1{,}485)$$

E[RdC] = 1,531 bits

Entropia total do dataset risco-de-crédito (RdC).

@relation risco-de-credito

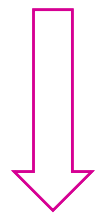
@attribute historico {semInfo, ruim, bom}
@attribute dividas {baixas, altas}
@attribute ganhos-extras {nenhum, adequado }
@attribute ganhos {0a15k, 15a35k, MQ35k}
@attribute risco {baixo, medio, alto}

@data
1. ruim, altas, nenhum, 0a15k, **alto**
2. semInfo, altas, nenhum, 15a35k, alto
3. semInfo, baixas, nenhum, 15a35k, **medio**
4. semInfo, baixas, nenhum, 0a15k, alto
5. semInfo, baixas, nenhum, MQ35k, **baixo**
6. semInfo, baixas, adequado, MQ35k, **baixo**
7. ruim, baixas, nenhum, 0a15k, **alto**
8. ruim, baixas, adequado, MQ35k, **medio**
9. bom, baixas, nenhum, MQ35k, **baixo**
10. bom, altas, adequado, MQ35k, **baixo**
11. bom, altas, nenhum, 0a15k, **alto**
12. bom, altas, nenhum, 15a35k, **medio**
13. bom, altas, nenhum, MQ35k, **baixo**
14. ruim, altas, nenhum, 15a35k, **alto**

Suponha para o exemplo anterior duas situações:
1. todas as classes de saída são iguais a **alto**;
2. as saídas dividem-se igualmente entre **alto** e **médio**;
3. as saídas dividem-se igualmente entre **alto**, **médio**, e **baixo**.

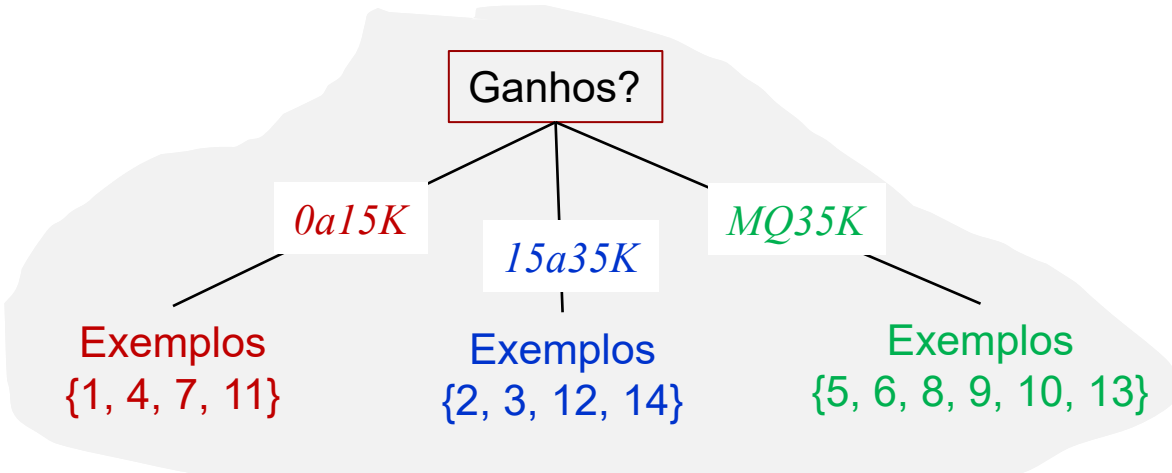
Ordene os valores da entropia para as situações acima
Não é preciso calcular, tente responder com base no conceito de entropia.

Como utilizar entropia para selecionar uma propriedade para ser raíz de uma subárvore?



Escolher primeiramente a propriedade que proporcionar menos incerteza na classificação!!! (i.e. menor entropia)

1. Ao escolher *P* como propriedade, particiona-se o conjunto de exemplos em *n* subconjuntos, um para cada valor possível de P



@data

1. ruim, altas, nenhum, **0a15k**, **alto**
2. semInfo, altas, nenhum, **15a35k**, **alto**
3. semInfo, baixas, nenhum, **15a35k**, **medio**
4. semInfo, baixas, nenhum, **0a15k**, **alto**
5. semInfo, baixas, nenhum, **MQ35k**, baixo
6. semInfo, baixas, adequado, **MQ35k**, **baixo**
7. ruim, baixas, nenhum, **0a15k**, **alto**
8. ruim, baixas, adequado, **MQ35k**, medio
9. bom, baixas, nenhum, **MQ35k**, **baixo**
10. bom, altas, adequado, **MQ35k**, **baixo**
11. bom, altas, nenhum, **0a15k**, **alto**
12. bom, altas, nenhum, **15a35k**, **medio**
13. bom, altas, nenhum, **MQ35k**, **baixo**
14. ruim, altas, nenhum, **15a35k**, **alto**

Este particionamento gera uma entropia calculada por:

$$E[P] = \sum_{i=1}^{n} \frac{|C_i|}{|C|} * E[C_i]$$

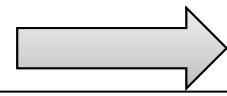
onde C é o conjunto de todos os exemplos e C_i é uma partição de C

$$E[ganhos] = \frac{|0a15k|}{|Exemplos|} * E[0a15k] + \frac{|15a35k|}{|Exemplos|} * E[15a35k] + \frac{|MQ35k|}{|Exemplos|} * E[MQ35k]$$

$$E[ganhos] = \frac{|0a15k|}{|Exemplos|} * E[0a15k] + \frac{|15a35k|}{|Exemplos|} * E[15a35k] + \frac{|MQ35k|}{|Exemplos|} * E[MQ35k]$$

$$= \frac{4}{14} * E[0a15k] + \frac{4}{14} * E[15a35k] + \frac{6}{14} * E[MQ35k]$$

$$= \frac{4}{14} * 0 + \frac{4}{14} * 1 + \frac{6}{14} * 0{,}650 = 0{,}564\ bits$$



Entropia para a ppde ganhos

Nos exemplos {1, 4, 7, 11} todos tem risco = ***alto***

$$E[0a15k] = -\frac{4}{4} * log2(p(alto)) - \frac{0}{4} * log2(p(medio)) - \frac{0}{4} * log2(p(baixo)) = 1 * log2\left(\frac{4}{4}\right) = 0$$

Nos exemplos {2, 3, 12, 14} 2 e 14 tem risco = ***alto*** *e 3 e 12,* ***médio***

$$E[15a35k] = -\frac{2}{4} * log2(p(alto)) - \frac{2}{4} * log2(p(medio)) - \frac{0}{4} * log2(p(baixo)) = 1$$

Nos exemplos {5, 6, 8, 9, 10, 13} todos tem risco = ***baixo****, salvo 8 que é* ***médio***

$$E[MQ35k] = -\frac{0}{6} * log2(p(alto)) - \frac{1}{6} * log2(p(medio)) - \frac{5}{6} * log2(p(baixo)) = 0{,}650$$

Portanto, para escolher a propriedade, é preciso calcular a entropia para cada uma delas!

Desta forma no exemplo risco-de-credito, tem-se:

E(ganhos-extras)=1,325
E(historico)=1,265
E(dividas)=0,898
E(ganhos)=0,564 bits

Escolhe-se a propriedade com menor valor de entropia = menor incerteza/desordem

ID3: GANHO DE INFORMAÇÃO COM DADOS NUMÉRICOS

Um agente deve aprender a classificar automaticamete as tarefas executadas por um usuário dados os tipos e quantidades de objetos que ele manipula em cada tarefa.

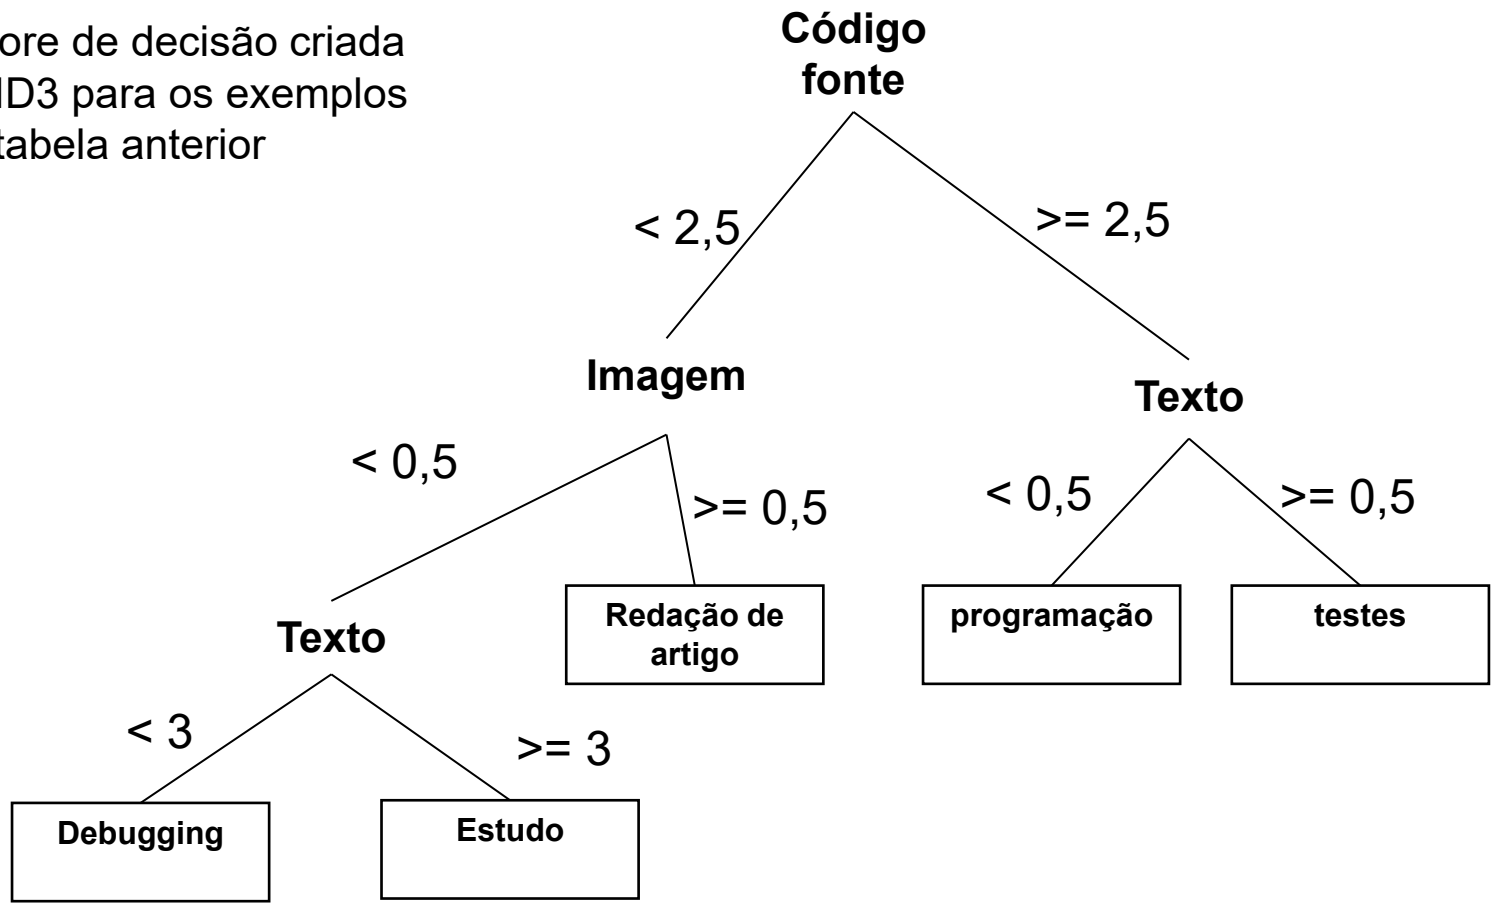
	EXEMPLOS DE TREINAMENTO	TIPOS DE OBJETOS							
		bookmark	*Request* agente	Imagem	Apresentação	Texto	Código fonte	Página WEB	e-mail
classes	1 *debugging*					2	2		
	2 Programação						3		
	3 Programação						5		
	4 testes					1	4		
	5 estudo	3	2			4			
	6 Redação de artigo	3		1	1	5			4
	7 Redação de artigo	2		1	2	3			2

Fonte: (Tacla, C. 2003, Tese de Doutorado)

Hipótese de modelagem: as tarefas podem ser caracterizadas pelos tipos de objetos e sua frequência de utilização na tarefa.

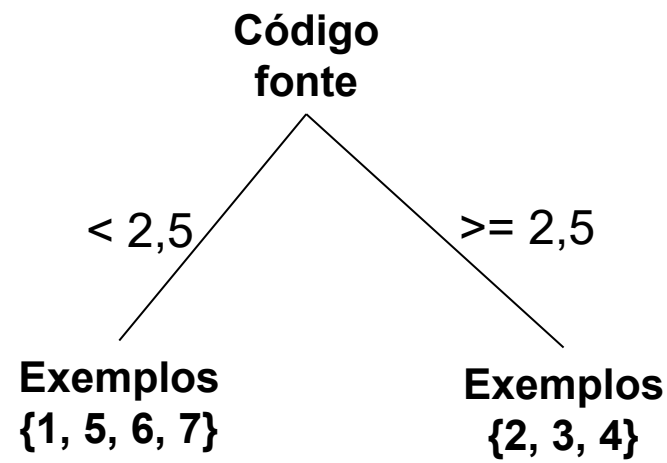
ID3: GANHO DE INFORMAÇÃO COM DADOS NUMÉRICOS

Árvore de decisão criada do ID3 para os exemplos da tabela anterior



Resultado produzido pela implementação de http://www.cs.utexas.edu/ftp/pub/mooney/ml-progs/ Droits de l'auteur, 1990, Raymond Joseph Mooney.

Um teste de um atributo numérico produz uma **partição binária** do conjunto de exemplos, tal que a primeira partição contém os exemplos menores que o ponto de referência e a segunda, os exemplos que apresentam valor do atributo maior do que o ponto de referência.



Escolha do ponto de referência

1. Ordenar os exemplos por ordem crescente dos valores do atributo numérico

2. Qualquer ponto intermediário entre dois valores diferentes e consecutivos dos valores observados no conjunto de treino pode ser utilizado como possível ponto de referência sendo usual considerar o valor médio.

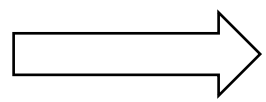
ID3: GANHO DE INFORMAÇÃO PARA ATRIBUTOS NUMÉRICOS

EXEMPLOS DE TREINAMENTO	TIPOS DE OBJETOS							
	bookmark	*Request* agente	Imagem	Apresentação	Texto	Código fonte	Página WEB	e-mail
1 *debugging*					2	2		
2 Programação						3		
3 Programação						5		
4 testes					1	4		
5 estudo	3	2			4			
6 Redação de artigo	3		1	1	5			4
7 Redação de artigo	2		1	2	3			2

Para o atributo imagem, ponto de referência = 0,5 tem-se uma entropia de :

$$E[Imagem] = \frac{|Menores|}{|Exemplos|} * I[Menores] + \frac{|Maiores|}{|Exemplos|} * I[Maiores]$$

$$= \frac{5}{7} * 1{,}922 + \frac{2}{7} * 1 = 2{,}373\ bits$$



$$I[Menores] = -\frac{1}{5} * log2\big(p(deb)\big) - \frac{2}{5} * log2\big(p(prog)\big) - \frac{1}{5} * log2\big(p(tst)\big) - \frac{1}{5} * log2\big(p(est)\big)$$
$$= 1{,}922$$

$$I[Maiores] = -\frac{1}{2} * log2\big(p(red)\big) - \frac{1}{2} * log2\big(p(red)\big) = 1$$

onde Menores são os exemplos cujo valor do atributo Imagem é menor que 0,5
Maiores é definido de forma similar.

Intuitivamente, responda:
1. Por que não foi utilizado o atributo e-mail ou o atributo apresentação ao invés de imagem?

Complexidade do ID3
Treinamento
Ruído
Atributos sem valores durante treinamento
Atributos sem valores durante classificação

Ver artigo **Quinlan, 1986**