ResearchGate

See discussions, stats, and author profiles for this publication at: https://www.researchgate.net/publication/230766603

How Many Trees in a Random Forest?

Conference Paper *in* Lecture Notes in Computer Science · July 2012

DOI: 10.1007/978-3-642-31537-4_13

CITATIONS
311

READS
35,296

3 authors, including:



José Augusto Baranauskas
University of São Paulo

31 PUBLICATIONS **635** CITATIONS

SEE PROFILE

Some of the authors of this publication are also working on these related projects:

Project

Software Engineering and Semantic Web Efforts on Context-Aware Computing View project

ResearchGate

Veja discussões, estatísticas e perfis de autores desta publicação em: https://www.researchgate.net/publication/230766603

Quantas árvores em uma floresta aleatória?

Artigo de conferência em notas de aula em ciência da computação · Julho de 2012 DOI: 10.1007/978-3-642-31537-4_13

CITAÇÕES 311

LÊ
35.296

3 autores, incluindo:



José Augusto Baranauskas
Universidade de São Paulo 31
PUBLICAÇÕES 635 CITAÇÕES VER
PERFIL

Alguns dos autores desta publicação também estão trabalhando nestes projetos relacionados:

Project

Esforços de engenharia de software e web semântica no projeto de visualização de computação sensível ao contexto

All content following this page was uploaded by José Augusto Baranauskas on 15 May 2014.

The user has requested enhancement of the downloaded file.

Todo o conteúdo desta página foi carregado por José Augusto Baranauskas em 15 de maio de 2014.

O usuário solicitou aprimoramento do arquivo baixado.

How Many Trees in a Random Forest?

Thais Mayumi Oshiro, Pedro Santoro Perez, and José Augusto Baranauskas

Department of Computer Science and Mathematics
Faculty of Philosophy, Sciences and Languages at Ribeirao Preto
University of Sao Paulo
{thaismayumi,pedrosperez,augusto}@usp.br

Abstract. Random Forest is a computationally efficient technique that can operate quickly over large datasets. It has been used in many recent research projects and real-world applications in diverse domains. However, the associated literature provides almost no directions about how many trees should be used to compose a Random Forest. The research reported here analyzes whether there is an optimal number of trees within a Random Forest, i.e., a threshold from which increasing the number of trees would bring no significant performance gain, and would only increase the computational cost. Our main conclusions are: as the number of trees grows, it does not always mean the performance of the forest is significantly better than previous forests (fewer trees), and doubling the number of trees is worthless. It is also possible to state there is a threshold beyond which there is no significant gain, unless a huge computational environment is available. In addition, it was found an experimental relationship for the AUC gain when doubling the number of trees in any forest. Furthermore, as the number of trees grows, the full set of attributes tend to be used within a Random Forest, which may not be interesting in the biomedical domain. Additionally, datasets' density-based metrics proposed here probably capture some aspects of the VC dimension on decision trees and low-density datasets may require large capacity machines whilst the opposite also seems to be true.

Keywords: Random Forest, VC Dimension, Number of Trees.

1 Introduction

A great interest in the machine learning research concerns ensemble learning — methods that generate many classifiers and combine their results. It is largely accepted that the performance of a set of many weak classifiers is usually better than a single classifier given the same quantity of train information [28]. Ensemble methods widely known are boosting [12], bagging [8], and more recently Random Forests [7,24].

The boosting method creates different base learners by sequentially reweighting the instances in the training set. At the beginning, all instances are initialized with equal weights. Each instance misclassified by the previous base learner will get a larger weight in the next round, in order to try to classify it correctly. The

P. Perner (Ed.): MLDM 2012, LNAI 7376, pp. 154–168, 2012.
© Springer-Verlag Berlin Heidelberg 2012

Quantas árvores em uma floresta aleatória?

Thais Mayumi Oshiro, Pedro Santoro Perez e José´e Augusto Baranauskas

Departamento de Ciência da Computação e Matemática Faculdade de Filosofia, Ciências e Letras da Universidade de São Paulo de Ribeirão Preto{ thaismayumi,pedrosperez,augusto}@usp.br

Resumo. Random Forest é uma técnica computacionalmente eficiente que pode operar rapidamente em grandes conjuntos de dados. Ele tem sido usado em muitos projetos de pesquisa recentes e em aplicações do mundo real em diversos domínios. Entretanto, a literatura associada quase não fornece orientações sobre quantas árvores devem ser utilizadas para compor uma Floresta Aleatória. A pesquisa aqui relatada analisa se existe um número ótimo de árvores dentro de uma Floresta Aleatória, ou seja, um limite a partir do qual aumentar o número de árvores não traria nenhum ganho significativo de desempenho, apenas aumentaria o custo computacional. Nossas principais conclusões são: à medida que o número de árvores cresce, isso nem sempre significa que o desempenho da floresta é significativamente melhor do que as florestas anteriores (menos árvores), e duplicar o número de árvores é inútil. Também é possível afirmar que existe um limite além do qual não há ganho significativo, a menos que um enorme ambiente computacional esteja disponível. Além disso, foi encontrada uma relação experimental para o ganho de AUC ao duplicar o número de árvores em qualquer floresta. Além disso, à medida que o número de árvores cresce, o conjunto completo de atributos tende a ser utilizado dentro de uma Floresta Aleatória, o que pode não ser interessante no domínio biomédico. Além disso, as métricas baseadas na densidade dos conjuntos de dados propostas aqui provavelmente capturam alguns aspectos da dimensão VC nas árvores de decisão e os conjuntos de dados de baixa densidade podem exigir máquinas de grande capacidade, enquanto o oposto também parece ser verdadeiro.

Palavras-chave: Floresta Aleatória, Dimensão VC, Número de Árvores.

1 Introdução

Um grande interesse na pesquisa de aprendizado de máquina diz respeito ao aprendizado conjunto – métodos que geram muitos classificadores e combinam seus resultados. É amplamente aceito que o desempenho de um conjunto de muitos classificadores fracos é geralmente melhor do que um único classificador, dada a mesma quantidade de informações do trem [28]. Os métodos de conjunto amplamente conhecidos estão impulsionando o [12], bagging [8], e, mais recentemente, as Florestas Aleatórias [7,24].

O método boosting cria diferentes aprendizes básicos, reponderando sequencialmente as instâncias no conjunto de treinamento. No início, todas as instâncias são inicializadas com pesos iguais. Cada instância classificada incorretamente pelo aluno base anterior receberá um peso maior na próxima rodada, para tentar classificá-la corretamente. O

P. Perner (Ed.): MLDM 2012, LNAI 7376, pp. 154–168, 2012. c○ Springer-Verlag Berlin Heidelberg2012

error is computed, the weight of the correctly classified instances is lowered, and the weight of the incorrectly classified instances is increased. The vote of each individual learner is weighted proportionally to its performance [31].

In the bagging method (bootstrap aggregation), different training subsets are randomly drawn with replacement from the entire training set. Each training subset is fed as input to base learners. All extracted learners are combined using a majority vote. While bagging can generate classifiers in parallel, boosting generates them sequentially.

Random Forest is another ensemble method, which constructs many decision trees that will be used to classify a new instance by the majority vote. Each decision tree node uses a subset of attributes randomly selected from the whole original set of attributes. Additionally, each tree uses a different bootstrap sample data in the same manner as bagging.

Normally, bagging is almost always more accurate than a single classifier, but it is sometimes much less accurate than boosting. On the other hand, boosting can create ensembles that are less accurate than a single classifier. In some situations, boosting can overfit noisy datasets, thus decreasing its performance. Random Forests, on the other hand, are more robust than boosting with respect to noise; faster than bagging and boosting; their performance is as good as boosting and sometimes better, and they do not overfit [7].

Nowadays, Random Forest is a method of ensemble learning widely used in the literature and applied fields. But the associate literature provides few or no directions about how many trees should be used to compose a Random Forest. In general, the user sets the number of trees in a *trial and error* basis. Sometimes when s/he increases the number of trees, in fact, only more computational power is spent, for almost no performance gain. In this study, we have analyzed the performance of Random Forests as the number of trees grows (from 2 to 4096 trees, and doubling the number of trees at every iteration), aiming to seek out for a number (or a range of numbers) of trees from which there is no more significant performance gain, unless huge computational resources are available for large datasets. As a complementary contribution, we have also analyzed the number (percentage) of attributes appearing within Random Forests of growing sizes.

The remaining of this paper is organized as follows. Section 2 describes some related work. Section 3 describes what Random Tree and Random Forest are and how they work. Section 4 provides some density-based metrics used to group datasets described in Section 5. Section 6 describes the methodology used, and results of the experiments are shown in Section 7. Section 8 presents some conclusions from this work.

2 Related Work

Since Random Forests are efficient, multi-class, and able to handle large attribute space, they have been widely used in several domains such as real-time face recognition [29], bioinformatics [16], and there are also some recent research

o erro é calculado, o peso das instâncias classificadas corretamente é reduzido e o peso das instâncias classificadas incorretamente é aumentado. O voto de cada aluno i ndividual é ponderado proporcionalmente ao seu desempenho [31].

No método de bagging (agregação de bootstrap), diferentes subconjuntos de treinamento são sorteados aleatoriamente com reposição de todo o conjunto de treinamento. Cada subconjunto de treinamento é alimentado como entrada para os alunos básicos. Todos os alunos extraídos são combinados por maioria de votos. Embora o ensacamento possa gerar classificadores em paralelo, o boosting os gera sequencialmente.

Random Forest é outro método de conjunto, que constrói muitas árvores de decisão que serão usadas para classificar uma nova instância por maioria de votos. Cada nó da árvore de decisão usa um subconjunto de atributos selecionados aleatoriamente de todo o conjunto original de atributos. Além disso, cada árvore usa dados de amostra de bootstrap diferentes da mesma maneira que o bagging.

Normalmente, o ensacamento é quase sempre mais preciso do que um único classificador, mas às vezes é muito menos preciso do que o reforço. Por outro lado, o boosting pode criar conjuntos menos precisos do que um único classificador. Em algu mas situações, o boosting pode superajustar conjuntos de dados ruidosos, diminuindo assim seu desempenho. As Florestas Aleatórias, por outro lado, são mais robustas do que as Booster no que diz respeito ao ruído; mais rápido do que ensacar e aumentar; seu desempenho é tão bom quanto um boost e às vezes até melhor, e eles não se ajustam demais [7].

Hoje em dia, Random Forest é um método de aprendizagem ensemble amplamente utilizado na literatura e nas áreas aplicadas. Mas a literatura associada fornece poucas ou nenhuma orientação sobre quantas árvores devem ser usadas para compor uma Floresta Aleatória. Em geral, o usuário define o número de árvores por tentativa e erro. Às vezes, quando ele/ela aumenta o número de árvores, na verdade, apenas mais poder computacional é gasto, quase sem ganho de desempenho. Neste estudo, analisamos o desempenho de Random Forests à medida que o número de árvores cresce (de 2 para 4.096 árvores, e dobrando o número de árvores a cada iteração), com o objetivo de buscar um número (ou um intervalo de números) de árvores das quais não haja ganho de desempenho mais significativo, a menos que enormes recursos computacionais estejam disponíveis para grandes conjuntos de dados. Como contribuição complementar, ta mbém analisamos o número (porcentagem) de atributos que aparecem em Florestas Aleatórias de tamanhos crescentes.

O restante deste artigo está organizado da seguinte forma. A seção 2 descreve alguns trabalhos relacionados. A Seção 3 descreve o que são Random Tree e Random Forest e como funcionam. A Seção 4 fornece algumas métricas baseadas em densidade usadas para agrupar conjuntos de dados descritos na Seção 5. A Seção 6 descreve a metodologia usada e os resultados dos experimentos são mostrados na Seção 7. A Seção 8 apresenta algumas conclusões deste trabalho.

2 Trabalhos Relacionados

Como as Florestas Aleatórias são eficientes, multiclasses e capazes de lidar com grandes espaços de atributos, elas têm sido amplamente utilizadas em vários domínios, como reconhecimento facial em tempo real [29], bioinformática [16], e também há algumas pesquisas recentes

in medical domain, for instance [18,6,21,19] as well as medical image segmentation [33,22,34,15,32].

A tracking algorithm using adaptive random forests for real-time face tracking is proposed by [29], and the approach was equally applicable to tracking any moving object. One of the first illustrations of successfully analyzing genome-wide association (GWA) data with Random Forests is presented in [16]. Random Forests, support vector machines, and artificial neural network models are developed in [18] to diagnose acute appendicitis. Random Forests are used in [6] to detect curvilinear structure in mammograms, and to decide whether it is normal or abnormal. In [21] it is introduced an efficient keyword based medical image retrieval method using image classification with Random Forests. A novel algorithm for the efficient classification of X-ray images to enhance the accuracy and performance using Random Forests with Local Binary Patterns is presented in [19]. An enhancement of the Random Forests to segment 3D objects in different 3D medical imaging modalities is proposed in [33]. Random Forests are evaluated on the problem of automatic myocardial tissue delineation in real-time 3D echocardiography in [22]. In [34] a new algorithm is presented for the automatic segmentation and classification of brain tissue from 3D MR scans. In [15] a new algorithm is presented for the automatic segmentation of Multiple Sclerosis (MS) lesions in 3D MR images. An automatic 3D Random Forests method which is applied to segment the fetal femur in 3D ultrasound and a weighted voting mechanism is proposed to generate the probabilistic class label is developed in [32].

There is one similar work to the one presented here. In [20] is proposed a simple procedure that *a priori* determine the minimum number of classifiers. They applied the procedure to four multiple classifiers systems, among them Random Forests. They used 5 large datasets, and produced forests with a maximum of 200 trees. They concluded that it was possible to limit the number of trees, and this minimum number could vary from one classifier combination method to another. In this study we have evaluated 29 datasets in forests with up to 4096 trees. In addition, we have also evaluated the percentage of attributes used in each forest.

3 Random Trees and Random Forests

Assume a training set T with a attributes, n instances, and define T_k a bootstrap training set sampled from T with replacement, and containing m random attributes ($m \leq a$) with n instances.

A Random Tree is a tree drawn at random from a set of possible trees, with m random attributes at each node. The term “at random” means that each tree has an equal chance of being sampled. Random Trees can be efficiently generated, and the combination of large sets of Random Trees generally lead to accurate models [35,10].

no domínio médico, por exemplo [18,6,21,19] bem como segmentação de imagens médicas [33,22,34,15,32].

Um algoritmo de rastreamento usando florestas aleatórias adaptativas para rastreamento facial em tempo real é proposto por [29], e a abordagem foi igualmente aplicável ao rastreamento de qualquer objeto em movimento. Uma das primeiras ilustrações da análise bem-sucedida de dados de associação genômica ampla (GWA) com Random Forests é apresentada em [16]. Random Forests, máquinas de vetores de suporte e modelos de redes neurais artificiais são desenvolvidos em [18] para diagnosticar apendicite aguda. Florestas Aleatórias são usadas em [6]para detectar estruturas curvilíneas em mamografias e para decidir se elas são normais ou anormais. Em [21] é introduzido um método eficiente de recuperação de imagens médicas baseado em palavras-chave usando classificação de imagens com Random Forests. Um novo algorit mo para a classificação eficiente de imagens de raios X para melhorar a precisão e o desempenho usando Florestas Aleatórias com Padrões Binários Locais é apresentado em [19]. Um aprimoramento das Random Forests para segmentar objetos 3D em diferentes modalidades de imagens médicas 3D é proposto em [33]. Random Forests são avaliadas no problema de delineamento automático de tecido miocárdico em ecocardiografia 3D e m tempo real em [22]. Em [34] é apresentado um novo algoritmo para segmentação e classificação automática de tecido cerebral a partir de exames de ressonância magnética 3D. Em [15] é apresentado um novo algoritmo para a segmentação automática de lesões de Esclerose Múltipla (EM) em imagens 3D de RM. Um método automático de Florestas Aleatórias 3D que é aplicado para segmentar o fêmur fetal em ultrassom 3D e um mecanismo de votação ponderada é proposto para gerar o rótulo de classe probabilística é desenvolvido em [32].

Existe um trabalho semelhante ao aqui apresentado. Em [20] é proposto um procedimento simples que determina a priori o número mínimo de classificadores. Eles aplicaram o procedimento a quatro sistemas classificadores múltiplos, entre eles Rando m Forests. Eles usaram 5 grandes conjuntos de dados e produziram florestas com no máximo 200 árvores. Concluíram que era possível limitar o número de árvores, e esse número mínimo poderia variar de um método de combinação de classificadores para outro. Neste estudo avaliamos 29 conjuntos de dados em florestas com até 4.096 árvores. Além disso, também avaliamos o percentual de atributos utilizados em cada floresta.

3 RandomTrees e RandomForests

Suponha um conjunto de treinamento T com atributos a , n instâncias e defina T_k um conjunto de treinamento de inicialização amostrado de T com substituição e contendo m atributos aleatórios ($m \leq a$) com instâncias n .

Uma Árvore Aleatória é uma árvore extraída aleatoriamente de um conjunto de árvores possíveis, com $m$atributos aleatórios em cada nó. O termo “aleatório” significa que cada árvore tem chances iguais de ser amostrada. Árvores Aleatórias podem ser geradas com eficiência, e a combinação de grandes conjuntos de Árvores Aleatórias geralmente leva a modelos precisos [35,10].

A Random Forest is defined formally as follows [7]: it is a classifier consisting of a collection of tree structured classifiers $\{h_k(\mathbf{x}, T_k)\}$, $k = 1, 2, \ldots, L$, where T_k are independent identically distributed random samples, and each tree casts a unit vote for the most popular class at input $\mathbf{x}$.

As already mentioned, Random Forests employ the same method bagging does to produce random samples of training sets (bootstrap samples) for each Random Tree. Each new training set is built, with replacement, from the original training set. Thus, the tree is built using the new subset, and a random attribute selection. The best split on the random attributes selected is used to split the node. The trees grown are not pruned.

The use of bagging method is justified by two reasons [7]: the use of bagging seems to enhance performance when random attributes are used; and bagging can be used to give ongoing estimates of the generalization error of the combined ensemble of trees, as well as estimates for the strength and correlation. Theses estimates are performed out-of-bag. In a Random Forest, the out-of-bag method works as follows: given a specific training set T, generate bootstrap training sets T_k, construct classifiers $\{h_k(\mathbf{x}, T_k)\}$ and let them vote to create the bagged classifier. For each $(\mathbf{x}, y)$ in the training set, aggregate the votes only over those classifiers for which T_k does not contain $(\mathbf{x}, y)$. This is the out-of-bag classifier. Then the out-of-bag estimate for the generalization error is the error rate of the out-of-bag classifier on the training set.

The error of a forest depends on the strength of the individual trees in the forest, and the correlation between any two trees in the forest. The strength can be interpreted as a measure of performance for each tree. Increasing the correlation increases the forest error rate, and increasing the strength of the individual trees decreases the forest error rate inasmuch as a tree with a low error rate is a strong classifier. Reducing the number of random attributes selected reduces both the correlation and the strength [23].

4 Density-Based Metrics for Datasets

It is well known from the computational learning theory that, given a hypotheses space (in this case, defined by the Random Forest classifier), it is possible to determine the training set complexity (size) for a learner to converge (with high probability) to a successful hypothesis [25, Chap. 7]. This requires knowing the hypotheses space size (i.e., its cardinality) or its capacity provided by the VC dimension [30]. In practice, finding the hypotheses space size or capacity is hard, and only recently an approach has defined the VC dimension for binary decision trees, at least partially, since it was defined in terms of left and right subtrees [4], whereas the gold standard should be defined in terms of the instances space.

On the other hand, datasets (instances space) metrics are much less discussed in the literature. Our concern is, once the hypotheses space is fixed (but its size or its VC dimension are both unknown or infinite), which training sets *seem* to have enough content so that learning could be successful. In a related work we have proposed some class balance metrics [27]. Since in this study we have used

Uma Floresta Aleatória é definida formalmente da seguinte forma [7]: é um classificador que consiste em uma coleção de classificadores estruturados em árvore $\{h_k(\mathbf{x}\ T_k)\}$, $k = 1, 2, \ldots, L$, ondeT_k são amostras aleatórias independentes e distribuídas de forma idêntica, e cada árvore lança um voto unitário para a classe mais popular na entrada x.

Como já mencionado, Random Forests empregam o mesmo método de bagging para produzir amostras aleatórias de conjuntos de treinamento (amostras de bootstrap) para cada Random Tree. Cada novo conjunto de treinamento é construído, com reposição, a partir do conjunto de treinamento original. Assim, a árvore é construída usando o novo subconjunto e uma seleção aleatória de atributos. A melhor divisão nos atributos aleatórios selecionados é usada para dividir o nó. As árvores cultivadas não são podadas.

O uso do método bagging é justificado por dois motivos [7]: o uso do bagging parece melhorar o desempenho quando atributos aleatórios são usados; e o ensacamento pode m ser usados para fornecer estimativas contínuas do erro de generalização do conjunto combinado de árvores, bem como estimativas de força e correlação. Essas estimativas são realizadas imediatamente. Em uma Random Forest, o método out-of-bag funciona da seguinte maneira: dado um conjunto de treinamento específico T, gere conjuntos de treinamento bootstrap T_k, construa classificadores $\{h_k(\mathbf{x}\ T_k)\}$ e deixe-os votar para criar o classificador bagged. Para cada (x y) no conjunto de treinamento, agregue os votos apenas sobre os classificadores para os quais T_k não contém (x y). Este é o classificador out-of-bag. Então, a estimativa out-of-bag para o erro de generalização é a taxa de erro do classificador out-of-bag no conjunto de treinamento.

O erro de uma floresta depende da força de cada árvore na floresta e da correlação entre quaisquer duas árvores na floresta. A resistência pode ser interpretada como uma medida de desempenho de cada árvore. Aumentar a correlação aumenta a taxa de erro da floresta, e aumentar a força das árvores individuais diminui a taxa de erro da floresta, na medida em que uma árvore com uma taxa de erro baixa é um classificador forte. A redução do número de atributos aleatórios selecionados reduz tanto a correlação quanto a força [23].

4 Métricas Baseadas em Densidade para Conjuntos de Dados

É bem sabido pela teoria de aprendizagem computacional que, dado um espaço de hipóteses (neste caso, definido pelo classificador Random Forest), é possível determinar a complexidade (tamanho) do conjunto de treinamento para um aprendiz convergir (com alta probabilidade) para uma hipótese bem sucedida [25, Cap. 7]. Isto requer conhecer o tamanho do espaço de hipóteses (ou seja, sua cardinalidade) ou sua capacidade fornecida pela dimensão VC [30]. Na prática, encontrar o tamanho ou capacidade do espaço das hipóteses é difícil, e apenas recentemente uma abordagem definiu a dimensão VC para árvores de decisão binárias, pelo menos parcialmente, uma vez que foi definida em termos de subárvores esquerda e direita [4],enquanto o padrão ouro deveria ser definido em termos de espaço de instâncias.

Por outro lado, métricas de conjuntos de dados (espaço de instâncias) são muito menos discutidas na literatura. Nossa preocupação é, uma vez que o espaço de hipóteses é fixo (mas seu tamanho ou sua dimensão VC são ambos desconhecidos ou infinitos), quais conjuntos de treinamento parecem ter conteúdo suficiente para que a aprendizagem possa ser bem-sucedida. Em um trabalho relacionado propusemos algumas métricas de equilíbrio de classes [27]. Como neste estudo usamos

datasets with very different numbers of classes, instances and attributes, they cannot be grouped in some (intuitive) sense using these three dimensions. For this purpose, we suggest here three different metrics, shown in (1), (2), and (3), where each dataset has c classes, a attributes, and n instances.

These metrics have been designed using the following ideas. For a physical object, the density D is its mass divided by its volume. For a dataset, we have considered its mass as the number of instances; its volume given by its attributes. Here we have used the concept the volume of an object (dataset) is understood as its capacity, i.e., the amount of fluid (attributes) that the object could hold, rather than the amount of space the object itself displaces. Under these considerations, we have $D \triangleq \frac{n}{a}$. Since, in general, these numbers vary considerably, a better way to looking at them was using both numbers in the natural logarithmic scale, $D \triangleq \frac{\ln n}{\ln a}$ which lead us to (1). In the next metric we have considered the number of instances (mass) is rarefied by the number of classes, therefore providing (2), and the last one embraces empty datasets (no instances) and datasets without the class label (unsupervised learning).

$$D_1 \triangleq \log_a n \tag{1}$$

$$D_2 \triangleq \log_a \frac{n}{c} \tag{2}$$

$$D_3 \triangleq \log_a \frac{n+1}{c+1} \tag{3}$$

Considering the common assumption in machine learning that $c \leq n$ (in general, $c \ll n$), it is obvious that, for every metric D_i, $D_i \geq 0$, $i = 1, 2, 3$. We considered that if $D_i < 1$, the density is low, and *perhaps* learning from this dataset should be difficult, under the computational point of view. Otherwise, $D_i \geq 1$, the density is high, and learning *may be* easier.

According to [4] the VC dimension of a binary tree is $\mathrm{VC} = 0.7(1 + \mathrm{VC}_l + \mathrm{VC}_r - \log a) + 1.2 \log M$, where VC_l and VC_r represent the VC dimension of its left and right subtrees and M is the number of nodes in the tree. Considering this, our density-based metrics may capture important information about the VC dimension: (i) the number a of attributes is directly expressed in this equation; (ii) since having more classes implies the tree must have more leaves, the number c of classes is related to the number of leaves, and more leaves implies larger M, therefore c is related to M, and probably VC_l and VC_r; (iii) the number n of instances does not appear directly in this expression but it is surely related to VC_l, VC_r, a and/or M, once the VC dimension of a hypotheses space is defined over the instances space [25, Section 7.4.2].

Intuitively, decision trees are able to represent the family of boolean functions and, in this case, the number n of required training instances for a boolean attributes is $n = 2^a$, and therefore $a = \log_2 n$; in other words, n is related to a as well as M, since more nodes are necessary for larger a values. For these problems expressed by boolean functions with $a \geq 2$ attributes and $n = 2^a$ instances,

conjuntos de dados com números muito diferentes de classes, instâncias e atributos, eles não podem ser agrupados em algum sentido (intuitivo) usando essas três dimensões. Para tanto, sugerimos aqui três métricas diferentes, mostradas em (1), (2) e (3), onde cada conjunto de dados possui c classes, a atributos e n instâncias.

Essas métricas foram projetadas usando as ideias a seguir. Para um objeto físico, a densidade D é a sua massa dividida pelo seu volume. Para um conjunto de dados, consideramos a sua massa como o número de instâncias; seu volume dado por seus atributos. Aqui usamos o conceito de que o volume de um objeto (conjunto de dados) é entendido como sua capacidade, ou seja, a quantidade de fluido (atributos) que o objeto poderia conter, e não a quantidade de espaço que o próprio objeto desloca. Sob estas considerações, temos $D \triangleq \frac{n}{a}$. Como, em geral, estes números variam consideravelmente, a melhor forma de observá-los seria utilizar ambos os números na escala logarítmica natural, $D \triangleq \ln n \ln a$ o que nos leva a (1). Na próxima métrica consideramos que o número de instâncias (massa) é rarefeito pelo número de classes, fornecendo portanto (2), e a última abrange conjuntos de dados vazios (sem instâncias) e conjuntos de dados sem o rótulo de classe (aprendizagem não supervisionada).

$$D_1 \triangleq \log_a n \tag{1}$$

$$D_2 \triangleq \log_a \frac{n}{c} \tag{2}$$

$$D_3 \triangleq \log_a \frac{n+1}{c+1} \tag{3}$$

Considerando a suposição comum em aprendizado de máquina de que $c \leq n$ (em geral, $c \ll n$), é óbvio que, para cada métrica D_i, $D_i \geq 0$, $i = 1$,2,3. Consideramos que se $D_i < 1$, a densidade é baixa, e talvez aprender com este conjunto de dados seja difícil, do ponto de vista computacional. Caso contrário, $D_i \geq 1$, a densidade é alta e o aprendizado pode ser mais fácil.

De acordo com [4] a dimensão VC de uma árvore binária é $\mathrm{VC} = 0.7(1 + \mathrm{VC}_l + \mathrm{VC}_r - \log a) + 1.2 \log M$, onde VC_l e VC_r representam a dimensão VC de suas subárvores esquerda e direita e M é o número de nós na árvore. Considerando isso, nossas métricas baseadas em densidade podem capturar informações importantes sobre a dimensão VC: (i) o número a de atributos é expresso diretamente nesta equação; (ii) como ter mais classes implica que a árvore deve ter mais folhas, o número c de classes está relacionado ao número de folhas, e mais folhas implica M maior, portanto c está relacionado a M, e provavelmente VC_l e VC_r; (iii) o número n de instâncias não aparece diretamente nesta expressão, mas certamente está relacionado a VC_l, VC_r, a e/ou M, uma vez que a dimensão VC de um espaço de hipóteses é definida sobre o espaço de instâncias [25, Seção 7.4.2].

Intuitivamente, as árvores de decisão são capazes de representar a família de funções booleanas e, neste caso, o número n de instâncias de treinamento necessárias para a atributos booleanos é $n = 2^a$ e, portanto, $a = \log_2 n$; em outras palavras, n está relacionado a a bem como a M, uma vez que mais nós são necessários para valores maiores de a . Para esses problemas expressos por funções booleanas com $a \geq 2$ atributos e $n = 2^a$ instâncias,

Table 1. Density-based metrics for binary class problems ($c = 2$) expressed by boolean functions with a attributes and $n = 2^a$ instances

a	n	D_1	D_2	D_3
2	4	2.00	1.00	**0.74**
3	8	1.89	1.26	1.00
4	16	2.00	1.50	1.25
5	32	2.15	1.72	1.49

$D_i \geq 1$ (except $D_3 = 0.74$ for $a = 2$), according to Table 1. Nevertheless, the proposed metrics are able to capture the fact binary class problems have high-density, indicating there is, probably, enough content so learning can take place.

5 Datasets

The experiments reported here used 29 datasets, all representing real medical data, and none of which had missing values for the class attribute. The biomedical domain is of particular interest since it allows one to evaluate Random Forests under real and difficult situations often faced by human experts.

Table 2 shows a summary of the datasets, and the corresponding density metrics defined in the previous section. Datasets are ordered according to metric D_2, obtaining 8 low-density and 21 high-density datasets. In the remaining of this section, a brief description of each dataset is provided.

Breast Cancer, Lung Cancer, CNS (Central Nervous System Tumour Outcome), *Lymphoma, GCM* (Global Cancer Map), *Ovarian 61902, Leukemia, Leukemia nom., WBC* (Wisconsin Breast Cancer), *WDBC* (Wisconsin Diagnostic Breast Cancer), *Lymphography* and *H. Survival* (*H.* stands for *Haberman's* are all related to cancer and their attributes consist of clinical, laboratory and gene expression data. *Leukemia* and *Leukemia nom.* represent the same data, but the second one had its attributes discretized [26]. *C. Arrhythmia* (*C.* stands for *Cardiac*), *Heart Statlog, HD Cleveland, HD Hungarian* and *HD Switz.* (*Switz.* stands for *Switzerland*) are related to heart diseases and their attributes represent clinical and laboratory data. *Allhyper, Allhypo, ANN Thyroid, Hypothyroid, Sick* and *Thyroid 0387* are a series of datasets related to thyroid conditions. *Hepatitis* and *Liver Disorders* are related to liver diseases, whereas *C. Method* (*C.* stands for *Contraceptive*), *Dermatology, Pima Diabetes* (Pima Indians Diabetes) and *P. Patient* (*P.* stands for *Postoperative*) are other datasets related to human conditions. *Splice Junction* is related to the task of predicting boundaries between exons and introns. Datasets were obtained from the UCI Repository [11], except *CNS, Lymphoma, GCM* and *ECML* were obtained from [2]; *Ovarian 61902* was obtained from [3]; *Leukemia* and *Leukemia nom.* were obtained from [1].

Tabela 1. Métricas baseadas em densidade para problemas de classe binária ($c = 2$) expressadas por funções booleanas com atributos a e instâncias $n = 2^a$

a	n	D_1	D_2	D_3
2	4	2,00	1,00	0,74
3	8	1,89	1,26	1,00
4	16	2,00	1,50	1,25
5	32	2,15	1,72	1,49

$D_i \geq 1$ (exceto $D_3 = 0.74$ para $a = 2$), conforme Tabela 1. No entanto, as métricas propostas são capazes de capturar o fato de que problemas de classes binárias possuem alta densidade, indicando que provavelmente há conteúdo suficiente para que o aprendizado possa ocorrer.

5 conjuntos de dados

Os experimentos aqui relatados usaram 29 conjuntos de dados, todos representando dados médicos reais, e nenhum deles tinha valores faltantes para o atributo de classe. O domínio biomédico é de particular interesse, pois permite avaliar Florestas Aleatórias e m situações reais e difíceis frequentemente enfrentadas por especialistas humanos.

A Tabela 2 mostra um resumo dos conjuntos de dados e as métricas de densidade correspondentes definidas na seção anterior. Os conjuntos de dados são ordenados de acordo com a métricaD_2, obtendo 8 conjuntos de dados de baixa densidade e 21 conjuntos de dados de alta densidade. No restante desta seção, é fornecida uma breve descrição de cada conjunto de dados.

Câncer de mama, câncer de pulmão, CNS (resultado de tumor do sistema nervoso central), linfoma, GCM (mapa global de câncer), ovário 61902, leucemia, leucemia nom., WBC (câncer de mama de Wisconsin), WDBC (câncer de mama diagnóstico de Wisconsin), linfografia e H. Sobrevivência (H. significa Haberman's estão todos relacionados ao câncer e seus atributos consistem em aspectos clínicos, laboratoriais e dados de expressão gênica. Leucemia e Leucemia nom representam os mesmos dados, mas o segundo teve seus atributos discretizados [26]. Arritmia (C. significa Cardiac), Heart Statlog, HD Cleveland, HD Hungaro e HD Switz (Switz. significa Switzerland) estão relacionados a doenças cardíacas e seus atributos representam dados clínicos e laboratoriais. uma série de conjuntos de dados relacionados a doenças da tireoide e distúrbios hepáticos estão relacionados a doenças hepáticas, enquanto C. Método (C. significa Contraceptivo), Dermatologia, Pima Diabetes (Pima Indians Diabetes) e P. Paciente (P. significa Pós-operatório) são outros conjuntos de dados relacionados a condições humanas. Splice Junction está relacionado à tarefa de prever limites entre exons e íntrons. CNS, Linfoma, GCM e ECML foram obtidos de [2] Ovário 61902 foi obtido de [3];

Table 2. Summary of the datasets used in the experiments, where n indicates the number of instances; c represents the number of classes; a, $a_{\#}$ and a_a indicates the total number of attributes, the number of numerical and the number of nominal attributes, respectively; MISS represents the percentage of attributes with missing values, not considering the class attribute; the last 3 columns are the density metrics D_1, D_2, D_3 of each dataset, respectively. Datasets are in ascending order by D_2.

Dataset	n	c	$a(a_{\#},a_a)$	MISS	D_1	D_2	D_3
GCM	190	14	16063 (16063, 0)	0.00%	0.54	0.27	0.26
Lymphoma	96	9	4026 (4026, 0)	5.09%	0.55	0.28	0.27
CNS	60	2	7129 (7129, 0)	0.00%	0.46	0.38	0.34
Leukemia	72	2	7129 (7129, 0)	0.00%	0.48	0.40	0.36
Leukemia nom.	72	2	7129 (7129, 0)	0.00%	0.48	0.40	0.36
Ovarian 61902	253	2	15154 (15154, 0)	0.00%	0.57	0.50	0.46
Lung Cancer	32	3	56 (0, 56)	0.28%	0.86	0.59	0.52
C. Arrhythmia	452	16	279 (206, 73)	0.32%	1.08	0.59	0.58
Dermatology	366	6	34 (1, 33)	0.06%	1.67	1.17	1.12
HD Switz.	123	5	13 (6, 7)	17.07%	1.88	1.25	1.18
Lymphography	148	4	18 (3, 15)	0.00%	1.73	1.25	1.17
Hepatitis	155	2	19 (6, 13)	5.67%	1.71	1.48	1.34
HD Hungarian	294	5	13 (6, 7)	20.46%	2.21	1.59	1.52
HD Cleveland	303	5	13 (6, 7)	0.18%	2.22	1.60	1.53
P. Patient	90	3	8 (0, 8)	0.42%	2.16	1.63	1.50
WDBC	569	2	30 (30, 0)	0.00%	1.86	1.66	1.54
Splice Junction	3190	3	60 (0, 60)	0.00%	1.97	1.70	1.63
Heart Statlog	270	2	13 (13, 0)	0.00%	2.18	1.91	1.75
Allhyper	3772	5	29 (7, 22)	5.54%	2.44	1.97	1.91
Allhypo	3772	4	29 (7, 22)	5.54%	2.44	2.03	1.97
Sick	3772	2	29 (7, 22)	5.54%	2.44	2.24	2.12
Breast Cancer	286	2	9 (0, 9)	0.35%	2.57	2.26	2.07
Hypothyroid	3163	2	25 (7, 18)	6.74%	2.50	2.29	2.16
ANN Thyroid	7200	3	21 (6, 15)	0.00%	2.92	2.56	2.46
WBC	699	2	9 (9, 0)	0.25%	2.98	2.66	2.48
C. Method	1473	3	9 (2, 7)	0.00%	3.32	2.82	2.69
Pima Diabetes	768	2	8 (8, 0)	0.00%	3.19	2.86	2.67
Liver Disorders	345	2	6 (6, 0)	0.00%	3.26	2.87	2.65
H. Survival	306	2	3 (2, 1)	0.00%	5.21	4.58	4.21

6 Experimental Methodology

Using the open source machine learning Weka [17], experiments were conducted building Random Forests with varying number of trees in exponential rates using base two, i.e., $L = 2^j$, $j = 1, 2, \ldots, 12$. Two measures to analyze the results were chosen: the weighted average area under the ROC curve (AUC), and the percentage of attributes used in each Random Forest. To assess performance, the experiments used ten repetitions of 10-fold cross-validation. The average of all repetitions for a given forest on a certain dataset was taken as the value of performance (AUC and percentage) for the pair.

In order to analyze if the results were significantly different, we applied the Friedman test [13], considering a significance level of 5%. If the Friedman test rejects the null hypothesis, a *post-hoc* test is necessary to check in which classifier pairs the differences actually are significant [9]. The *post-hoc* test used was the Benjamini-Hochberg [5], and we performed an all versus all comparison, making

Tabela 2. Resumo dos conjuntos de dados utilizados nos experimentos, onde n indica o número de instâncias; c representa o número de classes; a, $a_{\#}$ e a_a indica o número total de atributos, o número de atributos numéricos e o número de atributos nominais, respectivamente; MISS representa o percentual de atributos com valores faltantes, sem considerar o atributo de classe; as últimas 3 colunas são as métricas de densidade D_1, D_2, D_3 de cada conjunto de dados, respectivamente. Os conjuntos de dados estão em ordem crescente por D_2.

Conjunto de dados	n	c	$a(a_{\#},a_a)$ SENHORITA	D_1	D_2	D_3
GCM	190	14	16063 (16063, 0) 0,00% 0,54 0,27 0,26			
Linfoma	96	9	4026 (4026, 0) 5,09% 0,55 0,28 0,27			
CNS	60	2	7129 (7129, 0) 0,00% 0,46 0,38 0,34			
Leucemia	72	2	7129 (7129, 0) 0,00% 0,48 0,40 0,36			
Leucemia nom.	72	2	7129 (7129, 0) 0,00% 0,48 0,40 0,36			
Ovário 61902	253	2	15154 (15154, 0) 0,00% 0,57 0,50 0,46			
Câncer de Pulmão	32	3	56 (0, 56) 0,28% 0,86 0,59 0,52			
C. Arritmia	452	16	279 (206, 73) 0,32% 1,08 0,59 0,58			
Dermatologia	366	6	34 (1, 33) 0,06% 1,67 1,17 1,12			
HD Suíça.	123	5	13 (6, 7) 17,07% 1,88 1,25 1,18			
Linfografia	148	4	18 (3, 15) 0,00% 1,73 1,25 1,17			
Hepatite	155	2	19 (6, 13) 5,67% 1,71 1,48 1,34			
HD Húngaro	294	5	13 (6, 7) 20,46% 2,21 1,59 1,52			
HD Cleveland	303	5	13 (6, 7) 0,18% 2,22 1,60 1,53			
P. Paciente	90	3	8 (0, 8) 0,42% 2,16 1,63 1,50			
WDBC	569	2	30 (30, 0) 0,00% 1,86 1,66 1,54			
Junção de Emenda	3190	3	60 (0, 60) 0,00% 1,97 1,70 1,63			
Registro do coração	270	2	13 (13, 0) 0,00% 2,18 1,91 1,75			
Tudo hiper	3772	5	29 (7, 22) 5,54% 2,44 1,97 1,91			
Allhipo	3772	4	29 (7, 22) 5,54% 2,44 2,03 1,97			
Sick	3772	2	29 (7, 22) 5,54% 2,44 2,24 2,12			
Câncer de mama	286	2	9 (0, 9) 0,35% 2,57 2,26 2,07			
Hipotireoidismo	3163	2	25 (7, 18) 6,74% 2,50 2,29 2,16			
ANN Tireóide	7200	3	21 (6, 15) 0,00% 2,92 2,56 2,46			
WBC	699	2	9 (9, 0) 0,25% 2,98 2,66 2,48			
C. Método	1473	3	9 (2, 7) 0,00% 3,32 2,82 2,69			
Diabetes Pima	768	2	8 (8, 0) 0,00% 3,19 2,86 2,67			
Distúrbios hepáticos	345	2	6 (6, 0) 0,00% 3,26 2,87 2,65			
H. Sobrevivência	306	2	3 (2, 1) 0,00% 5,21 4,58 4,21			

6 Metodologia Experimental

Usando o aprendizado de máquina de código aberto, experimentos Weka [17], foram conduzidos construindo Florestas Aleatórias com número variável de árvores em taxas exponenciais usando base dois, ou seja, $L = 2^j$, $j = 1, 2, \ldots, 12$. Foram escolhidas duas medidas para análise dos resultados: a área média ponderada sob a curva ROC (AUC) e a porcentagem de atributos utilizados em cada Floresta Aleatória. Para avaliar o desempenho, os experimentos utilizaram dez repetições de validação cruzada de 10 vezes. A média de todas as repetições para uma determinada floresta em um determinado conjunto de dados foi tomada como o valor do desempenho (AUC e porcentagem) do par.

Para analisar se os resultados foram significativamente diferentes, aplicamos o teste de Friedman [13], considerando um nível de significância de 5%. Se o teste de Friedman rejeitar a hipótese nula, é necessário um teste post-hoc para verificar em quais pares de classificadores as diferenças são realmente significativas [9]. O teste post-hoc utilizado foi o de Benjamini-Hochberg [5], e realizamos uma comparação tudo versus todos, fazendo

all possible comparisons among the twelve forests. The tests were performed using the R software for statistical computing (`http://www.r-project.org/`).

7 Results and Discussion

The AUC values obtained for each dataset, and each number of trees within a Random Forest are presented in Table 3. We also provide in this table mean and median figures as well as the average rank obtained in the Friedman test. Mean, median and average rank are presented for the following groups: all datasets; only the 8 low-density datasets; and only the 21 high-density ones.

As can be seen, in all groups (all/8 low-density/21 high-density) the forest with 4096 trees has the smallest (best) rank of all. Besides, in the 21 high-density group, we can observe the forests with 2048 and 4096 trees have the same rank. Analyzing the group using all datasets and the 8 low-density datasets, we can notice that the forest with 512 trees has a better rank than the forest with 1024 trees, contrary to what would be expected. Another interesting result concerns mean and median values of high-density datasets for each one of the first three iterations, $L = 2, 4, 8$, are larger than low-density ones; the contrary is true for $L = 16, \ldots, 4096$. This may suggest low-density datasets, in fact, require more expressiveness power (larger forests) than high-density ones. This expressiveness power, of course, can be expressed as the Random Forests (hypotheses) space size or its VC dimension, as explained in Section 4.

In order to get a better understanding, AUC values are also presented in boxplots in Figures 1, 2 and 3 considering all datasets, only the 8 low-density datasets and only the 21 high-density datasets, respectively. As can be seen, in Figures 1 and 2, both mean and median increase as the number of trees grows, but from 64 trees and beyond these figures do not present major changes. In Figure 3, mean and median do not present major changes from 32 trees and 16 trees, respectively.

With these results we can notice an asymptotical behavior, where increases in the AUC values are harder to obtain, even doubling the number of trees within a forest. One way to comprehend this asymptotical behavior is computing the AUC difference from one iteration to the next (for instance, from 2 to 4, 4 to 8, etc.). These results are presented in Figures 4, 5 and 6 for all, 8 low-density and 21 high-density datasets, respectively. For this analysis, we have excluded AUC differences from datasets reaching AUC value equal to 99.99% before 4096 trees (boldface figures in Table 3). Analyzing them, we can notice that using all datasets and the 8 low-density datasets AUC differences (mean and median) between 32 and 64 trees in the forest are below 1%. Considering the 21 high-density datasets, these differences are below 1% between 16 and 32 trees in the forest, and below 0.3% between 32 and 64 trees.

Analyzing Figures 4, 5 and 6, we have adjusted mean and median values by least squares fit to the curve $g = aL^b$, where g represents the percentage AUC difference (gain), and L is the number of trees within the forest. We have obtained

todas as comparações possíveis entre as doze florestas. Os testes foram realizados utilizando o software R para computação estatística (//www.r-project.org/).

7 Resultados e Discussão

Os valores de AUC obtidos para cada conjunto de dados e cada número de árvores dentro de uma Floresta Aleatória são apresentados na Tabela 3. Também fornecemos nesta tabela valores médios e medianos, bem como a classificação média obtida no teste de Friedman. Média, mediana e classificação média são apresentadas para os seguintes grupos: todos os conjuntos de dados; apenas os 8 conjuntos de dados de baixa densidade; e apenas os 21 de alta densidade.

Como pode ser visto, em todos os grupos (todos/8 baixa densidade/21 alta densidade) a floresta com 4.096 árvores tem a menor (melhor) classificação de todas. Além disso, no grupo 21 de alta densidade, podemos observar que as florestas com 2.048 e 4.096 árvores possuem a mesma classificação. Analisando o grupo utilizando todos os conjuntos de dados e os 8 conjuntos de dados de baixa densidade, podemos notar que a floresta com 512 árvores tem uma classificação melhor que a floresta com 1024 árvores, ao contrário do que seria esperado. Outro resultado interessante diz respeito aos valores médios e medianos dos conjuntos de dados de alta densidade para cada uma das três primeiras iterações, $L = 2$, 4, 8, são maiores que os de baixa densidade; o contrário é verdadeiro para$L = 16, \ldots$, 4096. Isto pode sugerir que conjuntos de dados de baixa densidade, de fato, requerem mais poder de expressividade (florestas maiores) do que os de alta densidade. Esse poder de expressividade, é claro, pode ser expresso como o tamanho do espaço das Florestas Aleatórias (hipóteses) ou sua dimensão VC, conforme explicado na Seção 4.

Para melhor compreensão, os valores de AUC também são apresentados em boxplots nas Figuras 1, 2 e 3 considerando todos os conjuntos de dados, apenas os 8 conjuntos de dados de baixa densidade e apenas os 21 conjuntos de dados de alta densidade, respectivamente. Como pode ser observado nas Figuras 1 e 2, tanto a média quanto a mediana aumentam à medida que o número de árvores cresce, mas a partir de 64 árvores esses números não apresentam grandes alterações. Na Figura 3, média e mediana não apresentam grandes alterações de 32 árvores e 16 árvores, res pectivamente.

Com estes resultados podemos notar um comportamento assintótico, onde aumentos nos valores de AUC são mais difíceis de obter, chegando até a duplicar o número de árvores dentro de uma floresta. Uma maneira de compreender esse comportamento assintótico é calcular a diferença de AUC de uma iteração para a próxima (por exemplo, de 2 para 4, 4 para 8, etc.). Esses resultados são apresentados nas Figuras 4, 5 e 6 para todos os conjuntos de dados, 8 de baixa densidade e 21 de alta densidade, respectivamente. Para esta análise, excluímos as diferenças de AUC de conjuntos de dados que atingiram um valor de AUC igual a 99,99% antes de 4.096 árvores (valores em negrito na Tabela 3). Analisando-os, podemos notar que usando todos os conjuntos de dados e os 8 conjuntos de dados de baixa densidade, as diferenças de AUC (média e mediana) entre 32 e 64 árvores na floresta estão abaixo de 1%. Considerando os 21 conjuntos de dados de alta densidade, essas diferenças ficam abaixo de 1% entre 16 e 32 árvores na floresta, e abaixo de 0,3% entre 32 e 64 árvores.

Analisando as Figuras 4, 5 e 6, ajustamos os valores médios e medianos por mínimos quadrados ajustados à curva $g = aL^b$, onde g representa a diferença percentual de AUC (ganho) e L é o número de árvores dentro da floresta. Nós obtivemos

Table 3. AUC values, mean, median and average rank obtained in the experiments. Boldface figures represent values excluded from the AUC difference analysis.

Datasets	Number of Trees											
	2	4	8	16	32	64	128	256	512	1024	2048	4096
GCM	0.72	0.77	0.83	0.87	0.89	0.91	0.91	0.92	0.92	0.92	0.93	0.93
Lymphoma	0.85	0.92	0.96	0.98	0.98	0.99	0.99	0.99	0.99	0.99	0.99	0.99
CNS	0.50	0.52	0.56	0.58	0.59	0.59	0.59	0.58	0.60	0.60	0.60	0.60
Leukemia	0.76	0.85	0.93	0.97	0.98	0.98	0.99	0.99	0.99	0.99	0.99	1.00
Leukemia nom.	0.72	0.81	0.91	0.96	0.99	1.00	**1.00**	**1.00**	**1.00**	**1.00**	**1.00**	**1.00**
Ovarian 61902	0.90	0.96	0.98	0.99	0.99	0.99	1.00	1.00	1.00	1.00	1.00	1.00
Lung Cancer	0.58	0.64	0.66	0.65	0.65	0.66	0.66	0.68	0.69	0.68	0.68	0.69
C. Arrhythmia	0.71	0.77	0.82	0.85	0.87	0.88	0.89	0.89	0.89	0.89	0.89	0.89
Dermatology	0.97	0.99	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
HD Switz.	0.55	0.55	0.58	0.58	0.60	0.61	0.60	0.60	0.60	0.61	0.61	0.61
Lymphography	0.82	0.87	0.90	0.92	0.93	0.93	0.93	0.93	0.93	0.93	0.93	0.93
Hepatitis	0.76	0.80	0.83	0.84	0.85	0.85	0.85	0.85	0.86	0.85	0.86	0.86
HD Hungarian	0.80	0.84	0.86	0.87	0.88	0.88	0.88	0.88	0.88	0.88	0.88	0.88
HD Cleveland	0.80	0.84	0.87	0.88	0.89	0.89	0.90	0.89	0.89	0.89	0.90	0.90
P. Patient	0.45	0.45	0.46	0.46	0.45	0.45	0.45	0.45	0.45	0.45	0.45	0.45
WDBC	0.96	0.98	0.99	0.99	0.99	0.99	0.99	0.99	0.99	0.99	0.99	0.99
Splice Junction	0.87	0.93	0.97	0.99	0.99	0.99	0.99	1.00	1.00	1.00	1.00	1.00
Heart Statlog	0.80	0.84	0.87	0.89	0.89	0.89	0.90	0.90	0.90	0.90	0.90	0.90
Allhyper	0.89	0.95	0.98	0.99	0.99	1.00	1.00	1.00	1.00	1.00	1.00	1.00
Allhypo	0.98	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
Sick	0.92	0.97	0.99	0.99	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
Breast Cancer	0.60	0.63	0.64	0.65	0.65	0.66	0.66	0.67	0.66	0.66	0.66	0.66
Hypothyroid	0.95	0.97	0.98	0.98	0.99	0.99	0.99	0.99	0.99	0.99	0.99	0.99
ANN Thyroid	0.99	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
WBC	0.97	0.98	0.99	0.99	0.99	0.99	0.99	0.99	0.99	0.99	0.99	0.99
C. Method	0.62	0.64	0.66	0.66	0.67	0.67	0.67	0.68	0.68	0.68	0.68	0.68
Pima Diabetes	0.72	0.76	0.79	0.81	0.81	0.82	0.82	0.82	0.82	0.82	0.83	0.83
Liver Disorders	0.66	0.70	0.72	0.74	0.75	0.76	0.76	0.77	0.77	0.77	0.77	0.77
H. Survival	0.58	0.60	0.61	0.62	0.63	0.63	0.64	0.64	0.64	0.64	0.64	0.64
All												
Mean	0.77	0.81	0.84	0.85	0.86	0.86	0.86	0.87	0.87	0.87	0.87	0.87
Median	0.80	0.84	0.87	0.89	0.89	0.91	0.91	0.92	0.92	0.92	0.93	0.93
Average rank	11.83	10.55	8.79	8.05	6.88	5.81	5.12	4.62	4.31	4.39	3.91	3.72
8 low-density												
Mean	0.72	0.78	0.83	0.85	0.87	0.88	0.88	0.88	0.88	0.88	0.89	0.89
Median	0.72	0.79	0.87	0.91	0.93	0.94	0.95	0.96	0.96	0.96	0.96	0.96
Average rank	12.00	11.00	9.62	8.81	7.94	6.25	4.81	4.44	3.37	3.69	3.37	2.69
21 high-density												
Mean	0.79	0.82	0.84	0.85	0.86	0.86	0.86	0.86	0.86	0.86	0.86	0.86
Median	0.80	0.84	0.87	0.89	0.89	0.89	0.90	0.90	0.90	0.90	0.90	0.90
Average rank	11.76	10.38	8.47	7.76	6.47	5.64	5.24	4.69	4.66	4.66	4.12	4.12

Tabela 3. Valores de AUC, média, mediana e classificação média obtidos nos experimentos. Os números em negrito representam valores excluídos da análise de diferença de AUC.

Conjuntos de dados	Número de árvores											
	2	4	8	16	32	64	128	256	512	1024	2048	4096
GCM	0,72	0,77	0,83	0,87	0,89	0,91	0,91	0,92	0,92	0,92	0,93	0,93
Linfoma	0,85	0,92	0,96	0,98	0,98	0,99	0,99	0,99	0,99	0,99	0,99	0,99
CNS	0,50	0,52	0,56	0,58	0,59	0,59	0,59	0,58	0,60	0,60	0,60	0,60
Leucemia	0,76	0,85	0,93	0,97	0,98	0,98	0,99	0,99	0,99	0,99	0,99	1,00
Leucemia nom.	0,72	0,81	0,91	0,96	0,99	1,00	1,00	1,00	1,00	1,00	1,00	1,00
Ovário 61902	0,90	0,96	0,98	0,99	0,99	0,99	1,00	1,00	1,00	1,00	1,00	1,00
Câncer de Pulmão	0,58	0,64	0,66	0,65	0,65	0,66	0,66	0,68	0,69	0,68	0,68	0,69
C. Arritmia	0,71	0,77	0,82	0,85	0,87	0,88	0,89	0,89	0,89	0,89	0,89	0,89
Dermatologia	0,97	0,99	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00
HD Suíça.	0,55	0,55	0,58	0,58	0,60	0,61	0,60	0,60	0,60	0,61	0,61	0,61
Linfografia	0,82	0,87	0,90	0,92	0,93	0,93	0,93	0,93	0,93	0,93	0,93	0,93
Hepatite	0,76	0,80	0,83	0,84	0,85	0,85	0,85	0,85	0,86	0,85	0,86	0,86
HD Húngaro	0,80	0,84	0,86	0,87	0,88	0,88	0,88	0,88	0,88	0,88	0,88	0,88
HD Cleveland	0,80	0,84	0,87	0,88	0,89	0,89	0,90	0,89	0,89	0,89	0,90	0,90
P. Paciente	0,45	0,45	0,46	0,46	0,45	0,45	0,45	0,45	0,45	0,45	0,45	0,45
WDBC	0,96	0,98	0,99	0,99	0,99	0,99	0,99	0,99	0,99	0,99	0,99	0,99
Junção de emenda	0,87	0,93	0,97	0,99	0,99	0,99	0,99	1,00	1,00	1,00	1,00	1,00
Registro do coração	0,80	0,84	0,87	0,89	0,89	0,89	0,90	0,90	0,90	0,90	0,90	0,90
Tudo hiper	0,89	0,95	0,98	0,99	0,99	1,00	1,00	1,00	1,00	1,00	1,00	1,00
Allhipo	0,98	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00
Sick	0,92	0,97	0,99	0,99	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00
Câncer de mama	0,60	0,63	0,64	0,65	0,65	0,66	0,66	0,67	0,66	0,66	0,66	0,66
Hipotireoidismo	0,95	0,97	0,98	0,98	0,99	0,99	0,99	0,99	0,99	0,99	0,99	0,99
ANN Tireóide	0,99	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00
WBC	0,97	0,98	0,99	0,99	0,99	0,99	0,99	0,99	0,99	0,99	0,99	0,99
C. Método	0,62	0,64	0,66	0,66	0,67	0,67	0,67	0,68	0,68	0,68	0,68	0,68
Diabetes Pima	0,72	0,76	0,79	0,81	0,81	0,82	0,82	0,82	0,82	0,82	0,83	0,83
Distúrbios hepáticos	0,66	0,70	0,72	0,74	0,75	0,76	0,76	0,77	0,77	0,77	0,77	0,77
H. Sobrevivência	0,58	0,60	0,61	0,62	0,63	0,63	0,64	0,64	0,64	0,64	0,64	0,64
All												
Mean	0,77	0,81	0,84	0,85	0,86	0,86	0,86	0,87	0,87	0,87	0,87	0,87
Mediana	0,80	0,84	0,87	0,89	0,89	0,91	0,91	0,92	0,92	0,92	0,93	0,93
Classificação média	11,83	10,55	8,79	8,05	6,88	5,81	5,12	4,62	4,31	4,39	3,91	3,72
8 baixa densidade												
Mean	0,72	0,78	0,83	0,85	0,87	0,88	0,88	0,88	0,88	0,88	0,89	0,89
Mediana	0,72	0,79	0,87	0,91	0,93	0,94	0,95	0,96	0,96	0,96	0,96	0,96
Classificação média	12,00	11,00	9,62	8,81	7,94	6,25	4,81	4,44	3,37	3,69	3,37	2,69
21 alta densidade												
Mean	0,79	0,82	0,84	0,85	0,86	0,86	0,86	0,86	0,86	0,86	0,86	0,86
Mediana	0,80	0,84	0,87	0,89	0,89	0,89	0,90	0,90	0,90	0,90	0,90	0,90
Classificação média	11,76	10,38	8,47	7,76	6,47	5,64	5,24	4,69	4,66	4,66	4,12	4,12

(for all datasets) using the median AUC difference $a = 6.42$ and $b = -0.83$ with correlation coefficient $R^2 = 0.99$, and using the mean AUC difference $a = 6.06$ and $b = -0.65$ with correlation coefficient $R^2 = 0.98$. For practical purposes, it is possible to approximate to $g \backsimeq \frac{7}{L}\%$ with correlation coefficient $R^2 = 0.99$, which indicates that this is a good fit as well. For instance, having $L = 8$ trees with AUC equals 0.90 its possible to estimate the AUC for 16 trees (doubling L), therefore $g \backsimeq \frac{7}{8}\%$ and the expected AUC value for 16 trees is $0.90 \times (1 + \frac{7/8}{100}) \backsimeq 0.91$. Of course, this formula may be used with any positive number of trees, for example, having an forest of 100 trees, the expected gain in AUC for a forest with 200 trees is 0.07%.

In Table 4 are presented the results of the *post-hoc* test after the Friedman's test, and the rejection of the null hypothesis. It shows the results using all datasets, the 8 low-density datasets, and the 21 high-density datasets. In this table $\triangle$ ($\blacktriangle$) indicates the Random Forest at the specified row is better (significantly) than the Random Forest at the specified column; $\triangledown$ ($\blacktriangledown$) the Random Forest at the specified row is worse (significantly) than the Random Forest at the specified column; $\circ$ indicates no difference whatsoever.

Some important observations can be made from Table 4. First, we can observe that there is no significant difference between a given number of trees (2^j) and its double (2^{j+1}), in all cases. When there is a significant difference, it only appears when we compare the number of trees (2^j) with at least four times this number (2^{j+2}). Second, from $64 = 2^6$ a significant difference was found only at $4096 = 2^{12}$, only when the Random Forest grew sixty four times. Third, it can be seen that from $128 = 2^7$ trees, there is no more significant difference between the forests until 4096 trees.

In order to analyze the percentage of attributes used, boxplots of these experiments are presented in Figures 7, 8 and 9 for all datasets, the 8 low-density datasets, and the 21 high-density datasets, respectively. Considering Figure 7, the mean and median values from 128 trees corresponds to 80.91% and 99.64% of the attributes, respectively. When we analyze the 8 low-density datasets in Figure 8, it is possible to notice that even with 4096 trees in the forest, not all attributes were used. However, as can be seen, this curve has a different shape (sigmoidal) than those in Figures 7 and 9 (exponential). Also, the sigmoidal seems to grow up to its maximum at 100%.

Even Random Forests do not overtrain, this appear to be a unwanted side effect of them, for instance, datasets of gene expression have thousands genes, and in that case a large forest will use all the genes, even if not all are important to learn the biological/biomedical concept. In [26], trees have only 2 genes among 7129 genes expression values; and in [14] the aim of their work was to build classifiers composed by rules with few conditions, and when they use the same dataset with 7129 genes they only use 2 genes in their subgroup discovery strategy. Considering the 21 high-density datasets in Figure 9, from 8 trees the mean and median already corresponds to 96.18% and 100% of attributes, respectively.

(para todos os conjuntos de dados) usando a diferença média de AUC $a = 6.42$ e $b = -0.83$ com coeficiente de correlação $R^2 = 0.99$ e usando a diferença média de AUC $a = 6.06$ e $b = -0.65$ com coeficiente de correlação $R^2 = 0.98$. Para fins práticos, é possível aproximar $g \backsimeq \frac{7}{L}$% com coeficiente de correlação $R^2 = 0.99$, o que indica que este também é um bom ajuste. Por exemplo, tendo árvores $L = 8$ com AUC igual a 0,90, é possível estimar a AUC para 16 árvores (dobrando L), portanto, $g \backsimeq \frac{7}{8}$% e o valor de AUC esperado para 16 árvores é $0.90 \times (1 + \frac{7/8}{100}) \backsimeq 0.91$. É claro que esta fórmula pode ser usada com qualquer número positivo de árvores, por exemplo, tendo uma floresta com 100 árvores, o ganho esperado em AUC para uma floresta com 200 árvores é de 0,07%.

Na Tabela 4 são apresentados os resultados do teste post-hoc após o teste de Friedman e a rejeição da hipótese nula. Ele mostra os resultados usando todos os conjuntos de dados, os 8 conjuntos de dados de baixa densidade e os 21 conjuntos de dados de alta densidade. Nesta tabela $\triangle$ (▲) indica que a Floresta Aleatória na linha especificada é melhor (significativamente) do que a Floresta Aleatória na coluna especificada; $\triangledown$ (▼) a Floresta Aleatória na linha especificada é pior (significativamente) do que a Floresta Aleatória na coluna especificada; $\circ$ indica que não há diferença algu ma.

Algumas observações importantes podem ser feitas a partir da Tabela 4. Primeiramente, podemos observar que não há diferença significativa entre um determinado número de árvores (2^j) e seu dobro (2^{j+1}), em todos os casos. Quando há diferença significativa, ela só aparece quando comparamos o número de árvores (2^j) co m pelo menos quatro vezes esse número (2^{j+2}). Segundo, de $64 = 2^6$ uma diferença significativa foi encontrada apenas em$4096 = 2^{12}$, somente quando a Floresta Aleatória cresceu sessenta e quatro vezes. Terceiro, pode-se observar que a partir de $128 = 2^7$ árvores, não há diferença mais significativa entre as florestas até 4.096 árvores.

Para analisar a porcentagem de atributos utilizados, boxplots desses experimentos são apresentados nas Figuras 7, 8 e 9 para todos os conjuntos de dados, os 8 conjuntos de dados de baixa densidade e os 21 conjuntos de dados de alta densidade, respectiva mente. Considerando a Figura 7, os valores médios e medianos das 128 árvores correspondem a 80,91% e 99,64% dos atributos, respectivamente. Ao analisarmos os 8 conjuntos de dados de baixa densidade da Figura 8, é possível notar que mesmo com 4.096 árvores na floresta, nem todos os atributos foram utilizados. Porém, como pode ser observado, esta curva possui formato diferente (sigmoidal) daquelas das Figuras 7 e 9 (exponencial). Além disso, o sigmoidal parece crescer até o máximo de 100%.

Mesmo as Florestas Aleatórias não treinam em excesso, isso parece ser um efeito colateral indesejado delas, por exemplo, os conjuntos de dados de expressão gênica têm milhares de genes e, nesse caso, uma grande floresta usará todos os genes, mesmo que nem todos sejam importantes para aprender o conceito biológico/biomédico. Em [26], as árvores possuem apenas 2 genes entre 7.129 valores de expressão de genes; e em [14] o objetivo de seu trabalho era construir classificadores compostos por regras com poucas condições, e quando usam o mesmo conjunto de dados com 7129 genes eles usam apenas 2 genes em sua estratégia de descoberta de subgrupos. Considerando os 21 conjuntos de dados de alta densidade da Figura 9, de 8 árvores a média e a mediana já correspondem a 96,18% e 100% dos atributos, respectivamente.

Table 4. Friedman's test results for AUC values using all datasets/8 low-density datasets/21 high-density datasets

Number of Trees	2	4	8	16	32	64	128	256	512	1024	2048	4096
2	○	▽ / ▽ / ▽	▼ / ▽ / ▼	▼ / ▽ / ▼	▼ / ▽ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼
4		○	▽ / ▽ / ▽	▼ / ▽ / ▼	▼ / ▽ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼
8			○	▽ / ▽ / ▽	▽ / ▽ / ▼	▽ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼
16				○	▽ / ▽ / ▽	▼ / ▽ / ▽	▼ / ▽ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼
32					○	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▼ / ▽	▼ / ▽ / ▼	▽ / ▼ / ▼	▼ / ▽ / ▼	▼ / ▼ / ▽
64						○	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▼	▽ / ▽ / ▽
128							○	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽
256								○	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽
512									○	△ / △ / ○	▽ / ○ / ▽	▽ / ▽ / ▽
1024										○	▽ / ▽ / ▽	▽ / ▽ / ▽
2048											○	▽ / ▽ / ○
4096												○

Table 4. Friedman's test results for AUC values using all datasets/8 low-density datasets/21 high-density datasets

Number of Trees	2	4	8	16	32	64	128	256	512	1024	2048	4096
2	○	▽ / ▽ / ▽	▼ / ▽ / ▼	▼ / ▽ / ▼	▼ / ▽ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼
4		○	▽ / ▽ / ▽	▼ / ▽ / ▼	▼ / ▽ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼
8			○	▽ / ▽ / ▽	▽ / ▽ / ▼	▽ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼
16				○	▽ / ▽ / ▽	▼ / ▽ / ▽	▼ / ▽ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼	▼ / ▼ / ▼
32					○	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▼ / ▽	▼ / ▽ / ▼	▽ / ▼ / ▼	▼ / ▽ / ▼	▼ / ▼ / ▽
64						○	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▼	▽ / ▽ / ▽
128							○	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽
256								○	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽	▽ / ▽ / ▽
512									○	△ / △ / ○	▽ / ○ / ▽	▽ / ▽ / ▽
1024										○	▽ / ▽ / ▽	▽ / ▽ / ▽
2048											○	▽ / ▽ / ○
4096												○

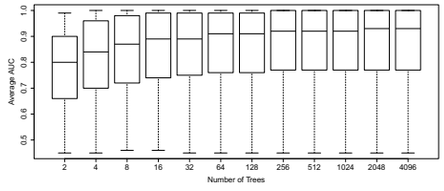


Fig. 1. AUC in all datasets

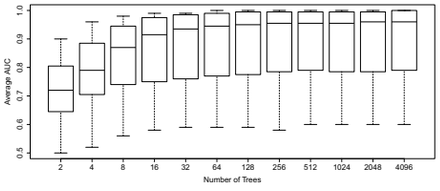


Fig. 2. AUC in the 8 low-density datasets

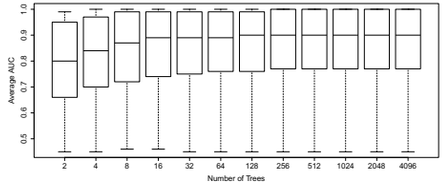


Fig. 3. AUC in the 21 high-density datasets

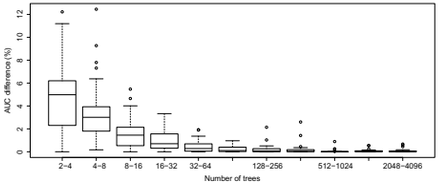


Fig. 4. AUC differences in all datasets

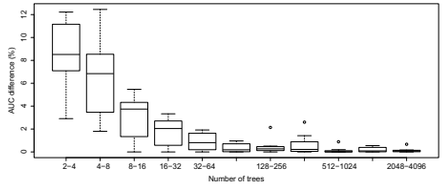


Fig. 5. AUC differences in the 8 low-density datasets

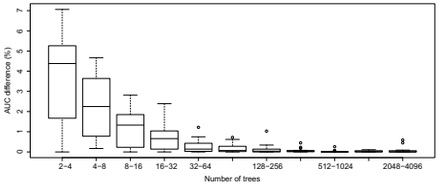


Fig. 6. AUC differences in the 21 high-density datasets

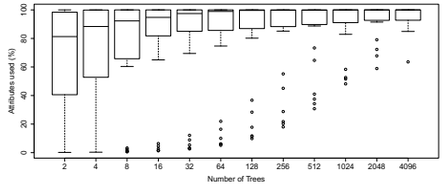


Fig. 7. Percentage of attributes used in all datasets

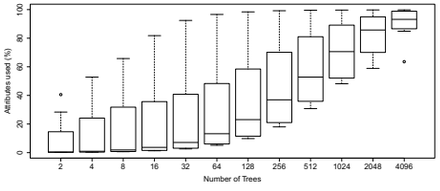


Fig. 8. Percentage of attributes used in the 8 low-density datasets

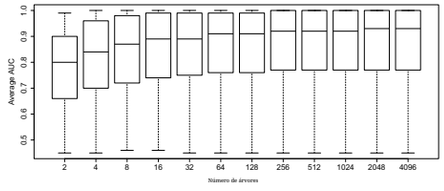


Figura 1. AUC em todos os conjuntos de dados

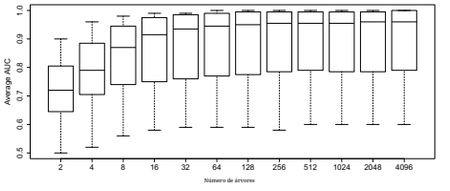


Figura 2. AUC nos 8 conjuntos de dados de baixa densidade

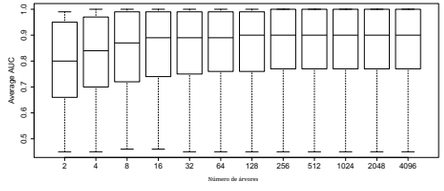


Figura 3. AUC nos 21 conjuntos de dados de alta densidade

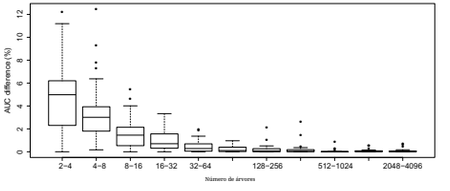


Figura 4. Diferenças de AUC em todos os conjuntos de dados

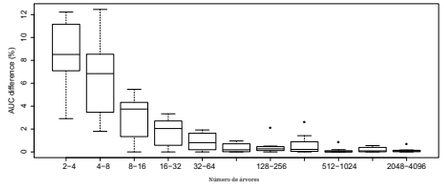


Figura 5. Diferenças de AUC nos 8 conjuntos de dados de baixa densidade

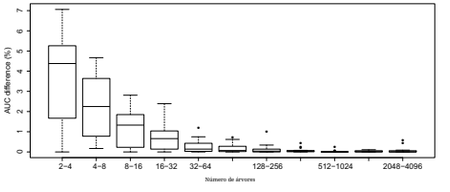


Figura 6. Diferenças de AUC nos 21 conjuntos de dados de alta densidade

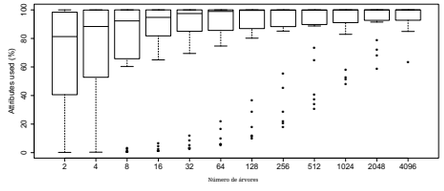


Figura 7. Porcentagem de atributos usados em todos os conjuntos de dados

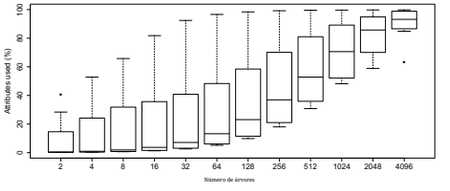


Figura 8. Porcentagem de atributos usados nos 8 conjuntos de dados de baixa densidade

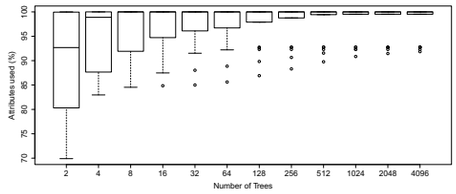


Fig. 9. Percentage of attributes used in the 21 high-density datasets

8 Conclusion

The results obtained show that, sometimes, a larger number of trees in a forest only increases its computational cost, and has no significant performance gain. They also indicate that mean and median AUC tend to converge asymptotically. Another observation is that there is no significant difference between using a number of trees within a Random Forest or its double. The analysis of 29 datasets shows that from 128 trees there is no more significant difference between the forests using 256, 512, 1024, 2048 and 4096 trees. The mean and the median AUC values do not present major changes from 64 trees. Therefore, it is possible to suggest, based on the experiments, a range between 64 and 128 trees in a forest. With these numbers of trees it is possible to obtain a good balance between AUC, processing time, and memory usage. We have also found an experimental relationship (inversely proportional) for AUC gain when doubling the number of trees in any forest.

Analyzing the percentage of attributes used, we can notice that using all datasets, the median reaches the full attribute set with 128 trees in the forest. If the total number of attributes is small, the median reaches the 100% with fewer trees (from 8 trees or more). If this number is larger, it reaches 100% with more trees, in some cases with more than 4096 trees. Thus, asymptotically the tendency indicates the Random Forest will use all attributes, and it is not interesting in some cases, for example in datasets with many attributes (i.e., gene expression datasets), since not all are important for learning the concept [26,14].

We have also proposed density-based metrics for datasets that probably capture some aspects of the VC dimension of decision trees. Under this assumption, low-density datasets may require large capacity learning machines composed by large Random Forests. The opposite also seems to be true.

Acknowledgments. This work was funded by FAPESP (São Paulo Research Foundation) as well as a joint grant between the National Research Council of Brazil (CNPq), and the Amazon State Research Foundation (FAPEAM) through the Program National Institutes of Science and Technology, INCT ADAPTA Project (Centre for Studies of Adaptations of Aquatic Biota of the Amazon).

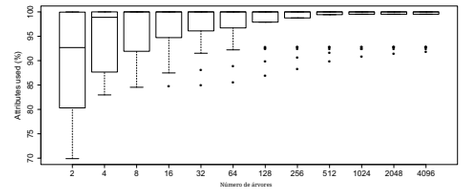


Figura 9. Porcentagem de atributos usados nos 21 conjuntos de dados de alta densidade

8 Conclusão

Os resultados obtidos mostram que, às vezes, um maior número de árvores em uma floresta apenas aumenta o seu custo computacional, não tendo ganho significativo de desempenho. Eles também indicam que a AUC média e mediana tende a convergir assintoticamente. Outra observação é que não há diferença significativa entre usar um número de árvores dentro de uma Floresta Aleatória ou seu dobro. A análise de 29 conjuntos de dados mostra que de 128 árvores não há diferença mais significativa entre as florestas que utilizam 256, 512, 1.024, 2.048 e 4.096 árvores. Os valores médios e medianos de AUC não apresentam grandes alterações em 64 árvores. Portanto, é possível sugerir, com base nos experimentos, uma faixa entre 64 e 128 árvores em uma floresta. Com esses números de árvores é possível obter um bom equilíbrio entre AUC, tempo de processamento e uso de memória. Também encontramos uma relação experimental (inversamente proporcional) para o ganho de AUC ao duplicar o número de árvores em qualquer floresta.

Analisando a porcentagem de atributos utilizados, podemos notar que utilizando todos os conjuntos de dados, a mediana atinge o conjunto completo de atributos com 128 árvores na floresta. Se o número total de atributos for pequeno, a mediana chega a 100% com menos árvores (de 8 árvores ou mais). Se esse número for maior, chega a 100% com mais árvores, em alguns casos com mais de 4.096 árvores. Assim, assintoticamente a tendência indica que a Random Forest utilizará todos os atributos, e isso não é interessante em alguns casos, por exemplo em conjuntos de dados com muitos atributos (ou seja, conjuntos de dados de expressão gênica), uma vez que nem todos são importantes para o aprendizado do conceito [26,14].

Também propusemos métricas baseadas em densidade para conjuntos de dados que provavelmente capturam alguns aspectos da dimensão VC das árvores de decisão. Sob esta suposição, conjuntos de dados de baixa densidade podem exigir máquinas de aprendizagem de grande capacidade compostas por grandes Florestas Aleatórias. O oposto também parece ser verdade.

Agradecimentos. Este trabalho foi financiado pela FAPESP (Fundação de Amparo à Pesquisa de São Paulo), bem como uma bolsa conjunta entre o Conselho Nacional de Pesquisa do Brasil (CNPq) e a Fundação de Amparo à Pesquisa do Estado do Amazonas (FAPEAM) por meio do Programa Institutos Nacionais de Ciência e Tecnologia, Projeto INCT ADAPTA (Centro de Estudos de Adaptações da Biota Aquática da Amazônia).

References

1. Cancer program data sets. Broad Institute (2010), http://www.broadinstitute.org/cgi-bin/cancer/datasets.cgi
2. Dataset repository in arff (weka). BioInformatics Group Seville (2010), http://www.upo.es/eps/bigs/datasets.html
3. Datasets. Cilab (2010), http://cilab.ujn.edu.cn/datasets.htm
4. Aslan, O., Yildiz, O.T., Alpaydin, E.: Calculating the VC-dimension of decision trees. In: International Symposium on Computer and Information Sciences 2009, pp. 193–198 (2009)
5. Benjamini, Y., Hochberg, Y.: Controlling the false discovery rate: a practical and powerful approach to multiple testing. Journal of the Royal Statistical Society Series B 57, 289–300 (1995)
6. Berks, M., Chen, Z., Astley, S., Taylor, C.: Detecting and Classifying Linear Structures in Mammograms Using Random Forests. In: Székely, G., Hahn, H.K. (eds.) IPMI 2011. LNCS, vol. 6801, pp. 510–524. Springer, Heidelberg (2011)
7. Breiman, L.: Random forests. Machine Learning 45(1), 5–32 (2001)
8. Breiman, L.: Bagging predictors. Machine Learning 24(2), 123–140 (1996)
9. Demšar, J.: Statistical comparison of classifiers over multiple data sets. Journal of Machine Learning Research 7(1), 1–30 (2006)
10. Dubath, P., Rimoldini, L., Süveges, M., Blomme, J., López, M., Sarro, L.M., De Ridder, J., Cuypers, J., Guy, L., Lecoeur, I., Nienartowicz, K., Jan, A., Beck, M., Mowlavi, N., De Cat, P., Lebzelter, T., Eyer, L.: Random forest automated supervised classification of hipparcos periodic variable stars. Monthly Notices of the Royal Astronomical Society 414(3), 2602–2617 (2011), http://dx.doi.org/10.1111/j.1365-2966.2011.18575.x
11. Frank, A., Asuncion, A.: UCI machine learning repository (2010), http://archive.ics.uci.edu/ml
12. Freund, Y., Schapire, R.E.: Experiments with a new boosting algorithm. In: Proceedings of the Thirteenth International Conference on Machine Learning, pp. 123–140. Morgan Kaufmann, Lake Tahoe (1996)
13. Friedman, M.: A comparison of alternative tests of significance for the problem of m rankings. The Annals of Mathematical Statistics 11(1), 86–92 (1940)
14. Gamberger, D., Lavrač, N., Zelezny, F., Tolar, J.: Induction of comprehensible models for gene expression datasets by subgroup discovery methodology. Journal of Biomedical Informatics 37, 269–284 (2004)
15. Geremia, E., Menze, B.H., Clatz, O., Konukoglu, E., Criminisi, A., Ayache, N.: Spatial Decision Forests for MS Lesion Segmentation in Multi-Channel MR Images. In: Jiang, T., Navab, N., Pluim, J.P.W., Viergever, M.A. (eds.) MICCAI 2010. LNCS, vol. 6361, pp. 111–118. Springer, Heidelberg (2010)
16. Goldstein, B., Hubbard, A., Cutler, A., Barcellos, L.: An application of random forests to a genome-wide association dataset: Methodological considerations and new findings. BMC Genetics 11(1), 49 (2010), http://www.biomedcentral.com/1471-2156/11/49
17. Hall, M., Frank, E., Holmes, G., Pfahringer, B., Reutemann, P., Witten, I.H.: The weka data mining software: an update. Association for Computing Machinery's Special Interest Group on Knowledge Discovery and Data Mining Explor. Newsl. 11(1), 10–18 (2009)
18. Hsieh, C., Lu, R., Lee, N., Chiu, W., Hsu, M., Li, Y.J.: Novel solutions for an old disease: diagnosis of acute appendicitis with random forest, support vector machines, and artificial neural networks. Surgery 149(1), 87–93 (2011)

Referências

1. Conjuntos de dados do programa de câncer. Broad Institute (2010), http://www.broadinstitute.org/cgi-bin/cancer/datasets.cgi 2. Repositório de conjunto de dados em arff (weka). Grupo de BioInformática Sevilha (2010), http://www.upo.es/eps/bigs/datasets.html 3. Conjuntos de dados. Cilab (2010), http://cilab.ujn.edu.cn/datasets.htm 4. Aslan, O., Yildiz, O.T., Alpaydin, E.: Calculando a dimensão VC das árvores de decisão. In: Simpósio Internacional de Ciências da Computação e da Informação 2009, pp. 193–198 (2009) 5. Benjamini, Y., Hochberg, Y.: Controlando a taxa de falsas descobertas: uma abordagem prática e poderosa para testes múltiplos. Journal of the Royal Statistical Society Series B 57, 289–300 (1995) 6. Berks, M., Chen, Z., Astley, S., Taylor, C.: Detectando e classificando estruturas lineares em mamografias usando florestas aleatórias. In: Sz´ekely, G., Hahn, H.K. (eds.) IPMI 2011. LNCS, vol. 6801, pp. Springer, Heidelberg (2011) 7. Breiman, L.: Florestas aleatórias. Aprendizado de Máquina 45(1), 5–32 (2001) 8. Breiman, L.: Preditores de ensacamento. Machine Learning 24(2), 123–140 (1996) 9. Dem˜sar, J.: Comparação estatística de classificadores em vários conjuntos de dados. Journal of Machine Learning Research 7(1), 1–30 (2006) 10. Dubath, P., Rimoldini, L., S¨uveges, M., Blomme, J., L´opez, M., Sarro, LM, De Ridder, J., Cuypers, J., Guy, L., Lecoeur, I., Nienartowicz, K., Jan, A., Beck, M., Mowlavi, N., De Cat, P., Lebzelter, T., Eyer, L.: Classificação supervisionada automatizada de floresta aleatória de estrelas variáveis periódicas de hipparcos. Avisos mensais da Royal Astronomical Society 414(3), 2602–2617 (2011), http://dx.doi.org/10.1111/j.1365-2966.2011.18575.x 11. Frank, A., Assunção, A.: Repositório de aprendizado de máquina UCI (2010), http://archive.ics.uci.edu/ml 12. Freund, Y., Schapire, RE: Experimentos com um novo algoritmo de reforço. In: Anais da Décima Terceira Conferência Internacional sobre Aprendizado de Máquina, pp. Morgan Kaufmann, Lake Tahoe (1996) 13. Friedman, M.: Uma comparação de testes alternativos de significância para o problema de classificações m. The Annals of Mathematical Statistics 11(1), 86–92 (1940) 14. Gamberger, D., Lavra˘ c, N., Zelezny, F., Tolar, J.: Indução de modelos compreensíveis para conjuntos de dados de expressão gênica por metodologia de descoberta de subgrupo. Journal of Biomedical Informatics 37, 269–284 (2004) 15. Geremia, E., Menze, BH, Clatz, O., Konukoglu, E., Criminisi, A., Ayache, N .: Florestas de decisão espacial para segmentação de lesões de MS em imagens de RM multicanal. In: Jiang, T., Navab, N., Pluim, JPW, Viergever, MA (eds.) MICCAI 2010. LNCS, vol. 6361, pp. Springer, Heidelberg (2010) 16. Goldstein, B., Hubbard, A., Cutler, A., Barcellos, L.: Uma aplicação de florestas aleatórias a um conjunto de dados de associação de todo o genoma: Considerações metodológicas e novas descobertas. BMC Genetics 11(1), 49 (2010), http://www.biomedcentral.com/1471 49 17 2156 11- / / . Hall, M., Frank, E., Holmes, G., Pfahringer, B., Reutemann, P., Witten, IH: O software de mineração de dados weka: uma atualização. Grupo de Interesse Especial da Association for Computing Machinery em Descoberta de Conhecimento e Exploração de Mineração de Dados. Notíciasl. 11 (1), 10–18 (2009) 18. Hsieh, C., Lu, R., Lee, N., Chiu, W., Hsu, M., Li, YJ: Novas soluções para uma doença antiga: diagnóstico de apendicite aguda com floresta aleatória, máquinas de vetores de suporte e redes neurais artificiais. Cirurgia 149(1), 87–93 (2011)

19. Kim, S.-H., Lee, J.-H., Ko, B., Nam, J.-Y.: X-ray image classification using random forests with local binary patterns. In: International Conference on Machine Learning and Cybernetics 2010, pp. 3190–3194 (2010)
20. Latinne, P., Debeir, O., Decaestecker, C.: Limiting the Number of Trees in Random Forests. In: Kittler, J., Roli, F. (eds.) MCS 2001. LNCS, vol. 2096, pp. 178–187. Springer, Heidelberg (2001)
21. Lee, J.H., Kim, D.Y., Ko, B.C., Nam, J.Y.: Keyword annotation of medical image with random forest classifier and confidence assigning. In: International Conference on Computer Graphics, Imaging and Visualization, pp. 156–159 (2011)
22. Lempitsky, V., Verhoek, M., Noble, J.A., Blake, A.: Random Forest Classification for Automatic Delineation of Myocardium in Real-Time 3D Echocardiography. In: Ayache, N., Delingette, H., Sermesant, M. (eds.) FIMH 2009. LNCS, vol. 5528, pp. 447–456. Springer, Heidelberg (2009)
23. Leshem, G.: Improvement of adaboost algorithm by using random forests as weak learner and using this algorithm as statistics machine learning for traffic flow prediction. Research proposal for a Ph.D. Thesis (2005)
24. Liaw, A., Wiener, M.: Classification and regression by randomforest. R News 2/3, 1–5 (2002)
25. Mitchell, T.M.: Machine Learning. McGraw-Hill (1997)
26. Netto, O.P., Nozawa, S.R., Mitrowsky, R.A.R., Macedo, A.A., Baranauskas, J.A.: Applying decision trees to gene expression data from dna microarrays: A leukemia case study. In: XXX Congress of the Brazilian Computer Society, X Workshop on Medical Informatics, p. 10. Belo Horizonte, MG (2010)
27. Perez, P.S., Baranauskas, J.A.: Analysis of decision tree pruning using windowing in medical datasets with different class distributions. In: Proceedings of the Workshop on Knowledge Discovery in Health Care and Medicine of the European Conference on Machine Learning and Principles and Practice of Knowledge Discovery in Databases (ECML PKDD KDHCM), Athens, Greece, pp. 28–39 (2011)
28. Sirikulviriya, N., Sinthupinyo, S.: Integration of rules from a random forest. In: International Conference on Information and Electronics Engineering, vol. 6, pp. 194–198 (2011)
29. Tang, Y.: Real-Time Automatic Face Tracking Using Adaptive Random Forests. Master's thesis, Department of Electrical and Computer Engineering McGill University, Montreal, Canada (June 2010)
30. Vapnik, V., Levin, E., Cun, Y.L.: Measuring the vc-dimension of a learning machine. Neural Computation 6, 851–876 (1994)
31. Wang, G., Hao, J., Ma, J., Jiang, H.: A comparative assessment of ensemble learning for credit scoring. Expert Systems with Applications 38, 223–230 (2011)
32. Yaqub, M., Mahon, P., Javaid, M.K., Cooper, C., Noble, J.A.: Weighted voting in 3d random forest segmentation. Medical Image Understanding and Analysis (2010)
33. Yaqub, M., Javaid, M.K., Cooper, C., Noble, J.A.: Improving the Classification Accuracy of the Classic RF Method by Intelligent Feature Selection and Weighted Voting of Trees with Application to Medical Image Segmentation. In: Suzuki, K., Wang, F., Shen, D., Yan, P. (eds.) MLMI 2011. LNCS, vol. 7009, pp. 184–192. Springer, Heidelberg (2011)
34. Yi, Z., Criminisi, A., Shotton, J., Blake, A.: Discriminative, Semantic Segmentation of Brain Tissue in MR Images. In: Yang, G.-Z., Hawkes, D., Rueckert, D., Noble, A., Taylor, C. (eds.) MICCAI 2009. LNCS, vol. 5762, pp. 558–565. Springer, Heidelberg (2009)
35. Zhao, Y., Zhang, Y.: Comparison of decision tree methods for finding active objects. Advances in Space Research 41, 1955–1959 (2008)

View publication stats

19. Kim, S.-H., Lee, J.-H., Ko, B., Nam, J.-Y .: Classificação de imagens de raios X usando florestas aleatórias com padrões binários locais. In: Conferência Internacional sobre Aprendizado de Máquina e Cibernética 2010, pp. 3190–3194 (2010) 20. Latinne, P., Debeir, O., Decaestecker, C.: Limitando o Número de Árvores em Florestas Aleatórias. In: Kittler, J., Roli, F. (eds.) MCS 2001. LNCS, vol. 2096, pp. Springer, Heidelberg (2001) 21. Lee, JH, Kim, DY, Ko, BC, Nam, JY: Anotação de palavras-chave de imagem médica com classificador de floresta aleatório e atribuição de confiança. In: Conferência Internacional sobre Computação Gráfica, Imagem e Visualização, pp. 156–159 (2011) 22. Lempitsky, V., Verhoek, M., Noble, JA, Blake, A.: Classificação Random Forest para Delineamento Automático de Miocárdio em Ecocardiografia 3D em Tempo Real. In: Ayache, N., Delingette, H., Sermesant, M. (eds.) FIMH 2009. LNCS, vol. 5528, pp. Springer, Heidelberg (2009) 23. Leshem, G.: Melhoria do algoritmo adaboost usando florestas aleatórias como aprendiz fraco e usando este algoritmo como aprendizado de máquina estatística para previsão de fluxo de tráfego. Proposta de pesquisa para doutorado. Tese (2005) 24. Liaw, A., Wiener, M.: Classificação e regressão por floresta aleatória. R News 2/3, 1–5 (2002) 25. Mitchell, TM: Machine Learning. McGraw-Hill (1997) 26. Netto, OP, Nozawa, SR, Mitrowsky, RAR, Macedo, AA, Baranauskas, JA: Aplicando árvores de decisão a dados de expressão gênica de microarranjos de DNA: Um estudo de caso de leucemia. In: XXX Congresso da Sociedade Brasileira de Computação, X Workshop de Informática Médica, p. 10. Belo Horizonte, MG (2010) 27. Perez, P.S., Baranauskas, J.A.: Análise de poda de árvores de decisão usando janelas em conjuntos de dados médicos com diferentes distribuições de classes. In: Anais do Workshop sobre Descoberta de Conhecimento em Cuidados de Saúde e Medicina da Conferência Europeia sobre Aprendizado de Máquina e Princípios e Prática de Descoberta de Conhecimento em Bancos de Dados (ECML PKDD KDHCM), Atenas, Grécia, pp. In: Conferência Internacional sobre Engenharia da Informação e Eletrônica, vol. 6, pp. 194–198 (2011) 29. Tang, Y.: Rastreamento facial automático em tempo real usando florestas aleatórias adaptativas. Tese de mestrado, Departamento de Engenharia Elétrica e de Computação da Universidade McGill, Montreal, Canadá (junho de 2010) 30. Vapnik, V., Levin, E., Cun, Y.L.: Medindo a dimensão vc de uma máquina de aprendizagem. Neural Computation 6, 851–876 (1994) 31. Wang, G., Hao, J., Ma, J., Jiang, H.: Uma avaliação comparativa da aprendizagem em conjunto para pontuação de crédito. Sistemas Especialistas com Aplicações 38, 223–230 (2011) 32. Yaqub, M., Mahon, P., Javaid, MK, Cooper, C., Noble, JA: Votação ponderada na segmentação florestal aleatória 3D. Compreensão e análise de imagens médicas (2010) 33. Yaqub, M., Javaid, MK, Cooper, C., Noble, JA: Melhorando a precisão da classificação do método RF clássico por seleção inteligente de recursos e votação ponderada de árvores com aplicação à segmentação de imagens médicas. In: Suzuki, K., Wang, F., Shen, D., Yan, P. (eds.) MLMI 2011. LNCS, vol. 7009, pp. Springer, Heidelberg (2011) 34. Yi, Z., Criminisi, A., Shotton, J., Blake, A.: Segmentação discriminativa e semântica do tecido cerebral em imagens de ressonância magnética. In: Yang, G.-Z., Hawkes, D., Rueckert, D., Noble, A., Taylor, C. (eds.) MICCAI 2009. LNCS, vol. 5762, pp. Springer, Heidelberg (2009) 35. Zhao, Y., Zhang, Y .: Comparação de métodos de árvore de decisão para encontrar objetos ativos. Avanços na Pesquisa Espacial 41, 1955–1959 (2008)

Ver estatísticas de publicação
Ver estatísticas de publicação