arXiv:1511.05741v1 [math.ST] 18 Nov 2015

A Random Forest Guided Tour

Gérard Biau
Sorbonne Universités, UPMC Univ Paris 06, F-75005, Paris, France & Institut universitaire de France
gerard.biau@upmc.fr

Erwan Scornet
Sorbonne Universités, UPMC Univ Paris 06, F-75005, Paris, France
erwan.scornet@upmc.fr

Abstract

The random forest algorithm, proposed by L. Breiman in 2001, has been extremely successful as a general-purpose classification and regression method. The approach, which combines several randomized decision trees and aggregates their predictions by averaging, has shown excellent performance in settings where the number of variables is much larger than the number of observations. Moreover, it is versatile enough to be applied to large-scale problems, is easily adapted to various ad-hoc learning tasks, and returns measures of variable importance. The present article reviews the most recent theoretical and methodological developments for random forests. Emphasis is placed on the mathematical forces driving the algorithm, with special attention given to the selection of parameters, the resampling mechanism, and variable importance measures. This review is intended to provide non-experts easy access to the main ideas.

Index Terms — Random forests, randomization, resampling, parameter tuning, variable importance.

2010 Mathematics Subject Classification: 62G05, 62G20.

1 Introduction

To take advantage of the sheer size of modern data sets, we now need learning algorithms that scale with the volume of information, while maintaining sufficient statistical efficiency. Random forests, devised by L. Breiman in the early 2000s (Breiman, 2001), are part of the list of the most successful methods currently available to handle data in these cases. This supervised

arXiv:1511.05741v1 [math.ST] 18 Nov 2015

Uma visita guiada aleatória pela floresta

G´erard Biau
Sorbonne Universit´es, UPMC Univ Paris 06,F-75005, Paris, França e Institut universitaire de France gerard.biau@upmc.fr

Erwan Scornet
Sorbonne Universit´es, UPMC Univ Paris 06, F-75005, Paris, França erwan.scornet@upmc.fr

Resumo

O algoritmo de floresta aleatória, proposto por L. Breiman em 2001, tem sido extremamente bem-sucedido como método de classificação e regressão de uso geral. A abordagem, que combina diversas árvores de decisão aleatórias e agrega suas previsões por meio de médias, mostrou excelente desempenho em ambientes onde o número de variáveis é muito maior que o número de observações. Além disso, é suficientemente versátil para ser aplicado a problemas de grande escala, é facilmente adaptável a diversas tarefas de aprendizagem ad-hoc e devolve medidas de importância variável. O presente artigo revisa os mais recentes desenvolvimentos teóricos e metodológicos para florestas aleatórias. A ênfase é colocada nas forças matemáticas que impulsionam o algoritmo, com atenção especial dada à seleção de parâmetros, ao mecanismo de reamostragem e às medidas de importância variável. Esta revisão tem como objetivo fornecer aos não especialistas acesso fácil às ideias principais.

Termos de indexação — Florestas aleatórias, randomização, reamostragem, ajuste de parâmetros, importância variável.

Classificação da disciplina de matemática 2010: 62G05, 62G20.

1 Introdução

Para aproveitar o tamanho dos conjuntos de dados modernos, precisamos agora de algoritmos de aprendizagem que se adaptem ao volume de informações, mantendo ao mesmo tempo eficiência estatística suficiente. As florestas aleatórias, idealizadas por L. Breiman no início dos anos 2000 (Breiman, 2001), fazem parte da lista dos métodos mais bem-sucedidos atualmente disponíveis para lidar com dados nestes casos. Este supervisionado

learning procedure, influenced by the early work of Amit and Geman (1997), Ho (1998), and Dietterich (2000), operates according to the simple but effective "divide and conquer" principle: sample fractions of the data, grow a randomized tree predictor on each small piece, then paste (aggregate) these predictors together.

What has greatly contributed to the popularity of forests is the fact that they can be applied to a wide range of prediction problems and have few parameters to tune. Aside from being simple to use, the method is generally recognized for its accuracy and its ability to deal with small sample sizes and high-dimensional feature spaces. At the same time, it is easily parallelizable and has therefore the potential to deal with large real-life systems. The corresponding `R` package `randomForest` can be freely downloaded on the CRAN website (http://www.r-project.org), while a MapReduce (Jeffrey and Sanja, 2008) open source implementation called *Partial Decision Forests* is available on the Apache Mahout website at https://mahout.apache.org. This allows the building of forests using large data sets as long as each partition can be loaded into memory.

The random forest methodology has been successfully involved in various practical problems, including a data science hackathon on air quality prediction (http://www.kaggle.com/c/dsg-hackathon), chemoinformatics (Svetnik et al., 2003), ecology (Prasad et al., 2006; Cutler et al., 2007), 3D object recognition (Shotton et al., 2011), and bioinformatics (Díaz-Uriarte and de Andrés, 2006), just to name a few. J. Howard (Kaggle) and M. Bowles (Biomatica) claim in Howard and Bowles (2012) that *ensembles of decision trees—often known as "random forests"—have been the most successful general-purpose algorithm in modern times*, while H. Varian, Chief Economist at Google, advocates in Varian (2014) the use of random forests in econometrics.

On the theoretical side, the story of random forests is less conclusive and, despite their extensive use, little is known about the mathematical properties of the method. The most celebrated theoretical result is that of Breiman (2001), which offers an upper bound on the generalization error of forests in terms of correlation and strength of the individual trees. This was followed by a technical note (Breiman, 2004), which focuses on a stylized version of the original algorithm (see also Breiman, 2000a,b). A critical step was subsequently taken by Lin and Jeon (2006), who highlighted an interesting connection between random forests and a particular class of nearest neighbor predictors, further developed by Biau and Devroye (2010). In recent years, various theoretical studies have been performed (e.g., Meinshausen, 2006;

O procedimento de aprendizagem, influenciado pelos primeiros trabalhos de Amit e Geman (1997), Ho (1998) e Dietterich (2000), opera de acordo com o princípio simples, mas eficaz, de "dividir e conquistar": amostrar frações dos dados, criar uma árvore preditora aleatória em cada pequeno pedaço e, em seguida, colar (agregar) esses preditores juntos.

O que contribuiu enormemente para a popularidade das florestas é o fato de que elas podem ser aplicadas a uma ampla gama de problemas de previsão e possuem poucos parâmetros para ajustar. Além de ser simples de usar, o método é geralmente reconhecido por sua precisão e capacidade de lidar com amostras pequenas e espaços de características de alta dimensão. Ao mesmo tempo, é facilmente paralelizável e tem, portanto, potencial para lidar com grandes siste mas da vida real. O `R` pacote `randomForest` correspondente pode ser baixado gratuitamente no site do CRAN (http://www.r-project.org), enquanto uma implementação de código aberto do MapReduce (Jeffrey e Sanja, 2008) chamada Partial Decision Forests está disponível no site do Apache Mahout em https://mahout.apache.org. Isto permite a construção de florestas usando grandes conjuntos de dados, desde que cada partição possa ser carregada na memória.

A metodologia de floresta aleatória tem sido envolvida com sucesso em vários problemas práticos, incluindo um hackathon de ciência de dados sobre previsão da qualidade do ar (//www.kaggle.com/c/dsg-hackathon), quimioinformática (Svetnik et al., 2003), ecologia (Prasad et al., 2006; Cutler et al., 2007), reconhecimento de objetos 3D (Shotton et al., 2006; Cutler et al., 2007), reconhecimento de objetos 3D (Shotton et al., 2006; Cutler et al., 2007). al., 2011) e bioinformática (D´ıaz-Uriarte e de André´es, 2006), apenas para citar alguns. J. Howard (Kaggle) e M. Bowles (Biomatica) afirmam em Howard e Bowles (2012) que conjuntos de árvores de decisão – muitas vezes conhecidos como "florestas aleatórias" – têm sido o algoritmo de uso geral de maior sucesso nos tempos modernos, enquanto H. Varian, economista-chefe do Google, defende em Varian (2014) o uso de florestas aleatórias em econometria.

Do lado teórico, a história das florestas aleatórias é menos conclusiva e, apesar da sua utilização extensiva, pouco se sabe sobre as propriedades matemáticas do método. O resultado teórico mais célebre é o de Breiman (2001), que oferece um limite superior para o erro de generalização das florestas em termos de correlação e força das árvores individuais. Isto foi seguido por uma nota técnica (Breiman, 2004), que se concentra em uma versão estilizada do algoritmo original (ver também Breiman, 2000a,b). Um passo crítico foi posteriormente dado por Lin e Jeo n (2006), que destacaram uma conexão interessante entre florestas aleatórias e uma classe particular de preditores de vizinhos mais próximos, desenvolvida por Biau e Devroye (2010). Nos últimos anos, vários estudos teóricos foram realizados (por exemplo, Meinshausen, 2006;

Biau et al., 2008; Ishwaran and Kogalur, 2010; Biau, 2012; Genuer, 2012; Zhu et al., 2015), analyzing more elaborate models and moving ever closer to the practical situation. Recent attempts towards narrowing the gap between theory and practice include that of Denil et al. (2013), who prove the consistency of a particular online forest, Wager (2014) and Mentch and Hooker (2015), who study the asymptotic distribution of forests, and Scornet et al. (2015), who show that Breiman's (2001) forests are consistent in an additive regression framework.

The difficulty in properly analyzing random forests can be explained by the black-box flavor of the method, which is indeed a subtle combination of different components. Among the forests' essential ingredients, both bagging (Breiman, 1996) and the Classification And Regression Trees (CART)-split criterion (Breiman et al., 1984) play critical roles. Bagging (a contraction of bootstrap-aggregating) is a general aggregation scheme, which generates bootstrap samples from the original data set, constructs a predictor from each sample, and decides by averaging. It is one of the most effective computationally intensive procedures to improve on unstable estimates, especially for large, high-dimensional data sets, where finding a good model in one step is impossible because of the complexity and scale of the problem (Bühlmann and Yu, 2002; Kleiner et al., 2014; Wager et al., 2014). As for the CART-split criterion, it originates from the influential CART program of Breiman et al. (1984), and is used in the construction of the individual trees to choose the best cuts perpendicular to the axes. At each node of each tree, the best cut is selected by optimizing the CART-split criterion, based on the so-called *Gini impurity* (for classification) or the prediction squared error (for regression).

However, while bagging and the CART-splitting scheme play key roles in the random forest mechanism, both are difficult to analyze with rigorous mathematics, thereby explaining why theoretical studies have so far considered simplified versions of the original procedure. This is often done by simply ignoring the bagging step and/or replacing the CART-split selection by a more elementary cut protocol. As well as this, in Breiman's (2001) forests, each leaf (that is, a terminal node) of individual trees contains a small number of observations, typically between 1 and 5.

The goal of this survey is to embark the reader on a guided tour of random forests. We focus on the theory behind the algorithm, trying to give an overview of major theoretical approaches while discussing their inherent pros and cons. For a more methodological review covering applied aspects of random forests, we refer to the surveys by Criminisi et al. (2011) and Boulesteix et al. (2012). We start by gently introducing the mathematical context in

Biau et al., 2008; Ishwaran e Kogalur, 2010; Biau, 2012; Genérico, 2012; Zhu et al., 2015), analisando modelos mais elaborados e aproximando-se cada vez mais da situação prática. Tentativas recentes de diminuir a lacuna entre teoria e prática incluem a de Denil et al. (2013), que comprovam a consistência de uma determinada floresta online, Wager (2014) e Mentch e Hooker (2015), que estudam a distribuição assintótica de florestas, e Scornet et al. (2015), que mostram que as florestas de Breiman (2001) são consistentes num quadro de regressão aditiva.

A dificuldade em analisar adequadamente florestas aleatórias pode ser explicada pelo sabor de caixa preta do método, que é na verdade uma combinação sutil de diferentes componentes. Entre os ingredientes essenciais das florestas, tanto o ensacamento (Breiman, 1996) quanto o critério de divisão das Árvores de Classificação e Regressão (CART) (Breiman et al., 1984) desempenham papéis críticos. Bagging (uma contração de agregação de bootstrap) é um esquema geral de agregação, que gera amostras de bootstrap a partir do conjunto de dados original, constrói um preditor de cada amostra e decide pela média. É um dos procedi mentos computacionalmente intensivos mais eficazes para melhorar estimativas instáveis, especialmente para conjuntos de dados grandes e de alta dimensão, onde encontrar um bom modelo em uma única etapa é impossível devido à complexidade e escala do problema (B¨uhlmann e Yu, 2002; Kleiner et al., 2014; Wager et al., 2014). Quanto ao critério de divisão CART, ele se origina do influente programa CART de Breiman et al. (1984), e é utilizado na construção das árvores individuais para escolha dos melhores cortes perpendiculares aos eixos. Em cada nó de cada árvore, o melhor corte é selecionado otimizando o critério de divisão CART, com base na chamada impureza de Gini (para classificação) ou no erro quadrático de predição (para regressão).

Contudo, embora o ensacamento e o esquema de divisão CART desempenhem papéis fundamentais no mecanismo florestal aleatório, ambos são difíceis de analisar com matemática rigorosa, explicando assim por que os estudos teóricos t êm considerado até agora versões simplificadas do procedimento original. Isso geralmente é feito simplesmente ignorando a etapa de ensacamento e/ou substituindo a seleção de divisão CART por um protocolo de corte mais elementar. Além disso, nas florestas de Breiman (2001), cada folha (ou seja, um nó terminal) de árvores individuais contém um pequeno número de observações, normalmente entre 1 e 5.

O objetivo desta pesquisa é levar o leitor a uma visita guiada por florestas aleatórias. Nós nos concentramos na teoria por trás do algoritmo, tentando f ornecer uma visão geral das principais abordagens teóricas enquanto discutimos seus prós e contras inerentes. Para uma revisão mais metodológica cobrindo aspectos aplicados de florestas aleatórias, referimo-nos às pesquisas de Criminisi et al. (2011) e Boulesteix et al. (2012). Começamos introduzindo suavemente o c ontexto matemático em

Section 2 and describe in full detail Breiman's (2001) original algorithm. Section 3 focuses on the theory for a simplified forest model called *purely random forests*, and emphasizes the connections between forests, nearest neighbor estimates and kernel methods. Section 4 provides some elements of theory about resampling mechanisms, the splitting criterion and the mathematical forces at work in Breiman's approach. Section 5 is devoted to the theoretical aspects of associated variable selection procedures. Section 6 discusses various extensions to random forests including online learning, survival analysis and clustering problems. A short discussion follows in Section 7.

2 The random forest estimate

2.1 Basic principles

Let us start with a word of caution. The term "random forests" is a bit ambiguous. For some authors, it is but a generic expression for aggregating random decision trees, no matter how the trees are obtained. For others, it refers to Breiman's (2001) original algorithm. We essentially adopt the second point of view in the present survey.

As mentioned above, the forest mechanism is versatile enough to deal with both supervised classification and regression tasks. However, to keep things simple, we focus in this introduction on regression analysis, and only briefly survey the classification case. Our objective in this section is to provide a concise but mathematically precise presentation of the algorithm for building a random forest. The general framework is nonparametric regression estimation, in which an input random vector $\mathbf{X} \in \mathcal{X} \subset \mathbb{R}^p$ is observed, and the goal is to predict the square integrable random response $Y \in \mathbb{R}$ by estimating the regression function $m(\mathbf{x}) = \mathbb{E}[Y|\mathbf{X} = \mathbf{x}]$. With this aim in mind, we assume we are given a training sample $\mathcal{D}_n = ((\mathbf{X}_1, Y_1), \ldots, (\mathbf{X}_n, Y_n))$ of independent random variables distributed as the independent prototype pair $(\mathbf{X}, Y)$. The goal is to use the data set $\mathcal{D}_n$ to construct an estimate $m_n : \mathcal{X} \to \mathbb{R}$ of the function m. In this respect, we say that the regression function estimate m_n is (mean squared error) consistent if $\mathbb{E}[m_n(\mathbf{X}) - m(\mathbf{X})]^2 \to 0$ as $n \to \infty$ (the expectation is evaluated over $\mathbf{X}$ and the sample $\mathcal{D}_n$).

A random forest is a predictor consisting of a collection of M randomized regression trees. For the j-th tree in the family, the predicted value at the query point $\mathbf{x}$ is denoted by $m_n(\mathbf{x}; \Theta_j, \mathcal{D}_n)$, where $\Theta_1, \ldots, \Theta_M$ are independent random variables, distributed the same as a generic random variable Θ

Seção 2 e descreve detalhadamente o algoritmo original de Breiman (2001). A Seção 3 concentra-se na teoria de um modelo florestal simplificado denominado florestas puramente aleatórias e enfatiza as conexões entre florestas, estimativas de vizinhos mais próximos e métodos de kernel. A Seção 4 fornece alguns elementos da teoria sobre os mecanismos de reamostragem, o critério de divisão e as forças matemáticas em ação na abordagem de Breiman. A Seção 5 é dedicada aos aspectos teóricos dos procedimentos de seleção de variáveis associadas. A Seção 6 discute várias extensões para florestas aleatórias, incluindo aprendizagem on-line, análise de sobrevivência e problemas de agrupamento. Uma breve discussão segue na Seção 7.

2 A estimativa florestal aleatória

2.1 Princípios básicos

Comecemos com uma palavra de cautela. O termo "florestas aleatórias" é um pouco ambíguo. Para alguns autores, trata-se apenas de uma expressão genérica para agregar árvores de decisão aleatória, independentemente de como as árvores são obtidas. Para outros, refere-se ao algoritmo original de Breiman (2001). Adotamos essencialmente o segundo ponto de vista na presente pesquisa.

Conforme mencionado acima, o mecanismo florestal é versátil o suficiente para lidar com tarefas de classificação supervisionada e de regressão. Contudo, para manter as coisas simples, focamos nesta introdução na análise de regressão e apenas examinamos brevemente o caso de classificação. Nosso objetivo nesta seção é fornecer uma apresentação concisa, mas matematicamente precisa, do algoritmo para construção de uma floresta aleatória. A estrutura geral é a estimativa de regressão não paramétrica, na qual um vetor aleatório de entrada X $\in \mathcal{X} \subset \mathbb{R}^p$ é observado, e o objetivo é prever a resposta aleatória quadrada integrável $Y \in \mathbb{R}$ estimando a função de regressão m(x) $= \mathbb{E}[Y|$X $=$ x]. Com esse objetivo em mente, assumimos que recebemos uma amostra de treinamento $\mathcal{D}_n =$ ((X1, Y_1) . . . , (X$_n$, Y_n)) de variáveis aleatórias independentes distribuídas como o par de protótipos independentes (X Y). O objetivo é usar o conjunto de dados $\mathcal{D}_n$ para construir u ma estimativa $m_n : \mathcal{X} \to \mathbb{R}$ da função m. A este respeito, dizemos que a estimativa da função de regressão m_né (erro quadrático médio) consistente se $\mathbb{E}[m_n$(X) $- m$(X) $]^2 \to 0$ como $n \to \infty$ (a expectativa é avaliada sobre X e a amostra $\mathcal{D}_n$).

Uma floresta aleatória é um preditor que consiste em uma coleção de M árvores de regressão aleatórias. Para a j-ésima árvore da família, o valor previsto no ponto de consulta x é denotado por m_n(x; Θ_j, $\mathcal{D}_n$), onde Θ_1, .. . , $\Theta_M$são variáveis aleatórias independentes, distribuídas da mesma forma que uma variável aleatória genérica Θ

and independent of $\mathcal{D}_n$. In practice, the variable Θ is used to resample the training set prior to the growing of individual trees and to select the successive directions for splitting—more precise definitions will be given later. In mathematical terms, the j-th tree estimate takes the form

$$m_n(\mathbf{x}; \Theta_j, \mathcal{D}_n) = \sum_{i \in \mathcal{D}_n^\star(\Theta_j)} \frac{\mathbb{1}_{\mathbf{X}_i \in A_n(\mathbf{x}; \Theta_j, \mathcal{D}_n)} Y_i}{N_n(\mathbf{x}; \Theta_j, \mathcal{D}_n)},$$

where $\mathcal{D}_n^\star(\Theta_j)$ is the set of data points selected prior to the tree construction, $A_n(\mathbf{x}; \Theta_j, \mathcal{D}_n)$ is the cell containing $\mathbf{x}$, and $N_n(\mathbf{x}; \Theta_j, \mathcal{D}_n)$ is the number of (preselected) points that fall into $A_n(\mathbf{x}; \Theta_j, \mathcal{D}_n)$.

At this stage, we note that the trees are combined to form the (finite) forest estimate

$$m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M, \mathcal{D}_n) = \frac{1}{M} \sum_{j=1}^{M} m_n(\mathbf{x}; \Theta_j, \mathcal{D}_n). \tag{1}$$

In the `R` package `randomForest`, the default value of M (the number of trees in the forest) is `ntree` $= 500$. Since M may be chosen arbitrarily large (limited only by available computing resources), it makes sense, from a modeling point of view, to let M tends to infinity, and consider instead of (1) the (infinite) forest estimate

$$m_{\infty,n}(\mathbf{x}; \mathcal{D}_n) = \mathbb{E}_\Theta \left[m_n(\mathbf{x}; \Theta, \mathcal{D}_n) \right].$$

In this definition, $\mathbb{E}_\Theta$ denotes the expectation with respect to the random parameter Θ, conditional on $\mathcal{D}_n$. In fact, the operation "$M \to \infty$" is justified by the law of large numbers, which asserts that almost surely, conditional on $\mathcal{D}_n$,

$$\lim_{M \to \infty} m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M, \mathcal{D}_n) = m_{\infty,n}(\mathbf{x}; \mathcal{D}_n)$$

(see for instance Breiman, 2001, and Scornet, 2015a, for more information on this limit calculation). In the following, to lighten notation we will simply write $m_{\infty,n}(\mathbf{x})$ instead of $m_{\infty,n}(\mathbf{x}; \mathcal{D}_n)$.

2.2 Algorithm

We now provide some insight on how the individual trees are constructed and how randomness kicks in. In Breiman's (2001) original forests, each node of a single tree is associated with a hyperrectangular cell. The root of the tree is $\mathcal{X}$ itself and, at each step of the tree construction, a node (or equivalently

e independente de $\mathcal{D}_n$. Na prática, a variável Θ é usada para reamostrar o conjunto de treinamento antes do crescimento de árvores individuais e para selecionar as direções sucessivas para divisão – definições mais precisas serão fornecidas posteriormente. Em termos matemáticos, a j-ésima estimativa da árvore assume a forma

$$m_n(\mathbf{x}; \Theta_j, \mathcal{D}_n) = \sum_{i \in \mathcal{D}_n^\star(\Theta_j)} \frac{\mathbb{1}_{\mathbf{X}_i \in A_n(\mathbf{x}; \Theta_j, \mathcal{D}_n)} Y_i}{N_n(\mathbf{x}; \Theta_j, \mathcal{D}_n)},$$

onde $\mathcal{D}_n^\star(\Theta_j)$ é o conjunto de pontos de dados selecionados antes da construção da árvore,A_n(x; Θ_j, $\mathcal{D}_n$) é a célula que contém x, e N_n(x; Θ_j, $\mathcal{D}_n$) é o número de pontos (pré-selecionados) que se enquadram em A_n(x; Θ_j, $\mathcal{D}_n$).

Nesta fase, notamos que as árvores são combinadas para formar a estimativa florestal (finita)

$$m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M, \mathcal{D}_n) = \frac{1}{M} \sum_{j=1}^{M} m_n(\mathbf{x}; \Theta_j, \mathcal{D}_n). \tag{1}$$

No pacote `R randomForest`, o valor padrão de M (o número de árvores na fl oresta) é `ntree` $= 500$. Como M pode ser escolhido arbitrariamente grande (limitado apenas pelos recursos de computação disponíveis), faz sentido, do ponto de vista da modelagem, deixar M tende ao infinito e considerar em vez de (1) a estimativa da floresta (infinita)

$$m_{\infty,n}(\mathbf{x}; \mathcal{D}_n) = \mathbb{E}_\Theta \left[m_n(\mathbf{x}; \Theta, \mathcal{D}_n) \right].$$

Nesta definição, $\mathbb{E}_\Theta$ denota a expectativa em relação ao parâmetro aleatório Θ, condicional em $\mathcal{D}_n$. Na verdade, a operação "$M \to \infty$" é justificada pela lei dos grandes números, que afirma que quase certamente, condicional a $\mathcal{D}_n$,

$$\lim_{M \to \infty} m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M, \mathcal{D}_n) = m_{\infty,n}(\mathbf{x}; \mathcal{D}_n)$$

(ver, por exemplo, Breiman, 2001, e Scornet, 2015a, para mais informações sobre este cálculo de limite). A seguir, para simplificar a notação, simplesmente escreveremos $m_{\infty,n}$(x) em vez de $m_{\infty,n}$(x; $\mathcal{D}_n$).

2.2 Algoritmo

Fornecemos agora algumas informações sobre como as árvores individuais são construídas e como a aleatoriedade entra em ação. Nas florestas originais de Breiman (2001), cada nó de uma única árvore está associado a uma célula hiperretangular. A raiz da árvore é ela mesma e, em cada etapa da construção da árvore, um nó (ou equivalentemente

its corresponding cell) is split in two parts. The terminal nodes (or leaves), taken together, form a partition of $\mathcal{X}$.

The algorithm works by growing M different (randomized) trees as follows. Prior to the construction of each tree, a_n observations are drawn at random with (or without) replacement from the original data set. These—and only these—a_n observations (with possible repetitions) are taken into account in the tree building. Then, at each cell of each tree, a split is performed by maximizing the CART-criterion (see below) over `mtry` directions chosen uniformly at random among the p original ones. (The resulting subset of selected coordinates is called $\mathcal{M}_{\text{try}}$.) Lastly, construction of individual trees is stopped when each cell contains less than `nodesize` points. For any query point $\mathbf{x} \in \mathcal{X}$, each regression tree predicts the average of the Y_i (that were among the a_n points) for which the corresponding $\mathbf{X}_i$ falls into the cell of $\mathbf{x}$. We draw attention to the fact that growing the tree and making the final estimation only depends on the a_n preselected data points. Algorithm 1 describes in full detail how to compute a forest's prediction.

Algorithm 1 may seem a bit complicated at first sight, but the underlying ideas are simple. We start by noticing that this algorithm has three important parameters:

1. $a_n \in \{1, \ldots, n\}$: the number of sampled data points in each tree;
2. `mtry` $\in \{1, \ldots, p\}$: the number of possible directions for splitting at each node of each tree;
3. `nodesize` $\in \{1, \ldots, a_n\}$: the number of examples in each cell below which the cell is not split.

By default, in the regression mode of the `R` package `randomForest`, the parameter `mtry` is set to $\lceil p/3 \rceil$ ($\lceil \cdot \rceil$ is the ceiling function), a_n is set to n, and `nodesize` is set to 5. The role and influence of these three parameters on the accuracy of the method will be thoroughly discussed in the next section.

We still have to describe how the CART-split criterion operates. As for now, we consider for the ease of understanding a tree with no subsampling, which uses the entire and original data set $\mathcal{D}_n$ for its construction. Also, we let A be a generic cell and denote by $N_n(A)$ the number of data points falling in A. A cut in A is a pair (j, z), where j is some value (dimension) from $\{1, \ldots, p\}$ and z the position of the cut along the j-th coordinate, within the limits of A. Let $\mathcal{C}_A$ be the set of all such possible cuts in A. Then, with the notation

sua célula correspondente) é dividida em duas partes. Os nós terminais (ou folhas), juntos, formam uma partição de $\mathcal{X}$.

O algoritmo funciona aumentando M árvores diferentes (randomizadas) da seguinte maneira. Antes da construção de cada árvore, a_n observações são sorteadas aleatoriamente com (ou sem) substituição do conjunto de dados original. Estas — e somente estas —a_n observações (com possíveis repetições) são levadas e m consideração na construção da árvore. Então, em cada célula de cada árvore, uma divisão é realizada maximizando o critério CART (veja abaixo) sobre `mtry` direções escolhidas uniformemente aleatoriamente entre as p originais. (O subconjunto resultante de coordenadas selecionadas é chamado $\mathcal{M}_{\text{try}}$.) Por último, a construção de árvores individuais é interrompida quando cada célula contém menos de `nodesize` pontos. Para qualquer ponto de consulta x $\in \mathcal{X}$, cada árvore de regressão prevê a média dos Y_i (que estavam entre os a_n pontos) para os quais o X correspondente$_i$ cai na célula de x. Chamamos a atenção para o fato de que o crescimento da árvore e a estimativa final dependem apenas dos a_n pontos de dados pré-selecionados. O Algoritmo 1 descreve detalhadamente como calcular a previsão de uma floresta.

O Algoritmo 1 pode parecer um pouco complicado à primeira vista, mas as ideias subjacentes são simples. Começamos percebendo que este algoritmo possui três parâmetros importantes:

1. $a_n \in \{1, \ldots, n\}$: o número de pontos de dados amostrados em cada árvore; 2. `mtry` $\in \{1, \ldots, p\}$: o número de direções possíveis de divisão em cada nó de cada árvore; 3. `nodesize` $\in \{1, \ldots, a_n\}$: o número de exemplos em cada célula abaixo dos quais a célula não está dividida.

Por padrão, no modo de regressão do `R` pacote `randomForest`, o parâmetro `mtry` é definido como $\lceil p/3 \rceil$ ($\lceil \cdot \rceil$ é a função teto), a_n é definido como n e`nodesize` é definido como 5. O papel e a influência desses três parâmetros na precisão do método serão discutidos detalhadamente na próxima seção.

Ainda temos que descrever como funciona o critério de divisão CART. Por enquanto, consideramos para facilitar o entendimento uma árvore sem subamostragem, que utiliza todo o conjunto de dados original $\mathcal{D}_n$ para sua construção. Além disso, deixamos A ser uma célula genérica e denotamos por $N_n(A)$ o número de pontos de dados que caem em A. Um corte em A é um par (j, z), onde j é algum valor (dimensão) de $\{1, \ldots, p\}$e z a posição do corte ao longo da j-ésima coordenada, dentro dos limites de$A$. Seja $\mathcal{C}_A$ o conjunto de todos esses cortes possíveis em A. Então, com a notação

Algorithm 1: Breiman's random forest predicted value at $\mathbf{x}$.

Input: Training set $\mathcal{D}_n$, number of trees $M > 0$, $a_n \in \{1, \ldots, n\}$, `mtry` $\in \{1, \ldots, p\}$, `nodesize` $\in \{1, \ldots, a_n\}$, and $\mathbf{x} \in \mathcal{X}$.

Output: Prediction of the random forest at $\mathbf{x}$.

for $j = 1, \ldots, M$ **do**
  Select a_n points, with (or without) replacement, uniformly in $\mathcal{D}_n$. In the following steps, only these a_n observations are used.
  Set $\mathcal{P} = (\mathcal{X})$ the list containing the cell associated with the root of the tree.
  Set $\mathcal{P}_{\text{final}} = \emptyset$ an empty list.
  while $\mathcal{P} \neq \emptyset$ **do**
    Let A be the first element of $\mathcal{P}$.
    if *A contains less than* `nodesize` *points or if all* $\mathbf{X}_i \in A$ *are equal* **then**
      Remove the cell A from the list $\mathcal{P}$.
      $\mathcal{P}_{\text{final}} \leftarrow \mathit{Concatenate}(\mathcal{P}_{\text{final}}, A)$.
    else
      Select uniformly, without replacement, a subset $\mathcal{M}_{\text{try}} \subset \{1, \ldots, p\}$ of cardinality `mtry`.
      Select the best split in A by optimizing the CART-split criterion along the coordinates in $\mathcal{M}_{\text{try}}$ *(see text for details)*.
      Cut the cell A according to the best split. Call A_L and A_R the two resulting cells.
      Remove the cell A from the list $\mathcal{P}$.
      $\mathcal{P} \leftarrow \mathit{Concatenate}(\mathcal{P}, A_L, A_R)$.
    end
  end
  Compute the predicted value $m_n(\mathbf{x}; \Theta_j, \mathcal{D}_n)$ at $\mathbf{x}$ equal to the average of the Y_i falling in the cell of $\mathbf{x}$ in partition $\mathcal{P}_{\text{final}}$.
end
Compute the random forest estimate $m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M, \mathcal{D}_n)$ at the query point $\mathbf{x}$ according to (1).

$\mathbf{X}_i = (\mathbf{X}_i^{(1)}, \ldots, \mathbf{X}_i^{(p)})$, for any $(j, z) \in \mathcal{C}_A$, the CART-split criterion takes the

Algoritmo 1: Valor previsto da floresta aleatória de Breiman em x. Entrada: Conjunto de treinamento $\mathcal{D}_n$, número de árvores $M > 0$, $a_n \in \{1, \ldots, n\}$, `mtry` $\in \{1, \ldots, p\}$, `nodesize` $\in \{1, \ldots, a_n\}$ e x $\in \mathcal{X}$. Saída: Predição da floresta aleatória em x. 1 para $j = 1, \ldots, M$ faça 2 Selecione a_n pontos, com (ou sem) substituição, uniformemente em $\mathcal{D}_n$. Nas etapas a seguir, somente essas a_n observações serão usadas. 3 Defina $\mathcal{P} = (\mathcal{X})$ a lista contendo a célula associada à raiz da árvore. 4 Defina $\mathcal{P}_{\text{final}} = \emptyset$ uma lista vazia. 5 enquanto $\mathcal{P} \neq \emptyset$ do 6 Seja A o primeiro elemento de $\mathcal{P}$. 7 se A contiver menos de `nodesize` pontos ou se todos os $\mathrm{X}_i \in A$ forem iguais, então 8 Remova a célula A da lista $\mathcal{P}$.9 $\mathcal{P}_{\text{final}} \leftarrow \mathit{Concatenate}(\mathcal{P}_{\text{final}}, A)$. 10 else 11 Selecione uniformemente, sem substituição, um subconjunto $\mathcal{M}_{\text{try}} \subset \{1, \ldots, p\}$ de cardinalidade `mtry`. 12 Selecione a melhor divisão em A otimizando o critério de divisão CART ao longo das coordenadas em $\mathcal{M}_{\text{try}}$ (veja o texto para detalhes). 13 Corte a célula A de acordo com a melhor divisão. Chame A_L e A_R as duas células resultantes. 14 Remova a célula A da lista $\mathcal{P}$. 15 $\mathcal{P} \leftarrow \mathit{Concatenate}(\mathcal{P}, A_L, A_R)$. 16 end 17 end 18 Calcule o valor previsto $m_n(\mathrm{x}; \Theta_j, \mathcal{D}_n)$ em x igual à média de Y_i caindo na célula de x na partição $\mathcal{P}_{\text{final}}$.

19 end 20 Calcule a estimativa aleatória da floresta $m_{M,n}(\mathrm{x}; \Theta_1, \ldots, \Theta_M, \mathcal{D}_n)$ no ponto de consulta x de acordo com (1).

$\mathrm{X}_i = (\mathrm{X}_i^{(1)}, \ldots, \mathrm{X}_i^{(p)})$, para qualquer $(j, z) \in \mathcal{C}_A$, o critério de divisão CART leva o

form

$$L_{\text{reg},n}(j,z) = \frac{1}{N_n(A)} \sum_{i=1}^{n} (Y_i - \bar{Y}_A)^2 \mathbb{1}_{\mathbf{X}_i \in A} - \frac{1}{N_n(A)} \sum_{i=1}^{n} (Y_i - \bar{Y}_{A_L} \mathbb{1}_{\mathbf{X}_i^{(j)} < z} - \bar{Y}_{A_R} \mathbb{1}_{\mathbf{X}_i^{(j)} \geq z})^2 \mathbb{1}_{\mathbf{X}_i \in A}, \qquad (2)$$

where $A_L = \{\mathbf{x} \in A : \mathbf{x}^{(j)} < z\}$, $A_R = \{\mathbf{x} \in A : \mathbf{x}^{(j)} \geq z\}$, and $\bar{Y}_A$ (resp., $\bar{Y}_{A_L}$, $\bar{Y}_{A_R}$) is the average of the Y_i belonging to A (resp., A_L, A_R), with the convention that the average is equal to 0 when no point $\mathbf{X}_i$ belongs to A (resp., A_L, A_R). For each cell A, the best cut $(j_n^\star, z_n^\star)$ is selected by maximizing $L_{\text{reg},n}(j,z)$ over $\mathcal{M}_{\text{try}}$ and $\mathcal{C}_A$; that is,

$$(j_n^\star, z_n^\star) \in \underset{\substack{j \in \mathcal{M}_{\text{try}} \\ (j,z) \in \mathcal{C}_A}}{\arg\max} L_{\text{reg},n}(j,z).$$

(To remove some of the ties in the argmax, the best cut is always performed in the middle of two consecutive data points.) Let us finally notice that the above optimization program extends effortlessly to the resampling case, by optimizing over the a_n preselected observations instead of the original data set $\mathcal{D}_n$.

Thus, at each cell of each tree, the algorithm chooses uniformly at random `mtry` coordinates in $\{1,\ldots,p\}$, evaluates criterion (2) over all possible cuts along the directions in $\mathcal{M}_{\text{try}}$, and returns the best one. The quality measure (2) is the criterion used in the influential CART algorithm of Breiman et al. (1984). This criterion computes the (renormalized) difference between the empirical variance in the node before and after a cut is performed. There are three essential differences between CART and a tree of Breiman's (2001) forest. First of all, in Breiman's forests, the criterion (2) is evaluated over a subset $\mathcal{M}_{\text{try}}$ of randomly selected coordinates, and not over the whole range $\{1,\ldots,p\}$. Besides, the individual trees are not pruned, and the final cells do not contain more than `nodesize` observations (unless all data points in the cell have the same $\mathbf{X}_i$). At last, each tree is constructed on a subset of a_n examples picked within the initial sample, not on the whole sample $\mathcal{D}_n$; and only these a_n observations are used to calculate the estimation. When $a_n = n$ (and the resampling is done with replacement), the algorithm runs in bootstrap mode, whereas $a_n < n$ corresponds to subsampling (with or without replacement).

form

$$L_{\text{reg},n}(j,z) = \frac{1}{N_n(A)} \sum_{i=1}^{n} (Y_i - \bar{Y}_A)^2 \mathbb{1}_{\mathbf{X}_i \in A} - \frac{1}{N_n(A)} \sum_{i=1}^{n} (Y_i - \bar{Y}_{A_L} \mathbb{1}_{\mathbf{X}_i^{(j)} < z} - \bar{Y}_{A_R} \mathbb{1}_{\mathbf{X}_i^{(j)} \geq z})^2 \mathbb{1}_{\mathbf{X}_i \in A}, \qquad (2)$$

onde $A_L = \{\mathbf{x} \in A : \mathbf{x}^{(j)} < z\}$, $A_R = \{\mathbf{x} \in A : \mathbf{x}^{(j)} \geq z\}$, e $\bar{Y}_A$ (resp., Y_{A_L}, Y_{A_R}) é a média do Y_i pertencente a A (resp., A_L, A_R), com a convenção de que a média é igual a 0 quando nenhum ponto $\mathbf{X}_i$ pertence a A (resp., A_L, A_R). Para cada célula A, o melhor corte $(j_n^\star, z_n^\star)$ é selecionado maximizando $L_{\text{reg},n}(j,z)$ sobre $\mathcal{M}_{\text{try}}$ e $\mathcal{C}_A$; aquilo é,

$$(j_n^\star, z_n^\star) \in \underset{\substack{j \in \mathcal{M}_{\text{try}} \\ (j,z) \in \mathcal{C}_A}}{\arg\max} L_{\text{reg},n}(j,z).$$

(Para remover algumas das ligações no argmax, o melhor corte é sempre realizado no meio de dois pontos de dados consecutivos.) Vamos finalmente notar que o programa de otimização acima se estende sem esforço ao caso de reamostragem, otimizando as a_n observações pré-selecionadas em vez do conjunto de dados original $\mathcal{D}_n$.

Assim, em cada célula de cada árvore, o algoritmo escolhe uniformemente e aleatoriamente `mtry` coordenadas em $\{1,\ldots,p\}$, avalia o critério (2) sobre todos os cortes possíveis ao longo das direções em $\mathcal{M}_{\text{try}}$ e retorna o melhor. A medida de qualidade (2) é o critério utilizado no influente algoritmo CART de Breiman et al. (1984). Este critério calcula a diferença (renormalizada) entre a variância empírica no nó antes e depois da execução de um corte. Existem três diferenças essenciais entre o CART e uma árvore da floresta de Breiman (2001). Em primeiro lugar, nas florestas de Breiman, o critério (2) é avaliado sobre um subconjunto $\mathcal{M}_{\text{try}}$ de coordenadas selecionadas aleatoriamente, e não sobre todo o intervalo $\{1,\ldots,p\}$. Além disso, as árvores individuais não são podadas e as células finais não contêm mais do que `nodesize` observações (a menos que todos os pontos de dados na célula tenham o mesmo $\mathbf{X}_i$). Por fim, cada árvore é construída em um subconjunto de a_n exemplos escolhidos na amostra inicial, não em toda a amostra $\mathcal{D}_n$; e somente essas a_n observações são usadas para calcular a estimativa. Quando $a_n = n$ (e a reamostragem é feita com substituição), o algoritmo é executado em modo bootstrap, enquanto $a_n < n$ corresponde à subamostragem (com ou sem substituição).

2.3 Supervised classification

For simplicity, we only consider here the binary classification problem, keeping in mind that random forests are intrinsically capable of dealing with multi-class problems (see, e.g., Díaz-Uriarte and de Andrés, 2006). In this setting (Devroye et al., 1996), the random response Y takes values in $\{0, 1\}$ and, given $\mathbf{X}$, one has to guess the value of Y. A classifier, or classification rule, m_n is a Borel measurable function of $\mathbf{X}$ and $\mathcal{D}_n$ that attempts to estimate the label Y from $\mathbf{X}$ and $\mathcal{D}_n$. In this framework, one says that the classifier m_n is consistent if its conditional probability of error

$$L(m_n) = \mathbb{P}[m_n(\mathbf{X}) \neq Y] \underset{n\to\infty}{\to} L^\star,$$

where $L^\star$ is the error of the optimal—but unknown—Bayes classifier:

$$m^\star(\mathbf{x}) = \begin{cases} 1 & \text{if } \mathbb{P}[Y = 1|\mathbf{X} = \mathbf{x}] > \mathbb{P}[Y = 0|\mathbf{X} = \mathbf{x}] \\ 0 & \text{otherwise.} \end{cases}$$

In the classification context, the random forest classifier is obtained via a majority vote among the classification trees, that is,

$$m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M, \mathcal{D}_n) = \begin{cases} 1 & \text{if } \frac{1}{M}\sum_{j=1}^{M} m_n(\mathbf{x}; \Theta_j, \mathcal{D}_n) > 1/2 \\ 0 & \text{otherwise.} \end{cases}$$

If a leaf represents region A, then a randomized tree classifier takes the simple form

$$m_n(\mathbf{x}; \Theta_j, \mathcal{D}_n) = \begin{cases} 1 & \text{if } \sum_{i\in\mathcal{D}_n^\star(\Theta)} \mathbf{1}_{\mathbf{X}_i\in A, Y_i=1} > \sum_{i\in\mathcal{D}_n^\star(\Theta)} \mathbf{1}_{\mathbf{X}_i\in A, Y_i=0}, \ \mathbf{x} \in A \\ 0 & \text{otherwise,} \end{cases}$$

where $\mathcal{D}_n^\star(\Theta)$ contains the data points selected in the resampling step. That is, in each leaf, a majority vote is taken over all $(\mathbf{X}_i, Y_i)$ for which $\mathbf{X}_i$ is in the same region. Ties are broken, by convention, in favor of class 0. Algorithm 1 can be easily adapted to do classification by modifying the CART-split criterion for the binary setting. To see this, let us consider a single tree with no subsampling step. For any generic cell A, let $p_{0,n}(A)$ (resp., $p_{1,n}(A)$) be the empirical probability of a data point in the cell A having label 0 (resp., label 1). Then, for any $(j, z) \in \mathcal{C}_A$, the classification CART-split criterion reads

$$L_{\text{class},n}(j, z) = p_{0,n}(A)p_{1,n}(A) - \frac{N_n(A_L)}{N_n(A)} \times p_{0,n}(A_L)p_{1,n}(A_L) - \frac{N_n(A_R)}{N_n(A)} \times p_{0,n}(A_R)p_{1,n}(A_R).$$

2.3 Classificação supervisionada

Para simplificar, consideramos aqui apenas o problema de classificação binária, tendo em mente que florestas aleatórias são intrinsecamente capazes de lidar com problemas multiclasses (ver, por exemplo, D´ıaz-Uriarte e de Andr´es, 2006). Neste cenário (Devroye et al., 1996), a resposta aleatória Y assume valores em $\{0, 1\}$e, dado X, é preciso adivinhar o valor de Y. Um classificador, ou regra de classificação, m_n é uma função mensurável do Borel de X e $\mathcal{D}_n$ que tenta estimar o rótulo Y de X e $\mathcal{D}_n$. Nesta estrutura, diz-se que o classificador m_n é consistente se a sua probabilidade condicional de erro

$$L(m_n) = \mathbb{P}[m_n(\mathbf{X}) \neq Y] \underset{n\to\infty}{\to} L^\star,$$

onde $L^\star$ é o erro do classificador Bayes ideal, mas desconhecido:

$$m^\star(\mathbf{x}) = \begin{cases} 1 & \text{if } \mathbb{P}[Y = 1|\mathbf{X} = \mathbf{x}] > \mathbb{P}[Y = 0|\mathbf{X} = \mathbf{x}] \\ 0 & \text{otherwise.} \end{cases}$$

No contexto de classificação, o classificador florestal aleatório é obtido por maioria de votos entre as árvores de classificação, ou seja,

$$m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M, \mathcal{D}_n) = \begin{cases} 1 & \text{if } \frac{1}{M}\sum_{j=1}^{M} m_n(\mathbf{x}; \Theta_j, \mathcal{D}_n) > 1/2 \\ 0 & \text{otherwise.} \end{cases}$$

Se uma folha representa a região A, então um classificador de árvore aleatório assume a forma simples

$$m_n(\mathbf{x}; \Theta_j, \mathcal{D}_n) = \begin{cases} 1 & \text{if } \sum_{i\in\mathcal{D}_n^\star(\Theta)} \mathbf{1}_{\mathbf{X}_i\in A, Y_i=1} > \sum_{i\in\mathcal{D}_n^\star(\Theta)} \mathbf{1}_{\mathbf{X}_i\in A, Y_i=0}, \ \mathbf{x} \in A \\ 0 & \text{otherwise,} \end{cases}$$

onde $\mathcal{D}_n^\star(\Theta)$ contém os pontos de dados selecionados na etapa de reamostragem. Ou seja, em cada folha ocorre uma votação majoritária sobre todos (X_i, Y_i) para os quais X_i está na mesma região. Os empates são quebrados, por convenção, em favor da classe 0. O Algoritmo 1 pode ser facilmente adaptado para fazer classificação, modificando o critério de divisão CART para a configuração binária. Para ver isso, consideremos uma única árvore sem etapa de subamostragem. Para qualquer célula genérica A, seja $p_{0,n}(A)$ (resp., $p_{1,n}(A)$) a probabilidade empírica de um ponto de dados na célula A tendo rótulo 0 (resp., rótulo 1). Então, para qualquer $(j, z) \in \mathcal{C}_A$, o critério de classificação CART-split é lido

$$L_{\text{class},n}(j, z) = p_{0,n}(A)p_{1,n}(A) - \frac{N_n(A_L)}{N_n(A)} \times p_{0,n}(A_L)p_{1,n}(A_L) - \frac{N_n(A_R)}{N_n(A)} \times p_{0,n}(A_R)p_{1,n}(A_R).$$

This criterion is based on the so-called *Gini impurity measure* $2p_{0,n}(A)p_{1,n}(A)$ (Breiman et al., 1984), which has the following simple interpretation. To classify a data point that falls in cell A, one uses the rule that assigns a point, uniformly selected from $\{\mathbf{X}_i \in A : (\mathbf{X}_i, Y_i) \in \mathcal{D}_n\}$, to label ℓ with probability $p_{\ell,n}(A)$, for $j \in \{0, 1\}$. The estimated probability that the item has actually label ℓ is $p_{\ell,n}(A)$. Therefore the estimated error under this rule is the Gini index $2p_{0,n}(A)p_{1,n}(A)$.

We note that whenever $Y \in \{0, 1\}$, optimizing the classification criterion $L_{\text{class},n}$ is equivalent to optimizing its regression counterpart $L_{\text{reg},n}$. Thus, in this case, the trees obtained with $L_{\text{class},n}$ and $L_{\text{reg},n}$ are identical. However, the prediction strategy is different: in the classification regime, each tree uses a local majority vote, whereas in regression the prediction is achieved by a local averaging.

When dealing with classification problems, it is usually recommended to set `nodesize` $= 1$ and `mtry` $= \sqrt{p}$ (see, e.g., Liaw and Wiener, 2002).

We draw attention to the fact that regression estimation may also have an interest in the context of dichotomous and multicategory outcome variables (in this case, it is often termed *probability estimation*). For example, estimating outcome probabilities for individuals is important in many areas of medicine, with applications to surgery, oncology, internal medicine, pathology, pediatrics, and human genetics. We refer the interested reader to Malley et al. (2012) and to the survey papers by Kruppa et al. (2014a) and Kruppa et al. (2014b).

2.4 Parameter tuning

Literature focusing on tuning the parameters M, `mtry`, `nodesize` and a_n is unfortunately rare, with the notable exception of Díaz-Uriarte and de Andrés (2006), Bernard et al. (2008), and Genuer et al. (2010). According to Schwarz et al. (2010), tuning the forest parameters may result in a computational burden, in particular for big data sets, with hundreds and thousands of samples and variables. To circumvent this issue, Schwarz et al. (2010) implement a fast version of the original algorithm, which they name *Random Jungle*.

It is easy to see that the forest's variance decreases as M grows. Thus, more accurate predictions are likely to be obtained by choosing a large number of trees. Interestingly, picking a large M does not lead to overfitting. In effect,

Este critério é baseado na chamada medida de impureza de Gini $2p_{0,n}(A)p_{1,n}(A)$ (Breiman et al., 1984), que tem a seguinte interpretação simples. Para classificar u m ponto de dados que cai na célula A, usa-se a regra que atribui um ponto, selecionado uniformemente de $\{\mathbf{X}_i \in A : (\mathbf{X}_i, Y_i) \in \mathcal{D}_n\}$, para rotular ℓ com probabilidade $p_{\ell,n}(A)$, para $j \in \{0, 1\}$. A probabilidade estimada de que o item tenha realmente o rótulo ℓ é $p_{\ell,n}(A)$. Portanto, o erro estimado sob esta regra é o índice de Gini $2p_{0,n}(A)p_{1,n}(A)$.

Observamos que sempre que $Y \in \{0, 1\}$, otimizar o critério de classificação $L_{\text{class},n}$ é equivalente a otimizar sua contraparte de regressão $L_{\text{reg},n}$. Assim, neste caso, as árvores obtidas com $L_{\text{class},n}$ e $L_{\text{reg},n}$ são idênticas. No entanto, a estratégia de predição é diferente: no regime de classificação, cada árvore utiliza o voto da maioria local, enquanto na regressão a predição é alcançada por uma média local.

Ao lidar com problemas de classificação, geralmente é recomendado definir `nodesize` $= 1$ e `mtry` $= \sqrt{p}$ (ver, por exemplo, Liaw e Wiener, 2002).

Chamamos a atenção para o facto de que a estimativa de regressão também pode t er interesse no contexto de variáveis de resultados dicotómicas e multicategorias (neste caso, é frequentemente denominada estimativa de probabilidade). Por exemplo, estimar as probabilidades de resultados para indivíduos é importante em muitas áreas da medicina, com aplicações em cirurgia, oncologia, medicina interna, patologia, pediatria e genética humana. Encaminhamos o leitor interessado para Malley et al. (2012) e aos artigos de pesquisa de Kruppa et al. (2014a) e Kruppa et al. (2014b).

2.4 Ajuste de parâmetros

A literatura focada no ajuste dos parâmetros M, `mtry`, `nodesize` e a_n é infeliz mente rara, com a notável exceção de Díaz-Uriarte e de Andrés (2006), Bernard et al. (2008) e Genuer et al. (2010). De acordo com Schwarz et al. (2010), o ajuste dos parâmetros florestais pode resultar em uma carga computacional, em particular para grandes conjuntos de dados, com centenas e milhares de amostras e variáveis. Para contornar esse problema, Schwarz et al. (2010) implementam uma versão rápida do algoritmo original, que chamam de Random Jungle.

É fácil ver que a variância da floresta diminui à medida que M cresce. Assim, é provável que previsões mais precisas sejam obtidas escolhendo um grande número de árvores. Curiosamente, escolher um valor grande M não leva ao overfitting. Com efeito,

following an argument of Breiman (2001), we have

$$\lim_{n\to\infty} \mathbb{E}[m_{M,n}(\mathbf{X};\Theta_1,\ldots,\Theta_M) - m(\mathbf{X})]^2 = \mathbb{E}[m_{\infty,n}(\mathbf{X}) - m(\mathbf{X})]^2.$$

However, the computational cost for inducing a forest increases linearly with M, so a good choice results from a trade-off between computational complexity (M should not be too large for the computations to finish in a reasonable time) and accuracy (M must be large enough for predictions to be stable). In this respect, Díaz-Uriarte and de Andrés (2006) argue that the value of M is irrelevant (provided that M is large enough) in a prediction problem involving microarray data sets, where the aim is to classify patients according to their genetic profiles (typically, less than one hundred patients for several thousand genes). For more details we refer the reader to Genuer et al. (2010), who offer a thorough discussion on the choice of this parameter in various regression problems. Another interesting and related approach is by Latinne et al. (2001), who propose a simple procedure that determines a priori a minimum number of tree estimates to combine in order to obtain a prediction accuracy level similar to that of a larger forest. Their experimental results show that it is possible to significantly limit the number of trees.

In the `R` package `randomForest`, the default value of the parameter `nodesize` is 1 for classification and 5 for regression. These values are often reported to be good choices (e.g., Díaz-Uriarte and de Andrés, 2006), despite the fact that this is not supported by solid theory. A simple algorithm to tune the parameter `nodesize` in the classification setting is discussed in Kruppa et al. (2013).

The effect of `mtry` is thoroughly investigated in Díaz-Uriarte and de Andrés (2006), who show that this parameter has a little impact on the performance of the method, though larger values may be associated with a reduction in the predictive performance. On the other hand, Genuer et al. (2010) claim that the default value of `mtry` is either optimal or too small. Therefore, a conservative approach is to take `mtry` as large as possible (limited by available computing resources) and set `mtry` $= p$ (recall that p is the dimension of the $\mathbf{X}_i$). A data-driven choice of `mtry` is implemented in the algorithm *Forest-RK* of Bernard et al. (2008).

Let us finally notice that even if there is no theoretical guarantee to support the default values of the parameters, they are nevertheless easy to tune without requiring an independent validation set. Indeed, the procedure accuracy is estimated internally, during the run, as follows. Since each tree is constructed using a different bootstrap sample from the original data, about

seguindo um argumento de Breiman (2001), temos

$$\lim_{n\to\infty} \mathbb{E}[m_{M,n}(\mathbf{X};\Theta_1,\ldots,\Theta_M) - m(\mathbf{X})]^2 = \mathbb{E}[m_{\infty,n}(\mathbf{X}) - m(\mathbf{X})]^2.$$

No entanto, o custo computacional para induzir uma floresta aumenta linearmente com M, portanto uma boa escolha resulta de um compromisso entre complexidade computacional (M não deve ser muito grande para que os cálculos terminem em um tempo razoável) e precisão (M deve ser grande o suficiente para que as previsões sejam estáveis). A este respeito, D´ıaz-Uriarte e de Andr´es (2006) argumentam que o valor de$M$ é irrelevante (desde que M seja suficientemente grande) num problema de predição envolvendo conjuntos de dados de microarranjos, onde o objetivo é classificar os pacientes de acordo com os seus perfis genéticos (normalmente, menos de cem pacientes para vários milhares de genes). Para mais detalhes remetemos o leitor para Genuer et al. (2010), que oferecem uma discussão aprofundada sobre a escolha desse parâmetro em diversos problemas de regressão. Outra abordagem interessante e relacionada é a de Latinne et al. (2001), que propõem um procedimento simples que determina a priori um número mínimo de estimativas de árvores a serem combinadas para obter um nível de precisão de previsão semelhante ao de uma floresta maior. Os seus resultados experimentais mostram que é possível limitar significativamente o número de árvores.

No `R` pacote `randomForest`, o valor padrão do parâmetro `nodesize`é 1 para classificação e 5 para regressão. Esses valores são frequentemente relatados como boas escolhas (por exemplo, D´ıaz-Uriarte e de Andr´es, 2006), apesar de isso não ser apoiado por uma teoria sólida. Um algoritmo simples para ajustar o parâmetro `nodesize` na configuração de classificação é discutido em Kruppa et al. (2013).

O efeito de `mtry` é exaustivamente investigado em D´ıaz-Uriarte e de Andr´es (2006), que mostram que este parâmetro tem pouco impacto no desempenho do método, embora valores maiores possam estar associados a uma redução no desempenho preditivo. Por outro lado, Genuer et al. (2010) afirmam que o valor padrão de `mtry` é ótimo ou muito pequeno. Portanto, uma abordagem conservadora é considerar `mtry`o maior possível (limitado pelos recursos computacionais disponíveis) e definir `mtry` $= p$ (lembre-se de que p é a dimensão do $\mathbf{X}_i$). Uma escolha baseada em dados de `mtry` é implementada no algoritmo Forest-RK de Bernard et al. (2008).

Notemos finalmente que mesmo que não haja nenhuma garantia teórica para suportar os valores padrão dos parâmetros, eles são fáceis de ajustar sem exigir u m conjunto de validação independente. Na verdade, a precisão do procedimento é estimada internamente, durante a execução, como segue. Como cada árvore é construída usando uma amostra de bootstrap diferente dos dados originais, cerca de

one-third of the observations are left out of the bootstrap sample and not used in the construction of the j-th tree. In this way, for each tree, a test set—disjoint from the training set—is obtained, and averaging over all these left-out data points and over all trees is known as the *out-of-bag* error estimate. Thus, the out-of-bag error, computed on the observations set aside by the resampling prior to the tree building, offers a simple way to adjust the parameters without the need of a validation set. (e.g., Kruppa et al., 2013).

3 Simplified models and local averaging estimates

3.1 Simplified models

Despite their widespread use, a gap remains between the theoretical understanding of random forests and their practical performance. This algorithm, which relies on complex data-dependent mechanisms, is difficult to analyze and its basic mathematical properties are still not well understood.

As observed by Denil et al. (2014), this state of affairs has led to polarization between theoretical and empirical contributions to the literature. Empirically focused papers describe elaborate extensions to the basic random forest framework but come with no clear guarantees. In contrast, most theoretical papers focus on simplifications or stylized versions of the standard algorithm, where the mathematical analysis is more tractable.

A basic framework to assess the theoretical properties of forests involves models in which trees are designed independently of the training set $\mathcal{D}_n$. This family of simplified models is often called *purely random forests*, for which $\mathcal{X} = [0,1]^d$. A widespread example is the *centered forest*, whose principle is as follows: (i) there is no resampling step; (ii) at each node of each individual tree, a coordinate is uniformly chosen in $\{1,\dots,p\}$; and (iii) a split is performed at the center of the cell along the selected coordinate. The operations (ii)-(iii) are recursively repeated k times, where $k \in \mathbb{N}$ is a parameter of the algorithm. The procedure stops when a full binary tree with k levels is reached, so that each tree ends up with exactly 2^k leaves. The final estimation at the query point $\mathbf{x}$ is achieved by averaging the Y_i corresponding to the $\mathbf{X}_i$ in the cell of $\mathbf{x}$. The parameter k acts as a smoothing parameter that controls the size of the terminal cells (see Figure 1 for an example in two dimensions). It should be chosen large enough in order to detect local changes in the distribution, but not too much to guarantee an effective

um terço das observações é deixado de fora da amostra bootstrap e não é usado na construção da j-ésima árvore. Dessa forma, para cada árvore, um conjunto de teste – separado do conjunto de treinamento – é obtido, e a média de todos esses pontos de dados deixados de fora e de todas as árvores é conhecida como estimativa de erro out-of-bag. Assim, o erro out-of-bag, calculado nas observações reservadas pela reamostragem antes da construção da árvore, oferece uma maneira simples de ajustar os parâmetros sem a necessidade de um conjunto de validação. (por exemplo, Kruppa et al., 2013).

3 Modelos simplificados e estimativas médias locais

3.1 Modelos simplificados

Apesar do seu uso generalizado, permanece uma lacuna entre a compreensão teórica das florestas aleatórias e o seu desempenho prático. Este algoritmo, que depende de mecanismos complexos dependentes de dados, é difícil de analisar e as suas propriedades matemáticas básicas ainda não são bem compreendidas.

Conforme observado por Denil et al. (2014), esse estado de coisas levou à polarização entre as contribuições teóricas e empíricas para a literatura. Artigos com foco empírico descrevem extensões elaboradas à estrutura básica de florestas aleatórias, mas não apresentam garantias claras. Em contraste, a maioria dos artigos teóricos concentra-se em simplificações ou versões estilizadas do algoritmo padrão, onde a análise matemática é mais tratável.

Uma estrutura básica para avaliar as propriedades teóricas das florestas envolve modelos nos quais as árvores são projetadas independentemente do conjunto de treinamento $\mathcal{D}_n$. Esta família de modelos simplificados é frequentemente chamada de florestas puramente aleatórias, para as quais $\mathcal{X} = [0,1]^d$. Um exemplo bastante difundido é a floresta centrada, cujo princípio é o seguinte: (i) não há etapa de reamostragem; (ii) em cada nó de cada árvore individual, uma coordenada é escolhida uniformemente em $\{1,\dots,p\}$; e (iii) uma divisão é realizada no centro da célula ao longo da coordenada selecionada. As operações (ii)-(iii) são repetidas recursivamente k vezes, onde $k \in$N é um parâmetro do algoritmo. O procedimento para quando uma árvore binária completa com k níveis é alcançada, de modo que cada árvore termine com exatamente 2^k folhas. A estimativa final no ponto de consulta x é obtida calculando a média do Y_i correspondente ao X_i na célula de x. O parâmetro k atua como um parâmetro de suavização que controla o tamanho das células terminais (veja a Figura 1 para ver um exemplo em duas dimensões). Deve ser escolhido suficientemente grande para detectar alterações locais na distribuição, mas não demasiado para garantir uma eficácia eficaz.

averaging process in the leaves. In *uniform random forests*, a variant of centered forests, cuts are performed uniformly at random over the range of the selected coordinate, not at the center. Modulo some minor modifications, their analysis is similar.

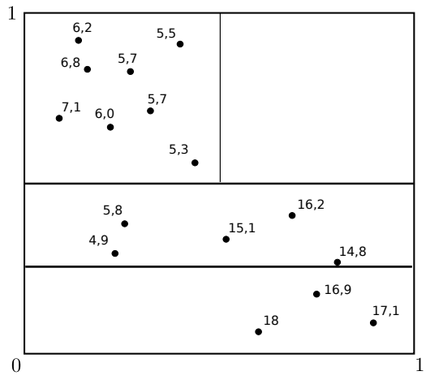


Figure 1: A centered tree at level 2.

The centered forest rule was first formally analyzed by Breiman (2004), and then later by Biau et al. (2008) and Scornet (2015a), who proved that the method is consistent (both for classification and regression) provided $k \to \infty$ and $n/2^k \to \infty$. The proof relies on a general consistency result for random trees stated in Devroye et al. (1996, Chapter 6). If $\mathbf{X}$ is uniformly distributed in $\mathcal{X} = [0,1]^p$, then there are on average about $n/2^k$ data points per terminal node. In particular, the choice $k \approx \log n$ corresponds to obtaining a small number of examples in the leaves, in accordance with Breiman's (2001) idea that the individual trees should not be pruned. Unfortunately, this choice of k does not satisfy the condition $n/2^k \to \infty$, so something is lost in the analysis. Moreover, the bagging step is absent, and forest consistency is obtained as a by-product of tree consistency. Overall, this model does not demonstrate the benefit of using forests in place of individual trees and is too simple to explain the mathematical forces driving Breiman's forests.

The rates of convergence of centered forests are discussed in Breiman (2004) and Biau (2012). In their approach, the covariates $X^{(j)}$ are independent and the target regression function $m(\mathbf{x}) = \mathbb{E}[Y|\mathbf{X} = \mathbf{x}]$, which is originally a function of $\mathbf{x} = (x^{(1)}, \ldots, x^{(p)})$, is assumed to depend only on a nonempty subset $\mathcal{S}$ (for $\mathcal{S}$trong) of the p features. Thus, letting $\mathbf{X}_\mathcal{S} = (X^{(j)} : j \in \mathcal{S})$,

processo de média nas folhas. Em florestas aleatórias uniformes, uma variante de florestas centralizadas, os cortes são executados de maneira uniforme e aleatória no intervalo da coordenada selecionada, e não no centro. Módulo algumas pequenas modificações, sua análise é semelhante.

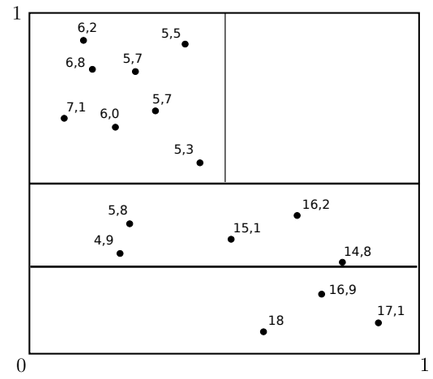


Figura 1: Uma árvore centrada no nível 2.

A regra florestal centrada foi analisada formalmente pela primeira vez por Breiman (2004) e posteriormente por Biau et al. (2008) e Scornet (2015a), que comprovaram que o método é consistente (tanto para classificação quanto para regressão) desde $k \to \infty$e $n/2^k \to \infty$. A prova baseia-se num resultado de consistência geral para árvores aleatórias declarado em Devroye et al. (1996, Capítulo 6). Se X for distribuído uniformemente em $\mathcal{X} = [0,1]^p$, então haverá em média cerca de $n/2^k$ pontos de dados por nó terminal. Em particular, a escolha $k \approx \log n$ corresponde à obtenção de um pequeno número de exemplos nas folhas, de acordo com a ideia de Breiman (2001) de que as árvores individuais não devem ser podadas. Infelizmente, esta escolha de k não satisfaz a condição $n/2^k \to \infty$, então algo se perde na análise. Além disso, a etapa de ensacamento está ausente e a consistência florestal é obtida como subproduto da consistência arbórea. No geral, este modelo não demonstra o benefício da utilização de florestas em vez de árvores individuais e é demasiado simples para explicar as forças matemáticas que impulsionam as florestas de Breiman.

As taxas de convergência das florestas centradas são discutidas em Breiman (2004) e Biau (2012). Em sua abordagem, as covariáveis $X^{(j)}$ são independentes e a função de regressão alvo m(x) $= \mathbb{E}[Y|$X $=$ x$]$, que é originalmente uma função de x $=(x^{(1)}$, $\ldots, x^{(p)})$, é assumido como dependente apenas de um subconjunto não vazio $\mathcal{S}$ (para $\mathcal{S}$trong) dos recursos p . Assim, deixando X$_\mathcal{S}$ $=(X^{(j)} :$ $j \in \mathcal{S})$,

we have

$$m(\mathbf{x}) = \mathbb{E}[Y|\mathbf{X}_{\mathcal{S}} = \mathbf{x}_{\mathcal{S}}].$$

The variables of the remaining set $\{1, \ldots, p\}\backslash\mathcal{S}$ have no influence on the function m and can be safely removed. The ambient dimension p can be large, much larger than the sample size n, but we believe that the representation is sparse, i.e., that a potentially small number of arguments of m are active— the ones with indices matching the set $\mathcal{S}$. Letting $|\mathcal{S}|$ be the cardinality of $\mathcal{S}$, the value $|\mathcal{S}|$ characterizes the sparsity of the model: the smaller $|\mathcal{S}|$, the sparser m. In this dimension-reduction scenario, Breiman (2004) and Biau (2012) proved that if the probability $p_{j,n}$ of splitting along the j-th direction tends to $1/S$ and m satisfies a Lipschitz-type smoothness condition, then

$$\mathbb{E}\left[m_{\infty,n}(\mathbf{X}) - m(\mathbf{X})\right]^2 = \mathrm{O}\left(n^{\frac{-0.75}{|\mathcal{S}|\log 2 + 0.75}}\right).$$

This equality shows that the rate of convergence of $m_{\infty,n}$ to m depends only on the number $|\mathcal{S}|$ of strong variables, not on the dimension p. This rate is strictly faster than the usual rate $n^{-2/(p+2)}$ as soon as $|\mathcal{S}| \leq \lfloor 0.54p \rfloor$ ($\lfloor\cdot\rfloor$ is the floor function). In effect, the intrinsic dimension of the regression problem is $|\mathcal{S}|$, not p, and we see that the random forest estimate adapts itself to the sparse framework. Of course, this is achieved by assuming that the procedure succeeds in selecting the informative variables for splitting, which is indeed a strong assumption.

An alternative model for pure forests, called *purely uniform random forests* (PURF) is discussed in Genuer (2012). For $p = 1$, a PURF is obtained by drawing k random variables uniformly on $[0, 1]$, and subsequently dividing $[0, 1]$ into random sub-intervals. (Note that as such, the PURF can only be defined for $p = 1$.). Although this construction is not exactly recursive, it is equivalent to growing a decision tree by deciding at each level which node to split with a probability equal to its length. Genuer (2012) proves that PURF are consistent and, under a Lipschitz assumption, that the estimate satisfies

$$\mathbb{E}[m_{\infty,n}(\mathbf{X}) - m(\mathbf{X})]^2 = \mathrm{O}\left(n^{-2/3}\right).$$

This rate is minimax over the class of Lipschitz functions (Stone, 1980, 1982).

It is often acknowledged that random forests reduce the estimation error of a single tree, while maintaining the same approximation error. In this respect, Biau (2012) argues that the estimation error of centered forests tends to zero (at the slow rate $1/\log n$) even if each tree is fully grown (i.e., $k \approx \log n$). This result is a consequence of the tree-averaging process, since the estimation error of an individual fully grown tree does not tend to zero.

nós
temos

$$m(\mathbf{x}) = \mathbb{E}[Y|\mathbf{X}_{\mathcal{S}} = \mathbf{x}_{\mathcal{S}}].$$

As variáveis do conjunto restante $\{1, \ldots, p\}\backslash\mathcal{S}$ não têm influência na função m e podem ser removidas com segurança. A dimensão ambiental p pode ser grande, muito maior que o tamanho da amostra n, mas acreditamos que a representação é esparsa, ou seja, que um número potencialmente pequeno de argumentos de m está ativo — aqueles com índices correspondentes ao conjunto $\mathcal{S}$. Sendo $|\mathcal{S}|$ a cardinalidade de$\mathcal{S}$, o valor $|\mathcal{S}|$ caracteriza a dispersão do modelo: quanto menor $|\mathcal{S}|$, mais esparso m. Neste cenário de redução de dimensão, Breiman (2004) e Biau (2012) provaram que se a probabilidade $p_{j,n}$ de divisão ao longo da j-ésima direção tende a $1/S$ e m satisfaz uma condição de suavidade do tipo Lipschitz, então

$$\mathbb{E}\left[m_{\infty,n}(\mathbf{X}) - m(\mathbf{X})\right]^2 = \mathrm{O}\left(n^{\frac{-0.75}{|\mathcal{S}|\log 2 + 0.75}}\right).$$

Esta igualdade mostra que a taxa de convergência de $m_{\infty,n}$ para m depende apenas do número $|\mathcal{S}|$ de variáveis fortes, não da dimensão p. Esta taxa é estritamente mais rápida que a taxa normal $n^{-2/(p+2)}$ assim que $|\mathcal{S}| \leq \lfloor 0.54p \rfloor$ ($\lfloor\cdot\rfloor$ é a função mínima). Com efeito, a dimensão intrínseca do problema de regressão é $|\mathcal{S}|$, não p, e vemos que a estimativa aleatória da floresta se adapta à estrutura esparsa. Naturalmente, isto é conseguido assumindo que o procedimento consegue selecionar as variáveis informativas para divisão, o que é de facto uma suposição forte.

Um modelo alternativo para florestas puras, denominado florestas aleatórias puramente uniformes (PURF), é discutido em Genuer (2012). Para $p = 1$, um PURF é obtido desenhando k variáveis aleatórias uniformemente em $[0, 1]$, e subseqüentemente dividindo$[0, 1]$ em subintervalos aleatórios. (Observe que, como tal, o PURF só pode ser definido para $p = 1$.). Embora esta construção não seja exatamente recursiva, é equivalente a fazer crescer uma árvore de decisão decidindo em cada nível qual nó dividir com uma probabilidade igual ao seu comprimento. Genuer (2012) prova que os PURF são consistentes e, sob uma suposição de Lipschitz, que a estimativa satisfaz

$$\mathbb{E}[m_{\infty,n}(\mathbf{X}) - m(\mathbf{X})]^2 = \mathrm{O}\left(n^{-2/3}\right).$$

Esta taxa é minimax sobre a classe de funções Lipschitz (Stone, 1980, 1982)

É frequentemente reconhecido que as florestas aleatórias reduzem o erro de estimativa de uma única árvore, mantendo o mesmo erro de aproximação. A este respeito, Biau (2012) argumenta que o erro de estimativa de florestas centradas tende a zero (na taxa lenta $1/\log n$) mesmo que cada árvore esteja totalmente crescida (ou seja, $k \approx \log n$). Este resultado é consequência do processo de cálculo da média das árvores, uma vez que o erro de estimativa de uma árvore individual totalmente crescida não tende a zero.

Unfortunately, the choice $k \approx \log n$ is too large to ensure consistency of the corresponding forest, whose approximation error remains constant. Similarly, Genuer (2012) shows that the estimation error of PURF is reduced by a factor of 0.75 compared to the estimation error of individual trees. The most recent attempt to assess the gain of forests in terms of estimation and approximation errors is by Arlot and Genuer (2014), who claim that the rate of the approximation error of certain models is faster than that of the individual trees.

3.2 Forests, neighbors and kernels

Let us consider a sequence of independent and identically distributed random variables $\mathbf{X}_1, \ldots, \mathbf{X}_n$. In random geometry, an observation $\mathbf{X}_i$ is said to be a *layered nearest neighbor* (LNN) of a point $\mathbf{x}$ (from $\mathbf{X}_1, \ldots, \mathbf{X}_n$) if the hyperrectangle defined by $\mathbf{x}$ and $\mathbf{X}_i$ contains no other data points (Barndorff-Nielsen and Sobel, 1966; Bai et al., 2005; see also Devroye et al., 1996, Chapter 11, Problem 6). As illustrated in Figure 2, the number of LNN of $\mathbf{x}$ is typically larger than one and depends on the number and configuration of the sample points.

Surprisingly, the LNN concept is intimately connected to random forests that ignore the resampling step. Indeed, if exactly one point is left in the leaves and if there is no resampling, then no matter what splitting strategy is used, the forest estimate at $\mathbf{x}$ is a weighted average of the Y_i whose corresponding $\mathbf{X}_i$ are LNN of $\mathbf{x}$. In other words,

$$m_{\infty,n}(\mathbf{x}) = \sum_{i=1}^{n} W_{ni}(\mathbf{x}) Y_i, \tag{3}$$

where the weights $(W_{n1}, \ldots, W_{nn})$ are nonnegative functions of the sample $\mathcal{D}_n$ that satisfy $W_{ni}(\mathbf{x}) = 0$ if $\mathbf{X}_i$ is not a LNN of $\mathbf{x}$ and $\sum_{i=1}^{n} W_{ni} = 1$. This important connection was first pointed out by Lin and Jeon (2006), who proved that if $\mathbf{X}$ is uniformly distributed on $[0,1]^p$ then, provided tree growing is independent of $Y_1, \ldots, Y_n$ (such simplified models are sometimes called *non-adaptive*), we have

$$\mathbb{E}\left[m_{\infty,n}(\mathbf{X}) - m(\mathbf{X})\right]^2 = \mathrm{O}\left(\frac{1}{n_{\max}(\log n)^{p-1}}\right),$$

where $n_{\max}$ is the maximal number of points in the terminal cells (Biau and Devroye, 2010, extended this inequality to the case where $\mathbf{X}$ has a density on

Infelizmente, a escolha $k \approx \log n$ é muito grande para garantir a consistência da floresta correspondente, cujo erro de aproximação permanece constante. Da mesma forma, Genuer (2012) mostra que o erro de estimativa do PURF é reduzido por um fator de 0,75 em comparação com o erro de estimativa de árvores individuais. A tentativa mais recente de avaliar o ganho das florestas em termos de erros de estimativa e aproximação é de Arlot e Genuer (2014), que afirmam que a taxa de erro de aproximação de certos modelos é mais rápida do que a das árvores individuais.

3.2 Florestas, vizinhos e núcleos

Consideremos uma sequência de variáveis aleatórias independentes e distribuídas de forma idêntica X1, . . . ,X_n. Em geometria aleatória, diz-se que uma observação X_i é um vizinho mais próximo em camadas (LNN) de um ponto x (de X1, . . . , X_n) se o hiperretângulo definido por x e X_i não contiver outros pontos de dados (Barndorff-Nielsen e Sobel, 1966; Bai et al., 2005; ver também Devroye et al., 1996, Capítulo 11, Problema 6). Conforme ilustrado na Figura 2, o número de LNN de x é normalmente maior que um e depende do número e da configuração dos pontos amostrais.

Surpreendentemente, o conceito LNN está intimamente ligado a florestas aleatórias que ignoram a etapa de reamostragem. Na verdade, se sobrar exatamente um ponto nas folhas e se não houver reamostragem, então, independentemente da estratégia de divisão usada, a estimativa da floresta em x é uma média ponderada de Y_i cujos X correspondentes$_i$ são LNN de x. Em outras palavras,

$$m_{\infty,n}(\mathbf{x}) = \sum_{i=1}^{n} W_{ni}(\mathbf{x}) Y_i, \tag{3}$$

onde os pesos $(W_{n1}, \ldots, W_{nn})$ são funções não negativas da amostra$\mathcal{D}_n$ que satisfazem W_{ni}(x) $= 0$ se X_i não for um LNN de x e $\sum_{i=1}^{n} W_{ni} = 1$. Esta i mportante conexão foi apontada pela primeira vez por Lin e Jeon (2006), que provaram que se X for uniformemente distribuído em $[0,1]^p$ então, desde que o crescimento da árvore seja independente de $Y_1, \ldots, Y_n$ (tais modelos simplificados às vezes são chamados de não adaptativos), temos

$$\mathbb{E}\left[m_{\infty,n}(\mathbf{X}) - m(\mathbf{X})\right]^2 = \mathrm{O}\left(\frac{1}{n_{\max}(\log n)^{p-1}}\right),$$

onde^{n}max é o número máximo de pontos nas células terminais (Biau e Devroye, 2010, estenderam esta desigualdade para o caso em que X tem uma densidade em

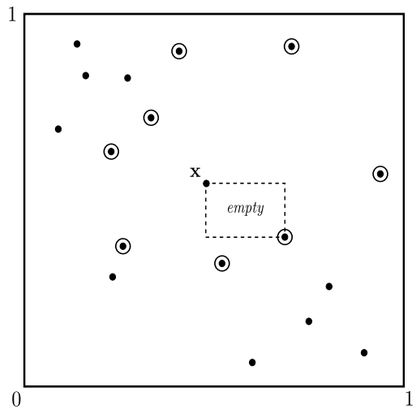


Figure 2: The layered nearest neighbors (LNN) of a point $\mathbf{x}$ in dimension $p = 2$.

$[0, 1]^p$). Unfortunately, the exact values of the weight vector $(W_{n1}, \ldots, W_{nn})$ attached to the original random forest algorithm are unknown, and a general theory of forests in the LNN framework is still undeveloped.

It remains however that equation (3) opens the way to the analysis of random forests via a local averaging approach, i.e., via the average of those Y_i for which $\mathbf{X}_i$ is "close" to $\mathbf{x}$ (Györfi et al., 2002). Indeed, observe starting from (1), that for a finite forest with M trees and without resampling, we have

$$m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M) = \frac{1}{M} \sum_{j=1}^{M} \left(\sum_{i=1}^{n} \frac{Y_i \mathbb{1}_{\mathbf{X}_i \in A_n(\mathbf{x}; \Theta_j)}}{N_n(\mathbf{x}; \Theta_j)} \right),$$

where $A_n(\mathbf{x}; \Theta_j)$ is the cell containing $\mathbf{x}$ and $N_n(\mathbf{x}; \Theta_j) = \sum_{i=1}^{n} \mathbb{1}_{\mathbf{X}_i \in A_n(\mathbf{x}; \Theta_j)}$ is the number of data points falling in $A_n(\mathbf{x}; \Theta_j)$. Thus,

$$m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M) = \sum_{i=1}^{n} W_{ni}(\mathbf{x}) Y_i,$$

where the weights $W_{ni}(\mathbf{x})$ are defined by

$$W_{ni}(\mathbf{x}) = \frac{1}{M} \sum_{j=1}^{M} \frac{\mathbb{1}_{\mathbf{X}_i \in A_n(\mathbf{x}; \Theta_j)}}{N_n(\mathbf{x}; \Theta_j)}.$$

It is easy to see that the W_{ni} are nonnegative and sum to one if the cell containing $\mathbf{x}$ is not empty. Thus, the contribution of observations falling

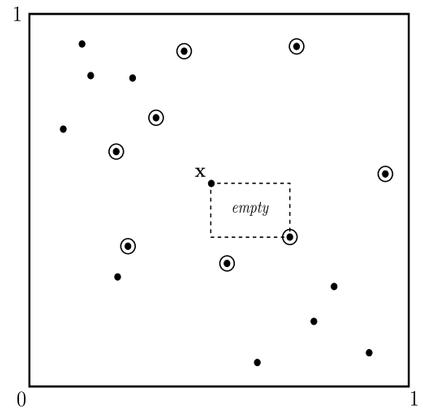


Figura 2: Os vizinhos mais próximos em camadas (LNN) de um ponto x dimensão $p = 2$.

$[0, 1]^p$). Infelizmente, os valores exatos do vetor de peso (W_{n1},..., W_{nn}) anexado ao algoritmo de floresta aleatória original são desconhecidos, e uma teoria geral de florestas na estrutura LNN ainda não foi desenvolvida.

Resta, no entanto, que a equação (3) abre caminho para a análise de florestas aleatórias através de uma abordagem de média local, ou seja, através da média daquelas Y_i para as quais X_i está "próximo" de x (Gy¨orfi et al., 2002). Na verdade, observe a partir de (1), que para uma floresta finita com M árvores e sem reamostragem, temos

$$m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M) = \frac{1}{M} \sum_{j=1}^{M} \left(\sum_{i=1}^{n} \frac{Y_i \mathbb{1}_{\mathbf{X}_i \in A_n(\mathbf{x}; \Theta_j)}}{N_n(\mathbf{x}; \Theta_j)} \right),$$

onde $A_n(x; \Theta_j)$ é a célula que contém x e $N_n(x; \Theta_j) = \sum_{i=1}^{n} \mathbb{1}_{\mathbf{X}_i \in A_n}(x; \Theta_j)$ é o número de pontos de dados que caem em $A_n(x; \Theta_j)$. Por isso,

$$m_{M,n}(\mathbf{x}; \Theta_1, \ldots, \Theta_M) = \sum_{i=1}^{n} W_{ni}(\mathbf{x}) Y_i,$$

onde os pesos $W_{ni}(x)$ são definidos por

$$W_{ni}(\mathbf{x}) = \frac{1}{M} \sum_{j=1}^{M} \frac{\mathbb{1}_{\mathbf{X}_i \in A_n(\mathbf{x}; \Theta_j)}}{N_n(\mathbf{x}; \Theta_j)}.$$

É fácil ver que W_{ni} são não negativos e somam um se a célula que contém x não estiver vazia. Assim, a contribuição das observações que caem

into cells with a high density of data points is smaller than the contribution of observations belonging to less-populated cells. This remark is especially true when the forests are built independently of the data set—for example, PURF—since, in this case, the number of examples in each cell is not controlled. Next, if we let M tend to infinity, then the estimate $m_{\infty,n}$ may be written (up to some negligible terms)

$$m_{\infty,n}(\mathbf{x}) \approx \frac{\sum_{i=1}^{n} Y_i K_n(\mathbf{X}_i, \mathbf{x})}{\sum_{j=1}^{n} K_n(\mathbf{X}_j, \mathbf{x})}, \tag{4}$$

where

$$K_n(\mathbf{x}, \mathbf{z}) = \mathbb{P}_\Theta \left[\mathbf{z} \in A_n(\mathbf{x}, \Theta) \right].$$

The function $K_n(\cdot, \cdot)$ is called the *kernel* and characterizes the shape of the "cells" of the infinite random forest. The quantity $K_n(\mathbf{x}, \mathbf{z})$ is nothing but the probability that $\mathbf{x}$ and $\mathbf{z}$ are connected (i.e., they fall in the same cell) in a random tree. Therefore, the kernel K_n can be seen as a proximity measure between two points in the forest. Hence, any forest has its own metric K_n, but unfortunately the one associated with the CART-splitting strategy is strongly data-dependent and therefore complicated to work with.

It should be noted that K_n does not necessarily belong to the family of Nadaraya-Watson-type kernels (Nadaraya, 1964; Watson, 1964), which satisfy a translation-invariant homogeneous property of the form $K_h(\mathbf{x}, \mathbf{z}) = \frac{1}{h} K((\mathbf{x} - \mathbf{z})/h)$ for some *smoothing parameter* $h > 0$. The analysis of estimates of the form (4) is, in general, more complicated, depending of the type of forest under investigation. For example, Scornet (2015b) proved that for a centered forest defined on $[0, 1]^p$ with parameter k, we have

$$K_{n,k}(\mathbf{x}, \mathbf{z}) = \sum_{\substack{k_1, \ldots, k_p \\ \sum_{j=1}^{p} k_j = k}} \frac{k!}{k_1! \ldots k_p!} \left(\frac{1}{p} \right)^k \prod_{j=1}^{p} \mathbb{1}_{\lceil 2^{k_j} x_j \rceil = \lceil 2^{k_j} z_j \rceil}.$$

As an illustration, Figure 3 shows the graphical representation for $k = 1$, 2 and 5 of the function f_k defined by

$$\begin{array}{rccl} f_k: & [0,1] \times [0,1] & \to & [0,1] \\ & \mathbf{z} = (z_1, z_2) & \mapsto & K_{n,k}\big((\frac{1}{2}, \frac{1}{2}), \mathbf{z}\big). \end{array}$$

The connection between forests and kernel estimates is mentioned in Breiman (2000a) and developed in detail in Geurts et al. (2006). The most recent advances in this direction are by Arlot and Genuer (2014), who show that a simplified forest model can be written as a kernel estimate, and provide its

em células com alta densidade de pontos de dados é menor do que a contribuição de observações pertencentes a células menos povoadas. Esta observação é especialmente verdadeira quando as florestas são construídas independentemente do conjunto de dados – por exemplo, PURF – uma vez que, neste caso, o número de exemplos em cada célula não é controlado. A seguir, se deixarmos M tender ao infinito, então a estimativa $m_{\infty,n}$ pode ser escrita (até alguns termos desprezíveis)

$$m_{\infty,n}(\mathbf{x}) \approx \frac{\sum_{i=1}^{n} Y_i K_n(\mathbf{X}_i, \mathbf{x})}{\sum_{j=1}^{n} K_n(\mathbf{X}_j, \mathbf{x})}, \tag{4}$$

onde

$$K_n(\mathbf{x}, \mathbf{z}) = \mathbb{P}_\Theta \left[\mathbf{z} \in A_n(\mathbf{x}, \Theta) \right].$$

A função $K_n(\cdot, \cdot)$ é chamada de kernel e caracteriza a forma das "células" da floresta aleatória infinita. A quantidade K_n(x, z) nada mais é do que a probabilidade de que x e z estejam conectados (ou seja, caiam na mesma célula) em uma árvore aleatória. Portanto, o kernel K_n pode ser visto como uma medida de proximidade entre dois pontos da floresta. Portanto, qualquer floresta tem sua própria métrica K_n, mas infelizmente aquela associada à estratégia de divisão CART é fortemente dependente de dados e, portanto, complicada de trabalhar.

Deve-se notar que K_n não pertence necessariamente à família de kernels do tipo Nadaraya-Watson (Nadaraya, 1964; Watson, 1964), que satisfaz uma propriedade homogênea invariante à tradução da forma K_h(x, z) $= \frac{1}{h} K$((x $-$ z)$/h$) para algum parâmetro de suavização $h > 0$. A análise das estimativas da forma (4) é, em geral, mais complicada, dependendo do tipo de floresta sob investigação. Por exemplo, Scornet (2015b) provou que para uma floresta centrada definida em $[0, 1]^p$ com o parâmetro k, temos

$$K_{n,k}(\mathbf{x}, \mathbf{z}) = \sum_{\substack{k_1, \ldots, k_p \\ \sum_{j=1}^{p} k_j = k}} \frac{k!}{k_1! \ldots k_p!} \left(\frac{1}{p} \right)^k \prod_{j=1}^{p} \mathbb{1}_{\lceil 2^{k_j} x_j \rceil = \lceil 2^{k_j} z_j \rceil}.$$

A título de ilustração, a Figura 3 mostra a representação gráfica para $k = 1$, 2 e 5 da função f_k definida por

$$\begin{array}{rccl} f_k: & [0,1] \times [0,1] & \to & [0,1] \\ & \mathbf{z} = (z_1, z_2) & \mapsto & K_{n,k}\big((\frac{1}{2}, \frac{1}{2}), \mathbf{z}\big). \end{array}$$

A ligação entre florestas e estimativas de kernel é mencionada em Breiman (2000a) e desenvolvida em detalhe em Geurts et al. (2006). Os avanços mais recentes nessa direção são de Arlot e Genuer (2014), que mostram que um modelo florestal simplificado pode ser escrito como uma estimativa de kernel, e fornece seu

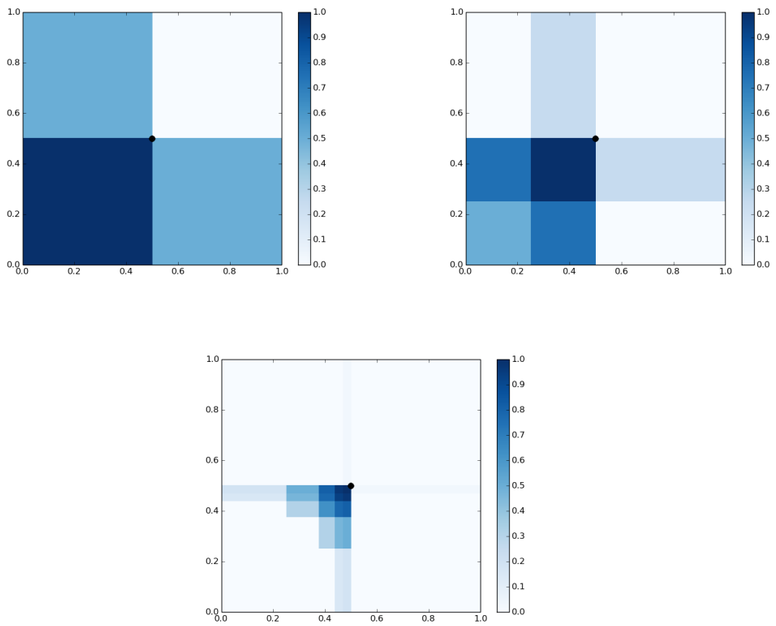


Figure 3: Representations of f_1, f_2 and f_5 in $[0,1]^2$.

rates of convergence. On the practical side, Davies and Ghahramani (2014) plug a specific (random forest-based) kernel—seen as a prior distribution over the piecewise constant functions—into a standard Gaussian process algorithm, and empirically demonstrate that it outperforms the same algorithm ran with linear and radial basis kernels. Besides, forest-based kernels can be used as the input for a large variety of existing kernel-type methods such as Kernel Principal Component Analysis and Support Vector Machines.

4 Theory for Breiman's forests

This section deals with Breiman's (2001) original algorithm. Since the construction of Breiman's forests depends on the whole sample $\mathcal{D}_n$, a mathematical analysis of the entire algorithm is difficult. To move forward, the individual mechanisms at work in the procedure have been investigated sep-

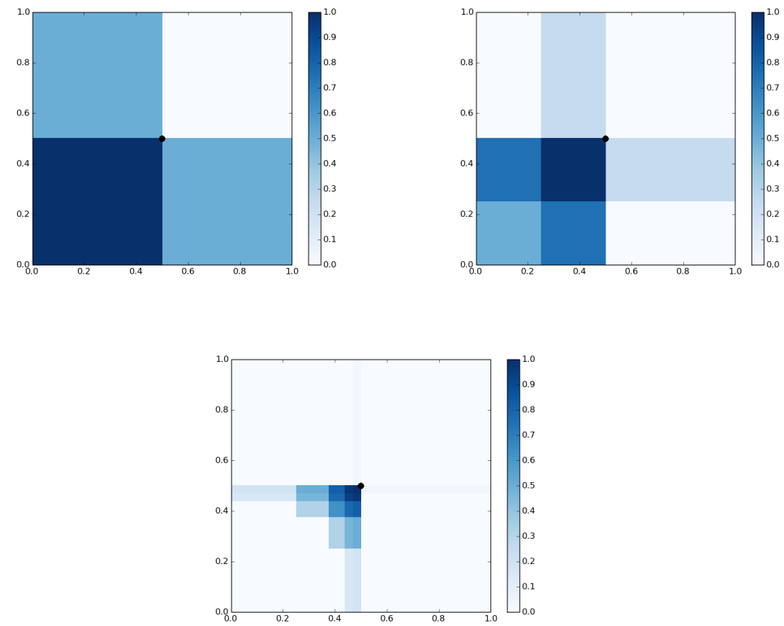


Figura 3: Representações de f_1, f_2 e f_5 em $[0,1]^2$.

taxas de convergência. Do lado prático, Davies e Ghahramani (2014) conectam um kernel específico (baseado em floresta aleatória) - visto como uma distribuição anterior sobre as funções constantes por partes - em um algoritmo de processo gaussiano padrão e demonstram empiricamente que ele supera o mesmo algorit mo executado com kernels de base linear e radial. Além disso, kernels baseados e m floresta podem ser usados como entrada para uma grande variedade de métodos existentes do tipo kernel, como Análise de Componentes Principais do Kernel e Máquinas de Vetores de Suporte.

4 Teoria para as florestas de Breiman

Esta seção trata do algoritmo original de Breiman (2001). Como a construção das florestas de Breiman depende de toda a amostra $\mathcal{D}_n$, uma análise matemática de todo o algoritmo é difícil. Para avançar, os mecanismos individuais em funcionamento no procedimento foram investigados separadamente.

arately, namely the resampling step and the splitting scheme.

4.1 The resampling mechanism

The resampling step in Breiman's (2001) original algorithm is performed by choosing n times from n points with replacement to compute the individual tree estimates. This procedure, which traces back to the work of Efron (1982) (see also Politis et al., 1999), is called the *bootstrap* in the statistical literature. The idea of generating many bootstrap samples and averaging predictors is called *bagging* (bootstrap-aggregating). It was suggested by Breiman (1996) as a simple way to improve the performance of weak or unstable learners. Although one of the great advantages of the bootstrap is its simplicity, the theory turns out to be complex. In effect, the distribution of the bootstrap sample $\mathcal{D}_n^\star$ is different from that of the original one $\mathcal{D}_n$, as the following example shows. Assume that $\mathbf{X}$ has a density, and note that whenever the data points are sampled with replacement then, with positive probability, at least one observation from the original sample is selected more than once. Therefore, with positive probability, there exist two identical data points in $\mathcal{D}_n^\star$, and the distribution of $\mathcal{D}_n^\star$ cannot be absolutely continuous.

The role of the bootstrap in random forests is still poorly understood and, to date, most analyses are doomed to replace the bootstrap by a subsampling scheme, assuming that each tree is grown with $a_n < n$ examples randomly chosen without replacement from the initial sample (Mentch and Hooker, 2015; Wager, 2014; Scornet et al., 2015). Most of the time, the subsampling rate a_n/n is assumed to tend to zero at some prescribed rate—an assumption that excludes de facto the bootstrap regime. In this respect, the analysis of so-called *median random forests* by Scornet (2015a) provides some insight as to the role and importance of subsampling.

A median forest resembles a centered forest. Once the splitting direction is chosen, the cut is performed at the empirical median of the $\mathbf{X}_i$ in the cell. In addition, the construction does not stop at level k but continues until each cell contains exactly one observation. Since the number of cases left in the leaves does not grow with n, each tree of a median forest is in general inconsistent (see Györfi et al., 2002, Problem 4.3). However, Scornet (2015a) shows that if $a_n/n \to 0$, then the median forest is consistent, despite the fact that the individual trees are not. The assumption $a_n/n \to 0$ guarantees that every single observation pair $(\mathbf{X}_i, Y_i)$ is used in the j-th tree's construction with a probability that becomes small as n grows. It also forces the query point $\mathbf{x}$ to be disconnected from $(\mathbf{X}_i, Y_i)$ in a large proportion of trees. Indeed, if this

separadamente, nomeadamente a etapa de reamostragem e o esquema de divisão.

4.1 O mecanismo de reamostragem

A etapa de reamostragem no algoritmo original de Breiman (2001) é realizada escolhendo n tempos de n pontos com substituição para calcular as estimativas individuais da árvore. Este procedimento, que remonta ao trabalho de Efron (1982) (ver também Politis et al., 1999), é denominado bootstrap na literatura estatística. A ideia de gerar muitas amostras de bootstrap e calcular a média dos preditores é chamada de empacotamento (agregação de bootstrap). Foi sugerido por Breiman (1996) como uma forma simples de melhorar o desempenho de alunos fracos ou instáveis. Embora uma das grandes vantagens do bootstrap seja a sua si mplicidade, a teoria acaba por ser complexa. Na verdade, a distribuição da a mostra de bootstrap $\mathcal{D}_n^\star$ é diferente daquela da amostra original $\mathcal{D}_n$, como mostra o exemplo a seguir. Suponha que X tenha densidade e observe que sempre que os pontos de dados são amostrados com substituição, então, com probabilidade positiva, pelo menos uma observação da amostra original é selecionada mais de uma vez. Portanto, com probabilidade positiva, existem dois pontos de dados idênticos em$\mathcal{D}_n^\star$, e a distribuição de $\mathcal{D}_n^\star$ não pode ser absolutamente contínua.

O papel do bootstrap em florestas aleatórias ainda é pouco compreendido e, até o momento, a maioria das análises está fadada a substituir o bootstrap por um esquema de subamostragem, assumindo que cada árvore é cultivada com $a_n < n$ exemplos escolhidos aleatoriamente sem substituição da amostra inicial (Mentch e Hooker, 2015; Wager, 2014; Scornet et al., 2015). Na maioria das vezes, presume-se que a taxa de subamostragem a_n/n tende a zero em alguma taxa prescrita - uma suposição que exclui de fato o regime bootstrap. A este respeito, a análise das chamadas florestas aleatórias medianas feita por Scornet (2015a) fornece algumas informações sobre o papel e a importância da subamostragem.

Uma floresta mediana se assemelha a uma floresta centralizada. Uma vez escolhida a direção de divisão, o corte é realizado na mediana empírica do X_i na célula. Além disso, a construção não para no nível k, mas continua até que cada célula contenha exatamente uma observação. Como o número de casos restantes nas folhas não cresce com n, cada árvore de uma floresta mediana é em geral inconsistente (ver Gy¨orfi et al., 2002, Problema 4.3). No entanto, Scornet (2015a) mostra que se $a_n/n \to 0$, então a floresta mediana é consistente, apesar do facto de as árvores individuais não o serem. A suposição $a_n/n \to 0$ garante que cada par de observação (X_i, Y_i) seja usado na construção da j-ésima árvore com uma probabilidade que se torna pequena à medida que n cresce. Também força o ponto de consulta x a ser desconectado de (X_i, Y_i) em uma grande proporção de árvores. Na verdade, se isso

were not the case, then the predicted value at $\mathbf{x}$ would be overly influenced by the single pair $(\mathbf{X}_i, Y_i)$, which would make the ensemble inconsistent. In fact, the estimation error of the median forest estimate is small as soon as the maximum probability of connection between the query point and all observations is small. Thus, the assumption $a_n/n \to 0$ is but a convenient way to control these probabilities, by ensuring that partitions are dissimilar enough.

Biau and Devroye (2010) noticed that Breiman's bagging principle has a simple application in the context of nearest neighbor methods. Recall that the 1-nearest neighbor (1-NN) regression estimate sets $r_n(\mathbf{x}) = Y_{(1)}(\mathbf{x})$, where $Y_{(1)}(\mathbf{x})$ corresponds to the feature vector $\mathbf{X}_{(1)}(\mathbf{x})$ whose Euclidean distance to $\mathbf{x}$ is minimal among all $\mathbf{X}_1, \ldots, \mathbf{X}_n$. (Ties are broken in favor of smallest indices.) It is clearly not, in general, a consistent estimate (Devroye et al., 1996, Chapter 5). However, by subbagging, one may turn the 1-NN estimate into a consistent one, provided that the size of subsamples is sufficiently small. We proceed as follows, via a randomized basic regression estimate r_{a_n} in which $1 \leq a_n < n$ is a parameter. The elementary predictor r_{a_n} is the 1-NN rule for a random subsample of size a_n drawn with (or without) replacement from $\mathcal{D}_n$. We apply subbagging, that is, we repeat the random subsampling an infinite number of times and take the average of the individual outcomes. Thus, the subbagged regression estimate $r_n^\star$ is defined by

$$r_n^\star(\mathbf{x}) = \mathbb{E}^\star \left[r_{a_n}(\mathbf{x}) \right],$$

where $\mathbb{E}^\star$ denotes expectation with respect to the resampling distribution, conditional on the data set $\mathcal{D}_n$. Biau and Devroye (2010) proved that the estimate $r_n^\star$ is universally (i.e., without conditions on the distribution of $(\mathbf{X}, Y)$) mean squared consistent, provided $a_n \to \infty$ and $a_n/n \to 0$. The proof relies on the observation that $r_n^\star$ is in fact a local averaging estimate (Stone, 1977) with weights

$$W_{ni}(\mathbf{x}) = \mathbb{P}[\mathbf{X}_i \text{ is the 1-NN of } \mathbf{x} \text{ in a random selection of size } a_n].$$

The connection between bagging and nearest neighbor estimation is further explored by Biau et al. (2010), who prove that the subbagged estimate $r_n^\star$ achieves optimal rate of convergence over Lipschitz smoothness classes, independently from the fact that resampling is done with or without replacement.

4.2 Decision splits

The coordinate-split process of the random forest algorithm is not easy to grasp, essentially because it uses both the $\mathbf{X}_i$ and Y_i variables to make its

não fosse o caso, então o valor previsto em x seria excessivamente influenciado pelo par único (X$_i$, Y_i), o que tornaria o conjunto inconsistente. Na verdade, o erro de estimação da estimativa florestal mediana é pequeno assim que a probabilidade máxima de conexão entre o ponto de consulta e todas as observações é pequena. Assim, a suposição $a_n/n \to 0$ é apenas uma maneira conveniente de controlar essas probabilidades, garantindo que as partições sejam suficientemente diferentes.

Biau e Devroye (2010) notaram que o princípio do ensacamento de Breiman tem uma aplicação simples no contexto de métodos do vizinho mais próximo. Lembre-se de que a estimativa de regressão do vizinho mais próximo (1-NN) define r_n (x) $= Y_{(1)}$(x), onde$Y_{(1)}$(x) corresponde ao vetor de características X$^{(1)}$(x) cuja distância euclidiana a x é mínima entre todos os X1, . . . ,X$_n$. (Os empates são quebrados a favor dos índices mais pequenos.) Claramente não é, em geral, uma estimativa consistente (Devroye et al., 1996, Capítulo 5). No entanto, por sub-ensaque, pode-se transformar a estimativa de 1-NN em uma estimativa consistente, desde que o tamanho das subamostras seja suficientemente pequeno. Procedemos da seguinte forma, através de uma estimativa de regressão básica aleatória r_{a_n} na qual $1 \leq a_n < n$ é um parâmetro. O preditor elementar r_{a_n} é a regra 1-NN para uma subamostra aleatória de tamanho a_n extraída com (ou sem) substituição de $\mathcal{D}_n$. Aplicamos subbagging, ou seja, repetimos a subamostragem aleatória um número infinito de vezes e calculamos a média dos resultados individuais. Assim, a estimativa de regressão subensacada $r_n^\star$ é definida por

$$r_n^\star(\mathbf{x}) = \mathbb{E}^\star \left[r_{a_n}(\mathbf{x}) \right],$$

onde $\mathbb{E}^\star$ denota a expectativa em relação à distribuição de reamostragem, condicional ao conjunto de dados $\mathcal{D}_n$. Biau e Devroye (2010) provaram que a estimativa $r_n^\star$ é universalmente (ou seja, sem condições na distribuição de (X Y)) média quadrática consistente, desde $a_n \to \infty$ e $a_n/n \to 0$. A prova baseia-se na observação de que $r_n^\star$ é na verdade uma estimativa de média local (Stone, 1977) com pesos

$$W_{ni}(\mathbf{x}) = \mathbb{P}[\mathbf{X}_i \text{ is the 1-NN of } \mathbf{x} \text{ in a random selection of size } a_n].$$

A conexão entre o ensacamento e a estimativa do vizinho mais próximo é explorada posteriormente por Biau et al. (2010), que comprovam que a estimativa subbagageada $r_n^\star$ atinge taxa ótima de convergência sobre as classes de suavidade de Lipschitz, independentemente do fato de a reamostragem ser feita com ou sem substituição.

4.2 Divisões de decisão

O processo de divisão de coordenadas do algoritmo de floresta aleatória não é fácil de entender, essencialmente porque ele usa as variáveis X$_i$ e Y_i para fazer seu

decision. Building upon the ideas of Bühlmann and Yu (2002), Banerjee and McKeague (2007) establish a limit law for the split location in the context of a regression model of the form $Y = m(\mathbf{X}) + \varepsilon$, where $\mathbf{X}$ is real-valued and ε an independent Gaussian noise. In essence, their result is as follows. Assume for now that the distribution of $(\mathbf{X}, Y)$ is known, and denote by $d^\star$ the (optimal) split that maximizes the theoretical CART-criterion at a given node. In this framework, the regression estimate restricted to the left (resp., right) child of the cell takes the form

$$\beta^\star_{\ell,n} = \mathbb{E}[Y|X \leq d^\star] \quad \Big(\text{resp., } \beta^\star_{r,n} = \mathbb{E}[Y|X > d^\star]\Big).$$

When the distribution of $(\mathbf{X}, Y)$ is unknown, so are $\beta^\star_\ell$, $\beta^\star_r$ and $d^\star$, and these quantities are estimated by their natural empirical counterparts:

$$(\hat{\beta}_{\ell,n}, \hat{\beta}_{r,n}, \hat{d}_n) \in \operatorname*{arg\,min}_{\beta_\ell, \beta_r, d} \sum_{i=1}^{n} \left[Y_i - \beta_\ell \mathbb{1}_{X_i \leq d} - \beta_r \mathbb{1}_{X_i > d}\right]^2.$$

Assuming that the model satisfies some regularity assumptions (in particular, $\mathbf{X}$ has a density f, and both f and m are continuously differentiable), Banerjee and McKeague (2007) prove that

$$n^{1/3} \begin{pmatrix} \hat{\beta}_{\ell,n} - \beta^\star_\ell \\ \hat{\beta}_{r,n} - \beta^\star_r \\ \hat{d}_n - d^\star \end{pmatrix} \xrightarrow{\mathcal{D}} \begin{pmatrix} c_1 \\ c_2 \\ 1 \end{pmatrix} \operatorname*{arg\,max}_t (aW(t) - bt^2), \tag{5}$$

where $\mathcal{D}$ denotes convergence in distribution, and W is a standard two-sided Brownian motion process on the real line. Both a and b are positive constants that depend upon the model parameters and the unknown quantities $\beta^\star_\ell$, $\beta^\star_r$ and $d^\star$. The limiting distribution in (5) allows one to construct confidence intervals for the position of CART-splits. Interestingly, Banerjee and McKeague (2007) refer to the study of Qian et al. (2003) on the effects of phosphorus pollution in the Everglades, which uses split points in a novel way. There, the authors identify threshold levels of phosphorus concentration that are associated with declines in the abundance of certain species. In their approach, split points are not just a means to build trees and forests, but can also provide important information on the structure of the underlying distribution.

A further analysis of the behavior of forest splits is performed by Ishwaran (2013), who argues that the so-called *End-Cut Preference* (ECP) of the CART-splitting procedure (that is, the fact that splits along non-informative

decisão. Com base nas ideias de B¨uhlmann e Yu (2002), Banerjee e McKeague (2007) estabelecem uma lei limite para a localização dividida no contexto de um modelo de regressão da forma $Y = m$(X) $+ \varepsilon$, onde X é de valor real e ε um ruído gaussiano independente. Em essência, o resultado é o seguinte. Suponha por enquanto que a distribuição de (X Y) é conhecida e denote por $d^\star$a divisão (ótima) que maximiza o critério CART teórico em um determinado nó. Nesta estrutura, a estimativa de regressão restrita ao filho esquerdo (ou direito) da célula assume a forma

$$\beta^\star_{\ell,n} = \mathbb{E}[Y|X \leq d^\star] \quad \Big(\text{resp., } \beta^\star_{r,n} = \mathbb{E}[Y|X > d^\star]\Big).$$

Quando a distribuição de (X Y) é desconhecida, $\beta^\star_\ell$, $\beta^\star_r$e $d^\star$ também o são, e essas quantidades são estimadas por suas contrapartes empíricas naturais:

$$(\hat{\beta}_{\ell,n}, \hat{\beta}_{r,n}, \hat{d}_n) \in \operatorname*{arg\,min}_{\beta_\ell, \beta_r, d} \sum_{i=1}^{n} \left[Y_i - \beta_\ell \mathbb{1}_{X_i \leq d} - \beta_r \mathbb{1}_{X_i > d}\right]^2.$$

Assumindo que o modelo satisfaz algumas suposições de regularidade (em particular, X tem uma densidade f, e ambos f e m são continuamente diferenciáveis), Banerjee e McKeague (2007) provam que

$$n^{1/3} \begin{pmatrix} \hat{\beta}_{\ell,n} - \beta^\star_\ell \\ \hat{\beta}_{r,n} - \beta^\star_r \\ \hat{d}_n - d^\star \end{pmatrix} \xrightarrow{\mathcal{D}} \begin{pmatrix} c_1 \\ c_2 \\ 1 \end{pmatrix} \operatorname*{arg\,max}_t (aW(t) - bt^2), \tag{5}$$

onde $\mathcal{D}$ denota convergência na distribuição e W é um processo de movimento browniano bilateral padrão na linha real. Tanto a quanto b são constantes positivas que dependem dos parâmetros do modelo e das quantidades desconhecidas$\beta^\star_\ell$, $\beta^\star_r$ e $d^\star$. A distribuição limitante em (5) permite construir intervalos de confiança para a posição das divisões CART. Curiosamente, Banerjee e McKeague (2007) referem-se ao estudo de Qian et al. (2003) sobre os efeitos da poluição por fósforo nos Everglades, que utiliza pontos de divisão de uma forma inovadora. Lá, os autores identificam níveis limiares de concentração de fósforo que estão associados a declínios na abundância de certas espécies. Na sua abordagem, os pontos de divisão não são apenas um meio para construir árvores e florestas, mas também podem fornecer informações importantes sobre a estrutura da distribuição subjacente.

Uma análise mais aprofundada do comportamento das divisões florestais é realizada por Ishwaran (2013), que argumenta que a chamada Preferência End-Cut (ECP) do procedimento de divisão CART (ou seja, o fato de que se divide ao longo de divisões não informativas

variables are likely to be near the edges of the cell—see Breiman et al., 1984) can be seen as a desirable property. Given the randomization mechanism at work in forests, there is indeed a positive probability that none of the preselected variables at a node are informative. When this happens, and if the cut is performed, say, at the center of a side of the cell (assuming that $\mathcal{X} = [0,1]^d$), then the sample size of the two resulting cells is drastically reduced by a factor of two—this is an undesirable property, which may be harmful for the prediction task. Thus, Ishwaran (2013) stresses that the ECP property ensures that a split along a noisy variable is performed near the edge, thus maximizing the tree node sample size and making it possible for the tree to recover from the split downstream. Ishwaran (2013) claims that this property can be of benefit even when considering a split on an informative variable, if the corresponding region of space contains little signal.

It is shown in Scornet et al. (2015) that random forests asymptotically perform, with high probability, splits along the S informative variables (in the sense of Section 3.1). Denote by $j_{n,1}(\mathbf{X}), \ldots, j_{n,k}(\mathbf{X})$ the first k cut directions used to construct the cell of $\mathbf{X}$, with the convention that $j_{n,q}(\mathbf{X}) = \infty$ if the cell has been cut strictly less than q times. Assuming some regularity conditions on the regression model, and considering a modification of Breiman's forests in which all directions are preselected for splitting, Scornet et al. (2015) prove that, with probability $1-\xi$, for all n large enough and all $1 \leq q \leq k$,

$$j_{n,q}(\mathbf{X}) \in \{1, \ldots, S\}.$$

This result offers an interesting perspective on why random forests nicely adapt to the sparsity setting. Indeed, it shows that the algorithm selects splits mostly along the S informative variables, so that everything happens as if data were projected onto the vector space spanned by these variables.

There exists a variety of random forest variants based on the CART-criterion. For example, the *Extra-Tree* algorithm of Geurts et al. (2006) consists in randomly selecting a set of split points and then choosing the split that maximizes the CART-criterion. This algorithm has similar accuracy performance while being more computationally efficient. In the *PERT* (Perfect Ensemble Random Trees) approach of Cutler and Zhao (2001), one builds perfect-fit classification trees with random split selection. While individual trees clearly overfit, the authors claim that the whole procedure is eventually consistent since all classifiers are believed to be almost uncorrelated. As a variant of the original algorithm, Breiman (2001) considered splitting along linear combinations of features (this procedure has been implemented by Truong, 2009,

as variáveis provavelmente estarão próximas das bordas da célula (ver Breiman et al., 1984) pode ser vista como uma propriedade desejável. Dado o mecanismo de randomização em funcionamento nas florestas, existe de fato uma probabilidade positiva de que nenhuma das variáveis pré-selecionadas em um nó seja i nformativa. Quando isso acontece, e se o corte for realizado, digamos, no centro de um lado da célula (assumindo que $\mathcal{X} = [0,1]^d$), então o tamanho da amostra das duas células resultantes é drasticamente reduzido por um fator de dois – esta é u ma propriedade indesejável, que pode ser prejudicial para a tarefa de previsão. Assim, Ishwaran (2013) enfatiza que a propriedade ECP garante que uma divisão ao longo de uma variável ruidosa seja realizada perto da borda, maximizando assim o tamanho da amostra do nó da árvore e possibilitando que a árvore se recupere da divisão a jusante. Ishwaran (2013) afirma que esta propriedade pode ser benéfica mesmo quando se considera uma divisão numa variável informativa, se a região correspondente do espaço contiver pouco sinal.

É mostrado em Scornet et al. (2015) que florestas aleatórias realizam assintoticamente, com alta probabilidade, divisões ao longo das S variáveis informativas (no sentido da Seção 3.1). Denote por j_n,1(X) . . . , j_n,k(X) as primeiras k direções de corte usadas para construir a célula de X, com a convenção de que j_n,q(X) $= \infty$se a célula tiver sido cortada estritamente menos de q vezes. Assumindo algumas condições de regularidade no modelo de regressão, e considerando uma modificação das florestas de Breiman em que todas as direções são pré-selecionadas para divisão, Scornet et al. (2015) provam que, com probabilidade $1-\xi$, para todo n grande o suficiente e todos$1 \leq q \leq k$,

$$j_{n,q}(\mathbf{X}) \in \{1, \ldots, S\}.$$

Este resultado oferece uma perspectiva interessante sobre por que as florestas aleatórias se adaptam bem ao cenário de escassez. Na verdade, isso mostra que o algoritmo seleciona divisões principalmente ao longo das S variáveis informativas, de modo que tudo acontece como se os dados fossem projetados no espaço vetorial abrangido por essas variáveis.

Existe uma variedade de variantes florestais aleatórias com base no critério CART. Por exemplo, o algoritmo Extra-Tree de Geurts et al. (2006) consiste em selecionar aleatoriamente um conjunto de pontos de divisão e depois escolher a divisão que maximiza o critério CART. Este algoritmo tem desempenho de precisão se melhante, ao mesmo tempo que é mais eficiente computacionalmente. Na abordagem PERT (Perfect Ensemble Random Trees) de Cutler e Zhao (2001), constroem-se árvores de classificação de ajuste perfeito com seleção aleatória por divisão. Embora as árvores individuais claramente se ajustem demais, os autores afirmam que todo o procedimento é eventualmente consistente, uma vez que se acredita que todos os classificadores sejam quase não correlacionados. Como uma variante do algoritmo original, Breiman (2001) considerou a divisão ao longo de combinações lineares de características (este procedimento foi implementado por Truong, 2009,

in the package `obliquetree` of the statistical computing environment `R`). As noticed by Menze et al. (2011), the feature space separation by orthogonal hyperplanes in random forests results in box-like decision surfaces, which may be advantageous for some data but suboptimal for other, particularly for collinear data with correlated features .

With respect to the tree building process, selecting uniformly at each cell a set of features for splitting is simple and convenient, but such procedures inevitably select irrelevant variables. Therefore, several authors have proposed modified versions of the algorithm that incorporate a data-driven weighing of variables. For example, Kyrillidis and Zouzias (2014) study the effectiveness of non-uniform randomized feature selection in classification tree, and experimentally show that such an approach may be more effective compared to naive uniform feature selection. *Enriched Random Forests*, designed by Amaratunga et al. (2008) choose at each node the eligible subsets by weighted random sampling with the weights tilted in favor of informative features. Similarly, the *Reinforcement Learning Trees* (RLT) of Zhu et al. (2015) build at each node a random forest to determine the variable that brings the greatest future improvement in later splits, rather than choosing the one with largest marginal effect from the immediate split. Splits in random forests are known to be biased toward covariates with many possible splits (Breiman et al., 1984; Segal, 1988) or with missing values (Kim and Loh, 2001). Hothorn et al. (2006) propose a two-step procedure to correct this situation by first selecting the splitting variable and then the position of the cut along the chosen variable. The predictive performance of the resulting trees is empirically shown to be as good as the performance of the exhaustive search procedure. We also refer the reader to Ziegler and König (2014), who review the different splitting strategies.

Choosing weights can also be done via regularization. Deng and Runger (2012) propose a *Regularized Random Forest* (RRF), which penalizes selecting a new feature for splitting when its gain is similar to the features used in previous splits. Deng and Runger (2013) suggest a *Guided RRF* (GRRF), in which the importance scores from an ordinary random forest are used to guide the feature selection process in RRF. Lastly, a Garrote-style convex penalty, proposed by Meinshausen (2009), selects functional groups of nodes in trees, yielding to parcimonious estimates. We also mention the work of Konukoglu and Ganz (2014) who address the problem of controlling the false positive rate of random forests and present a principled way to determine thresholds for the selection of relevant features without any additional computational load.

no pacote `obliquetree` do ambiente de computação estatística `R`). Como observado por Menze et al. (2011), a separação do espaço de características por hiperplanos ortogonais em florestas aleatórias resulta em superfícies de decisão semelhantes a caixas, o que pode ser vantajoso para alguns dados, mas subótimo para outros, particularmente para dados colineares com características correlacionadas.

Com relação ao processo de construção da árvore, selecionar uniformemente em cada célula um conjunto de características para divisão é simples e conveniente, mas tais procedimentos inevitavelmente selecionam variáveis irrelevantes. Portanto, vários autores propuseram versões modificadas do algoritmo que incorporam uma ponderação de variáveis baseada em dados. Por exemplo, Kyrillidis e Zouzias (2014) estudam a eficácia da seleção de características aleatórias não uniformes na árvore de classificação e mostram experimentalmente que tal abordagem pode ser mais eficaz em comparação com a seleção ingênua de características uniformes. Florestas Aleatórias Enriquecidas, projetadas por Amaratunga et al. (2008) escolhem em cada nó os subconjuntos elegíveis por amostragem aleatória ponderada com os pesos inclinados em favor de características informativas. Da mesma forma, as Árvores de Aprendizagem por Reforço (RLT) de Zhu et al. (2015) constroem em cada nó uma floresta aleatória para determinar a variável que traz a maior melhoria futura nas divisões posteriores, em vez de escolher aquela com maior efeito marginal da divisão imediata. Sabe-se que as divisões em florestas aleatórias são tendenciosas para covariáveis com muitas divisões possíveis (Breiman et al., 1984; Segal, 1988) ou co m valores faltantes (Kim e Loh, 2001). Hothorn et al. (2006) propõem um procedimento em duas etapas para corrigir esta situação, selecionando primeiro a variável de divisão e depois a posição do corte ao longo da variável escolhida. O desempenho preditivo das árvores resultantes é empiricamente demonstrado ser tão bom quanto o desempenho do procedimento de busca exaustiva. Também remetemos o leitor para Ziegler e K¨onig (2014), que revisam as diferentes estratégias de divisão.

A escolha dos pesos também pode ser feita via regularização. Deng e Runger (2012) propõem uma Floresta Aleatória Regularizada (RRF), que penaliza a seleção de um novo recurso para divisão quando seu ganho é semelhante aos recursos usados em divisões anteriores. Deng e Runger (2013) sugerem um RRF Guiado (GRRF), no qual as pontuações de importância de uma floresta aleatória comum são usadas para orientar o processo de seleção de características no RRF. Por último, uma penalidade convexa do tipo Garrote, proposta por Meinshausen (2009), seleciona grupos funcionais de nós em árvores, rendendo estimativas parcimoniosas. Mencionamos também o trabalho de Konukoglu e Ganz (2014) que abordam o problema de controlar a taxa de falsos positivos de florestas aleatórias e apresentam uma forma baseada em princípios para determinar limites para a seleção de características relevantes sem qualquer carga computacional adicional.

4.3 Consistency, asymptotic normality, and more

All in all, little has been proven mathematically for the original procedure of Breiman. A seminal result by Breiman (2001) shows that the error of the forest is small as soon as the predictive power of each tree is good and the correlation between the tree errors is low. More precisely, independently of the type of forest, one has

$$\mathbb{E}_{\mathbf{X},Y}[Y - m_{\infty,n}(\mathbf{X})]^2 \leq \bar{\rho}\, \mathbb{E}_{\Theta,\mathbf{X},Y}[Y - m_n(\mathbf{X};\Theta)]^2,$$

where

$$\bar{\rho} = \frac{\mathbb{E}_{\Theta,\Theta'}[\rho(\Theta,\Theta')g(\Theta)g(\Theta')]}{\mathbb{E}_{\Theta}[g(\Theta)]^2},$$

with Θ and Θ' independent and identically distributed,

$$\rho(\Theta,\Theta') = \mathrm{Corr}_{\mathbf{X},Y}\big[Y - m_n(\mathbf{X};\Theta), Y - m_n(\mathbf{X};\Theta')\big],$$

and $g(\Theta) = \sqrt{\mathbb{E}_{\mathbf{X},Y}[Y - m_n(\mathbf{X};\Theta)]^2}$. Similarly, Friedman et al. (2009) decompose the variance of the forest as a product of the correlation between trees and the variance of a single tree. Thus, for all $\mathbf{x}$,

$$\mathrm{Var}[m_{\infty,n}(\mathbf{x})] = \rho(\mathbf{x})\sigma(\mathbf{x}),$$

where $\rho(\mathbf{x}) = \mathrm{Corr}[m_n(\mathbf{x};\Theta), m_n(\mathbf{x};\Theta')]$ and $\sigma(\mathbf{x}) = \mathrm{Var}[m_n(\mathbf{x};\Theta)]$.

A link between the error of the finite and infinite forests is established in Scornet (2015a), who shows, provided some regularity assumptions are satisfied, that

$$\begin{aligned} 0 &\leq \mathbb{E}[m_{M,n}(\mathbf{X};\Theta_1,\ldots,\Theta_M) - m(\mathbf{X})]^2 - \mathbb{E}[m_{\infty,n}(\mathbf{X}) - m(\mathbf{X})]^2 \\ &\leq \frac{8}{M} \times \big(\|m\|_\infty^2 + \sigma^2(1 + 4\log n)\big). \end{aligned}$$

This inequality provides an interesting solution for choosing the number of trees, by making the error of the finite forest arbitrary close to that of the infinite one.

Consistency and asymptotic normality of the whole algorithm were recently proved, replacing bootstrap by subsampling and simplifying the splitting step. So, Wager (2014) shows the asymptotic normality of Breiman's infinite forests, assuming that (i) cuts are spread along all the p directions and do not separate a small fraction of the data set; and (ii) two different data set

4.3 Consistência, normalidade assintótica e muito mais

Em suma, pouco foi provado matematicamente para o procedimento original de Breiman. Um resultado seminal de Breiman (2001) mostra que o erro da floresta é pequeno desde que o poder preditivo de cada árvore seja bom e a correlação entre os erros das árvores seja baixa. Mais precisamente, independentemente do tipo de floresta, tem-se

$$\mathbb{E}_{\mathbf{X},Y}[Y - m_{\infty,n}(\mathbf{X})]^2 \leq \bar{\rho}\, \mathbb{E}_{\Theta,\mathbf{X},Y}[Y - m_n(\mathbf{X};\Theta)]^2,$$

onde

$$\bar{\rho} = \frac{\mathbb{E}_{\Theta,\Theta'}[\rho(\Theta,\Theta')g(\Theta)g(\Theta')]}{\mathbb{E}_{\Theta}[g(\Theta)]^2},$$

com Θ e Θ' independentes e distribuídos de forma idêntica,

$$\rho(\Theta,\Theta') = \mathrm{Corr}_{\mathbf{X},Y}\big[Y - m_n(\mathbf{X};\Theta), Y - m_n(\mathbf{X};\Theta')\big],$$

e $g(\Theta) = \sqrt{\mathrm{Ex},_Y[Y - m_n(\mathrm{X};\Theta)]^2}$. Da mesma forma, Friedman et al. (2009) decompõem a variância da floresta como produto da correlação entre árvores e a variância de uma única árvore. Assim, para todo x,

$$\mathrm{Var}[m_{\infty,n}(\mathbf{x})] = \rho(\mathbf{x})\sigma(\mathbf{x}),$$

onde $\rho(\mathrm{x}) = \mathrm{Corr}[m_n(\mathrm{x};\Theta)\ m_n(\mathrm{x};\Theta')]$ e $\sigma(\mathrm{x}) = \mathrm{Var}[m_n(\mathrm{x};\Theta)]$.

Uma ligação entre o erro das florestas finitas e infinitas é estabelecida em Scornet (2015a), que mostra, desde que algumas suposições de regularidade sejam satisfeitas, que

$$\begin{aligned} 0 &\leq \mathbb{E}[m_{M,n}(\mathbf{X};\Theta_1,\ldots,\Theta_M) - m(\mathbf{X})]^2 - \mathbb{E}[m_{\infty,n}(\mathbf{X}) - m(\mathbf{X})]^2 \\ &\leq \frac{8}{M} \times \big(\|m\|_\infty^2 + \sigma^2(1 + 4\log n)\big). \end{aligned}$$

Esta desigualdade fornece uma solução interessante para a escolha do número de árvores, ao tornar arbitrário o erro da floresta finita próximo ao da floresta i nfinita.

A consistência e a normalidade assintótica de todo o algoritmo foram recente mente comprovadas, substituindo o bootstrap pela subamostragem e si mplificando a etapa de divisão. Assim, Wager (2014) mostra a normalidade assintótica das florestas infinitas de Breiman, assumindo que (i) os cortes estão espalhados ao longo de todas as direções p e não separam uma pequena fração do conjunto de dados; e (ii) dois conjuntos de dados diferentes

are used to respectively build the tree and estimate the value within a leaf. He also establishes that the infinitesimal jackknife (Efron, 1979) consistently estimates the forest variance.

Mentch and Hooker (2015) prove a similar result for finite forests, which mainly relies on the assumption that the prediction of the forests does not much vary when the label of one point in the training set is slightly modified. These authors show that whenever M_n (the number of trees) is allowed to vary with n, and when $a_n = \mathrm{o}(\sqrt{n})$ and $\lim_{n\to\infty} n/M_n = 0$, then, for a fixed $\mathbf{x}$,

$$\frac{\sqrt{n}(m_{M,n}(\mathbf{x};\Theta_1,\ldots,\Theta_M) - \mathbb{E}[m_{\infty,n}(\mathbf{x})])}{\sqrt{a_n^2\zeta_{1,a_n}}} \xrightarrow{\mathcal{D}} N,$$

where N is a standard normal random variable,

$$\zeta_{1,a_n} = \mathrm{Cov}\left[m_n(\mathbf{X}_1,\mathbf{X}_2,\ldots,\mathbf{X}_{a_n};\Theta), m_n(\mathbf{X}_1,\mathbf{X}_2',\ldots,\mathbf{X}_{a_n}';\Theta')\right],$$

$\mathbf{X}_i'$ an independent copy of $\mathbf{X}_i$ and Θ' an independent copy of Θ. It is worth noting that both Mentch and Hooker (2015) and Wager et al. (2014) provide corrections for estimating the forest variance ζ_{1,a_n}.

Scornet et al. (2015) proved a consistency result in the context of additive regression models for the pruned version of Breiman's forest. Unfortunately, the consistency of the unpruned procedure comes at the price of a conjecture regarding the behavior of the CART algorithm that is difficult to verify.

We close this section with a negative but interesting result due to Biau et al. (2008). In this example, the total number k of cuts is fixed and $\texttt{mtry} = 1$. Furthermore, each tree is built by minimizing the true probability of error at each node. Consider the joint distribution of $(\mathbf{X}, Y)$ sketched in Figure 4 and let $m(\mathbf{x}) = \mathbb{E}[Y|\mathbf{X} = \mathbf{x}]$. The variable $\mathbf{X}$ has a uniform distribution on $[0,1]^2 \cup [1,2]^2 \cup [2,3]^2$ and Y is a function of $\mathbf{X}$—that is, $m(\mathbf{x}) \in \{0,1\}$ and $L^\star = 0$—defined as follows. The lower left square $[0,1]\times[0,1]$ is divided into countably infinitely many vertical strips in which the strips with $m(\mathbf{x}) = 0$ and $m(\mathbf{x}) = 1$ alternate. The upper right square $[2,3]\times[2,3]$ is divided similarly into horizontal strips. The middle rectangle $[1,2]\times[1,2]$ is a 2×2 checkerboard. It is easy to see that no matter what the sequence of random selection of split directions is and no matter for how long each tree is grown, no tree will ever cut the middle rectangle and therefore the probability of error of the corresponding random forest classifier is at least $1/6$. This example illustrates that consistency of greedily grown random forests is a delicate issue. We note however that if Breiman's (2001) original algorithm is used in this example (that is, each cell contains exactly one data point) then

são usados respectivamente para construir a árvore e estimar o valor dentro de uma folha. Ele também estabelece que o canivete infinitesimal (Efron, 1979) estima consistentemente a variância florestal.

Mentch e Hooker (2015) provam um resultado semelhante para florestas finitas, que se baseia principalmente na suposição de que a previsão das florestas não varia muito quando o rótulo de um ponto no conjunto de treinamento é ligeiramente modificado. Esses autores mostram que sempre que M_n (o número de árvores) pode variar com n, e quando $a_n = \mathrm{o}(\sqrt{n})$ e $\lim_{n\to\infty} n/M_n = 0$, então, para um x fixo,

$$\frac{\sqrt{n}(m_{M,n}(\mathbf{x};\Theta_1,\ldots,\Theta_M) - \mathbb{E}[m_{\infty,n}(\mathbf{x})])}{\sqrt{a_n^2\zeta_{1,a_n}}} \xrightarrow{\mathcal{D}} N,$$

onde N é uma variável aleatória normal padrão,

$$\zeta_{1,a_n} = \mathrm{Cov}\left[m_n(\mathbf{X}_1,\mathbf{X}_2,\ldots,\mathbf{X}_{a_n};\Theta), m_n(\mathbf{X}_1,\mathbf{X}_2',\ldots,\mathbf{X}_{a_n}';\Theta')\right],$$

X_i' uma cópia independente de X_i e Θ' uma cópia independente de Θ. Vale ressaltar que tanto Mentch e Hooker (2015) quanto Wager et al. (2014) fornecem correções para estimar a variância florestal ζ_{1,a_n}.

Scornet et al. (2015) comprovaram um resultado consistente no contexto de modelos de regressão aditiva para a versão podada da floresta de Breiman. Infelizmente, a consistência do procedimento não corrigido tem o preço de uma conjectura sobre o comportamento do algoritmo CART que é difícil de verificar.

Encerramos esta seção com um resultado negativo, mas interessante, devido a Biau et al. (2008). Neste exemplo, o número total k de cortes é fixo e $\texttt{mtry} = 1$. Além disso, cada árvore é construída minimizando a verdadeira probabilidade de erro em cada nó. Considere a distribuição conjunta de (X Y) esboçada na Figura 4 e seja m (x) $= \mathrm{E}[Y|\mathrm{X} = \mathrm{x}]$. A variável X tem uma distribuição uniforme em$[0,1]^2 \cup [1,2]^2 \cup [2,3]^2$ e Yé uma função de X — isto é, m(x) $\in \{0,1\}$ e$L^\star = 0$ — definida como segue. O quadrado inferior esquerdo $[0,1]\times[0,1]$ é dividido em infinitas faixas verticais contáveis nas quais as faixas com m(x) $= 0$e m(x) $= 1$ se alternam. O quadrado superior direito $[2,3]\times[2,3]$ é dividido de forma semelhante em faixas horizontais. O retângulo do meio $[1,2]\times[1,2]$ é um 2×2tabuleiro de xadrez. É fácil ver que não importa qual seja a sequência de seleção aleatória de direções divididas e não importa por quanto tempo cada árvore cresce, nenhuma árvore jamais cortará o retângulo do meio e, portanto, a probabilidade de erro do classificador de floresta aleatório correspondente é de pelo menos $1/6$. Este exemplo ilustra que a consistência das florestas aleatórias cultivadas avidamente é uma questão delicada. Notamos, no entanto, que se o algoritmo original de Breiman (2001) for usado neste exemplo (ou seja, cada célula contém exatamente um ponto de dados), então

one obtains a consistent classification rule. We also note that the regression function m is not Lipschitz—a smoothness assumption on which many results on random forests rely.

5 Variable importance

5.1 Variable importance measures

Random forests can be used to rank the importance of variables in regression or classification problems via two measures of significance. The first, called *Mean Decrease Impurity* (MDI; see Breiman, 2003a), is based on the total decrease in node impurity from splitting on the variable, averaged over all trees. The second, referred to as *Mean Decrease Accuracy* (MDA), first defined by Breiman (2001), stems from the idea that if the variable is not important, then rearranging its values should not degrade prediction accuracy.

Set $\mathbf{X} = (X^{(1)}, \ldots, X^{(p)})$. For a forest resulting from the aggregation of M trees, the MDI of the variable $X^{(j)}$ is defined by

$$\widehat{\mathrm{MDI}}(X^{(j)}) = \frac{1}{M} \sum_{\ell=1}^{M} \sum_{\substack{t \in \mathcal{T}_\ell \\ j^\star_{n,t} = j}} p_{n,t} L_{\mathrm{reg},n}(j^\star_{n,t}, z^\star_{n,t}),$$

where $p_{n,t}$ is the fraction of observations falling in the node t, $\{\mathcal{T}_\ell\}_{1 \le \ell \le M}$ the collection of trees in the forest, and $(j^\star_{n,t}, z^\star_{n,t})$ the split that maximizes the empirical criterion (2) in node t. Note that the same formula holds for classification random forests by replacing the criterion $L_{\mathrm{reg},n}$ by its classification version $L_{\mathrm{class},n}$. Thus, the MDI of $X^{(j)}$ computes the weighted decrease of impurity corresponding to splits along the variable $X^{(j)}$ and averages this quantity over all trees.

The MDA relies on a different principle and uses the out-of-bag error estimate (see Section 2.4). To measure the importance of the j-th feature, we randomly permute the values of variable $X^{(j)}$ in the out-of-bag observations and put these examples down the tree. The MDA of $X^{(j)}$ is obtained by averaging the difference in out-of-bag error estimation before and after the permutation over all trees. In mathematical terms, consider a variable $X^{(j)}$ and denote by $\mathcal{D}_{\ell,n}$ the out-of-bag data set of the ℓ-th tree and $\mathcal{D}^j_{\ell,n}$ the same data set where the values of $X^{(j)}$ have been randomly permuted. Recall that $m_n(\cdot; \Theta_\ell)$

obtém-se uma regra de classificação consistente. Observamos também que a função de regressão m não é Lipschitz – uma suposição de suavidade da qual dependem muitos resultados em florestas aleatórias.

5 Importância variável

5.1 Medidas de importância variável

As florestas aleatórias podem ser usadas para classificar a importância das variáveis em problemas de regressão ou classificação através de duas medidas de significância. O primeiro, denominado Mean Decrease Impurity (MDI; ver Brei man, 2003a), baseia-se na diminuição total da impureza do nó resultante da divisão na variável, calculada a média de todas as árvores. A segunda, referida como Mean Decrease Accuracy (MDA), definida pela primeira vez por Breiman (2001), decorre da ideia de que se a variável não for importante, então a reorganização dos seus valores não deve degradar a precisão da previsão.

Defina X $= (X^{(1)}, \ldots, X^{(p)})$. Para uma floresta resultante da agregação de árvores M, o MDI da variável $X^{(j)}$ é definido por

$$\widehat{\mathrm{MDI}}(X^{(j)}) = \frac{1}{M} \sum_{\ell=1}^{M} \sum_{\substack{t \in \mathcal{T}_\ell \\ j^\star_{n,t} = j}} p_{n,t} L_{\mathrm{reg},n}(j^\star_{n,t}, z^\star_{n,t}),$$

onde $p_{n,t}$ é a fração de observações que caem no nó t, $\{\mathcal{T}_\ell\}_{1 \le \ell \le M}$ a coleção de árvores na floresta e $(j^\star_{n,t}, z^\star_{n,t})$ a divisão que maximiza o critério empírico (2) no nó t. Observe que a mesma fórmula vale para a classificação de florestas aleatórias, substituindo o critério $L_{\mathrm{reg},n}$ pela sua versão de classificação $L_{\mathrm{class},n}$. Assim, o MDI de $X^{(j)}$ calcula a diminuição ponderada de impureza correspondente às divisões ao longo da variável $X^{(j)}$ e calcula a média desta quantidade para todas as árvores.

O MDA baseia-se num princípio diferente e utiliza a estimativa de erro out-of-bag (ver Secção 2.4). Para medir a importância do j-ésimo recurso, permutamos aleatoriamente os valores da variável $X^{(j)}$ nas observações prontas e colocamos esses exemplos na árvore. O MDA de $X^{(j)}$ é obtido calculando a média da diferença na estimativa do erro out-of-bag antes e depois da permutação em todas as árvores. Em termos matemáticos, considere uma variável $X^{(j)}$ e denote por $\mathcal{D}_{\ell,n}$ o conjunto de dados pronto para uso da ℓ-ésima árvore e $\mathcal{D}^j_{\ell,n}$ o mesmo conjunto de dados onde os valores de $X^{(j)}$ foram permutados aleatoriamente. Lembre-se de que $m_n(\cdot; \Theta_\ell)$

stands for the ℓ-th tree estimate. Then, by definition,

$$\widehat{\mathrm{MDA}}(X^{(j)}) = \frac{1}{M}\sum_{\ell=1}^{M}\left[R_n\big[m_n(\cdot;\Theta_\ell),\mathcal{D}^j_{\ell,n}\big] - R_n\big[m_n(\cdot;\Theta_\ell),\mathcal{D}_{\ell,n}\big]\right], \qquad (6)$$

where R_n is defined for $\mathcal{D} = \mathcal{D}_{\ell,n}$ or $\mathcal{D} = \mathcal{D}^j_{\ell,n}$ by

$$R_n\big[m_n(\cdot;\Theta_\ell),\mathcal{D}\big] = \frac{1}{|\mathcal{D}|}\sum_{i:(\mathbf{X}_i,Y_i)\in\mathcal{D}}(Y_i - m_n(\mathbf{X}_i;\Theta_\ell))^2. \qquad (7)$$

It is easy to see that the population version of $\widehat{\mathrm{MDA}}(X^{(j)})$ is

$$\mathrm{MDA}^\star(X^{(j)}) = \mathbb{E}\big[Y - m_n(\mathbf{X}'_j;\Theta)\big]^2 - \mathbb{E}\big[Y - m_n(\mathbf{X};\Theta)\big]^2,$$

where $\mathbf{X}'_j = (X^{(1)},\ldots,X'^{(j)},\ldots,X^{(p)})$ and $X'^{(j)}$ is an independent copy of $X^{(j)}$. For classification purposes, the MDA still satisfies (6) and (7) since $Y_i \in \{0,1\}$ (so, $R_n(m_n(\cdot;\Theta),\mathcal{D})$ is also the proportion of points that are correctly classified by $m_n(\cdot;\Theta)$ in $\mathcal{D}$).

5.2 Theoretical results

In the context of a pair of categorical variables $(\mathbf{X}, Y)$, where $\mathbf{X}$ takes finitely many values in, say, $\mathcal{X}_1 \times \cdots \times \mathcal{X}_d$, Louppe et al. (2013) consider an infinite ensemble of totally randomized and fully developed trees. At each cell, the ℓ-th tree is grown by selecting a variable $X^{(j)}$ uniformly among the features that have not been used in the parent nodes, and by subsequently dividing the cell into $|\mathcal{X}_j|$ children (so the number of children equals the number of modalities of the selected variable). In this framework, it can be shown that the population version of $\mathrm{MDI}(X^{(j)})$ computed with the whole forest satisfies

$$\mathrm{MDI}^\star(X^{(j)}) = \sum_{k=0}^{p-1}\frac{1}{\binom{k}{p}(p-k)}\sum_{B\in\mathcal{P}_k(V^{-j})} I(X^{(j)};Y|B),$$

where $V^{-j} = \{1,\ldots,j-1,j+1,\ldots,p\}$, $\mathcal{P}_k(V^{-j})$ the set of subsets of V^{-j} of cardinality k, and $I(X^{(j)};Y|B)$ the *conditional mutual information* of $X^{(j)}$ and Y given the variables in B. In addition,

$$\sum_{j=1}^{p}\mathrm{MDI}^\star(X^{(j)}) = I(X^{(1)},\ldots,X^{(p)};Y).$$

significa a ℓ-ésima estimativa da árvore. Então, por definição,

$$\widehat{\mathrm{MDA}}(X^{(j)}) = \frac{1}{M}\sum_{\ell=1}^{M}\left[R_n\big[m_n(\cdot;\Theta_\ell),\mathcal{D}^j_{\ell,n}\big] - R_n\big[m_n(\cdot;\Theta_\ell),\mathcal{D}_{\ell,n}\big]\right], \qquad (6)$$

onde R_n é definido para $\mathcal{D} = \mathcal{D}_{\ell,n}$ ou $\mathcal{D} = \mathcal{D}^j_{\ell,n}$ por

$$R_n\big[m_n(\cdot;\Theta_\ell),\mathcal{D}\big] = \frac{1}{|\mathcal{D}|}\sum_{i:(\mathbf{X}_i,Y_i)\in\mathcal{D}}(Y_i - m_n(\mathbf{X}_i;\Theta_\ell))^2. \qquad (7)$$

É fácil ver que a versão populacional de $\widehat{\mathrm{MDA}}(X^{(j)})$ é

$$\mathrm{MDA}^\star(X^{(j)}) = \mathbb{E}\big[Y - m_n(\mathbf{X}'_j;\Theta)\big]^2 - \mathbb{E}\big[Y - m_n(\mathbf{X};\Theta)\big]^2,$$

onde $\mathbf{X}'_j = (X^{(1)},\ldots,X'^{(j)},\ldots,X^{(p)})$ e $X'^{(j)}$ é uma cópia independente de $X^{(j)}$. Para fins de classificação, o MDA ainda satisfaz (6) e (7) já que $Y_i \in \{0,1\}$ (então, $R_n(m_n(\cdot;\Theta)\ \mathcal{D})$ também é a proporção de pontos que são classificados corretamente por $m_n(\cdot;\Theta)$ e m $\mathcal{D}$).

5.2 Resultados teóricos

No contexto de um par de variáveis categóricas (X Y), onde X assume um número finito de valores em, digamos, $\mathcal{X}_1 \times \cdots \times \mathcal{X}_d$, Louppe et al. (2013) consideram um conjunto infinito de árvores totalmente aleatórias e totalmente desenvolvidas. Em cada célula, a ℓ-ésima árvore é cultivada selecionando uma variável $X^{(j)}$ uniformemente entre os recursos que não foram usados nos nós pais e subseqüentemente dividindo a célula em $|\mathcal{X}_j|$ filhos (de forma que o número de filhos seja igual ao número de modalidades da variável selecionada). Nesta estrutura, pode-se mostrar que a versão populacional do MDI($X^{(j)}$) calculada com toda a floresta satisfaz

$$\mathrm{MDI}^\star(X^{(j)}) = \sum_{k=0}^{p-1}\frac{1}{\binom{k}{p}(p-k)}\sum_{B\in\mathcal{P}_k(V^{-j})} I(X^{(j)};Y|B),$$

onde $V^{-j} = \{1,\ldots,j-1,j+1,\ldots,p\}$, $\mathcal{P}_k(V^{-j})$ o conjunto de subconjuntos de V^{-j} de cardinalidade k, e $I(X^{(j)};Y|B)$ a informação mútua condicional de $X^{(j)}$ e Y dadas as variáveis em B. Além disso,

$$\sum_{j=1}^{p}\mathrm{MDI}^\star(X^{(j)}) = I(X^{(1)},\ldots,X^{(p)};Y).$$

These results show that the information $I(X^{(1)}, \ldots, X^{(p)}; Y)$ is the sum of the importances of each variable, which can itself be made explicit using the information values $I(X^{(j)}; Y|B)$ between each variable $X^{(j)}$ and the output Y, conditional on variable subsets B of different sizes.

Louppe et al. (2013) define a variable $X^{(j)}$ as irrelevant with respect to $B \subset V = \mathcal{X}_1 \times \cdots \times \mathcal{X}_p$ whenever $I(X^{(j)}; Y|B) = 0$. Thus, $X^{(j)}$ is irrelevant with respect to V if and only if $\text{MDI}^\star(X^{(j)}) = 0$. It is easy to see that if an additional irrelevant variable $X^{(p+1)}$ is added to the list of variables, then, for any j, the variable importance $\text{MDI}^\star(X^{(j)})$ computed with a single tree does not change if the tree is built with the new collection of variables $V \cup \{X^{(p+1)}\}$. In other words, building a tree with an additional irrelevant variable does not alter the importances of the other variables in an infinite sample setting.

The most notable results regarding $\text{MDA}^\star$ are due to Ishwaran (2007), who studies a slight modification of the criterion replacing permutation by feature noising. To add noise to a variable $X^{(j)}$, one considers a new observation $\mathbf{X}$, take $\mathbf{X}$ down the tree and stop when a split is made according to the variable $X^{(j)}$. Then the right or left child node is selected with probability $1/2$, and this procedure is repeated for each subsequent node (whether it is performed along the variable $X^{(j)}$ or not). The variable importance $\text{MDA}^\star(X^{(j)})$ is still computed by comparing the error of the forest with that of the "noisy" forest. Assuming that the forest is consistent and that the regression function is piecewise constant, Ishwaran (2007) gives the asymptotic behavior of $\text{MDA}^\star(X^{(j)})$ when the sample size tends to infinity. This behavior is intimately related to the set of subtrees (of the initial regression tree) whose roots are split along the coordinate $X^{(j)}$.

Let us lastly mention the approach of Gregorutti et al. (2013), who compute the MDA criterion for several distributions of $(\mathbf{X}, Y)$. For example, consider a model of the form

$$Y = m(\mathbf{X}) + \varepsilon,$$

where $(\mathbf{X}, \varepsilon)$ is a Gaussian random vector, and assume that the correlation matrix C satisfies $C = [\text{Cov}(X^{(j)}, X^{(k)})]_{1 \leq j,k \leq p} = (1-c)I_p + c\mathbb{1}\mathbb{1}^\top$ (the symbol $\top$ denotes transposition, $\mathbb{1} = (1, \ldots, 1)^\top$, and c is a constant in $(0, 1)$). Assume, in addition, that $\text{Cov}(X^{(j)}, Y) = \tau_0$ for all $j \in \{1, \ldots, p\}$. Then, for all j,

$$\text{MDA}^\star(X^{(j)}) = 2\left(\frac{\tau_0}{1-c+pc}\right)^2.$$

Esses resultados mostram que a informação $I(X^{(1)}, \ldots, X^{(p)}; Y)$ é a soma das importâncias de cada variável, que pode ser explicitada usando os valores de informação $I(X^{(j)}; Y|B)$ entre cada variável $X^{(j)}$ e a saída Y, condicional a subconjuntos de variáveis B de tamanhos diferentes.

Louppe et al. (2013) definem uma variável $X^{(j)}$ como irrelevante em relação a $B \subset V = \mathcal{X}_1 \times \cdots \times \mathcal{X}_p$ sempre que $I(X^{(j)}; Y|B) = 0$. Assim, $X^{(j)}$ é irrelevante em relação a V se e somente se $\text{MDI}^\star(X^{(j)}) = 0$. É fácil ver que se uma variável adicional irrelevante $X^{(p+1)}$ for adicionada à lista de variáveis, então, para qualquer j, a importância da variável $\text{MDI}^\star(X^{(j)})$ calculada com uma única árvore não muda se a árvore for construída com a nova coleção de variáveis $V \cup \{X^{(p+1)}\}$. Em outras palavras, construir uma árvore com uma variável irrelevante adicional não altera as importâncias das outras variáveis em um cenário de amostra infinita.

Os resultados mais notáveis em relação ao $\text{MDA}^\star$ devem-se a Ishwaran (2007), que estuda uma ligeira modificação do critério substituindo a permutação por ruído de características. Para adicionar ruído a uma variável $X^{(j)}$, considera-se uma nova observação X, leva X para baixo na árvore e para quando é feita uma divisão de acordo com a variável $X^{(j)}$. Em seguida, o nó filho direito ou esquerdo é selecionado com probabilidade $1/2$, e este procedimento é repetido para cada nó subsequente (seja executado ao longo da variável $X^{(j)}$ ou não). A importância da variável $\text{MDA}^\star(X^{(j)})$ ainda é calculada comparando o erro da floresta com o da floresta "ruidosa". Assumindo que a floresta é consistente e que a função de regressão é constante por partes, Ishwaran (2007) fornece o comportamento assintótico de $\text{MDA}^\star(X^{(j)})$ quando o tamanho da amostra tende ao infinito. Este comportamento está intimamente relacionado ao conjunto de subárvores (da árvore de regressão inicial) cujas raízes são divididas ao longo da coordenada $X^{(j)}$.

Mencionemos por último a abordagem de Gregorutti et al. (2013), que calculam o critério MDA para diversas distribuições de (X Y). Por exemplo, considere um modelo da forma

$$Y = m(\mathbf{X}) + \varepsilon,$$

onde (X ε) é um vetor aleatório gaussiano e suponha que a matriz de correlação C satisfaça $C = [\text{Cov}(X^{(j)}, X^{(k)})]_{1 \leq j,k \leq p} = (1-c)I_p + c\mathbb{1}\mathbb{1}^\top$ (o símbolo $\top$ denota transposição, $\mathbb{1} = (1, \ldots, 1)^\top$, e c é uma constante em (0, 1)). Suponha, além disso, que $\text{Cov}(X^{(j)}, Y) = \tau_0$ para todos $j \in \{1, \ldots, p\}$. Então, para todos j,

$$\text{MDA}^\star(X^{(j)}) = 2\left(\frac{\tau_0}{1-c+pc}\right)^2.$$

Thus, in the Gaussian setting, the variable importance decreases as the inverse of the square of p when the number of correlated variables p increases.

5.3 Related works

The empirical properties of the MDA criterion have been extensively explored and compared in the statistical computing literature. Indeed, Archer and Kimes (2008), Strobl et al. (2008), Nicodemus and Malley (2009), Auret and Aldrich (2011), and Toloşi and Lengauer (2011) stress the negative effect of correlated variables on MDA performance. In this respect, Genuer et al. (2010) noticed that MDA is less able to detect the most relevant variables when the number of correlated features increases. Similarly, the empirical study of Archer and Kimes (2008) points out that both MDA and MDI behave poorly when correlation increases—these results have been experimentally confirmed by Auret and Aldrich (2011) and Toloşi and Lengauer (2011). An argument of Strobl et al. (2008) to justify the bias of MDA in the presence of correlated variables is that the algorithm evaluates the marginal importance of the variables instead of taking into account their effect conditional on each other. A way to circumvent this issue is to combine random forests and the *Recursive Feature Elimination* algorithm of Guyon et al. (2002), as in Gregorutti et al. (2013). Detecting relevant features can also be achieved via hypothesis testing (Mentch and Hooker, 2015)—a principle that may be used to detect more complex structures of the regression function, like for instance its additivity (Mentch and Hooker, 2014).

6 Extensions

Weighted forests. In Breiman's (2001) forests, the final prediction is the average of the individual tree outcomes. A natural way to improve the method is to incorporate tree-level weights to emphasize more accurate trees in prediction (Winham et al., 2013). A closely related idea, proposed by Bernard et al. (2012), is to guide tree building—via resampling of the training set and other ad hoc randomization procedures—so that each tree will complement as much as possible the existing trees in the ensemble. The resulting *Dynamic Random Forest* (DRF) shows significant improvement in terms of accuracy on 20 real-based data sets compared to the standard, static, algorithm.

Assim, no cenário gaussiano, a importância da variável diminui à medida que o inverso do quadrado de p quando o número de variáveis correlacionadas p aumenta.

5.3 Trabalhos relacionados

As propriedades empíricas do critério MDA foram extensivamente exploradas e comparadas na literatura de computação estatística. Na verdade, Archer e Kimes (2008), Strobl et al. (2008), Nicodemus e Malley (2009), Auret e Aldrich (2011) e Toloşi e Lengauer (2011) enfatizam o efeito negativo de variáveis correlacionadas no desempenho do MDA. A esse respeito, Genuer et al. (2010) notaram que o MDA é menos capaz de detectar as variáveis mais relevantes quando o número de características correlacionadas aumenta. Da mesma forma, o estudo empírico de Archer e Kimes (2008) aponta que tanto o MDA como o MDI se comportam mal quando a correlação aumenta – estes resultados foram confirmados experimentalmente por Auret e Aldrich (2011) e Toloşi e Lengauer (2011). Um argumento de Strobl et al. (2008) para justificar o viés do MDA na presença de variáveis correlacionadas é que o algoritmo avalia a importância marginal das variáveis em vez de levar em conta o seu efeito condicional entre si. Uma maneira de contornar esse problema é combinar florestas aleatórias e o algoritmo de eliminação de recursos recursivos de Guyon et al. (2002), como em Gregorutti et al. (2013). A detecção de características relevantes também pode ser alcançada através de testes de hipóteses (Mentch e Hooker, 2015) – um princípio que pode ser usado para detectar estruturas mais complexas da função de regressão, como por exemplo a sua aditividade (Mentch e Hooker, 2014).

6 extensões

Florestas ponderadas. Nas florestas de Breiman (2001), a previsão final é a média dos resultados individuais das árvores. Uma maneira natural de melhorar o método é incorporar pesos em nível de árvore para enfatizar árvores mais precisas na previsão (Winham et al., 2013). Uma ideia intimamente relacionada, proposta por Bernard et al. (2012), é orientar a construção de árvores – por meio de reamostragem do conjunto de treinamento e outros procedimentos de randomização ad hoc – para que cada árvore complemente, tanto quanto possível, as árvores existentes no conjunto. A Floresta Aleatória Dinâmica (DRF) resultante mostra uma melhoria significativa em termos de precisão em 20 conjuntos de dados baseados em reais em comparação com o algoritmo estático padrão.

Online forests. In its original version, random forests is an *offline algorithm*, which is given the whole data set from the beginning and required to output an answer. In contrast, *online algorithms* do not require that the entire training set is accessible at once. These models are appropriate for streaming settings, where training data is generated over time and must be incorporated into the model as quickly as possible. Random forests have been extended to the online framework in several ways (Saffari et al., 2009; Denil et al., 2013; Lakshminarayanan et al., 2014). In Lakshminarayanan et al. (2014), so-called *Mondrian forests* are grown in an online fashion and achieve competitive predictive performance comparable with other online random forests while being faster. When building online forests, a major difficulty is to decide when the amount of data is sufficient to cut a cell. Exploring this idea, Yi et al. (2012) propose *Information Forests*, whose construction consists in deferring classification until a measure of *classification confidence* is sufficiently high, and in fact break down the data so as to maximize this measure. An interesting theory related to these greedy trees can be found in Biau and Devroye (2013).

Survival forests. Survival analysis attempts to deal with analysis of time duration until one or more events happen. Most often, survival analysis is also concerned with incomplete data, and particularly right-censored data, in fields such as clinical trials. In this context, parametric approaches such as proportional hazards are commonly used, but fail to model nonlinear effects. Random forests have been extended to the survival context by Ishwaran et al. (2008), who prove consistency of *Random Survival Forests* (RSF) algorithm assuming that all variables are categorical. Yang et al. (2010) showed that by incorporating kernel functions into RSF, their algorithm KIRSF achieves better results in many situations. Ishwaran et al. (2011) review the use of the *minimal depth*, which measures the predictive quality of variables in survival trees.

Ranking forests. Clémençon et al. (2013) have extended random forests to deal with ranking problems and propose an algorithm called *Ranking Forests* based on the ranking trees of Clémençon and Vayatis (2009). Their approach relies on nonparametric scoring and ROC curve optimization in the sense of the AUC criterion.

Clustering forests. Yan et al. (2013) present a new clustering ensemble method called *Cluster Forests* (CF) in the context of unsupervised classification. CF randomly probes a high-dimensional data cloud to obtain good local clusterings, then aggregates via spectral clustering to obtain cluster assignments for the whole data set. The search for good local clusterings

Florestas on-line. Na sua versão original, florestas aleatórias é um algoritmo offline, que recebe todo o conjunto de dados desde o início e é necessário para gerar uma resposta. Em contraste, os algoritmos online não exigem que todo o conjunto de treinamento esteja acessível de uma só vez. Esses modelos são apropriados para configurações de streaming, onde os dados de treinamento são gerados ao longo do tempo e devem ser incorporados ao modelo o mais rápido possível. As florestas aleatórias foram estendidas à estrutura on-line de diversas maneiras (Saffari et al., 2009; Denil et al., 2013; Lakshminarayanan et al., 2014). Em Lakshminarayanan et al. (2014), as chamadas florestas Mondrian são cultivadas on-line e alcançam um desempenho preditivo competitivo comparável a outras florestas aleatórias on-line, ao mesmo tempo que são mais rápidas. Ao construir florestas online, uma grande dificuldade é decidir quando a quantidade de dados é suficiente para cortar uma célula. Explorando essa ideia, Yi et al. (2012) propõem Florestas de Informação, cuja construção consiste em adiar a classificação até que uma medida de confiança na classificação seja suficientemente elevada, e de facto desagregar os dados de forma a maximizar esta medida. Uma teoria interessante relacionada a essas árvores gananciosas pode ser encontrada em Biau e Devroye (2013).

Florestas de sobrevivência. A análise de sobrevivência tenta lidar com a análise da duração do tempo até que um ou mais eventos aconteçam. Na maioria das vezes, a análise de sobrevivência também se preocupa com dados incompletos, e particularmente com dados censurados à direita, em campos como os ensaios clínicos. Neste contexto, abordagens paramétricas, como riscos proporcionais, são comumente utilizadas, mas não conseguem modelar efeitos não lineares. As florestas aleatórias foram estendidas ao contexto de sobrevivência por Ishwaran et al. (2008), que comprovam a consistência do algoritmo Random Survival Forests (RSF) assumindo que todas as variáveis são categóricas. Yang et al. (2010) mostraram que ao incorporar funções do kernel no RSF, seu algoritmo KIRSF alcança melhores resultados em muitas situações. Ishwaran et al. (2011) revisam o uso da profundidade mínima, que mede a qualidade preditiva de variáveis em árvores de sobrevivência.

Classificação de florestas. Cl´emen¸con et al. (2013) estenderam florestas aleatórias para lidar com problemas de classificação e propuseram um algoritmo chamado Ranking Forests baseado nas árvores de classificação de Cl´emen¸con e Vayatis (2009). A sua abordagem baseia-se na pontuação não paramétrica e na otimização da curva ROC no sentido do critério AUC.

Agrupamento de florestas. Yan et al. (2013) apresentam um novo método de clustering ensemble denominado Cluster Forests (CF) no contexto de classificação não supervisionada. O CF investiga aleatoriamente uma nuvem de dados de alta dimensão para obter bons agrupamentos locais e, em seguida, agrega por meio de agrupamento espectral para obter atribuições de agrupamento para todo o conjunto de dados. A busca por bons clusters locais

is guided by a cluster quality measure, and CF progressively improves each local clustering in a fashion that resembles tree growth in random forests.

Quantile forests. Meinshausen (2006) shows that random forests provide information about the full conditional distribution of the response variable, and thus can be used for quantile estimation.

Missing data. One of the strengths of random forests is that they can handle missing data. The procedure, explained in Breiman (2003b), takes advantage of the so-called *proximity matrix*, which measures the proximity between pairs of observations in the forest, to estimate missing values. This measure is the empirical counterpart of the kernels defined in Section 3.2. Data imputation based on random forests has further been explored by Rieger et al. (2010), Crookston and Finley (2008), and extended to unsupervised classification by Ishioka (2013).

Single class data. One-class classification is a binary classification task for which only one class of samples is available for learning. Désir et al. (2013) study the *One Class Random Forests* algorithm, which is designed to solve this particular problem. Geremia et al. (2013) have introduced a supervised learning algorithm called *Spatially Adaptive Random Forests* to deal with semantic image segmentation applied to medical imaging protocols. Lastly, in the context of multi-label classification, Joly et al. (2014) adapt the idea of random projections applied to the output space to enhance tree-based ensemble methods by improving accuracy while significantly reducing the computational burden.

Unbalanced data set. Random forests can naturally be adapted to fit the unbalanced data framework by down-sampling the majority class and growing each tree on a more balanced data set (Chen et al., 2004; Kuhn and Johnson, 2013). An interesting application in which unbalanced data sets are involved is by Fink et al. (2010), who explore the continent-wide inter-annual migrations of common North American birds. They use random forests for which each tree is trained and allowed to predict on a particular (random) region in space and time.

7 Conclusion and perspectives

The authors trust that this review paper has provided an overview of some of the recent literature on random forests and offered insights into how new and emerging fields are impacting the method. As statistical applications become

é guiado por uma medida de qualidade de cluster, e a FC melhora progressivamente cada cluster local de uma forma que se assemelha ao crescimento de árvores em florestas aleatórias.

Florestas quantílicas. Meinshausen (2006) mostra que florestas aleatórias fornece m informações sobre a distribuição condicional completa da variável resposta e, portanto, podem ser usadas para estimativa de quantis.

Dados ausentes. Um dos pontos fortes das florestas aleatórias é que elas podem li dar com dados ausentes. O procedimento, explicado em Breiman (2003b), aproveita a chamada matriz de proximidade, que mede a proximidade entre pares de observações na floresta, para estimar valores faltantes. Esta medida é a contrapartida empírica dos núcleos definidos na Secção 3.2. A imputação de dados baseada em florestas aleatórias foi explorada por Rieger et al. (2010), Crookston e Finley (2008), e estendido para classificação não supervisionada por Ishioka (2013).

Dados de classe única. A classificação de uma classe é uma tarefa de classificação binária para a qual apenas uma classe de amostras está disponível para aprendizagem. D´esir et al. (2013) estudam o algoritmo One Class Random Forests, que foi projetado para resolver esse problema específico. Geremia et al. (2013) introduziram um algoritmo de aprendizagem supervisionado chamado Spatally Adaptive Random Forests para lidar com a segmentação semântica de imagens aplicadas a protocolos de imagens médicas. Por último, no contexto da classificação multirótulo, Joly et al. (2014) adaptam a ideia de projeções aleatórias aplicadas ao espaço de saída para aprimorar métodos de conjuntos baseados em árvores, melhorando a precisão e reduzindo significativamente a carga computacional.

Conjunto de dados desequilibrado. As florestas aleatórias podem naturalmente ser adaptadas para se ajustarem à estrutura de dados desequilibrados, reduzindo a amostragem da classe majoritária e aumentando cada árvore em um conjunto de dados mais equilibrado (Chen et al., 2004; Kuhn e Johnson, 2013). Uma aplicação interessante na qual estão envolvidos conjuntos de dados desequilibrados é a de Fink et al. (2010), que exploram as migrações interanuais de aves comuns da América do Norte em todo o continente. Eles usam florestas aleatórias para as quais cada árvore é treinada e pode prever uma região específica (aleatória) no espaço e no tempo.

7 Conclusão e perspectivas

Os autores confiam que este artigo de revisão forneceu uma visão geral de parte da literatura recente sobre florestas aleatórias e ofereceu insights sobre como campos novos e emergentes estão impactando o método. À medida que as aplicações estatísticas se tornam

increasingly sophisticated, massive and complex data sets require today the development of algorithms that ensure global competitiveness, achieving both computational efficiency and safe with high-dimension models and huge number of samples. It is our belief that forests and their basic principles ("divide and conquer", resampling, aggregation, random search of the feature space) offer simple but fundamental ideas that may leverage new state-of-the-art algorithms.

It remains however that the present results are insufficient to explain in full generality the remarkable behavior of random forests. The authors' intuition is that tree aggregation models are able to estimate patterns that are more complex than classical ones—patterns that cannot be simply characterized by standard sparsity or smoothness conditions. These patterns, which are beyond the reach of classical methods, are still to be discovered, quantified, and mathematically described.

It is sometimes alluded to that random forests have the flavor of deep network architectures (e.g., Bengio, 2009), insofar as ensemble of trees allow to discriminate between a very large number of regions. Indeed, the identity of the leaf node with which a data point is associated for each tree forms a tuple that can represent a considerable quantity of possible patterns, because the total intersections of the leaf regions can be exponential in the number of trees. This point of view, largely unexamined, could be one of the reasons for the success of forests on large-scale data. As a matter of fact, the connection between random forests and neural networks is largely unexamined (Welbl, 2014).

Another critical issue is how to choose tuning parameters that are optimal in a certain sense, especially the size a_n of the preliminary resampling. By default, the algorithm runs in bootstrap mode (i.e., $a_n = n$ points selected with replacement) and although this seems to give excellent results, there is to date no theory to support this choice. Furthermore, although random forests are fully grown in most applications, the impact of tree depth on the statistical performance of the algorithm is still an open question.

Acknowledgments. We thank the Editors and three anonymous referees for valuable comments and insightful suggestions.

conjuntos de dados cada vez mais sofisticados, massivos e complexos exigem hoje o desenvolvimento de algoritmos que garantam a competitividade global, alcançando eficiência computacional e segurança com modelos de alta dimensão e grande número de amostras. Acreditamos que as florestas e os seus princípios básicos (" dividir e conquistar", reamostragem, agregação, pesquisa aleatória do espaço de características) oferecem ideias simples mas fundamentais que podem alavancar novos algoritmos de última geração.

Resta, no entanto, que os presentes resultados são insuficientes para explicar de forma geral o comportamento notável das florestas aleatórias. A intuição dos autores é que os modelos de agregação de árvores são capazes de estimar padrões que são mais complexos que os clássicos – padrões que não podem ser simplesmente caracterizados por condições padrão de dispersão ou suavidade. Esses padrões, que estão além do alcance dos métodos clássicos, ainda precisam ser descobertos, quantificados e descritos matematicamente.

Às vezes é aludido que as florestas aleatórias têm o sabor de arquiteturas de redes profundas (por exemplo, Bengio, 2009), na medida em que o conjunto de árvores permite discriminar entre um grande número de regiões. Na verdade, a identidade do nó folha ao qual um ponto de dados está associado para cada árvore forma uma tupla que pode representar uma quantidade considerável de padrões possíveis, porque o total de interseções das regiões folha pode ser exponencial no número de árvores. Este ponto de vista, em grande parte não examinado, poderia ser uma das razões do sucesso das florestas em dados de grande escala. Na verdade, a conexão entre florestas aleatórias e redes neurais ainda não foi examinada (Welbl, 2014).

Outra questão crítica é como escolher parâmetros de ajuste que sejam ideais em certo sentido, especialmente o tamanho a_n da reamostragem preliminar. Por padrão, o algoritmo é executado no modo bootstrap (ou seja, $a_n = n$ pontos selecionados com substituição) e embora isso pareça dar resultados excelentes, não há até o momento nenhuma teoria para apoiar esta escolha. Além disso, embora as florestas aleatórias sejam totalmente cultivadas na maioria das aplicações, o impacto da profundidade das árvores no desempenho estatístico do algoritmo ainda é uma questão em aberto.

Agradecimentos. Agradecemos aos Editores e a três pareceristas anônimos pelos valiosos comentários e sugestões perspicazes.

References

D. Amaratunga, J. Cabrera, and Y.-S. Lee. Enriched random forests. *Bioinformatics*, 24:2010–2014, 2008.

Y. Amit and D. Geman. Shape quantization and recognition with randomized trees. *Neural Computation*, 9:1545–1588, 1997.

K.J. Archer and R.V. Kimes. Empirical characterization of random forest variable importance measures. *Computational Statistics & Data Analysis*, 52:2249–2260, 2008.

S. Arlot and R. Genuer. Analysis of purely random forests bias. *arXiv:1407.3939*, 2014.

L. Auret and C. Aldrich. Empirical comparison of tree ensemble variable importance measures. *Chemometrics and Intelligent Laboratory Systems*, 105:157–170, 2011.

Z.-H. Bai, L. Devroye, H.-K. Hwang, and T.-H. Tsai. Maxima in hypercubes. *Random Structures & Algorithms*, 27:290–309, 2005.

M. Banerjee and I.W. McKeague. Confidence sets for split points in decision trees. *The Annals of Statistics*, 35:543–574, 2007.

O. Barndorff-Nielsen and M. Sobel. On the distribution of the number of admissible points in a vector random sample. *Theory of Probability and Its Applications*, 11:249–269, 1966.

Y. Bengio. Learning deep architectures for AI. *Foundations and Trends in Machine Learning*, 2:1–127, 2009.

S. Bernard, L. Heutte, and S. Adam. Forest-RK: A new random forest induction method. In D.-S. Huang, D.C. Wunsch II, D.S. Levine, and K.-H. Jo, editors, *Advanced Intelligent Computing Theories and Applications. With Aspects of Artificial Intelligence*, pages 430–437, Berlin, 2008. Springer.

S. Bernard, S. Adam, and L. Heutte. Dynamic random forests. *Pattern Recognition Letters*, 33:1580–1586, 2012.

G. Biau. Analysis of a random forests model. *Journal of Machine Learning Research*, 13:1063–1095, 2012.

Referências

D. Amaratunga, J. Cabrera e Y.-S. Lee. Florestas aleatórias enriquecidas. Bioinformática, 24:2010–2014, 2008. Y. Amit e D. Geman. Quantização e reconhecimento de formas com árvores aleatórias. Computação Neural, 9:1545–1588, 1997. KJ. Archer e R.V. Kimes. Caracterização empírica de medidas aleatórias de importância de variáveis florestais. Estatística Computacional e Análise de Dados, 52:2249–2260, 2008. S. Arlot e R. Genuer. Análise do viés de florestas puramente aleatórias. arXiv:1407.3939, 2014. L. Auret e C. Aldrich. Comparação empírica de medidas de importância variável de conjuntos de árvores. Quimiometria e Sistemas Laboratoriais Inteligentes, 105:157–170, 2011. Z.-H. Bai, L. Devroye, H.-K. Hwang e T.-H. Tsai. Máximos em hipercubos. Random Structures & Algorithms, 27:290–309, 2005. M. Banerjee e IW McKeague. Conjuntos de confiança para pontos de divisão em árvores de decisão. Os Anais de Estatística, 35:543–574, 2007. O. Barndorff-Nielsen e M. Sobel. Sobre a distribuição do número de pontos admissíveis em uma amostra aleatória vetorial. Teoria da Probabilidade e suas Aplicações, 11:249–269, 1966. Y. Bengio. Aprendendo arquiteturas profundas para IA. Fundamentos e Tendências em Aprendizado de Máquina, 2:1–127, 2009. S. Bernard, L. Heutte e S. Adam. Forest-RK: Um novo método aleatório de indução florestal. Em D.-S. Huang, DC Wunsch II, DS Levine e K.-H. Jo, editores, Teorias e Aplicações de Computação Inteligente Avançada. Com Aspectos de Inteligência Artificial, páginas 430–437, Berlim, 2008. Springer. S. Bernard, S. Adam e L. Heutte. Florestas aleatórias dinâmicas. Cartas de reconhecimento de padrões, 33:1580–1586, 2012. G. Biau. Análise de um modelo de florestas aleatórias. Journal of Machine Learning Research, 13:1063–1095, 2012.

G. Biau and L. Devroye. On the layered nearest neighbour estimate, the bagged nearest neighbour estimate and the random forest method in regression and classification. *Journal of Multivariate Analysis*, 101:2499–2518, 2010.

G. Biau and L. Devroye. Cellular tree classifiers. *Electronic Journal of Statistics*, 7:1875–1912, 2013.

G. Biau, L. Devroye, and G. Lugosi. Consistency of random forests and other averaging classifiers. *Journal of Machine Learning Research*, 9:2015–2033, 2008.

G. Biau, F. Cérou, and A. Guyader. On the rate of convergence of the bagged nearest neighbor estimate. *Journal of Machine Learning Research*, 11:687–712, 2010.

A.-L. Boulesteix, S. Janitza, J. Kruppa, and I.R. König. Overview of random forest methodology and practical guidance with emphasis on computational biology and bioinformatics. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 2:493–507, 2012.

L. Breiman. Bagging predictors. *Machine Learning*, 24:123–140, 1996.

L. Breiman. *Some infinity theory for predictor ensembles*. Technical Report 577, University of California, Berkeley, 2000a.

L. Breiman. Randomizing outputs to increase prediction accuracy. *Machine Learning*, 40:229–242, 2000b.

L. Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.

L. Breiman. *Setting up, using, and understanding random forests V3.1*. https://www.stat.berkeley.edu/~breiman/Using_random_forests_V3.1.pdf, 2003a.

L. Breiman. *Setting up, using, and understanding random forests V4.0*. https://www.stat.berkeley.edu/~breiman/Using_random_forests_v4.0.pdf, 2003b.

L. Breiman. *Consistency for a simple model of random forests*. Technical Report 670, University of California, Berkeley, 2004.

L. Breiman, J.H. Friedman, R.A. Olshen, and C.J. Stone. *Classification and Regression Trees*. Chapman & Hall/CRC, Boca Raton, 1984.

G. Biau e L. Devroye. Na estimativa do vizinho mais próximo em camadas, na estimativa do vizinho mais próximo ensacado e no método florestal aleatório na regressão e classificação. Journal of Multivariate Analysis, 101:2499–2518, 2010. G. Biau e L. Devroye. Classificadores de árvores celulares. Jornal Eletrônico de Estatística, 7:1875–1912, 2013. G. Biau, L. Devroye e G. Lugosi. Consistência de florestas aleatórias e outros classificadores de média. Journal of Machine Learning Research, 9:2015–2033, 2008. G. Biau, F. C´erou e A. Guyader. Sobre a taxa de convergência da estimativa do vizinho mais próximo ensacado. Journal of Machine Learning Research, 11:687–712, 2010. A.-L. Boulesteix, S. Janitza, J. Kruppa e I.R. K¨ onig. Visão geral da metodologia florestal aleatória e orientação prática com ênfase em biologia computacional e bioinformática. Revisões Interdisciplinares de Wiley: Mineração de Dados e Descoberta de Conhecimento, 2:493–507, 2012. L. Breiman. Preditores de ensacamento. Aprendizado de Máquina, 24:123–140, 1996. L. Brei man. Alguma teoria do infinito para conjuntos de preditores. Relatório Técnico 577, Universidade da Califórnia, Berkeley, 2000a. L. Breiman. Randomizando resultados para aumentar a precisão da previsão. Aprendizado de Máquina, 40:229–242, 2000b. L. Breiman. Florestas aleatórias. Aprendizado de Máquina, 45:5–32, 2001. L. Breiman. Configurando, usando e compreendendo florestas aleatórias V3.1. https://www.stat.berkeley.edu/~breiman/Using_random_forests_V3.1.pdf, 2003a. L. Breiman. Configurando, usando e compreendendo florestas aleatórias V4.0. https://www.stat.berkeley.edu/~breiman/Using_random_forests_v4.0.pdf, 2003b. L. Breiman. Consistência para um modelo simples de florestas aleatórias. Relatório Técnico 670, Universidade da Califórnia, Berkeley, 2004. L. Breiman, J.H. Friedman, R. A. Olshen e CJ Stone. Árvores de Classificação e Regressão. Chapman & Hall/CRC, Boca Raton, 1984.

34

P. Bühlmann and B. Yu. Analyzing bagging. *The Annals of Statistics*, 30: 927–961, 2002.

C. Chen, A. Liaw, and L. Breiman. Using random forest to learn imbalanced data. *Technical Report 666, University of California, Berkeley*, 2004.

S. Clémençon, M. Depecker, and N. Vayatis. Ranking forests. *Journal of Machine Learning Research*, 14:39–73, 2013.

S. Clémençon and N. Vayatis. Tree-based ranking methods. *IEEE Transactions on Information Theory*, 55:4316–4336, 2009.

A. Criminisi, J. Shotton, and E. Konukoglu. Decision forests: A unified framework for classification, regression, density estimation, manifold learning and semi-supervised learning. *Foundations and Trends in Computer Graphics and Vision*, 7:81–227, 2011.

N.L. Crookston and A.O. Finley. yaImpute: An `R` package for kNN imputation. *Journal of Statistical Software*, 23:1–16, 2008.

A. Cutler and G. Zhao. PERT – perfect random tree ensembles. *Computing Science and Statistics*, 33:490–497, 2001.

D.R. Cutler, T.C. Edwards Jr., K.H. Beard, A. Cutler, K.T. Hess, J. Gibson, and J.J. Lawler. Random forests for classification in ecology. *Ecology*, 88: 2783–2792, 2007.

A. Davies and Z. Ghahramani. The Random Forest Kernel and creating other kernels for big data from random partitions. *arXiv:1402.4293*, 2014.

H. Deng and G. Runger. Feature selection via regularized trees. In *The 2012 International Joint Conference on Neural Networks*, pages 1–8, 2012.

H. Deng and G. Runger. Gene selection with guided regularized random forest. *Pattern Recognition*, 46:3483–3489, 2013.

M. Denil, D. Matheson, and N. de Freitas. Consistency of online random forests. In *International Conference on Machine Learning (ICML)*, 2013.

M. Denil, D. Matheson, and N. de Freitas. Narrowing the gap: Random forests in theory and in practice. In *International Conference on Machine Learning (ICML)*, 2014.

C. Désir, S. Bernard, C. Petitjean, and L. Heutte. One class random forests. *Pattern Recognition*, 46:3490–3506, 2013.

P. B¨uhlmann e B. Yu. Analisando ensacamento. Os Anais de Estatística, 30: 927–961, 2002. C. Chen, A. Liaw e L. Breiman. Usando floresta aleatória para aprender dados desequilibrados. Relatório Técnico 666, Universidade da Califórnia, Berkeley, 2004. S. Cl´emen¸con, M. Depecker e N. Vayatis. Classificação de florestas. Journal of Machine Learning Research, 14:39–73, 2013. S. Cl´emen¸con e N. Vayatis. Métodos de classificação baseados em árvore. IEEE Transactions on Information Theory, 55:4316–4336, 2009. A. Criminisi, J. Shotton e E. Konukoglu. Florestas de decisão: uma estrutura unificada para classificação, regressão, estimativa de densidade, aprendizagem múltipla e aprendizagem semissupervisionada. Fundamentos e Tendências em Computação Gráfica e Visão, 7:81–227, 2011. N.L. Crookston e A.O. Finley. yaImpute: Um pacote `R` para imputação kNN. Journal of Statistical Soft ware, 23:1–16, 2008. A. Cutler e G. Zhao. PERT – conjuntos de árvores aleatórios perfeitos. Ciência da Computação e Estatística, 33:490–497, 2001. D.R. Cutler, T.C. Edwards Jr., K.H. Barba, A. Cutler, KT. Hess, J. Gibson e J.J. Lawler. Florestas aleatórias para classificação em ecologia. Ecologia, 88: 2783–2792, 2007. A. Davies e Z. Ghahramani. O Random Forest Kernel e a criação de outros kernels para big data a partir de partições aleatórias. arXiv:1402.4293, 2014. H. Deng e G. Runger. Seleção de recursos por meio de árvores regularizadas. Na Conferência Conjunta Internacional sobre Redes Neurais de 2012, páginas 1–8, 2012. H. Deng e G. Runger. Seleção genética com floresta aleatória regularizada guiada. Reconhecimento de Padrões, 46:3483–3489, 2013. M. Denil, D. Matheson e N. de Freitas. Consistência de florestas aleatórias online. Na Conferência Internacional sobre Aprendizado de Máquina (ICML), 2013. M. Denil, D. Matheson e N. de Freitas. Reduzindo a lacuna: florestas aleatórias na teoria e na prática. Na Conferência Internacional sobre Aprendizado de Máquina (ICML), 2014. C. D´esir, S. Bernard, C. Petitjean e L. Heutte. Florestas aleatórias de uma classe. Reconhecimento de padrões, 46:3490–3506, 2013.

L. Devroye, L. Györfi, and G. Lugosi. *A Probabilistic Theory of Pattern Recognition*. Springer, New York, 1996.

R. Díaz-Uriarte and S. Alvarez de Andrés. Gene selection and classification of microarray data using random forest. *BMC Bioinformatics*, 7:1–13, 2006.

T.G. Dietterich. Ensemble methods in machine learning. In *Multiple Classifier Systems*, pages 1–15. Springer, 2000.

B. Efron. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7:1–26, 1979.

B. Efron. *The Jackknife, the Bootstrap and Other Resampling Plans*, volume 38. CBMS-NSF Regional Conference Series in Applied Mathematics, Philadelphia, 1982.

D. Fink, W.M. Hochachka, B. Zuckerberg, D.W. Winkler, B. Shaby, M.A. Munson, G. Hooker, M. Riedewald, D. Sheldon, and S. Kelling. Spatiotemporal exploratory models for broad-scale survey data. *Ecological Applications*, 20:2131–2147, 2010.

J. Friedman, T. Hastie, and R. Tibshirani. *The Elements of Statistical Learning. Second Edition*. Springer, New York, 2009.

R. Genuer. Variance reduction in purely random forests. *Journal of Nonparametric Statistics*, 24:543–562, 2012.

R. Genuer, J.-M. Poggi, and C. Tuleau-Malot. Variable selection using random forests. *Pattern Recognition Letters*, 31:2225-2236, 2010.

E. Geremia, B.H. Menze, and N. Ayache. Spatially adaptive random forests. In *IEEE International Symposium on Biomedical Imaging: From Nano to Macro*, pages 1332–1335, 2013.

P. Geurts, D. Ernst, and L. Wehenkel. Extremely randomized trees. *Machine Learning*, 63:3–42, 2006.

B. Gregorutti, B. Michel, and P. Saint Pierre. Correlation and variable importance in random forests. *arXiv:1310.5726*, 2013.

I. Guyon, J. Weston, S. Barnhill, and V. Vapnik. Gene selection for cancer classification using support vector machines. *Machine Learning*, 46:389–422, 2002.

L. Devroye, L. Gy¨orfi e G. Lugosi. Uma teoria probabilística de reconhecimento de padrões. Springer, Nova York, 1996. R. D´ıaz-Uriarte e S. Alvarez de Andr´es. Seleção genética e classificação de dados de microarranjos usando floresta aleatória. BMC Bioinformática, 7:1–13, 2006. T.G. Dietrich. Métodos ensemble em aprendizado de máquina. Em Sistemas Classificadores Múltiplos, páginas 1–15. Springer, 2000. B. Efron. Métodos Bootstrap: Outra olhada no canivete. Os Anais de Estatística, 7:1–26, 1979. B. Efron. The Jackknife, the Bootstrap and Other Resampling Plans, volume 38. CBMS-NSF Regional Conference Series in Applied Mathematics, Filadélfia, 1982. D. Fink, W.M. Hochachka, B. Zuckerberg, D.W. Winkler, B. Shaby, MA Munson, G. Hooker, M. Riedewald, D. Sheldon e S. Kelling. Modelos exploratórios espaço-temporais para dados de pesquisas em larga escala. Aplicações Ecológicas, 20:2131–2147, 2010. J. Friedman, T. Hastie e R. Tibshirani. Os elementos da aprendizagem estatística. Segunda edição. Springer, Nova York, 2009. R. Genuer. Redução da variância em florestas puramente aleatórias. Journal of Non-parametric Statistics, 24:543–562, 2012. R. Genuer, J.-M. Poggi e C. Tuleau-Malot. Seleção de variáveis usando florestas aleatórias. Cartas de reconhecimento de padrões, 31:2225-2236, 2010. E. Geremia, B.H. Menze e N. Ayache. Florestas aleatórias espacialmente adaptativas. No Simpósio Internacional IEEE sobre Imagens Biomédicas: Do Nano ao Macro, páginas 1332–1335, 2013. P. Geurts, D. Ernst e L. Wehenkel. Árvores extremamente aleatórias. Aprendizado de Máquina, 63:3–42, 2006. B. Gregorutti, B. Michel e P. Saint Pierre. Correlação e importância variável em florestas aleatórias. arXiv:1310.5726, 2013. I. Guyon, J. Weston, S. Barnhill e V. Vapnik. Seleção de genes para classificação de câncer usando máquinas de vetores de suporte. Aprendizado de Máquina, 46:389–422, 2002.

L. Györfi, M. Kohler, A. Krzyżak, and H. Walk. *A Distribution-Free Theory of Nonparametric Regression*. Springer, New York, 2002.

T. Ho. The random subspace method for constructing decision forests. *Pattern Analysis and Machine Intelligence*, 20, 832-844, 1998.

T. Hothorn, K. Hornik, and A. Zeileis. Unbiased recursive partitioning: A conditional inference framework. *Journal of Computational and Graphical Statistics*, 15:651–674, 2006.

J. Howard and M. Bowles. The two most important algorithms in predictive modeling today. In *Strata Conference: Santa Clara*. http://strataconf.com/strata2012/public/schedule/detail/22658, 2012.

T. Ishioka. Imputation of missing values for unsupervised data using the proximity in random forests. In *eLmL 2013, The Fifth International Conference on Mobile, Hybrid, and On-line Learning*, pages 30–36. International Academy, Research, and Industry Association, 2013.

H. Ishwaran. Variable importance in binary regression trees and forests. *Electronic Journal of Statistics*, 1:519–537, 2007.

H. Ishwaran. The effect of splitting on random forests. *Machine Learning*, 99:75–118, 2013.

H. Ishwaran and U.B. Kogalur. Consistency of random survival forests. *Statistics & Probability Letters*, 80:1056–1064, 2010.

H. Ishwaran, U.B. Kogalur, E.H. Blackstone, and M.S. Lauer. Random survival forests. *The Annals of Applied Statistics*, 2:841–860, 2008.

H. Ishwaran, U.B. Kogalur, X. Chen, and A.J. Minn. Random survival forests for high-dimensional data. *Statistical Analysis and Data Mining: The ASA Data Science Journal*, 4:115–132, 2011.

D. Jeffrey and G. Sanja. Simplified data processing on large clusters. *Communications of the ACM*, 51:107–113, 2008.

A. Joly, P. Geurts, and L. Wehenkel. Random forests with random projections of the output space for high dimensional multi-label classification. In T. Calders, F. Esposito, E. Hüllermeier, and R. Meo, editors, *Machine Learning and Knowledge Discovery in Databases*, pages 607–622, Berlin, 2014. Springer.

L. Gy¨orfi, M. Kohler, A. Krzy˙zak e H. Walk. Uma teoria de regressão não paramétrica livre de distribuição. Springer, Nova York, 2002. T. Ho. O método de subespaço aleatório para construção de florestas de decisão. Análise de Padrões e Inteligência de Máquina, 20, 832-844, 1998. T. Hothorn, K. Hornik e A. Zeileis. Particionamento recursivo imparcial: uma estrutura de inferência condicional. Journal of Computational and Graphical Statistics, 15:651–674, 2006. J. Howard e M. Bowles. Os dois algoritmos mais importantes na modelagem preditiva atualmente. Conferência In Strata: Santa Clara. http://strataconf.com/strata2012/public/schedule/detail/22658, 2012. T. Ishioka. Imputação de valores faltantes para dados não supervisionados utilizando a proximidade em florestas aleatórias. Em eLmL 2013, Quinta Conferência Internacional sobre Aprendizagem Móvel, Híbrida e On-line, páginas 30–36. Associação Internacional da Academia, Pesquisa e Indústria, 2013. H. Ishwaran. Importância variável em árvores e florestas de regressão binária. Jornal Eletrônico de Estatística, 1:519–537, 2007. H. Ishwaran. O efeito da divisão em florestas aleatórias. Aprendizado de Máquina, 99:75–118, 2013. H. Ishwaran e U.B. Kogalur. Consistência de florestas de sobrevivência aleatórias. Cartas de Estatística e Probabilidade, 80:1056–1064, 2010. H. Ishwaran, U.B. Kogalur, E.H. Blackstone e M.S. Lauer. Florestas de sobrevivência aleatória. Os Anais de Estatística Aplicada, 2: 841–860, 2008. H. Ishwaran, U.B. Kogalur, X. Chen e A.J. Minn. Florestas de sobrevivência aleatórias para dados de alta dimensão. Análise Estatística e Mineração de Dados: The ASA Data Science Journal, 4:115–132, 2011. D. Jeffrey e G. Sanja. Processamento de dados si mplificado em grandes clusters. Communications of the ACM, 51:107–113, 2008. A. Joly, P. Geurts e L. Wehenkel. Florestas aleatórias com projeções aleatórias do espaço de saída para classificação multi-rótulo de alta dimensão. Em T. Calders, F. Esposito, E. H¨ullermeier e R. Meo, editores, Machine Learning and Knowledge Discovery in Databases, páginas 607–622, Berlim, 2014. Springer.

H. Kim and W.-Y. Loh. Classification trees with unbiased multiway splits. *Journal of the American Statistical Association*, 96:589–604, 2001.

A. Kleiner, A. Talwalkar, P. Sarkar, and M.I. Jordan. A scalable bootstrap for massive data. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 76:795–816, 2014.

E. Konukoglu and M. Ganz. Approximate false positive rate control in selection frequency for random forest. *arXiv:1410.2838*, 2014.

J. Kruppa, A. Schwarz, G. Arminger, and A. Ziegler. Consumer credit risk: Individual probability estimates using machine learning. *Expert Systems with Applications*, 40:5125–5131, 2013.

J. Kruppa, Y. Liu, G. Biau, M. Kohler, I.R. König, J.D. Malley, and A. Ziegler. Probability estimation with machine learning methods for dichotomous and multicategory outcome: Theory. *Biometrical Journal*, 56: 534–563, 2014a.

J. Kruppa, Y. Liu, H.-C. Diener, T. Holste, C. Weimar, I.R. König, and A. Ziegler. Probability estimation with machine learning methods for dichotomous and multicategory outcome: Applications. *Biometrical Journal*, 56:564–583, 2014b.

M. Kuhn and K. Johnson. *Applied Predictive Modeling*. Springer, New York, 2013.

A. Kyrillidis and A. Zouzias. Non-uniform feature sampling for decision tree ensembles. In *IEEE International Conference on Acoustics, Speech and Signal Processing*, pages 4548–4552, 2014.

B. Lakshminarayanan, D.M. Roy, and Y.W. Teh. Mondrian forests: Efficient online random forests. In Z. Ghahramani, M. Welling, C. Cortes, N.D. Lawrence, and K.Q. Weinberger, editors, *Advances in Neural Information Processing Systems*, pages 3140–3148, 2014.

P. Latinne, O. Debeir, and C. Decaestecker. Limiting the number of trees in random forests. In J. Kittler and F. Roli, editors, *Multiple Classifier Systems*, pages 178–187, Berlin, 2001. Springer.

A. Liaw and M. Wiener. Classification and regression by randomForest. *R News*, 2:18–22, 2002.

Y. Lin and Y. Jeon. Random forests and adaptive nearest neighbors. *Journal of the American Statistical Association*, 101:578–590, 2006.

H. Kim e W.-Y. Ah. Árvores de classificação com divisões multivias imparciais. Journal of the American Statistical Association, 96:589–604, 2001. A. Kleiner, A. Talwalkar, P. Sarkar e M.I. Jordânia. Um bootstrap escalável para dados massivos. Journal of the Royal Statistical Society: Série B (Metodologia Estatística), 76:795–816, 2014. E. Konukoglu e M. Ganz. Controle aproximado da taxa de falsos positivos na frequência de seleção para floresta aleatória. arXiv:1410.2838, 2014. J. Kruppa, A. Schwarz, G. Arminger e A. Ziegler. Risco de crédito ao consumidor: estimativas de probabilidade individuais usando aprendizado de máquina. Sistemas Especialistas com Aplicações, 40:5125–5131, 2013. J. Kruppa, Y. Liu, G. Biau, M. Kohler, I.R. K¨onig, JD Malley e A. Ziegler. Estimativa de probabilidade com métodos de aprendizado de máquina para resultados dicotômicos e multicategorias: Teoria. Jornal Biométrico, 56: 534–563, 2014a. J. Kruppa, Y. Liu, H.-C. Diener, T. Holste, C. Weimar, IR. K¨onig e A. Ziegler. Estimativa de probabilidade com métodos de aprendizado de máquina para resultados dicotômicos e multicategorias: Aplicações. Diário Biométrico, 56:564–583, 2014b. M. Kuhn e K. Johnson. Modelagem Preditiva Aplicada. Springer, Nova York, 2013. A. Kyrillidis e A. Zouzias. Amostragem de recursos não uniforme para conjuntos de árvores de decisão. Na Conferência Internacional IEEE sobre Acústica, Fala e Processamento de Sinais, páginas 4548–4552, 2014. B. Lakshminarayanan, D.M. Roy e Y.W. Ah. Florestas Mondrian: Florestas aleatórias online eficientes. Em Z. Ghahramani, M. Welling, C. Cortes, ND Lawrence e KQ. Weinberger, editores, Advances in Neural Information Processing Systems, páginas 3140–3148, 2014. P. Latinne, O. Debeir e C. Decaestecker. Limitando o número de árvores em florestas aleatórias. Em J. Kittler e F. Roli, editores, Multiple Classifier Systems, páginas 178–187, Berlim, 2001. Springer. A. Liaw e M. Wiener. Classificação e regressão por randomForest. R News, 2:18–22, 2002. Y. Lin e Y. Jeon. Florestas aleatórias e vizinhos mais próximos adaptativos. Jornal da Associação Estatística Americana, 101:578–590, 2006.

G. Louppe, L. Wehenkel, A. Sutera, and P. Geurts. Understanding variable importances in forests of randomized trees. In C.J.C. Burges, L. Bottou, M. Welling, Z. Ghahramani, and K.Q. Weinberger, editors, *Advances in Neural Information Processing Systems*, pages 431–439, 2013.

J.D. Malley, J. Kruppa, A. Dasgupta, K.G. Malley, and A. Ziegler. Probability machines: consistent probability estimation using nonparametric learning machines. *Methods of Information in Medicine*, 51:74–81, 2012.

N. Meinshausen. Quantile regression forests. *Journal of Machine Learning Research*, 7:983–999, 2006.

N. Meinshausen. Forest Garrote. *Electronic Journal of Statistics*, 3:1288–1304, 2009.

L. Mentch and G. Hooker. A novel test for additivity in supervised ensemble learners. *arXiv:1406.1845*, 2014.

L. Mentch and G. Hooker. Ensemble trees and CLTs: Statistical inference for supervised learning. *Journal of Machine Learning Research, in press*, 2015.

B.H. Menze, B.M. Kelm, D.N. Splitthoff, U. Koethe, and F.A. Hamprecht. On oblique random forests. In *Machine Learning and Knowledge Discovery in Databases*, pages 453–469. Springer, 2011.

E.A. Nadaraya. On estimating regression. *Theory of Probability and Its Applications*, 9:141–142, 1964.

K.K. Nicodemus and J.D. Malley. Predictor correlation impacts machine learning algorithms: Implications for genomic studies. *Bioinformatics*, 25: 1884–1890, 2009.

D.N. Politis, J.P. Romano, and M. Wolf. *Subsampling*. Springer, New York, 1999.

A.M. Prasad, L.R. Iverson, and A. Liaw. Newer classification and regression tree techniques: Bagging and random forests for ecological prediction. *Ecosystems*, 9:181–199, 2006.

S.S. Qian, R.S. King, and C.J. Richardson. Two statistical methods for the detection of environmental thresholds. *Ecological Modelling*, 166:87–97, 2003.

G. Louppe, L. Wehenkel, A. Sutera e P. Geurts. Compreensão das importâncias variáveis em florestas de árvores aleatórias. Em C.J.C. Burges, L. Bottou, M. Welling, Z. Ghahramani e K.Q. Weinberger, editores, Advances in Neural Information Processing Systems, páginas 431–439, 2013. JD Malley, J. Kruppa, A. Dasgupta, K.G. Malley e A. Ziegler. Máquinas de probabilidade: estimativa de probabilidade consistente usando máquinas de aprendizagem não paramétricas. Métodos de Informação em Medicina, 51:74–81, 2012. N. Meinshausen. Florestas de regressão quantílica. Journal of Machine Learning Research, 7:983–999, 2006. N. Meinshausen. Garrote Florestal. Jornal Eletrônico de Estatística, 3:1288–1304, 2009. L. Mentch e G. Hooker. Um novo teste para aditividade em alunos supervisionados. arXiv:1406.1845, 2014. L. Mentch e G. Hooker. Árvores de conjunto e CLTs: inferência estatística para aprendizagem supervisionada. Journal of Machine Learning Research, no prelo, 2015. B.H. Menze, B.M. Kelm, DN Splitthoff, U. Koethe e FA Hamprecht. Em florestas aleatórias oblíquas. Em Machine Learning and Knowledge Discovery in Databases, páginas 453–469. Springer, 2011. EA. Nadaraya. Sobre estimar a regressão. Teoria da Probabilidade e suas Aplicações, 9:141–142, 1964. K.K. Nicodemos e JD Malley. A correlação de preditores impacta algoritmos de aprendizado de máquina: implicações para estudos genômicos. Bioinformática, 25: 1884–1890, 2009. DN Politis, JP Romano e M. Wolf. Subamostragem. Springer, Nova York, 1999. SOU. Prasad, L.R. Iverson e A. Liaw. Técnicas mais recentes de classificação e árvore de regressão: Bagging e florestas aleatórias para previsão ecológica. Ecossistemas, 9: 181–199, 2006. SS Qian, RS. King e CJ Richardson. Dois métodos estatísticos para a detecção de limiares ambientais. Modelagem Ecológica, 166:87–97, 2003.

A. Rieger, T. Hothorn, and C. Strobl. *Random forests with missing values in the covariates*. Technical Report 79, University of Munich, Munich, 2010.

A. Saffari, C. Leistner, J. Santner, M. Godec, and H. Bischof. On-line random forests. In *IEEE 12th International Conference on Computer Vision Workshops*, pages 1393–1400, 2009.

D.F. Schwarz, I.R. König, and A. Ziegler. On safari to random jungle: A fast implementation of random forests for high-dimensional data. *Bioinformatics*, 26:1752–1758, 2010.

E. Scornet. On the asymptotics of random forests. *Journal of Multivariate Analysis, in press*, 2015a.

E. Scornet. Random forests and kernel methods. *arXiv:1502.03836*, 2015b.

E. Scornet, G. Biau, and J.-P. Vert. Consistency of random forests. *The Annals of Statistics*, 43:1716–1741, 2015.

M.R. Segal. Regression trees for censored data. *Biometrics*, 44:35–47, 1988.

J. Shotton, A. Fitzgibbon, M. Cook, T. Sharp, M. Finocchio, R. Moore, A. Kipman, and A. Blake. Real-time human pose recognition in parts from single depth images. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 1297–1304, 2011.

C.J. Stone. Consistent nonparametric regression. *The Annals of Statistics*, 5:595–645, 1977.

C.J. Stone. Optimal rates of convergence for nonparametric estimators. *The Annals of Statistics*, 8:1348–1360, 1980.

C.J. Stone. Optimal global rates of convergence for nonparametric regression. *The Annals of Statistics*, 10:1040–1053, 1982.

C. Strobl, A.-L. Boulesteix, T. Kneib, T. Augustin, and A. Zeileis. Conditional variable importance for random forests. *BMC Bioinformatics*, 9: 307, 2008.

V. Svetnik, A. Liaw, C. Tong, J.C. Culberson, R.P. Sheridan, and B.P. Feuston. Random forest: A classification and regression tool for compound classification and QSAR modeling. *Journal of Chemical Information and Computer Sciences*, 43:1947–1958, 2003.

A. Rieger, T. Hothorn e C. Strobl. Florestas aleatórias com valores ausentes nas covariáveis. Relatório Técnico 79, Universidade de Munique, Munique, 2010. A. Saffari, C. Leistner, J. Santner, M. Godec e H. Bischof. Florestas aleatórias on-line. Na 12ª Conferência Internacional IEEE sobre Workshops de Visão Computacional, páginas 1393–1400, 2009. D.F. Schwarz, I.R. K¨onig e A. Ziegler. No safari para a s elva aleatória: uma implementação rápida de florestas aleatórias para dados de alta dimensão. Bioinformática, 26:1752–1758, 2010. E. Scornet. Sobre a assintótica de florestas aleatórias. Journal of Multivariate Analysis, no prelo, 2015a. E. Scornet. Florestas aleatórias e métodos de kernel. arXiv:1502.03836, 2015b. E. Scornet, G. Biau e J.-P. Verde. Consistência de florestas aleatórias. The Annals of Statistics, 43: 1716–1741, 2015. MR Segal. Árvores de regressão para dados censurados. Bio metria, 44:35–47, 1988. J. Shotton, A. Fitzgibbon, M. Cook, T. Sharp, M. Finocchio, R. Moore, A. Kipman e A. Blake. Reconhecimento de pose humana em tempo real em partes de imagens de profundidade única. Na Conferência IEEE sobre Visão Computacional e Reconhecimento de Padrões, páginas 1297–1304, 2011. CJ Stone. Regressão não paramétrica consistente. The Annals of Statistics, 5:595–645, 1977. CJ Stone. Taxas ótimas de convergência para estimadores não paramétricos. The Annals of Statistics, 8: 1348–1360, 1980. CJ Stone. Taxas globais ótimas de convergência para regressão não paramétrica. Os Anais de Estatística, 10:1040–1053, 1982. C. Strobl, A.-L. Boulesteix, T. Kneib, T. Augustin e A. Zeileis. Importância da variável condicional para florestas aleatórias. BMC Bioinformatics, 9: 307, 2008. V. Svetnik, A. Liaw, C. Tong, JC Culberson, RP Sheridan e B.P. Feuston. Floresta aleatória: uma ferramenta de classificação e regressão para classificação de compostos e modelagem QSAR. Jornal de Informação Química e Ciências da Computação, 43:1947–1958, 2003.

L. Tolo̧si and T. Lengauer. Classification with correlated features: Unreliability of feature ranking and solutions. *Bioinformatics*, 27:1986–1994, 2011.

A.K.Y. Truong. *Fast Growing and Interpretable Oblique Trees via Logistic Regression Models*. PhD thesis, University of Oxford, Oxford, 2009.

H. Varian. Big data: New tricks for econometrics. *Journal of Economic Perspectives*, 28:3–28, 2014.

S. Wager. Asymptotic theory for random forests. *arXiv:1405.0352*, 2014.

S. Wager, T. Hastie, and B. Efron. Confidence intervals for random forests: The jackknife and the infinitesimal jackknife. *Journal of Machine Learning Research*, 15:1625–1651, 2014.

G.S. Watson. Smooth regression analysis. *Sankhyā Series A*, pages 359–372, 1964.

J. Welbl. Casting random forests as artificial neural networks (and profiting from it). In X. Jiang, J. Hornegger, and R. Koch, editors, *Pattern Recognition*, pages 765–771. Springer, 2014.

S.J. Winham, R.R. Freimuth, and J.M. Biernacka. A weighted random forests approach to improve predictive performance. *Statistical Analysis and Data Mining: The ASA Data Science Journal*, 6:496–505, 2013.

D. Yan, A. Chen, and M.I. Jordan. Cluster forests. *Computational Statistics & Data Analysis*, 66:178–192, 2013.

F. Yang, J. Wang, and G. Fan. Kernel induced random survival forests. *arXiv:1008.3952*, 2010.

Z. Yi, S. Soatto, M. Dewan, and Y. Zhan. Information forests. In *2012 Information Theory and Applications Workshop*, pages 143–146, 2012.

R. Zhu, D. Zeng, and M.R. Kosorok. Reinforcement learning trees. *Journal of the American Statistical Association, accepted*, 2015.

A. Ziegler and I.R. König. Mining data with random forests: Current options for real-world applications. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 4:55–63, 2014.

L. Tolo̧si e T. Lengauer. Classificação com recursos correlacionados: Falta de confiabilidade na classificação de recursos e soluções. Bioinformática, 27:1986–1994, 2011. A.K.Y. Truong. Árvores oblíquas interpretáveis e de crescimento rápido por meio de modelos de regressão logística. Tese de doutorado, Universidade de Oxford, Oxford, 2009. H. Varian. Big data: novos truques para econometria. Journal of Economic Perspectives, 28:3–28, 2014. S. Wager. Teoria assintótica para florestas aleatórias. arXiv:1405.0352, 2014. S. Wager, T. Hastie e B. Efron. Intervalos de confiança para florestas aleatórias: O canivete e o canivete infinitesimal. Journal of Machine Learning Research, 15: 1625–1651, 2014. GS Watson. Análise de regressão suave. Sankhyā Série A, páginas 359–372, 1964. J. Welbl. Transformar florestas aleatórias em redes neurais artificiais (e lucrar com isso). Em X. Jiang, J. Hornegger e R. Koch, editores, Pattern Recognition, páginas 765–771. Springer, 2014. SJ. Winham, RR Freimuth e JM Biernacka. Uma abordagem de florestas aleatórias ponderadas para melhorar o desempenho preditivo. Análise Estatística e Mineração de Dados: The ASA Data Science Journal, 6:496–505, 2013. D. Yan, A. Chen e M.I. Jordânia. Florestas aglomeradas. Estatística Computacional e Análise de Dados, 66:178–192, 2013. F. Yang, J. Wang e G. Fan. O kernel induziu florestas de sobrevivência aleatórias. arXiv:1008.3952, 2010. Z. Yi, S. Soatto, M. Dewan e Y. Zhan. Florestas de informação. Em 2012, Workshop de Teoria e Aplicações da Infor mação, páginas 143–146, 2012. R. Zhu, D. Zeng e MR Kosorok. Árvores de aprendizagem por reforço. Journal of the American Statistical Association, aceito, 2015. A. Ziegler e I.R. K¨onig. Mineração de dados com florestas aleatórias: opções atuais para aplicações do mundo real. Revisões interdisciplinares de Wiley: mineração de dados e descoberta de conhecimento, 4:55–63, 2014.

41

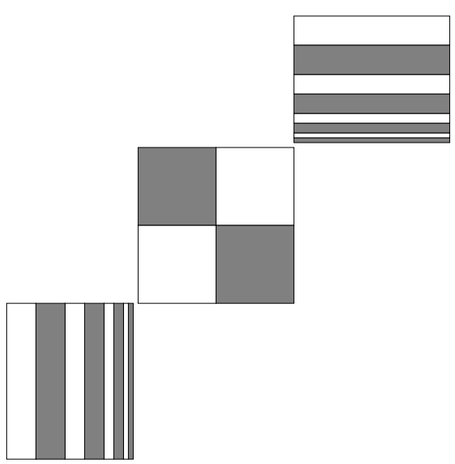


Figure 4: An example of a distribution for which greedy random forests are inconsistent. The distribution of $\mathbf{X}$ is uniform on the union of the three large squares. White areas represent the set where $m(\mathbf{x}) = 0$ and grey where $m(\mathbf{x}) = 1$.



Figura 4: Um exemplo de distribuição para a qual florestas aleatórias gananciosas são inconsistentes. A distribuição de X é uniforme na união dos três grandes quadrados. As áreas brancas representam o conjunto onde m(x) $= 0$ e cinza onde$m$ (x) $= 1$.