TREES
and
RANDOM FORESTS

ÁRVORES
and
FLORESTAS ALEATÓRIAS

TREES

From “Decision Tree Algorithm Explained with Examples” (08/2021)
https://www.mygreatlearning.com/blog/decision-tree-algorithm/

Assumptions:

1- Discretization of continuous variables is required

2- The data taken for training should be wholly considered as root

3- Distribution of records is done in a recursive manner on the basis of attribute values.

ÁRVORES

Extraído de “Algoritmo de árvore de decisão explicado com exemplos” (08/2021) https://www.mygreatlearning.com/blog/decision-tree-algorithm/

Suposições:

1- É necessária discretização de variáveis contínuas

2- Os dados retirados para treinamento devem ser considerados integralmente como raiz

3- A distribuição dos registros é feita de forma recursiva com base nos valores dos atributos.

TREES- Processes involved in Decision Making

From “Decision Tree Algorithm Explained with Examples” (08/2021)
https://www.mygreatlearning.com/blog/decision-tree-algorithm/

1-Entropy

2-Information Gain:

Information Gain = Entropy of Parent – sum (weighted % * Entropy of Child)

Weighted % = Number of observations in particular child/sum
(observations in all child nodes)

3-Gini - “grau de variedade” em cada nó (busca-se variedade zero)

4-Reduction in Variance

-tree works for regression and the output is continuous
-criteria of splitting are selected only when the variance is reduced to minimum

TREES - Processos envolvidos na tomada de decisões

Extraído de “Algoritmo de árvore de decisão explicado com exemplos”
(08/2021) https://www.mygreatlearning.com/blog/decision-tree-algorithm/

1-Entropia

2-Ganho de informação:

Ganho de informação = Entropia do pai - soma (% ponderada * Entropia do filho)

% ponderada = Número de observações em determinado filho/soma (observações em todos os nós filhos)

3-Gini - “grau de variedade” em cada nó (busca-se variedade zero)

4-Redução da Variância

-tree funciona para regressão e a saída é contínua -critérios de divisão são selecionados somente quando a variância é reduzida ao mínimo

TREES - ALGORITHMS

From “Decision Tree Algorithm Explained with Examples” (08/2021)
https://www.mygreatlearning.com/blog/decision-tree-algorithm/

ID3 - Entropy / Information Gain

C4.5 - **NORMALIZED** information gain

CART

-greedy algorithm to reduce cost function
-for classification, Gini index cost function
-for regression, sum squared error

ÁRVORES - ALGORITMO S

Extraído de “Algoritmo de árvore de decisão explicado com exemplos”
(08/2021) https://www.mygreatlearning.com/blog/decision-tree-algorithm/

ID3 - Entropia/Ganho de Informação

C4.5 - Ganho de informação NORMALIZADO

□= RT

-algoritmo ganancioso para reduzir a função de custo -para classificação, função de custo do índice de Gini -para regressão, soma quadrada do erro

TREES – RANDOM FORESTS

From “An intuitive explanation of random forests” (08/2021)
https://towardsdatascience.com/an-intuitive-explanation-of-random-forests-109b04bca343
“The Intuition behind Random Forest”(08/2021) – https://www.kaggle.com/general/191828

WHY ?

To foster PRECISION (decrease VARIANCE + maintain BIAS)
→ FLEXIBILITY to unseen examples

BIAS and VARIANCE - (STATQUEST)
https://www.youtube.com/watch?v=EuBBz3bI-aA

RANDOM FORESTS: BUILDING, USING, EVALUATING - (STATQUEST)
https://www.youtube.com/watch?v=J4Wdy0Wc_xQ

ÁRVORES – FLORESTAS ALEATÓRIAS

Extraído de “Uma explicação intuitiva de florestas aleatórias” (08/2021)
https://towardsdatascience.com/an-intuitive-explanation-of-random-forests-109b04bca343 “A intuição por trás da floresta aleatória”(08/2021) - https://www.kaggle.com/general/191828

POR QUE ?

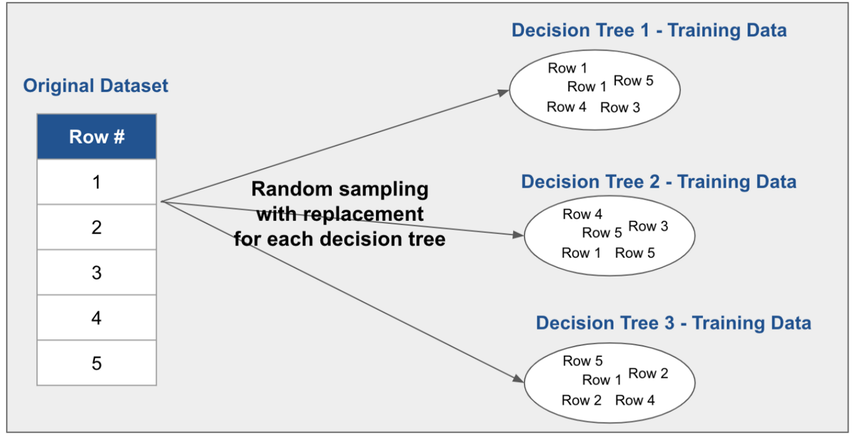
Para promover a PRECISÃO (diminuir a VARIÂNCIA **+**manter o BIAS)→ FLEXIBILIDADE para exemplos invisíveis

BIAS e VARIÂNCIA - (STATQUEST)
https://www.youtube.com/watch?v□EuBBz3bI-aA

FLORESTAS ALEATÓRIAS: CONSTRUINDO, USANDO, AVALIANDO - (STATQUEST) https://www.youtube.com/watch?v□J4Wdy0Wc□xQ

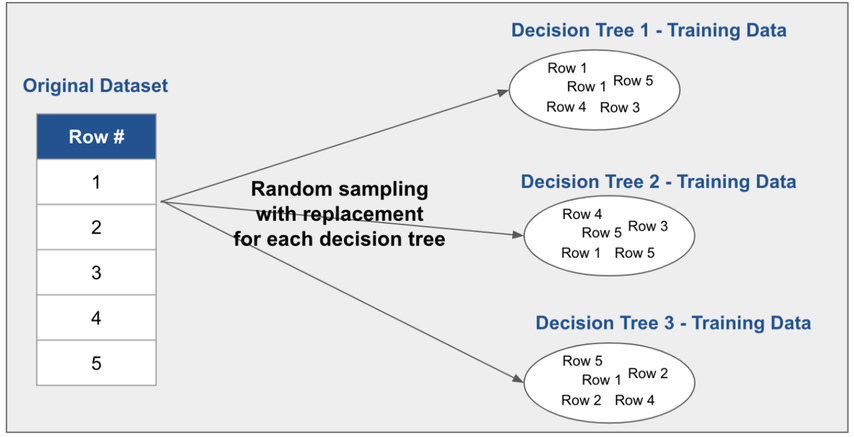
TREES – RANDOM FORESTS

From “An intuitive explanation of random forests” (08/2021)
https://towardsdatascience.com/an-intuitive-explanation-of-random-forests-109b04bca343



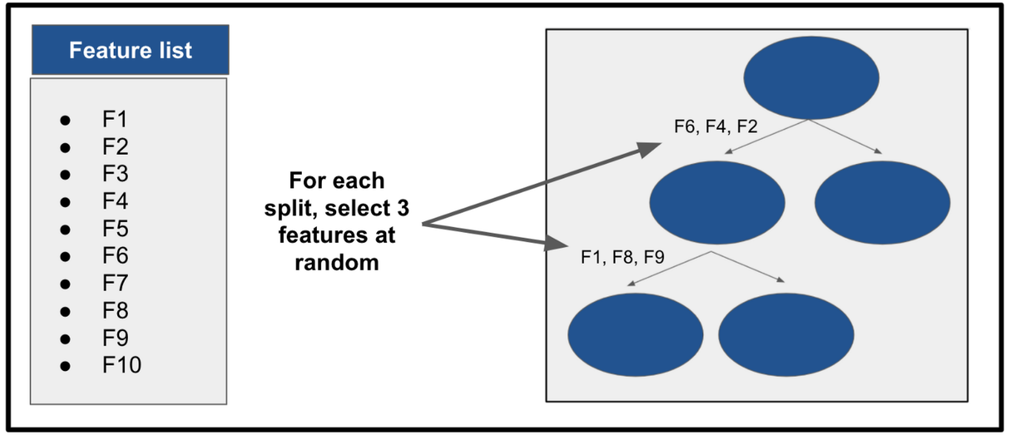
ÁRVORES – FLORESTAS ALEATÓRIAS

Extraído de “Uma explicação intuitiva de florestas aleatórias” (08/2021)
https://towardsdatascience.com/an-intuitive-explanation-of-random-forests-109b04bca343



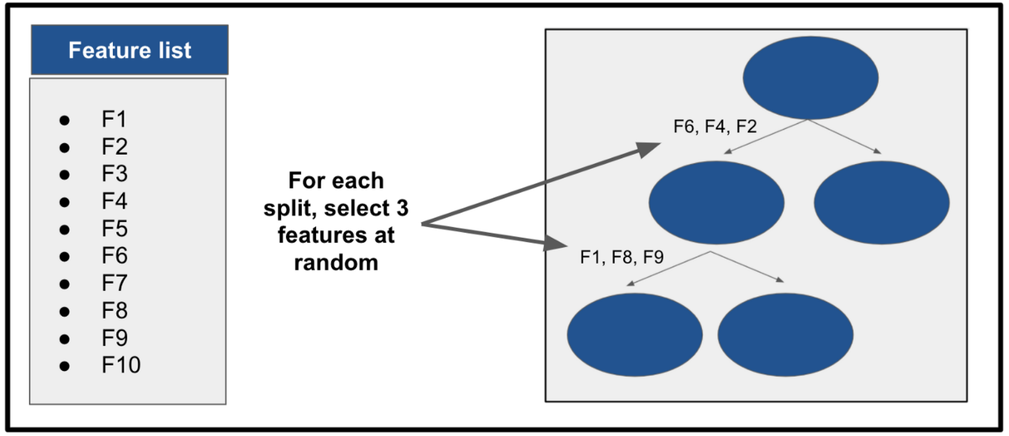
TREES – RANDOM FORESTS

From “An intuitive explanation of random forests” (08/2021)
https://towardsdatascience.com/an-intuitive-explanation-of-random-forests-109b04bca343



ÁRVORES – FLORESTAS ALEATÓRIAS

Extraído de “Uma explicação intuitiva de florestas aleatórias” (08/2021)
https://towardsdatascience.com/an-intuitive-explanation-of-random-forests-109b04bca343



TREES– RANDOM FORESTS

From “An intuitive explanation of random forests” s\ (08/2021)
https://towardsdatascience.com/an-intuitive-explanation-of-random-forests-109b04bca343

INTUITION

Random forest algorithm encourages **DIVERSITY**:

- each decision tree is trained on a DIFFERENT SUBSET of the data (each decision tree “knows” a different subset of the data)
- selecting a RANDOM SUBSET(of size M) of the full list of features at every split

This process generates trees that have been exposed to DIFFERENT INFORMATION, which are then AGGREGATED together

ÁRVORES – FLORESTAS ALEATÓRIAS

De “Uma explicação intuitiva de florestas aleatórias” s\ (08/2021)
https://towardsdatascience.com/an-intuitive-explanation-of-random-forests-109b04bca343

INTUIÇÃO

O algoritmo de floresta aleatória incentiva a DIVERSIDADE:

- cada árvore de decisão é treinada em um subconjunto diferente de dados (cada árvore de decisão “conhece” um subconjunto diferente de dados)
- selecionando um SUBCONJUNTO ALEATÓRIO (de tamanho M) da lista completa de recursos em cada divisão

Este processo gera árvores que foram expostas a DIFERENTES INFORMAÇÕES, que depois são AGREGADAS.

TREES– RANDOM FORESTS

From “An intuitive explanation of random forests” (08/2021)
https://towardsdatascience.com/an-intuitive-explanation-of-random-forests-109b04bca343

HYPERPARAMETERS

1-MAX FEATURES: how many features are available at each split (common default is the **square root** of the total number of features)

2-COST FUNCTION: method used to identify the best split in each tree — gini impurity, feature importance, etc.

3-NUMBER OF ESTIMATORS: how many trees are in the forest.

4-MAX DEPTH: how far from the root node can each tree grow.

5-MINIMUM SAMPLES FOR A SPLIT: number of records that must be in each node to proceed with another split

ÁRVORES – FLORESTAS ALEATÓRIAS

Extraído de “Uma explicação intuitiva de florestas aleatórias” (08/2021)
https://towardsdatascience.com/an-intuitive-explanation-of-random-forests-109b04bca343

HIPERPARÂMETROS

1-MAX RECURSOS: quantos recursos estão disponíveis em cada divisão (o padrão comum é a raiz quadrada do número total de recursos)

2-FUNÇÃO CUSTO: método utilizado para identificar a melhor divisão em cada árvore – impureza gini, importância da característica, etc.

3-NÚMERO DE ESTIMADORES: quantas árvores existem na floresta.

4-PROFUNDIDADE MÁXIMA: a que distância do nó raiz cada árvore pode crescer.

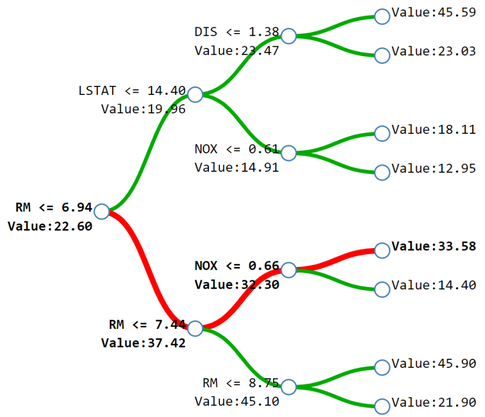
5-AMOSTRAS MÍNIMAS PARA UM SPLIT: quantidade de registros que devem estar em cada nó para prosseguir com outro split

RANDOM FORESTS - INTERPRETABILIDADE

From “Interpreting random forests” (08/2021)
http://blog.datadive.net/interpreting-random-forests/

-breakdown of the prediction, in terms of value changes along the path
-together with feature names that “caused” every value change

INTUITION:
- there is a more “operational” way to define the prediction: through the sequence of **REGIONS of the FEATURE SPACE** that correspond to **each node/decision** in the tree.
- for each decision that a tree (or a forest) makes there is a path (or paths) from the Root of the tree to the leaf, consisting of a series of decisions, guarded by a particular feature
- each decision either adds or subtracts from the value given in the parent node
-the prediction can be defined as the sum of the feature contributions + the “bias” (i.e. the mean given by the topmost region that covers the entire training set).



Prediction: **33.58** ≈ **22.60** (trainset mean) + **14.82**(gain from RM) - **5.12**(loss from RM) + **1.28**(gain from NOX)

RM	LSTAT	NOX	DIST	
3.1	4.5	0.54	2.6	Predict
6.5	16.1	0.12	2.2	Predict
7.1	10.5	0.31	1.8	Predict

CLASSICAL ML BOOK: https://hastie.su.domains/ElemStatLearn/

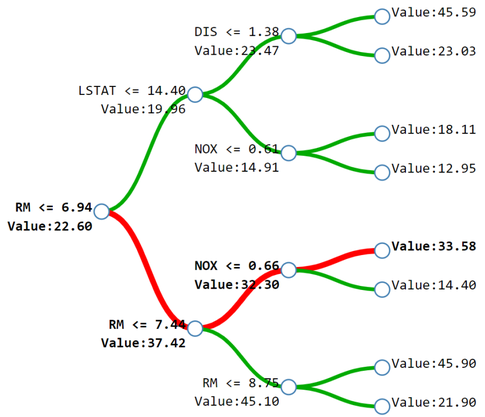
FLORESTAS ALEATÓRIAS - INTERPRETABILIDADE

Extraído de “Interpretando florestas aleatórias” (08/2021)
http://blog.datadive.net/interpreting-random-forests/

-detalhamento da previsão, em termos de mudanças de valor ao longo do caminho - juntamente com nomes de recursos que “ causaram” cada mudança de valor

INTUIÇÃO:
- existe uma forma mais “operacional” de definir a predição: através da sequência de REGIÕES do FEATURE SPACE que correspondem a cada nó/decisão na árvore.

- para cada decisão que uma árvore (ou uma floresta) toma existe um caminho (ou ca minhos) desde a raiz da árvore até à folha, constituído por uma série de decisões, guardadas por uma característica particular
- cada decisão adiciona ou subtrai do valor dado no nó pai - a previsão pode ser definida como a soma das contribuições de recursos + o “viés” (ou seja, a média dada pela região superior que cobre todo o conjunto de treinamento).



Prediction: **33.58** ≈ **22.60** (trainset mean) + **14.82**(gain from RM) - **5.12**(loss from RM) + **1.28**(gain from NOX)

RM	LSTAT	NOX	DIST	
3.1	4.5	0.54	2.6	Predict
6.5	16.1	0.12	2.2	Predict
7.1	10.5	0.31	1.8	Predict

LIVRO CLÁSSICO DE ML: https://hastie.su.domains/ElemStatLearn/