Conceitos Básicos

- O que são **Redes Neurais Artificiais**:

"Modelos computacionais constituídos a partir do estudo de sistemas neuro-biológicos encontrados nos animais e nos seres humanos".

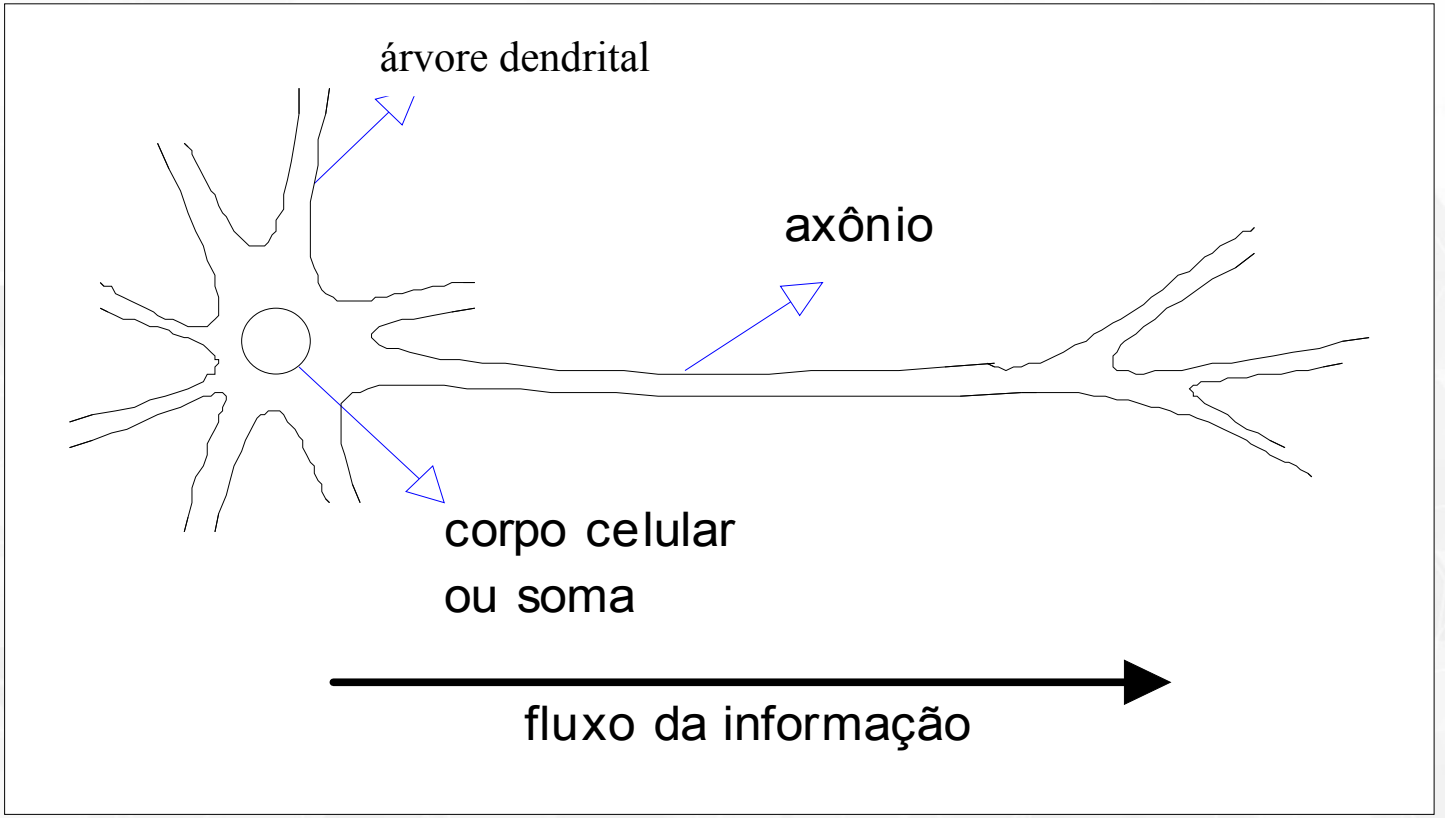
Conceito Básicos-**Neurofisiologia**

- o que faz o cérebro?
  - › **o cérebro controla o comportamento visando garantir a sobrevivência**.
- funcionalidade do cérebro:
  - › **adaptabilidade por intermédio de aprendizado**
  - › **comportamento sensível ao contexto**
  - › **tolerância a erro**
  - › **capacidade de operar com conhecimento parcial**
  - › **grande capacidade de memória**
  - › **capacidade de processamento em tempo real**

O neurônio biológico

Corpo celular: 5 a 50 μm

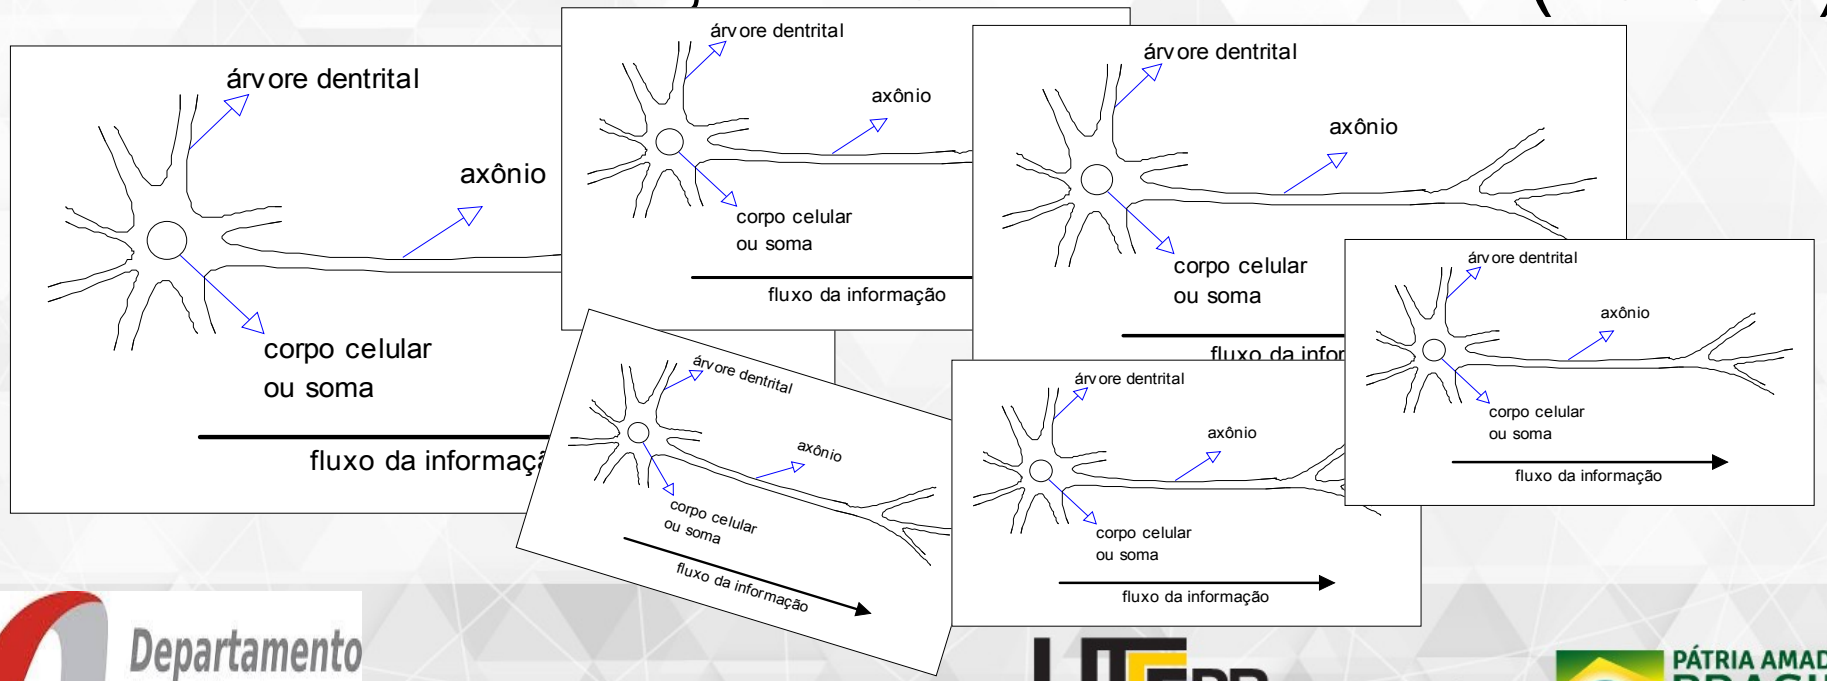
Axônio: 1 μm a até 1m



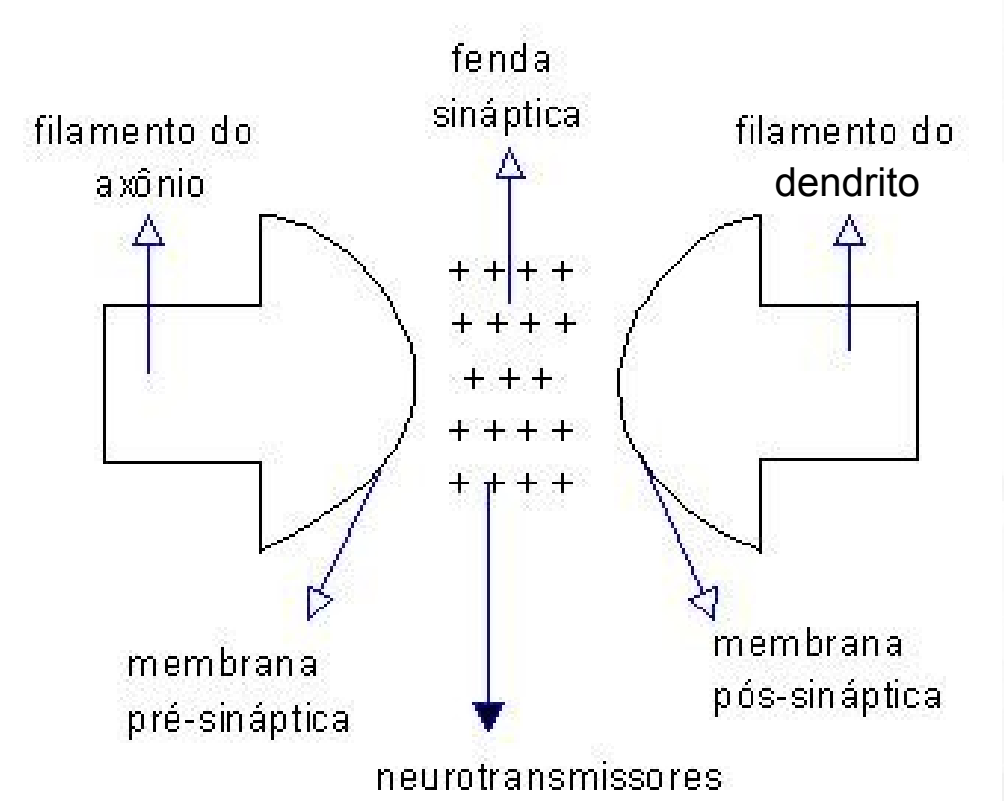
O neurônio biológico

- O cérebro humano possui em torno de 10^{11} neurônios, ou 100 BILHÕES = 100 Giga-neurônios (100.000.000.000)*

- Cada neurônio pode apresentar até 10^{4} conexões com outros neurônios, ou 10 Kilo-conexões (10.000)



O neurônio biológico – ***Sinapses***



Sinapse: ligação entre um axônio de um neurônio, e um dentrito de um outro neurônio posterior.

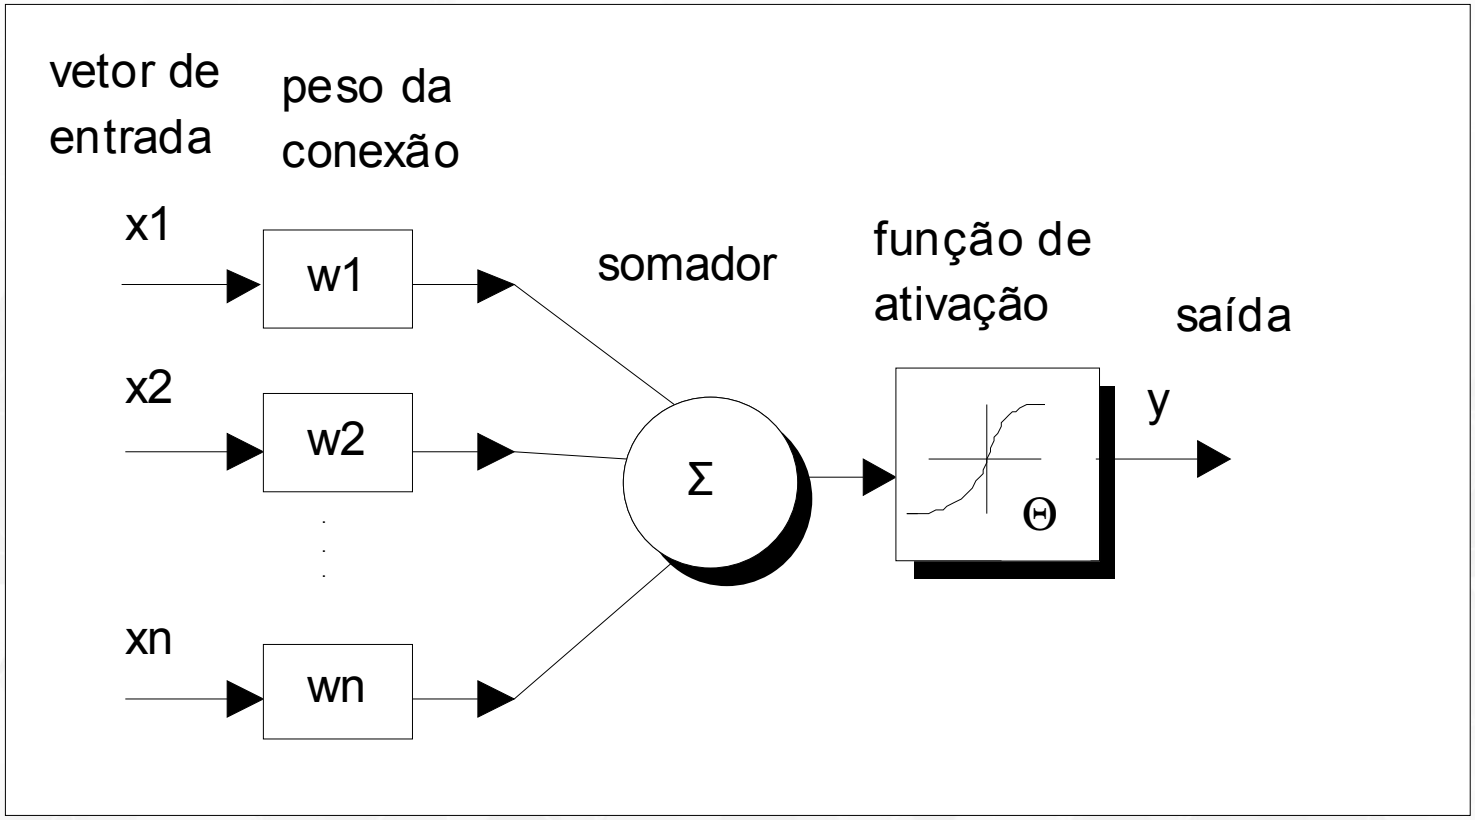
O neurônio biológico no cérebro humano

"Estima-se" que o cérebro pode possuir, portanto, um máximo de 10^{15} conexões, **cada uma podendo armazenar informação, e todas operando em paralelo =** 1 QUADRILHÃO = 1 Peta-conexões (1.000.000.000.000.000) **= mil milhões de milhões**

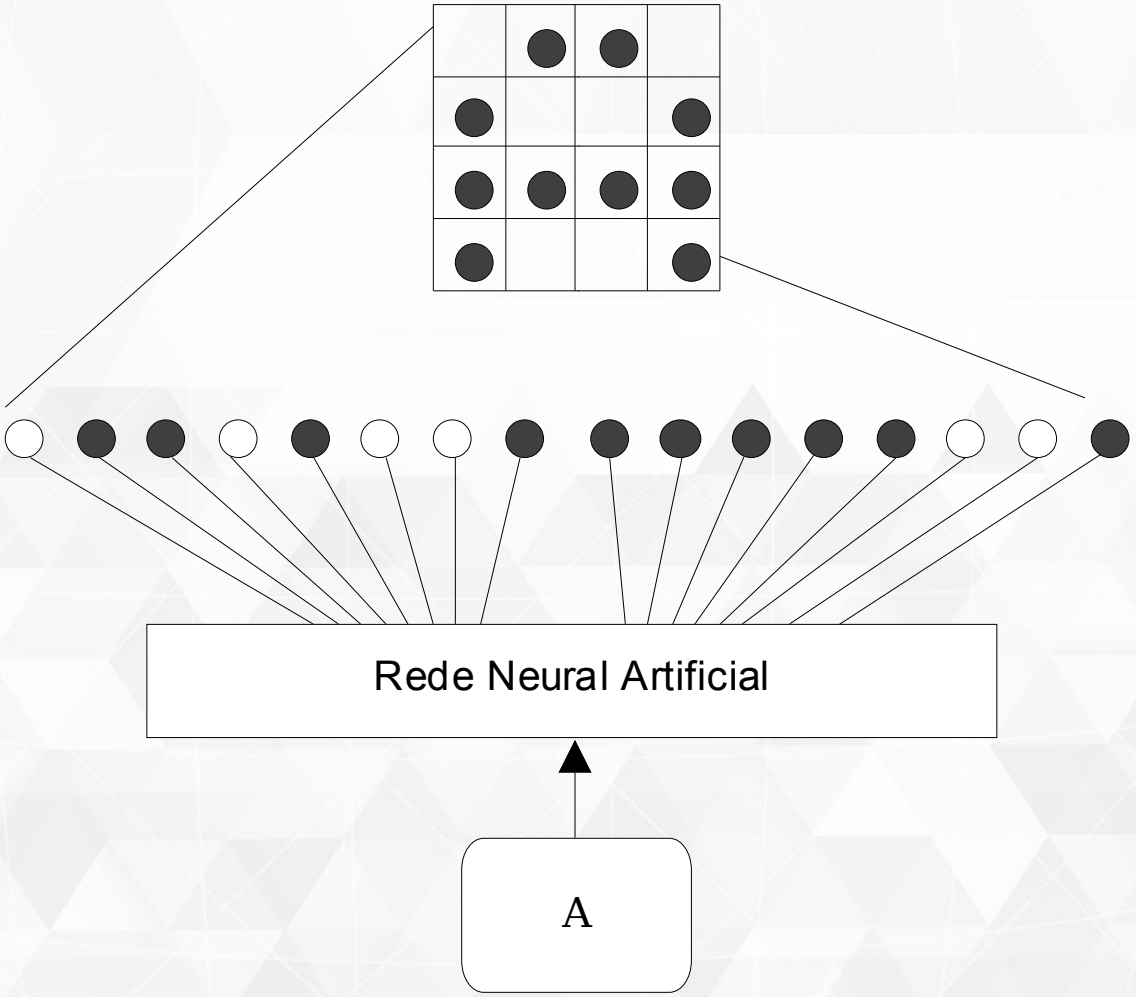
- Uma estimativa mais "realista" indica "**apenas**" 10^{14} conexões (100 Tera-conexões = 100 Trilhões!!) (100.000.000.000.000) = MUITOS BYTES!!!!

* O cérebro humano médio (masculino, 50 anos) possui em torno de 86 bilhões de neurônios (Suzana Herculano-Louzel, 2009). Desse número, 69 bilhões estão situados no cerebelo e 16 bilhões no córtex cerebral.

UM neurônio artificial



Aplicações (~1970...)



Aplicações: MNIST (1998 ~2012)



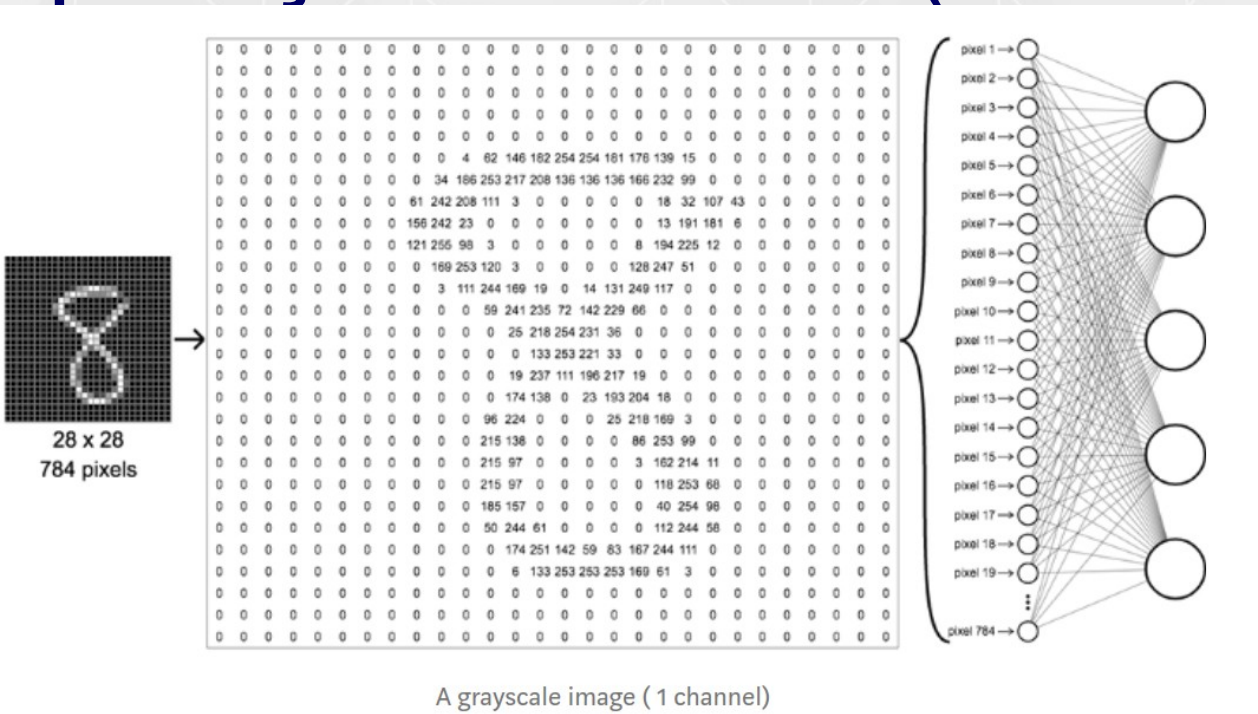
Data & Labels



0
1
2
3
4
5
6
7
8
9

MNIST Dataset and Number Classification [1]

Aplicações: MNIST (1998 ~2012)



A grayscale image (1 channel)

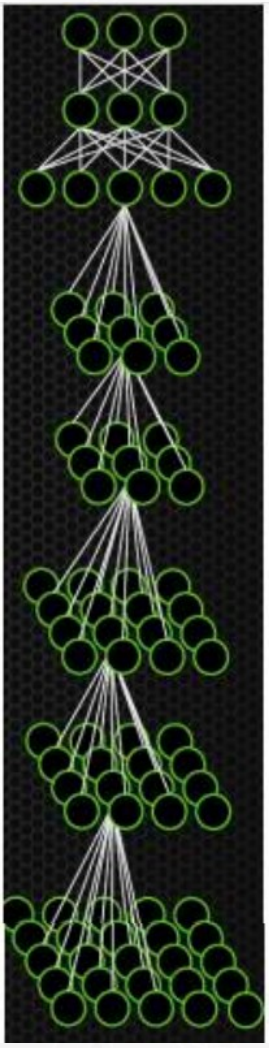
[LeCun et al., 1998],Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. **Gradient-based learning applied to document recognition**. Proc. of the IEEE, 86(11), November 1998. →

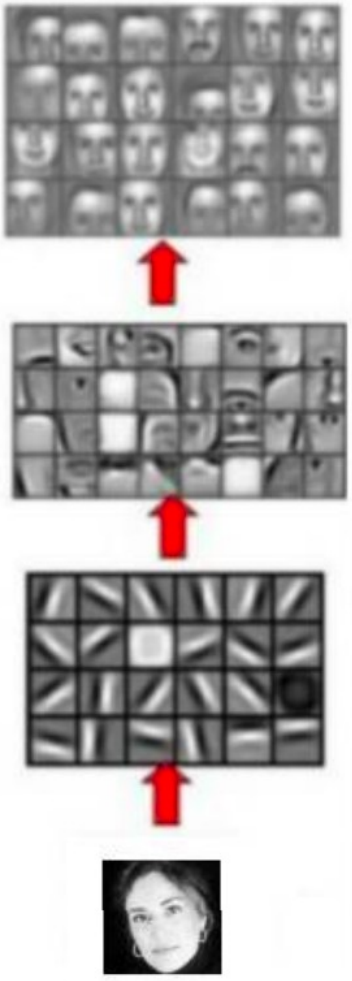
Erro de Classificação: 1 % (RNA "Normal")

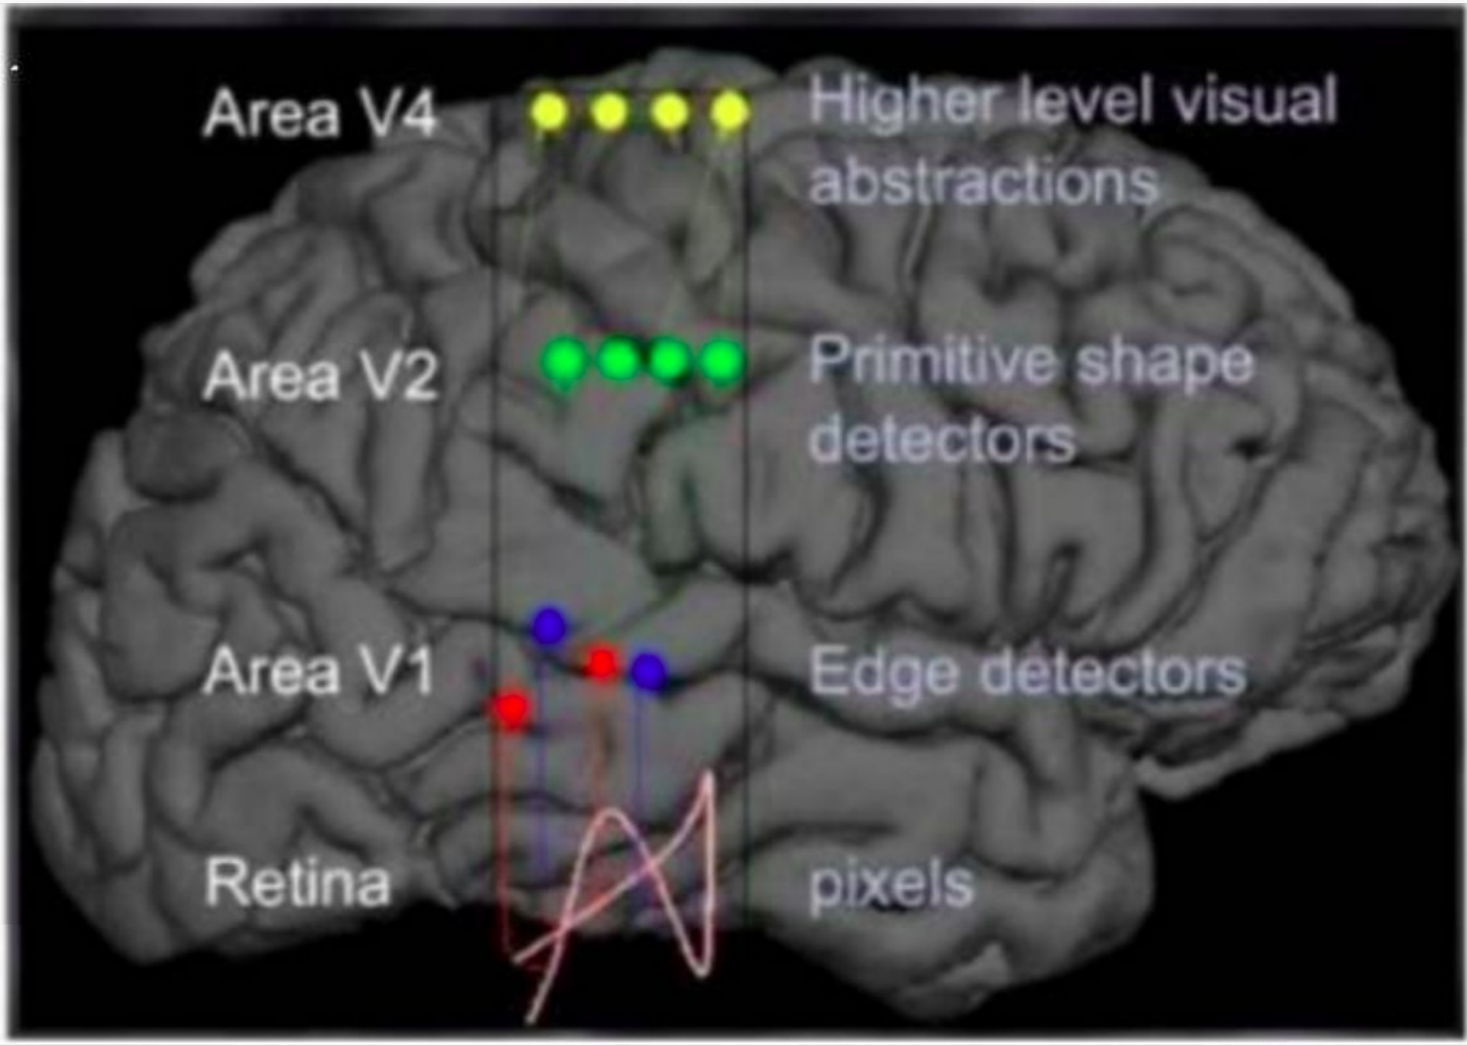
[Ciresan et al., 2012] D. Cireşan, U. Meier, J. Schmidhuber, **Multi-column Deep Neural Networks for Image Classification**, CVPR, 2012, →

Erro de Classificação: 0.23% (RNA "Convolucional"!!!)

Aplicações: “Visão” Artificial



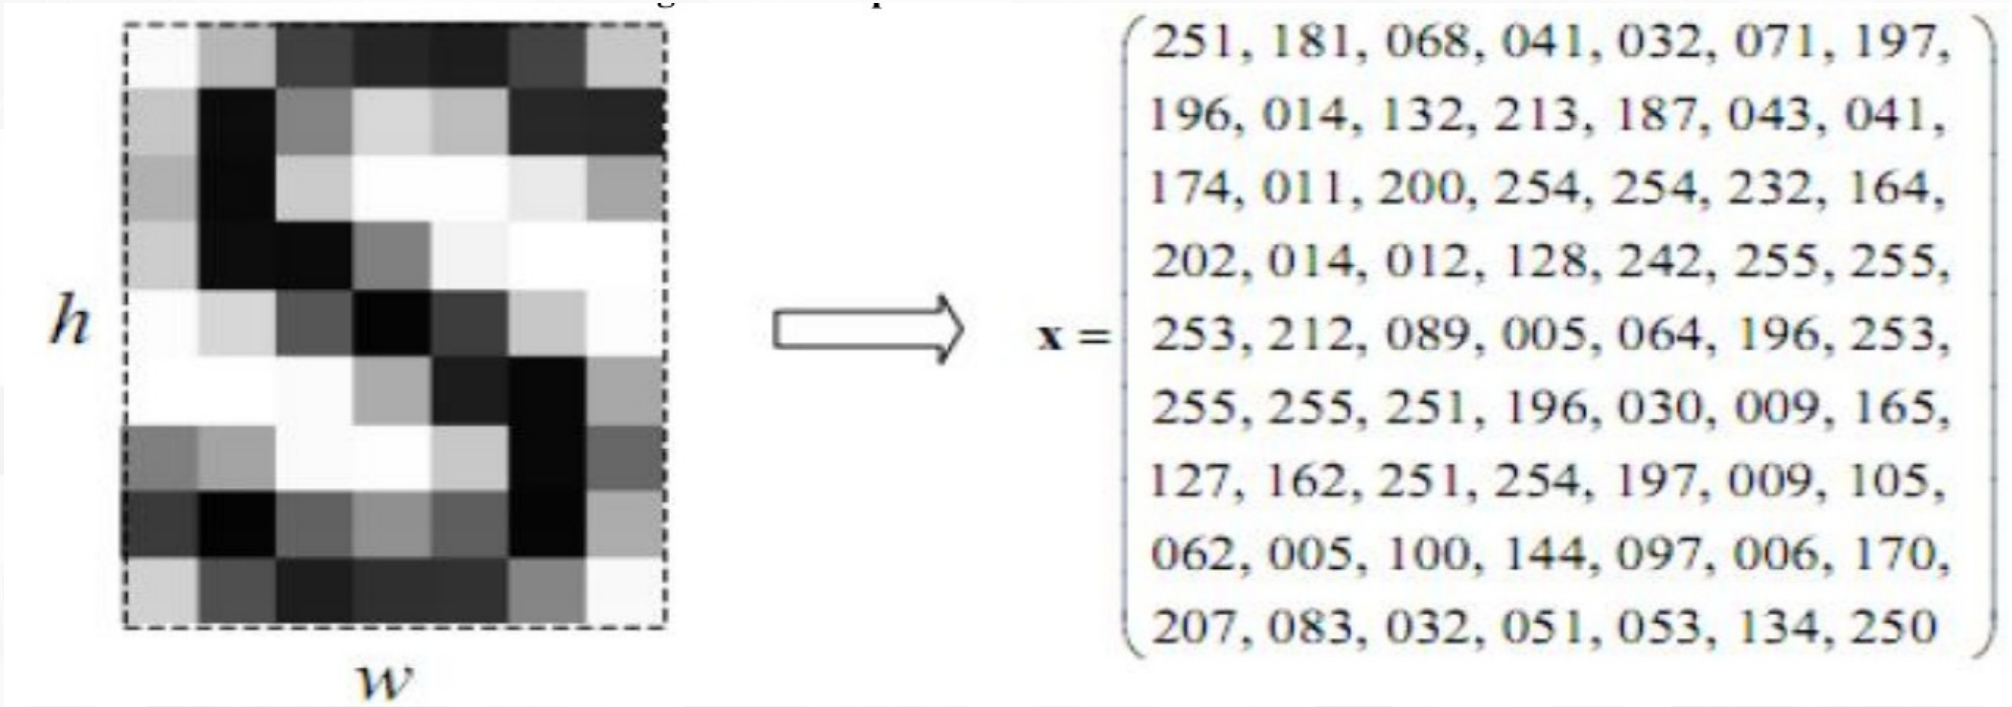




Visão Geral

- Imagens
- Redes Neurais Completamente Conectadas
- Redes Neurais Convolucionais
- Exemplos de CNNs

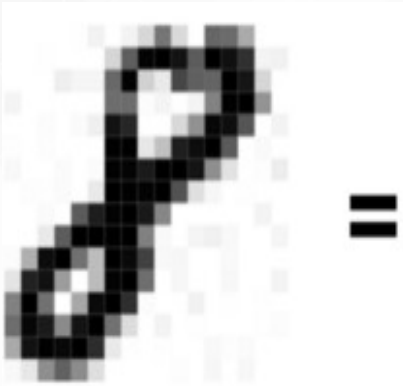
Imagens são números



Toda imagem é uma matriz de valores de pixels

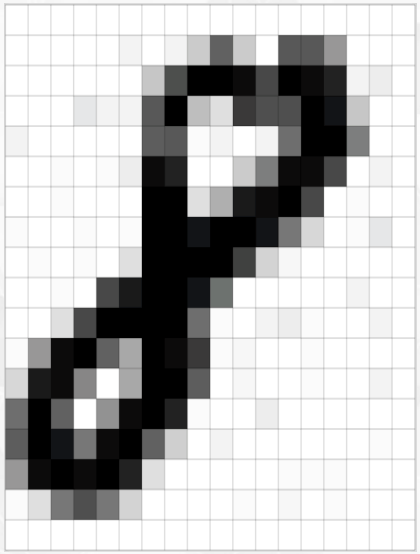
Fonte: Automatic_Bangladeshi_Vehicle_Number_Plate_Recognition_System_using_Neural_Network (2014), Available at: https://www.researchgate.net/publication/284003940

Imagens são números



=

[0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 12, 0, 11, 39, 137, 37, 0, 152, 147, 84, 0, 0, 0, 0,
0, 1, 0, 0, 0, 41, 160, 250, 255, 235, 162, 255, 238, 206, 11, 13, 0, 0, 0, 0, 16, 9, 9, 150, 251, 45, 21, 184, 159, 154, 2
55, 233, 40, 0, 0, 10, 0, 0, 0, 0, 0, 145, 146, 3, 10, 0, 11, 124, 253, 255, 107, 0, 0, 0, 0, 3, 0, 4, 15, 236, 216, 0, 0,
38, 109, 247, 240, 169, 0, 11, 0, 1, 0, 2, 0, 0, 0, 253, 253, 23, 62, 224, 241, 255, 164, 0, 5, 0, 0, 6, 0, 0, 4, 0, 3, 252
, 250, 228, 255, 255, 234, 112, 28, 0, 2, 17, 0, 0, 2, 1, 4, 0, 21, 255, 253, 251, 255, 172, 31, 8, 0, 1, 0, 0, 0, 0, 0, 4,
0, 163, 225, 251, 255, 229, 120, 0, 0, 0, 0, 0, 11, 0, 0, 0, 0, 21, 162, 255, 255, 254, 255, 126, 6, 0, 10, 14, 6, 0, 0, 9
, 0, 3, 79, 242, 255, 141, 66, 255, 245, 189, 7, 8, 0, 0, 5, 0, 0, 0, 0, 26, 221, 237, 98, 0, 67, 251, 255, 144, 0, 8, 0, 0
, 7, 0, 0, 11, 0, 125, 255, 141, 0, 87, 244, 255, 208, 3, 0, 0, 13, 0, 1, 0, 1, 0, 0, 145, 248, 228, 116, 235, 255, 141, 34
, 0, 11, 0, 1, 0, 0, 0, 1, 3, 0, 85, 237, 253, 246, 255, 210, 21, 1, 0, 1, 0, 0, 6, 2, 4, 0, 0, 0, 6, 23, 112, 157, 114, 32
, 0, 0, 0, 0, 2, 0, 8, 0, 7, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]



Fonte: https://medium.com/@ageitgey/

Imagens RGB



Fonte: https://en.wikipedia.org/wiki/Channel_(digital_image)

Imagens RGB

- Canais RGB convertidos para escala de cinza.



R



G



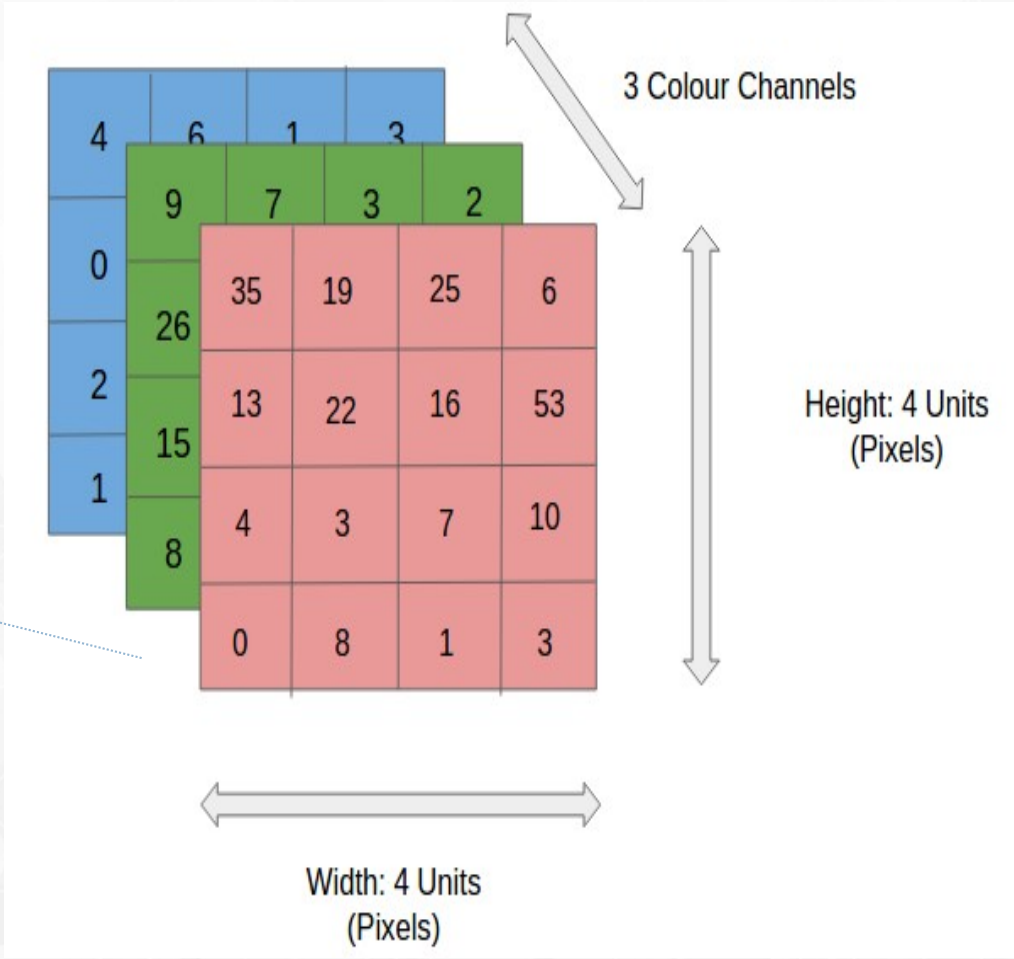
B



Imagens RGB

- Toda imagem RGB é uma estrutura tridimensional.





Datasets de imagens

- CIFAR-100
- MNIST
- ImageNet

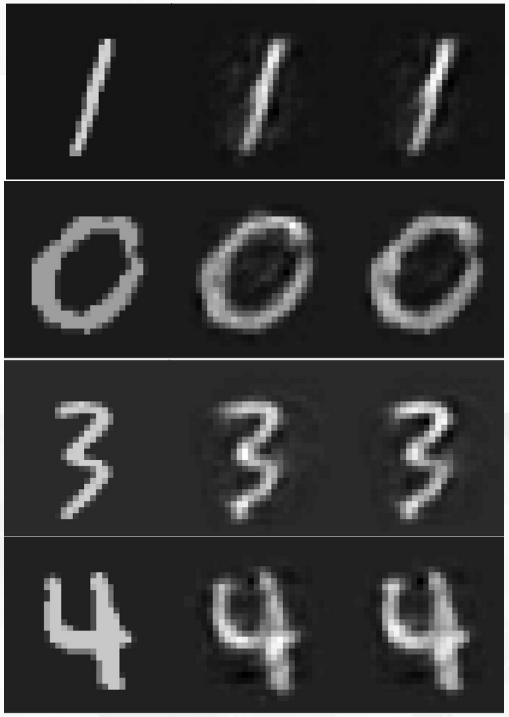
Datasets: CIFAR

- CIFAR-10
  - 60K imagens RGB 32x32
  - Total de 10 classes
    - 6000 imagens por classe.
  - Treinamento/teste: 50K/10K.
- CIFAR-100
  - similar ao CIFAR-10, mas com 100 600 imagens por classe.

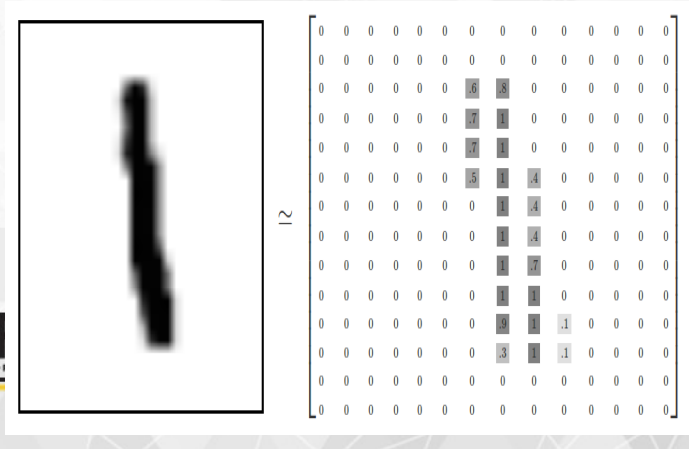


Datasets: MNIST (*handwritten digits dataset*)

- Dataset com 70k exemplos
  - Treinamento: 60k
  - Teste: 10k
- Cada exemplo: 28x28 pixels
- Melhores desempenhos:
  - classificador linear: 12% error
  - (Gaussian) SVM 1.4% error
  - ConvNets <1% error



[http://yann.lecun.com/exdb/mnist/]

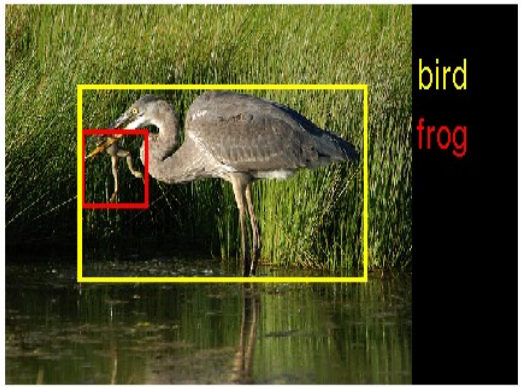


Departamento Acadêmico de Informática

UTFPR
UNIVERSIDADE TECNOLÓGICA FEDERAL DO
CÂMPUS CURITIBA

Datasets: ImageNet

- Tamanho médio das imagens: 482x415 pixels.
- 14M+ de imagens no total
- 1M+ de imagens com “bounding boxes” anotados
- Competições:
  - ILSVRC
  - ImageNet Object Detection Challenge (Kaggle)

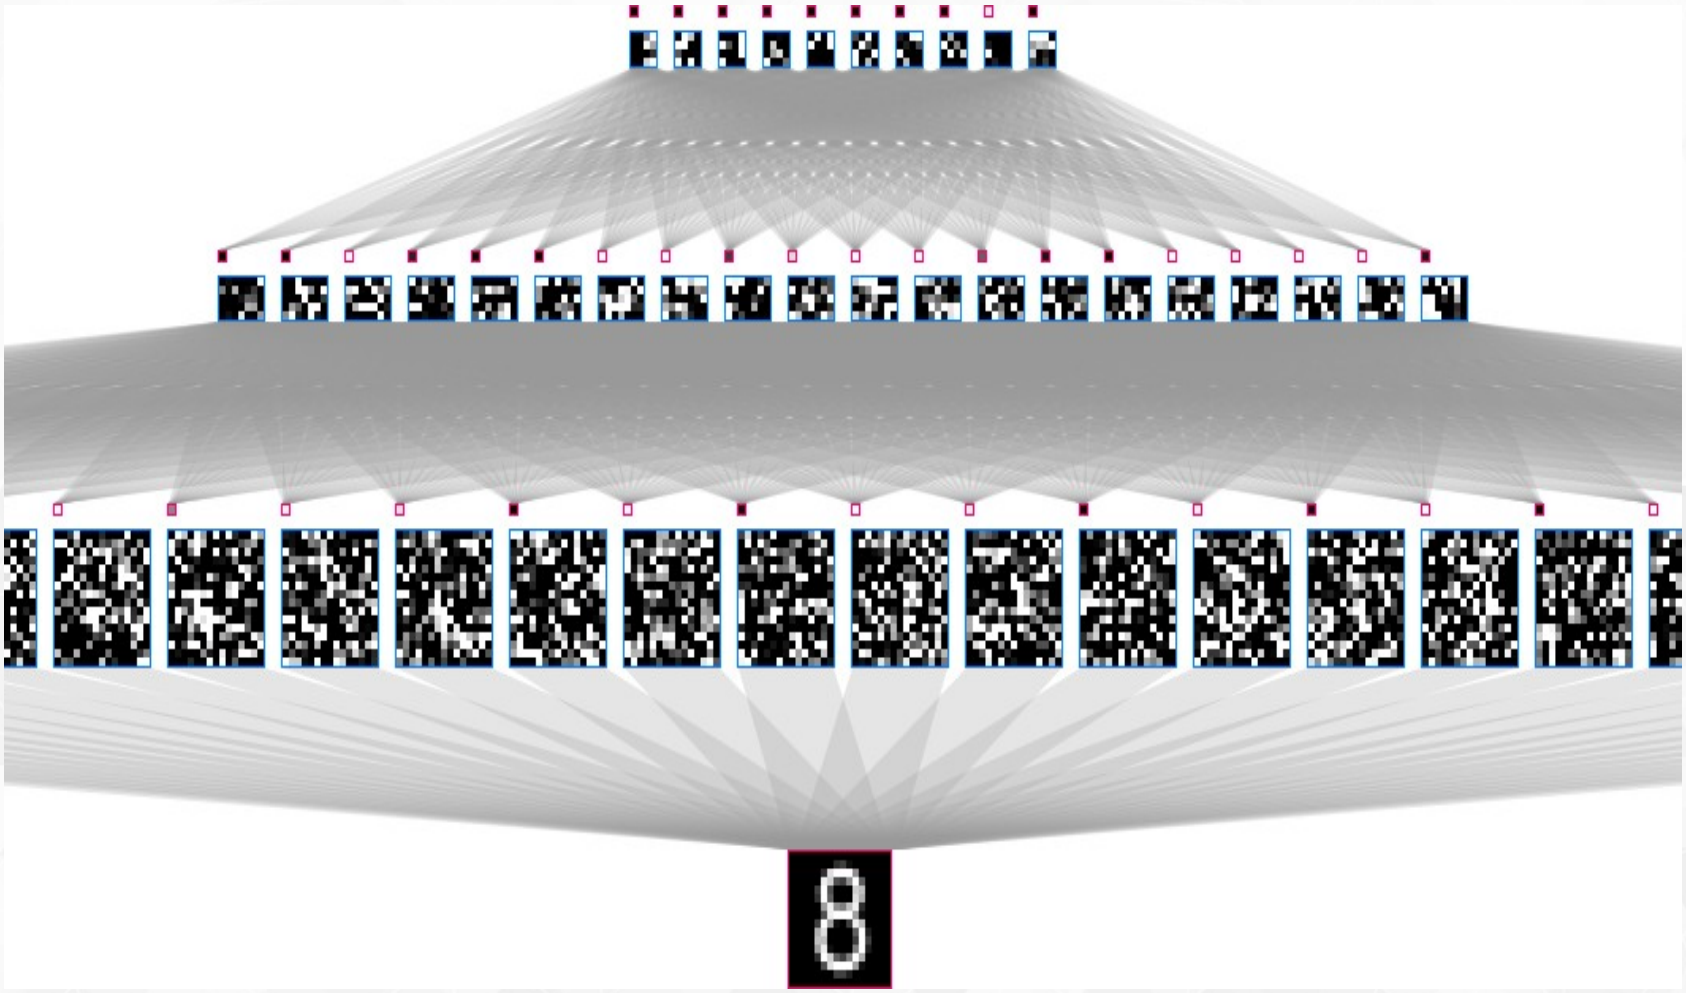


Redes Completamente Conectadas

(Fully Connected Networks)

Em que apresentamos desvantagens do uso de redes completamente conectadas (redes densas) no processamento de imagens.

Redes completamente conectadas



Fonte: http://scs.ryerson.ca/~aharley/neural-networks/

Redes completamente conectadas

- Suponha treinar sobre o MNIST uma rede neural completamente conectada (*fully conected*) para classificação.
- Considere uma única camada oculta com o dobro de unidades da camada de entrada.
- Nesse caso, teríamos da ordem de 10^6 parâmetros para ajustar durante o treinamento!

Redes completamente conectadas

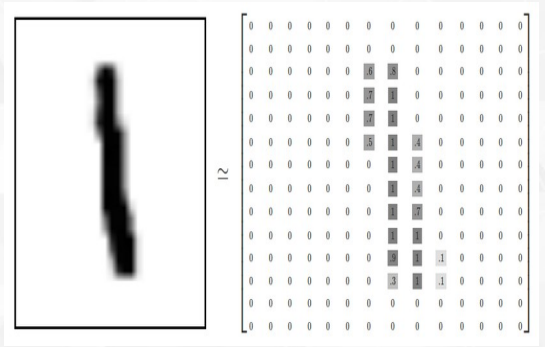


- Quantidade grande de parâmetros
  - risco de sobreajuste (*overfitting*)
- Inadequadas a imagens de alta resolução
  - risco de sobreajuste
- Tempo para computar as ativações/pré-ativações.

Redes completamente conectadas

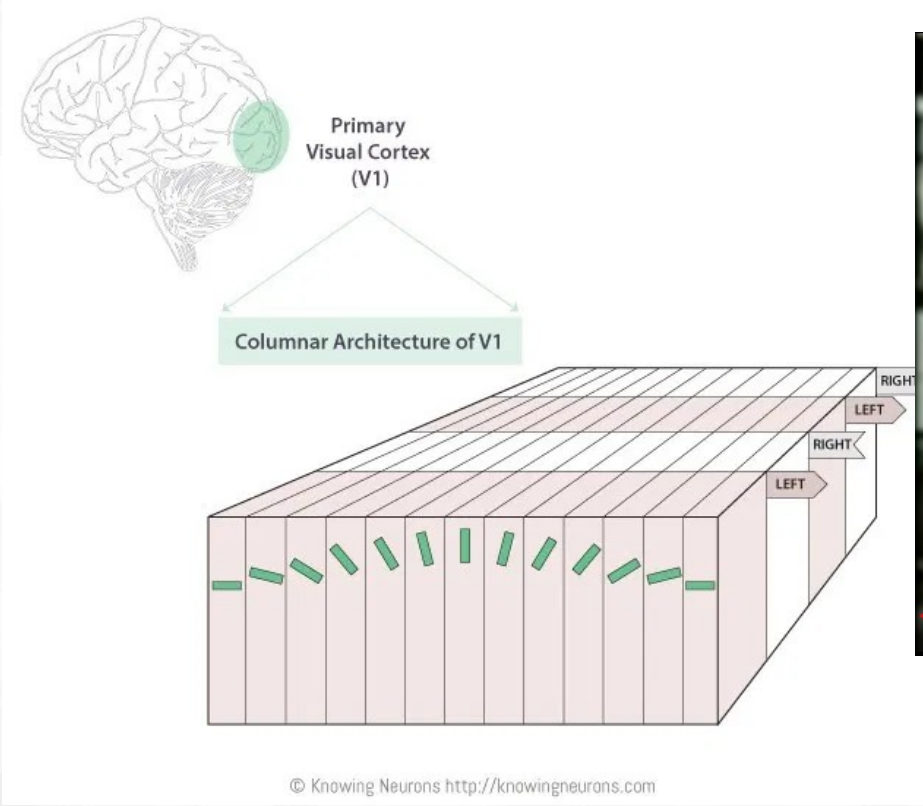


- Ignoram a estrutura espacial existente em imagens
  - Se as imagens são linearizadas (pixels próximos e os localizados em regiões distantes tratados indistintamente.)
  - A própria rede teria que detectar as dependências existentes na estrutura espacial da distribuição subjacente às imagens de entrada.



Redes Neurais Convolucionais *(Convolutional Neural Networks, ConvNet, CNN)*

Experimento de Hubel e Wiesel



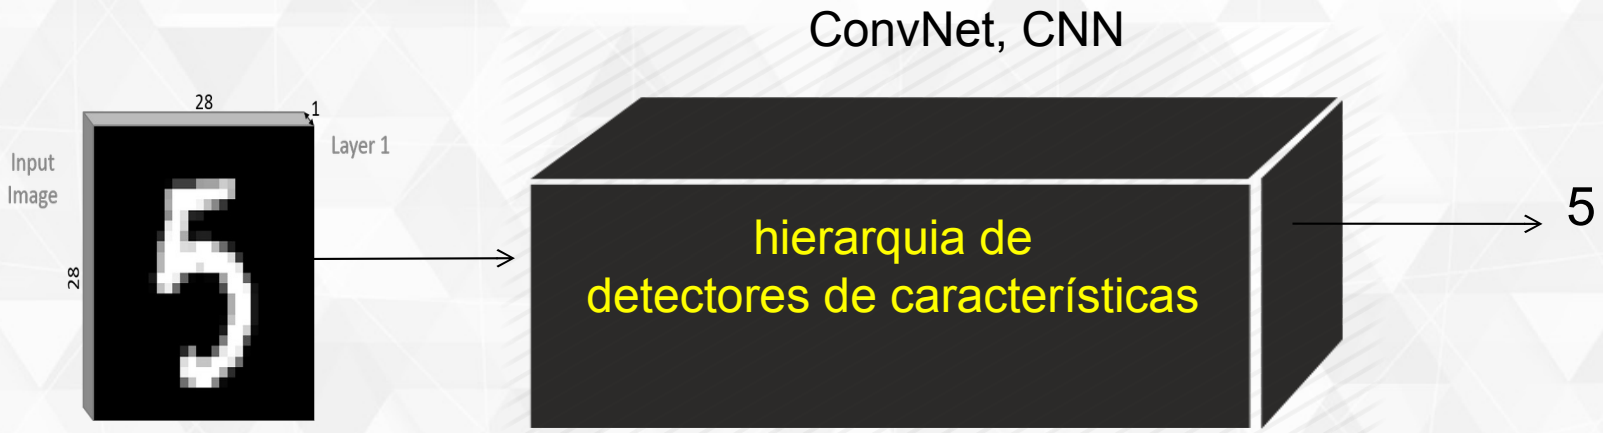


https://www.youtube.com/watch?v=Yoo4GWiAx94

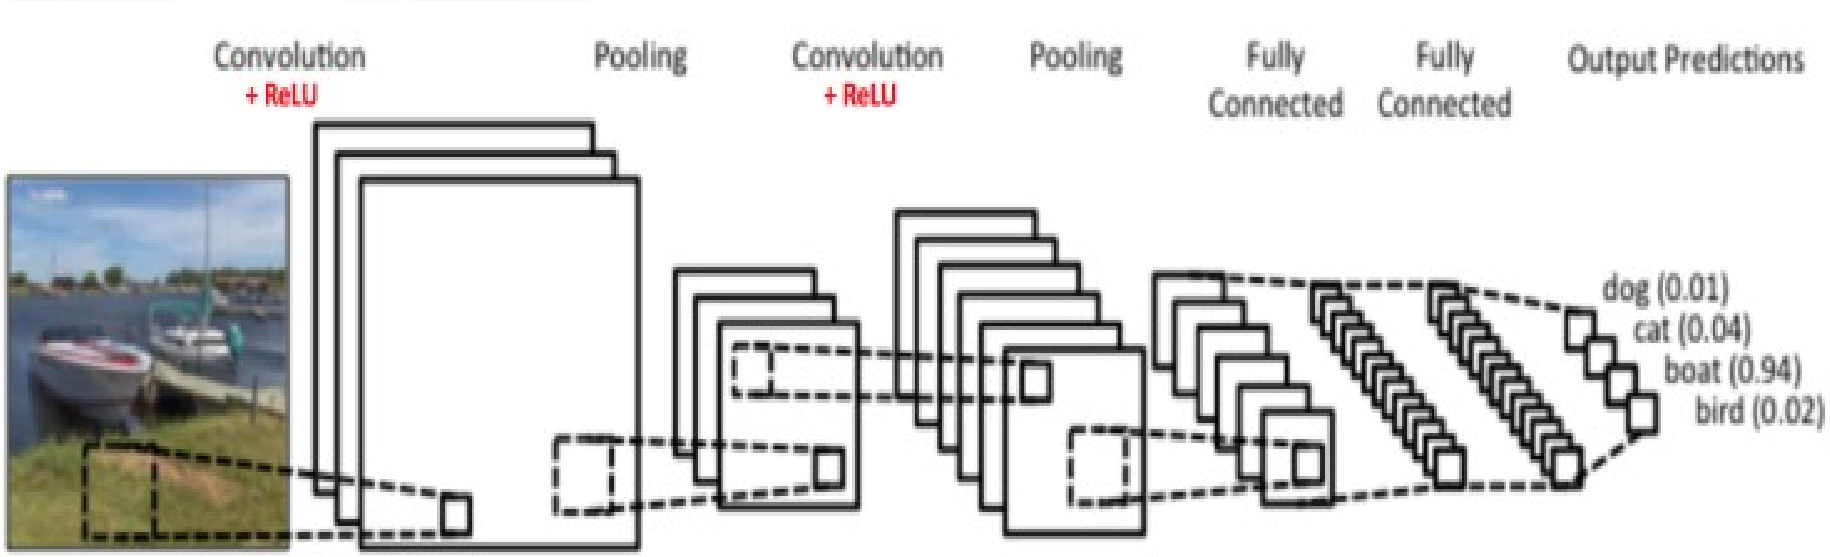
Hubel, D. and Wiesel, T. (1968). Receptive fields and functional architecture of monkey striate cortex. Journal of Physiology.
Fonte: https://knowingneurons.com/2014/10/29/hubel-and-wiesel-the-neural-basis-of-visual-perception/

Rede Neural Convolucional

- Uma CNN é adaptada para explorar a correlação espacial existente em imagens.
  - Inspirada no funcionamento do cérebro (córtex visual).
- É uma rede de propagação adiante (*FF network*).

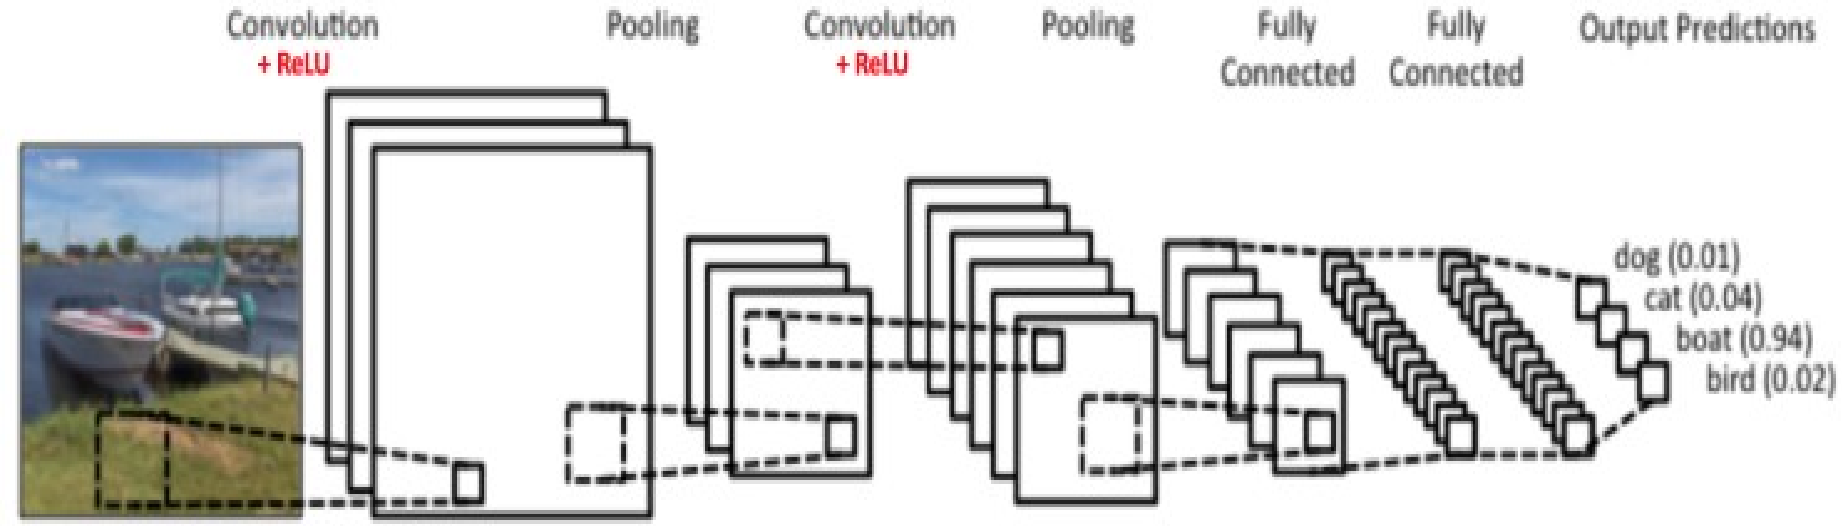


Rede Convolucional - Conceitos



Fonte: https://www.clarifai.com/technology

Rede Convolucional - Conceitos



Fonte: https://www.clarifai.com/technology

Redes Neurais Convolucionais são baseadas em **"4 CONCEITOS CHAVE"**:

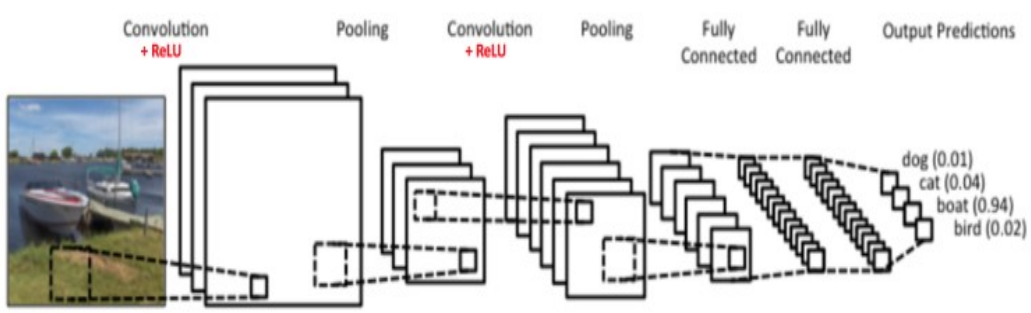
- Funções de Ativação ReLU (*Rectifying Linear Unit***)**

- Saída como "Probabilidade" (*Soft-Max Output Layer***)**

- Convoluções (*Convolutions***)**

- Sub-Amostragem (*Sub-sampling***, *Pooling*)**

Rede Convolucional – ReLU

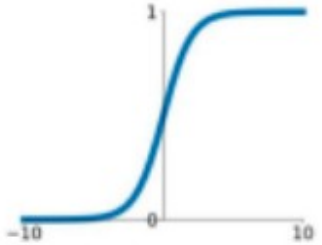


Fonte: https://www.clarifai.com/technology

Activation Functions

Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



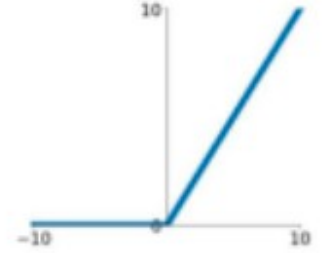
tanh

$$\tanh(x)$$



ReLU

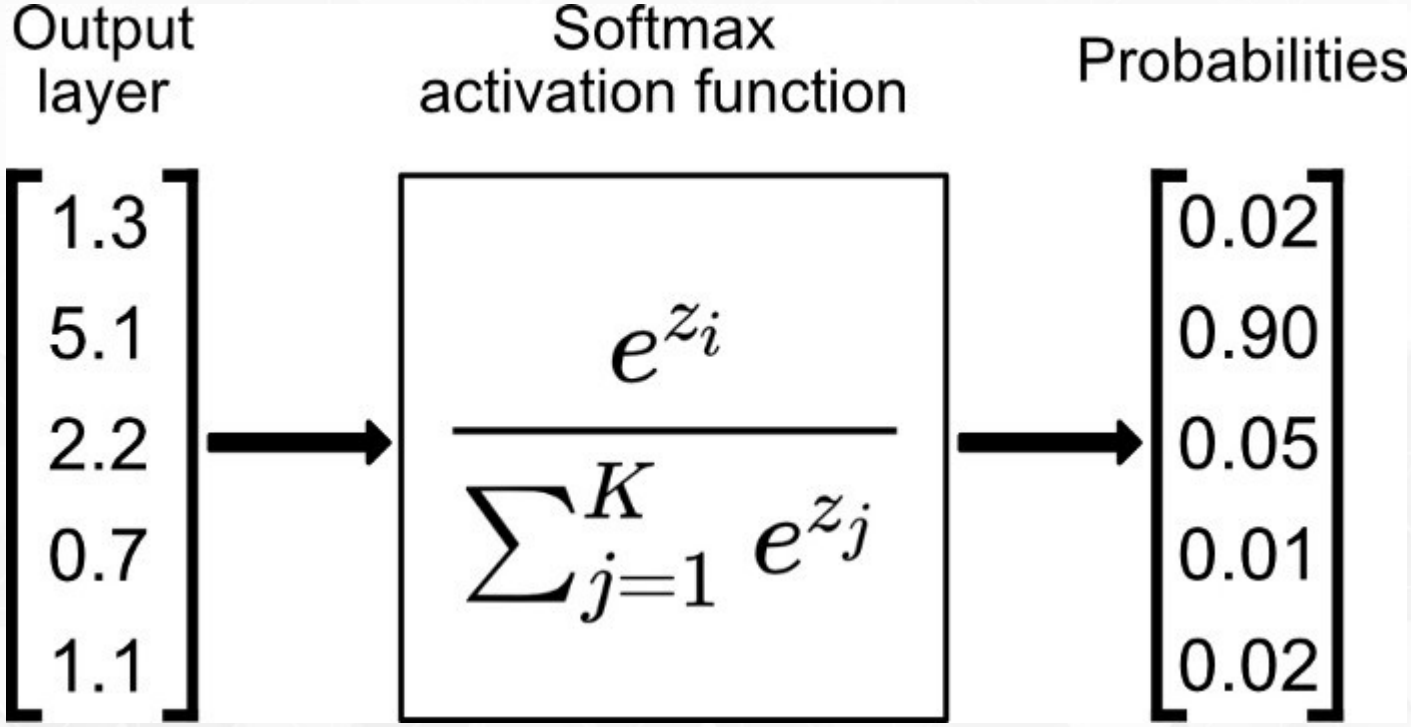
$$\max(0, x)$$



Fonte: https://medium.com/@a.nikishaev

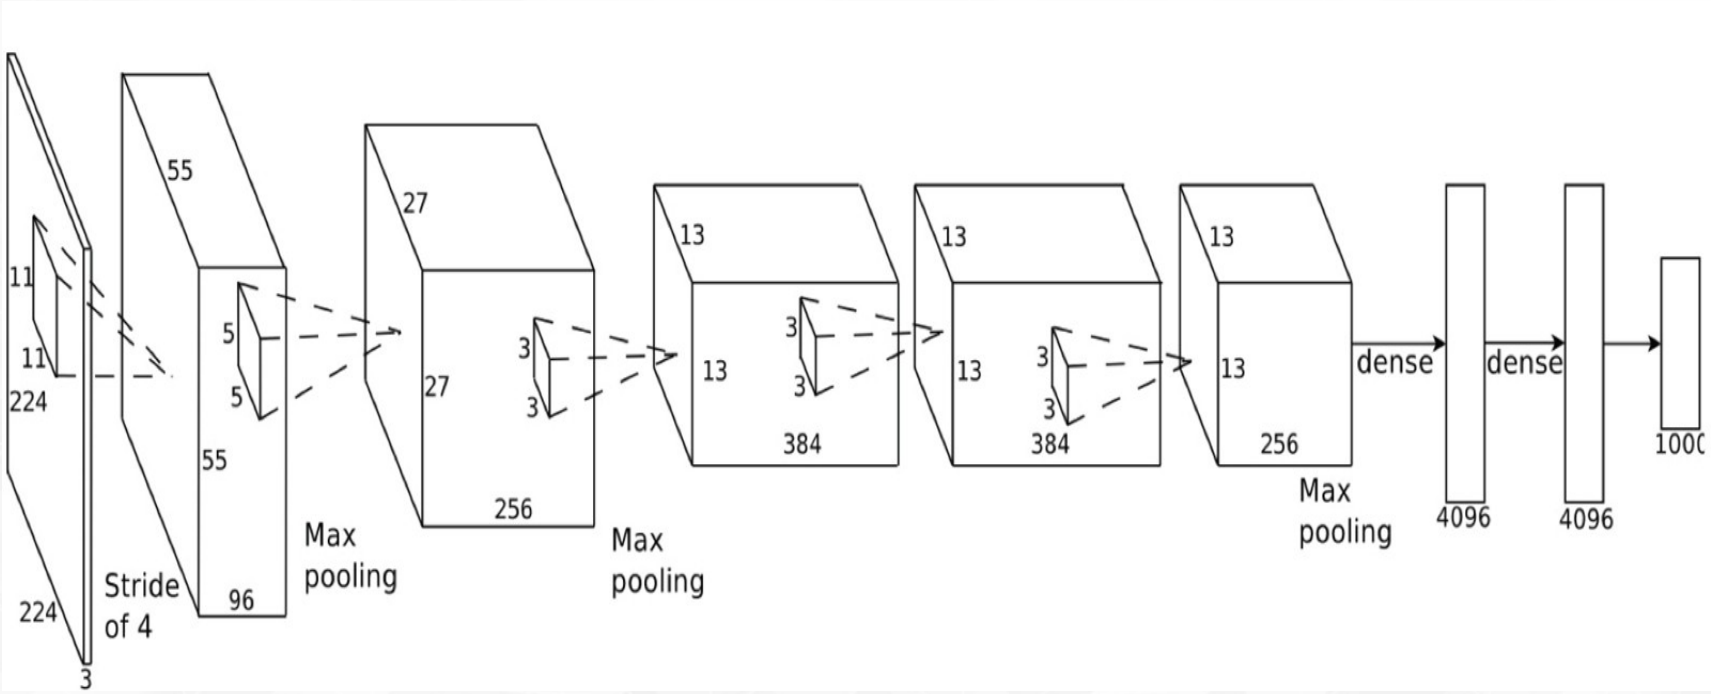
Rede Convolucional – SoftMax

Saída em Porcentagem (*Soft-Max Layer*)



Fonte: https://towardsdatascience.com/softmax-activation-function-explained-a7e1bc3ad60

Rede Convolucional – outro exemplo



Fonte: https://medium.com/@ageitgey

Conceitos e Operações

- Conceitos
  - campos receptivos locais (*local receptive fields*),

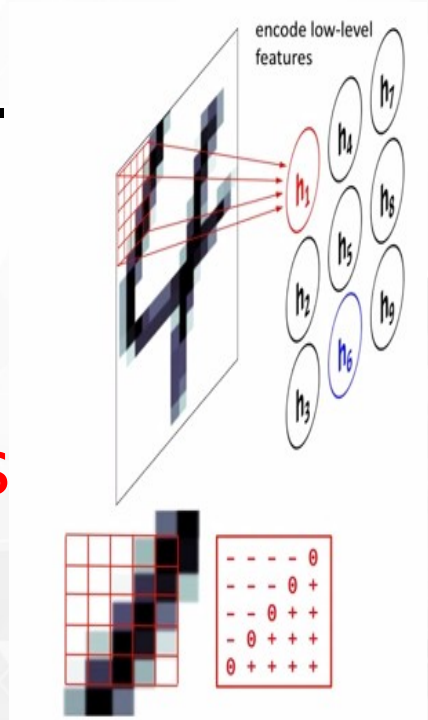
- Operações
  - convolução (*convolution*)
  - subamostragem (*subsampling*, *pooling*)

Campos receptivos locais

- Neurônios em uma CONV utilizam conectividade local (em vez de conectividade global)
  - i.e, cada neurônio está conectado a uma região contígua de unidades da camada anterior.
- Essa região é o campo receptivo local dessa unidade.

Campos receptivos locais

- Por meio de seu campo receptivo, cada neurônio pode detectar características visuais elementares .
  - e.g., arestas orientadas, extremidades, cantos
- ...que podem então ser combinadas por camadas subsequentes para detectar características visuais mais complexas.
  - e.g., olhos, bicos, rodas, etc.

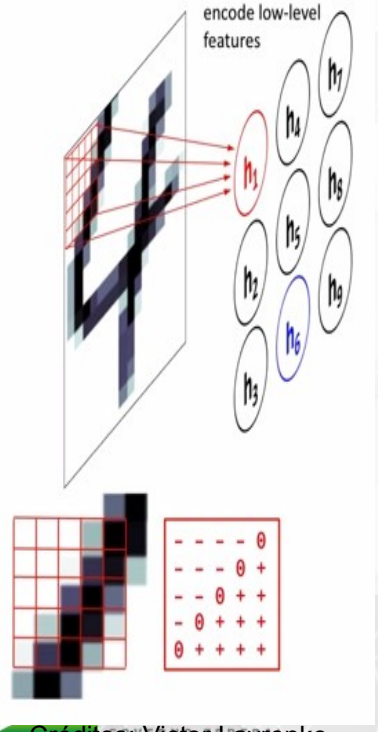


Créditos: Victor Lavrenko

Campos receptivos locais

- Analogia: um campo receptivo pode ser comparado a uma lanterna iluminando uma região quadrada da imagem (ou volume de entrada).
- Se movermos a lanterna, o campo receptivo de outros neurônios será “iluminado”.





Créditos: Victor Lavrenko

Operação de convolução

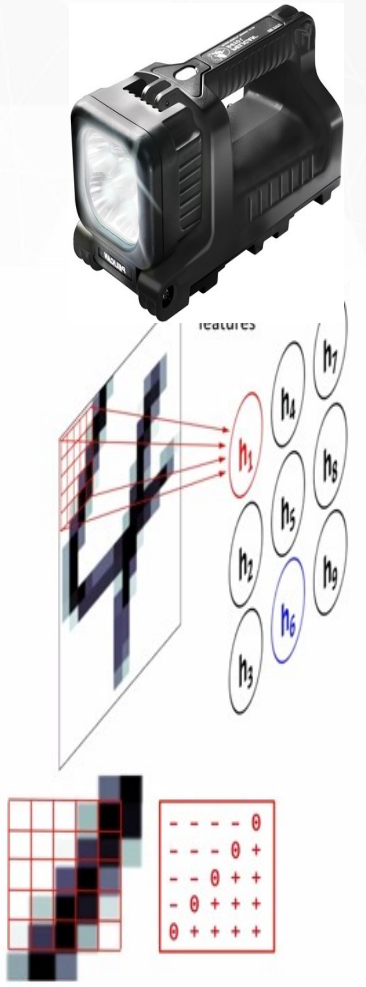
- O tipo de camada principal em uma CNN é a camada de convolução (*convolution layer, CONV*).
- Cada neurônio em uma CONV aplica um operador de convolução (*filter, kernel*) sobre seu campo receptivo.
  - Um operador de convolução é uma matriz!
- Objetivo: extrair características (*features*) da imagem de forma automática durante o treinamento.

Operação de convolução

- No contexto de uma CNN, a aplicação de uma convolução corresponde a computar o produto escalar (*dot product*) entre a entrada e o filtro.
  - A definição geral é mais complexa...
- Resultado: outra matriz!
  - mapa de ativação (*activation map)* ou
  - mapa de características *(feature map)*

Operação de convolução

- Analogia: a convolução corresponde a mover uma lanterna da direita para a esquerda, e de cima para baixo, até chegar ao canto inferior direito da imagem de entrada.
  - Em cada região iluminada, o filtro da convolução é aplicado na tentativa de detectar alguma característica visual.

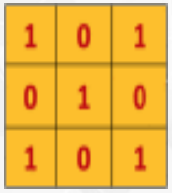


Créditos: Victor Lavrenko

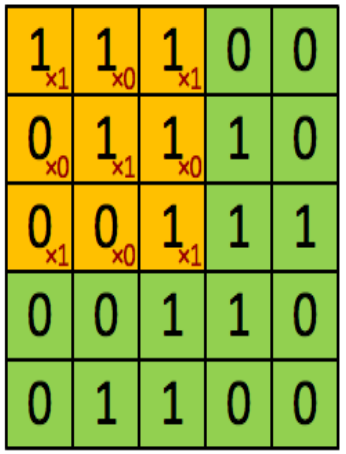
Operação de convolução - exemplo



imagem

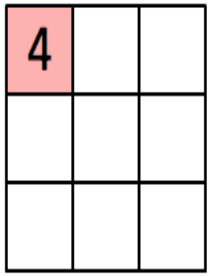


operador de convolução
(filtro, kernel)



Image

mapa de características



Convolved Feature

Fonte: http://deeplearning.stanford.edu/wiki/index.php/Feature_extraction_using_convolution

Operação de convolução - exemplo

- Em função do filtro, podem ser extraídas diferentes características da imagem.

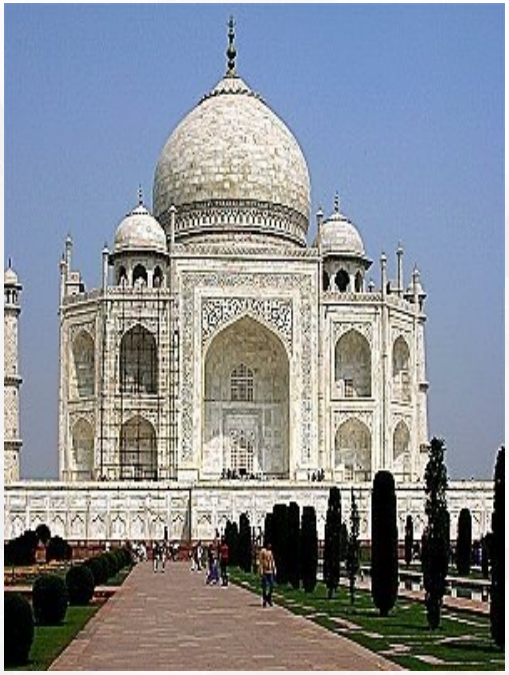


CNNs aprendem os filtros durante o treinamento!

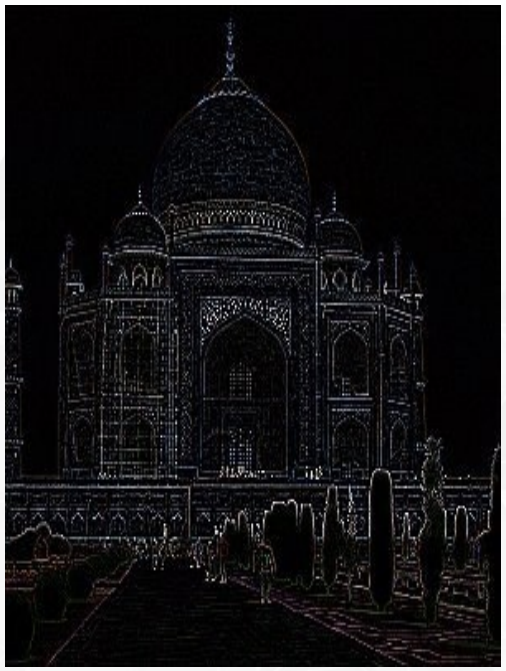
Fonte: Rob Fergus (NYU) , apud https://ujjwalkarn.me/2016/08/11/intuitive-explanation-convnets/,

Operação de convolução - exemplo

- Um filtro comumente aprendido em uma CNN (nas CONVs iniciais) é o detector de arestas.



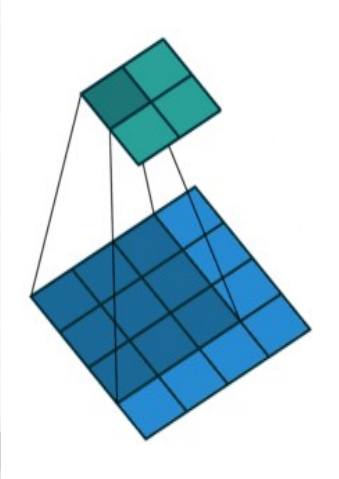
	0	1	0	
	1	-4	1	
	0	1	0	



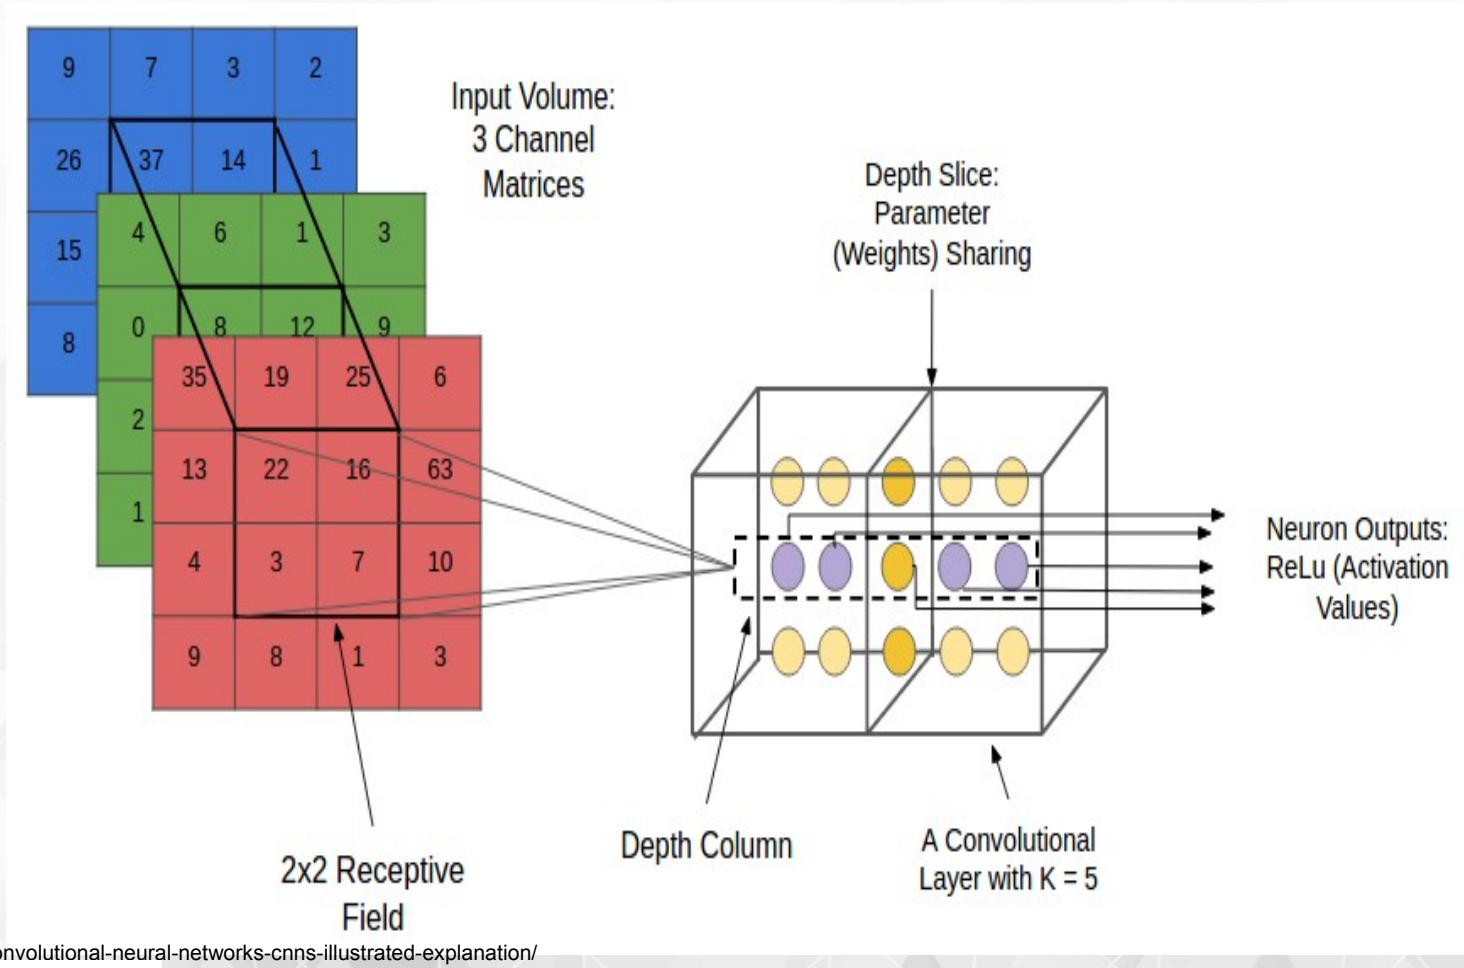
Fonte: https://docs.gimp.org/en/plug-in-convmatrix.html'

CONVs

- Cada entrada em um volume de saída é resultante da computação de um neurônio que
  - analisa uma pequena região na entrada e
  - compartilha parâmetros com neurônios no mesmo mapa de ativação.

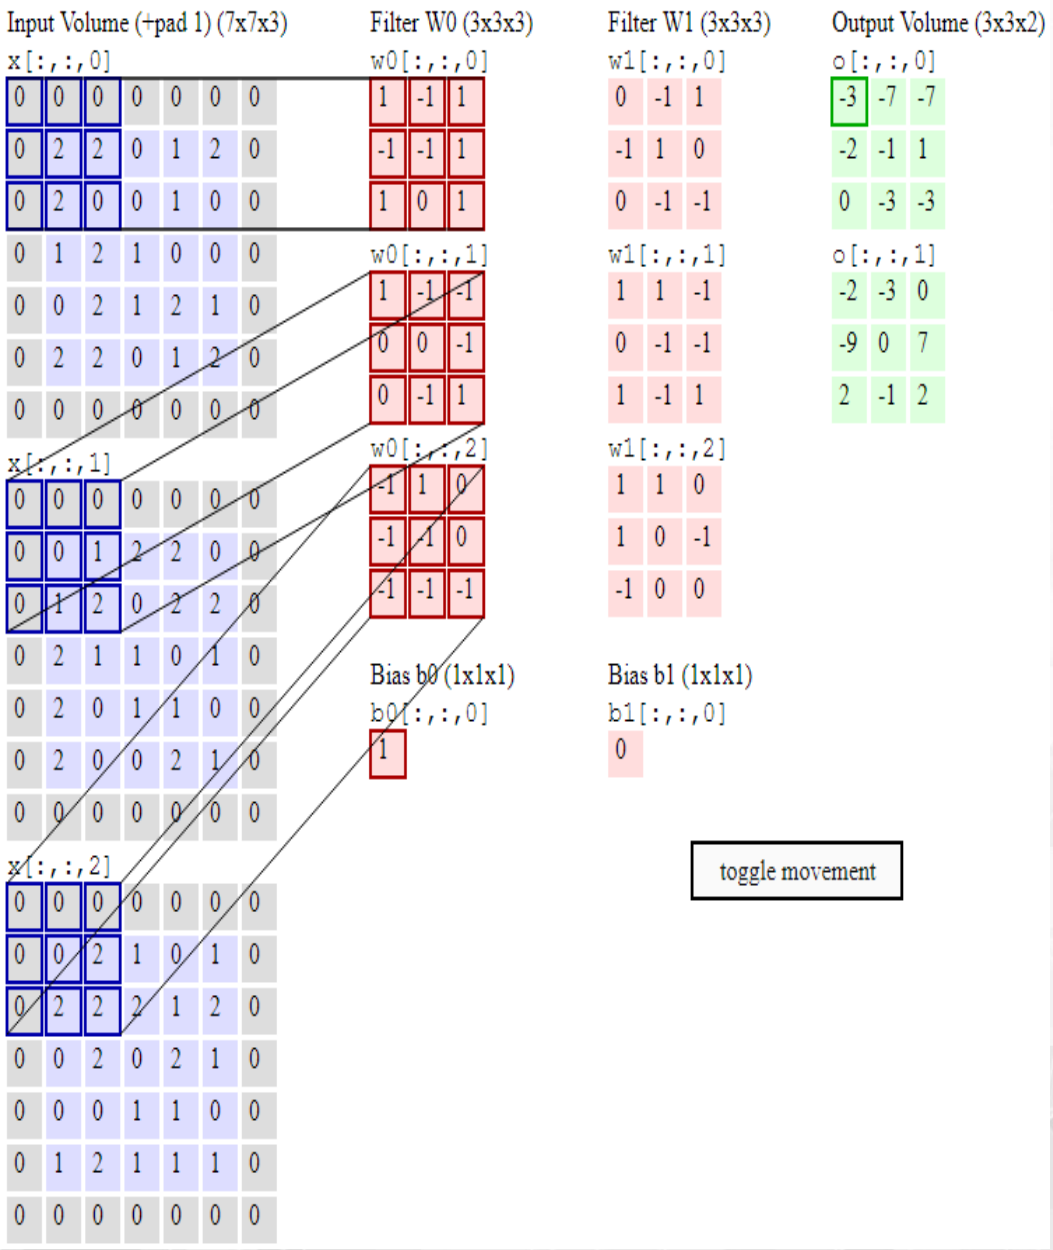


CONVs



http://xrds.acm.org/blog/2016/06/convolutional-neural-networks-cnns-illustrated-explanation/

Convolução - exemplo

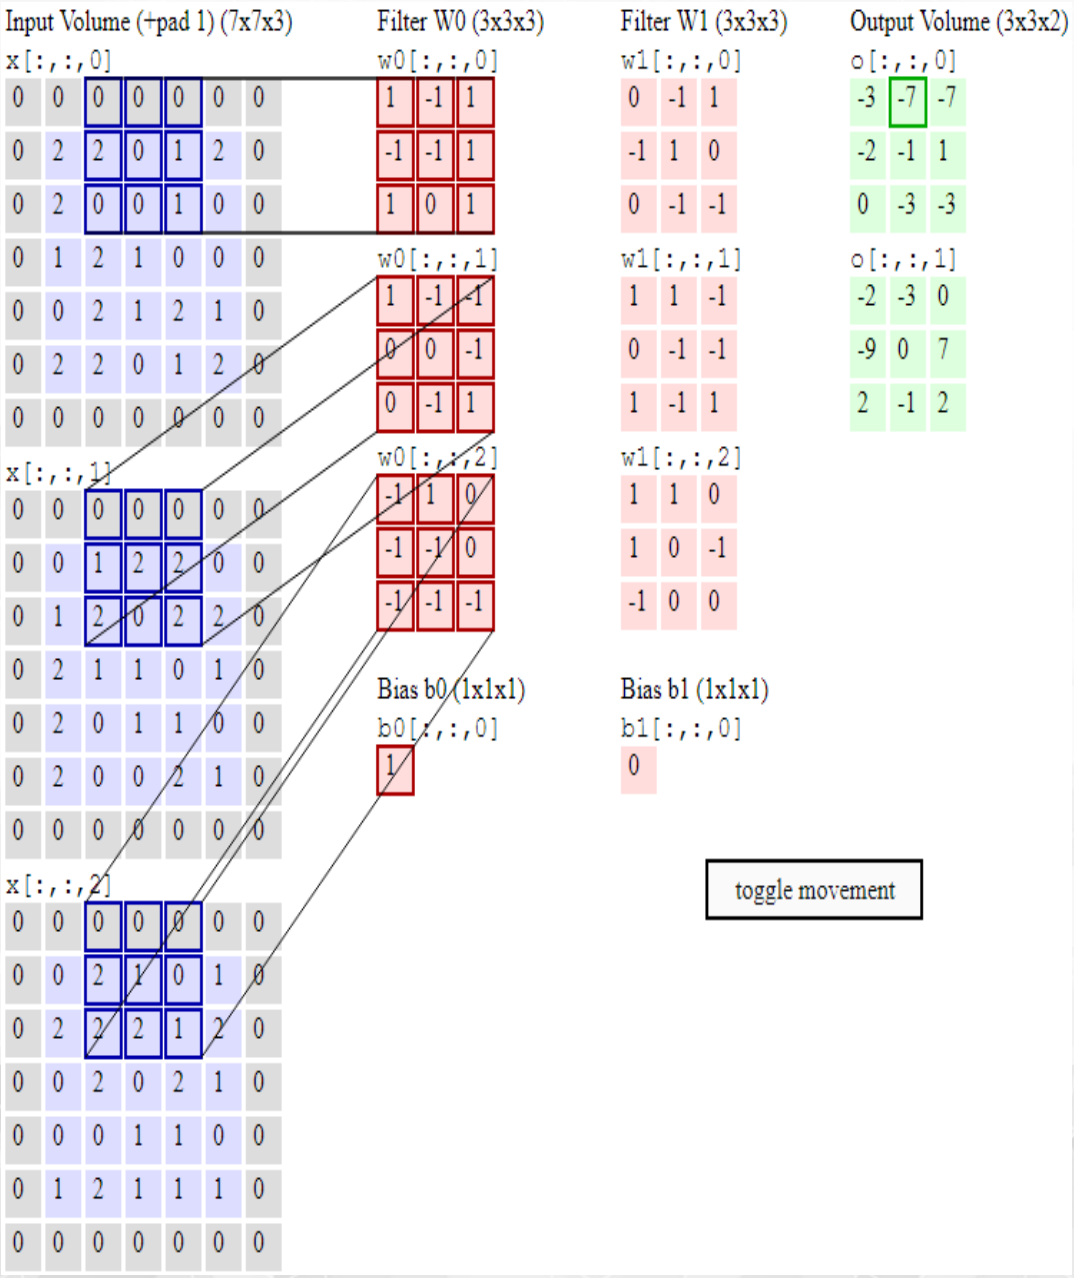


http://cs231n.github.io/convolutional-networks/

Departamento Acadêmico de Informática

PÁTRIA AMADA BRASIL GOVERNO FEDERAL

Convolução - exemplo (cont.)

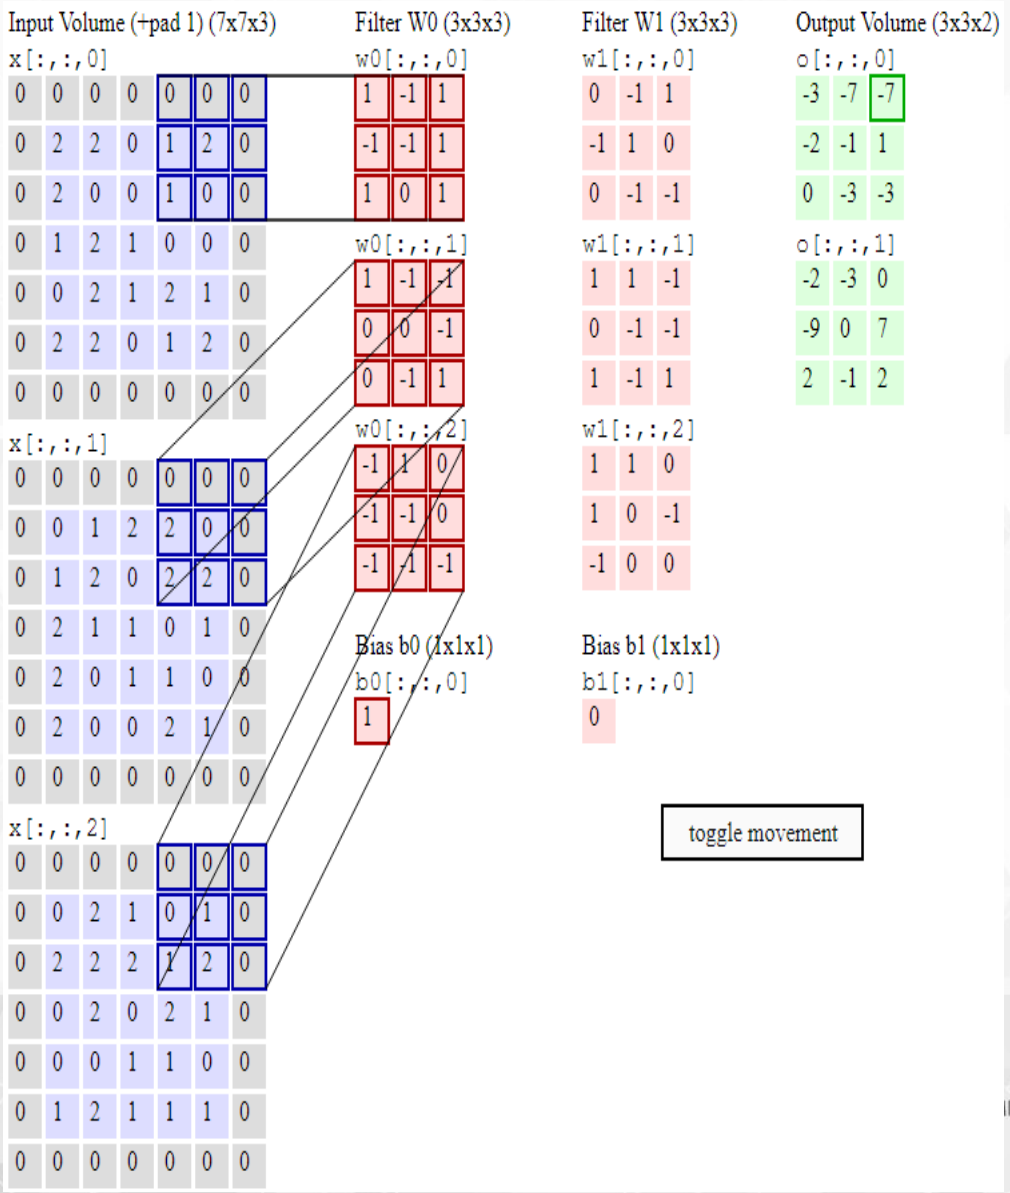


http://cs231n.github.io/convolutional-networks/

Departamento Acadêmico de Informática

PÁTRIA AMADA BRASIL GOVERNO FEDERAL

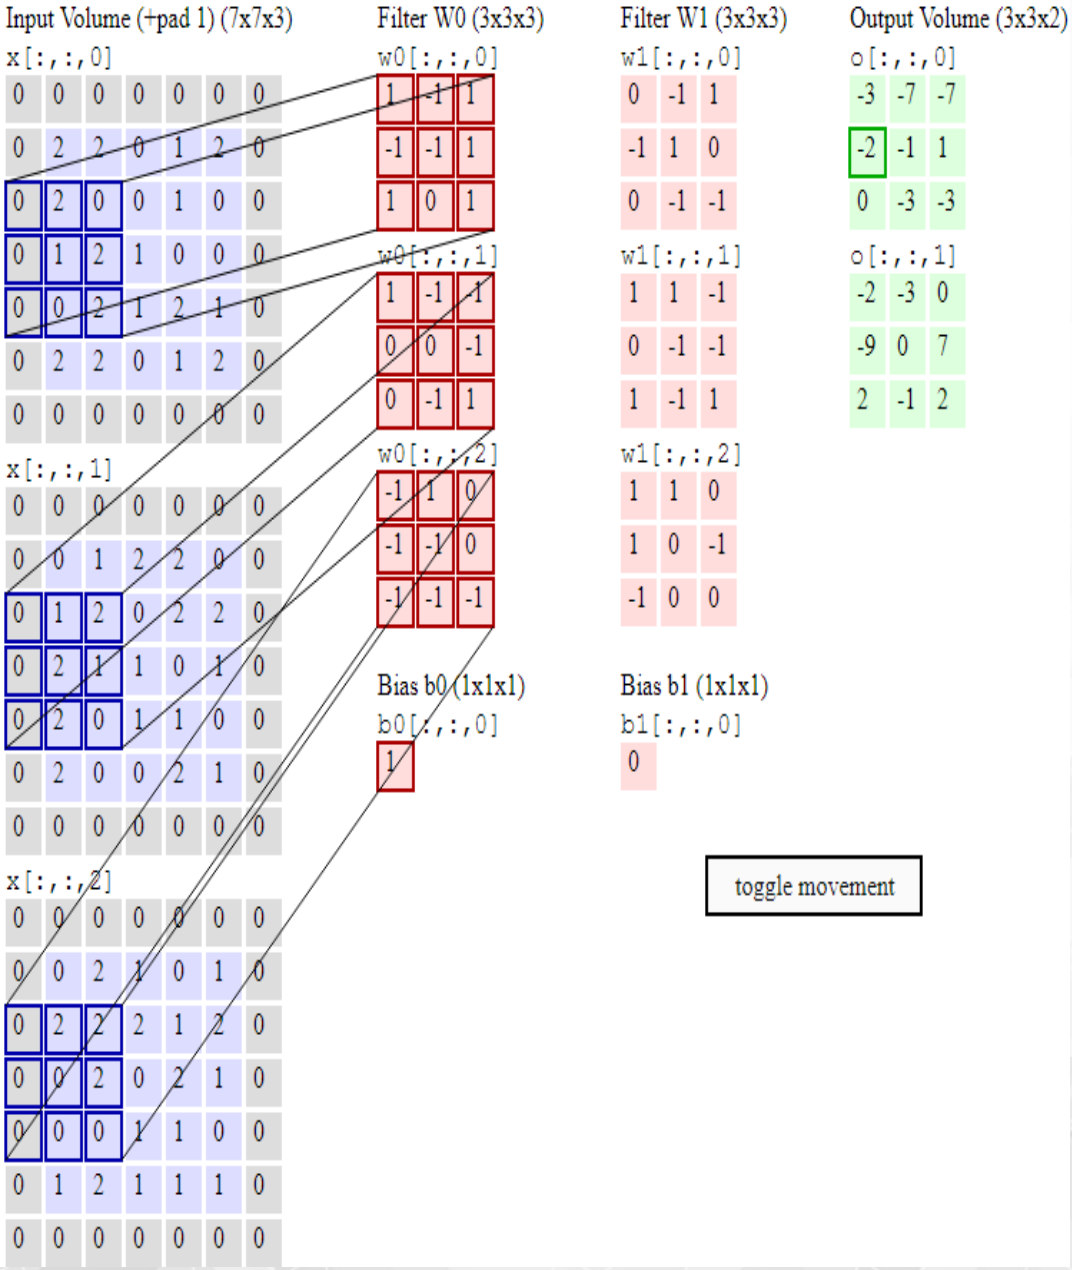
Convolução - exemplo (cont.)



http://cs231n.github.io/convolutional-networks/

Departamento Acadêmico de Informática
MINISTÉRIO DA EDUCAÇÃO
PÁTRIA AMADA BRASIL GOVERNO FEDERAL

Convolução - exemplo (cont.)

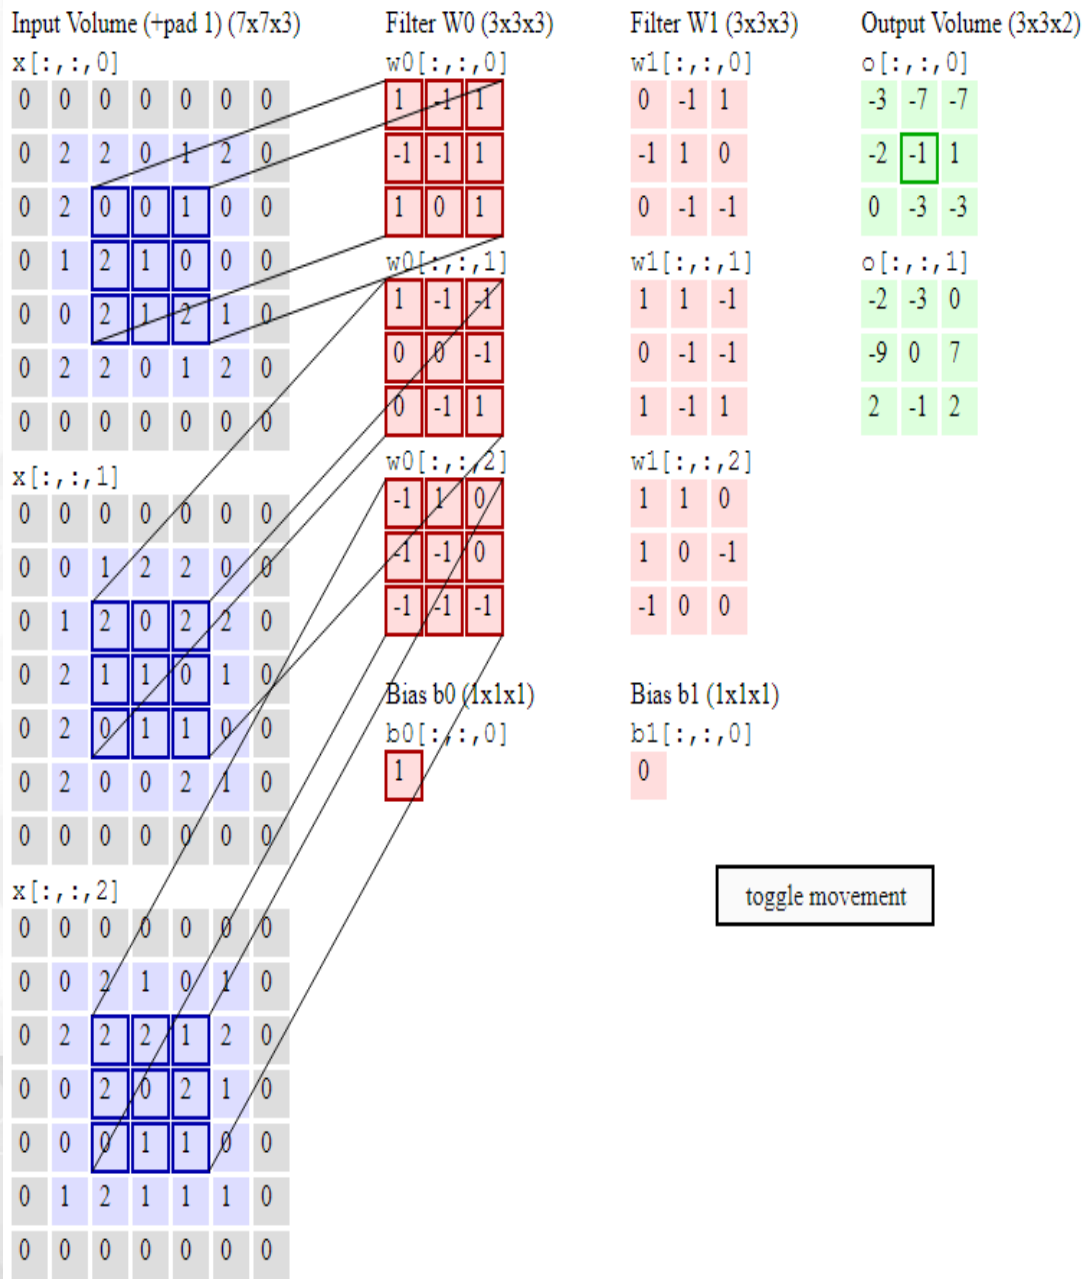


http://cs231n.github.io/convolutional-networks/

Departamento Acadêmico de Informática

PÁTRIA AMADA BRASIL GOVERNO FEDERAL

Convolução - exemplo (cont.)

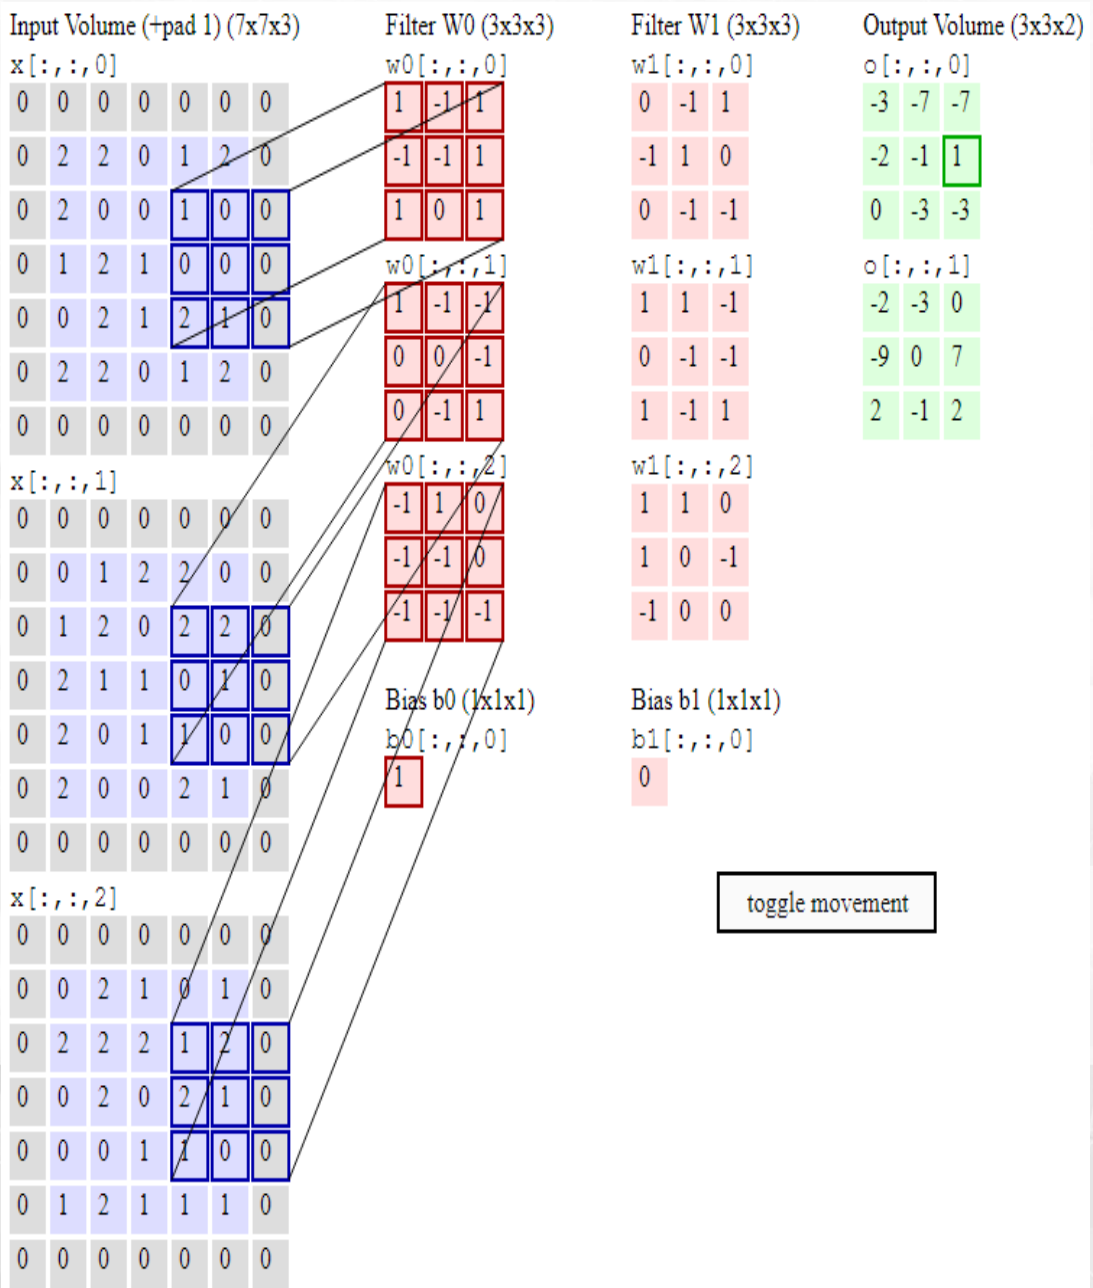


http://cs231n.github.io/convolutional-networks/

Departamento Acadêmico de Informática

PÁTRIA AMADA BRASIL GOVERNO FEDERAL

Convolução - exemplo (cont.)

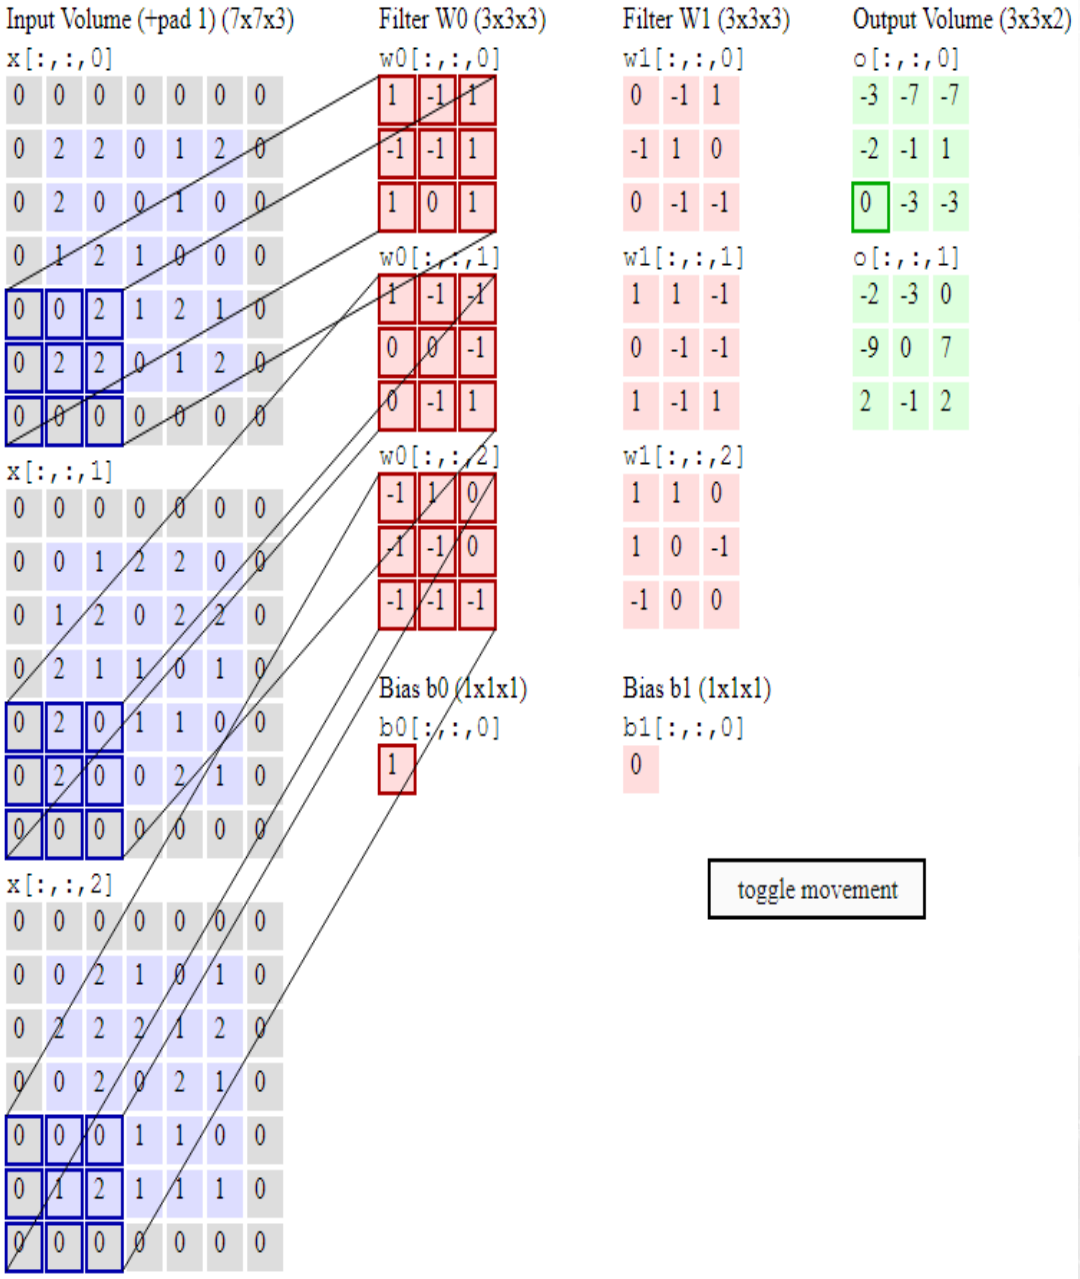


http://cs231n.github.io/convolutional-networks/

Departamento Acadêmico de Informática

PÁTRIA AMADA BRASIL GOVERNO FEDERAL

Convolução - exemplo (cont.)

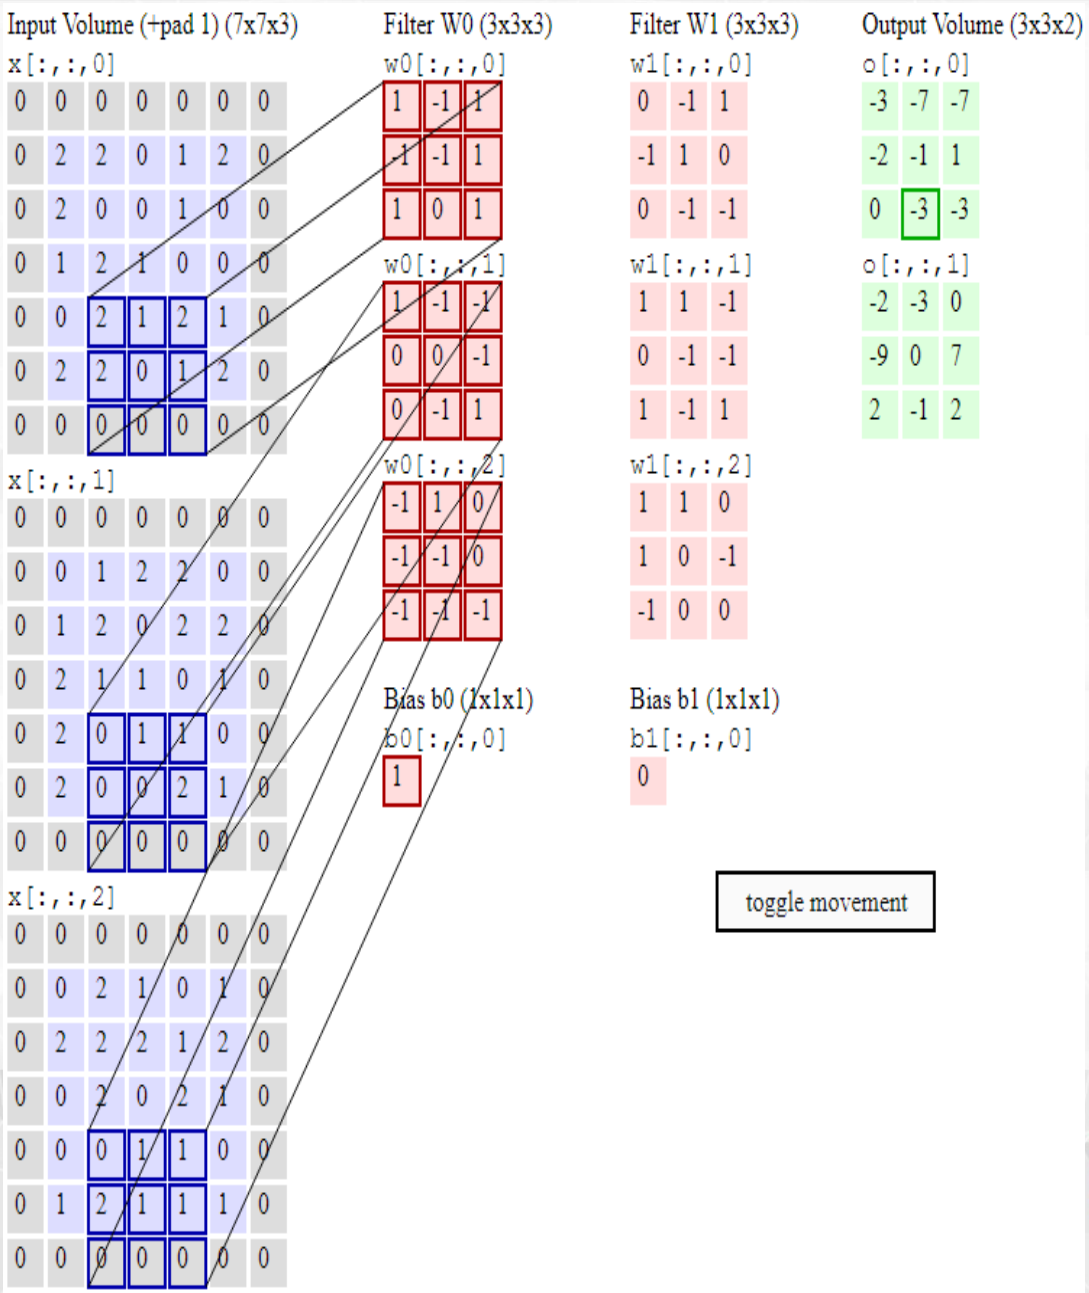


http://cs231n.github.io/convolutional-networks/

Departamento Acadêmico de Informática

PÁTRIA AMADA BRASIL GOVERNO FEDERAL

Convolução - exemplo (cont.)

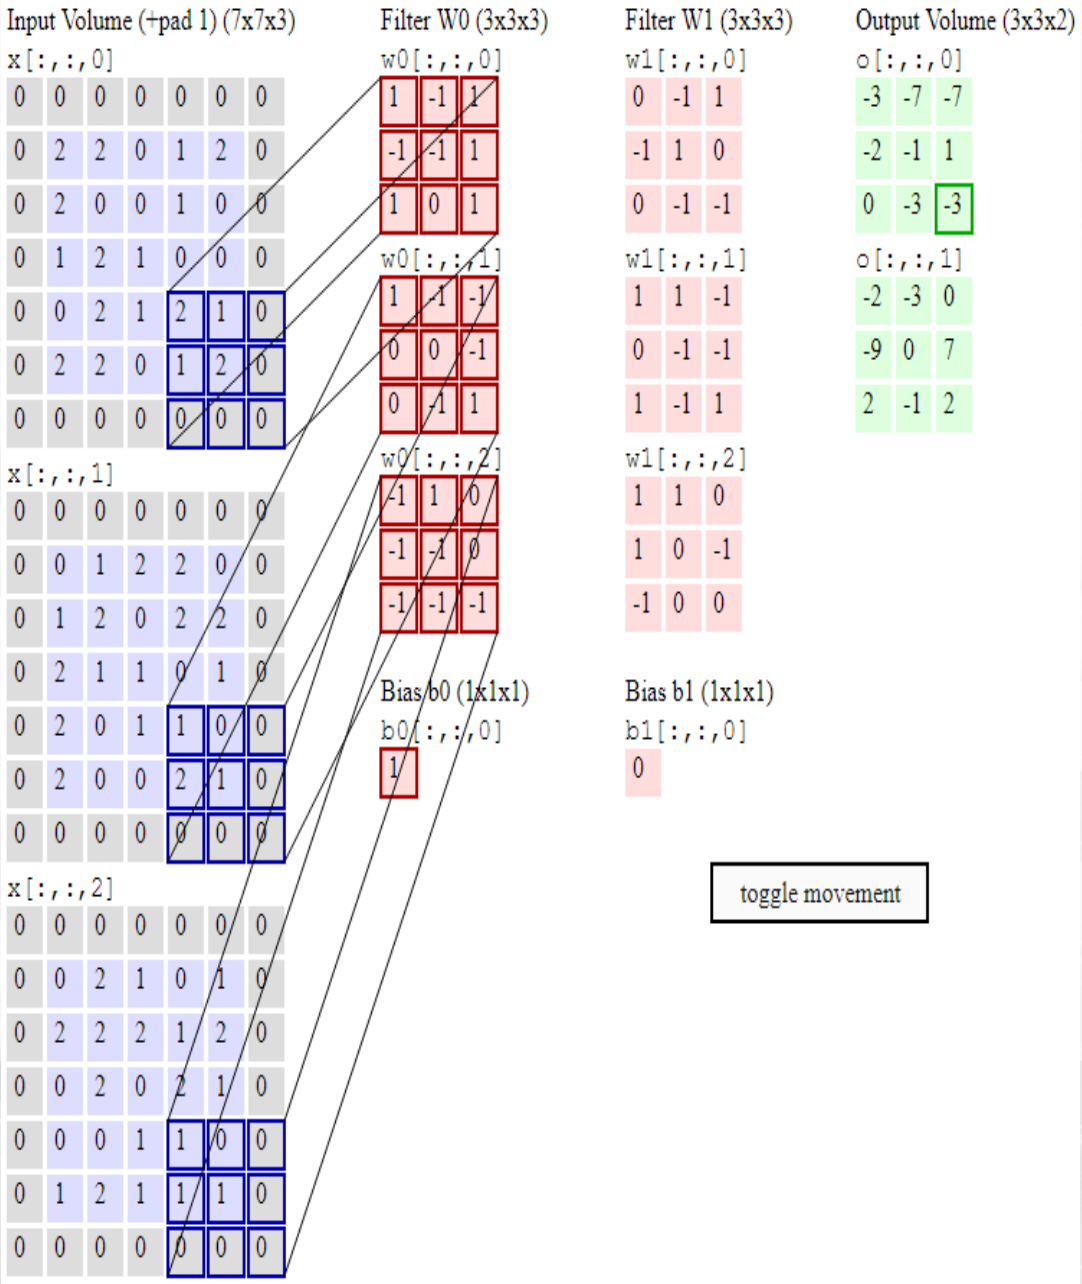


http://cs231n.github.io/convolutional-networks/

Departamento Acadêmico de Informática

PÁTRIA AMADA BRASIL GOVERNO FEDERAL

Convolução - exemplo (cont.)

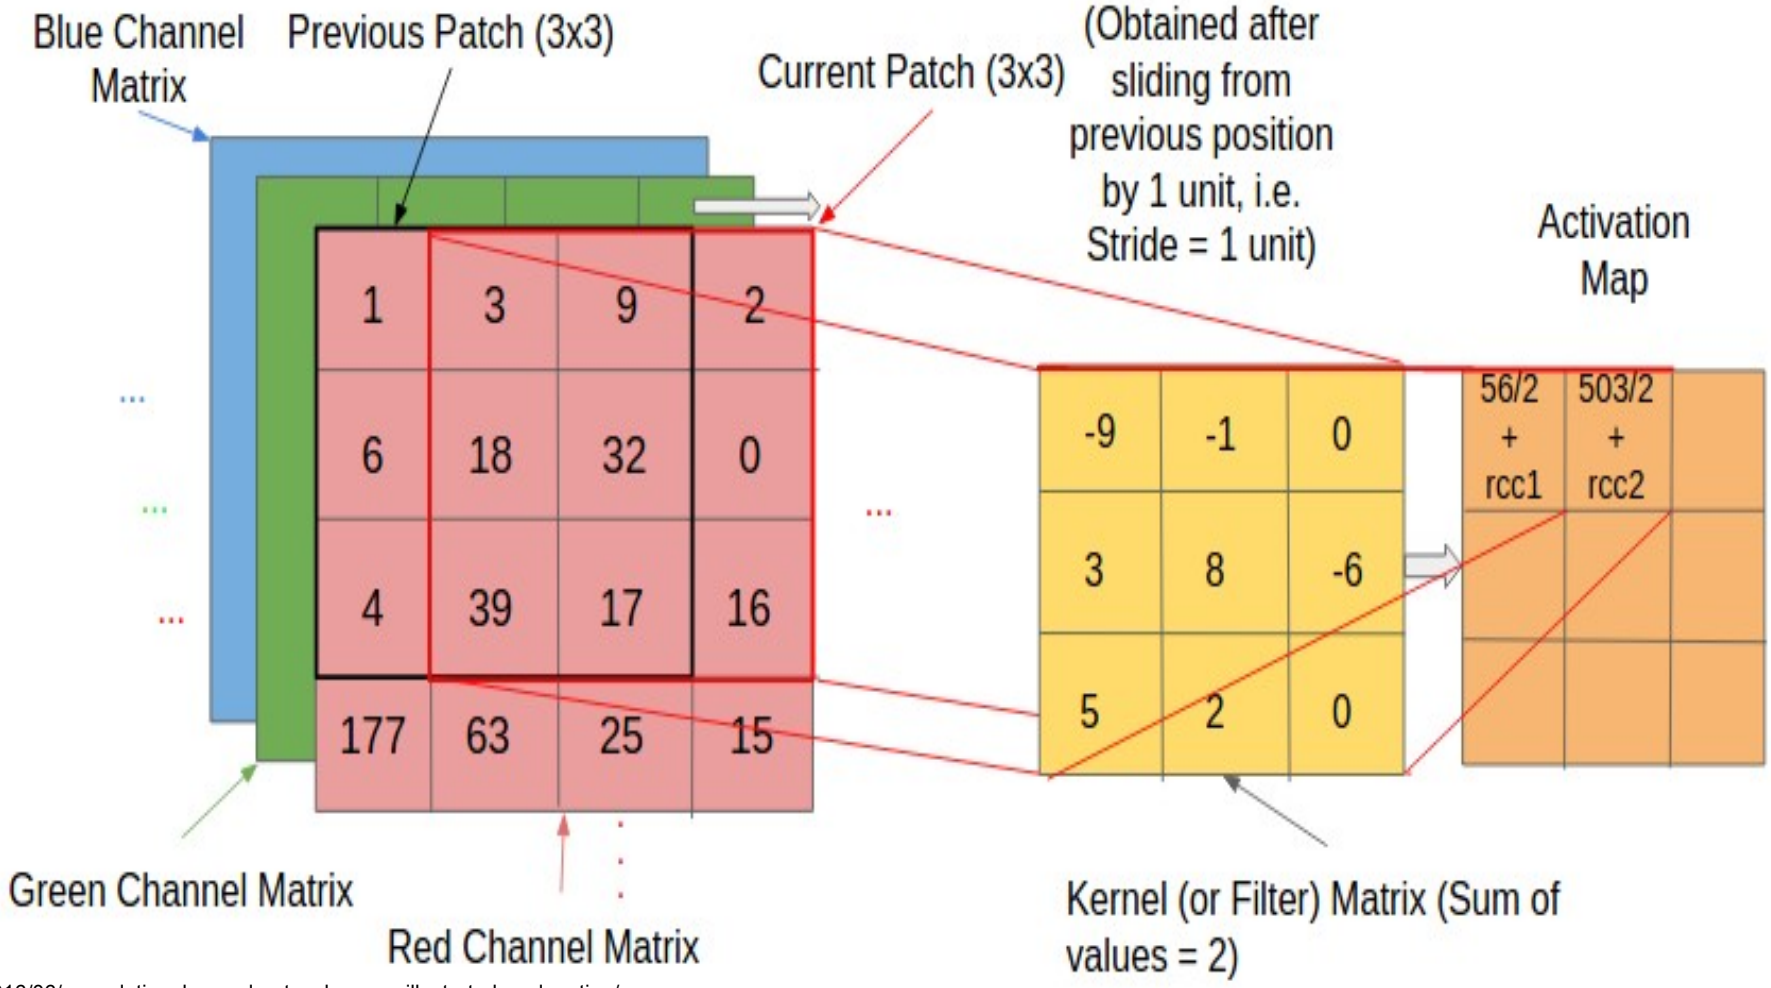


http://cs231n.github.io/convolutional-networks/

Departamento Acadêmico de Informática

PÁTRIA AMADA BRASIL GOVERNO FEDERAL

Convolução - outro exemplo



http://xrds.acm.org/blog/2016/06/convolutional-neural-networks-cnns-illustrated-explanation/

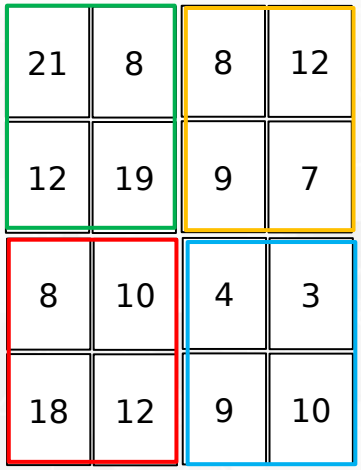
Camada de Pooling *(Pooling Layer)*

- Por vezes encontrada entre duas camadas CONVs sucessivas para reduzir a complexidade do modelo (mitigar sobreajuste).
- Objetivo: reduzir dimensões espaciais (largura x altura) do volume de entrada para a próxima CONV.
  - Aplicada a cada fatia de profundidade do volume de entrada.
  - Profundidade do volume de saída igual à do volume de entrada.

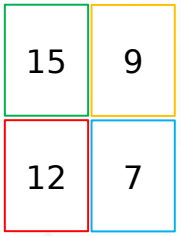
Camada de Pooling – outro exemplo

(S = 2, F = 2, W_1 = 4, H_1 = 4)

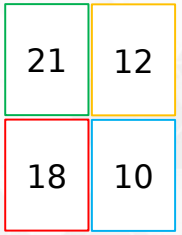
W_2 = 2, H_2 = 2



avg pooling



max pooling

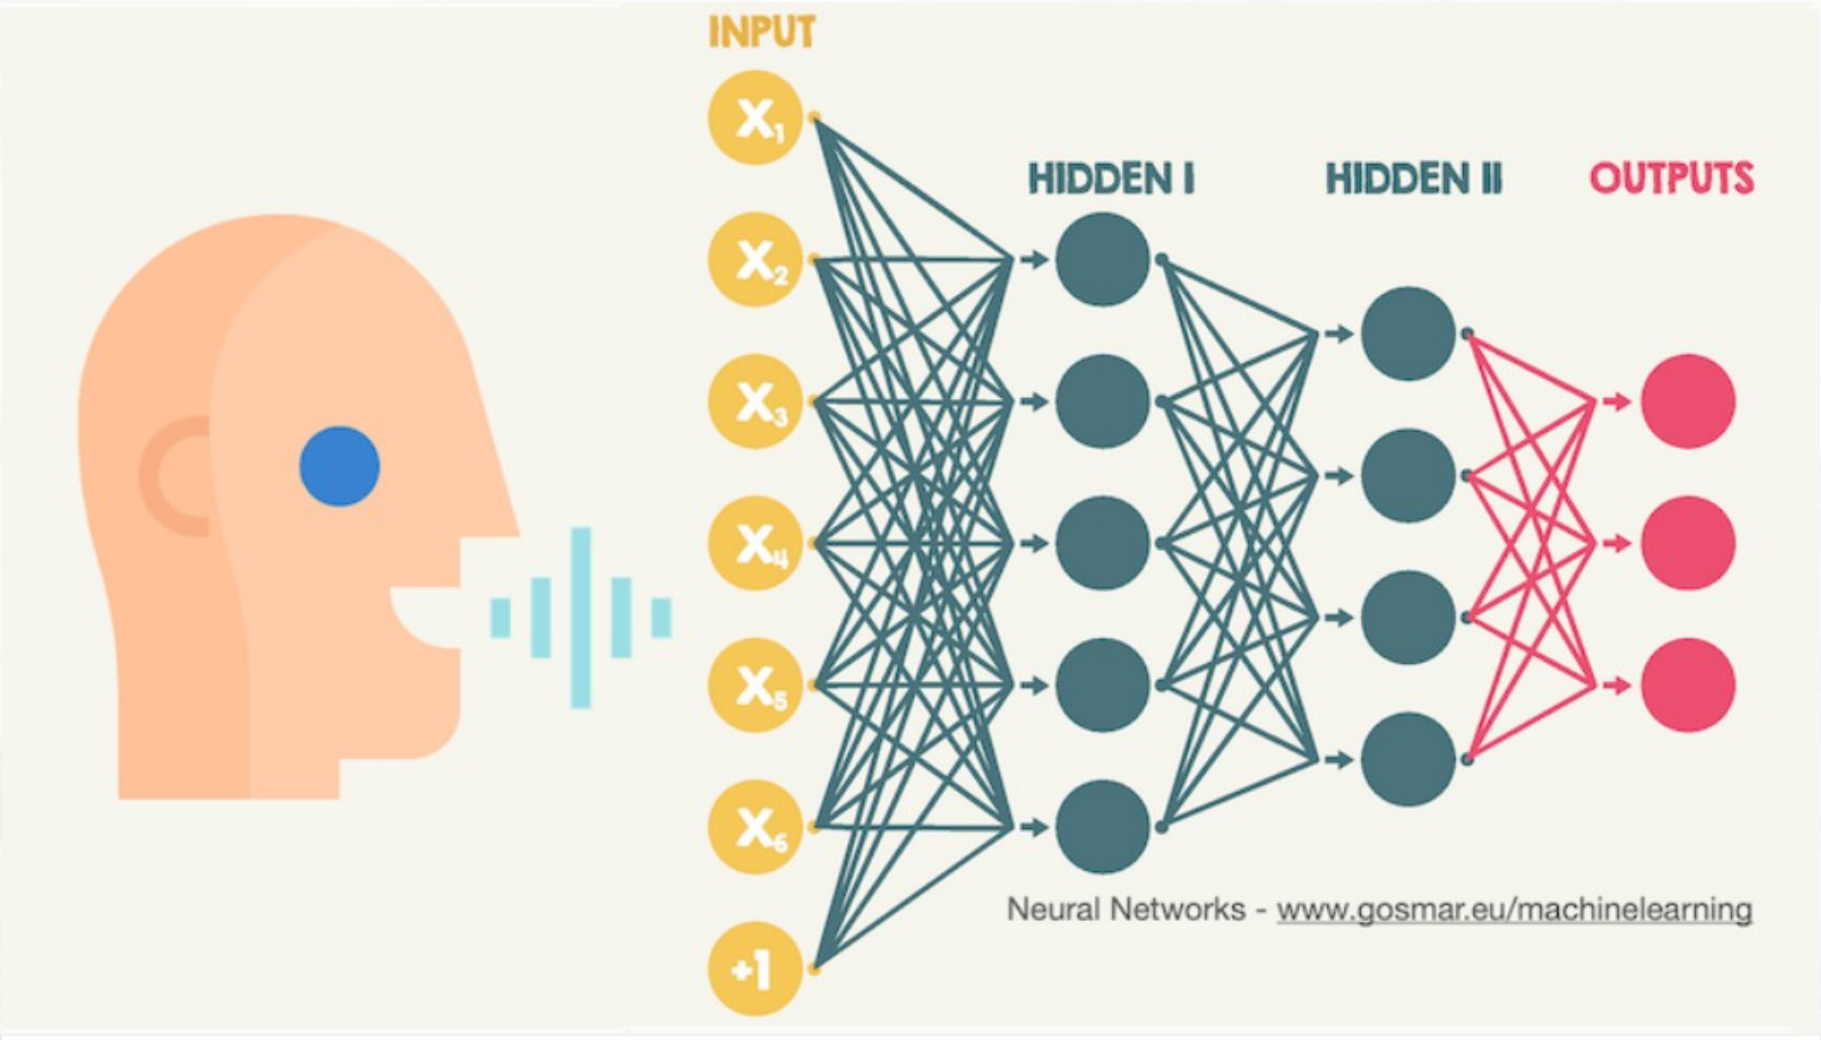


$$W_2 = (W_1 - F)/S + 1$$
$$H_2 = (H_1 - F)/S + 1$$

Repare que 75% das ativações são descartadas!

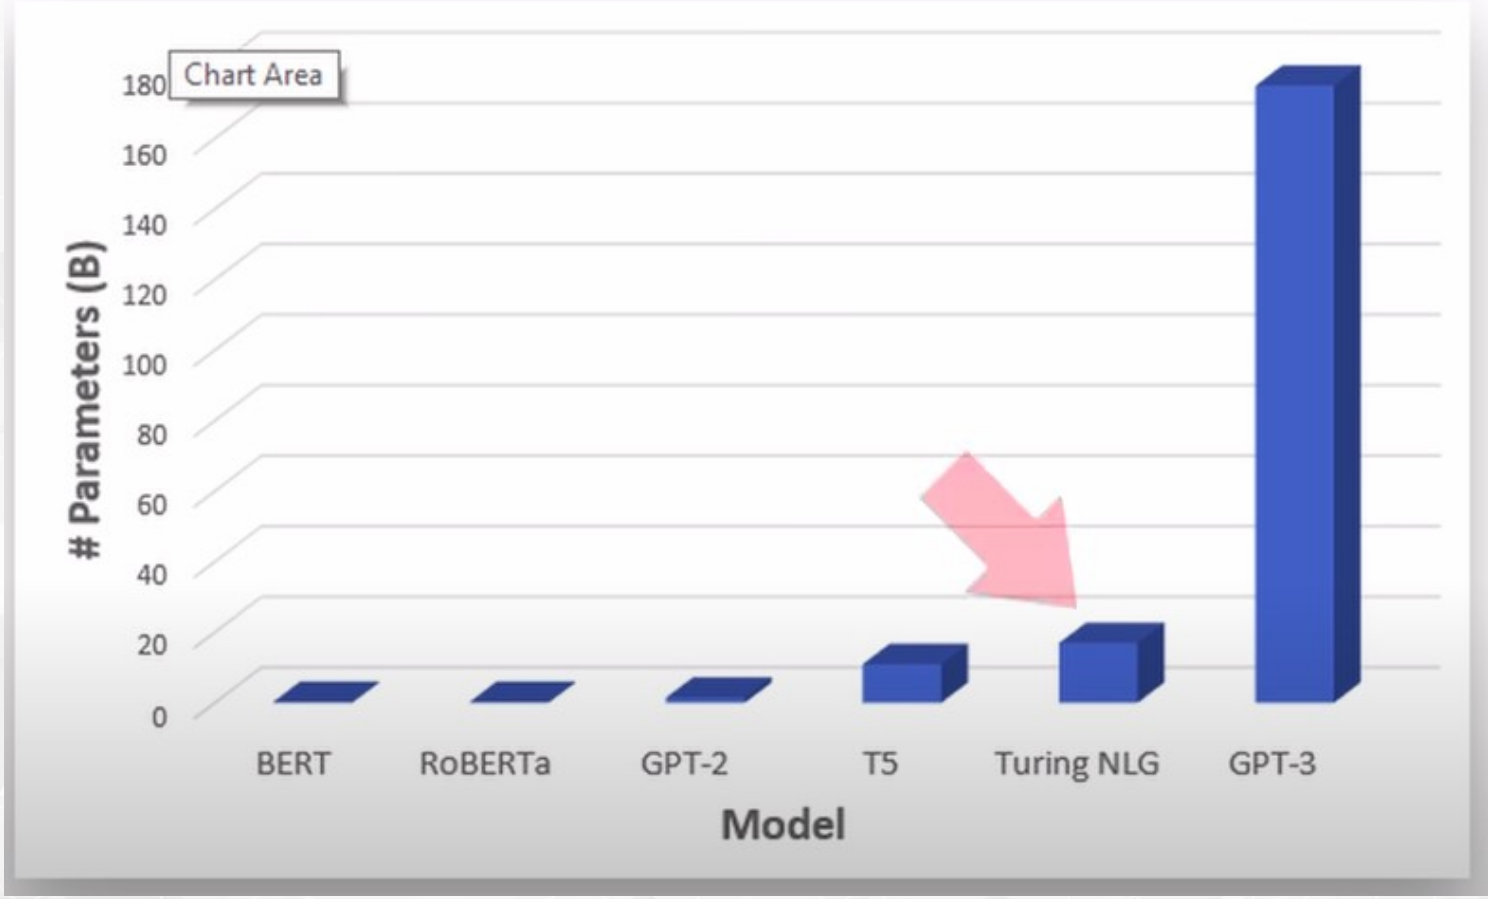
Imagem reproduzida do material disponibilizado na disciplina cs231n (http://cs231n.stanford.edu/)

Aplicações: “Voice Recognition”!



Aplicações: “Interpretação (e geração!) de Texto em Linguagem Natural(NLP)”

Número de Parâmetros (Pesos):
em BILHÕES!!!
180 Bilhões….
(2020)



Aplicações: “Interpretação (e geração!) de Texto em Linguagem Natural(NLP)”

```
1   def is_palindrome(s):
2       """Check whether a string is a palindrome"""
3       return s == s[::-1]
4
5   def long_palindrome_indices(l):
6       """Return list indices for elements that are palindromes and at least 7 characters"""
7       return [i for i, s in enumerate(l) if is_palindrome(s) and len(s) >= 7]
```

Filipe Deschamps: “**E Agora? Nova Inteligência Artificial Começou a Programar Sozinha**”
https://www.youtube.com/watch?v=KdgKQoq1jk0

Prof. João Alberto Fabro

fabro@utfpr.edu.br

Ficou interessado? Entre em contato, ou visite a página do **LASER-Laboratório Avançado de Sistemas Embarcados e Robótica:**

http://laser.dainf.ct.utfpr.edu.br/

Agradecimentos:

Prof. Eduardo Bezerra (CEFET/RJ)

Departamento Acadêmico de Informática

UTFPR
UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ
CAMPUS CURITIBA

PÁTRIA AMADA BRASIL
GOVERNO FEDERAL