Psychological Review
Vol. 65, No. 6, 1958

THE PERCEPTRON: A PROBABILISTIC MODEL FOR INFORMATION STORAGE AND ORGANIZATION IN THE BRAIN[1]

F. ROSENBLATT

Cornell Aeronautical Laboratory

If we are eventually to understand the capability of higher organisms for perceptual recognition, generalization, recall, and thinking, we must first have answers to three fundamental questions:

1. How is information about the physical world sensed, or detected, by the biological system?
2. In what form is information stored, or remembered?
3. How does information contained in storage, or in memory, influence recognition and behavior?

The first of these questions is in the province of sensory physiology, and is the only one for which appreciable understanding has been achieved. This article will be concerned primarily with the second and third questions, which are still subject to a vast amount of speculation, and where the few relevant facts currently supplied by neurophysiology have not yet been integrated into an acceptable theory.

With regard to the second question, two alternative positions have been maintained. The first suggests that storage of sensory information is in the form of coded representations or images, with some sort of one-to-one mapping between the sensory stimulus and the stored pattern. According to this hypothesis, if one understood the code or "wiring diagram" of the nervous system, one should, in principle, be able to discover exactly what an organism remembers by reconstructing the original sensory patterns from the "memory traces" which they have left, much as we might develop a photographic negative, or translate the pattern of electrical charges in the "memory" of a digital computer. This hypothesis is appealing in its simplicity and ready intelligibility, and a large family of theoretical brain models has been developed around the idea of a coded, representational memory (**2**, **3**, **9**, **14**). The alternative approach, which stems from the tradition of British empiricism, hazards the guess that the images of stimuli may never really be recorded at all, and that the central nervous system simply acts as an intricate switching network, where retention takes the form of new connections, or pathways, between centers of activity. In many of the more recent developments of this position (Hebb's "cell assembly," and Hull's "cortical anticipatory goal response," for example) the "responses" which are associated to stimuli may be entirely contained within the CNS itself. In this case the response represents an "idea" rather than an action. The important feature of this approach is that there is never any simple mapping of the stimulus into memory, according to some code which would permit its later reconstruction. Whatever in-

[1] The development of this theory has been carried out at the Cornell Aeronautical Laboratory, Inc., under the sponsorship of the Office of Naval Research, Contract Nonr-2381(00). This article is primarily an adaptation of material reported in Ref. 15, which constitutes the first full report on the program.

Revisão Psicológica Vol.
65, nº 6, 1958

O PERCEPTRON: UM MODELO PROBABILÍSTICO PARA ARMAZENAMENTO E ORGANIZAÇÃO DE INFORMAÇÕES NO CÉREBRO[1]

F. ROSENBLATT

Laboratório Aeronáutico Cornell

Se quisermos eventualmente compreender a capacidade dos organismos superiores de reconhecimento perceptual, generalização, recordação e pensamento, devemos primeiro ter respostas para três questões fundamentais:

1. Como as informações sobre o mundo físico são percebidas ou detectadas pelo sistema biológico?
2. De que forma as informações são armazenadas ou lembradas?
3. Como a informação contida no armazenamento ou na memória influencia o reconhecimento e o comportamento?

A primeira dessas questões pertence à fisiologia sensorial e é a única sobre a qual foi alcançada uma compreensão apreciável. Este artigo tratará principalmente da segunda e terceira questões, que ainda estão sujeitas a muita especulação e onde os poucos fatos relevantes atualmente fornecidos pela neurofisiologia ainda não foram integrados numa teoria aceitável.

No que diz respeito à segunda questão, foram mantidas duas posições alternativas. A primeira sugere que o armazenamento de informações sensoriais ocorre na forma de representações ou imagens codificadas, com algum tipo de mapeamento um-para-um entre o estí mulo sensorial e o padrão armazenado. De acordo co m esta hipótese, se alguém compreendesse o código ou "diagrama de ligações" do sistema nervoso, deveria, em princípio, ser capaz de descobrir exactamente o que um organismo recorda, reconstruindo os padrões sensoriais originais a partir dos " traços de memória" que eles deixaram, tal como poderíamos revelar um negativo fotográfico, ou traduzir o padrão de cargas eléctricas na "memória" de um co mputador digital. Esta hipótese é atraente pela sua simplicidade e fácil i nteligibilidade, e uma grande família de modelos teóricos do cérebro foi desenvolvida em torno da ideia de uma memória representacional codificada (2, 3, 9, 14). A abordagem alternativa, que deriva da tradição do empirismo britânico, arrisca a suposição de que as imagens dos estímulos podem nunca ser realmente registadas e que o sistema nervoso central actua simplesmente como uma intrincada rede de comutação, onde a retenção ass ume a forma de novas ligações, ou caminhos, entre centros de actividade. Em muitos dos desenvolvimentos mais recentes desta posição (a "montagem celular" de Hebb e a "resposta cortical antecipatória ao objectivo" de Hull, por exemplo) as " respostas" associadas a estímulos podem estar inteiramente contidas no próprio S NC. Neste caso, a resposta representa uma " ideia" e não uma ação. A característica importante desta abordagem é que nunca há qualquer mapeamento simples do estímulo na memória, de acordo com alg um código que permitiria a sua posterior reconstrução. Qualquer que seja

[1] O desenvolvimento desta teoria foi realiza do no Cornell Aeronautical Laboratory, Inc., sob o patrocínio do Office of Naval Research, Contract Nonr-2381(00). Este artigo é principalmente uma adaptação do material relatado na Ref. IS, que constitui o primeiro relatório completo do programa.

formation is retained must somehow be stored as a *preference for a particular response;* i.e., the information is contained in *connections* or *associations* rather than topographic representations. (The term *response*, for the remainder of this presentation, should be understood to mean any distinguishable state of the organism, which may or may not involve externally detectable muscular activity. The activation of some nucleus of cells in the central nervous system, for example, can constitute a response, according to this definition.)

Corresponding to these two positions on the method of information retention, there exist two hypotheses with regard to the third question, the manner in which stored information exerts its influence on current activity. The "coded memory theorists" are forced to conclude that recognition of any stimulus involves the matching or systematic comparison of the contents of storage with incoming sensory patterns, in order to determine whether the current stimulus has been seen before, and to determine the appropriate response from the organism. The theorists in the empiricist tradition, on the other hand, have essentially combined the answer to the third question with their answer to the second: since the stored information takes the form of new connections, or transmission channels in the nervous system (or the creation of conditions which are functionally equivalent to new connections), it follows that the new stimuli will make use of these new pathways which have been created, automatically activating the appropriate response without requiring any separate process for their recognition or identification.

The theory to be presented here takes the empiricist, or "connectionist" position with regard to these questions. The theory has been developed for a hypothetical nervous system, or machine, called a *perceptron.* The perceptron is designed to illustrate some of the fundamental properties of intelligent systems in general, without becoming too deeply enmeshed in the special, and frequently unknown, conditions which hold for particular biological organisms. The analogy between the perceptron and biological systems should be readily apparent to the reader.

During the last few decades, the development of symbolic logic, digital computers, and switching theory has impressed many theorists with the functional similarity between a neuron and the simple on-off units of which computers are constructed, and has provided the analytical methods necessary for representing highly complex logical functions in terms of such elements. The result has been a profusion of brain models which amount simply to logical contrivances for performing particular algorithms (representing "recall," stimulus comparison, transformation, and various kinds of analysis) in response to sequences of stimuli—e.g., Rashevsky (**14**), McCulloch (**10**), McCulloch & Pitts (**11**), Culbertson (**2**), Kleene (**8**), and Minsky (**13**). A relatively small number of theorists, like Ashby (**1**) and von Neumann (**17, 18**), have been concerned with the problems of how an imperfect neural network, containing many random connections, can be made to perform reliably those functions which might be represented by idealized wiring diagrams. Unfortunately, the language of symbolic logic and Boolean algebra is less well suited for such investigations. The need for a suitable language for the mathematical analysis of events in systems where only the gross organization can be characterized, and the

a formação é retida deve de alguma for ma ser armazenada como uma preferência por uma resposta particular; isto é, a informação está contida em conexões ou associações, em vez de representações topográficas. (O termo resposta, no restante desta apresentação, deve ser entendido como significando qualquer estado distinguível do organismo, que pode ou não envolver atividade muscular detectável externamente. A ativação de algum núcleo de células no sistema nervoso central, por exemplo, pode constituir uma resposta, de acordo com esta definição.)

Correspondendo a estas duas posições sobre o método de retenção de i nformação, existem duas hipóteses relativamente à terceira questão, a forma como a informação armazenada exerce a sua influência na actividade corrente. Os " teóricos da memória codificada" são forçados a concluir que o reconhecimento de qualquer estímulo envolve a correspondência ou comparação sistemática dos conteúdos de armazenamento com os padrões se nsoriais recebidos, a fim de determinar se o estímulo atual foi visto antes e para determinar a resposta apropriada do organismo. Os teóricos da tradição empirista, por outro lado, combinaram essencialmente a resposta à terceira questão com a sua resposta à segunda: uma vez que a informação armazenada assume a forma de novas ligações, ou canais de transmissão no sistema nervoso (ou a criação de condições que são funcionalmente equivalentes a novas ligações), segue-se que os novos estímulos farão uso destes novos caminhos que foram criados, activando auto maticamente a resposta apropriada sem exigir qualquer processo separado para o seu reconhecimento ou identificação.

A teoria a ser apresentada aqui ass ume a posição empirista, ou "conexionista" em relação a estas questões. A teoria foi desenvolvida para um hipotético sistema nervoso, ou máquina, chamado perceptron. O perceptron foi projetado para ilustrar algumas das propriedades fundamentais dos sistemas inteligentes em geral, sem ficar profundamente enredado nas condições especiais, e frequentemente desconhecidas, que se aplicam a organismos biológicos específicos. A analogia entre o perceptron e os sistemas biológicos deve ser facilmente aparente para o leitor.

Durante as últimas décadas, o desenvolvimento da lógica simbólica, dos computadores digitais e da teoria da comutação impressionou muitos teóricos com a semelhança funcional entre um neurónio e as simples unidades liga-desliga com as quais os computadores são construídos, e forneceu os métodos analíticos necessários para representar funções lógicas altamente complexas em termos de tais elementos. O resultado tem sido uma profusão de modelos cerebrais que equivalem simplesmente a artifícios lógicos para executar algoritmos específicos (representando "recordação", comparação de estímulos, transformação e vários tipos de análise) em resposta a sequências de estímulos - por exemplo, Rashevsky (14), McCulloch (10), McCulloch & Pitts (11), Culbertson (2), Kleene (8) e Minsky (13). Um número relativamente pequeno de teóricos, como Ashby (1) e von Neumann (17, 18), tem se preocupado com os problemas de como uma rede neural imperfeita, contendo muitas conexões aleatórias, pode ser feita para executar de forma confiável aquelas funções que poderiam ser representadas por diagramas de fiação idealizados. Infelizmente, a linguagem da lógica simbólica e da álgebra booleana é menos adequada para tais investigações. A necessidade de uma linguagem adequada para a análise matemática de eventos em sistemas onde apenas a organização bruta pode ser caracterizada, e a

precise structure is unknown, has led the author to formulate the current model in terms of probability theory rather than symbolic logic.

The theorists referred to above were chiefly concerned with the question of how such functions as perception and recall might be achieved by a deterministic physical system of any sort, rather than how this is actually done by the brain. The models which have been produced all fail in some important respects (absence of equipotentiality, lack of neuroeconomy, excessive specificity of connections and synchronization requirements, unrealistic specificity of stimuli sufficient for cell firing, postulation of variables or functional features with no known neurological correlates, etc.) to correspond to a biological system. The proponents of this line of approach have maintained that, once it has been shown how a physical system of any variety might be made to perceive and recognize stimuli, or perform other brainlike functions, it would require only a refinement or modification of existing principles to understand the working of a more realistic nervous system, and to eliminate the shortcomings mentioned above. The writer takes the position, on the other hand, that these shortcomings are such that a mere refinement or improvement of the principles already suggested can never account for biological intelligence; a *difference in principle* is clearly indicated. The theory of statistical separability (Cf. **15**), which is to be summarized here, appears to offer a solution in principle to all of these difficulties.

Those theorists—Hebb (**7**), Milner (**12**), Eccles (**4**), Hayek (**6**)—who have been more directly concerned with the biological nervous system and its activity in a natural environment, rather than with formally analogous machines, have generally been less exact in their formulations and far from rigorous in their analysis, so that it is frequently hard to assess whether or not the systems that they describe could actually work in a realistic nervous system, and what the necessary and sufficient conditions might be. Here again, the lack of an analytic language comparable in proficiency to the Boolean algebra of the network analysts has been one of the main obstacles. The contributions of this group should perhaps be considered as suggestions of what to look for and investigate, rather than as finished theoretical systems in their own right. Seen from this viewpoint, the most suggestive work, from the standpoint of the following theory, is that of Hebb and Hayek.

The position, elaborated by Hebb (**7**), Hayek (**6**), Uttley (**16**), and Ashby (**1**), in particular, upon which the theory of the perceptron is based, can be summarized by the following assumptions:

1. The physical connections of the nervous system which are involved in learning and recognition are not identical from one organism to another. At birth, the construction of the most important networks is largely random, subject to a minimum number of genetic constraints.

2. The original system of connected cells is capable of a certain amount of plasticity; after a period of neural activity, the probability that a stimulus applied to one set of cells will cause a response in some other set is likely to change, due to some relatively long-lasting changes in the neurons themselves.

3. Through exposure to a large sample of stimuli, those which are most "similar" (in some sense which must be defined in terms of the particular physical system) will tend

a estrutura precisa é desconhecida, levou o autor a formular o modelo atual em ter mos de teoria da probabilidade, em vez de lógica simbólica.

Os teóricos acima referidos estavam principalmente preocupados com a questão de como funções como a percepção e a recordação poderiam ser alcançadas por um sistema físico determinístico de qualquer tipo, e não com a forma como isso é realmente feito pelo cérebro. Todos os modelos que foram produzidos falham em alguns aspectos importantes (ausência de equipotencialidade, falta de neuroeconomia, especificidade excessiva de conexões e requisitos de sincronização, especificidade irrealista de estímulos suficientes para o disparo celular; postulação de variáveis ou características funcionais sem correlatos neurológicos conhecidos, etc.) em corresponder a um sistema biológico. Os proponentes desta linha de abordagem sustentam que, uma vez demonstrado como um sistema físico de qualquer variedade pode ser levado a perceber e reconhecer estímulos, ou executar outras funções semelhantes às do cérebro, seria necessário apenas um refinamento ou modificação dos princípios existentes para compreender o funcionamento de um sistema nervoso mais realista e para eliminar as deficiências mencionadas acima. O escritor assume a posição, por outro lado, de que estas deficiências são tais que um mero refinamento ou melhoria dos princípios já sugeridos nunca poderá explicar a inteligência biológica; uma diferença de princípio é claramente indicada. A teoria da separabilidade estatística (Cf. 15), que será aqui resumida, parece oferecer uma sol ução em princípio para todas estas dificuldades.

Os teóricos – Hebb (7), Milner (12), Eccles (4), Hayek (6) – que se preocuparam mais diretamente com o sistema nervoso biológico e sua atividade em um ambiente natural, em vez de com a análise formal.

máquinas idênticas, têm sido geralmente menos exactas nas suas formulações e longe de serem rigorosas nas suas análises, de modo que é frequentemente difícil avaliar se os sistemas que descrevem poderiam ou não realmente funcionar num sistema nervoso realista, e quais poderiam ser as condições necessárias e suficientes. Aqui, novamente, a falta de uma linguagem analítica comparável em proficiência à álgebra booleana dos analistas de redes tem sido um dos principais obstáculos. As contribuições deste grupo talvez devam ser consideradas como sugestões sobre o que procurar e investigar, e não como sistemas teóricos acabados por si só. Visto deste ponto de vista, o trabalho mais sugestivo, do ponto de vista da teoria seguinte, é o de Hebb e Hayek.

A posição, elaborada por Hebb (7), Hayek (6), Uttley (16) e Ashby (1), em particular, na qual se baseia a teoria do perceptron, pode ser resumida pelos seguintes pressupostos:

1. As conexões físicas do sistema nervoso envolvidas na aprendizagem e no reconhecimento não são idênticas de um organismo para outro. Ao nascer, a construção das redes mais importantes é em grande parte aleatória, sujeita a um número mínimo de restrições genéticas.

2. O sistema original de células conectadas é capaz de apresentar uma c erta plasticidade; após um período de atividade neural, a probabilidade de um estímulo aplicado a um conjunto de células causar uma resposta em algum outro conjunto provavelmente mudará, devido a algumas mudanças relativamente duradouras nos próprios neurônios.

3. Através da exposição a uma grande amostra de estímulos, aqueles que são mais "semelhantes" (em certo sentido, que devem ser definidos em termos do sistema físico particular) tenderão

to form pathways to the same sets of responding cells. Those which are markedly "dissimilar" will tend to develop connections to different sets of responding cells.

4. The application of positive and/or negative reinforcement (or stimuli which serve this function) may facilitate or hinder whatever formation of connections is currently in progress.

5. *Similarity*, in such a system, is represented at some level of the nervous system by a tendency of similar stimuli to activate the same sets of cells. Similarity is not a necessary attribute of particular formal or geometrical classes of stimuli, but depends on the physical organization of the perceiving system, an organization which evolves through interaction with a given environment. The structure of the system, as well as the ecology of the stimulus-environment, will affect, and will largely determine, the classes of "things" into which the perceptual world is divided.

THE ORGANIZATION OF A PERCEPTRON

The organization of a typical photoperceptron (a perceptron responding to optical patterns as stimuli) is shown in Fig. 1. The rules of its organization are as follows:

1. Stimuli impinge on a retina of sensory units (S-points), which are assumed to respond on an all-or-nothing basis, in some models, or with a pulse amplitude or frequency proportional to the stimulus intensity, in other models. In the models considered here, an all-or-nothing response will be assumed.

2. Impulses are transmitted to a set of association cells (A-units) in a "projection area" (A_I). This projection area may be omitted in some models, where the retina is connected directly to the association area (A_{II}).

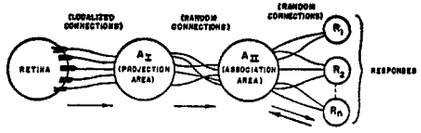


FIG. 1. Organization of a perceptron.

The cells in the projection area each receive a number of connections from the sensory points. The set of S-points transmitting impulses to a particular A-unit will be called the *origin points* of that A-unit. These origin points may be either *excitatory* or *inhibitory* in their effect on the A-unit. If the algebraic sum of excitatory and inhibitory impulse intensities is equal to or greater than the threshold (θ) of the A-unit, then the A-unit fires, again on an all-or-nothing basis (or, in some models, which will not be considered here, with a frequency which depends on the net value of the impulses received). The origin points of the A-units in the projection area tend to be clustered or focalized, about some central point, corresponding to each A-unit. The number of origin points falls off exponentially as the retinal distance from the central point for the A-unit in question increases. (Such a distribution seems to be supported by physiological evidence, and serves an important functional purpose in contour detection.)

3. Between the projection area and the association area (A_{II}), connections are assumed to be random. That is, each A-unit in the A_{II} set receives some number of fibers from origin points in the A_I set, but these origin points are scattered at random throughout the projection area. Apart from their connection distribution, the A_{II} units are identical with the A_I units, and respond under similar conditions.

4. The "responses," R_1, R_2, . . . , R_n are cells (or sets of cells) which

para formar caminhos para os mesmos conjuntos de células respondentes. Aqueles que são marcadamente "diferentes" tenderão a desenvolver conexões com diferentes conjuntos de células respondentes.

4. A aplicação de reforço positivo e/ou negativo (ou estímulos que servem esta função) pode facilitar ou dificultar qualquer formação de conexões que esteja atualmente em andamento.

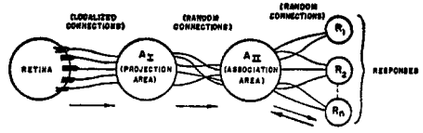
5. A similaridade, num tal sistema, é representada em algum nível do sistema nervoso por uma tendência de estímulos semelhantes para ativar os mesmos conjuntos de células. A similaridade não é um atributo necessário de determinadas classes formais ou geométricas de estí mulos, mas depende da organização física do sistema de percepção, uma organização que evolui através da interação com um determinado ambiente. A estrutura do sistema, bem como a ecologia do ambiente-estímulo, afetará e determinará em grande parte as classes de "coisas" em que o mundo perceptivo está dividido.

A ORGANIZAÇÃO DE UM PERCEPTRON

A organização de um fotoperceptron típico (um perceptron respondendo a padrões ópticos como estímulos) é mostrada na Figura 1. As regras de sua organização são as seguintes:

1. Os estímulos incidem sobre uma retina de unidades sensoriais (pontos S), que se supõe que respondem numa base de tudo ou nada, em alguns modelos, ou com uma amplitude ou frequência de pulso proporcional à intensidade do estímulo, e m outros modelos. Nos modelos aqui considerados, será assumida uma resposta de tudo ou nada.

2. Os impulsos são transmitidos a um conjunto de células de associação (unidades A) numa "área de projeção" (Ai). Esta área de projeção pode ser omitida em alguns modelos, onde a retina está conectada diretamente à área de associação (An).



FIGO. 1. Organização de um perceptron.

Cada célula na área de projeção recebe uma série de conexões dos pontos sensoriais. O conjunto de pontos S que transmitem impulsos para uma unidade A específica será chamado de pontos de origem dessa unidade A. Esses pontos de origem podem ser excitatórios ou i nibitórios em seu efeito sobre a unidade A. Se a soma algébrica das intensidades dos impulsos excitatórios e inibitórios for igual ou superior ao limiar (6) da unidade A, então a unidade A dispara, novamente numa base de tudo ou nada (ou, em alguns modelos, que não serão considerados aqui, com uma frequência que depende do valor líquido dos impulsos recebidos). Os pontos de origem das unidades A na área de projeção tendem a ser agrupados ou focalizados, em torno de algum ponto central, correspondente a cada unidade A. O número de pontos de origem diminui exponencialmente à medida que a distância da retina ao ponto central da unidade A em questão aumenta. (Tal distribuição parece ser apoiada por evidências fisiológicas e serve um importante propósito funcional na detecção de contornos.)

3. Entre a área de projeção e a área de associação (An), as conexões são consideradas aleatórias. Ou seja, cada unidade A no conjunto An recebe um certo número de fibras dos pontos de origem no conjunto AI, mas esses pontos de origem estão espalhados aleatoriamente por toda a área de projeção. Independentemente da sua distribuição de ligação, as unidades An são idênticas às unidades AI e respondem em condições semelhantes.

4. As "respostas", Ri, R^, . . . , R_n são células (ou conjuntos de células) que

respond in much the same fashion as the A-units. Each response has a typically large number of origin points located at random in the A_{II} set. The set of A-units transmitting impulses to a particular response will be called the source-set for that response. (The source-set of a response is identical to its set of origin points in the A-system.) The arrows in Fig. 1 indicate the direction of transmission through the network. Note that up to A_{II} all connections are forward, and there is no feedback. When we come to the last set of connections, between A_{II} and the R-units, connections are established in both directions. The rule governing feedback connections, in most models of the perceptron, can be either of the following alternatives:

(*a*) Each response has excitatory feedback connections to the cells in its own source-set, or

(*b*) Each response has inhibitory feedback connections to the complement of its own source-set (i.e., it tends to prohibit activity in any association cells which do not transmit to it).

The first of these rules seems more plausible anatomically, since the R-units might be located in the same cortical area as their respective source-sets, making mutual excitation between the R-units and the A-units of the appropriate source-set highly probable. The alternative rule (*b*) leads to a more readily analyzed system, however, and will therefore be assumed for most of the systems to be evaluated here.

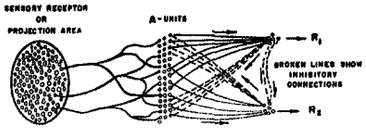


FIG. 2A. Schematic representation of connections in a simple perceptron.

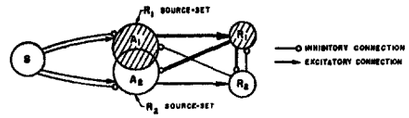


FIG. 2B. Venn diagram of the same perceptron (shading shows active sets for R_1 response).

Figure 2 shows the organization of a simplified perceptron, which affords a convenient entry into the theory of statistical separability. After the theory has been developed for this simplified model, we will be in a better position to discuss the advantages of the system in Fig. 1. The feedback connections shown in Fig. 2 are inhibitory, and go to the complement of the source-set for the response from which they originate; consequently, this system is organized according to Rule *b*, above. The system shown here has only three stages, the first association stage having been eliminated. Each A-unit has a set of randomly located origin points in the retina. Such a system will form similarity concepts on the basis of *coincident areas* of stimuli, rather than by the similarity of contours or outlines. While such a system is at a disadvantage in many discrimination experiments, its capability is still quite impressive, as will be demonstrated presently. The system shown in Fig. 2 has only two responses, but there is clearly no limit on the number that might be included.

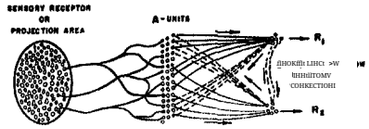
The responses in a system organized in this fashion are mutually exclusive. If R_1 occurs, it will tend to inhibit R_2, and will also inhibit the source-set for R_2. Likewise, if R_2 should occur, it will tend to inhibit R_1. If the total impulse received from all the A-units in one source-set is stronger or more frequent than the impulse received by the alternative (antagonistic) response, then the first response will

respondem da mesma maneira que as unidades A. Cada resposta tem um nú mero tipicamente grande de pontos de origem localizados aleatoriamente no conjunto An. O conjunto de unidades A que transmitem impulsos para uma resposta específica será chamado de conjunto-fonte para essa resposta. (O conjunto fonte de uma resposta é idêntico ao seu conjunto de pontos de origem no sistema A.) As setas na Fig. 1 indicam a direção da transmissão através da rede. Observe que até An todas as conexões são encaminhadas e não há feedback. Quando chegamos ao último conjunto de conexões, entre as unidades An e R, as conexões são estabelecidas em ambas as direções. A regra que rege as conexões de feedback, na maioria dos modelos do perceptron, pode ser uma das seguintes alternativas:

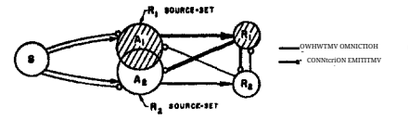
(a) Cada resposta tem conexões de feedback excitatório com as células em seu próprio conjunto de fontes, ou

(&) Cada resposta tem conexões de feedback inibitórias com o complemento de seu próprio conjunto de fontes (ou seja, tende a proibir a atividade em quaisquer células de associação que não transmitam para ela).

A primeira destas regras parece mais plausível anatomicamente uma vez que as unidades R podem estar localizadas na mesma área cortical que a sua respectiva fonte-



FIGO. 2A. Representação esquemática de conexões em um perceptron simples.



FIGO. 2B. Diagrama de Venn do mesmo perceptronf (o sombreamento mostra conjuntos ativos para resposta RI).

conjuntos, tornando altamente provável a excitação mútua entre as unidades R e as unidades A do conjunto fonte apropriado. A regra alternativa (6) leva a um sistema mais facilmente analisado e, portanto, será assumida para a maioria dos sistemas a serem avaliados aqui.

A Figura 2 mostra a organização de um perceptron simplificado, que permite uma entrada conveniente na teoria da separabilidade estatística. Após a teoria ter sido desenvolvida para este modelo simplificado, estaremos em melhor posição para discutir as vantagens do sistema na Figura 1. As conexões de realimentação mostradas na Figura 2 são inibitórias e vão para o complemento do conjunto fonte para a resposta da qual elas se originam; consequentemente, este sistema é organizado de acordo com a Regra b, acima. O sistema aqui mostrado possui apenas três estágios, tendo sido eliminado o primeiro estágio de associação. Cada unidade A possui um conjunto de pontos de origem localizados aleatoriamente na retina. Tal sistema formará conceitos de similaridade com base em áreas coincidentes de estímulos, e não pela similaridade de contornos ou contornos. Embora tal sistema esteja em desvantage m em muitas experiências de discriminação, a sua capacidade ainda é bastante impressionante, como será demonstrado atualmente. O sistema mostrado na Fig. 2 tem apenas duas respostas, mas claramente não há limite para o número que pode ser incluído.

As respostas num sistema organizado desta forma são mutuamente exclusivas. Se RI ocorrer, tenderá a inibir Rs e ta mbém inibirá o conjunto de origem para R_2. Da mesma forma, se Ra ocorrer, tenderá a inibir o IR. Se o impulso total recebido de todas as unidades A num conjunto fonte f or mais forte ou mais frequente do que o impulso recebido pela resposta alternativa (antagônica), então a primeira resposta será

tend to gain an advantage over the other, and will be the one which occurs. If such a system is to be capable of learning, then it must be possible to modify the A-units or their connections in such a way that stimuli of one class will tend to evoke a stronger impulse in the R_1 source-set than in the R_2 source-set, while stimuli of another (dissimilar) class will tend to evoke a stronger impulse in the R_2 source-set than in the R_1 source-set.

It will be assumed that the impulses delivered by each A-unit can be characterized by a value, V, which may be an amplitude, frequency, latency, or probability of completing transmission. If an A-unit has a high value, then all of its output impulses are considered to be more effective, more potent, or more likely to arrive at their endbulbs than impulses from an A-unit with a lower value. The value of an A-unit is considered to be a fairly stable characteristic, probably depending on the metabolic condition of the cell and the cell membrane, but it is not absolutely constant. It is assumed that, in general, periods of activity tend to increase a cell's value, while the value may decay (in some models) with inactivity. The most interesting models are those in which cells are assumed to compete for metabolic materials, the more active cells gaining at the expense of the less active cells. In such a system, if there is no activity, all cells will tend to remain in a relatively constant condition, and (regardless of activity) the net value of the system, taken in

TABLE 1

COMPARISON OF LOGICAL CHARACTERISTICS OF α, β, AND γ SYSTEMS

	α-System (Uncompensated Gain System)	β-System (Constant Feed System)	γ-System (Parasitic Gain System)
Total value-gain of source set per reinforcement	N_{a_r}	K	0
ΔV for A-units active for 1 unit of time	+1	K/N_{a_r}	+1
ΔV for inactive A-units outside of dominant set	0	K/N_{A_r}	0
ΔV for inactive A-units of dominant set	0	0	$\frac{-N_{a_r}}{N_{A_r}-N_{a_r}}$
Mean value of A-system	Increases with number of reinforcements	Increases with time	Constant
Difference between mean values of source-sets	Proportional to differences of reinforcement frequency $(n_{s_{r_1}}-n_{s_{r_2}})$	0	0

Note: In the β and γ systems, the total value-change for any A-unit will be the sum of the ΔV's for all source-sets of which it is a member.

N_{a_r} = Number of active units in source-set
N_{A_r} = Total number of units in source-set
$n_{s_{r_i}}$ = Number of stimuli associated to response r_i
K = Arbitrary constant

tendem a obter vantagem sobre o outro, e será o que ocorrerá. Se tal sistema for capaz de aprender, então deve ser possível modificar as unidades A ou suas conexões de tal forma que os estímulos de uma classe tenderão a evocar um impulso mais forte no conjunto fonte Ri do que no conjunto fonte Ra, enquanto estímulos de outra classe (diferente) tenderão a evocar um impulso mais forte no conjunto fonte Ra do que no conjunto fonte Ri.

Será assumido que os impulsos entregues por cada unidade A podem ser caracterizados por um valor, V, que pode ser uma amplitude, frequência, latência ou probabilidade de completar a transmissão. Se uma unidade A tiver um valor alto, então todos os seus impulsos de saída serão considerados mais eficazes, mais potentes ou com maior probabilidade de chegar aos bulbos terminais do que os impulsos de uma unidade A com valor inferior. O valor de uma unidade A é considerado uma característica bastante estável, provavelmente dependendo da condição metabólica da célula e da membrana celular, mas não é absolutamente constante. Supõe-se que, em geral, os períodos de atividade tendem a aumentar o valor de uma célula, enquanto o valor pode decair (e m alguns modelos) com a inatividade. Os modelos mais interessantes são aqueles em que se presume que as células competem por materiais metabólicos, ganhando as células mais activas à custa das células menos activas. Num tal sistema, se não houver actividade, todas as células tenderão a permanecer nu ma condição relativamente constante, e (independentemente da actividade) o valor líquido do sistema, considerado

TABELA 1 COMPARAÇÃO OU CARACTERÍSTICAS LÓGICAS DOS SISTEMAS a, /3 e 7

	a-Sistema (Sistema de ganho não compensado)	/3-Sistema (Alimentação Constante Sistema)	7-Sistema (Ganho Parasita Sistema)
Ganho de valor total do conjunto fonte por reforçar			
AV para unidades A ativas por 1 unidade de tempo		K/N_{a_r}	
AV para unidades A inativas fora do domicílio conjunto nant			
AV para unidades A inativas do conjunto dominante			$\frac{-N_{a_r}}{N_{A_r}-N_{a_r}}$
Valor médio do sistema A	Aumenta com número de reforços	Aumenta com	Constante
Diferença entre valores médios de conjuntos de origem	Proporcional a diferente ências de reforço frequência de implementação $(n_{s_{r_1}}-n_{s_{r_2}})$		

Nota: Nos sistemas /3 e 7, a alteração total de valor para qualquer unidade A será a soma dos AVs para todos os conjuntos de fontes dos quais é membro.

N»r = Número de unidades ativas no conjunto fonte
NA_T — Número total de unidades no conjunto fonte «„ = Número de estímulos associados à resposta TJ K = Constante arbitrária

its entirety, will remain constant at all times. Three types of systems, which differ in their value dynamics, have been investigated quantitatively. Their principal logical features are compared in Table 1. In the alpha system, an active cell simply gains an increment of value for every impulse, and holds this gain indefinitely. In the beta system, each source-set is allowed a certain constant rate of gain, the increments being apportioned among the cells of the source-set in proportion to their activity. In the gamma system, active cells gain in value at the expense of the inactive cells of their source-set, so that the total value of a source-set is always constant.

For purposes of analysis, it is convenient to distinguish two phases in the response of the system to a stimulus (Fig. 3). In the *predominant phase*, some proportion of A-units (represented by solid dots in the figure) responds to the stimulus, but the R-units are still inactive. This phase is transient, and quickly gives way to the *postdominant phase*, in which one of the responses becomes active, inhibiting activity in the complement of its own source-set, and thus preventing the occurrence of any alternative response. The response which happens to become dominant is initially random, but if the A-units are reinforced (i.e., if the active units are allowed to gain in value), then when the same stimulus is presented again at a later time, the same response will have a stronger tendency to recur, and learning can be said to have taken place.

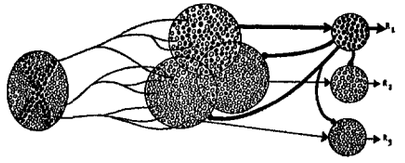


FIG. 3A. Predominant phase. Inhibitory connections are not shown. Solid black units are active.

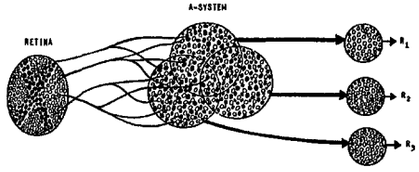


FIG. 3B. Postdominant phase. Dominant subset suppresses rival sets. Inhibitory connections shown only for R1.

FIG. 3. Phases of response to a stimulus.

ANALYSIS OF THE PREDOMINANT PHASE

The perceptrons considered here will always assume a fixed threshold, θ, for the activation of the A-units. Such a system will be called a *fixed-threshold model*, in contrast to a *continuous transducer model*, where the response of the A-unit is some continuous function of the impinging stimulus energy.

In order to predict the learning curves of a fixed-threshold perceptron, two variables have been found to be of primary importance. They are defined as follows:

P_a = the expected proportion of A-units activated by a stimulus of a given size,

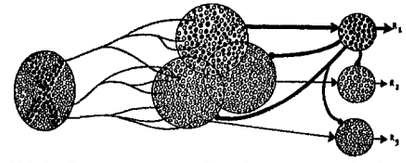
P_c = the conditional probability that an A-unit which responds to a given stimulus, S_1, will also respond to another given stimulus, S_2.

It can be shown (Rosenblatt, **15**) that as the size of the retina is increased, the number of S-points (N_s) quickly ceases to be a significant parameter, and the values of P_a and P_c approach the value that they would have for a retina with infinitely many points. For a large retina, therefore, the equations are as follows:

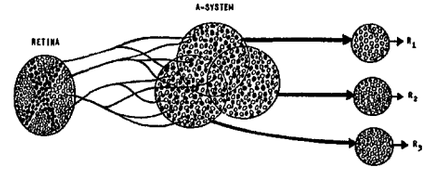
$$P_a = \sum_{e=\theta}^{x} \sum_{i=\theta}^{min\ (y,\ e-\theta)} P(e,i) \qquad (1)$$

sua totalidade, permanecerá constante em todos os momentos. Três tipos de sistemas, que diferem na sua dinâmica de valor, foram investigados quantitativamente. Suas principais características lógicas são comparadas na Tabela 1. No sistema alfa, uma célula ativa simplesmente ganha um incremento de valor para cada impulso e mantém esse ganho indefinidamente. No sistema beta, é permitida a cada conjunto fonte uma certa taxa constante de ganho, sendo os incrementos distribuídos entre as células do conjunto fonte em proporção à sua atividade. No sistema gama, as células ativas ganham valor às custas das células inativas do seu conjunto fonte, de modo q ue o valor total de um conjunto fonte é sempre constante.

Para fins de análise, é conveniente distinguir duas fases na resposta do siste ma a um estímulo (Fig. 3). Na fase predominante, alguma proporção de unidades A (representadas por pontos sólidos na figura) responde ao estímulo, mas as unidades R ainda estão inativas. Esta fase é transitória e rapidamente dá lugar à fase pós-dominante, na qual uma das respostas se torna ativa, inibindo a atividade do complexo.



FIGO. 3A. Fase predominante. Conexões inibitórias não são mostradas. Unidades pretas sólidas estão ativas.



FIGO. 3B. Fase pós-dominante. O subconjunto dominante suprime os conjuntos rivais. Conexões inibitórias mostradas apenas para Ri.

FIGO. 3. Fases de resposta a um estímulo,

implementação de seu próprio conjunto de fontes, evitando assim a ocorrência de qualquer resposta alternativa. A resposta que se torna dominante é inicialmente aleatória, mas se as unidades A forem reforçadas (ou seja, se for permitido que as unidades ativas ganhem valor), então, quando o mesmo estímulo for apresentado novamente num momento posterior, a mesma resposta terá uma tendência mais forte para se repetir, e pode-se dizer que a aprendizagem ocorreu.

ANÁLISE DA FASE PREDOMINANTE

Os perceptrons aqui considerados sempre assumirão um limite fixo, 6, para a ativação das unidades A. Tal sistema será chamado de modelo de limiar fixo, em contraste com um modelo de transdutor contínuo, onde a resposta da unidade A é alguma função contínua da energia do estímulo incidente.

Para prever as curvas de aprendizagem de um perceptron de limiar fixo, duas variáveis foram consideradas de importância primordial. Eles são definidos da seguinte forma:

P_a = a proporção esperada de unidades A ativadas por um estímulo de um determinado tamanho,

PC = a probabilidade condicional de que uma unidade A que responde a um determinado estímulo, Si, também responderá a outro determinado estímulo, 82-

Pode ser mostrado (Rosenblatt, IS) que à medida que o tamanho da retina aumenta, o número de pontos S (N_a} rapidamente deixa de ser um parâmetro significativo, e os valores de P_a e P_c se aproximam do valor que teriam para uma retina com infinitos pontos. Para uma retina grande, portanto, as equações são as seguintes:

$$P_a = \sum_{e=\theta}^{x} \sum_{i=\theta}^{min\ (y,\ e-\theta)} P(e,i) \qquad (1)$$

where

$$P(e,i) = \binom{x}{e} R^e(1-R)^{x-e} \times \binom{y}{i} R^i(1-R)^{y-i}$$

and

R = proportion of S-points activated by the stimulus
x = number of excitatory connections to each A-unit
y = number of inhibitory connections to each A-unit
θ = threshold of A-units.

(The quantities e and i are the excitatory and inhibitory components of the excitation received by the A-unit from the stimulus. If the algebraic sum $\alpha = e + i$ is equal to or greater than θ, the A-unit is assumed to respond.)

$$P_c = \frac{1}{P_a} \sum_{e=\theta}^{x} \sum_{i=e-\theta}^{y} \sum_{l_e=0}^{e} \sum_{l_i=0}^{i} \sum_{g_e=0}^{x-e} \sum_{g_i=0}^{y-i} P(e,i,l_e,l_i,g_e,g_i) \qquad (2)$$

$$(e - i - l_e + l_i + g_e - g_i \geq \theta)$$

where

$$P(e,i,l_e,l_i,g_e,g_i) = \binom{x}{e} R^e(1-R)^{x-e} \times \binom{y}{i} R^i(1-R)^{y-i} \times \binom{e}{l_e} L^{l_e}(1-L)^{e-l_e} \times \binom{i}{l_i} L^{l_i}(1-L)^{i-l_i} \times \binom{x-e}{g_e} G^{g_e}(1-G)^{x-e-g_e} \times \binom{y-i}{g_i} G^{g_i}(1-G)^{y-i-g_i}$$

and

L = proportion of the S-points illuminated by the first stimulus, S_1, which are not illuminated by S_2
G = proportion of the residual S-set (left over from the first stimulus) which is included in the second stimulus (S_2).

The quantities R, L, and G specify the two stimuli and their retinal overlap. l_e and l_i are, respectively, the numbers of excitatory and inhibitory origin points "lost" by the A-unit when stimulus S_1 is replaced by S_2; g_e and g_i are the numbers of excitatory and inhibitory origin points "gained" when stimulus S_1 is replaced by S_2. The summations in Equation 2 are between the limits indicated, subject to the side condition $e - i - l_e + l_i + g_e - g_i \geq \theta$.

Some of the most important characteristics of P_a are illustrated in Fig. 4, which shows P_a as a function of the retinal area illuminated (R). Note that P_a can be reduced in magnitude by either increasing the threshold, θ, or by increasing the proportion of inhibitory connections (y). A comparison of Fig. 4b and 4c shows that if the excitation is about equal to the inhibition, the curves for P_a as a function of R are flattened out, so that there is little variation in P_a for stimuli of different sizes. This fact is of great importance for systems which require P_a to be close to an optimum value in order to perform properly.

The behavior of P_c is illustrated in Fig. 5 and 6. The curves in Fig. 5 can be compared with those for P_a in Fig. 4. Note that as the threshold is increased, there is an even sharper reduction in the value of P_c than was the case with P_a. P_c also decreases as the proportion of inhibitory connections increases, as does P_a. Fig. 5, which is

onde

$$P(e,i) = \binom{x}{e} R^e(1-R)^{x-e} \times \binom{y}{i} R^i(1-R)^{y-i}$$

R = proporção de pontos S ativados pelo estímulo x — número de conexões excitatórias para cada unidade A y = número de conexões inibitórias para cada unidade A 0 = limiar de unidades A.

(As quantidades e e i são os componentes excitatórios e inibitórios da excitação recebida pela unidade A do estímulo. Se a soma algébrica a = e + i for igual ou superior a 6, presume-se que a unidade A responda.)

$$P_c = \frac{1}{P_a} \sum_{e=\theta}^{x} \sum_{i=e-\theta}^{y} \sum_{l_e=0}^{e} \sum_{l_i=0}^{i} \sum_{g_e=0}^{x-e} \sum_{g_i=0}^{y-i} P(e,i,l_e,l_i,g_e,g_i) \qquad (2)$$

$$(e - i - l_e + l_i + g_e - g_i \geq \theta)$$

onde

$$P(e,i,l_e,l_i,g_e,g_i) = \binom{x}{e} R^e(1-R)^{x-e} \times \binom{y}{i} R^i(1-R)^{y-i} \times \binom{e}{l_e} L^{l_e}(1-L)^{e-l_e} \times \binom{i}{l_i} L^{l_i}(1-L)^{i-l_i} \times \binom{x-e}{g_e} G^{g_e}(1-G)^{x-e-g_e} \times \binom{y-i}{g_i} G^{g_i}(1-G)^{y-i-g_i}$$

L — proporção de pontos S iluminados pelo primeiro estímulo, Si, que não são iluminados por S_2

G — proporção do S-set residual (sobra do primeiro estímulo) que é incluída no segundo estímulo (82).

As quantidades R, L e G especificam os dois estímulos e sua sobreposição retinal. l_e e /,• são, respectivamente, os números de pontos de origem excitatórios e inibitórios " perdidos" pela unidade A quando o estímulo Si é substituído por 82; g_e e gi são os números de pontos de origem excitatórios e inibitórios "ganhos" quando o estímulo Si é substituído por 82. Os somatórios na Equação 2 estão entre os limites indicados, sujeitos à condição l ateral e — i — I, + l
+ > 0 g, - gi .

Algumas das características mais importantes de P_a estão ilustradas na Fig. 4, que mostra P_a em função da área iluminada da retina (R). Observe que P_a pode ser reduzido em magnitude aumentando o limite, 6, ou aumentando a proporção de conexões inibitórias (y). Uma comparação das Figuras 4b e 4c mostra que se a excitação for aproximadamente igual à inibição, as curvas para P_a em função de R são achatadas, de modo que há pouca variação em P_a para estímulos de ta manhos diferentes. Este fato é de grande importância para sistemas que necessitam que P_a esteja próximo de um valor ótimo para funcionar adequadamente.

O comportamento de P_c é ilustrado nas Figuras 5 e 6. As curvas da Figura 5 podem ser comparadas com aquelas de P_a na Figura 4. Observe que à medida que o li mite é aumentado, há uma redução ainda mais acentuada no valor de P_c do que foi o caso com P_a. P_c também diminui à medida que a proporção de conexões inibitórias aumenta, assim como P_a. Figura 5, que é

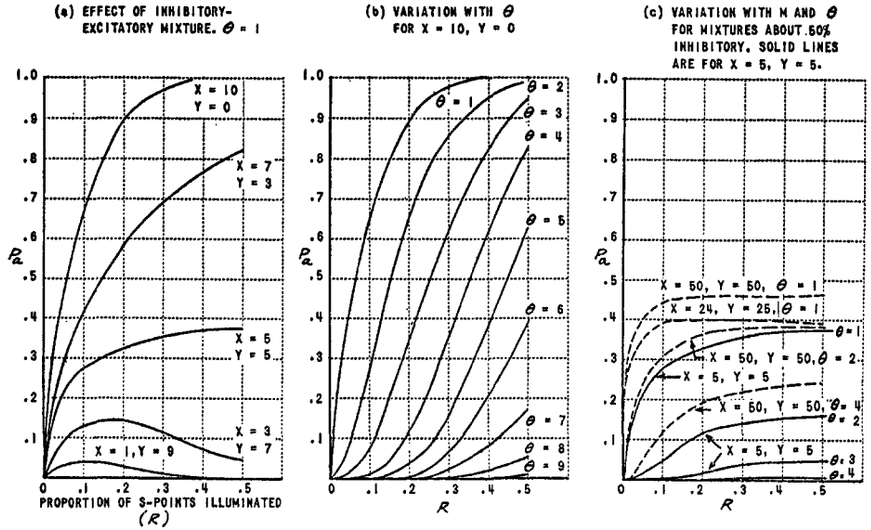


FIG. 4. P_a as function of retinal area illuminated.

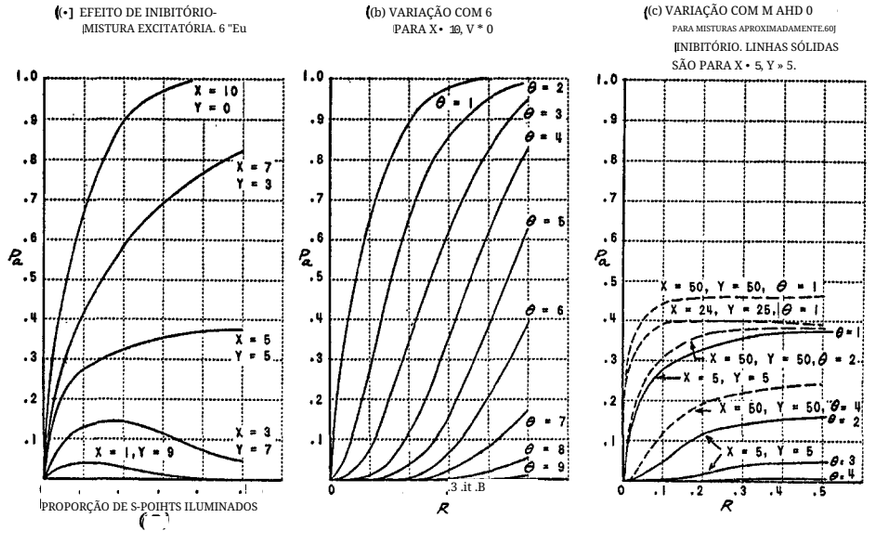
calculated for nonoverlapping stimuli, illustrates the fact that P_c remains greater than zero even when the stimuli are completely disjunct, and illuminate no retinal points in common. In Fig. 6, the effect of varying amounts of overlap between the stimuli is shown. In all cases, the value of P_c goes to unity as the stimuli approach perfect identity. For smaller stimuli (broken line curves), the value of P_c is lower than for large stimuli. Similarly, the value is less for high thresholds than for low thresholds. The minimum value of P_c will be equal to

$$P_{cmin} = (1 - L)^x(1 - G)^y. \quad (3)$$

In Fig. 6, P_{cmin} corresponds to the curve for $\theta = 10$. Note that under these conditions the probability that the A-unit responds to both stimuli (P_c) is practically zero, except for stimuli which are quite close to identity. This condition can be of considerable help in discrimination learning.

MATHEMATICAL ANALYSIS OF LEARNING IN THE PERCEPTRON

The response of the perceptron in the predominant phase, where some fraction of the A-units (scattered throughout the system) responds to the stimulus, quickly gives way to the postdominant response, in which activity is limited to a single source-set, the other sets being suppressed. Two possible systems have been studied for the determination of the "dominant" response, in the postdominant phase. In one (the mean-discriminating system, or μ-system), the response whose inputs have the greatest mean value responds first, gaining a slight advantage over the others, so that it quickly becomes dominant. In the second case (the sum-discriminating system, or Σ-system), the response whose inputs have the greatest net value gains an advantage. In most cases, systems which respond to mean values have an advantage over systems which respond to sums, since the means are



FIGO. 4. P_0 em função da área da retina iluminada.

calculado para estímulos não sobrepostos, ilustra o fato de que P_c permanece maior que zero mesmo quando os estímulos são completamente disjuntos e não iluminam pontos retinianos em comum. Na Figura 6, é mostrado o efeito de diferentes quantidades de sobreposição entre os estímulos. Em todos os casos, o valor de P_c vai para a unidade à medida que os estímulos se aproximam da identidade perfeita. Para estímulos menores (curvas de linha tracejada), o valor de P_c é menor do que para estímulos grandes. Da mesma forma, o valor é menor para limiares elevados do que para limiares baixos. O valor mínimo de P_c será igual a

)

Na Fig. 6, Pemin corresponde à curva para 6 = 10. Observe que nessas condições a probabilidade de a unidade A responder a ambos os estímulos (P_c) é praticamente zero, exceto para estímulos bastante próximos da identidade. Esta condição pode ser de grande ajuda na a prendizagem da discriminação.

ANÁLISE MATEMÁTICA DA APRENDIZAGEM NO PERCEPTRON

A resposta do perceptron na fase predominante, onde alguma fração das unidades A (espalhadas por todo o sist ema) responde ao estímulo, rapidamente dá lugar à resposta pós-dominante, na qual a atividade é limitada a um único conjunto-fonte, sendo os outros conjuntos suprimidos. Dois possíveis sistemas foram estudados para a determinação da resposta "dominante", na fase pós-dominante. Num deles (o sistema de discriminação de médias, ou ju-sistema), a resposta cujos inputs têm o maior valor médio responde primeiro, ganhando uma ligeira vantagem sobre as outras, de modo que rapidamente se torna dominante. No segundo caso (o sistema discriminatório de soma, ou sistema S), a resposta cujos insumos têm o maior valor líquido ganha uma vantagem. Na maioria dos casos, os sistemas que respondem a valores médios têm uma vantagem sobre os sistemas que respondem a somas, uma vez que as médias são

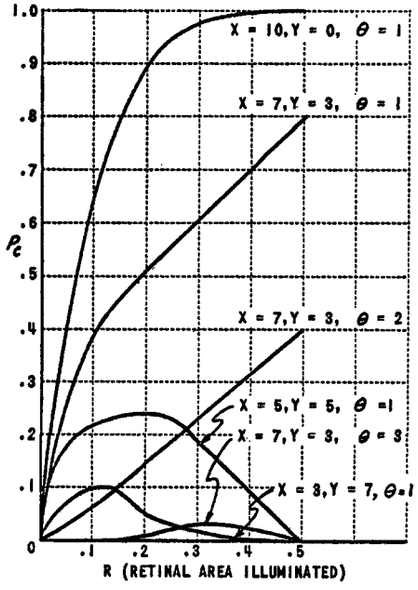


FIG. 5. P_c as a function of R, for nonoverlapping stimuli.

less influenced by random variations in P_a from one source-set to another. In the case of the γ-system (see Table 1), however, the performance of the μ-system and Σ-system become identical.

We have indicated that the perceptron is expected to learn, or to form associations, as a result of the changes in value that occur as a result of the activity of the association cells. In evaluating this learning, one of two types of hypothetical experiments can be considered. In the first case, the perceptron is exposed to some series of stimulus patterns (which might be presented in random positions on the retina) and is "forced" to give the desired response in each case. (This forcing of responses is assumed to be a prerogative of the experimenter. In experiments intended to evaluate trial-and-error learning, with more sophisticated perceptrons, the experimenter does not force the system to respond in the desired fashion, but merely applies positive reinforcement when the response happens to be correct, and negative reinforcement when the response is wrong.) In evaluating the learning which has taken place during this "learning series," the perceptron is assumed to be "frozen" in its current condition, no further value changes being allowed, and the same series of stimuli is presented again in precisely the same fashion, so that the stimuli fall on identical positions on the retina. The probability that the perceptron will show a bias towards the "correct" response (the one which has been previously reinforced during the learning series) in preference to any given alternative response is called P_r, the probability of correct choice of response between two alternatives.

In the second type of experiment, a learning series is presented exactly as before, but instead of evaluating the perceptron's performance using the same series of stimuli which were shown before, a new series is presented, in which stimuli may be drawn from the same *classes* that were previ-

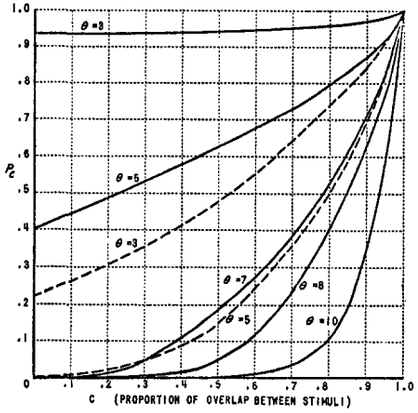
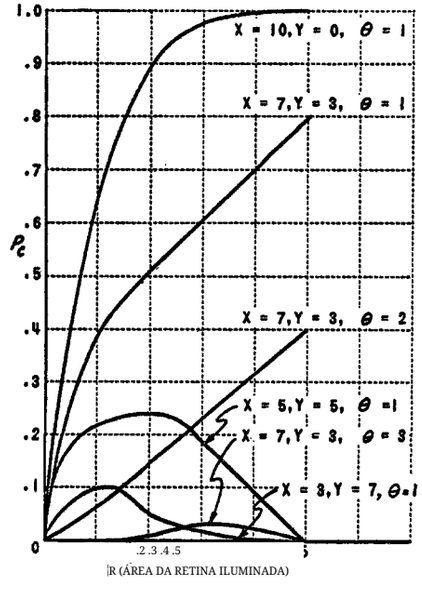


FIG. 6. P_c as a function of C. $X = 10$, $Y = 0$. Solid lines: R = .5; broken lines: R = .2.

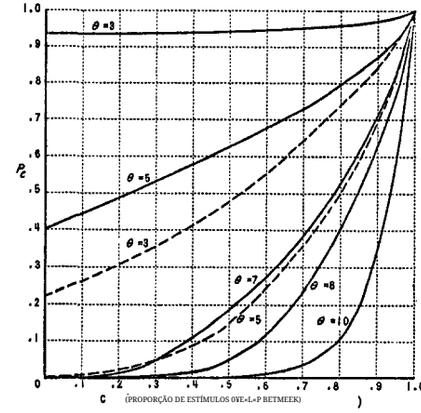


FIGO. 5. P_c em função de R, para estímulos não sobrepostos.

menos influenciado por variações aleatórias em P_a de um conjunto fonte para outro. No caso do sistema -/- (consulte a Tabela 1), entretanto, o desempenho do sistema ^ e do sistema S torna-se idêntico.

Indicamos que se espera que o perceptron aprenda, ou forme associações, como resultado das mudanças de valor que ocorrem como resultado da atividade das células de associação. Ao avaliar esta aprendizagem, um de dois tipos de experimentos hipotéticos pode ser considerado. No primeiro caso, o perceptron é exposto a uma série de padrões de estímulo (que podem ser apresentados em posições aleatórias na retina) e é "forçado" a dar a resposta desejada em cada caso. (Supõe-se que esse forçamento de respostas seja uma prerrogativa do experimentador. Em experimentos destinados a avaliar a aprendizagem por tentativa e erro, com perceptrons mais sofisticados, o experimentador não força o sistema a responde da maneira desejada, mas apenas aplica reforço positivo quando a resposta está correta, e reforço negativo quando a resposta está errada.) Ao avaliar a aprendizagem que ocorreu durante esta " série de aprendizagem", supõe-se que o perceptron esteja "congelado" em sua condição atual, não sendo permitidas mais alterações de valor, e a mesma série de estímulos é apresentada novamente precisamente da mesma maneira, de modo que os estímulos caiam em posições idênticas na retina. A probabilidade de o perceptron mostrar uma tendência para a resposta "correta" (aquela que foi previamente reforçada durante a série de aprendizagem) em preferência a qualquer resposta alternativa é chamada P_r, a probabilidade de escolha correta da resposta entre duas alternativas.

No segundo tipo de experimento, uma série de aprendizagem é apresentada exatamente como antes, mas em vez de avaliar o desempenho do perceptron usando a mesma série de estímulos mostrada anteriormente, uma nova série é aprese ntada, na qual os estímulos podem ser extraídos das mesmas classes que foram apresentadas anteriormente.



FIGO. 6. P_c em função de C. X - 10, Y = 0. Linhas sólidas: R = .5; linhas tracejadas: R = .2.

ously experienced, but are not necessarily identical. This new test series is assumed to be composed of stimuli projected onto random retinal positions, which are chosen independently of the positions selected for the learning series. The stimuli of the test series may also differ in size or rotational position from the stimuli which were previously experienced. In this case, we are interested in the probability that the perceptron will give the correct response for the *class* of stimuli which is represented, regardless of whether the particular stimulus has been seen before or not. This probability is called P_g, the probability of correct generalization. As with P_r, P_g is actually the probability that a bias will be found in favor of the proper response rather than any one alternative; only one pair of responses at a time is considered, and the fact that the response bias is correct in one pair does not mean that there may not be other pairs in which the bias favors the wrong response. The probability that the correct response will be preferred over *all* alternatives is designated P_R or P_G.

In all cases investigated, a single general equation gives a close approximation to P_r and P_g, if the appropriate constants are substituted. This equation is of the form:

$$P = P(N_{a_r} > 0) \cdot \phi(Z) \qquad (4)$$

where

$$P(N_{a_r} > 0) = 1 - (1 - P_a)^{N_e}$$

$\phi(Z)$ = normal curve integral from $-\infty$ to Z

and

$$Z = \frac{c_1 n_{s_r} + c_2}{\sqrt{c_3 n_{s_r}^2 + c_4 n_{s_r}}}.$$

If R_1 is the "correct" response, and R_2 is the alternative response under consideration, Equation 4 is the probability that R_1 will be preferred over R_2 after n_{s_r} stimuli have been shown for each of the two responses, during the learning period. N_e is the number of "effective" A-units in each source-set; that is, the number of A-units in either source-set which are not connected in common to both responses. Those units which are connected in common contribute equally to both sides of the value balance, and consequently do not affect the net bias towards one response or the other. N_{a_r} is the number of active units in a source-set, which respond to the test stimulus, S_t. $P(N_{a_r} > 0)$ is the probability that at least one of the N_e effective units in the source-set of the correct response (designated, by convention, as the R_1 response) will be activated by the test stimulus, S_t.

In the case of P_g, the constant c_2 is always equal to zero, the other three constants being the same as for P_r. The values of the four constants depend on the parameters of the physical nerve net (the perceptron) and also on the organization of the stimulus environment.

The simplest cases to analyze are those in which the perceptron is shown stimuli drawn from an "ideal environment," consisting of randomly placed points of illumination, where there is no attempt to classify stimuli according to intrinsic similarity. Thus, in a typical learning experiment, we might show the perceptron 1,000 stimuli made up of random collections of illuminated retinal points, and we might arbitrarily reinforce R_1 as the "correct" response for the first 500 of these, and R_2 for the remaining 500. This environment is "ideal" only in the sense that we speak of an ideal gas in physics; it is a convenient artifact for purposes of analysis, and does not lead to the best performance from the perceptron. In the ideal environment situation, the constant c_1 is always equal to zero, so that, in the

experimentados, mas não são necessariamente idênticos. Supõe-se que esta nova série de testes seja composta de estímulos projetados em posições aleatórias da retina, que são escolhidas independentemente das posições selecionadas para a série de aprendizagem. Os estímulos da série de testes também podem diferir em tamanho ou posição rotacional dos estímulos que foram experimentados anteriormente. Neste caso, estamos interessados na probabilidade de o perceptron dar a resposta correta para a classe de estímulos que está representada, independentemente de o estímulo específico ter sido visto antes ou não. Esta probabilidade é chamada P_r, a probabilidade de generalização correta. Tal como acontece com P_r, P_g é na verdade a probabilidade de que um viés seja encontrado em favor da resposta adequada em vez de qualquer alternativa; apenas um par de respostas por vez é considerado, e o fato de o viés da resposta ser correto em u m par não significa que possa não haver outros pares em que o viés favoreça a resposta errada. A probabilidade de a resposta correta ser preferida a todas as alternativas é designada PR ou Pa.

Em todos os casos investigados, uma única equação geral dá uma grande aproximação a P_r e P_g, se as constantes apropriadas forem substituídas. Esta equação é da forma:

$$P = P(N_{a_r} > 0) \cdot \phi(Z) \qquad (4)$$

onde

<t>(Z) = integral da curva normal from $-\infty$ to Z

$$Z = \frac{c_1 n_{s_r} + c_2}{\sqrt{c_3 n_{s_r}^2 + c_4 n_{s_r}}}.$$

Se Ri for a resposta "correta" e R_2 for a resposta alternativa em consideração, a Equação 4 é a probabilidade de que Rj seja preferido a

Ra após n_{sr} estímulos foram mostrados para cada uma das duas respostas, durante o período de aprendizagem. N, é o número de unidades A "efetivas" em cada conjunto fonte; isto é, o número de unidades A em qualquer conjunto fonte que não estão conectadas em comum a ambas as respostas. As unidades que estão ligadas e m comum contribuem igualmente para ambos os lados do equilíbrio de valor e, consequentemente, não afectam a t endência líquida para uma resposta ou outra. N_{ar} é o número de unidades ativas e m um conjunto fonte, que respondem ao estímulo de teste, S_t-P($Na_r > 0$) é a probabilidade de que pelo menos uma das N_e unidades efetivas no conjunto fonte da resposta correta (designada, por convenção, como a resposta Ri) seja ativada pelo estímulo de teste, S_t.

No caso de P_g, a constante c_2 é sempre igual a zero, sendo as outras três constantes iguais a P_r. Os valores das quatro constantes dependem dos parâmetros da rede nervosa física (o perceptron) e também da organização do ambiente de estímulo.

Os casos mais simples de analisar são aqueles em que são mostrados ao perceptron estímulos extraídos de um " ambiente ideal", consistindo de pontos de iluminação colocados aleatoriamente, onde não há tentativa de classificar os estímulos de acordo com a similaridade intrínseca. Assim, num experimento de aprendizagem típico, poderíamos mostrar ao perceptron 1.000 estímulos compostos de coleções aleatórias de pontos retinais iluminados, e poderíamos reforçar arbitrariamente Ri como a resposta "correta" para os pri meiros 500 deles, e R.2 para os 500 r estantes. Este ambiente é "ideal" apenas no sentido de que falamos de um gás ideal em física; é um artefato conveniente para fins de análise e não leva ao melhor desempenho do perceptron. Na situação de ambiente ideal, a constante c\ é sempre i gual a zero, de modo que, no

case of P_g (where c_2 is also zero), the value of Z will be zero, and P_g can never be any better than the random expectation of 0.5. The evaluation of P_r for these conditions, however, throws some interesting light on the differences between the alpha, beta, and gamma systems (Table 1).

First consider the alpha system, which has the simplest dynamics of the three. In this system, whenever an A-unit is active for one unit of time, it gains one unit of value. We will assume an experiment, initially, in which N_{s_r} (the number of stimuli associated to each response) is constant for all responses. In this case, for the sum system,

$$\left.\begin{aligned} c_1 &= 0 \\ c_2 &= (1 - P_a)N_e \\ c_3 &= 2P_a\omega \\ c_4 &\approx 0 \end{aligned}\right\} \qquad (5)$$

where ω = the fraction of responses connected to each A-unit. If the source-sets are disjunct, $\omega = 1/N_R$, where N_R is the number of responses in the system. For the μ-system,

$$\left.\begin{aligned} c_1 &= 0 \\ c_2 &= (1 - P_a)N_e \\ c_3 &= 0 \\ c_4 &= 2\omega \end{aligned}\right\} \qquad (6)$$

The reduction of c_3 to zero gives the μ-system a definite advantage over the Σ-system. Typical learning curves for these systems are compared in Fig. 7 and 8. Figure 9 shows the effect of variations in P_a upon the performance of the system.

If n_{s_r}, instead of being fixed, is treated as a random variable, so that the number of stimuli associated to each response is drawn separately from some distribution, then the per-

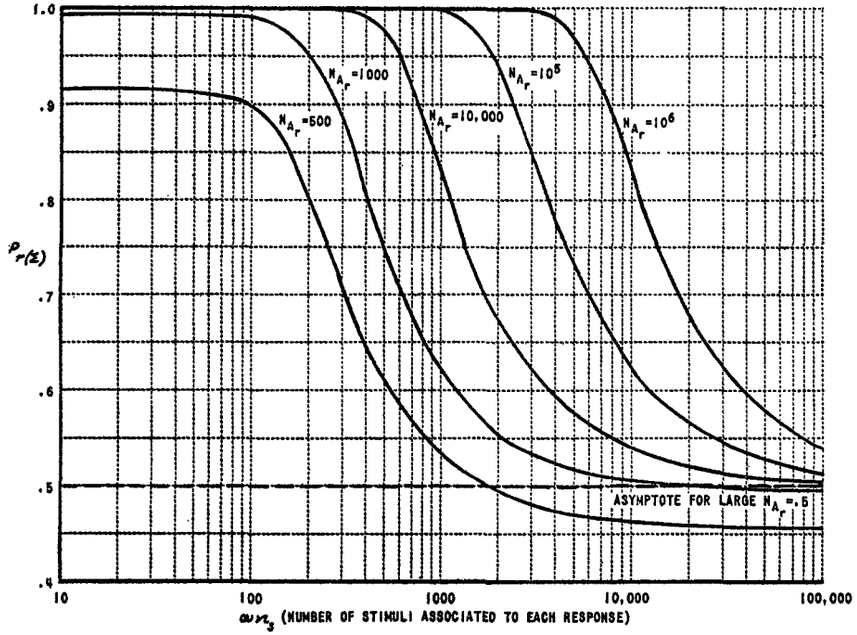


FIG. 7. $P_r(\Sigma)$ as function of ωn_s, for discrete subsets. ($\omega_e = 0$, $P_a = .005$. Ideal environment assumed.)

caso de P_g (onde c_2 também é zero), o valor de Z será zero e P_g nunca poderá ser melhor do que a expectativa aleatória de 0,5. A avaliação de P_r para estas condições, no entanto, lança alguma luz interessante sobre as diferenças entre os sistemas alfa, beta e gama (Tabela 1).

Primeiro considere o sistema alfa, que possui a dinâmica mais simples dos três. Neste sistema, sempre que uma unidade A estiver ativa por uma unidade de tempo, ela ganha uma unidade de valor. Assumiremos um experimento, inicialmente, em que N_{s_r} (o número de estímulos associados a cada resposta) é constante para todas as respostas. Neste caso, para o sistema de soma,

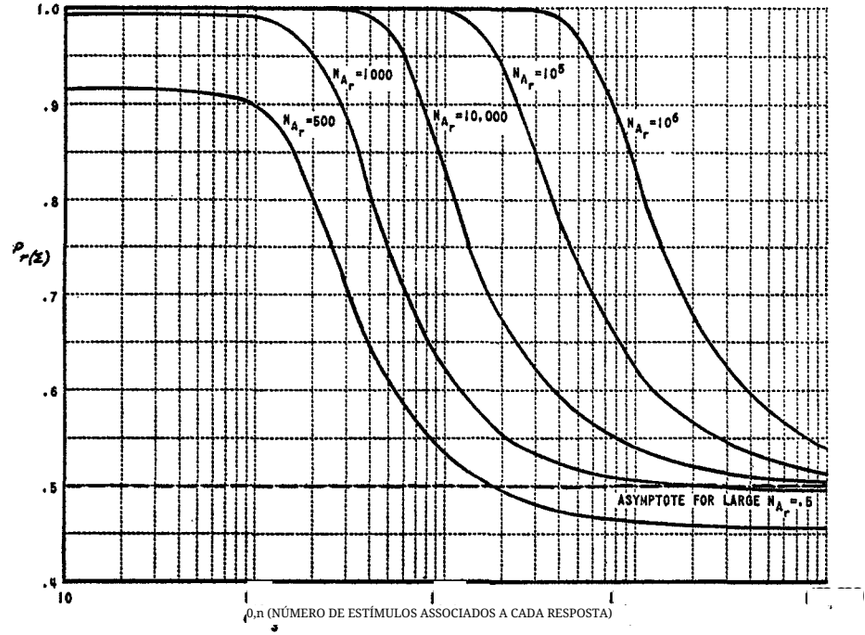
$$\left.\begin{aligned} c_1 &= 0 \\ c_2 &= (1 - P_a)N_e \\ c_3 &= 2P_a\omega \\ c_4 &\approx 0 \end{aligned}\right\} \qquad (5)$$

onde u> = a fração de respostas conectadas a cada unidade A. Se os conjuntos-fonte forem disjuntos, w = I/NR, onde NR é o número de respostas no sistema. Para o sistema ^,

$$\left.\begin{aligned} c_1 &= 0 \\ c_2 &= (1 - P_a)N_e \\ c_3 &= 0 \\ c_4 &= 2\omega \end{aligned}\right\} \qquad (6)$$

A redução de c_3 a zero dá ao sistema ^ uma vantagem definitiva sobre o sistema S. Curvas de aprendizado típicas para esses sistemas são comparadas nas Figuras 7 e 8. A Figura 9 mostra o efeito das variações em P_a sobre o desempenho do sistema.

Se n_{s_r}, em vez de ser fixo, for tratado como uma variável aleatória, de modo que o número de estímulos associados a cada resposta seja extraído separadamente de alguma distribuição, então o per-



FIGO. 7. P,(2) em função de an,, para subconjuntos discretos. (a>« = 0, P_a = .005. Ambiente ideal assumido.)

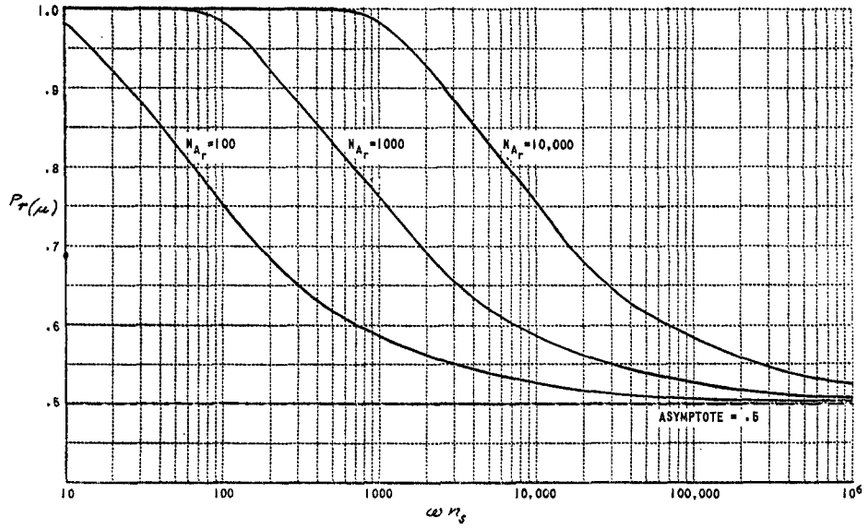


FIG. 8. $P_{r(\mu)}$ as function of ωn_s. (For $P_a = .07$, $\omega_c = 0$. Ideal environment assumed.)

formance of the α-system is considerably poorer than the above equations indicate. Under these conditions, the constants for the μ-system are

$$\left.\begin{aligned} c_1 &= 0 \\ c_2 &= 1 - P_a \\ c_3 &= 2P_a^2q^2\left[\frac{(\omega N_R - 1)^2}{N_R - 2} + 1\right] \\ c_4 &= \frac{2(1 - P_a)N_R}{(1 - \omega_c)N_A} \end{aligned}\right\} \quad (7)$$

where

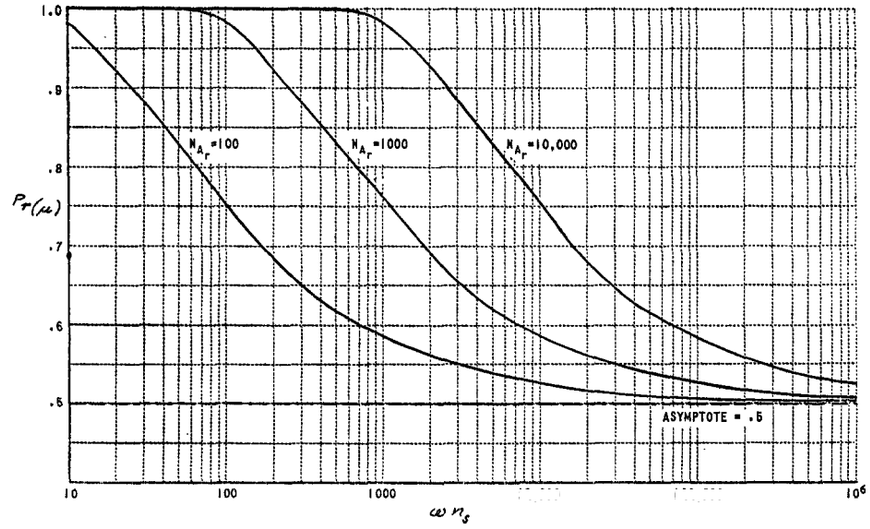
q = ratio of $\sigma_{n_{sr}}$ to $\bar{n}_{sr}$
N_R = number of responses in the system
N_A = number of A-units in the system
ω_c = proportion of A-units common to R_1 and R_2.

For this equation (and any others in which n_{sr} is treated as a random variable), it is necessary to define n_{sr} in Equation 4 as the expected value of this variable, over the set of all responses.

For the β-system, there is an even greater deficit in performance, due to the fact that the net value continues to grow regardless of what happens to the system. The large net values of the subsets activated by a stimulus tend to amplify small statistical differences, causing an unreliable performance. The constants in this case (again for the μ-system) are

$$\left.\begin{aligned} c_1 &= 0 \\ c_2 &= (1 - P_a)N_e \\ c_3 &= 2(P_aN_eq\omega N_R^2)^2 \\ c_4 &= 2(1 - P_a)\omega N_RN_e \end{aligned}\right\} \quad (8)$$

In both the alpha and beta systems, performance will be poorer for the sum-discriminating model than for the mean-discriminating case. In the gamma-system, however, it can be shown that $P_{r(\Sigma)} = P_{r(\mu)}$; i.e., it makes no difference in performance whether the Σ-system or μ-system is used. Moreover, the constants for the γ-system, with variable n_{sr}, are identical to the constants for the alpha μ-sys-



FIGO. 8. Prdit em função de an. (Para P_a — 0,07, w_c = 0. Ambiente ideal assumido.)

O desempenho do sistema-a é consideravelmente pior do que as eq uações acima indicam. Sob estas condições, as constantes para o sistema // são

$$\left.\begin{aligned} c_1 &= 0 \\ c_2 &= 1 - P_a \\ c_3 &= 2P_a^2q^2\left[\frac{(\omega N_R - 1)^2}{N_R - 2} + 1\right] \\ c_4 &= \frac{2(1 - P_a)N_R}{(1 - \omega_c)N_A} \end{aligned}\right\} \quad (7)$$

onde

q = razão de 0*„ para n„ N_R = nú mero de respostas no sistema NA = número de A-unidades no sistema co,. = proporção de unidades A comuns a RX e R2.

Para esta equação (e quaisquer outras em que $n_{,r}$ é tratado como uma variável aleatória), é necessário definir $n_{,r}$ in'. A Equação 4 é o valor esperado desta variável, sobre o conjunto de todas as respostas.

Para o sistema /3, existe um défice ainda maior no desempenho, devido ao facto de o valor líquido continuar a crescer independentemente do que aconteça ao sistema. Os grandes valores líquidos dos subconjuntos ativados por um estímulo tendem a amplificar pequenas diferenças estatísticas, causando um desempenho pouco confiável. As constantes neste caso (novamente para o sistema /u) são

$$\left.\begin{aligned} c_1 &= 0 \\ c_2 &= (1 - P_a)N_e \\ c_3 &= 2(P_aN_eq\omega N_R^2)^2 \\ c_4 &= 2(1 - P_a)\omega N_RN_e \end{aligned}\right\} \quad (8)$$

Tanto no sistema alfa como no beta, o desempenho será pior para o modelo com discriminação de soma do que para o caso com discriminação de média. No sistema gama, entretanto, pode ser mostrado queP,(s) = PK/O; ou seja, não faz diferença no desempenho se o sistema S ou o sistema ^ é usado. Além disso, as constantes para o sistema y, com variável n_{sr}, são idênticas às constantes para o alfa jt-sys-

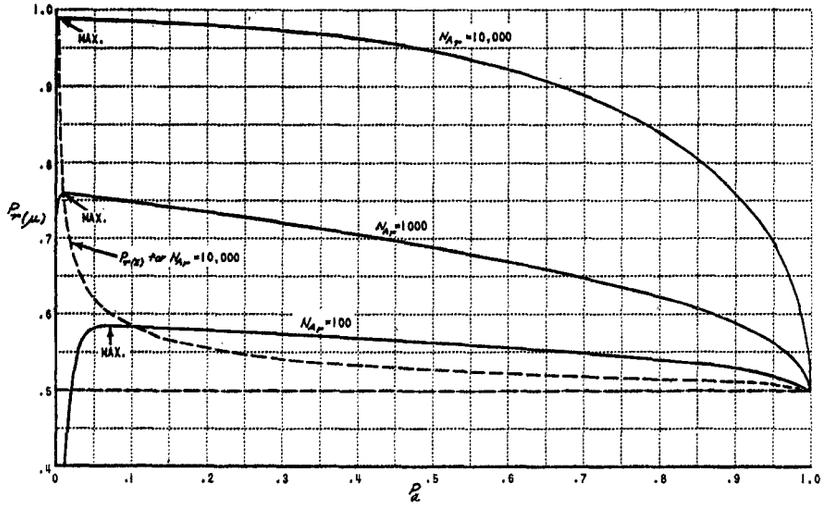


FIG. 9. $P_{r(\mu)}$ as function of P_a. (For $n_{s_r} = 1{,}000$, $\omega_o = 0$. Ideal environment assumed.)

tem, with n_{s_r} fixed (Equation 6). The performance of the three systems is compared in Fig. 10, which clearly demonstrates the advantage of the γ-system.

Let us now replace the "ideal en-

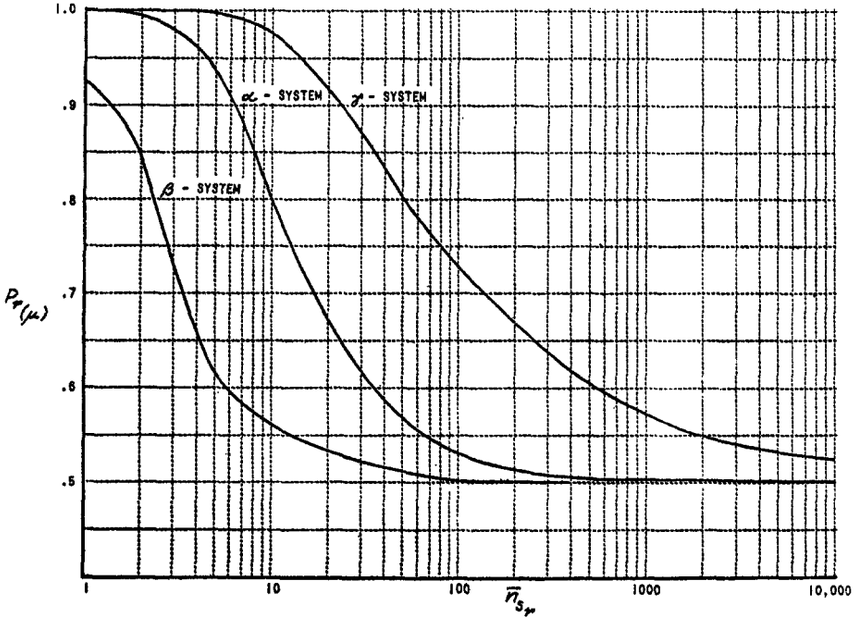
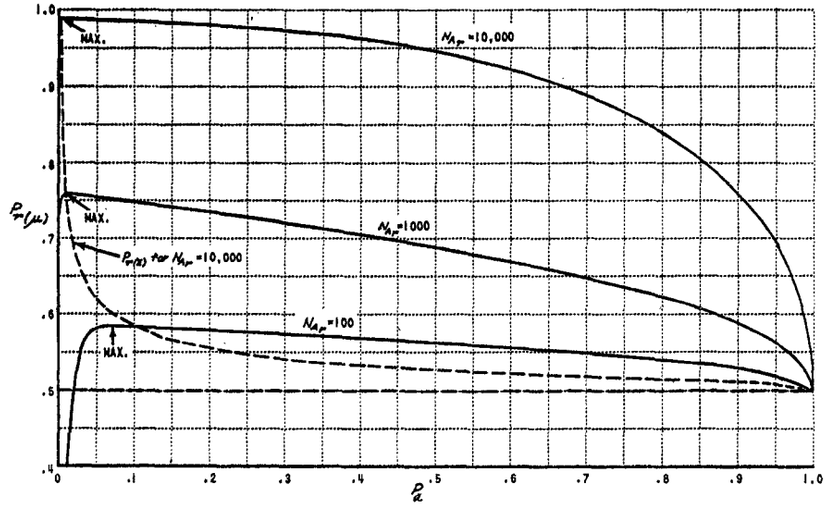


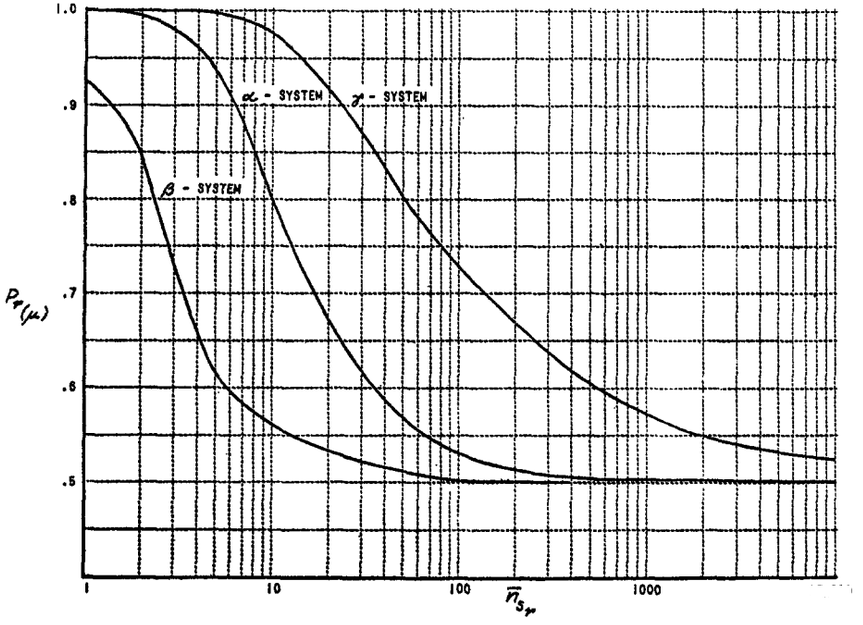
FIG. 10. Comparison of α, β, and γ systems, for variable n_{s_r} ($N_R = 100$, $\sigma_{n_{rs}} = .5\bar{n}_{s_1}$, $N_A = 10{,}000$, $P_a = .07$, $\omega = .2$).



G. 9. P,tf) em função de P*. (Para n_{sr} — 1.000, u, = 0. Ambiente ideal assumido.

tern, com n_{sr} fixo (Equação 6). O desempenho dos três sistemas é comparado na Fig. 10, que claramente demonstra a vantagem do 7-sistema.

Vamos agora substituir o "ambiente ideal"



FIGO. 10. Comparação dos sistemas a, /3 e 7, para a variável «», (N $_R$ = 100, <m_r, = .5*,,, N_A = 10,000, P_a = ,07, w = ,2).

vironment" assumptions with a model for a "differentiated environment," in which several distinguishable classes of stimuli are present (such as squares, circles, and triangles, or the letters of the alphabet). If we then design an experiment in which the stimuli associated to each response are drawn from a different class, then the learning curves of the perceptron are drastically altered. The most important difference is that the constant c_1 (the coefficient of n_{s_r} in the numerator of Z) is no longer equal to zero, so that Equation 4 now has a nonrandom asymptote. Moreover, in the form for P_g (the probability of correct generalization), where $c_2 = 0$, the quantity Z remains greater than zero, and P_g actually approaches the same asymptote as P_r. Thus the equation for the perceptron's performance after infinite experience with each class of stimuli is identical for P_r and P_g:

$$P_{r\infty} = P_{g\infty} = [1 - (1 - P_a)^{N_e}] \times \phi\left(\frac{c_1}{\sqrt{c_3}}\right) \quad (9)$$

This means that *in the limit it makes no difference whether the perceptron has seen a particular test stimulus before or not; if the stimuli are drawn from a differentiated environment, the performance will be equally good in either case.*

In order to evaluate the performance of the system in a differentiated environment, it is necessary to define the quantity $P_{c\alpha\beta}$. This quantity is interpreted as the expected value of P_c between pairs of stimuli drawn at random from classes α and β. In particular, P_{c11} is the expected value of P_c between members of the same class, and P_{c12} is the expected value of P_c between an S_1 stimulus drawn from Class 1 and an S_2 stimulus drawn from Class 2. P_{c1x} is the expected value of P_c between members of Class 1 and stimuli drawn at random from all other classes in the environment.

If $P_{c11} > P_a > P_{c12}$, the limiting performance of the perceptron ($P_{g\infty}$) will be better than chance, and learning of some response, R_1, as the proper "generalization response" for members of Class 1 should eventually occur. If the above inequality is not met, then improvement over chance performance may not occur, and the Class 2 response is likely to occur instead. It can be shown (**15**) that for most simple geometrical forms, which we ordinarily regard as "similar," the required inequality can be met, if the parameters of the system are properly chosen.

The equation for P_r, for the sum-discriminating version of an α-perceptron, in a differentiated environment where n_{s_r} is fixed for all responses, will have the following expressions for the four coefficients:

$$\left.\begin{aligned}
c_1 &= P_a N_e (P_{c11} - P_{c12}) \\
c_2 &= P_a N_e (1 - P_{c11}) \\
c_3 &= \sum_{r=1,2} P_a (1 - P_a) N_e \\
&\quad \times [P_{c_{1r}}^2 + \sigma_s^2(P_{c1r}) \\
&\quad + \sigma_j^2(P_{c1r}) + (\omega N_R - 1)^2 \\
&\quad \times (P_{c1x} + \sigma_s^2(P_{c1x}) \\
&\quad + \sigma_j^2(P_{crx})) + 2(\omega N_R - 1) \\
&\quad (P_{c1r} P_{c1x})] + P_a^2 N_e^2 \\
&\quad \times [\sigma_s^2(P_{c1r}) + (\omega N_R - 1)^2 \\
&\quad \times \sigma_s^2(P_{c1x}) + 2(\omega N_R - 1)\epsilon] \\
c_4 &= \sum_{r=1,2} P_a N_e [P_{c1r} - P_{c1r}^2 \\
&\quad - \sigma_s^2(P_{c1r}) - \sigma_j^2(P_{c1r}) \\
&\quad + (\omega N_R - 1)(P_{c1x} - P_{c1x}^2 \\
&\quad - \sigma_j^2(P_{c1x}))]
\end{aligned}\right\} \quad (10)$$

where

$\sigma_s^2(P_{c1r})$ and $\sigma_s^2(P_{c1x})$ represent the variance of P_{c1r} and P_{c1x} measured over the set of possible test stimuli, S_t, and

ambiente" com um modelo para um " ambiente diferenciado", no qual várias classes distinguíveis de estímulos estão presentes (como quadrados, círculos e triângulos, ou as letras do alfabeto). Se então projetarmos um experimento no qual os estímulos associados a cada resposta são extraídos de uma classe diferente, então as curvas de aprendizado do perceptron são drasticamente alteradas. A diferença mais importante é que a constante c\ (o coeficiente de n_{sr} no numerador de Z) não é mais igual a zero, de modo que a Equação 4 agora tem uma assíntota não aleatória Além disso, na forma de P, (a probabilidade de generalização correta), onde c% = 0, a quantidade Z permanece maior que zero, e P_a na verdade se aproxima da mesma assíntota que P_r Assim, a equação para o desempenho do perceptron após experiência infinita com cada classe de estímulos é idêntica para P_T e P_g.

$$P_{r\infty} = P_{g\infty} = [1 - (1 - P_a)^{N_e}] \times \phi\left(\frac{c_1}{\sqrt{c_3}}\right) \quad (9)$$

Isto significa que no limite não faz diferença se o perceptron já viu um determinado estímulo de teste antes ou não; se os estímulos vierem de um ambiente diferenciado, o desempenho será igualmente bom em ambos os casos.

Para avaliar o desempenho do sistema em um ambiente diferenciado, é necessário definir a quantidade $P_{C\omega}p$. Essa quantidade é interpretada como o valor esperado de PC entre pares de estímulos sorteados aleatoriamente das classes a e j3. Em particular, P_{cU} é o valor esperado de P_c entre membros da mesma classe, e Peis é o valor esperado de PC entre um estímulo Si extraído da Classe 1 e um estímulo S_2 extraído da Classe 2. P_{clx} é o valor esperado de P_c entre membros da Classe 1 e estímulos extraídos aleatoriamente de todas as outras classes do ambiente.

Se $P_{c11} > P_a > P_{C12}$, o desempenho limitante do perceptron ($P_{B\infty}$) será melhor que o acaso, e o aprendizado de alguma resposta, RI, como a "resposta de generalização" adequada para membros da Classe 1 deverá eventualmente ocorrer. Se a desigualdade acima não for satisfeita, então a melhoria do desempenho em relação ao acaso pode não ocorrer e, em vez disso, é provável que ocorra a resposta de Classe 2. Pode ser demonstrado (IS) que para a maioria das formas geométricas simples, que normalmente consideramos como " semelhantes", a desigualdade exigida pode ser satisfeita, se os parâmetros do sistema forem escolhidos adequadamente.

A equação para P_r, para a versão discriminante de soma de um a-perceptron, em um ambiente diferenciado onde n_{sr} é fixo para todas as respostas, terá as seguintes expressões para os quatro coeficientes:

$$\left.\begin{aligned}
c_1 &= P_a N_e (P_{c11} - P_{c12}) \\
c_2 &= P_a N_e (1 - P_{c11}) \\
c_3 &= \sum_{r=1,2} P_a (1 - P_a) N_e \\
&\quad \times [P_{c_{1r}}^2 + \sigma_s^2(P_{c1r}) \\
&\quad + \sigma_j^2(P_{c1r}) + (\omega N_R - 1)^2 \\
&\quad \times (P_{c1x} + \sigma_s^2(P_{c1x}) \\
&\quad + \sigma_j^2(P_{crx})) + 2(\omega N_R - 1) \\
&\quad (P_{c1r} P_{c1x})] + P_a^2 N_e^2 \\
&\quad \times [\sigma_s^2(P_{c1r}) + (\omega N_R - 1)^2 \\
&\quad \times \sigma_s^2(P_{c1x}) + 2(\omega N_R - 1)\epsilon] \\
c_4 &= \sum_{r=1,2} P_a N_e [P_{c1r} - P_{c1r}^2 \\
&\quad - \sigma_s^2(P_{c1r}) - \sigma_j^2(P_{c1r}) \\
&\quad + (\omega N_R - 1)(P_{c1x} - P_{c1x}^2 \\
&\quad - \sigma_j^2(P_{c1x}))]
\end{aligned}\right\} \quad (10)$$

onde

ir) e a?($P_{c\backslash x}$) representam a variância de $P_{c\backslash r}$ e $P_{c\backslash x}$ medida sobre o conjunto de possíveis estímulos de teste, S_t, e

$\sigma_j^2(P_{c1r})$ and $\sigma_j^2(P_{c1x})$ represent the variance of P_{c1r} and P_{c1x} measured over the set of all A-units, a_j.

ϵ = covariance of $P_{c1r}P_{c1x}$, which is assumed to be negligible.

The variances which appear in these expressions have not yielded, thus far, to a precise analysis, and can be treated as empirical variables to be determined for the classes of stimuli in question. If the sigma is set equal to half the expected value of the variable, in each case, a conservative estimate can be obtained. When the stimuli of a given class are all of the same shape, and uniformly distributed over the retina, the subscript s variances are equal to zero. $P_{g(\Sigma)}$ will be represented by the same set of coefficients, except for c_2, which is equal to zero, as usual.

For the mean-discriminating system, the coefficients are:

$$\left.\begin{aligned}
c_1 &= (P_{c11}-P_{c12})\\
c_2 &= (1-P_{c11})\\
c_3 &= \sum_{r=1,2}\left[\frac{1}{P_a(N_e-1)}-\frac{1}{N_e-1}\right]\\
&\quad\times[\sigma_j^2(P_{c1r})+(\omega N_R-1)^2\\
&\quad\times\sigma_j^2(P_{c1x})]+[\sigma_s^2(P_{c1r})\\
&\quad+(\omega N_R-1)^2\sigma_s^2(P_{c1x})]\\
c_4 &= \sum_{r=1,2}\frac{1}{P_aN_e}[P_{c1r}-P_{c1r}^2\\
&\quad-\sigma_s^2(P_{c1r})-\sigma_j^2(P_{c1r})\\
&\quad+(\omega N_R-1)(P_{c1x}-P_{c1x}^2\\
&\quad-\sigma_s^2(P_{c1x})-\sigma_j^2(P_{c1x}))]
\end{aligned}\right\} \quad (11)$$

Some covariance terms, which are considered negligible, have been omitted here.

A set of typical learning curves for the differentiated environment model is shown in Fig. 11, for the mean-discriminating system. The parameters are based on measurements for a

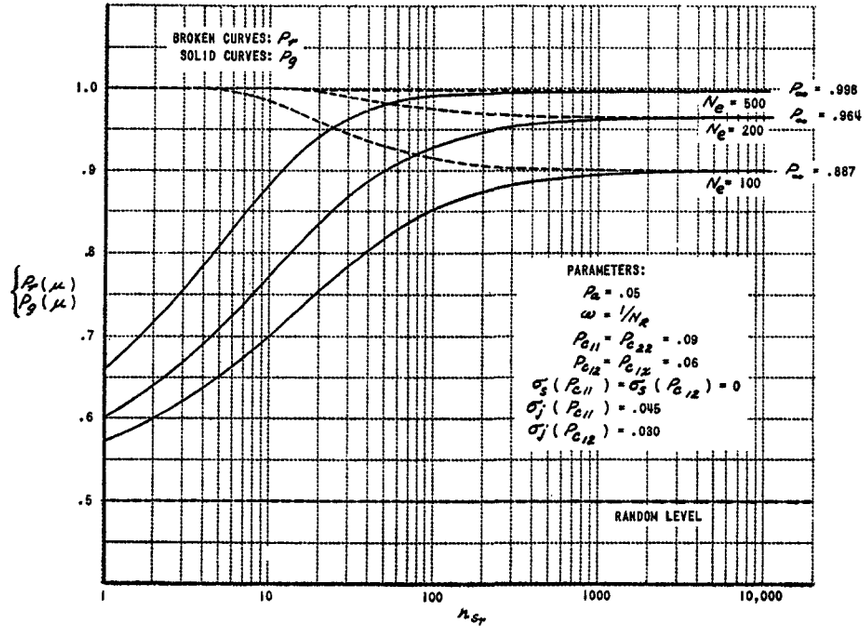


FIG. 11. P_r and P_g as function of n_{s_r}. Parameters based on square-circle discrimination.

iJ e crf(Pcix) representam a variância de P_{cir} e P^ medida sobre o conjunto de todas as unidades A, e = covariância de P_{clr} P_{clx}, que é assumida como insignificante.

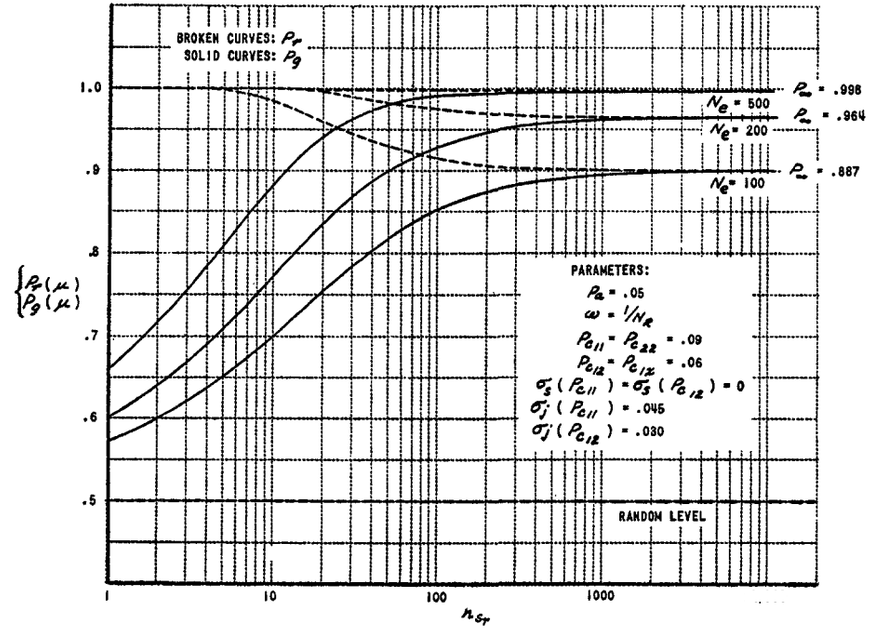
As variâncias que aparecem nestas expressões não renderam, até o momento, uma análise precisa, e podem ser tratadas como variáveis empíricas a serem determinadas para as classes de estímulos em questão. Se o sigma for igual à metade do valor esperado da variável, em cada caso, uma estimativa conservadora pode ser obtida. Quando os estímulos de uma determinada classe têm todos o mesmo formato e estão uniformemente distribuídos pela retina, as variâncias do subscrito são iguais a zero. P_aw será representado pelo mesmo conjunto de coeficientes, exceto c_2, que é igual a zero, como sempre.

Para o sistema discriminatório de médias, os coeficientes são:

$$\left.\begin{aligned}
c_1 &= (P_{c11}-P_{c12})\\
c_2 &= (1-P_{c11})\\
c_3 &= \sum_{r=1,2}\left[\frac{1}{P_a(N_e-1)}-\frac{1}{N_e-1}\right]\\
&\quad\times[\sigma_j^2(P_{c1r})+(\omega N_R-1)^2\\
&\quad\times\sigma_j^2(P_{c1x})]+[\sigma_s^2(P_{c1r})\\
&\quad+(\omega N_R-1)^2\sigma_s^2(P_{c1x})]\\
c_4 &= \sum_{r=1,2}\frac{1}{P_aN_e}[P_{c1r}-P_{c1r}^2\\
&\quad-\sigma_s^2(P_{c1r})-\sigma_j^2(P_{c1r})\\
&\quad+(\omega N_R-1)(P_{c1x}-P_{c1x}^2\\
&\quad-\sigma_s^2(P_{c1x})-\sigma_j^2(P_{c1x}))]
\end{aligned}\right\} \quad (11)$$

Alguns termos de covariância, considerados insignificantes, foram omitidos aqui.

Um conjunto de curvas de aprendizado típicas para o modelo de ambiente diferenciado é mostrado na Fig. 11, para o sistema discriminador de médias. Os parâmetros são baseados em medições para um



FIGO. 11. P e P_g em função de «,r. Parâmetros baseados na discriminação de círculo quadrado.

square-circle discrimination problem. Note that the curves for P_r and P_g both approach the same asymptotes, as predicted. The values of these asymptotes can be obtained by substituting the proper coefficients in Equation 9. As the number of association cells in the system increases, the asymptotic learning limit rapidly approaches unity, so that for a system of several thousand cells, the errors in performance should be negligible on a problem as simple as the one illustrated here.

As the number of responses in the system increases, the performance becomes progressively poorer, if every response is made mutually exclusive of all alternatives. One method of avoiding this deterioration (described in detail in Rosenblatt, **15**) is through the binary coding of responses. In this case, instead of representing 100 different stimulus patterns by 100 distinct, mutually exclusive responses, a limited number of discriminating features is found, each of which can be independently recognized as being present or absent, and consequently can be represented by a single pair of mutually exclusive responses. Given an ideal set of binary characteristics (such as dark, light; tall, short; straight, curved; etc.), 100 stimulus classes could be distinguished by the proper configuration of only seven response pairs. In a further modification of the system, a single response is capable of denoting by its activity or inactivity the presence or absence of each binary characteristic. The efficiency of such coding depends on the number of independently recognizable "earmarks" that can be found to differentiate stimuli. If the stimulus can be identified only in its entirety and is not amenable to such analysis, then ultimately a separate binary response pair, or bit, is required to denote the presence or absence of each stimulus class (e.g., "dog" or "not dog"), and nothing has been gained over a system where all responses are mutually exclusive.

BIVALENT SYSTEMS

In all of the systems analyzed up to this point, the increments of value gained by an active A-unit, as a result of reinforcement or experience, have always been *positive*, in the sense that an active unit has always *gained* in its power to activate the responses to which it is connected. In the gamma-system, it is true that some units lose value, but these are always the *inactive units*, the active ones gaining in proportion to their rate of activity. In a *bivalent system*, two types of reinforcement are possible (positive and negative), and an active unit may either gain or lose in value, depending on the momentary state of affairs in the system. If the positive and negative reinforcement can be controlled by the application of external stimuli, they become essentially equivalent to "reward" and "punishment," and can be used in this sense by the experimenter. Under these conditions, a perceptron appears to be capable of trial-and-error learning. A bivalent system need not necessarily involve the application of reward and punishment, however. If a binary-coded response system is so organized that there is a single response or response-pair to represent each "bit," or stimulus characteristic that is learned, with positive feedback to its own source-set if the response is "on," and negative feedback (in the sense that active A-units will lose rather than gain in value) if the response is "off," then the system is still bivalent in its characteristics. Such a bivalent

problema de discriminação em círculo quadrado. Observe que as curvas para P_r e P_g se aproximam das mesmas assíntotas, conforme previsto. Os valores destas assíntotas podem ser obtidos substituindo os coeficientes adequados na Equação 9. À medida que o número de células de associação no sistema aumenta, o limite de aprendizagem assintótica aproxima-se rapidamente da unidade, de modo que, para um sistema de vários milhares de células, os erros de desempenho devem ser insignificantes num problema tão simples como o ilustrado aqui.

À medida que o número de respostas no sistema aumenta, o desempenho t orna-se progressivamente pior, se cada resposta for mutuamente exclusiva de t odas as alternativas. Um método para e vitar esta deterioração (descrita detalhadamente em Rosenblatt, 15) é através da codificação binária das respostas. Neste caso, em vez de representar 100 padrões de estímulo diferentes por 100 respostas distintas e mutuamente exclusivas, encontra-se um número limitado de características discriminantes, cada uma das quais pode ser reconhecida independentemente como estando presente ou ausente e, consequentemente, pode ser representada por um único par de respostas mutuamente exclusivas. Dado um conjunto ideal de características binárias (como escuro, claro; alto, baixo; reto, curvo; etc.), 100 classes de estímulos poderiam ser distinguidas pela configuração adequada de apenas sete pares de respostas. Numa modificação adicional do sistema, uma única resposta é capaz de denotar pela sua atividade ou inatividade a presença ou ausência de cada característica binária. A eficiência de tal codificação depende do número de "marcas" independentemente reconhecíveis que podem ser encontradas para diferenciar os estímulos. Se o estí mulo puder ser identificado apenas em sua totalidade e não for passível de tal análise, então, em última análise, um par de resposta binária separado, ou bit, será necessário para denotam a presença ou ausência de cada classe de estímulo (por exemplo, "cachorro" ou "não cachorro"), e nada foi ganho em um sistema onde todas as respostas são mutuamente exclusivas.

SISTEMAS BIVALENTES

Em todos os sistemas analisados até agora, os incrementos de valor obtidos por uma unidade A activa, como resultado de reforço ou experiência, sempre foram positivos, no sentido de que uma unidade activa sempre ganhou o seu poder de activar as respostas às quais está ligada. No sistema gama, é verdade que algumas unidades perdem valor, mas estas são sempre as unidades inativas, as ativas ganhando proporcionalmente à sua taxa de atividade. Num sistema bivalente, são possíveis dois tipos de reforço (positivo e negativo), e uma unidade ativa pode ga nhar ou perder valor, dependendo do estado momentâneo das coisas no sistema. Se o reforço positivo e negativo puderem ser controlados pela aplicação de estímulos externos, eles se tornarão essencialmente equivalentes a "recompensa" e "punição" e poderão ser usados neste sentido pelo experimentador. Nessas condições, um perceptron parece ser capaz de aprender por tentativa e erro. Contudo, um sistema bivalente não precisa necessariamente envolver a aplicação de recompensa e punição. Se um sistema de resposta codificado em binário for organizado de tal forma que haja uma única resposta ou par de respostas para representar cada "bit" ou característica de estímulo que é aprendida, com feedback positivo para seu próprio conjunto de fontes se a resposta estiver " ligada" e feedback negativo (no sentido de que as unidades A ativas perderão em vez de ganhar em valor) se a resposta estiver " desligada", então o sistema ainda é bivalente em suas características. Tal bivalente

system is particularly efficient in reducing some of the bias effects (preference for the wrong response due to greater size or frequency of its associated stimuli) which plague the alternative systems.

Several forms of bivalent systems have been considered (**15**, Chap. VII). The most efficient of these has the following logical characteristics.

If the system is under a state of positive reinforcement, then a positive ΔV is added to the values of all active A-units in the source-sets of "on" responses, while a negative ΔV is added to the active units in the source-sets of "off" responses. If the system is currently under negative reinforcement, then a negative ΔV is added to all active units in the source-set of an "on" response, and a positive ΔV is added to active units in an "off" source-set. If the source-sets are disjunct (which is essential for this system to work properly), the equation for a bivalent γ-system has the same coefficients as the monovalent α-system, for the μ-case (Equation 11).

The performance curves for this system are shown in Fig. 12, where the asymptotic generalization probability attainable by the system is plotted for the same stimulus parameters that were used in Fig. 11. This is the probability that all bits in an n-bit response pattern will be correct. Clearly, if a majority of correct responses is sufficient to identify a stimulus correctly, the performance will be better than these curves indicate.

In a form of bivalent system which utilizes more plausible biological assumptions, A-units may be either excitatory or inhibitory in their effect on connected responses. A positive ΔV in this system corresponds to the incrementing of an excitatory unit, while a negative ΔV corresponds to the incrementing of an inhibitory unit. Such a system performs similarly to the one considered above, but can be shown to be less efficient.

Bivalent systems similar to those illustrated in Fig. 12 have been simulated in detail in a series of experiments with the IBM 704 computer at the Cornell Aeronautical Laboratory. The results have borne out the theory in all of its main predictions, and will be reported separately at a later time.

IMPROVED PERCEPTRONS AND SPONTANEOUS ORGANIZATION

The quantitative analysis of perceptron performance in the preceding sections has omitted any consideration of *time* as a stimulus dimension. A perceptron which has no capability for temporal pattern recognition is referred to as a "momentary stimulus perceptron." It can be shown (**15**) that the same principles of statistical separability will permit the perceptron to distinguish velocities, sound sequences, etc., provided the stimuli leave some temporarily persistent trace, such as an altered threshold,

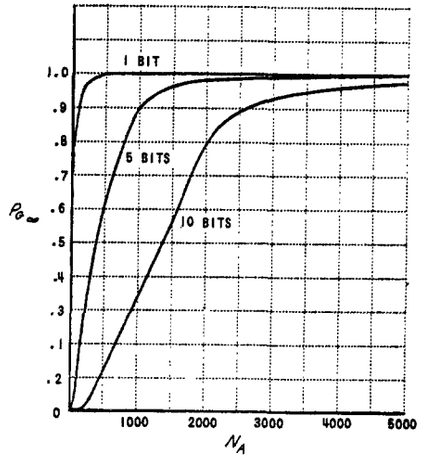


FIG. 12. P_{G_∞} for a bivalent binary system (same parameters as Fig. 11).

O sistema é particularmente eficiente na redução de alguns dos efeitos de viés (preferência pela resposta errada devido ao maior tamanho ou frequência dos estí mulos associados) que afetam os sistemas alternativos.

Várias formas de sistemas bivalentes foram consideradas (15, Cap. VII). O mais eficiente deles possui as seguintes características lógicas.

Se o sistema estiver sob um estado de reforço positivo, então um AV positivo é adicionado aos valores de todas as unidades A ativas nos conjuntos fonte de respostas " ligadas", enquanto um AV negativo é adicionado às unidades ativas nos c onjuntos fonte de respostas "desligadas". Se o sistema estiver atualmente sob reforço negativo, então um AV negativo é adicionado a todas as unidades ativas no conjunto fonte de uma resposta "ligada" e um AV positivo é adicionado às unidades ativas em um conjunto fonte "desligado". Se os conjuntos-fonte forem disjuntos (o que é essencial para que este sistema funcione corretamente), a equação para um sistema - y bivalente tem os mesmos coeficientes que o sistema a monovalente, para o caso /j (Equação 11).

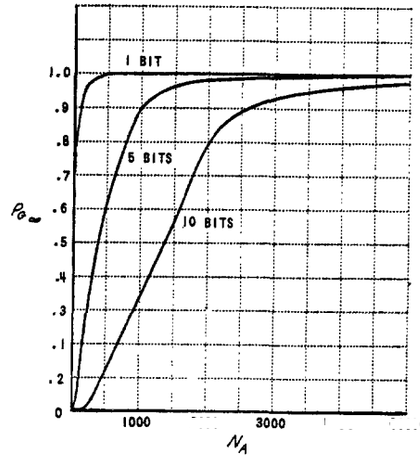
As curvas de desempenho para este sistema são mostradas na Fig. 12, onde a probabilidade de generalização assintótica atingível pelo sistema é traçada para os mesmos parâmetros de estímulo que foram usados na Fig. Claramente, se a maioria das respostas corretas for suficiente para identificar corretamente um estímulo, o desempenho será melhor do que estas curvas indicam.

Numa forma de sistema bivalente que utiliza pressupostos biológicos mais plausíveis, as unidades A podem ser excitatórias ou inibitórias no seu efeito sobre respostas interligadas. Um AV positivo neste sistema corresponde ao incremento de uma unidade excitatória, enquanto um AV negativo corresponde ao incremento de uma unidade inibitória. Tal sistema tem um desempenho semelhante ao considerado acima, mas pode ser menos eficiente.

Sistemas bivalentes semelhantes aos ilustrados na Fig. 12 foram simulados em detalhes em uma série de experimentos com o computador IBM 704 no Cornell Aeronautical Laboratory. Os resultados confirmaram a teoria em todas as suas principais previsões e serão relatados separadamente mais tarde.

PERCEPTRONS MELHORADOS E ORGANIZAÇÃO ESPONTÂNEA

A análise quantitativa do desempenho do perceptron nas seções anteriores omitiu qualquer consideração do tempo como u ma dimensão de estímulo. Um perceptron que não tem capacidade de reco nhecimento de padrões temporais é denominado "perceptron de estímulo momentâneo". Pode ser demonstrado (15) que os mesmos princípios de s eparabilidade estatística permitirão ao perceptron distinguir velocidades, sequências sonoras, etc., desde que os estímulos deixem algum traço temporariamente persistente, como um limiar alterado,



FIGO. 12. Pg_∞ para um sistema binário bivalente (mesmos parâmetros da Fig. 11).

which causes the activity in the A-system at time t to depend to some degree on the activity at time $t - 1$.

It has also been assumed that the origin points of A-units are completely random. It can be shown that by a suitable organization of origin points, in which the spatial distribution is constrained (as in the projection area origins shown in Fig. 1), the A-units will become particularly sensitive to the location of contours, and performance will be improved.

In a recent development, which we hope to report in detail in the near future, it has been proven that if the values of the A-units are allowed to decay at a rate proportional to their magnitude, a striking new property emerges: the perceptron becomes capable of "spontaneous" concept formation. That is to say, if the system is exposed to a random series of stimuli from two "dissimilar" classes, and all of its responses are automatically reinforced without any regard to whether they are "right" or "wrong," the system will tend towards a stable terminal condition in which (for each binary response) the response will be "1" for members of one stimulus class, and "0" for members of the other class; i.e., the perceptron will spontaneously recognize the difference between the two classes. This phenomenon has been successfully demonstrated in simulation experiments, with the 704 computer.

A perceptron, even with a single logical level of A-units and response units, can be shown to have a number of interesting properties in the field of selective recall and selective attention. These properties generally depend on the intersection of the source sets for different responses, and are elsewhere discussed in detail (**15**). By combining audio and photo inputs, it is possible to associate sounds, or auditory "names" to visual objects, and to get the perceptron to perform such selective responses as are designated by the command "Name the object on the left," or "Name the color of this stimulus."

The question may well be raised at this point of where the perceptron's capabilities actually stop. We have seen that the system described is sufficient for pattern recognition, associative learning, and such cognitive sets as are necessary for selective attention and selective recall. The system appears to be potentially capable of temporal pattern recognition, as well as spatial recognition, involving any sensory modality or combination of modalities. It can be shown that with proper reinforcement it will be capable of trial-and-error learning, and can learn to emit ordered sequences of responses, provided its own responses are fed back through sensory channels.

Does this mean that the perceptron is capable, without further modification in principle, of such higher order functions as are involved in human speech, communication, and thinking? Actually, the limit of the perceptron's capabilities seems to lie in the area of relative judgment, and the abstraction of relationships. In its "symbolic behavior," the perceptron shows some striking similarities to Goldstein's brain-damaged patients (**5**). Responses to definite, concrete stimuli can be learned, even when the proper response calls for the recognition of a number of simultaneous qualifying conditions (such as naming the color if the stimulus is on the left, the shape if it is on the right). As soon as the response calls for the recognition of a relationship between stimuli (such as "Name the object left of the square." or "Indicate the pattern that appeared before the circle."), however, the

o que faz com que a atividade no sistema A no tempo t dependa até certo ponto da atividade no tempo t — 1.

Também foi assumido que os pontos de origem das unidades A são completamente aleatórios. Pode ser demonstrado que através de uma organização adequada dos pontos de origem, nos quais a distribuição espacial é restrita (como nas origens da área de projeção mostrada na Fig. 1), as unidades A se tornarão particularmente sensíveis à localização dos contornos, e o desempenho será melhorado.

Num desenvolvimento recente, que esperamos relatar em detalhe num futuro próximo, foi provado que se for permitido que os valores das unidades A decaiam a uma taxa proporcional à sua magnitude, surge uma propriedade nova e surpreendente: o perceptron torna-se capaz de formação de conceitos "espontâneos". Isto é, se o sistema for exposto a uma série aleatória de estímulos de duas classes " diferentes", e todas as suas respostas forem automaticamente reforçadas sem qualquer consideração se estão "certas" ou "erradas", o sistema tenderá para uma condição terminal estável na qual (para cada resposta binária) a resposta será "1" para membros de uma classe de estímulos, e "0" para membros da outra classe; isto é, o perceptron reconhecerá espontaneamente a diferença entre as duas classes. Este fenômeno foi demonstrado com sucesso e m experimentos de simulação, com o computador 704.

Um perceptron, mesmo com um único nível lógico de unidades A e unidades de resposta, pode demonstrar ter uma série de propriedades interessantes no campo da recordação seletiva e da atenção seletiva. Essas propriedades geralmente dependem da interseção dos conjuntos de origem para diferentes respostas e são discutidas em detalhes em outro lugar (IS). Ao combinar entradas de áudio e foto, é possível associar sons, ou áudio "nomes" históricos para objetos visuais e fazer com que o perceptron execute as respostas seletivas designadas pelo comando "Nomeie o objeto à esquerda" ou " Nomeie a cor deste estímulo".

Neste ponto pode muito bem ser levantada a questão de onde as capacidades do perceptron realmente param. Vimos que o sistema descrito é suficiente para o reconhecimento de padrões, a aprendizagem associativa e os conjuntos cognitivos necessários para a atenção selectiva e a recordação selectiva. O siste ma parece ser potencialmente capaz de reconhecimento de padrões temporais, be m como de reconhecimento espacial, envolvendo qualquer modalidade sensorial ou combinação de modalidades. Pode-se demonstrar que, com o reforço adequado, será capaz de aprender por tentativa e erro e pode aprender a emitir sequências ordenadas de respostas, desde que as suas próprias respostas sejam retroalimentadas através de canais sensoriais.

Significa isto que o perceptron é capaz, sem modificações adicionais em princípio, de funções de ordem superior que estão envolvidas na fala, comunicação e pensamento humanos? Na verdade, o li mite das capacidades do perceptron parece residir na área do julgamento relativo e da abstração de relacionamentos. No seu " comportamento simbólico", o perceptron mostra algumas semelhanças impressionantes com os pacientes com danos cerebrais de Goldstein (5). As respostas a estímulos definidos e concretos podem ser aprendidas, mesmo quando a resposta adequada exige o reconhecimento de uma série de condições qualificadoras simultâneas (como nomear a cor se o estímulo estiver à esquerda, a forma se estiver à direita). Assim que a resposta exige o reconhecimento de uma relação entre os estímulos (como "Nomeie o objeto à esquerda do quadrado" ou "Indique o padrão que apareceu antes do círculo"), entretanto, o

problem generally becomes excessively difficult for the perceptron. Statistical separability alone does not provide a sufficient basis for higher order abstraction. Some system, more advanced in principle than the perceptron, seems to be required at this point.

CONCLUSIONS AND EVALUATION

The main conclusions of the theoretical study of the perceptron can be summarized as follows:

1. In an environment of random stimuli, a system consisting of randomly connected units, subject to the parametric constraints discussed above, can learn to associate specific responses to specific stimuli. Even if many stimuli are associated to each response, they can still be recognized with a better-than-chance probability, although they may resemble one another closely and may activate many of the same sensory inputs to the system.

2. In such an "ideal environment," the probability of a correct response diminishes towards its original random level as the number of stimuli learned increases.

3. In such an environment, no basis for generalization exists.

4. In a "differentiated environment," where each response is associated to a distinct class of mutually correlated, or "similar" stimuli, the probability that a learned association of some specific stimulus will be correctly retained typically approaches a better-than-chance asymptote as the number of stimuli learned by the system increases. This asymptote can be made arbitrarily close to unity by increasing the number of association cells in the system.

5. In the differentiated environment, the probability that a stimulus *which has not been seen before* will be correctly recognized and associated to its appropriate class (the probability of correct generalization) approaches the same asymptote as the probability of a correct response to a previously reinforced stimulus. This asymptote will be better than chance if the inequality $P_{c12} < P_a < P_{c11}$ is met, for the stimulus classes in question.

6. The performance of the system can be improved by the use of a contour-sensitive projection area, and by the use of a binary response system, in which each response, or "bit," corresponds to some independent feature or attribute of the stimulus.

7. Trial-and-error learning is possible in bivalent reinforcement systems.

8. Temporal organizations of both stimulus patterns and responses can be learned by a system which uses only an extension of the original principles of statistical separability, without introducing any major complications in the organization of the system.

9. The memory of the perceptron is *distributed*, in the sense that any association may make use of a large proportion of the cells in the system, and the removal of a portion of the association system would not have an appreciable effect on the performance of any one discrimination or association, but would begin to show up as a general deficit in *all* learned associations.

10. Simple cognitive sets, selective recall, and spontaneous recognition of the classes present in a given environment are possible. The recognition of relationships in space and time, however, seems to represent a limit to the perceptron's ability to form cognitive abstractions.

Psychologists, and learning theorists in particular, may now ask: "What has the present theory accomplished,

O problema geralmente se torna excessivamente difícil para o perceptron. A separabilidade estatística por si só não fornece uma base suficiente para uma abstração de ordem superior. Algum sistema, em princípio mais avançado que o perceptron, parece ser necessário neste ponto.

CONCLUSÕES E AVALIAÇÃO

As principais conclusões do estudo teórico do perceptron podem ser resu midas da seguinte forma:

1. Num ambiente de estímulos aleatórios, um sistema constituído por unidades ligadas aleatoriamente, sujeito às restrições paramétricas discutidas acima, pode aprender a associar respostas específicas a estímulos específicos. Mesmo que muitos estímulos estejam associados a cada resposta, eles ainda podem ser reconhecidos com uma probabilidade melhor do que o acaso, embora possam assemelhar-se muito e ativar muitas das mesmas entradas sensoriais para o siste ma.

2. Num tal "ambiente ideal", a probabilidade de uma resposta correcta diminui em direcção ao seu nível aleatório original à medida que aumenta o número de estímulos aprendidos.

3. Num tal ambiente, não existe base para generalização.

4. Num "ambiente diferenciado", onde cada resposta está associada a uma classe distinta de estímulos mutuamente correlacionados, ou "semelhantes", a probabilidade de que uma associação aprendida de algum estímulo específico s eja retida corretamente normalmente se aproxima de uma assíntota melhor que o acaso, à medida que o número de estí mulos aprendidos pelo sistema aumenta. Esta assíntota pode ser arbitrariamente próxima da unidade aumentando o nú mero de células de associação no sistema.

5. No ambiente diferenciado, a probabilidade de um estímulo que não foi visto antes será corretamente reconhecido e associado à sua classe apropriada (a probabilidade de generalização correta) aproxima-se da mesma assíntota que a probabilidade de uma resposta correta a um estímulo previamente reforçado. Esta assíntota será melhor que o acaso se a desigualdade Pci2 < Pa < Pen for satisfeita, para as classes de estímulos em questão.

6. O desempenho do sistema pode ser melhorado pelo uso de uma área de projeção sensível ao contorno e pelo uso de um sistema de resposta binária, no qual cada resposta, ou "bit", corresponde a alguma característica ou atributo independente do estímulo.

7. A aprendizagem por tentativa e erro é possível em sistemas de reforço bivalente.

8. As organizações temporais tanto dos padrões de estímulo como das respostas podem ser aprendidas por um sistema que utiliza apenas uma extensão dos princípios originais de separabilidade estatística, sem introduzir quaisquer complicações importantes na organização do sistema.

9. A memória do perceptron é distribuída, no sentido de que qualquer associação pode fazer uso de uma grande proporção das células do sistema, e a remoção de uma porção do sistema de associação não teria um efeito apreciável no desempenho de qualquer discri minação ou associação, mas começaria a aparecer como um déficit geral em todas as associações aprendidas.

10. São possíveis conjuntos cognitivos simples, recordação seletiva e reconhecimento espontâneo das classes presentes em um determinado ambiente. O reconhecimento de relações no espaço e no tempo, contudo, parece representar um limite à capacidade do perceptron de formar abstrações cognitivas.

Os psicólogos, e os teóricos da aprendizagem em particular, podem agora perguntar: "O que a teoria atual realizou,

beyond what has already been done in the quantitative theories of Hull, Bush and Mosteller, etc., or physiological theories such as Hebb's?" The present theory is still too primitive, of course, to be considered as a full-fledged rival of existing theories of human learning. Nonetheless, as a first approximation, its chief accomplishment might be stated as follows:

For a given mode of organization (α, β, or γ; Σ or μ; monovalent or bivalent) the fundamental phenomena of *learning, perceptual discrimination, and generalization can be predicted entirely from six basic physical parameters*, namely:

x: the number of excitatory connections per A-unit,
y: the number of inhibitory connections per A-unit,
θ: the expected threshold of an A-unit,
ω: the proportion of R-units to which an A-unit is connected,
N_A: the number of A-units in the system, and
N_R: the number of R-units in the system.

N_s (the number of sensory units) becomes important if it is very small. It is assumed that the system begins with all units in a uniform state of value; otherwise the initial value distribution would also be required. *Each of the above parameters is a clearly defined physical variable, which is measurable in its own right, independently of the behavioral and perceptual phenomena which we are trying to predict.*

As a direct consequence of its foundation on physical variables, the present system goes far beyond existing learning and behavior theories in three main points: parsimony, verifiability, and explanatory power and generality. Let us consider each of these points in turn.

1. *Parsimony*. Essentially all of the basic variables and laws used in this system are already present in the structure of physical and biological science, so that we have found it necessary to postulate only one hypothetical variable (or construct) which we have called V, the "value" of an association cell; this is a variable which must conform to certain functional characteristics which can clearly be stated, and which is assumed to have a potentially measurable physical correlate.

2. *Verifiability*. Previous quantitative learning theories, apparently without exception, have had one important characteristic in common: they have all been based on measurements of *behavior*, in specified situations, using these measurements (after theoretical manipulation) to predict *behavior* in other situations. Such a procedure, in the last analysis, amounts to a process of curve fitting and extrapolation, in the hope that the constants which describe one set of curves will hold good for other curves in other situations. While such extrapolation is not necessarily circular, in the strict sense, it shares many of the logical difficulties of circularity, particularly when used as an "explanation" of behavior. Such extrapolation is difficult to justify in a new situation, and it has been shown that if the basic constants and parameters are to be derived anew for any situation in which they break down empirically (such as change from white rats to humans), then the basic "theory" is essentially irrefutable, just as any successful curve-fitting equation is irrefutable. It has, in fact, been widely conceded by psychologists that there is little point in trying to "disprove" any of the major learning theories in use today, since by extension, or a change in parameters, they

além do que já foi feito nas teorias quantitativas de Hull, Bush e Mosteller, etc., ou nas teorias fisiológicas como a de Hebb?

Para um determinado modo de organização (a, /3 ou 7; S ou n; monovalente ou bivalente), os fenómenos fundamentais de aprendizagem, discriminação perceptual e generalização podem ser previstos inteiramente a partir de seis parâmetros físi cos básicos, nomeadamente:

x: o número de conexões excitatórias por unidade A, y: o número de conexões inibitórias por unidade A, 6: o limite esperado de uma unidade A, co: a proporção de unidades R às quais uma unidade A está conectada, NA: o número de unidades A no sistema, e NR-. o número de unidades R no sistema.

N_s (o número de unidades sensoriais) torna-se importante se for muito pequeno. Supõe-se que o sistema começa com todas as unidades num estado uniforme de valor; caso contrário, a distribuição de valor inicial também seria necessária. Cada um dos parâmetros acima é uma variável física claramente definida, que é mensurável por si só, independentemente dos fenómenos comportamentais e perceptivos que estamos a tentar prever.

Como consequência directa da sua base em variáveis físicas, o actual sistema vai muito além das teorias de aprendizagem e comportamento existentes em três pontos principais: parcimónia, verificabilidade e poder explicativo e generalidade. Consideremos cada um desses pontos separadamente.

1. Parcimônia. Essencialmente, todas as variáveis e leis básicas utilizadas neste sistema já estão presentes na estrutura da ciência física e biológica, de modo que achamos necessário postular apenas uma variável (ou construção) hipotética que chamamos de V, o "valor" de uma célula de associação; esta é uma variável que deve estar em conformidade com certas características funcionais que podem ser claramente declaradas e que se supõe ter um correlato físico potencialmente mensurável.

2. Verificabilidade. As anteriores t eorias de aprendizagem quantitativa, aparentemente sem excepção, tiveram u ma característica importante em comum: todas se basearam em medidas de comportamento, em situações específicas, utilizando estas medidas (após manipulação teórica) para prever o comportamento noutras situações. Tal procedimento, em última análise, equivale a um processo de ajuste e extrapolação de curvas, na esperança de que as constantes que descrevem um conjunto de curvas sejam válidas para outras curvas em outras situações. Embora tal extrapolação não seja necessariamente circular, no sentido estrito, partilha muitas das dificuldades lógicas da circularidade, particularmente quando usada como uma "explicação" do comportamento. Tal extrapolação é difícil de justificar numa nova situação, e foi demonstrado que se as constantes e os parâmetros básicos forem derivados de novo para qualquer situação em que se desfaçam empiricamente (como a mudança de ratos brancos para humanos), então a "teoria" básica é essencialmente irrefutável, tal como qualquer equação de ajuste de curva bem sucedida é irrefutável. Na verdade, tem sido amplamente reconhecido pelos psicólogos que não faz muito sentido tentar "refutar" qualquer uma das principais teorias de aprendizagem em uso hoje, uma vez que, por extensão, ou por uma mudança nos parâmetros, elas

have all proved capable of adapting to any specific empirical data. This is epitomized in the increasingly common attitude that a choice of theoretical model is mostly a matter of personal aesthetic preference or prejudice, each scientist being entitled to a favorite model of his own. In considering this approach, one is reminded of a remark attributed to Kistiakowsky, that "given seven parameters, I could fit an elephant." This is clearly *not* the case with a system in which the independent variables, or parameters, can be measured *independently* of the predicted behavior. In such a system, it is not possible to "force" a fit to empirical data, if the parameters in current use should lead to improper results. In the current theory, a failure to fit a curve in a new situation would be a clear indication that either the theory or the empirical measurements are wrong. Consequently, if such a theory *does* hold up for repeated tests, we can be considerably more confident of its validity and of its generality than in the case of a theory which must be hand-tailored to meet each situation.

3. *Explanatory power and generality.* The present theory, being derived from basic physical variables, is not specific to any one organism or learning situation. It can be generalized in principle to cover any form of behavior in any system for which the physical parameters are known. A theory of learning, constructed on these foundations, should be considerably more powerful than any which has previously been proposed. It would not only tell us what behavior might occur in any known organism, but would permit the *synthesis* of behaving systems, to meet special requirements. Other learning theories tend to become increasingly qualitative as they are generalized. Thus a set of equations describing the effects of reward on T-maze learning in a white rat reduces simply to a statement that rewarded behavior tends to occur with increasing probability, when we attempt to generalize it from any species and any situation. The theory which has been presented here loses none of its precision through generality.

The theory proposed by Donald Hebb (**7**) attempts to avoid these difficulties of behavior-based models by showing how psychological functioning might be derived from neurophysiological theory. In his attempt to achieve this, Hebb's philosophy of approach seems close to our own, and his work has been a source of inspiration for much of what has been proposed here. Hebb, however, has never actually achieved a model by which behavior (or any psychological data) can be *predicted* from the physiological system. His physiology is more a suggestion as to the *sort* of organic substrate which might underlie behavior, and an attempt to show the plausibility of a bridge between biophysics and psychology.

The present theory represents the first actual completion of such a bridge. Through the use of the equations in the preceding sections, it is possible to predict learning curves from neurological variables, and likewise, to predict neurological variables from learning curves. How well this bridge stands up to repeated crossings remains to be seen. In the meantime, the theory reported here clearly demonstrates the feasibility and fruitfulness of a quantitative statistical approach to the organization of cognitive systems. By the study of systems such as the perceptron, it is hoped that those fundamental laws of organization which are common to all information handling systems, ma-

todos provaram ser capazes de se adaptar a quaisquer dados empíricos específicos. Isto é sintetizado na atitude cada vez mais comum de que a escolha de um modelo teórico é principalmente uma questão de preferência ou preconceito estético pessoal, tendo cada cientista direito a um modelo favorito próprio. Ao considerar esta abordagem, le mbramo-nos de uma observação atribuída a Kistiakowsky, de que "com sete parâmetros, eu poderia caber num elef ante". Este claramente não é o caso de um sistema no qual as variáveis independentes, ou parâmetros, podem ser medidas independentemente do comportamento previsto. Num tal sistema, não é possível "forçar" um ajuste aos dados empíricos, se os parâmetros actualmente utilizados conduzirem a resultados impróprios. Na teoria actual, a incapacidade de ajustar uma curva numa nova situação seria uma indicação clara de que a teoria ou as medições empíricas estão erradas. Consequentemente, se tal teoria resistir a testes repetidos, podemos estar consideravelmente mais confiantes na sua validade e na sua generalidade do que no caso de uma teoria que deve ser adaptada à mão para responder a cada situação.

3. Poder explicativo e generalidade. A presente teoria, sendo derivada de variáveis físicas básicas, não é específica de nenhum organismo ou situação de aprendizagem. Pode ser generalizado, em princípio, para cobrir qualquer forma de comportamento em qualquer sistema para o qual os parâmetros físicos sejam conhecidos. Uma teoria da aprendizagem, construída sobre estes fundamentos, deveria ser consideravelmente mais poderosa do que qualquer outra que tenha sido proposta anteriormente. Não apenas nos diria qual comportamento poderia ocorrer em qualquer organismo conhecido, mas também permitiria a síntese de sistemas comportamentais, para atender a requisitos especiais. Outras teorias de aprendizagem tendem a tornar-se cada vez mais qualitativas à medida que são generalizadas. Assim, um conjunto de equações que descreve os efeitos da recompensa na aprendizagem do labirinto em T num rato branco reduz-se simplesmente a uma afirmação de que o comportamento recompensado tende a ocorrer com probabilidade crescente, quando tentamos generalizá-lo a partir de qualquer espécie e qualquer situação. A teoria que foi apresentada aqui não perde nada de sua precisão por causa da generalidade.

A teoria proposta por Donald Hebb (7) tenta evitar estas dificuldades dos modelos baseados no comportamento, mostrando como o funcionamento psicológico pode ser derivado da teoria neurofisiológica. Na sua tentativa de conseguir isto, a filosofia de abordagem de Hebb parece próxima da nossa, e o seu trabalho tem sido uma fonte de inspiração para muito do que foi aqui proposto. Hebb, no entanto, nunca conseguiu realmente um modelo pelo qual o comportamento (ou quaisquer dados psicológicos) pudesse ser previsto a partir do sistema fisiológico. A sua fisiologia é mais uma sugestão sobre o tipo de substrato orgânico que pode estar subjacente ao comportamento e uma tentativa de mostrar a plausibilidade de uma ponte entre a biofísica e a psicologia.

A presente teoria representa a primeira conclusão real de tal ponte. Através do uso das equações das seções anteriores, é possível prever curvas de aprendizado a partir de variáveis neurológicas e, da mesma forma, prever variáveis neurológicas a partir de curvas de aprendizado. Ainda não se sabe até que ponto esta ponte resiste a repetidas travessias. Entretanto, a teoria aqui relatada demonstra claramente a viabilidade e a fecundidade de uma abordagem estatística quantitativa para a organização de sistemas cognitivos. Pelo estudo de sistemas como o perceptron, espera-se que aquelas leis fundamentais de organização que são comuns a todos os sistemas de tratamento de informações, possam

chines and men included, may eventually be understood.

REFERENCES

1. ASHBY, W. R. *Design for a brain.* New York: Wiley, 1952.
2. CULBERTSON, J. T. *Consciousness and behavior.* Dubuque, Iowa: Wm. C. Brown, 1950.
3. CULBERTSON, J. T. Some uneconomical robots. In C. E. Shannon & J. McCarthy (Eds.), *Automata studies.* Princeton: Princeton Univer. Press, 1956. Pp. 99–116.
4. ECCLES, J. C. *The neurophysiological basis of mind.* Oxford: Clarendon, 1953.
5. GOLDSTEIN, K. *Human nature in the light of psychopathology.* Cambridge: Harvard Univer. Press, 1940.
6. HAYEK, F. A. *The sensory order.* Chicago: Univer. Chicago Press, 1952.
7. HEBB, D. O. *The organization of behavior.* New York: Wiley, 1949.
8. KLEENE, S. C. Representation of events in nerve nets and finite automata. In C. E. Shannon & J. McCarthy (Eds.), *Automata studies.* Princeton: Princeton Univer. Press, 1956. Pp. 3–41.
9. KÖHLER, W. Relational determination in perception. In L. A. Jeffress (Ed.), *Cerebral mechanisms in behavior.* New York: Wiley, 1951. Pp. 200–243.
10. MCCULLOCH, W. S. Why the mind is in the head. In L. A. Jeffress (Ed.), *Cerebral mechanisms in behavior.* New York: Wiley, 1951. Pp. 42–111.
11. MCCULLOCH, W. S., & PITTS, W. A logical calculus of the ideas immanent in nervous activity. *Bull. math. Biophysics*, 1943, **5**, 115–133.
12. MILNER, P. M. The cell assembly: Mark II. *Psychol. Rev.*, 1957, **64**, 242–252.
13. MINSKY, M. L. Some universal elements for finite automata. In C. E. Shannon & J. McCarthy (Eds.), *Automata studies.* Princeton: Princeton Univer. Press, 1956. Pp. 117–128.
14. RASHEVSKY, N. *Mathematical biophysics.* Chicago: Univer. Chicago Press, 1938.
15. ROSENBLATT, F. *The perceptron: A theory of statistical separability in cognitive systems.* Buffalo: Cornell Aeronautical Laboratory, Inc. Rep. No. VG-1196-G-1, 1958.
16. UTTLEY, A. M. Conditional probability machines and conditioned reflexes. In C. E. Shannon & J. McCarthy (Eds.), *Automata studies.* Princeton: Princeton Univer. Press, 1956. Pp. 253–275.
17. VON NEUMANN, J. The general and logical theory of automata. In L. A. Jeffress (Ed.), *Cerebral mechanisms in behavior.* New York: Wiley, 1951. Pp. 1–41.
18. VON NEUMANN, J. Probabilistic logics and the synthesis of reliable organisms from unreliable components. In C. E. Shannon & J. McCarthy (Eds.), *Automata studies.* Princeton: Princeton Univer. Press, 1956. Pp. 43–98.

(Received April 23, 1958)

chineses e homens incluídos, podem eventualmente ser compreendidos.

REFERÊNCIAS

1. ASHBY, W. R Projeto para um cérebro. Nova York: Wiley, 1952. 2. CULBERTSON, J. T. Consciência e comportamento. Dubuque, Iowa: Wm. C. Brown, 1950. 3. CULBERTSON, J. T. Alguns robôs antieconômicos. Em C. E. Shannon & J. McCarthy (Eds.), Estudos de autômatos. Princeton: Universidade de Princeton. Imprensa, 1956. Págs. 99-116. 4. ECCLES, J. C. A base neurofisiológica da mente. Oxford: Clarendon, 1953. 5. GOLDSTEIN, K. A natureza humana à luz da psicopatologia. Cambridge: Universidade de Harvard. Press, 1940. 6. HAYEK, F. A. A ordem sensorial. Chicago: Univer. Chicago Press, 1952. 7. HEBB, D. O. A organização do comportamento. Nova York: Wiley, 1949. 8. KLEENE, S. C. Representação de eventos em redes nervosas e autômatos finitos. Em C. E. Shannon & J. McCarthy (Eds.), Estudos de autômatos. Princeton: Princeton Univer. Imprensa, 1956. Págs. 3-41. 9. KOHLER, W. Determinação relacional na percepção. Em LA Jeffress (Ed.), Mecanismos cerebrais no comportamento. Nova York: Wiley, 1951. Pp. 200-243. 10. McCuLLOCH, W. S. Por que a mente está na cabeça. Em LA Jeffress (Ed.), Mecanismos cerebrais no comportamento. Nova York: Wiley, 1951. Pp. 42-111.
11. MCCULLOCH, W. S., & PITTS, W. Um cálculo lógico das ideias imanentes na atividade nervosa. Bunda. matemática. Biofísica, 1943, S, 115-133. 12. MILNER, PM A montagem da célula: Mark II. Psicol. Rev., 1957,64,242-252. 13. MINSKY, M. L. Alguns elementos universais para autômatos finitos. Em C. E. Shannon & J. McCarthy (Eds.), Estudos de autômatos. Princeton: Universidade de Princeton. Imprensa, 1956. Págs. 117-128. 14. RASHEVSKY, N. Biofísica matemática. Chicago: Univer. Chicago Press, 1938. 15. ROSENBLATT, F. O perceptron: Uma teoria da separabilidade estatística em sistemas cognitivos. Buffalo: Cornell Aeronautical Laboratory, Inc. Rep. No. VG-1196-G-1, 1958. 16. UTTLEY, A. M. Máquinas de probabilidade condicional e reflexos condicionados. Em C. E. Shannon & J. McCarthy (Eds.), Estudos de autômatos. Princeton: Universidade de Princeton. Imprensa, 1956. Págs. 253-275. 17. VON NEUMANN, J. A teoria geral e lógica dos autômatos. Em LA Jeffress (Ed.), Mecanismos cerebrais no comportamento. Nova York: Wiley, 1951. Pp. 1-41. 18. VON NEUMANN, J. Lógica probabilística e a síntese de organismos confiáveis a partir de componentes não confiáveis. Em C. E. Shannon & J. McCarthy (Eds.), Estudos de autô matos. Princeton: Princeton Univer. Imprensa, 1956. Págs. 43-98.

(Recebido em 23 de abril de 1958)