frontiers in Neural Circuits

HYPOTHESIS AND THEORY
published: 11 January 2019
doi: 10.3389/fncir.2018.00121

A Framework for Intelligence and Cortical Function Based on Grid Cells in the Neocortex

Jeff Hawkins, Marcus Lewis, Mirko Klukas, Scott Purdy and Subutai Ahmad*

Numenta, Inc., Redwood City, CA, United States

How the neocortex works is a mystery. In this paper we propose a novel framework for understanding its function. Grid cells are neurons in the entorhinal cortex that represent the location of an animal in its environment. Recent evidence suggests that grid cell-like neurons may also be present in the neocortex. We propose that grid cells exist throughout the neocortex, in every region and in every cortical column. They define a location-based framework for how the neocortex functions. Whereas grid cells in the entorhinal cortex represent the location of one thing, the body relative to its environment, we propose that cortical grid cells simultaneously represent the location of many things. Cortical columns in somatosensory cortex track the location of tactile features relative to the object being touched and cortical columns in visual cortex track the location of visual features relative to the object being viewed. We propose that mechanisms in the entorhinal cortex and hippocampus that evolved for learning the structure of environments are now used by the neocortex to learn the structure of objects. Having a representation of location in each cortical column suggests mechanisms for how the neocortex represents object compositionality and object behaviors. It leads to the hypothesis that every part of the neocortex learns complete models of objects and that there are many models of each object distributed throughout the neocortex. The similarity of circuitry observed in all cortical regions is strong evidence that even high-level cognitive tasks are learned and represented in a location-based framework.

Keywords: neocortex, grid cell, neocortical theory, hierarchy, object recognition, cortical column

OPEN ACCESS

Edited by:
Robert C. Froemke, New York University, United States

Reviewed by:
Michael E. Hasselmo, Boston University, United States
Srikanth Ramaswamy, École Polytechnique Fédérale de Lausanne, Switzerland

****Correspondence:***
Jeff Hawkins
jhawkins@numenta.com

Received: *20 October 2018*
Accepted: *24 December 2018*
Published: *11 January 2019*

Citation:
Hawkins J, Lewis M, Klukas M, Purdy S and Ahmad S (2019) A Framework for Intelligence and Cortical Function Based on Grid Cells in the Neocortex. Front. Neural Circuits 12:121. doi: 10.3389/fncir.2018.00121

INTRODUCTION

The human neocortex learns an incredibly complex and detailed model of the world. Each of us can recognize 1000s of objects. We know how these objects appear through vision, touch, and audition, we know how these objects behave and change when we interact with them, and we know their location in the world. The human neocortex also learns models of abstract objects, structures that don't physically exist or that we cannot directly sense. The circuitry of the neocortex is also complex. Understanding how the complex circuitry of the neocortex learns complex models of the world is one of the primary goals of neuroscience.

Vernon Mountcastle was the first to propose that all regions of the neocortex are fundamentally the same. What distinguishes one region from another, he argued, is mostly determined by the inputs to a region and not by differences in intrinsic circuitry and function. He further proposed that a small volume of cortex, a cortical column, is the unit of replication (Mountcastle, 1978).

frontiers in Neural Circuits

HIPÓTESE E TEORIA publicada:
11 de janeiro de 2019 doi:
10.3389/fncir.2018.00121

Uma estrutura para inteligência e função cortical baseada em células de grade no neocórtex

Jeff Hawkins, Marcus Lewis, Mirko Klukas, Scott Purdy e Subutai Ahmad*

Numenta, Inc., Redwood City, CA, Estados Unidos

Como funciona o neocórtex é um mistério. Neste artigo, propomos uma nova estrutura para compreender sua função. As células da grade são neurônios no córtex entorrinal que representam a localização de um animal em seu ambiente. Evidências recentes sugerem que neurônios semelhantes a células em grade também podem estar presentes no neocórtex. Propomos que existam células de grade em todo o neocórtex, em todas as regiões e em todas as colunas corticais. Eles definem uma estrutura baseada em localização para o funcionamento do neocórtex. Enquanto as células da grade no córtex entorrinal representam a localização de uma coisa, o corpo, em relação ao seu ambiente, propomos que as células da grade cortical representam simultaneamente a localização de muitas coisas. As colunas corticais no córtex somatossensorial rastreiam a localização das características táteis em relação ao objeto que está sendo tocado e as colunas corticais no córtex visual rastreiam a localização das características visuais em relação ao objeto que está sendo visualizado. Propomos que mecanismos no córtex entorrinal e no hipocampo que evoluíram para aprender a estrutura dos ambientes sejam agora usados pelo neocórtex para aprender a estrutura dos objetos. Ter uma representação da localização em cada coluna cortical sugere mecanismos de como o neocórtex representa a composicionalidade e o comportamento do objeto. Isso leva à hipótese de que cada parte do neocórtex aprende modelos completos de objetos e que existem muitos modelos de cada objeto distribuídos por todo o neocórtex. A semelhança dos circuitos observados em todas as regiões corticais é uma forte evidência de que mesmo as tarefas cognitivas de alto nível são aprendidas e representadas numa estrutura baseada na localização.

Palavras-chave: neocórtex, grade celular, teoria neocortical, hierarquia, reconhecimento de objetos, coluna cortical

OPEN ACCESS

Editado por:
Robert C. Froemke, Universidade de Nova York, Estados Unidos

Revisado por:
Michael E. Hasselmo, Universidade de Boston, Estados Unidos Srikanth Ramaswamy, École PolytechniqueFédérale de Lausanne, Suíça

**Correspondência:*
Jeff Hawkins
jhawkins@numenta.com

Recebido: 20 de outubro de 2018 Aceito: 24 de dezembro de 2018 Publicado: 11 de janeiro de 2019

Citação:
Hawkins J, Lewis M, Klukas M, Purdy S e Ahmad S (2019) Uma Estrutura para Inteligência e Função Cortical Baseada em Células de Grade no Neocórtex. Frente. Circuitos Neurais 12:121. doi: 10.3389/fncir.2018.00121

INTRODUÇÃO

O neocórtex humano aprende um modelo incrivelmente complexo e detalhado do mundo. Cada um de nós pode reconhecer milhares de objetos. Sabemos como esses objetos aparecem através da visão, do tato e da audição, sabemos como esses objetos se comportam e mudam quando interagimos com eles e sabemos sua localização no mundo. O neocórtex humano também aprende modelos de objetos abstratos, estruturas que não existem fisicamente ou que não podemos sentir diretamente. Os circuitos do neocórtex também são complexos. Compreender como os circuitos complexos do neocórtex aprendem modelos complexos do mundo é um dos principais objetivos da neurociência.

Vernon Mountcastle foi o primeiro a propor que todas as regiões do neocórtex são fundamentalmente iguais. O que distingue uma região da outra, argumentou ele, é principalmente determinado pelas entradas de uma região e não pelas diferenças nos circuitos e funções intrínsecos. Ele propôs ainda que um pequeno volume de córtex, uma coluna cortical, é a unidade de replicação (Mountcastle, 1978).

These are compelling ideas, but it has been difficult to identify what a column could do that is sufficient to explain all cognitive abilities. Today, the most common view is that the neocortex processes sensory input in a series of hierarchical steps, extracting more and more complex features until objects are recognized (Fukushima, 1980; Riesenhuber and Poggio, 1999). Although this view explains some aspects of sensory inference, it fails to explain the richness of human behavior, how we learn multi-dimensional models of objects, and how we learn how objects themselves change and behave when we interact with them. It also fails to explain what most of the circuitry of the neocortex is doing. In this paper we propose a new theoretical framework based on location processing that addresses many of these shortcomings.

Over the past few decades some of the most exciting advances in neuroscience have been related to "grid cells" and "place cells." These neurons exist in the hippocampal complex of mammals, a set of regions, which, in humans, is roughly the size and shape of a finger, one on each side of the brain. Grid cells in combination with place cells learn maps of the world (O'Keefe and Dostrovsky, 1971; Hafting et al., 2005; Moser et al., 2008). Grid cells represent the current location of an animal relative to those maps. Modeling work on the hippocampus has demonstrated the power of these neural representations for episodic and spatial memory (Byrne et al., 2007; Hasselmo et al., 2010; Hasselmo, 2012), and navigation (Erdem and Hasselmo, 2014; Bush et al., 2015). There is also evidence that grid cells play a role in more abstract cognitive tasks (Constantinescu et al., 2016; Behrens et al., 2018).

Recent experimental evidence suggests that grid cells may also be present in the neocortex. Using fMRI (Doeller et al., 2010; Constantinescu et al., 2016; Julian et al., 2018) have found signatures of grid cell-like firing patterns in prefrontal and parietal areas of the neocortex. Using single cell recording in humans (Jacobs et al., 2013) have found more direct evidence of grid cells in frontal cortex (Long and Zhang, 2018), using multiple tetrode recordings, have reported finding cells exhibiting grid cell, place cell, and conjunctive cell responses in rat S1. Our team has proposed that prediction of sensory input by the neocortex requires a representation of an object-centric location to be present throughout the sensory regions of the neocortex, which is consistent with grid cell-like mechanisms (Hawkins et al., 2017).

Here we propose that grid cell-like neurons exist in every column of the neocortex. Whereas grid cells in the medial entorhinal cortex (MEC) primarily represent the location of one thing, the body, we suggest that cortical grid cells simultaneously represent the location of multiple things. Columns in somatosensory cortex that receive input from different parts of the body represent the location of those inputs in the external reference frames of the objects being touched. Similarly, cortical columns in visual cortex that receive input from different patches of the retinas represent the location of visual input in the external reference frames of the objects being viewed. Whereas grid cells and place cells learn models of environments via movement of the body, we propose that cortical grid cells combined with sensory input learn models of objects via movement of the sensors.

Although much is known about the receptive field properties of grid cells in MEC and how these cells encode location (Rowland et al., 2016), the underlying mechanisms leading to those properties is not known. Experimental results suggest that grid cells have unique membrane and dendritic properties (Domnisoru et al., 2013; Schmidt-Hieber et al., 2017). There are two leading computational candidates, oscillatory interference models (O'Keefe and Burgess, 2005; Burgess et al., 2007; Giocomo et al., 2007, 2011; Burgess, 2008) and continuous attractor models (Fuhs and Touretzky, 2006; Burak and Fiete, 2009). The framework proposed in this paper assumes that "cortical grid cells" exhibit similar physiological properties as grid cells in MEC, but the framework is not dependent on how those properties arise.

Throughout this paper we refer to "cortical columns." We use this term similarly to Mountcastle, to represent a small area of neocortex that spans all layers in depth and of sufficient lateral extent to capture all cell types and receptive field responses. For this paper, a cortical column is not a physically demarked entity. It is a convenience of nomenclature. We typically think of a column as being about one square millimeter of cortical area, although this size is not critical and could vary by species and region.

HOW GRID CELLS REPRESENT LOCATION

To understand our proposal, we first review how grid cells in the entorhinal cortex are believed to represent space and location, **Figure 1**. Although many details of grid cell function remain unknown, general consensus exists on the following principles. A grid cell is a neuron that becomes active at multiple locations in an environment, typically in a grid-like, or tiled, triangular lattice. A "grid cell module" is a set of grid cells that activate with the same lattice spacing and orientation but at shifted locations within an environment (Stensola et al., 2012). As an animal moves, the active grid cells in a grid cell module change to reflect the animal's updated location. This change occurs even if the animal is in the dark, telling us that grid cells are updated using an internal, or "efference," copy of motor commands (Hafting et al., 2005; McNaughton et al., 2006; Moser et al., 2008; Kropff et al., 2015). This process, called "path integration," has the desirable property that regardless of the path of movement, when the animal returns to the same physical location, then the same grid cells in a module will be active.

Due to tiling, a single grid cell module cannot represent a unique location. To form a representation of a unique location requires looking at the active cells in multiple grid cell modules where each grid cell module differs in its tile spacing and/or orientation relative to the environment, **Figures 1C,D**. For example, if a single grid cell module can represent twenty different locations before repeating, then 10 grid cell modules can represent approximately 20^{10} different locations before repeating (Fiete et al., 2008). This method of representing location has several desirable properties:

Estas são ideias convincentes, mas tem sido difícil identificar o que uma coluna poderia fazer que fosse suficiente para explicar todas as capacidades cognitivas. Hoje, a visão mais comum é que o neocórtex processa informações sensoriais em uma série de eta pas hierárquicas, extraindo características cada vez mais complexas até que os objetos sejam reconhecidos (Fukushima, 1980; Riesenhuber e Poggio, 1999). Embora esta visão explique alguns aspectos da inferência sensorial, ela não consegue explicar a riqueza do comportamento humano, como aprendemos modelos multidimensionais de objetos e como aprendemos como os próprios objetos mudam e se comportam quando interagimos com eles. Também não explica o que a maior parte dos circuitos do neocórtex está fazendo. Neste artigo propomos um novo arcabouço teórico baseado no processamento de localização que aborda muitas dessas deficiências.

Nas últimas décadas, alguns dos avanços mais emocionantes da neurociência foram relacionados com "células de grade" e " células de lugar". Esses neurônios existem no complexo hipocampal dos mamíferos, um conjunto de regiões que, nos humanos, tem aproximadamente o tamanho e o formato de um dedo, um de cada lado do cérebro. Células de grade em combinação com células de lugar aprendem mapas do mundo (O' Keefe e Dostrovsky, 1971; Hafting et al., 2005; Moser et al., 2008). As células da grade representam a localização atual de um animal em relação a esses mapas. O trabalho de modelagem no hipocampo demonstrou o poder dessas representações neurais para memória episódica e espacial (Byrne et al., 2007; Hasselmo et al., 2010; Hasselmo, 2012) e navegação (Erdem e Hasselmo, 2014; Bushet al., 2015). Há também evidências de que as células da grelha desempenham um papel em tarefas cognitivas mais abstratas (Constantinescu et al., 2016; Behrens et al., 2018).

Evidências experimentais recentes sugerem que as células da grade também podem estar presentes no neocórtex. Usando fMRI (Doeller et al., 2010; Constantinescu et al., 2016; Julian et al., 2018) encontraram assinaturas de padrões de disparo semelhantes a células de grade em áreas pré-frontais e parietais do neocórtex. Usando registro de célula única em humanos (Jacobs et al., 2013) encontraram evidências mais diretas de células de grade no córtex frontal (Long e Zhang, 2018), usando registros de múltiplos tetrodos, relataram encontrar células exibindo células de grade, células de lugar e respostas de células conjuntivas no rato S1. Nossa equipe propôs que a previsão da entrada sensorial pelo neocórtex requer uma representação de uma localização centrada no objeto presente em todas as regiões sensoriais do neocórtex, o que é consistente com mecanismos semelhantes a células de grade (Hawkins et al., 2017).

Aqui propomos que neurônios semelhantes a células de grade existam em todas as colunas do neocórtex. Enquanto as células da grade no córtex entorrinal medial (MEC) representam principalmente a localização de uma coisa, o corpo, sugerimos que as células da grade cortical representam simultaneamente a localização de múltiplas coisas. Colunas no córtex s omatossensorial que recebem informações de diferentes partes do corpo representam a localização dessas entradas nos quadros de referência externos dos objetos que estão sendo tocados. Da mesma forma, as colunas corticais no córtex visual que recebem informações de diferentes áreas da retina representam a localização da entrada visual nos quadros de referência externos dos objetos que estão sendo visualizados. Enquanto as células da grade e as células locais aprendem modelos de ambientes por meio do movimento do corpo, propomos que as células da grade cortical combinadas com informações sensoriais aprendam modelos de objetos por meio do movimento dos sensores.

Embora muito se saiba sobre as propriedades do campo receptivo das células da grade no MEC e como essas células codificam a localização (Rowland et al., 2016), os mecanismos subjacentes que levam a essas propriedades não são conhecidos. Resultados experimentais sugerem que as células da grade possuem propriedades únicas de membrana e dendríticas (Domnisoru et al., 2013; Schmidt-Hieber et al., 2017). Existem dois principais candidatos computacionais, modelos de interferência oscilatória (O'Keefeand Burgess, 2005; Burgess et al., 2007; Giocomo et al., 2007, 2011; Burgess, 2008) e modelos de atratores contínuos (Fuhs e Touretzky, 2006; Burak e Fiete, 2009). A estrutura proposta neste artigo assume que as "células da grade cortical" exibem propriedades fisiológicas semelhantes às das células da grade no MEC, mas a estrutura não depende de como essas propriedades surgem.

Ao longo deste artigo nos referimos a "colunas corticais". Usamos este termo de forma semelhante a Mountcastle, para representar uma pequena área do neocórtex que abrange todas as camadas em profundidade e com extensão lateral suficiente para capturar todos os tipos de células e respostas de campo receptivo. Para este artigo, uma coluna cortical não é uma entidade fisicamente demarcada. É uma conveniência de nomenclatura. Normalmente pensamos em uma coluna como tendo cerca de um milímetro quadrado de área cortical, embora esse tamanho não seja crítico e possa variar de acordo com a espécie e a região.

COMO AS CÉLULAS DA GRADE REPRESENTAM A LOCALIZAÇÃO

Para entender nossa proposta, primeiro revisamos como se acredita que as células da grade no córtex entorrinal representem o espaço e a localização, Figura 1. Embora muitos detalhes da função das células da grade permaneçam desconhecidos, existe um consenso geral sobre os seguintes princípios. Uma célula de grade é um neurônio que se torna ativo em vários locais de um ambiente, normalmente em uma rede triangular semelhante a uma grade ou lado a lado. Um "módulo de célula de grade" é um conjunto de células de grade que são ativadas com o mesmo espaçamento e orientação de rede, mas em locais deslocados dentro de um ambiente (Stensola et al., 2012). À medida que um animal se move, as células da grade ativas em um módulo de células da grade mudam para refletir a localização atualizada do animal. Essa mudança ocorre mesmo se o animal estiver no escuro, nos dizendo que as células da grade são atualizadas usando uma cópia interna, ou "eferência", dos comandos motores (Hafting et al., 2005; McNaughton et al., 2006; Moser et al., 2008; Kropff et al., 2015). Este processo, denominado "integração de caminho", tem a propriedade desejável de que, independentemente do caminho de movimento, quando o animal retornar ao mesmo local físico, as mesmas células da grade em um módulo estarão ativas.

Devido ao ladrilho, um único módulo de célula da grade não pode representar um local exclusivo. Para formar uma representação de um local único, é necessário observar as células ativas em vários módulos de células de grade, onde cada módulo de célula de grade difere em seu espaçamento e/ou orientação em relação ao ambiente, Figuras 1C,D. Por exemplo, se um único módulo de célula de grade pode representar vinte locais diferentes antes da repetição, então 10 módulos de células de grade podem representar locais aproximadamente 20^{10} diferentes antes da repetição (Fiete et al., 2008). Este método de representação de localização possui diversas propriedades desejáveis:

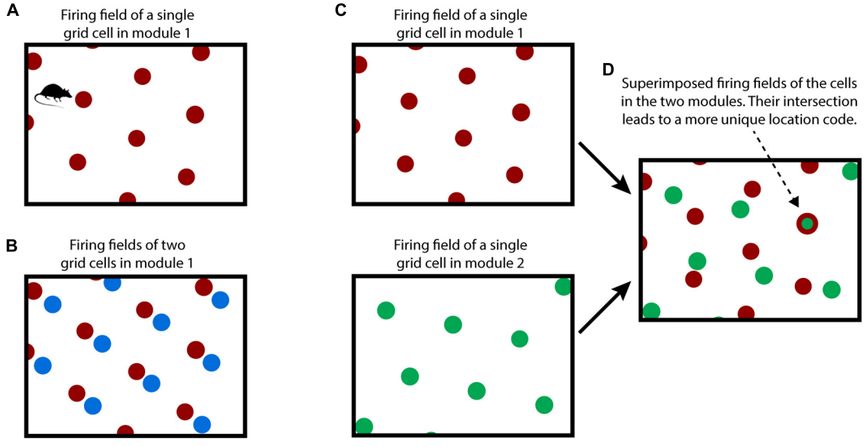


FIGURE 1 | How grid cells represent location. **(A)** An individual grid cell becomes active at multiple locations (red circles) as an animal moves about an environment (rectangle). The locations of activation form a periodic grid-like lattice. The activation locations are always the same for any particular environment. **(B)** A grid cell module is a set of grid cells that activate at the same spacing and orientation but at different positions in the environment. The activation locations for two grid cells in a grid cell module are shown (red and blue dots). Every location in an environment will activate one or more grid cells in a module. Because of the periodic activation of grid cells, a single grid cell module cannot represent unique locations. **(C)** Multiple grid cell modules (two shown, top and bottom) tile the same space at different orientations and/or spacings. **(D)** Although a single module cannot represent unique locations in an environment, the activity across multiple modules can. This rectangle shows the superimposed firing fields of the two grid cells from **C**). Note that when the two cells (red and green) fire together, only one location is possible (indicated by arrow). The number of locations that can be represented increases exponentially with the number of modules.

(1) Large representational capacity:

The number of locations that can be represented by a set of grid cell modules is large as it scales exponentially with the number of modules.

(2) Path integration works from any location:

No matter what location the network starts with, path integration will work. This is a form of generalization. The path integration properties have to be learned once for each grid cell module, but then apply to all locations, even those the animal has never been in before.

(3) Locations are unique to each environment:

Every learned environment is associated with a set of unique locations. Experimental recordings suggest that upon entering a learned environment, entorhinal grid cell modules "anchor" differently (Rowland and Moser, 2014; Marozzi et al., 2015). (The term "anchor" refers to selecting which grid cells in each module should be active at the current location.) This suggests that the current location and all the locations that the animal can move to in that environment will, with high certainty, have representations that are unique to that environment (Fiete et al., 2008; Sreenivasan and Fiete, 2011).

Combining these properties, we can now broadly describe how grid cells represent an environment such as a room, **Figure 2A**. An environment consists of a set of location representations that are related to each other via path integration (i.e., the animal can move between these location representations). Each location representation in the set is unique to that environment and will not appear in any other environment. An environment consists of all the locations that the animal can move among, including locations that have not been visited, but could be visited. Associated with some of the location representations are observable landmarks.

GRID CELLS IN THE NEOCORTEX

Now let us consider a patch of neocortex that receives input from the tip of a finger, **Figure 2B**. Our proposal is that some of the neurons in that patch of cortex represent the location of the fingertip as it explores an object. When the finger moves, these cortical grid cells update their representation of location via a motor efference copy and path integration. Objects, such as a coffee cup, have an associated set of locations, in the same way that environments, such as a room, have an associated set of locations. Associated with some of the object's locations are observable features. The cortical area receiving input from the fingertip tracks the location of the sensory input from the fingertip in the location space of the object. Through movement and sensation, the fingertip cortical area learns models of objects in the same way that grid cells and place cells learn models of environments. Whereas the entorhinal cortex tracks the location of the body, different areas of the neocortex independently track the location of each movable sensory patch. For example, each area of somatosensory cortex tracks the location of sensory input

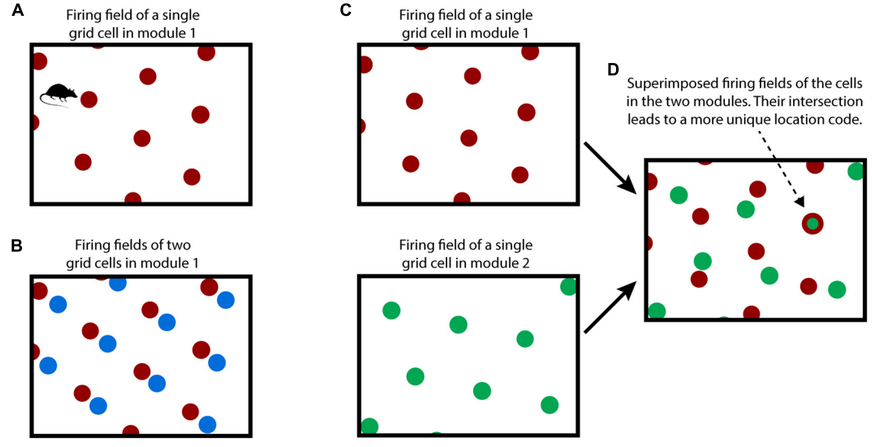


FIGURA **1 |** Como as células da grade representam a localização. (A) Uma célula de grade individual torna-se ativa em vários locais (círculos vermelhos) à medida que um animal se move em um ambiente (retângulo). Os locais de ativação formam uma rede periódica semelhante a uma grade. Os locais de ativação são sempre os mesmos para qualquer ambiente específico. (B) Um módulo de célula de grade é um conjunto de células de grade que são ativadas no mesmo espaçamento e orientação, mas em posições diferentes no ambiente. Os locais de ativação para duas células da grade em um módulo de células da grade são mostrados (pontos vermelhos e azuis). Cada local em um ambiente ativará uma ou mais células de grade em um módulo. Devido à ativação periódica das células da grade, um único módulo de célula da grade não pode representar localizações exclusivas. (C) Vários módulos de células de grade (dois mostrados, superior e inferior) lado a lado no mesmo espaço em diferentes orientações e/ou espaçamentos. (D) Embora um único módulo não possa representar locais exclusivos em um ambiente, a atividade em vários módulos pode. Este retângulo mostra os campos de disparo sobrepostos das duas células da grade de C). Observe que quando as duas células (vermelha e verde) disparam juntas, apenas um local é possível (indicado pela seta). O número de locais que podem ser representados aumenta exponencialmente co m o número de módulos.

(1) Grande capacidade representacional:

O número de locais que podem ser representados por um conjunto de módulos de células da grade é grande, pois aumenta exponencialmente com o número de módulos.

(2) A integração do caminho funciona em qualquer local:

Não importa em que local a rede comece, a integração de c aminhos funcionará. Esta é uma forma de generalização. As propriedades de integração do caminho devem ser aprendidas uma vez para cada módulo de célula da grade, mas depois aplicadas a todos os locais, mesmo aqueles onde o animal nunca esteve antes.

(3) Os locais são exclusivos para cada ambiente:

Cada ambiente aprendido está associado a um conjunto de locais únicos. Gravações experimentais sugerem que, ao entrar e m um ambiente aprendido, os módulos de células da grade entorrinal "ancoram" de maneira diferente (Rowland e Moser, 2014; Marozzi et al., 2015). (O termo "âncora" refere-se à seleção de quais células da grade em cada módulo devem estar ativas no local atual.) Isso sugere que o local atual e todos os locais para os quais o animal pode se mover naquele ambiente terão, com alta certeza, representações que são exclusivas desse ambiente (Fiete et al., 2008; SreenivasanandFiete, 2011).

Combinando essas propriedades, podemos agora descrever amplamente como as células da grade representam um ambiente co mo uma sala, Figura 2A. Um ambiente consiste em um conjunto de representações de localização que estão relacionadas entre si através da integração de caminhos (ou seja, o animal pode se mover entre essas representações de localização). Cada representação de local no conjunto é exclusiva daquele ambiente e não aparecerá em nenhum outro ambiente. Um ambiente consiste em todos os locais pelos quais o animal pode circular, incluindo locais que não foram visitados, mas que poderiam ser visitados. Associados a algumas das representações de localização estão pontos de referência observáveis.

CÉLULAS DA GRADE NO NEOCÓRTEX

Agora vamos considerar um trecho do neocórtex que recebe informações da ponta de um dedo, Figura 2B. Nossa proposta é que alguns dos neurônios nessa área do córtex representem a localização da ponta do dedo enquanto ela explora um objeto. Quando o dedo se move, essas células da grade cortical atualizam sua representação de localização por meio de uma cópia de eferência motora e integração de caminho. Objetos, como uma xícara de café, possuem um conjunto associado de localizações, da mesma forma que ambientes, como uma sala, possuem um conjunto associado de localizações. Associadas a algumas das localizações do objeto estão características observáveis. A área cortical que recebe informações da ponta do dedo rastreia a localização da entrada sensorial da ponta do dedo no espaço de localização do objeto. Através do movimento e da sensação, a área cortical da ponta do dedo aprende modelos de objetos da mesma forma que as células da grade e as células de localização a prendem modelos de ambientes. Enquanto o córtex entorrinal rastreia a localização do corpo, diferentes áreas do neocórtex rastreiam independentemente a localização de cada área sensorial móvel. Por exemplo, cada área do córtex somatossensorial rastreia a localização da entrada sensorial

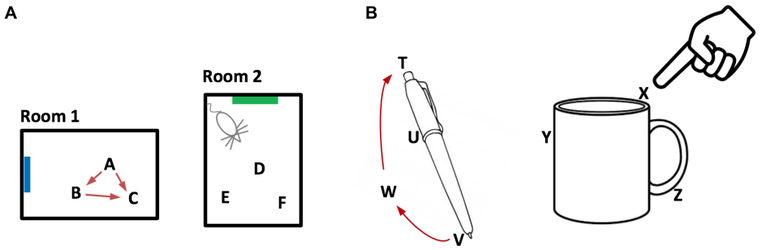


FIGURE 2 | Representing objects as location spaces. We propose that the neocortex learns the structure of objects in the same way that the entorhinal cortex and hippocampus learn the structure of environments. **(A)** Two rooms that a rodent has learned. Because of distinct landmarks (suggested by blue and green rectangles) an animal will perceive these as different rooms. Locations in a room are represented by the activity in a set of grid cell modules in the entorhinal cortex. Three locations are shown for each room (A,B,C and D,E,F). Representations of location are unique to both the location in a room and the room. Therefore, if an animal can determine it is in location A, then it knows what room it is in (Room1) and its location in the room. The locations associated with a room are united via movement and path integration. As an animal moves, the representation of location is updated (red arrows) based on an internal copy of its motor behavior. By exploring a room, the animal learns the features associated with locations in the room. **(B)** We propose that objects such as a pen or coffee cup are similarly defined by a set of locations (four labeled for the pen and three labeled for the cup). Grid cells in the neocortex represent the location of a sensor patch (for example, tip of finger) in the location space of the object. Locations in an object's space are unique to the object and the location relative to the object. An object's space includes locations that can be moved to but don't necessarily have an associated feature. For example, location W is part of the pen because a finger can move from V to W to T via path integration. By moving and exploring the object, the neocortex learns the features associated with locations of the object.

from its associated body part. These areas operate in parallel and build parallel models of objects. The same basic method applies to vision. Patches of the retina are analogous to patches of skin. Different parts of the retina observe different locations on an object. Each patch of cortex receiving visual input tracks the location of its visual input in the location space of the object being observed. As the eyes move, visual cortical columns sense different locations on an object and learn parallel models of the observed object.

We have now covered the most basic aspects of our proposal:

(1) Every cortical column has neurons that perform a function similar to grid cells. The activation pattern of these cortical grid cells represents the location of the column's input relative to an external reference frame. The location representation is updated via a motor efference copy and path integration.
(2) Cortical columns learn models of objects in the world similarly to how grid cells and place cells learn models of environments. The models learned by cortical columns consist of a set of location representations that are unique to each object, and where some of the locations have observable features.

A LOCATION-BASED FRAMEWORK FOR CORTICAL COMPUTATION

Our proposal suggests that cortical columns are more powerful than previously assumed. By pairing input with a grid cell-derived representation of location, individual columns can learn complex models of structure in the world (see also Lewis et al., 2018). In this section we show how a location-based framework allows neurons to learn the rich models that we know the neocortex is capable of.

Object Compositionality

Objects are composed of other objects arranged in a particular way. For example, it would be inefficient to learn the morphology of a coffee cup by remembering the sensory sensation at each location on the cup. It is far more efficient to learn the cup as the composition of previously learned objects, such as a cylinder and a handle. Consider a coffee cup with a logo on it, **Figure 3A**. The logo exists in multiple places in the world and is itself a learned "object." To represent the cup with the logo we need a way of associating one object, "the logo," at a relative position to another object, "the cup." Compositional structure is present in almost all objects in the world, therefore cortical columns must have a neural mechanism that represents a new object as an arrangement of previously-learned objects. How can this functionality be achieved?

We have proposed that each object is associated with a set of locations which are unique to the object and comprise a space around the object. If a finger is touching the coffee cup with the logo, then the cortical grid cells representing the location of the finger can at one moment represent the location of the finger in the space of the coffee cup and at another moment, after re-anchoring, represent the location of the finger in the space of the logo. If the logo is attached to the cup, then there is a fixed, one-to-one, relationship between any point in the space of the logo and the equivalent point in the space of the cup, **Figure 3B**. The task of representing the logo on the cup can be achieved by creating a "displacement" vector that converts any point in cup space to the equivalent point in logo space.

Determining the displacement between two objects is similar to a previously-studied navigation problem, specifically, how an animal knows how to get from point **a** to point **b** within an environment, **Figure 3C**. Mechanisms that solve the navigation problem (determining the displacement between two points in

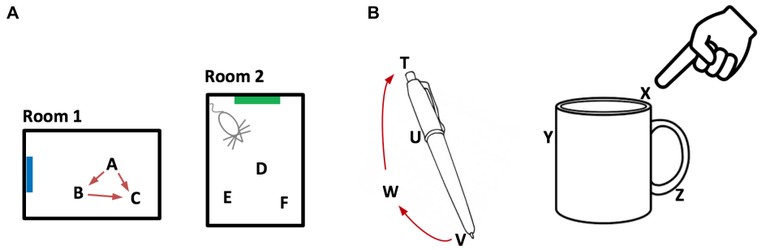


FIGURA **2 |** Representando objetos como espaços de localização. Propomos que o neocórtex aprende a estrutura dos objetos da mesma forma que o córtex entorrinal e o hipocampo aprendem a estrutura dos ambientes. (A) Duas salas que um roedor aprendeu. Devido aos pontos de referência distintos (sugeridos pelos retângulos azuis e verdes), um animal os perceberá como salas diferentes. As localizações em uma sala são representadas pela atividade em um conjunto de módulos de células da grade no córtex entorrinal. Três locais são mostrados para cada sala (A,B,C e D,E,F). As representações de localização são exclusivas tanto para a localização em uma sala quanto para a sala. Portanto, se um animal puder determinar que está na localização A, então ele saberá em que sala está (Sala 1) e sua localização na sala. Os locais associados a uma sala são unidos através da integração de movimentos e caminhos. À medida que um animal se move, a representação da localização é atualizada (setas vermelhas) com base numa cópia interna do seu comportamento motor. Ao explorar uma sala, o animal aprende as características associadas aos locais da sala. (B) Propomos que objetos como uma caneta ou uma xícara de café sejam definidos de forma semelhante por um conjunto de locais (quatro rotulados para a caneta e três rotulados para a xícara). As células da grade no neocórtex representam a localização de uma área sensora (por exemplo, a ponta do dedo) no espaço de localização do objeto. As localizações no espaço de um objeto são exclusivas do objeto e a localização relativa ao objeto. O espaço de um objeto inclui locais para os quais pode ser movido, mas não necessariamente possuem um recurso associado. Por exemplo, a localização W faz parte da caneta porque um dedo pode mover-se de V para W e para T através da integração de caminho. Ao mover e explorar o objeto, o neocórtex aprende as características associadas às localizações do objeto.

da parte do corpo associada. Essas áreas operam em paralelo e constroem modelos paralelos de objetos. O mesmo método básico se aplica à visão. As manchas da retina são análogas às manchas da pele. Diferentes partes da retina observam diferentes localizações em um objeto. Cada pedaço do córtex que recebe informações visuais rastreia a localização de suas informações visuais no espaço de localização do objeto que está sendo observado. À medida que os olhos se movem, as colunas corticais visuais detectam diferentes localizações em um objeto e aprende m modelos paralelos do objeto observado.

Já cobrimos os aspectos mais básicos da nossa proposta:

(1) Cada coluna cortical possui neurônios que desempenham uma função semelhante às células da grade. O padrão de ativação dessas células da grade cortical representa a localização da entrada da coluna em relação a um referencial externo. A representação da localização é atualizada através de uma cópia de eferência do motor e integração de caminho.

(2) As colunas corticais aprendem modelos de objetos no mundo de forma semelhante à forma como as células da grade e as células de lugar aprendem modelos de ambientes. Os modelos aprendidos pelas colunas corticais consistem em um conjunto de representações de localização que são únicas para cada objeto e onde algumas das localizações possuem características observáveis.

UMA ESTRUTURA BASEADA EM LOCALIZAÇÃO PARA COMPUTAÇÃO CORTICAL

Nossa proposta sugere que as colunas corticais são mais poderosas do que se supunha anteriormente. Ao emparelhar a entrada com uma representação de localização derivada de células de grade, colunas individuais podem aprender modelos complexos de estrutura no mundo (ver também Lewis et al., 2018). Nesta seção, mostramos como uma estrutura baseada em localização permite que os neurônios aprendam os modelos ricos que sabemos que o neocórtex é capaz.

Composicionalidade do Objeto

Os objetos são compostos de outros objetos organizados de uma maneira particular. Por exemplo, seria ineficiente aprender a morfologia de uma xícara de café lembrando-se da sensação sensorial em cada local da xícara. É muito mais eficiente aprender o copo como a composição de objetos previamente aprendidos, como um cilindro e uma alça. Considere uma xícara de café com um logotipo, Figura 3A. O logotipo existe em vários lugares do mundo e é em si um "objeto" aprendido. Para representar a xícara com o logotipo, precisamos de uma forma de associar um objeto, " o logotipo", em uma posição relativa a outro objeto, "a xícara". A estrutura composicional está presente em quase todos os objetos do mundo, portanto as colunas corticais devem ter um mecanismo neural que represente um novo objeto como um arranjo de objetos previamente aprendidos. Como essa funcionalidade pode ser alcançada?

Propusemos que cada objeto esteja associado a um conjunto de localizações que são exclusivas do objeto e compreendem um espaço ao redor do objeto. Se um dedo estiver tocando a xícara de café com o logotipo, então as células da grade cortical que representam a localização do dedo podem, em um momento, representar a localização do dedo no espaço da xícara de café e e m outro momento, após a reancoragem, representar a localização do dedo no espaço do logotipo. Se o logotipo estiver anexado ao copo, então existe uma relação fixa, um a um, entre qualquer ponto no espaço do logotipo e o ponto equivalente no espaço do copo, Figura 3B. A tarefa de representar o logotipo na xícara pode ser alcançada criando um vetor de "deslocamento" que converte qualquer ponto no espaço da xícara no ponto equivalente no espaço do logotipo.

Determinar o deslocamento entre dois objetos é semelhante a um problema de navegação previamente estudado, especificamente, como um animal sabe como ir do ponto a ao ponto b dentro de um a mbiente, Figura 3C. Mecanismos que resolvem o problema de navegação (determinar o deslocamento entre dois pontos em

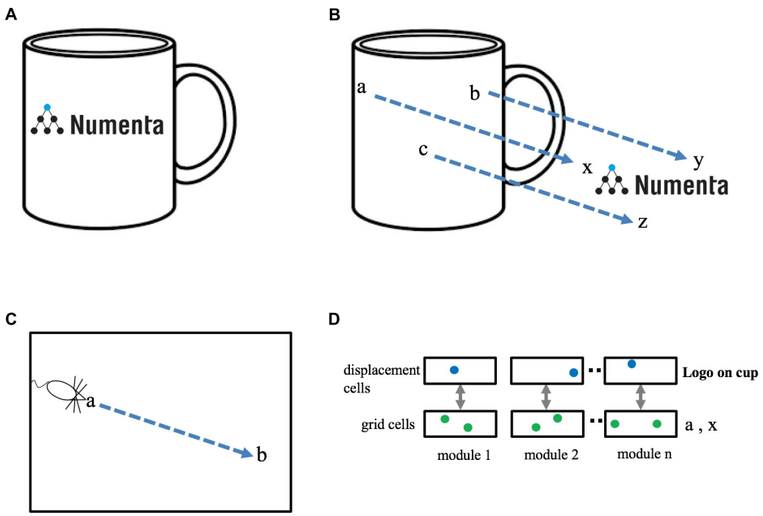


FIGURE 3 | Representing objects as compositions of other objects. **(A)** The neocortex can learn an object, such as a "coffee cup with logo," as a composition of two previously learned objects, "cup" and "logo." The goal is to represent this relationship efficiently, without any relearning. **(B)** The cup and the logo each have their own unique set of locations. Three locations are shown in cup space (**a**, **b**, **c**) and three locations are shown in logo space (**x**, **y**, **z**). When the logo is placed on the cup there is a fixed one-to-one mapping between locations in cup space and locations in logo space. This relationship can be represented as a displacement vector between the two spaces (blue arrows). **(C)** Animals exploring an environment can determine the direction and distance from their current location, **a,** to a previously visited target location, **b**, even if they have never taken this path before. Determining the displacement between two locations in the same space (e.g., **a** to **b** in **C**) is equivalent to determining the displacement between two locations in separate spaces (e.g., **a** to **x** in **B**). **(D)** A method to determine the displacement between two locations. Each grid cell module is paired with a displacement cell module. Cells in a displacement cell module (blue dots) respond to a particular displacement between pairs of grid cells (green dots). Any two pairs of grid cells with the same displacement in physical space will activate the same displacement cell. Displacement cells cannot represent a unique displacement in the same way that grid cells cannot represent a unique location. However, the set of active cells in multiple displacement cell modules (three shown) will represent a unique displacement. Because the set of active grid cells in multiple grid cell modules is unique to objects (cup and logo), the set of active displacement cells will also be unique (to both the cup and logo). Thus, a set of active displacement cells can represent the relative placement of two specific objects (location of logo on cup).

the same space) can also solve the object composition problem (determining the displacement between two points in two different spaces).

Displacement Cells

Several solutions have been proposed for solving the point-to-point navigation problem using grid cells. One class of solutions detects the difference between two sets of active grid cells across multiple grid cell modules (Bush et al., 2015) and another uses linear look-ahead probes using grid cells for planning and computing trajectories (Erdem and Hasselmo, 2014). We suggest an alternate but related solution. Our proposal also relies on detecting differences between two sets of active grid cells, however, we propose this is done on a grid cell module by grid cell module basis. We refer to these cells as "displacement cells" (see **Supplementary Material** for a more thorough description). Displacement cells are similar to grid cells in that they can't on their own represent a unique displacement. (In the **Supplementary Material** example, a displacement cell that represents a displacement of "two to the right and one up," would also be active for "five over and four up.") However, the cell activity in multiple displacement cell modules represents a unique displacement in much the same way as the cell activity in multiple grid cell modules represents a unique location, **Figure 3D**. Hence, a single displacement vector can represent the logo on the coffee cup at a specific relative position. Note, a displacement vector not only represents the relative position of two objects, it also is unique to the two objects. Complex objects can be represented by a set of displacement vectors which define the components of an object and how they are arranged relative to each other. This is a highly efficient means of representing and storing the structure of objects.

This method of representing objects allows for hierarchical composition. For example, the logo on the cup is also composed of sub-objects, such as letters and a graphic. A displacement vector placing the logo on the cup implicitly carries with it all the sub-objects of the logo. The method also allows for recursive structures. For example, the logo could contain a picture of a coffee cup with a logo. Hierarchical and recursive composition are fundamental elements of not only physical objects but language, mathematics, and other manifestations of intelligent thought. The key idea is that the identity and relative position of two previously-learned objects, even complex

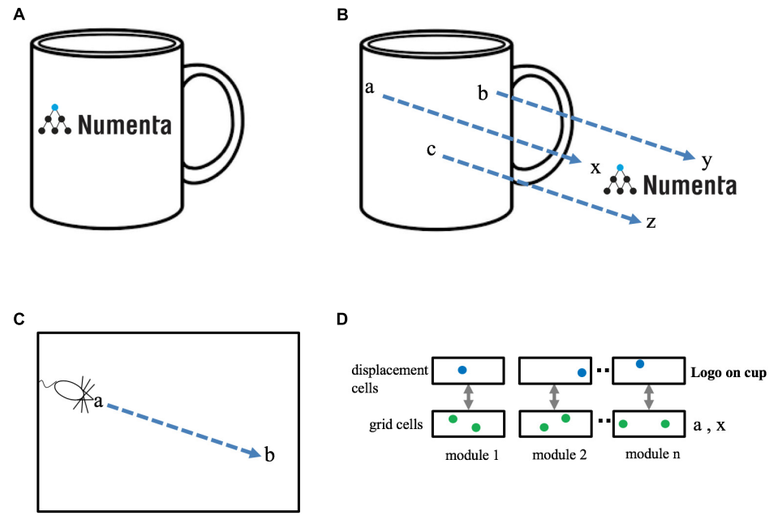


FIGURA **3 |** Representando objetos como composições de outros objetos. (A) O neocórtex pode aprender um objeto, como uma "xícara de café com logotipo", como uma composição de dois objetos previamente aprendidos, "xícara" e "logotipo". O objetivo é representar esse relacionamento de forma eficiente, sem qualquer reaprendizado. (B) O copo e o logotipo têm, cada um, seu próprio conjunto exclusivo de locais. Três locais são mostrados no espaço do copo (a, b, c) e três locais são mostrados no espaço do logotipo (x, y, z). Quando o logotipo é colocado no copo, há um mapeamento fixo um a um entre os locais no espaço do copo e os locais no espaço do logotipo. Esta relação pode ser representada como um vetor de deslocamento entre os dois espaços (setas azuis). (C) Os animais que exploram um ambiente podem determinar a direção e a distância da sua localização atual, a, até um local alvo previamente visitado, b, mesmo que nunca tenham percorrido esse caminho antes. Determinar o deslocamento entre dois locais no mesmo espaço (por exemplo, a para b em C) é equivalente a determinar o deslocamento entre dois locais em espaços separados (por exemplo, a para x em B). (D) Um método para determinar o deslocamento entre dois locais. Cada módulo de célula da grade é emparelhado com um módulo de célula de deslocamento. As células em um módulo de células de deslocamento (pontos azuis) respondem a um deslocamento específico entre pares de células da grade (pontos verdes). Quaisquer dois pares de células da grade com o mesmo deslocamento no espaço físico ativarão a mesma célula de deslocamento. As células de deslocamento não podem representar um deslocamento único da mesma forma que as células da grade não podem representar uma localização única. No entanto, o conjunto de células ativas em módulos de células de deslocamento múltiplo (três mostrados) representará um deslocamento único. Como o conjunto de células de grade ativas em vários módulos de células de grade é exclusivo para objetos (copo e logotipo), o conjunto de células de deslocamento ativas também será exclusivo (tanto para o copo quanto para o logotipo). Assim, um conjunto de células de deslocamento ativo pode representar o posicionamento relativo de dois objetos específicos (localização do logotipo no copo).

no mesmo espaço) também pode resolver o problema de composição de objetos (determinar o deslocamento entre dois pontos em dois espaços diferentes).

Células de Deslocamento

Várias soluções foram propostas para resolver o problema de navegação ponto a ponto usando células de grade. Uma classe de soluções detecta a diferença entre dois conjuntos de células de grade ativas em vários módulos de células de grade (Bush et al., 2015) e outra usa sondas lineares antecipadas usando células de grade para planejamento e computação de trajetórias (Erdem e Hasselmo, 2014). Sugerimos uma solução alternativa, mas relacionada. Nossa proposta também se baseia na detecção de diferenças entre dois conjuntos de células de grade ativas, no entanto, propomos que isso seja feito módulo de célula de grade por módulo de célula de grade. Referimo-nos a essas células como "células de deslocamento" (ver Material Suplementar para uma descrição mais completa). As células de deslocamento são semelhantes às células da grade porque não podem, por si só, representar um deslocamento único. (No exemplo do Material Suplementar, uma célula de deslocamento que representa u m deslocamento de "dois para a direita e um para cima" também estaria ativa para "cinco para cima e quatro para cima".) No entanto, a atividade celular em múltiplos módulos de células de deslocamento representa um

o deslocamento único, da mesma maneira que a atividade celular em vários módulos de células da grade, representa uma l ocalização única, Figura 3D. Assim, um único vetor de deslocamento pode representar o logotipo na xícara de café em uma posição relativa específica. Observe que um vetor de deslocamento não representa apenas a posição relativa de dois objetos, mas também é exclusivo para os dois objetos. Objetos complexos podem ser representados por um conjunto de vetores de deslocamento que definem os componentes de um objeto e como eles são organizados entre si. Este é um meio altamente eficiente de representar e armazenar a estrutura dos objetos.

Este método de representação de objetos permite a composição hierárquica. Por exemplo, o logotipo do copo também é composto por subobjetos, como letras e um gráfico. Um vetor de deslocamento que coloca o logotipo no copo carrega consigo implicitamente todos os subobjetos do logotipo. O método ta mbém permite estruturas recursivas. Por exemplo, o logotipo pode conter a imagem de uma xícara de café com um logotipo. A composição hierárquica e recursiva são elementos fundamentais não apenas dos objetos físicos, mas também da linguagem, da matemática e de outras manifestações do pensamento inteligente. A ideia chave é que a identidade e a posição relativa de dois objetos previamente aprendidos, mesmo complexos,

objects, can be represented efficiently by a single displacement vector.

Grid Cells and Displacement Cells Perform Complementary Operations

Grid cells and displacement cells perform complementary operations. Grid cells determine a new location based on a current location and a displacement vector (i.e., movement). Displacement cells determine what displacement is required to reach a new location from a current location.

Grid cells : **(Location1 + Displacement => Location2)**

Displacement cells : **(Location2 – Location1 => Displacement)**

If the two locations are in the same space, then grid cells and displacement cells are useful for navigation. In this case, grid cells predict a new location based on a starting location and a given movement. Displacement cells would represent what movement is needed to get from Location1 to Location2.

If the two locations are in different spaces (that is the same physical location relative to two different objects) then grid cells and displacement cells are useful for representing the relative position of two objects. Grid cells convert a location in one object space to the equivalent location in a second object space based on a given displacement. In this case, displacement cells represent the relative position of two objects.

We propose that grid cells and displacement cells exist in all cortical columns. They perform two fundamental and complementary operations in a location-based framework of cortical processing. By alternating between representations of locations in a single object space and representations of locations in two different object spaces, the neocortex can use grid cells and displacement cells to learn both the structure of objects and generate behaviors to manipulate those objects.

The existence of grid cells in the entorhinal cortex is well-documented. We propose they also exist in all regions of the neocortex. The existence of displacement cells is a prediction introduced in this paper. We propose displacement cells are also present in all regions of the neocortex. Given their complementary role to grid cells, it is possible that displacement cells are also present in the hippocampal complex.

Object Behaviors

Objects may exhibit behaviors. For example, consider the stapler in **Figure 4**. The top of the stapler can be lifted and rotated. This action changes the stapler's morphology but not its identity. We don't perceive the open and closed stapler as two different objects even though the overall shape has changed. The movement of a part of an object relative to other parts of an object is a "behavior" of the object. The behaviors of an object can be learned, and therefore they must be represented in the neural tissue of cortical columns. We can represent behaviors in a location-based framework, again using displacement vectors. The top half and bottom half of the stapler are two components of the stapler. The relative position of the top and bottom is represented by a displacement vector in the same way as the relative position of the logo and the coffee cup. However, unlike the logo on the coffee cup, the two halves of the stapler can move relative to each other. As the stapler top rotates upward, the displacement of the stapler top to bottom changes. Thus, the rotation of the stapler top is represented by a sequence of displacement vectors. By learning this sequence, the system will have learned this behavior of the object.

Opening and closing the stapler are different behaviors yet they are composed of the same displacement elements, just in reverse order. These are sometimes referred to as "high-order" sequences. Previously we described a neural mechanism for learning high-order sequences in a layer of neurons (Hawkins and Ahmad, 2016). This mechanism, if applied to the displacement modules, would allow the learning, inference, and recall of complex behavioral sequences of objects.

"What" and "Where" Processing

Sensory processing occurs in two parallel sets of neocortical regions, often referred to as "what" and "where" pathways. In vision, damage to the "what," or ventral, pathway is associated with the loss of ability to visually recognize objects whereas damage to the "where," or dorsal, pathway is associated with the loss of ability to reach for an object even if it has been visually identified. Equivalent "what" and "where" pathways have been observed in other sensory modalities, thus it appears to be general principle of cortical organization (Goodale and Milner, 1992; Ungerleider and Haxby, 1994; Rauschecker, 2015). "What" and "where" cortical regions have similar anatomy and therefore we can assume they operate on similar principles.

A location-based framework for cortical function is applicable to both "what" and "where" processing. Briefly, we propose that the primary difference between "what" regions and "where" regions is that in "what" regions cortical grid cells represent locations that are allocentric, in the location space of objects, and in "where" regions cortical grid cells represent locations that are egocentric, in the location space of the body. **Figure 5** shows how a displacement vector representing movement could be generated in "what" and "where" regions. The basic operation, common to all, is that a region first attends to one location and then to a second location. The displacement cells will determine the movement vector needed to move from the first location to the second location. In a "what" region, **Figure 5C**, the two locations are in the space of an object, therefore, the displacement vector will represent the movement needed to move the finger from the first location on the object to the second location on the object. In this example, the "what" region needs to know where the finger is relative to the cup, but it does not need to know where the cup or finger is relative to the body. In a "where" region, **Figure 5B**, the two locations are in the space of the body, therefore, the displacement vector will represent how to move from one egocentric location to a second egocentric location. The "where" region can perform this calculation not knowing what object may or may not be at the second location. A more detailed discussion of processing in "where" regions is beyond the scope of this paper. We only

objetos, podem ser representados eficientemente por um único vetor de deslocamento.

Células de grade e células de deslocamento realizam operações complementares

As células de grade e as células de deslocamento realizam operações complementares. As células da grade determinam uma nova localização com base na localização atual e em um vetor de deslocamento (ou seja, movimento). As células de deslocamento determinam qual deslocamento é necessário para chegar a um novo local a partir de um local atual.

Células de grade : **(Local1 +Deslocamento => Local2)**

Deslocar **células de gerenciamento** : **(Location2 – Location1 => Deslocar** **mento)**

Se os dois locais estiverem no mesmo espaço, as células da grade e as células de deslocamento serão úteis para a navegação. Nesse caso, as células da grade prevêem um novo local com base em um local inicial e em um determinado movimento. As células de deslocamento representariam o movimento necessário para ir do Local1 ao Local2.

Se os dois locais estiverem em espaços diferentes (ou seja, o mesmo local físico em relação a dois objetos diferentes), as células da grade e as células de deslocamento serão úteis para re presentar a posição relativa de dois objetos. As células da grade convertem uma localização em um espaço de objetos em uma localização equivalente em um segundo espaço de objetos com base em um determinado deslocamento. Neste caso, as células de deslocamento representam a posição relativa de dois objetos.

Propomos que existam células de grade e células de deslocamento em todas as colunas corticais. Eles realizam duas operações fundamentais e complementares em uma estrutura de processamento cortical baseada em localização. Ao alternar entre representações de locais em um único espaço de objetos e representações de locais em dois espaços de objetos diferentes, o neocórtex pode usar células de grade e células de deslocamento para aprender a estrutura dos objetos e gerar comportamentos para manipular esses objetos.

A existência de células de grade no córtex entorrinal está be m documentada. Propomos que eles também existam em todas as regiões do neocórtex. A existência de células de deslocamento é uma previsão introduzida neste artigo. Propomos que as células de deslocamento também estejam presentes em todas as regiões do neocórtex. Dado o seu papel complementar às células da grade, é possível que as células de deslocamento também estejam presentes no complexo do hipocampo.

Comportamentos de objetos

Os objetos podem exibir comportamentos. Por exemplo, considere o grampeador da Figura 4. A parte superior do grampeador pode ser levantada e girada. Esta ação altera a morfologia do grampeador, mas não a sua identidade. Não percebemos o grampeador aberto e fechado como dois objetos diferentes, embora a forma geral tenha mudado. O movimento de uma parte de um objeto em relação a outras partes de um objeto é um " comportamento" do objeto. Os comportamentos de um objeto podem ser aprendidos e, portanto, devem ser representados no tecido neural das colunas corticais. Podemos representar comportamentos em uma estrutura baseada em localização, novamente usando vetores de deslocamento. A metade superior e a metade inferior do grampeador são dois componentes do grampeador. A posição relativa da parte superior e inferior é representada por um vetor de deslocamento da mesma forma que a posição relativa do logotipo e da xícara de café. No entanto, ao contrário do logótipo na chávena de café, as duas metades do agrafador podem mover-se uma em relação à outra. À medida que a parte superior do grampeador gira para cima, o deslocamento da parte superior do grampeador para a parte inferior muda. Assim, a rotação do topo do grampeador é representada por uma sequência de vetores de deslocamento. Ao aprender esta sequência, o sistema terá aprendido este comportamento do objeto.

Abrir e fechar o grampeador são comportamentos diferentes, mas são compostos pelos mesmos elementos de deslocamento, apenas na ordem inversa. Às vezes, elas são chamadas de sequências de "ordem superior". Anteriormente, descrevemos um mecanismo neural para aprender sequências de alta ordem em uma camada de neurônios (Hawkins e Ahmad, 2016). Este mecanismo, se aplicado aos módulos de deslocamento, permitiria a aprendizagem, inferência e recordação de sequências comportamentais complexas de objetos.

Processamento "O quê" e "Onde"

O processamento sensorial ocorre em dois conjuntos paralelos de regiões neocorticais, muitas vezes referidas como vias "o quê" e " onde". Na visão, os danos na via "o quê", ou ventral, estão associados à perda da capacidade de reconhecer objetos visualmente, enquanto os danos na via "onde", ou dorsal, estão associados à perda da capacidade de alcançar um objeto, mesmo que tenha sido identificado visualmente. Caminhos equivalentes de "o quê" e "onde" foram observados em outras modalidades sensoriais, portanto, parece ser o princípio geral da organização cortical (Goodale e Milner, 1992; Ungerleider e Haxby, 1994; Rauschecker, 2015). As regiões corticais "o quê" e "onde" têm anatomia semelhante e, portanto, podemos assumir que operam com princípios semelhantes.

Uma estrutura baseada em localização para a função cortical é aplicável tanto ao processamento "o quê" quanto ao "onde". Resumidamente, propomos que a principal diferença entre regiões "o quê" e regiões "onde" é que nas regiões "o que" as células da grade cortical representam locais que são alocêntricos, no espaço de localização dos objetos, e nas regiões "onde" as células da grade cortical representam locais que são egocêntricos, no espaço de localização do corpo. A Figura 5 mostra como um vetor de deslocamento representando movimento poderia ser gerado em regiões "o quê" e "onde". O funcionamento básico, comum a todos, é que uma região atende primeiro um local e depois um segundo local. As células de deslocamento determinarão o vetor de movimento necessário para passar do primeiro local para o segundo local. Em uma região "o quê", Figura 5C, as duas localizações estão no espaço de um objeto, portanto, o vetor deslocamento representará o movimento necessário para mover o dedo da primeira localização no objeto para a segunda localização no objeto. Neste exemplo, a região "o quê" precisa saber onde o dedo está em relação à xícara, mas não precisa saber onde a xícara ou o dedo está em relação ao corpo. Numa região "onde", Figura 5B, as duas localizações estão no espaço do corpo, portanto, o vetor de deslocamento representará como passar de uma localização egocêntrica para uma segunda localização egocêntrica. A região " onde" pode realizar este cálculo sem saber qual objeto pode ou não estar no segundo local. Uma discussão mais detalhada do processamento em regiões "onde" está além do escopo deste artigo. Nós apenas

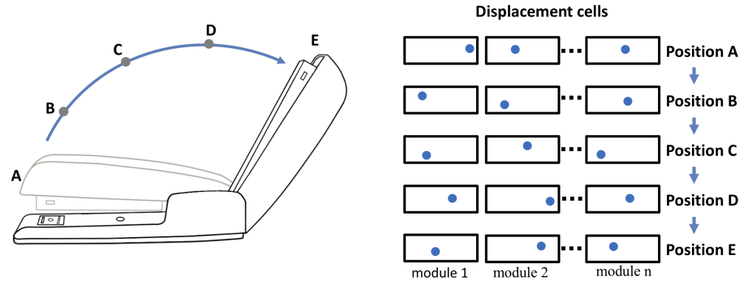


FIGURE 4 | Representing behaviors of objects. Objects have "behaviors," they can change their shape and features over time. The neocortex can learn these changes, but how? For example, a stapler has several behaviors, one is rotating the top relative to the base. If the top of the stapler is a component object of the stapler, with its own location space, then its position relative to the stapler base is represented by a displacement vector as illustrated in **Figure 3**. (The top and base of the stapler are analogous to the logo and the cup. Unlike the logo on the cup, the location of the stapler top relative to the base can change.) The closed position is represented by displacement A and the fully open position is represented by displacement E. As the stapler top hinges from the closed to open position, the displacement vector will continually change. (Five positions, A to E, and corresponding displacement vectors are shown.) To learn this behavior, the neocortex only needs to learn the sequence of displacement vectors as the top rotates.

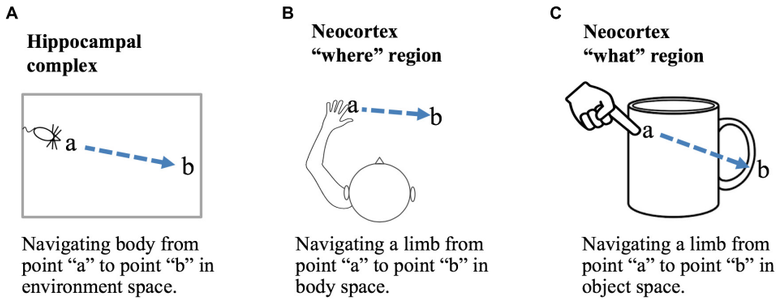


FIGURE 5 | Location processing in different areas of the brain. Grid cells and displacement cells (see text) can be applied to different tasks in different areas of the brain. **(A)** If grid cell modules in the hippocampal complex are anchored by cues in an environment, then grid cell activation patterns will represent locations relative to that environment. Given two locations, **a** and **b**, displacement cells will calculate the movement vector needed to move the body from point **a** to point **b**. **(B)** If cortical grid cell modules are anchored relative to the body, then they will represent locations in body space. Given two locations, displacement cells will calculate the movement vector needed to move a body part from its current location to a desired new location relative to the body. **(C)** If cortical grid cell modules are anchored by cues relative to an object, then they will represent locations in the object's space. Displacement cells will calculate the movement vector needed to move a limb or sensory organ from its current location to a new location relative to the object. Operations performed in **(B,C)** are associated with "where" and "what" regions in the neocortex.

want to point out that it is possible to understand both "what" and "where" processing using similar mechanisms by assuming different location spaces.

Rethinking Hierarchy, the Thousand Brains Theory of Intelligence

Regions of the neocortex are organized in a hierarchy (Felleman and Van Essen, 1991; Riesenhuber and Poggio, 1999; Markov et al., 2014). It is commonly believed that when sensory input enters the neocortex the first region detects simple features. The output of this region is passed to a second region that combines simple features into more complex features. This process is repeated until, several levels up in the hierarchy, cells respond to complete objects (**Figure 6A**). This view of the neocortex as a hierarchy of feature extractors also underlies many artificial neural networks (LeCun et al., 2015).

We propose that cortical columns are more powerful than currently believed. Every cortical column learns models of complete objects. They achieve this by combining input with a grid cell-derived location, and then integrating over movements (see Hawkins et al., 2017; Lewis et al., 2018 for details). This suggests a modified interpretation of the cortical hierarchy, where complete models of objects are learned at every hierarchical level, and every region contains multiple models of objects (**Figure 6B**).

Feedforward and feedback projections between regions typically connect to multiple levels of the hierarchy (only one level of connection is shown in **Figure 6**). For example, the retina projects to thalamic relay cells in LGN, which then project to cortical regions V1, V2, and V4, not just V1. This form of

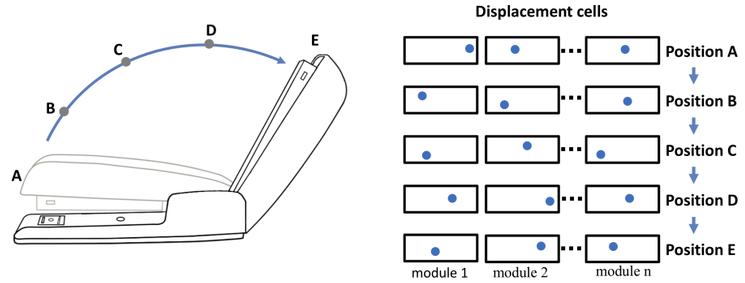


FIGURA **4 |** Representando comportamentos de objetos. Os objetos têm "comportamentos", eles podem mudar sua forma e características ao longo do tempo. O neocórtex pode aprender essas mudanças, mas como? Por exemplo, um grampeador tem vários comportamentos, um deles é girar a parte superior em relação à base. Se a parte superior do grampeador for um objeto componente do grampeador, com seu próprio espaço de localização, então sua posição em relação à base do grampeador é representada por um vetor de deslocamento, conforme ilustrado na Figura 3. (A parte superior e a base do grampeador são análogas ao logotipo e ao copo. Ao contrário do logotipo no copo, a localização da parte superior do grampeador em relação à base pode mudar.) A posição fechada é representada pelo deslocamento A e a posição totalmente aberta é representada pelo deslocamento E. À medida que a parte superior do grampeador gira de fechado para aberto posição, o vetor de deslocamento mudará continuamente. (São mostradas cinco posições, de A a E, e os vetores de deslocamento correspondentes.) Para aprender esse comportamento, o neocórtex só precisa aprender a sequência de vetores de deslocamento à medida que o topo gira.

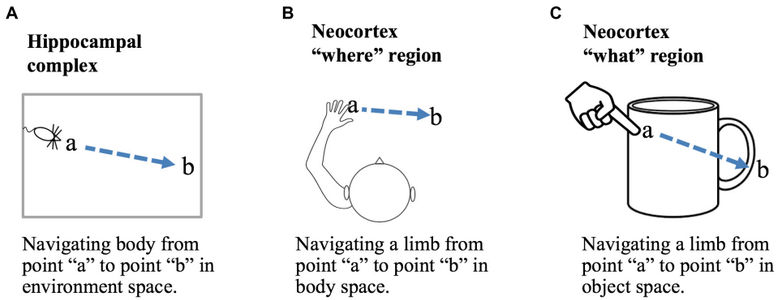


FIGURA **5 |** Processamento de localização em diferentes áreas do cérebro. As células de grade e as células de deslocamento (ver texto) podem ser aplicadas a diferentes tarefas em diferentes áreas do cérebro. (A) Se os módulos de células da grade no complexo do hipocampo forem ancorados por sinais em um ambiente, então os padrões de ativação das células da grade representarão locais relativos a esse ambiente. Dadas duas localizações, aeb, as células de deslocamento calcularão o vetor de movimento necessário para mover o corpo do ponto a ao ponto b. (B) Se os módulos de células da grade cortical estiverem ancorados em relação ao corpo, então eles representarão localizações no espaço corporal. Dadas duas localizações, as células de deslocamento calcularão o vetor de movimento necessário para mover uma parte do corpo de sua localização atual para uma nova localização desejada em relação ao corpo. (C) Se os módulos de células da grade cortical forem ancorados por pistas relativas a um objeto, então eles representarão localizações no espaço do objeto. As células de deslocamento calcularão o vetor de movimento necessário para mover um membro ou órgão sensorial de sua localização atual para uma nova localização em relação ao objeto. As operações realizadas em (B,C) estão associadas às regiões "onde" e "o quê" do neocórtex.

quero ressaltar que é possível entender o processamento de "o q uê" e "onde" usando mecanismos semelhantes, assumindo diferentes espaços de localização.

Repensando a Hierarquia, a Teoria da Inteligência dos Mil Cérebros

As regiões do neocórtex são organizadas em uma hierarquia (Felleman e Van Essen, 1991; Riesenhuber e Poggio, 1999; Markov et al., 2014). Acredita-se comumente que quando a entrada sensorial entra no neocórtex, a primeira região detecta características simples. A saída desta região é passada para uma segunda região que combina recursos simples em recursos mais complexos. Este processo é repetido até que, vários níveis acima na hierarquia, as células respondam a objetos completos (Figura 6A). Esta visão do neocórtex como uma hierarquia de extratores de recursos também está subjacente a muitas redes neurais artificiais (LeCun et al., 2015).

Propomos que as colunas corticais são mais poderosas do que se acredita atualmente. Cada coluna cortical aprende modelos de objetos completos. Eles conseguem isso combinando a entrada c om uma localização derivada de células da grade e, em seguida, integrando os movimentos (ver Hawkins et al., 2017; Lewis et al., 2018 para detalhes). Isto sugere uma interpretação modificada da hierarquia cortical, onde modelos completos de objetos são aprendidos em todos os níveis hierárquicos, e cada região contém múltiplos modelos de objetos (Figura 6B).

As projeções de feedforward e feedback entre regiões normalmente se conectam a vários níveis da hierarquia (apenas um nível de conexão é mostrado na Figura 6). Por exemplo, a retina projeta células totálamicas no LGN, que então se projetam para as regiões corticais V1, V2 e V4, e não apenas para V1. Esta forma de

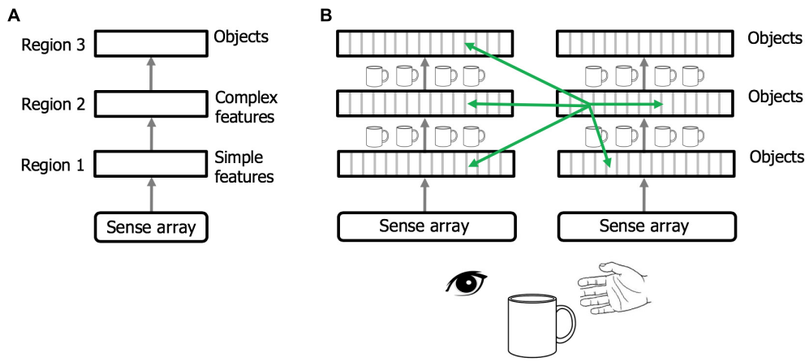


FIGURE 6 | Rethinking cortical hierarchy. **(A)** Commonly held view of cortical hierarchy. Sensory input is processed in a hierarchy of cortical regions. The first region detects simple features. The next region combines simple features into more complex features. This is repeated until a region at the top of the hierarchy forms representations of complete objects. **(B)** Modified view of cortical hierarchy. Every column in every region learns complete models of objects. (Columns learn complete models by combining sensory input with an object-centric location of that input and integrating over movements of the sensor.). Shown are two sensory hierarchies, one for vision and one for touch, both sensing the same object, a cup. There are multiple models of an object within each region, in different regions within a sensory modality, and in different sensory modalities. Although there are many models of the same object (suggested by the small cup images), the models are not identical, as each model is learned via a different subset of the sensory arrays. The green arrows denote the numerically-large cortical-cortical connections that are not hierarchical in nature. The non-hierarchical connections project within the region of origin, across hierarchical levels, across modalities, and between hemispheres. Typically, many columns will be simultaneously observing the same object. The non-hierarchical connections between columns allow them to rapidly infer the correct object (see text). Although learning objects requires movement of the sensors, inference often occurs without movement due to the non-hierarchical connections.

"level skipping" is the rule, not the exception. Therefore, V1 and V2 are both, to some extent, operating on retinal input. The connections from LGN to V2 are more divergent suggesting that V2 is learning models at a different spatial scale than V1. We predict that the spatial scale of cortical grid cells in V2 will similarly be larger than those in V1. The level of convergence of input to a region, paired with the spatial scale of its grid cells, determines the range of object sizes the region can learn. For example, imagine recognizing printed letters of the alphabet. Letters at the smallest discernable size will be recognized in V1 and only V1. The direct input to V2 will lack the feature resolution needed. However, larger printed letters would be recognized in both V1 and V2, and even larger letters may be too large for V1 but recognizable in V2. Hierarchical processing still occurs. All we are proposing is that when a region such as V1 passes information to another region such as V2, it is not passing representations of unclassified features but, if it can, it passes representations of complete objects. This would be difficult to observe empirically if objects are represented by population codes as proposed in Hawkins et al. (2017). Individual neurons would participate in many different object representations and if observed in isolation will appear to represent sensory features, not objects. The number of objects that a cortical column can learn is large but limited (Hawkins et al., 2017). Not every column can learn every object. Analysis of system capacity requires a more thorough understanding of hierarchical flow and is beyond the scope of this paper.

There are many cortical-cortical projections that are inconsistent with pure hierarchical processing (**Figure 6B**, green arrows). For example, there are long range projections between regions in the left and right hemispheres (Clarke and Zaidel, 1994), and there are numerous connections between regions in different sensory modalities, even at the lowest levels of the hierarchy (Schroeder and Foxe, 2005; Driver and Noesselt, 2008; Suter and Shepherd, 2015). These connections may not be hierarchical as their axons terminate on cells located outside of cellular layers associated with feedforward or feedback input. It has been estimated that 40% of all possible region-to-region connections actually exist which is much larger than a pure hierarchy would suggest (Felleman and Van Essen, 1991). What is the purpose of these long-range non-hierarchical connections? In Hawkins et al. (2017) we proposed that cell activity in some layers (e.g., L4 and L6) of a column changes with each new sensation, whereas, cell activity in other layers (e.g., L2/3), representing the observed "object," are stable over changing input. We showed how long-range associative connections in the "object" layer allow multiple columns to vote on what object they are currently observing. For example, if we see and touch a coffee cup there will be many columns simultaneously observing different parts of the cup. These columns will be in multiple levels of both the visual and somatosensory hierarchies. Every one of these columns has a unique sensory input and a unique location, and therefore, long-range connections between the cells representing location and input do not make sense. However, if the columns are observing the same object, then connections between cells in the object layer allow the columns to rapidly settle on the correct object. Thus, non-hierarchical connections between any two regions, even primary and secondary sensory regions in different sensory modalities, make sense if the two regions often observe

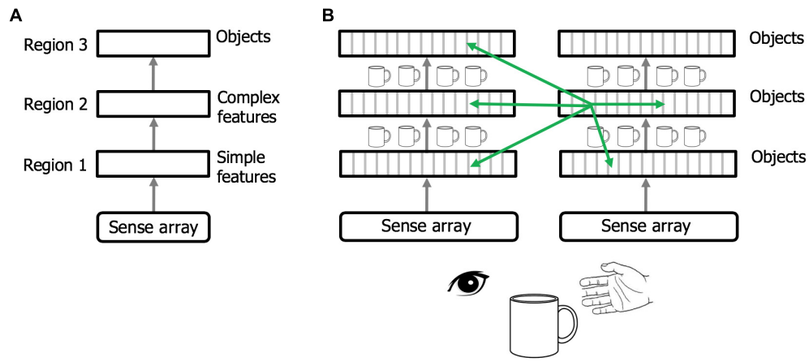


FIGURA **6 |** Repensando a hierarquia cortical. (A) Visão comum da hierarquia cortical. A entrada sensorial é processada em uma hierarquia de regiões corticais. A primeira região detecta recursos simples. A próxima região combina recursos simples em recursos mais complexos. Isto é repetido até que uma região no topo da hierarquia forme representações de objetos completos. (B) Visão modificada da hierarquia cortical. Cada coluna em cada região aprende modelos completos de objetos. (As colunas aprendem modelos completos combinando a entrada sensorial com uma localização centrada no objeto dessa entrada e integrando os movimentos do sensor.). São mostradas duas hierarquias sensoriais, uma para visão e outra para tato, ambas sentindo o mesmo objeto, uma xícara. Existem vários modelos de um objeto dentro de cada região, em diferentes regiões dentro de uma modalidade sensorial e em diferentes modalidades sensoriais. Embora existam muitos modelos do mesmo objeto (sugeridos pelas pequenas imagens do copo), os modelos não são idênticos, pois cada modelo é aprendido através de um subconjunto diferente de matrizes sensoriais. As setas verdes denotam as conexões cortical-corticais numericamente grandes que não são de natureza hierárquica. As ligações não hierárquicas projectam-se dentro da região de origem, através de níveis hierárquicos, através de modalidades e entre hemisférios. Normalmente, muitas colunas observarão simultaneamente o mesmo objeto. As conexões não hierárquicas entre colunas permitem inferir rapidamente o objeto correto (ver texto). Embora os objetos de aprendizagem exijam movimento dos sensores, a inferência geralmente ocorre sem movimento devido às conexões não hierárquicas.

"pular nível" é a regra, não a exceção. Portanto, V1 e V2 estão ambos, até certo ponto, operando com base na retina. As conexões de LGN para V2 são mais divergentes, sugerindo que V2 está aprendendo modelos em uma escala espacial diferente de V1. Prevemos que a escala espacial das células da grade cortical em V2 será similarmente maior que as de V1. O nível de convergência de entrada para uma região, emparelhado com a escala espacial de suas células da grade, determina a faixa de tamanhos de objetos que a região pode aprender. Por exemplo, imagine reconhecer letras impressas do alfabeto. Letras com o menor tamanho discernível serão reconhecidas em V1 e somente em V1. A entrada direta para V2 não terá a resolução necessária. No entanto, letras impressas maiores seriam reconhecidas tanto em V1 como em V2, e letras ainda maiores podem ser demasiado grandes para V1, mas reconhecíveis em V2. O processamento hierárquico ainda ocorre. Tudo o que estamos propondo é que quando uma região como V1 passa informações para outra região como V2, ela não está passando representações de características não classificadas, mas, se puder, passa representações de objetos completos. Isto seria difícil de observar empiricamente se os objetos fossem representados por códigos populacionais conforme proposto em Hawkins et al. (2017). Neurônios individuais participariam de muitas representações de objetos diferentes e, se observados isoladamente, pareceriam representar características sensoriais, não objetos. O número de objetos que uma coluna cortical pode aprender é grande, mas limitado (Hawkins et al., 2017). Nem todas as colunas podem aprender todos os objetos. A análise da capacidade do sistema requer uma compreensão mais completa do fluxo hierárquico e está além do escopo deste artigo.

Existem muitas projeções córtico-corticais que são inconsistentes com o processamento hierárquico puro (Figura 6B, setas verdes). Por exemplo, existem projeções de longo alcance entre regiões nos hemisférios esquerdo e direito (Clarke e Zaidel, 1994), e existem inúmeras conexões entre regiões em diferentes modalidades sensoriais, mesmo nos níveis mais baixos da hierarquia (Schroeder e Foxe, 2005; Driver e Noeselt, 2008; Suter e Shepherd, 2015). Essas conexões podem não ser hierárquicas, pois seus axônios terminam em células localizadas fora das camadas celulares associadas à entrada de feedforward ou feedback. Foi estimado que 40% de todas as ligações possíveis entre regiões existem, o que é muito maior do que uma hierarquia pura poderia sugerir (Felleman e Van Essen, 1991). Qual é o propósito dessas conexões não hierárquicas de longo alcance? Em Hawkins et al. (2017) propusemos que a atividade celular em algumas camadas (por exemplo, L4 e L6) de uma coluna muda com cada nova sensação, enquanto a atividade celular em outras camadas (por exemplo, L2/3), representando o "objeto" observado, é estável em relação à mudança de entrada. Mostramos como as conexões associativas de longo alcance na camada "objeto" permitem que múltiplas colunas votem em qual objeto estão observando no momento. Por exemplo, se virmos e tocarmos uma xícara de café, haverá muitas colunas observando simultaneamente diferentes partes da xícara. Essas colunas estarão em vários níveis das hierarquias visual e somatossensorial. Cada uma dessas colunas possui uma entrada sensorial única e uma localização única e, portanto, conexões de longo alcance entre as células que representam a localização e a entrada não fazem sentido. No entanto, se as colunas estiverem observando o mesmo objeto, as conexões entre as células na camada do objeto permitirão que as colunas se estabeleçam rapidamente no objeto correto. Assim, conexões não hierárquicas entre quaisquer duas regiões, mesmo regiões sensoriais primárias e secundárias em diferentes modalidades sensoriais, fazem sentido se as duas regiões frequentemente observam

the same object at the same time (see Hawkins et al., 2017 for details).

One of the classic questions about perception is how does the neocortex fuse different sensory inputs into a unified model of a perceived object. We propose that the neocortex implements a decentralized model of sensor fusion. For example, there is no single model of a coffee cup that includes what a cup feels like and looks like. Instead there are 100s of models of a cup. Each model is based on a unique subset of sensory input within different sensory modalities. There will be multiple models based on visual input and multiple models based on somatosensory input. Each model can infer the cup on its own by observing input over movements of its associated sensors. However, long-range non-hierarchical connections allow the models to rapidly reach a consensus of the identity of the underlying object, often in a single sensation.

Just because each region learns complete models of objects does not preclude hierarchical flow. The main idea is that the neocortex has 100s, likely 1000s, of models of each object in the world. The integration of observed features does not just occur at the top of the hierarchy, it occurs in every column at all levels of the hierarchy. We call this "The Thousand Brains Theory of Intelligence."

DISCUSSION

Crick (1979) wrote an essay titled, "Thinking about the Brain." In it he wrote, "In spite of the steady accumulation of detailed knowledge, how the human brain works is still profoundly mysterious." He posited that over the coming years we would undoubtedly accumulate much more data about the brain, but it may not matter, as "our entire way of thinking about such problems may be incorrect." He concluded that we lacked a "theoretical framework," a framework in which we can interpret experimental findings and to which detailed theories can be applied. Nearly 40 years after Crick wrote his essay, his observations are still largely valid.

Arguably, the most progress we have made toward establishing a theoretical framework is based on the discovery of place cells and grid cells in the hippocampal complex. These discoveries have suggested a framework for how animals learn maps of environments, and how they navigate through the world using these maps. The success of this framework has led to an explosion of interest in studying the entorhinal cortex and hippocampus.

In this paper we are proposing a theoretical framework for understanding the neocortex. Our proposed cortical framework is a derivative of the framework established by grid cells and place cells. Mechanisms that evolved for learning the structure of environments are now applied to learning the structure of objects. Mechanisms that evolved for tracking the location of an animal in its environments are now applied to tracking the location of limbs and sensory organs relative to objects in the world. How far this analogy can be taken is uncertain. Within the circuits formed by the hippocampus, subiculum, and entorhinal cortex are grid cells (Hafting et al., 2005), place cells (O'Keefe and Dostrovsky, 1971; O'Keefe and Burgess, 2005), head direction cells (Taube et al., 1990; Giocomo et al., 2014; Winter et al., 2015), border cells (Lever et al., 2009), object vector cells (Deshmukh and Knierim, 2013), and others, plus many conjunctive cells that exhibit properties that are combinations of these (Sargolini et al., 2006; Brandon et al., 2011; Stensola et al., 2012; Hardcastle et al., 2017). We are currently exploring the idea that the neocortex contains cells that perform equivalent functions to the variety of cells found in the hippocampal complex. The properties of these cells would only be detectable in an awake animal actively sensing learned objects. The recent work of Long and Zhang (2018) suggests this might be true.

Orientation

In the entorhinal cortex, and elsewhere in the brain, are found head direction cells (Taube et al., 1990; Sargolini et al., 2006; Brandon et al., 2011; Giocomo et al., 2014; Winter et al., 2015; Raudies et al., 2016). These cells represent the allocentric orientation of an animal relative to its environment. Inferring where you are via sensation, predicting what you will sense after moving, and determining how to move to get to a new location all require knowing your current orientation relative to your environment. In the models reviewed in Hasselmo (2009) and Hasselmo et al. (2010) head direction cells are critical for accurately transitioning between spatial locations. The same need for orientation exists throughout the neocortex. For example, knowing that a finger is at a particular location on a coffee cup is not sufficient. The finger also has an orientation relative to the cup (which way it is rotated and its angle at contact). Predicting what the finger will sense when it contacts the cup or what movement is required to reach a new location on the cup requires knowing the finger's orientation relative to the cup in addition to its location. Therefore, we predict that within each cortical column there will be a representation of orientation that performs an analogous function to head direction cells in the hippocampal complex. How orientation is represented in the cortex is unknown. There could be a set of orientation cells each with a preferred orientation, similar to head direction cells, but we are not aware of any evidence for this. Alternately, orientation could be represented via a population code, which would be more difficult to detect. For example, in somatosensory regions orientation could be represented by activating a sparse subset of egocentric orientation detectors (Hsiao et al., 2002; Bensmaia et al., 2008; Pruszynski and Johansson, 2014). How orientation is represented and interacts with cortical grid cells and displacement cells is largely unknown. It is an area we are actively studying.

Prediction

A long standing principle behind many theories of cortical function is prediction (Lashley, 1951; Rao and Ballard, 1999; Hawkins and Blakeslee, 2004; Lotter et al., 2018). By representing the location of a sensor, a cortical column can associate sensory information within the location space of each object, similar to the way place cells associate sensory information with locations (O'Keefe and Nadel, 1978; Komorowski et al., 2009). This enables a column to build powerful predictive models. For example, when moving your finger from the bottom of a cup to the top, it can predict the sensation regardless of how the cup is rotated

o mesmo objeto ao mesmo tempo (ver Hawkins et al., 2017 para detalhes).

Uma das questões clássicas sobre a percepção é como o neocórtex funde diferentes estímulos sensoriais em um modelo unificado de um objeto percebido. Propomos que o neocórtex implemente um modelo descentralizado de fusão de sensores. Por exemplo, não existe um modelo único de xícara de café que inclua a sensação e a aparência de uma xícara. Em vez disso, existem centenas de modelos de xícara. Cada modelo é baseado em um subconjunto único de informações sensoriais em diferentes modalidades sensoriais. Haverá vários modelos baseados em informações visuais e vários modelos baseados em informações somatossensoriais. Cada modelo pode inferir o copo por si só, observando as informações sobre os movimentos dos sensores associados. No entanto, conexões não hierárquicas de longo alcance permitem que os modelos cheguem rapidamente a um consenso sobre a identidade do objeto subjacente, muitas vezes numa única sensação.

Só porque cada região aprende modelos completos de objetos não impede o fluxo hierárquico. A ideia principal é que o neocórtex possui centenas, provavelmente milhares, de modelos de cada objeto no mundo. A integração dos recursos observados não ocorre apenas no topo da hierarquia, ela ocorre em todas as colunas e em todos os níveis da hierarquia. Chamamos isso de " Teoria da Inteligência dos Mil Cérebros".

DISCUSSÃO

Crick (1979) escreveu um ensaio intitulado "Pensando sobre o Cérebro". Nele ele escreveu: "Apesar do acúmulo constante de conhecimento detalhado, o funcionamento do cérebro humano ainda é profundamente misterioso". Ele postulou que nos próximos anos acumularíamos, sem dúvida, muito mais dados sobre o cérebro, mas isso pode não importar, pois "toda a nossa maneira de pensar sobre esses problemas pode estar incorreta". Ele concluiu que nos faltava um "quadro teórico", um quadro no qual pudéssemos interpretar resultados experimentais e ao qual teorias detalhadas pudessem ser aplicadas. Quase 40 anos depois de Crick ter escrito seu ensaio, suas observações ainda são em grande parte válidas.

Indiscutivelmente, o maior progresso que fizemos no estabelecimento de uma estrutura teórica baseia-se na descoberta de células locais e células de grade no complexo do hipocampo. Estas descobertas sugeriram uma estrutura para a forma como os animais aprendem mapas de ambientes e como navegam pelo mundo utilizando esses mapas. O sucesso desta estrutura levou a uma explosão de interesse no estudo do córtex entorrinal e do hipocampo.

Neste artigo estamos propondo uma estrutura teórica para a compreensão do neocórtex. Nossa estrutura cortical proposta é u m derivado da estrutura estabelecida pelas células da grade e pelas células locais. Os mecanismos que evoluíram para aprender a estrutura dos ambientes são agora aplicados à aprendizagem da estrutura dos objetos. Os mecanismos que evoluíram para rastrear a localização de um animal em seus ambientes são agora aplicados para rastrear a localização de membros e órgãos sensoriais em relação a objetos no mundo. Até onde esta analogia pode ser l evada é incerto. Dentro dos circuitos formados pelo hipocampo, subículo e córtex entorrinal estão células de grade (Hafting et al., 2005), células de lugar (O'Keefe e Dostrovsky, 1971; O'Keefe e Burgess, 2005), células de direção da cabeça (Taube et al., 1990; Giocomo et al., 2014; Winter et al., 2015), células de borda (Lever et al., 2009), células de vetor objeto (Deshmukh e Knierim, 2013) e outras, além de muitas células conjuntivas que exibem propriedades que são combinações destas (Sargolini et al., 2006; Brandon et al., 2011; Stensola et al., 2012; Hardcastle et al., 2017). Atualmente estamos explorando a ideia de que o neocórtex contém células que desempenham funções equivalentes à variedade de células encontradas no complexo do hipocampo. As propriedades dessas células só seriam detectáveis em um animal acordado, sentindo ativamente objetos aprendidos. O trabalho recente de Long e Zhang (2018) sugere que isto pode ser verdade.

Orientação

No córtex entorrinal, e em outras partes do cérebro, são encontradas células de direção da cabeça (Taube et al., 1990; Sargolini et al., 2006; Brandon et al., 2011; Giocomo et al., 2014; Winter et al., 2015; Raudies et al., 2016). Essas células representa m a orientação alocêntrica de um animal em relação ao seu ambiente. Inferir onde você está por meio da sensação, prever o que sentirá após se mover e determinar como se mover para chegar a um novo local, tudo isso exige conhecer sua orientação atual em relação ao ambiente. Nos modelos revisados em Hasselmo (2009) e Hasselmo et al. (2010) as células de direção da cabeça são críticas para a transição precisa entre localizações espaciais. A mesma necessidade de orientação existe em todo o neocórtex. Por exemplo, saber que um dedo está num local específico de uma xícara de café não é suficiente. O dedo também tem uma orientação em relação ao copo (para que lado ele é girado e seu ângulo de contato). Prever o que o dedo sentirá quando entrar em contato com o copo ou que movimento será necessário para alcançar um novo local no copo requer o conhecimento da orientação do dedo em relação ao copo, além de sua localização. Portanto, prevemos que dentro de cada coluna cortical haverá uma representação de orientação que dese mpenha uma função análoga às células de direção da cabeça no complexo do hipocampo. Não se sabe como a orientação é representada no córtex. Poderia haver um conjunto de células de orientação, cada uma com uma orientação preferida, semelhante às células de direção da cabeça, mas não temos conhecimento de nenhuma evidência disso. Alternativamente, a orientação poderia ser representada através de um código populacional, que seria mais difícil de detectar. Por exemplo, em regiões s omatossensoriais a orientação poderia ser representada pela ativação de um subconjunto esparso de detectores de orientação egocêntrica (Hsiao et al., 2002; Bensmaia et al., 2008; Pruszynski e Johansson, 2014). Como a orientação é representada e interage com as células da grade cortical e com as células de deslocamento é amplamente desconhecida. É uma área que estamos estudando ativamente.

Previsão

Um princípio de longa data por trás de muitas teorias da função cortical é a previsão (Lashley, 1951; Rao e Ballard, 1999; Hawkins e Blakeslee, 2004; Lotter et al., 2018). Ao representar a localização de um sensor, uma coluna cortical pode associar informações sensoriais dentro do espaço de localização de cada objeto, semelhante à forma como as células locais associam informações sensoriais a locais (O'Keefe e Nadel, 1978; Komorowski et al., 2009). Isso permite que uma coluna construa modelos preditivos poderosos. Por exemplo, ao mover o dedo do fundo para o topo de um copo, ele pode prever a sensação, independentemente de co mo o copo é girado.

with respect to the sensor. Representing composite objects using displacement cells enables a column to generalize and predict sensations even when encountering a novel object. For example, suppose we see a cup with a familiar logo (**Figure 3A**) and that portions of the logo are obscured. Once a column has recognized the logo and the cup, it can make predictions regarding the entire logo in relation to the cup even if that combined object is new. Building such predictive models would be much harder without an explicit representation of location. In previous papers we proposed dendritic mechanisms that could serve as the neural basis for predictive networks (Hawkins and Ahmad, 2016; Hawkins et al., 2017). Overall, prediction underlies much of the framework discussed in this paper.

Attention

One of the key elements of a location-based framework for cortical processing is the ability of an area of cortex to rapidly switch between object spaces. To learn there is a logo on the coffee cup we need to alternate our attention between the cup and the logo. With each shift of attention, the cortical grid cells re-anchor to the location space of the newly attended object. This shift to a new object space is necessary to represent the displacement between two objects, such as the logo and the cup. It is normal to continuously shift our attention between the objects around us. With each newly attended object the cortical grid cells re-anchor in the space of the new object, and displacement cells represent where the new object is relative to the previously attended object. Changing attention is intimately tied to movement of the sensor, re-anchoring of grid cells, and, as widely believed, feedback signals to the thalamus (Crick, 1984; McAlonan et al., 2006), presumably to select a subset of input for processing. How these elements work together is poorly understood and represents an area for further study.

Uniqueness of Location Code

Our proposal is based on the idea that a set of grid cell modules can encode a very large number of unique locations. There are some observations that suggest that grid cells, on their own, may not be capable of forming enough unique codes. For example, because each grid cell exhibits activity over a fairly large area of physical space (Hafting et al., 2005), the activation of the cells in a grid cell module is not very sparse. Sparsity is helpful for creating easily discernable unique codes. The lack of sparsity can be overcome by sampling the activity over more grid cell modules, but not enough is known about the size of grid cell modules and how many can be realistically sampled (Gu et al., 2018) have shown that grid cell modules are composed of smaller sub-units that activate independently, which would also increase the representation capacity of grid cells. Another factor impacting capacity is conjunctive cells. In the entorhinal cortex there are more conjunctive cells than pure grid cells. Conjunctive cells exhibit some combination of "gridness" plus orientation and/or other factors (Sargolini et al., 2006). Conjunctive cells may have a sparser activation than pure grid cells and therefore would be a better basis for forming a set of unique location codes. If the neocortex has cells similar to conjunctive cells, they also might play a role in location coding. Not enough is known about how grid cells, orientation cells, and conjunctive cells work together to suggest exactly how locations are encoded in the neocortex. As we learn more about location coding in the neocortex, it is important to keep these possibilities in mind.

Where Are Grid Cells and Displacement Cells in the Neocortex?

The neocortex is commonly divided into six layers that run parallel to the surface. There are dozens of different cell types, therefore, each layer contains multiple cell types. Several lines of evidence suggest that cortical grid cells are located in L6 [specifically L6 cortical-cortical neurons (Thomson, 2010)] and displacement cells are located in L5 (specifically L5 thick-tufted neurons) (**Figure 7**).

One piece of evidence suggesting cortical grid cells are in L6 is the unusual connectivity between L4 and L6. L4 is the primary input layer. However, feed forward input forms less than 10% of the synapses on L4 cells (Ahmed et al., 1994, 1997; Sherman and Guillery, 2013), whereas approximately 45% of the synapses on L4 cells come from L6a cortical-cortical neurons (Ahmed et al., 1994; Binzegger et al., 2004). Similarly, L4 cells make large numbers of synapses onto those same L6 cells (McGuire et al., 1984; Binzegger et al., 2004; Kim et al., 2014). Also, the connections between L6 and L4 are relatively narrow in spread (Binzegger et al., 2004). The narrow connectivity between L6 and L4 is reminiscent of the topologically-aligned bidirectional connectivity between grid cells in MEC and place cells in hippocampus (Rowland et al., 2013; Zhang et al., 2013). We previously showed how the reciprocal connections between L6 and L4 can learn the structure of objects by movement of sensors if L6 represents a location in the space of the object (Lewis et al., 2018). For a column to learn the structure of objects in this fashion requires bidirectional connections between cells receiving sensory input and cells representing location. L6a is the only known set of cells that meet this requirement. Also, grid cells use motor input to update their representations for path integration. Experiments show significant motor projections to L6 (Nelson et al., 2013; Leinweber et al., 2017). The current experimental evidence for the presence of grid cells in the neocortex is unfortunately mute on what cortical layers contain grid cells. It should be possible to experimentally determine this in the near future. Our prediction is they will be in L6.

The main evidence for displacement cells being in L5 is again connectivity. A subset of L5 cells (known as "L5 thick-tufted cells") that, as far as we know exists in all cortical regions, projects sub-cortically to brain regions involved with motor behavior. (For example, L5 cells in the visual cortex project to the superior colliculus which controls eye movements.) These L5 cells are the motor output cells of the neocortex. However, the same L5 cells send a branch of their axon to thalamic relay nuclei, which then project to hierarchically higher cortical regions (Douglas and Martin, 2004; Guillery and Sherman, 2011; Sherman and Guillery, 2011). It is difficult to understand how the same L5 cells can be both the motor output and the feedforward input to other regions. One interpretation put forth by Guillery and Sherman is that L5 cells represent a motor command and that

em relação ao sensor. Representar objetos compostos usando células de deslocamento permite que uma coluna generalize e preveja sensações mesmo ao encontrar um objeto novo. Por exemplo, suponha que vemos um copo com um logotipo familiar (Figura 3A) e que partes do logotipo estão obscurecidas. Depois que uma coluna reconhece o logotipo e a xícara, ela pode fazer previsões sobre todo o logotipo em relação à xícara, mesmo que o objeto combinado seja novo. A construção de tais modelos preditivos seria muito mais difícil sem uma representação explícita da localização. Em artigos anteriores, propusemos mecanismos dendríticos que poderiam servir como base neural para redes preditivas (Hawkins e Ahmad, 2016; Hawkins et al., 2017). No geral, a previsão está subjacente a grande parte do quadro discutido neste artigo.

Atenção

Um dos elementos-chave de uma estrutura baseada em localização para processamento cortical é a capacidade de uma área do córtex alternar rapidamente entre espaços de objetos. Para saber que existe um logotipo na xícara de café, precisamos alternar nossa atenção entre a xícara e o logotipo. A cada mudança de atenção, as células da grade cortical se ancoram novamente no espaço de localização do objeto recentemente atendido. Essa mudança para um novo espaço de objetos é necessária para representar o deslocamento entre dois objetos, como o logotipo e a xícara. É normal mudar continuamente a nossa atenção entre os objetos que nos rodeiam. Com cada objeto recém-atendido, as células da grade cortical se ancoram novamente no espaço do novo objeto, e as células de deslocamento representam onde o novo objeto está em relação ao objeto atendido anteriormente. A mudança de atenção está intimamente ligada ao movimento do sensor, à reancoragem das células da grade e, como se acredita, aos sinais de feedback para o tálamo (Crick, 1984; McAlonan et al., 2006), presumivelmente para selecionar um subconjunto de entrada para processamento. A forma como estes elementos funcionam e m conjunto é pouco compreendida e representa uma área para um estudo mais aprofundado.

Exclusividade do código de localização

Nossa proposta é baseada na ideia de que um conjunto de módulos de células da grade pode codificar um grande número de localizações únicas. Existem algumas observações que sugerem que as células da grade, por si só, podem não ser capazes de f ormar códigos únicos suficientes. Por exemplo, como cada célula da grade exibe atividade em uma área bastante grande do espaço físico (Hafting et al., 2005), a ativação das células em um módulo de células da grade não é muito esparsa. A dispersão é útil para criar códigos exclusivos facilmente discerníveis. A falta de esparsidade pode ser superada amostrando a atividade em mais módulos de células da grade, mas não se sabe o suficiente sobre o tamanho dos módulos das células da grade e quantos podem ser amostrados de forma realista (Gu et al., 2018) mostraram que os módulos das células da grade são compostos de subunidades menores que são ativadas de forma independente, o que também aumentaria a capacidade de representação das células da grade. No córtex entorrinal existem mais células conjuntivas do que células puras da grade. As células conjuntivas exibem alguma combinação de "grade" mais orientação e/ou outros fatores (Sargolini et al., 2006). As células conjuntivas podem ter uma ativação mais esparsa do que as células da grade pura e, portanto, seriam uma base melhor para formar um conjunto de códigos de localização únicos. Se o neocórtex tiver células semelhantes às células conjuntivas, elas também poderão desempenhar um papel na codificação de localização. Não se sabe o suficiente sobre como células de grade, células de orientação e células conjuntivas trabalha m juntas para sugerir exatamente como as localizações são codificadas no neocórtex. À medida que aprendemos mais sobre a codificação de localização no neocórtex, é importante ter em mente essas possibilidades.

Onde estão as células da grade e as células de deslocamento no neocórtex?

O neocórtex é comumente dividido em seis camadas que correm paralelamente à superfície. Existem dezenas de tipos de células diferentes, portanto, cada camada contém vários tipos de células. Várias linhas de evidência sugerem que as células da grade cortical estão localizadas em L6(especificamente neurônios corticais-corticais L6 (Thomson, 2010)] e as células de deslocamento estão localizadas em L5 (especificamente neurônios de tufos grossos L5) (Figura 7).

Uma evidência que sugere que as células da grade cortical estão em L6 é a conectividade incomum entre L4 e L6. L4 é a camada de entrada primária. No entanto, a entrada feed forward forma menos de 10% das sinapses nas células L4 (Ahmed et al., 1994, 1997; Sherman e Guillery, 2013), enquanto aproximadamente 45% das sinapses nas células L4 vêm de neurônios corticais-corticais L6a (Ahmed et al., 1994; Binzegger et al., 2004). Da mesma forma, as células L4 fazem um grande número de sinapses com as mesmas células L6 (McGuire et al., 1984; Binzegger et al., 2004; Kim et al., 2014). Além disso, as conexões entre L6 e L4 são relativamente estreitas (Binzegger et al., 2004). A conectividade estreita entre L6 e L4 lembra a conectividade bidirecional topologicamente alinhada entre as células da grade no MEC e as células do hipocampo (Rowland et al., 2013; Zhang et al., 2013). Mostramos anteriormente como as conexões recíprocas entre L6 e L4 podem aprender a estrutura dos objetos pelo movimento dos sensores se L6 representar uma localização no espaço do objeto (Lewis et al., 2018). Para que uma coluna aprenda a estrutura dos objetos dessa maneira, são necessárias conexões bidirecionais entre as células que recebem informações sensoriais e as células que representam a localização. L6a é o único conjunto conhecido de células que atende a esse requisito. Além disso, as células da grade usam a entrada do motor para atualizar suas representações para integração de caminhos. Os experimentos mostram projeções motoras significativas para L6 (Nelson et al., 2013; Leinweber et al., 2017). A evidência experimental atual da presença de células da grade no neocórtex infelizmente é muda sobre quais camadas corticais contêm células da grade. Deveria ser possível determinar isso experimentalmente em um futuro próximo. Nossa previsão é que eles estarão em L6.

A principal evidência de que as células de deslocamento estão em L5 é novamente a conectividade. Um subconjunto de células L5 (conhecidas como "células L5 de tufos grossos") que, até onde sabe mos, existe em todas as regiões corticais, projeta-se subcorticalmente para regiões cerebrais envolvidas com o comportamento motor. (Por exemplo, as células L5 no córtex visual projetam-se para o colículo superior que controla os movimentos oculares.) Essas células L5 são as células de saída motora do neocórtex. No entanto, as mesmas células L5 enviam um ramo do seu axônio para os núcleos de retransmissão do tálamo, que então se projetam para regiões corticais hierarquicamente superiores (Douglas e Martin, 2004; Guillery e Sherman, 2011; Sherman e Guillery, 2011). É difícil entender como as mesmas células L5 podem ser tanto a saída do motor quanto a entrada de alimentação para outras regiões. Uma interpretação apresentada por Guillery e Sherman é que as células L5 representam um comando motor e que

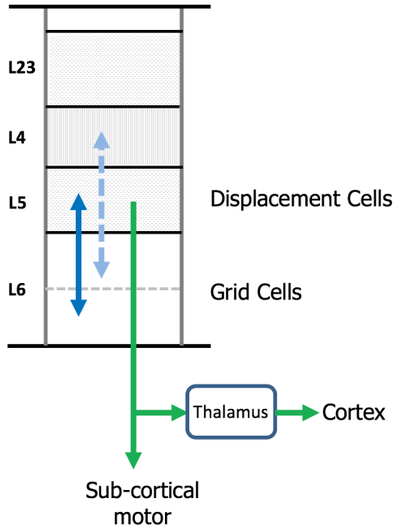


FIGURE 7 | Location of grid cells and displacement cells in the neocortex. The neocortex contains dozens of cell types commonly organized into six cellular layers. Here, we show a simple drawing of a cortical column. We propose cortical grid cells are located in layer 6 and displacement cells are in layer 5. A requirement of our proposal is that cortical grid cells make bi-lateral connections with displacement cells (solid blue line). Another requirement is that, when combined with a representation of orientation, they make bi-lateral connections with cells in layer 4 (dashed blue line). This is how the column predicts the next input into layer 4. Displacement cells match the unusual connectivity of layer 5 "thick tufted" neurons, which are the motor output cells of the neocortex. These neurons send their axon down into the white matter where the axon splits (green arrows). One branch terminates in sub-cortical structures responsible for motor behavior. The second axon branch terminates on relay cells in the thalamus which become the feedforward input to a hierarchically-higher cortical region. As explained in the text, displacement cells can alternate between representing movements and representing the composition of multiple objects. We propose that L5 thick tufted cells alternate between these two functions which aligns with their unusual connectivity.

the feedforward L5 projection can be interpreted as an efference copy of the motor command (Guillery and Sherman, 2002, 2011).

We offer a possible alternate interpretation. The L5 cells in question are displacement cells and they alternately represent movements (sent sub-cortically) and then represent compositional objects (sent to higher regions via thalamic relay cells). As described above, displacement cells will represent a movement vector when comparing two locations in the same space and will represent composite objects when comparing two locations in two different spaces. These two rapidly-changing representations could be disambiguated at their destination either by phase of an oscillatory cycle or by physiological firing patterns (Burgess et al., 2007; Hasselmo, 2008; Hasselmo and Brandon, 2012). Although we are far from having a complete understanding of what the different cellular layers do and how they work together, a location-based framework offers the opportunity of looking anew at the vast body of literature on cortical anatomy and physiology and making progress on this problem.

Location-Based Framework for High-Level Thought and Intelligence

We have described our location-based framework using examples from sensory inference. Given that the anatomy in all cortical regions is remarkably similar, it is highly likely that everything the neocortex does, including language and other forms of high-level thought, will be built upon the same location-based framework. In support of this idea, the current empirical evidence that grid cells exist in the neocortex was collected from humans performing what might be called "cognitive tasks," and it was detected in cortical regions that are far from direct sensory input (Doeller et al., 2010; Jacobs et al., 2013; Constantinescu et al., 2016).

The location-based framework can be applied to physical structures, such as a cup, and to abstract concepts, such as mathematics and language. A cortical column is fundamentally a system for learning predictive models. The models are learned from inputs and movements that lead to changes in the input. Successful models are ones that can predict the next input given the current state and an anticipated movement. However, the "inputs" and "movements" of a cortical column do not have to correspond to physical entities. The "input" to a column can originate from the retina or it can originate from other regions of the neocortex that have already recognized a visual object such as a word or a mathematical expression. A "movement" can represent the movement of the eyes or it can represent an abstract movement, such as a verb or a mathematical operator.

Success in learning a predictive model requires discovering the correct dimensionality of the space of the object, learning how movements update locations in that space, and associating input features with specific locations in the space of the object. These attributes apply to both sensory perception and high-level thought. Imagine a column trying to learn a model of a cup using visual input from the retina and movement input from a finger. This would fail, as the location spaced traversed by the finger would not map onto the feature space of the object as evidenced by the changing inputs from the eyes. Similarly, when trying to understand a mathematical problem you might fail when using one operator to manipulate an equation but succeed by switching to a different operator.

Grid cells in the neocortex suggests that all knowledge is learned and stored in the context of locations and location spaces and that "thinking" is movement through those location spaces. We have a long way to go before we understand the details of how the neocortex performs cognitive functions, however, we believe that the location-based framework will not only be at the core of the solutions to these problems, but will suggest solutions.

CONCLUSION

It is sometimes said that neuroscience is "data rich and theory poor." This notion is especially true for the neocortex. We are not lacking empirical data as much as lacking a theoretical framework

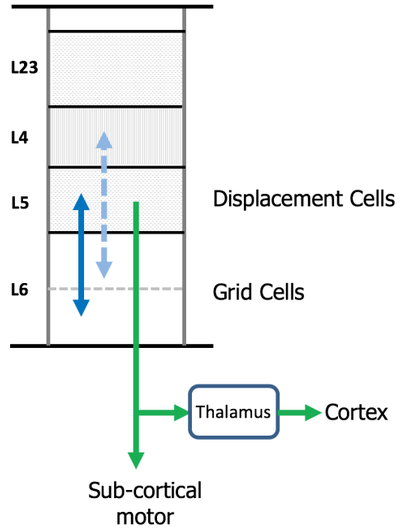


FIGURA **7 |**Localização das células da grade e células de deslocamento no neocórtex. O neocórtex contém dezenas de tipos de células comumente organizadas em seis camadas celulares. Aqui mostramos um desenho simples de uma coluna cortical. Propomos que as células da grade cortical estejam localizadas na camada 6 e as células de deslocamento estejam na camada 5. Um requisito da nossa proposta é que as células da grade cortical façam conexões bilaterais com as células de deslocamento (linha azul sólida). Outro requisito é que, quando combinados com uma representação de orientação, façam conexões bilaterais com células da camada 4 (linha azul tracejada). É assim que a coluna prevê a próxima entrada na camada 4. As células de deslocamento correspondem à conectividade incomum dos neurônios "de tufos grossos" da camada 5, que são as células de saída motora do neocórtex. Esses neurônios enviam seu axônio para a substância branca, onde o axônio se divide (setas verdes). Um ramo termina em estruturas subcorticais responsáveis pelo comportamento motor. O segundo ramo do axônio termina em células retransmissoras no tálamo, que se tornam a entrada de alimentação para uma região cortical hierarquicamente superior. Conforme explicado no texto, as células de deslocamento podem alternar entre representar movimentos e representar a composição de múltiplos objetos. Propomos que células L5 com tufos grossos alterne m entre essas duas funções, o que se alinha com sua conectividade incomum.

a projeção feedforward L5 pode ser interpretada como uma cópia eferente do comando motor (Guillery e Sherman, 2002, 2011).

Oferecemos uma possível interpretação alternativa. As células L5 em questão são células de deslocamento e representam alternadamente movimentos (enviados subcorticalmente) e depois representam objetos de composição (enviados para regiões superiores através de células retransmissoras talâmicas). Conforme descrito acima, as células de deslocamento representarão um vetor de movimento ao comparar dois locais no mesmo espaço e representarão objetos compostos ao comparar dois locais em dois espaços diferentes. Estas duas representações em rápida mudança poderiam ser desambiguadas no seu destino, quer pela fase de um ciclo oscilatório, quer por padrões de disparo fisiológicos (Burgess et al., 2007; Hasselmo, 2008; Hasselmo e Brandon, 2012). Embora estejamos longe de ter uma compreensão completa do que as diferentes camadas celulares fazem e como funcionam em conjunto, uma estrutura baseada na localização oferece a oportunidade de olhar de novo para o vasto corpo de literatura sobre anatomia e fisiologia cortical e fazendo progressos neste problema.

Estrutura Baseada em Localização para Pensamento e Inteligência de Alto Nível

Descrevemos nossa estrutura baseada em localização usando exemplos de inferência sensorial. Dado que a anatomia em todas as regiões corticais é notavelmente semelhante, é altamente provável que tudo o que o neocórtex faz, incluindo a linguagem e outras formas de pensamento de alto nível, seja construído sobre a mesma estrutura baseada na localização. Em apoio a esta ideia, a atual evidência empírica de que existem células de grelha no neocórtex foi recolhida de humanos que realizam o que poderia ser chamado de "tarefas cognitivas", e foi detetada em regiões corticais que estão longe da entrada sensorial direta (Doeller et al., 2010; Jacobs et al., 2013; Constantinescu et al., 2016).

A estrutura baseada em localização pode ser aplicada a estruturas físicas, como uma xícara, e a conceitos abstratos, como matemática e linguagem. Uma coluna cortical é f undamentalmente um sistema para aprender modelos preditivos. Os modelos são aprendidos a partir de entradas e movimentos que levam a mudanças nas entradas. Modelos bem-sucedidos são aqueles que podem prever a próxima entrada, dado o estado atual e um movimento previsto. Contudo, as "entradas" e "movimentos" de uma coluna cortical não precisam corresponder a entidades físicas. A "entrada" para uma coluna pode originar-se da retina ou de outras regiões do neocórtex que já reconheceram um objeto visual, como uma palavra ou uma expressão matemática. Um " movimento" pode representar o movimento dos olhos ou pode representar um movimento abstrato, como um verbo ou um operador matemático.

O sucesso no aprendizado de um modelo preditivo requer a descoberta da dimensionalidade correta do espaço do objeto, aprendendo como os movimentos atualizam as localizações nesse espaço e associando recursos de entrada a localizações específicas no espaço do objeto. Esses atributos se aplicam tanto à percepção sensorial quanto ao pensamento de alto nível. Imagine uma c oluna tentando aprender o modelo de uma xícara usando informações visuais da retina e informações de movimento de um dedo. Isso falharia, pois a localização espaçada percorrida pelo dedo não seria mapeada no espaço de características do objeto, conforme evidenciado pelas mudanças nas entradas dos olhos. Da mesma forma, ao tentar entender um problema matemático, você pode falhar ao usar um operador para manipular uma equação, mas ter sucesso ao mudar para um operador diferente.

As células da grade no neocórtex sugerem que todo o conhecimento é aprendido e armazenado no contexto de locais e espaços de localização e que "pensar" é movimento através desses espaços de localização. Temos um longo caminho a percorrer a ntes de compreendermos os detalhes de como o neocórtex desempenha funções cognitivas, no entanto, acreditamos que a estrutura baseada na localização não estará apenas no centro das soluções para estes problemas, mas irá sugerir soluções.

CONCLUSÃO

Às vezes diz-se que a neurociência é "rica em dados e pobre em teoria". Esta noção é especialmente verdadeira para o neocórtex. Não nos faltam dados empíricos, mas sim um enquadramento teórico

that can bridge the gap between the heterogeneous capabilities of perception, cognition, and intelligence and the homogeneous circuitry observed in the neocortex. The closest we have to such a framework today is hierarchical feature extraction, which is widely recognized as insufficient.

One approach to developing a theory of neocortical function is to build in-silico models of a cortical column based on detailed anatomical data (Helmstaedter et al., 2007; Markram et al., 2015). This approach starts with anatomy and hopes to discover theoretical principles via simulation of a cortical column. We have used a different method. We start with a detailed function that we know the neocortex performs (such as sensory-motor learning and inference), we deduce neural mechanisms that are needed to perform those functions (such as cells that represent location), and then map those neural mechanisms onto detailed biological data.

Based on this method, this paper proposes a new framework for understanding how the neocortex works. We propose that grid cells are present everywhere in the neocortex. Cortical grid cells track the location of inputs to the neocortex in the reference frames of the objects being observed. We propose the existence of a new type of neuron, displacement cells, that complement grid cells, and are similarly present throughout the neocortex. The framework shows how it is possible that a small patch of cortex can represent and learn the morphology of objects, how objects are composed of other objects, and the behaviors of objects. The framework also leads to a new interpretation of how the neocortex works overall. Instead of processing input in a series of feature extraction steps leading to object recognition at the top of the hierarchy, the neocortex consists of 1000s of models operating in parallel as well as hierarchically.

Introspection can sometimes reveal basic truths that are missed by more objective experimental techniques. As we go about our day we perceive 1000s of objects, such as trees, printed and spoken words, buildings, and people. Everything is perceived at a location. As we attend to each object we perceive the distance and direction from ourselves to these objects, and we perceive where they are relative to each other. The sense of location and distance is inherent to perception, it occurs without effort or delay. It is self-evident that the brain must have neural representations for the locations of objects and for the distances between the objects as we attend to them in succession. The novelty of our claim is that these locations and distances are calculated everywhere in the neocortex, they are the principal data types of cortical function, perception, and intelligence.

AUTHOR CONTRIBUTIONS

JH, together with ML, MK, SP, and SA conceived of the overall theory and mapping to neuroscience. JH, together with SA, wrote the majority of the manuscript. ML, MK, and SP participated in writing, editing, and revising the manuscript.

FUNDING

Numenta is a privately held company. Its funding sources are independent investors and venture capitalists.

ACKNOWLEDGMENTS

We thank the reviewers for many helpful and detailed comments which have significantly improved the overall manuscript. We thank David Eagleman, Weinan Sun, Michael Hasselmo, and Mehmet Fatih Yanik for their feedback and help with this manuscript. We also thank numerous collaborators at Numenta over the years for many discussions, especially Donna Dubinsky, Christy Maver, Celeste Baranski, Luiz Scheinkman, and Teri Fry. We also note that a version of this paper has been posted to the preprint server bioRxiv (Hawkins et al., 2018).

SUPPLEMENTARY MATERIAL

The Supplementary Material for this article can be found online at: https://www.frontiersin.org/articles/10.3389/fncir.2018.00121/full#supplementary-material

REFERENCES

Ahmed, B., Anderson, J. C., Douglas, R. J., Martin, K. A., and Nelson, J. C. (1994). Polyneuronal innervation of spiny stellate neurons in cat visual cortex. *J. Comp. Neurol.* 341, 16–24. doi: 10.1002/cne.903410103

Ahmed, B., Anderson, J. C., Martin, K. A., and Nelson, J. C. (1997). Map of the synapses onto layer 4 basket cells of the primary visual cortex of the cat. *J. Comp. Neurol.* 380, 230–242. doi: 10.1002/(SICI)1096-9861(19970407)380:2<230::AID-CNE6>3.0.CO;2-4

Behrens, T. E. J., Muller, T. H., Whittington, J. C. R., Mark, S., Baram, A. B., Stachenfeld, K. L., et al. (2018). What is a cognitive map? Organizing knowledge for flexible behavior. *Neuron* 100, 490–509. doi: 10.1016/J.NEURON.2018.10.002

Bensmaia, S. J., Denchev, P. V., Dammann, J. F., Craig, J. C., and Hsiao, S. S. (2008). The representation of stimulus orientation in the early stages of somatosensory processing. *J. Neurosci.* 28, 776–786. doi: 10.1523/JNEUROSCI.4162-07.2008

Binzegger, T., Douglas, R. J., and Martin, K. A. C. (2004). A quantitative map of the circuit of cat primary visual cortex. *J. Neurosci.* 24, 8441–8453. doi: 10.1523/JNEUROSCI.1400-04.2004

Brandon, M. P., Bogaard, A. R., Libby, C. P., Connerney, M. A., Gupta, K., and Hasselmo, M. E. (2011). Reduction of theta rhythm dissociates grid cell spatial periodicity from directional tuning. *Science* 332, 595–599. doi: 10.1126/SCIENCE.1201652

Burak, Y., and Fiete, I. R. (2009). Accurate path integration in continuous attractor network models of grid cells. *PLoS Comput. Biol.* 5:e1000291. doi: 10.1371/journal.pcbi.1000291

Burgess, N. (2008). Grid cells and theta as oscillatory interference: theory and predictions. *Hippocampus* 18, 1157–1174. doi: 10.1002/hipo.20518

Burgess, N., Caswell, B., and O'Keefe, J. (2007). An oscillatory interference model of grid cell firing. *Hippocampus* 17, 801–812. doi: 10.1002/hipo

Bush, D., Barry, C., Manson, D., and Burgess, N. (2015). Using grid cells for navigation. *Neuron* 87, 507–520. doi: 10.1016/j.neuron.2015.07.006

que pode preencher a lacuna entre as capacidades heterogêneas de percepção, cognição e inteligência e os circuitos homogêneos observados no neocórtex. O mais próximo que temos de tal estrutura hoje é a extração hierárquica de características, que é amplamente reconhecida como insuficiente.

Uma abordagem para desenvolver uma teoria da função neocortical é construir modelos in-silico de coluna cortical com base em dados anatômicos detalhados (Helmstaedter et al., 2007; Markram et al., 2015). Esta abordagem começa com a anatomia e espera descobrir princípios teóricos através da simulação de uma coluna cortical. Usamos um método diferente. Começamos com uma função detalhada que sabemos que o neocórtex desempenha (como aprendizagem e inferência sensório-motora), deduzimos mecanismos neurais necessários para executar essas funções (como células que representam localização) e, em seguida, mapeamos esses mecanismos neurais em dados biológicos detalhados.

Com base neste método, este artigo propõe uma nova estrutura para a compreensão de como funciona o neocórtex. Propomos que as células da grade estejam presentes em todo o neocórtex. As células da grade cortical rastreiam a localização das entradas do neocórtex nos referenciais dos objetos que estão se ndo observados. Propomos a existência de um novo tipo de neurônio, as células de deslocamento, que complementam as células da grade e estão presentes de forma semelhante em todo o neocórtex. A estrutura mostra como é possível que um pequeno pedaço de córtex possa representar e aprender a morfologia dos objetos, como os objetos são compostos de outros objetos e os comportamentos dos objetos. A estrutura também leva a uma nova interpretação de como o neocórtex funciona em geral. Em vez de processar a entrada em uma série de etapas de extração de características que levam ao reconhecimento de objetos no topo da hierarquia, o neocórtex consiste em milhares de modelos operando em paralelo e também hierarquicamente.

A introspecção às vezes pode revelar verdades básicas que passam despercebidas por técnicas experimentais mais objetivas. À medida que passamos o dia, percebemos milhares de objetos, como árvores, palavras impressas e faladas, edifícios e pessoas. Tudo é percebido em um local. À medida que prestamos atenção a cada objeto, percebemos a distância e a direção de nós mesmos e m relação a esses objetos e percebemos onde eles estão em relação uns aos outros. A sensação de localização e distância é inerente à percepção, ocorre sem esforço ou atraso. É evidente que o cérebro deve ter representações neurais para a localização dos objetos e para as distâncias entre os objetos à medida que os observamos sucessivamente. A novidade da nossa afirmação é que essas localizações e distâncias são calculadas em todo o neocórtex, são os principais tipos de dados da função cortical, percepção e inteligência.

CONTRIBUIÇÕES DO AUTOR

JH, juntamente com ML, MK, SP e SA conceberam a teoria geral e o mapeamento para a neurociência. JH, juntamente com SA, escreveram a maior parte do manuscrito. ML, MK e SP participaram da redação, edição e revisão do manuscrito.

FINANCIAMENTO

Numenta é uma empresa privada. As suas fontes de financiamento são investidores independentes e capitalistas de risco.

AGRADECIMENTOS

Agradecemos aos revisores por muitos comentários úteis e detalhados que melhoraram significativamente o manuscrito geral. Agradecemos a David Eagleman, Weinan Sun, Michael Hasselmo e Mehmet Fatih Yanik pelos seus comentários e ajuda com este manuscrito. Agradecemos também a numerosos colaboradores da Numenta ao longo dos anos por muitas discussões, especialmente Donna Dubinsky, Christy Maver, Celeste Baranski, Luiz Scheinkman e Teri Fry. Observamos também que uma versão deste artigo foi publicada no servidor de pré-impressão bioRxiv (Hawkins et al., 2018).

MATERIAL SUPLEMENTAR

O material complementar deste artigo pode ser encontrado online em: https://www.frontiersin.org/articles/10.3389/fncir.2018.00121/completo#material suplementar

REFERÊNCIAS

Ahmed, B., Anderson, JC, Douglas, RJ, Martin, KA e Nelson, JC (1994). Inervação polineuronal de neurônios estrelados espinhosos no córtex visual de gatos. J. Comp. Neurol. 341, 16–24. doi: 10.1002/cne.903410103 Ahmed, B., Anderson, JC, Martin, KA e Nelson, JC (1997). Mapa das sinapses nas células da cesta da camada 4 do córtex visual primário do gato. J. Comp. Neurol. 380, 230–242. doi: 10.1002/(SICI)1096-9861(19970407)380: 2<230::AID-CNE6>3.0.CO;2-4 Behrens, TEJ, Muller, TH, Whittington, JCR, Mark, S., Baram, AB, Stachenfeld, KL, et al. (2018). O que é um mapa cognitivo? Organizando o conhecimento para um comportamento fl exível. Neurônio 100, 490–509. doi: 10.1016/J.NEURON.2018.10. 002 Bensmaia, SJ, Denchev, PV, Dammann, JF, Craig, JC e Hsiao, SS (2008). A representação da orientação do estímulo nos estágios iniciais do processamento somatossensorial. J. Neurosci. 28, 776–786. doi: 10.1523/JNEUROSCI.4162-07. 2008

Binzegger, T., Douglas, RJ e Martin, KAC (2004). Um mapa quantitativo do circuito do córtex visual primário do gato. J. Neurosci. 24, 8441–8453. doi: 10.1523/JNEUROSCI.1400-04.2004 Brandon, MP, Bogaard, AR, Libby, CP, Connerney, MA, Gupta, K., e Hasselmo, ME (2011). A redução do ritmo teta dissocia a periodicidade espacial das células da grade da sintonia direcional. Ciência 332, 595–599. doi: 10.1126/SCIENCE.1201652 Burak, Y., e Fiete, IR (2009). Integração precisa de caminhos em modelos de redes de atratores contínuos de células de grade. Computação PLoS. Biol. 5:e1000291. doi: 10.1371/journal.pcbi.1000291 Burgess, N. (2008). Células de grade e teta como interferência oscilatória: teoria e previsões. Hipocampo 18, 1157–1174. doi: 10.1002/hipo.2 0518 Burgess, N., Caswell, B., e O'Keefe, J. (2007). Um modelo de interferência oscilatória de disparo de células de grade. Hipocampo 17, 801–812. doi: 10.1002/hipo Bush, D., Barry, C., Manson, D. e Burgess, N. (2015). Usando células de grade para navegação. Neurônio 87, 507–520. doi: 10.1016/j.neuron.2015.07.006

Byrne, P., Becker, S., and Burgess, N. (2007). Remembering the past and imagining the future: a neural model of spatial memory and imagery. *Psychol. Rev.* 114, 340–375. doi: 10.1037/0033-295X.114.2.340

Clarke, J. M., and Zaidel, E. (1994). Anatomical-behavioral relationships: Corpus callosum morphometry and hemispheric specialization. *Behav. Brain Res.* 64, 185–202. doi: 10.1016/0166-4328(94)90131-7

Constantinescu, A. O., O'Reilly, J. X., and Behrens, T. E. J. (2016). Organizing conceptual knowledge in humans with a gridlike code. *Science* 352, 1464–1468. doi: 10.1126/science.aaf0941

Crick, F. (1984). Function of the thalamic reticular complex: the searchlight hypothesis. *Proc. Natl. Acad. Sci. U.S.A.* 81, 4586–4590. doi: 10.1073/pnas.81.14.4586

Crick, F. H. (1979). Thinking about the brain. *Sci. Am.* 241, 219–232. doi: 10.1038/scientificamerican0979-219

Deshmukh, S. S., and Knierim, J. J. (2013). Influence of local objects on hippocampal representations: landmark vectors and memory. *Hippocampus* 23, 253–267. doi: 10.1002/hipo.22101

Doeller, C. F., Barry, C., and Burgess, N. (2010). Evidence for grid cells in a human memory network. *Nature* 463, 657–661. doi: 10.1038/nature08704

Domnisoru, C., Kinkhabwala, A. A., and Tank, D. W. (2013). Membrane potential dynamics of grid cells. *Nature* 495, 199–204. doi: 10.1038/nature11973

Douglas, R. J., and Martin, K. A. C. (2004). Neuronal circuits of the neocortex. *Annu. Rev. Neurosci.* 27, 419–451. doi: 10.1146/annurev.neuro.27.070203.144152

Driver, J., and Noesselt, T. (2008). Multisensory interplay reveals crossmodal influences on 'sensory-specific' brain regions, neural responses, and judgments. *Neuron* 57, 11–23. doi: 10.1016/J.NEURON.2007.12.013

Erdem, U. M., and Hasselmo, M. E. (2014). A biologically inspired hierarchical goal directed navigation model. *J. Physiol. Paris* 108, 28–37. doi: 10.1016/j.jphysparis.2013.07.002

Felleman, D. J., and Van Essen, D. C. (1991). Distributed hierarchical processing in the primate cerebral cortex. *Cereb. Cortex* 1, 1–47. doi: 10.1093/cercor/1.1.1

Fiete, I. R., Burak, Y., and Brookings, T. (2008). What grid cells convey about rat location. *J. Neurosci.* 28, 6858–6871. doi: 10.1523/JNEUROSCI.5684-07.2008

Fuhs, M. C., and Touretzky, D. S. (2006). A spin glass model of path integration in rat medial entorhinal cortex. *J. Neurosci.* 10, 436–447. doi: 10.1523/jneurosci.4353-05.2006

Fukushima, K. (1980). Neocognitron: a self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position. *Biol. Cybern.* 36, 193–202. doi: 10.1007/BF00344251

Giocomo, L. M., Moser, M. B., and Moser, E. I. (2011). Computational models of grid cells. *Neuron* 71, 589–603. doi:10.1016/j.neuron.2011.07.023

Giocomo, L. M., Stensola, T., Bonnevie, T., Van Cauter, T., Moser, M.-B., and Moser, E. I. (2014). Topography of head direction cells in medial entorhinal cortex. *Curr. Biol.* 24, 252–262. doi: 10.1016/J.CUB.2013.12.002

Giocomo, L. M., Zilli, E. A., Fransén, E., and Hasselmo, M. E. (2007). Temporal frequency of subthreshold oscillations scales with entorhinal grid cell field spacing. *Science* 315, 1719–1722. doi: 10.1126/science.1139207

Goodale, M. A., and Milner, A. D. (1992). Separate visual pathways for perception and action. *Trends Neurosci.* 15, 20–25. doi: 10.1016/0166-2236(92)90344-8

Gu, Y., Lewallen, S., Kinkhabwala, A. A., Domnisoru, C., Yoon, K., Gauthier, J. L., et al. (2018). A map-like micro-organization of grid cells in the medial entorhinal cortex. *Cell* 175, 736–750.e30. doi: 10.1016/j.cell.2018.08.066

Guillery, R. W., and Sherman, S. M. (2002). The thalamus as a monitor of motor outputs. *Philos. Trans. R. Soc. B Biol. Sci.* 357, 1809–1821. doi: 10.1098/rstb.2002.1171

Guillery, R. W., and Sherman, S. M. (2011). Branched thalamic afferents: what are the messages that they relay to the cortex? *Brain Res. Rev.* 66, 205–219. doi: 10.1016/j.brainresrev.2010.08.001

Hafting, T., Fyhn, M., Molden, S., Moser, M.-B., and Moser, E. I. (2005). Microstructure of a spatial map in the entorhinal cortex. *Nature* 436, 801–806. doi: 10.1038/nature03721

Hardcastle, K., Ganguli, S., and Giocomo, L. M. (2017). Cell types for our sense of location: where we are and where we are going. *Nat. Neurosci.* 20, 1474–1482. doi: 10.1038/nn.4654

Hasselmo, M. (2012). *How we Remember: Brain Mechanisms of Episodic Memory*. Cambridge, MA: MIT Press.

Hasselmo, M. E. (2008). Grid cell mechanisms and function: contributions of entorhinal persistent spiking and phase resetting. *Hippocampus* 18, 1213–1229. doi: 10.1002/hipo.20512

Hasselmo, M. E. (2009). A model of episodic memory: mental time travel along encoded trajectories using grid cells. *Neurobiol. Learn. Mem.* 92, 559–573. doi: 10.1016/j.nlm.2009.07.005

Hasselmo, M. E., and Brandon, M. P. (2012). A model combining oscillations and attractor dynamics for generation of grid cell firing. *Front. Neural Circuits* 6:30. doi: 10.3389/fncir.2012.00030

Hasselmo, M. E., Giocomo, L. M., Brandon, M. P., and Yoshida, M. (2010). Cellular dynamical mechanisms for encoding the time and place of events along spatiotemporal trajectories in episodic memory. *Behav. Brain Res.* 215, 261–274. doi: 10.1016/j.bbr.2009.12.010

Hawkins, J., and Ahmad, S. (2016). Why neurons have thousands of synapses, a theory of sequence memory in neocortex. *Front. Neural Circuits* 10:23. doi: 10.3389/fncir.2016.00023

Hawkins, J., Ahmad, S., and Cui, Y. (2017). A theory of how columns in the neocortex enable learning the structure of the world. *Front. Neural Circuits* 11:81. doi: 10.3389/FNCIR.2017.00081

Hawkins, J., and Blakeslee, S. (2004). *On Intelligence*. New York, NY: Times Books.

Hawkins, J., Lewis, M., Klukas, M., Purdy, S., and Ahmad, S. (2018). A framework for intelligence and cortical function based on grid cells in the neocortex. *bioRxiv* [Preprint]. doi: 10.1101/442418

Helmstaedter, M., de Kock, C. P. J., Feldmeyer, D., Bruno, R. M., and Sakmann, B. (2007). Reconstruction of an average cortical column in silico. *Brain Res. Rev.* 55, 193–203. doi: 10.1016/J.BRAINRESREV.2007.07.011

Hsiao, S. S., Lane, J., and Fitzgerald, P. (2002). Representation of orientation in the somatosensory system. *Behav. Brain Res.* 135, 93–103. doi: 10.1016/S0166-4328(02)00160-2

Jacobs, J., Weidemann, C. T., Miller, J. F., Solway, A., Burke, J. F., Wei, X. X., et al. (2013). Direct recordings of grid-like neuronal activity in human spatial navigation. *Nat. Neurosci.* 16, 1188–1190. doi: 10.1038/nn.3466

Julian, J. B., Keinath, A. T., Frazzetta, G., and Epstein, R. A. (2018). Human entorhinal cortex represents visual space using a boundary-anchored grid. *Nat. Neurosci.* 21, 191–194. doi: 10.1038/s41593-017-0049-1

Kim, J., Matney, C. J., Blankenship, A., Hestrin, S., and Brown, S. P. (2014). Layer 6 corticothalamic neurons activate a cortical output layer, layer 5a. *J. Neurosci.* 34, 9656–9664. doi: 10.1523/JNEUROSCI.1325-14.2014

Komorowski, R. W., Manns, J. R., and Eichenbaum, H. (2009). Robust conjunctive item-place coding by hippocampal neurons parallels learning what happens where. *J. Neurosci.* 29, 9918–9929. doi: 10.1523/JNEUROSCI.1378-09.2009

Kropff, E., Carmichael, J. E., Moser, M.-B., and Moser, E. I. (2015). Speed cells in the medial entorhinal cortex. *Nature* 523, 419–424. doi: 10.1038/nature14622

Lashley, K. S. (1951). "The problem of serial order in behavior." in *Cerebral Mechanisms in Behavior; the Hixon Symposium*, ed. L. A. Jeffres (New York, NY: Wiley), 112–131.

LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *Nature* 521, 436–444. doi: 10.1038/nature14539

Leinweber, M., Ward, D. R., Sobczak, J. M., Attinger, A., and Keller, G. B. (2017). A sensorimotor circuit in mouse cortex for visual flow predictions. *Neuron* 95, 1420–1432.e5. doi: 10.1016/j.neuron.2017.08.036

Lever, C., Burton, S., Jeewajee, A., O'Keefe, J., and Burgess, N. (2009). Boundary vector cells in the subiculum of the hippocampal formation. *J. Neurosci.* 29, 9771–9777. doi: 10.1523/JNEUROSCI.1319-09.2009

Lewis, M., Purdy, S., Ahmad, S., and Hawkins, J. (2018). Locations in the neocortex: a theory of sensorimotor object recognition using cortical grid cells. *bioRxiv* [Preprint]. doi: 10.1101/436352

Long, X., and Zhang, S.-J. (2018). A novel somatosensory spatial navigation system outside the hippocampal formation. *bioRxiv* [Preprint]. doi: 10.1101/473090

Lotter, W., Kreiman, G., and Cox, D. (2018). A neural network trained to predict future video frames mimics critical properties of biological neuronal responses and perception. *arXiv* [Preprint]. arXiv:1805.10734

Markov, N. T., Vezoli, J., Chameau, P., Falchier, A., Quilodran, R., Huissoud, C., et al. (2014). Anatomy of hierarchy: feedforward and feedback pathways in macaque visual cortex. *J. Comp. Neurol.* 522, 225–259. doi: 10.1002/cne.23458

Markram, H., Muller, E., Ramaswamy, S., Reimann, M. W., Abdellah, M., Sanchez, C. A., et al. (2015). Reconstruction and simulation of neocortical microcircuitry. *Cell* 163, 456–492. doi: 10.1016/j.cell.2015.09.029

Byrne, P., Becker, S. e Burgess, N. (2007). Lembrando o passado e imaginando o futuro: um modelo neural de memória espacial e imagens. Psicol. Rev. faça: . / - X. . . Clarke, J M e Zaidel, E. (1994). Relações anátomo-comportamentais: Morfometria do corpo caloso e especialização hemisférica. Comporte-se. Cérebro Res. 64, 185 202 10 1016 0166 4328 94 90131 7 – . faça: . / - ( ) - Constantinescu, A. O., O'Reilly, J. X., e Behrens, T. E. J. (2016). Organizando o conhecimento conceitual em humanos com um código semelhante a uma grade. Ciência 352, 1464–1468. doi: 10.1126/science.aaf0941 Crick, F. (1984). Função do complexo reticular talâmico: a hipótese do holofote. Processo. Nacional. Acad. Ciência. EUA 81, 4586–4590. doi: 10.1073/pnas.81. 14.4586 Crick, FH (1979). Pensando no cérebro. Ciência. Sou. 241, 219–232. doi: 10.1038/cientificamerican0979-219 Deshmukh, SS e Knierim, JJ (2013). Influência de objetos locais nas representações do hipocampo: vetores de referência e memória. Hipocampo 23, 253 267 10 1002 22101 – . faça: . /hipo. Doeller, CF, Barry, C. e Burgess, N. (2010). Evidência de células de grade em uma rede de memória humana. Natureza 463, 657–661. doi: 10.1038/nature08704 Domnisoru, C., Kinkhabwala, AA, e Tank, DW (2013). Dinâmica do potencial de membrana das células da grade. Natureza 495, 199–204. doi: 10.1038/nature11973 Douglas, RJ e Martin, KAC (2004). Circuitos neuronais do neocórtex. Anu. Rev. 27, 419–451. doi: 10.1146/annurev.neuro.27.070203. 144152 Driver, J. e Noeselt, T. (2008). A interação multissensorial revela influências transmodais em regiões cerebrais, respostas neurais e julgamentos "específicos dos sentidos". Neurônio 57, 11–23. doi: 10.1016/J.NEURON.2007.12.013 Erdem, UM, e Hasselmo, ME (2014). Um modelo de navegação hierárquica dirigida por objetivos de inspiração biológica. J. Fisiol. Paris 108, 28–37. doi: 10.1016/j.jphysparis. 2013.07.002 Felleman, DJ e Van Essen, DC (1991). Processamento hierárquico distribuído no córtex cerebral de primatas. Cerebe. Córtex 1, 1–47. doi: 10.1093/cercor/1.1.1 Fiete, IR, Burak, Y., e Brookings, T. (2008). O que as células da grade transmitem sobre a localização dos ratos. J. Neurosci. 28, 6858–6871. doi: 10.1523/JNEUROSCI.5684-07.2008 Fuhs, MC e Touretzky, DS (2006). Um modelo de spin glass de integração de caminhos no córtex entorrinal medial de ratos. J. Neurosci. 10, 436–447. doi: 10.1523/jneurosci. 4353-05.2006 Fukushima, K. (1980). Neocognitron: um modelo de rede neural auto-organizada para um mecanismo de reconhecimento de padrões não afetado pela mudança de posição. Biol. Cibernético. 36, 193–202. doi: 10.1007/BF00344251 Giocomo, LM, Moser, MB, e Moser, EI (2011). Modelos computacionais de células de grade. Neurônio 71, 589–603. doi:10.1016/j.neuron.2011. 07.023 Giocomo, L. M., Stensola, T., Bonnevie, T., Van Cauter, T., Moser, MB-B., e Moser, E. I. (2014). Topografia das células de direção da cabeça no córtex entorrinal medial. Curr. Biol. 24, 252–262. doi: 10.1016/J.CUB.2013.12.002 Giocomo, LM, Zilli, EA, Fransén, E. e Hasselmo, ME (2007). Frequência temporal de escalas de oscilações subliminares com espaçamento de campo de células da grade entorrinal. Ciência 315, 1719–1722. doi: 10.1126/science.1139207 Goodale, MA e Milner, AD (1992). Caminhos visuais separados para percepção e ação. Tendências Neurosci. 15, 20–25. doi: 10.1016/0166-2236(92)90344-8 Gu, Y., Lewallen, S., Kinkhabwala, AA, Domnisoru, C., Yoon, K., Gauthier, JL, et al. (2018). Uma microorganização semelhante a um mapa de células de grade no córtex entorrinal medial. Célula 175, 736–750.e30. doi: 10.1016/j.cell.2018.08.066 Guillery, RW e Sherman, SM (2002). O tálamo como monitor das saídas motoras. Filós. Trad. R.Soc. B Biol. Ciência. 357, 1809–1821. doi: 10.1098/rstb. 2002.1171 Guillery, RW e Sherman, SM (2011). Aferentes talâmicos ramificados: quais são as mensagens que transmitem ao córtex? Cérebro Res. Apocalipse 66, 205–219. doi: 10.1016/j.brainresrev.2010.08.001 Hafting, T., Fyhn, M., Molden, S., Moser, MB.-B., e Moser, E. I. (2005). Microestrutura de um mapa espacial no córtex entorrinal. Natureza 436, 801–806. doi: 10.1038/nature03721 Hardcastle, K., Ganguli, S. e Gioco mo, LM (2017). Tipos de células para nosso senso de localização: onde estamos e para onde vamos. Nat. Neurosci. 20, 1474–1482. doi: 10.1038/nn.4654 Hasselmo, M. (2012). Como lembramos: mecanismos cerebrais de memória episódica. Cambridge, MA: MIT Press.

Hasselmo, ME (2008). Mecanismos e função das células da grade: contribuições do aumento persistente entorrinal e da redefinição de fase. Hipocampo 18, 1213–1229. doi: 10.1002/hipo.20512 Hasselmo, ME (2009). Um modelo de memória episódica: viagem mental no tempo ao longo de trajetórias codificadas usando células de grade. Neurobiol. Aprender. Mem. 92, 559–573. doi: 10.1016/j.nlm.2009.07.005 Hasselmo, ME e Brandon, MP (2012). Um modelo que combina oscilações e dinâmica de atratores para geração de disparo de células de grade. Frente. Circuitos Neurais 6:30. doi: 10.3389/fncir.2012.00030 Hasselmo, ME, Giocomo, LM, Brandon, MP e Yoshida, M. (2010). Mecanismos dinâmicos celulares para codificar o tempo e o local dos eventos ao longo das trajetórias espaço-temporais na memória episódica. Comporte-se. Cérebro Res. 215, 261–274. doi: 10.1016/j.bbr.2009.12.010 Hawkins, J. e Ahmad, S. (2016). Por que os neurônios têm milhares de sinapses, uma teoria da memória sequencial no neocórtex. Frente. Circuitos Neurais 10:23. doi: 10.3389/fncir.2016.00023 Hawkins, J., Ahmad, S. e Cui, Y. (2017). Uma teoria de como as colunas do neocórtex permitem aprender a estrutura do mundo. Frente. Circuitos Neurais 11:81. doi: 10.3389/FNCIR.2017.00081 Hawkins, J. e Blakeslee, S. (2004). Sobre Inteligência. Nova York, NY: Times Books. Hawkins, J., Lewis, M., Klukas, M., Purdy, S. e Ahmad, S. (2018). Uma estrutura para inteligência e função cortical baseada em células de grade no neocórtex. bioRxiv [Pré-impressão]. doi: 10.1101/442418 Helmstaedter, M., de Kock, CPJ, Feldmeyer, D., Bruno, RM, e Sakmann, B. (2007). Reconstrução de coluna cortical média in silico. Cérebro Res. Apocalipse 55, 193–203. doi: 10.1016/J.BRAINRESREV.2007.07.011 Hsiao, SS, Lane, J. e Fitzgerald, P. (2002). Representação da orientação no sistema somatossensorial. Comporte-se. Cérebro Res. 135, 93–103. doi: 10.1016/S0166- 4328(02)00160-2 Jacobs, J., Weidemann, CT, Miller, J.F., Solway, A., Burke, J.F., Wei, X.X., et al. (2013). Gravações diretas de atividade neuronal semelhante a uma grade na navegação espacial humana. Nat. Neurosci. 16, 1188–1190. doi: 10.1038/nn.3466 Julian, JB, Keinath, AT, Frazzetta, G. e Epstein, RA (2018). O córtex entorrinal humano representa o espaço visual usando uma grade ancorada em limites. Nat. Neurosci. 21, 191–194. doi: 10.1038/s41593-017-0049-1 Kim, J., Matney, CJ, Blankenship, A., Hestrin, S., e Brown, SP (2014). Os neurônios corticotalâmicos da camada 6 ativam uma camada de saída cortical, a camada 5a. J. Neurosci. 34, 9656–9664. doi: 10.1523/JNEUROSCI.1325-14.2014 Komorowski, RW, Manns, JR e Eichenbaum, H. (2009). A codificação conjuntiva robusta de item-lugar por neurônios do hipocampo é paralela ao aprendizado do que acontece e onde. J. Neurosci. 29, 9918–9929. doi: 10.1523/JNEUROSCI.1378-09.2009 Kropff, E., Car michael, JE, Moser, M.-B., e Moser, E. I. (2015). Células de velocidade no córtex entorrinal medial. Natureza 523, 419–424. doi: 10.1038/nature14622 Lashley, KS (1951). "O problema da ordem serial no comportamento." em Mecanismos Cerebrais no Comportamento; o Simpósio Hixon, ed. LA Jeffres (Nova York, NY: Wiley), 112–131. LeCun, Y., Bengio, Y. e Hinton, G. (2015). Aprendizagem profunda. Natureza 521, 436–444. doi: 10.1038/nature14539 Leinweber, M., Ward, DR, Sobczak, JM, Attinger, A., e Keller, GB (2017). Um circuito sensório-motor no córtex de camundongos para previsões visuais de fluxo. Neurônio 95, 1420 1432 5 10 1016 2017 08 036 – .e . faça: . / j.neurônio. . . Lever, C., Burton, S., Jeewajee, A., O'Keefe, J., e Burgess, N. (2009). Células vetoriais limite no subículo da formação do hipocampo. J. Neurosci. 29, 9771 9777 10 1523 1319 09 2009 – . faça: . /JNEUROSCI. - . Lewis, M., Purdy, S., Ahmad, S. e Hawkins, J. (2018). Locais no neocórtex: uma teoria de reconhecimento sensório-motor de objetos usando células da grade cortical. bioRxiv [Pré-impressão]. doi: 10.1101/436352 Long, X. e Zhang, S.-J. (2018). Um novo sistema de navegação espacial somatossensorial fora da formação do hipocampo. bioRxiv [Pré-impressão]. doi: 10.1101/473090 Lotter, W., Kreiman, G. e Cox, D. (2018). Uma rede neural trei nada para prever quadros de vídeo futuros imita propriedades críticas de respostas e percepção neuronal biológica. arXiv [Pré-impressão]. arXiv:1805.10734 Markov, NT, Vezoli, J., Chameau, P., Falchier, A., Quilodran, R., Huissoud, C., et al. (2014). Anato mia da hierarquia: vias de feedforward e feedback no córtex visual de macacos. J. Comp. Neurol. 522, 225–259. doi: 10.1002/cne.23458 Markram, H., Muller, E., Ramaswamy, S., Reimann, MW, Abdellah, M., Sanchez, CA, et al. (2015). Reconstrução e simulação de microcircuitos neocorticais. Cela 163, 456–492. doi: 10.1016/j.cell.2015.09.029

Marozzi, E., Ginzberg, L. L., Alenda, A., and Jeffery, K. J. (2015). Purely translational realignment in grid cell firing patterns following nonmetric context change. *Cereb. Cortex* 25, 4619–4627. doi: 10.1093/cercor/bhv120

McAlonan, K., Cavanaugh, J., and Wurtz, R. H. (2006). Attentional modulation of thalamic reticular neurons. *J. Neurosci.* 26, 4444–4450. doi: 10.1523/JNEUROSCI.5602-05.2006

McGuire, B. A., Hornung, J. P., Gilbert, C. D., and Wiesel, T. N. (1984). Patterns of synaptic input to layer 4 of cat striate cortex. *J. Neurosci.* 4, 3021–3033. doi: 10.1523/JNEUROSCI.04-12-03021.1984

McNaughton, B. L., Battaglia, F. P., Jensen, O., Moser, E. I., and Moser, M.-B. (2006). Path integration and the neural basis of the "cognitive map". *Nat. Rev. Neurosci.* 7, 663–678. doi: 10.1038/nrn1932

Moser, E. I., Kropff, E., and Moser, M.-B. (2008). Place cells, grid cells, and the brain's spatial representation system. *Annu. Rev. Neurosci.* 31, 69–89. doi: 10.1146/annurev.neuro.31.061307.090723

Mountcastle, V. (1978). "An organizing principle for cerebral function: the unit model and the distributed system," in *The Mindful Brain*, eds G. Edelman and V. Mountcastle (Cambridge, MA: MIT Press), 7–50.

Nelson, A., Schneider, D. M., Takatoh, J., Sakurai, K., Wang, F., and Mooney, R. (2013). A circuit for motor cortical modulation of auditory cortical activity. *J. Neurosci.* 33, 14342–14353. doi: 10.1523/JNEUROSCI.2275-13.2013

O'Keefe, J., and Burgess, N. (2005). Dual phase and rate coding in hippocampal place cells: theoretical significance and relationship to entorhinal grid cells. *Hippocampus* 15, 853–866. doi: 10.1002/hipo.20115

O'Keefe, J., and Dostrovsky, J. (1971). The hippocampus as a spatial map. Preliminary evidence from unit activity in the freely-moving rat. *Brain Res.* 34, 171–175. doi: 10.1016/0006-8993(71)90358-1

O'Keefe, J., and Nadel, L. (1978). *The Hippocampus as a Cognitive Map*. Oxford: Oxford University Press. doi: 10.1017/CBO9781107415324.004

Pruszynski, J. A., and Johansson, R. S. (2014). Edge-orientation processing in first-order tactile neurons. *Nat. Neurosci.* 17, 1404–1409. doi: 10.1038/nn.3804

Rao, R. P. N., and Ballard, D. H. (1999). Predictive coding in the visual cortex: a functional interpretation of some extra-classical receptive-field effects. *Nat. Neurosci.* 2, 79–87. doi: 10.1038/4580

Raudies, F., Hinman, J. R., and Hasselmo, M. E. (2016). Modelling effects on grid cells of sensory input during self-motion. *J. Physiol.* 594, 6513–6526. doi: 10.1113/JP270649

Rauschecker, J. P. (2015). Auditory and visual cortex of primates: a comparison of two sensory systems. *Eur. J. Neurosci.* 41, 579–585. doi: 10.1111/ejn.12844

Riesenhuber, M., and Poggio, T. (1999). Hierarchical models of object recognition in cortex. *Nat. Neurosci.* 2, 1019–1025. doi: 10.1038/14819

Rowland, D. C., and Moser, M. B. (2014). From cortical modules to memories. *Curr. Opin. Neurobiol.* 24, 22–27. doi: 10.1016/j.conb.2013.08.012

Rowland, D. C., Roudi, Y., Moser, M.-B., and Moser, E. I. (2016). Ten years of grid cells. *Annu. Rev. Neurosci.* 39, 19–40. doi: 10.1146/annurev-neuro-070815-013824

Rowland, D. C., Weible, A. P., Wickersham, I. R., Wu, H., Mayford, M., Witter, M. P., et al. (2013). Transgenically targeted rabies virus demonstrates a major monosynaptic projection from hippocampal area CA2 to medial entorhinal layer II neurons. *J. Neurosci.* 33, 14889–14898. doi: 10.1523/JNEUROSCI.1046-13.2013

Sargolini, F., Fyhn, M., Hafting, T., McNaughton, B. L., Witter, M. P., Moser, M. B., et al. (2006). Conjunctive representation of position, direction, and velocity in entorhinal cortex. *Science* 312, 758–762. doi: 10.1126/science.1125572

Schmidt-Hieber, C., Toleikyte, G., Aitchison, L., Roth, A., Clark, B. A., Branco, T., et al. (2017). Active dendritic integration as a mechanism for robust and precise grid cell firing. *Nat. Neurosci.* 20, 1114–1121. doi: 10.1038/nn.4582

Schroeder, C. E., and Foxe, J. (2005). Multisensory contributions to low-level, "unisensory" processing. *Curr. Opin. Neurobiol.* 15, 454–458. doi: 10.1016/j.conb.2005.06.008

Sherman, S., and Guillery, R. (2013). *Thalamocortical Processing: Understanding the Messages that Link the Cortex to the World*. Cambridge, MA: MIT Press.

Sherman, S. M., and Guillery, R. W. (2011). Distinct functions for direct and transthalamic corticocortical connections. *J. Neurophysiol.* 106, 1068–1077. doi: 10.1152/jn.00429.2011

Sreenivasan, S., and Fiete, I. (2011). Grid cells generate an analog error-correcting code for singularly precise neural computation. *Nat. Neurosci.* 14, 1330–1337. doi: 10.1038/nn.2901

Stensola, H., Stensola, T., Solstad, T., Frøland, K., Moser, M. B., and Moser, E. I. (2012). The entorhinal grid map is discretized. *Nature* 492, 72–78. doi: 10.1038/nature11649

Suter, B. A., and Shepherd, G. M. G. (2015). Reciprocal interareal connections to corticospinal neurons in mouse M1 and S2. *J. Neurosci.* 35, 2959–2974. doi: 10.1523/JNEUROSCI.4287-14.2015

Taube, J. S., Muller, R. U., and Ranck, J. B. (1990). Head-direction cells recorded from the postsubiculum in freely moving rats. I. Description and quantitative analysis. *J. Neurosci.* 10, 420–435. doi: 10.1212/01.wnl.0000299117.48935.2e

Thomson, A. M. (2010). Neocortical layer 6, a review. *Front. Neuroanat.* 4:13. doi: 10.3389/fnana.2010.00013

Ungerleider, L. G., and Haxby, J. V. (1994). "What" and "where" in the human brain. *Curr. Opin. Neurobiol.* 4, 157–165. doi: 10.1016/0959-4388(94)90066-3

Winter, S. S., Clark, B. J., and Taube, J. S. (2015). Disruption of the head direction cell network impairs the parahippocampal grid cell signal. *Science* 347, 870–874. doi: 10.1126/science.1259591

Zhang, S.-J., Ye, J., Miao, C., Tsao, A., Cerniauskas, I., Ledergerber, D., et al. (2013). Optogenetic dissection of entorhinal-hippocampal functional connectivity. *Science* 340:1232627. doi: 10.1126/science.1232627

Conflict of Interest Statement: JH, ML, MK, SP, and SA were employed by Numenta, Inc. Numenta has some patents relevant to the work. Numenta has stated that use of its intellectual property, including all the ideas contained in this work, is free for non-commercial research purposes. In addition Numenta has released all pertinent source code as open source under an AGPL V3 license (which includes a patent peace provision).

Copyright © 2019 Hawkins, Lewis, Klukas, Purdy and Ahmad. This is an open-access article distributed under the terms of the Creative Commons Attribution License (CC BY). The use, distribution or reproduction in other forums is permitted, provided the original author(s) and the copyright owner(s) are credited and that the original publication in this journal is cited, in accordance with accepted academic practice. No use, distribution or reproduction is permitted which does not comply with these terms.

Marozzi, E., Ginzberg, LL, Alenda, A. e Jeffery, KJ (2015). Realinhamento puramente translacional em padrões de disparo de células da grade após mudança de contexto não métrica. Cerebe. Córtex 25, 4619–4627. doi: 10.1093/cercor/bhv120 McAlonan, K., Cavanaugh, J., e Wurtz, RH (2006). Modulação atencional de neurônios reticulares talâmicos. J. Neurosci. 26, 4444–4450. doi: 10.1523/ JNEUROSCI.5602-05.2006 McGuire, BA, Hornung, JP, Gilbert, CD e Wiesel, TN (1984). Padrões de entrada sináptica para a camada 4 do córtex estriado do gato. J. Neurosci. 4, 3021–3033. doi: 10.1523/JNEUROSCI.04-12-03021.1984 McNaughton, BL, Battaglia, FP, Jensen, O., Moser, EI, e Moser, M.-B. (2006). Integração de caminhos e a base neural do "mapa cognitivo". Nat. Rev. 7, 663–678. doi: 10.1038/nrn1932 Moser, E. I., Kropff, E., e Moser, M.-B. (2008). Coloque células, células de grade e o sistema de representação espacial do cérebro. Anu. Rev. 31, 69–89. doi: 10.1146/annurev.neuro.31.061307.090723 Mountcastle, V. (1978). "Um princípio organizador para a função cerebral: o modelo unitário e o sistema distribuído", em The Mindful Brain, eds G. Edelman e V. Mountcastle (Cambridge, MA: MIT Press), 7–50. Nelson, A., Schneider, DM, Takatoh, J., Sakurai, K., Wang, F. e Mooney, R. (2013). Um circuito para modulação cortical motora da atividade cortical auditiva. J. Neurosci. 33, 14342–14353. doi: 10.1523/JNEUROSCI.2275-13.2013 O'Keefe, J., e Burgess, N. (2005). Codificação de fase dupla e taxa em células locais do hipocampo: significado teórico e relação com células da grade entorrinal. Hipocampo 15, 853–866. doi: 10.1002/hipo.20115 O'Keefe, J., e Dostrovsky, J. (1971). O hipocampo como mapa espacial. Evidência preliminar da atividade unitária no rato que se move livremente. Cérebro Res. 34, 171 175 10 1016 0006 8993 71 90358 1 – . faça: . / - ( ) - O'Keefe, J., e Nadel, L. (1978). O hipocampo como mapa cognitivo. Oxford: Imprensa da Universidade de Oxford. doi: 10.1017/CBO9781107415324.004 Pruszynski, JA, e Johansson, RS (2014). Processa mento de orientação de borda em neurônios táteis de primeira ordem. Nat. Neurosci. 17, 1404–1409. doi: 10.1038/nn.3804 Rao, RPN e Ballard, DH (1999). Codificação preditiva no córtex visual: uma interpretação funcional de alguns efeitos extraclássicos do campo receptivo. Nat. Neurosci. 2, 79–87. doi: 10.1038/4580 Raudies, F., Hinman, JR e Hasselmo, ME (2016). Efeitos de modelagem nas células da grade de entrada sensorial durante o movimento próprio. J. Fisiol. 594, 6513–6526. doi: 10.1113/JP270649 Rauschecker, JP (2015). Córtex auditivo e visual de primatas: uma comparação de dois sistemas sensoriais. EUR. J. Neurosci. 41, 579–585. doi: 10.1111/ejn.12844 Riesenhuber, M., e Poggio, T. (1999). Modelos hierárquicos de reconhecimento de objetos no córtex. Nat. Neurosci. 2, 1019–1025. doi: 10.1038/14819 Rowland, DC, e Moser, MB (2014). Dos módulos corticais às memórias. Curr. Opinião. Neurobiol. 24, 22–27. doi: 10.1016/j.conb.2013.08.012 Rowland, DC, Roudi, Y., Moser, MB, e Moser, EI (2016). Dez anos de células de grade. Anu. Rev. 39, 19–40. doi: 10.1146/annurev-neuro-070815-013824 Rowland, DC, Weible, AP, Wickersham, IR, Wu, H., Mayford, M., Witter, MP, et al. (2013). O vírus da raiva direcionado transgenicamente demonstra uma grande projeção monossináptica da área CA2 do hipocampo para os neurônios da camada entorrinal medial II. J. Neurosci. 33, 14889–14898. doi: 10.1523/JNEUROSCI.1046- 13.2013

Sargolini, F., Fyhn, M., Hafting, T., McNaughton, BL, Witter, MP, Moser, MB, et al. (2006). Representação conjuntiva de posição, direção e velocidade no córtex entorrinal. Ciência 312, 758–762. doi: 10.1126/science.1125572 Schmidt-Hieber, C., Toleikyte, G., Aitchison, L., Roth, A., Clark, BA, Branco, T., et al. (2017). Integração dendrítica ativa como mecanismo para disparo robusto e preciso de células de grade. Nat. Neurosci. 20, 1114–1121. doi: 10.1038/nn.4582 Schroeder, CE, e Foxe, J. (2005). Contribuições multissensoriais para o processamento "unissensorial" de baixo nível. Curr. Opinião. Neurobiol. 15, 454–458. doi: 10.1016/j. conb.2005.06.008 Sherman, S. e Guillery, R. (2013). Processamento Talamocortical: Compreendendo as Mensagens que Ligam o Córtex ao Mundo. Cambridge, MA: MIT Press. Sherman, SM e Guillery, RW (2011). Funções distintas para conexões corticocorticais diretas e transtalâmicas. J. Neurofisiol. 106, 1068–1077. doi: 10.1152/jn.00429.2011 Sreenivasan, S. e Fiete, I. (2011). As células da grade geram um código analógico de correção de erros para computação neural singularmente precisa. Nat. Neurosci. 14, 1330–1337. doi: 10.1038/nn.2901 Stensola, H., Stensola, T., Solstad, T., Frøland, K., Moser, MB, e Moser, EI (2012). O mapa da grade entorrinal é discretizado. Natureza 492, 72–78. doi: 10.1038/nature11649 Suter, BA, e Shepherd, GMG (2015). Conexões interareas recíprocas com neurônios corticospinais em camundongos M1 e S2. J. Neurosci. 35, 2959–2974. doi: 10.1523/JNEUROSCI.4287-14.2015 Taube, JS, Muller, RU, e Ranck, JB (1990). Células de direção da cabeça registradas no pós-subículo em ratos que se movem livremente. I. Descrição e análise quantitativa. J. Neurosci. 10, 420–435. doi: 10.1212/01.wnl.0000299117.48935.2e Thomson, AM (2010). Camada neocortical 6, u ma revisão. Frente. Neuroanato. 4:13. doi: 10.3389/fnana.2010.00013 Ungerleider, LG e Haxby, JV (1994). "O quê" e "onde" no cérebro humano. Curr. Opinião. Neurobiol. 4, 157–165. doi: 10.1016/0959-4388(94)90066-3 Winter, SS, Clark, BJ, e Taube, JS (2015). A interrupção da rede celular de direção da cabeça prejudica o sinal das células da grade parahipocampal. Ciência 347, 870–874. doi: 10.1126/science.1259591 Zhang, S.-J., Ye, J., Miao, C., Tsao, A., Cerniauskas, I., Ledergerber, D., et al. (2013). Dissecção optogenética da conectividade funcional entorrinal-hipocampal. Ciência 340:1232627. doi: 10.1126/science.1232627

Declaração de conflito de interesses: JH, ML, MK, SP e SA foram empregados da Numenta, Inc. A Numenta possui algumas patentes relevantes para o trabalho. A Numenta declarou que o uso de sua propriedade intelectual, incluindo todas as ideias contidas neste trabalho, é gratuito para fins de pesquisa não comercial. Além disso, a Numenta lançou todo o código-fonte pertinente como código-fonte aberto sob uma licença AGPL V3 (que inclui uma cláusula de paz de patente).

Direitos autorais © 2019 Hawkins, Lewis, Klukas, Purdy e Ahmad. Este é um artigo de acesso aberto distribuído sob os termos da Licença Creative Commons Attribution (CC BY). O uso, distribuição ou reprodução em outros fóruns é permitido, desde que o(s) autor(es) original(is) e o(s) proprietário(s) dos direitos autorais sejam creditados e que a publicação original nesta revista seja citada, de acordo com a prática acadêmica aceita. Não é permitido uso, distribuição ou reprodução que não esteja em conformidade com estes termos.